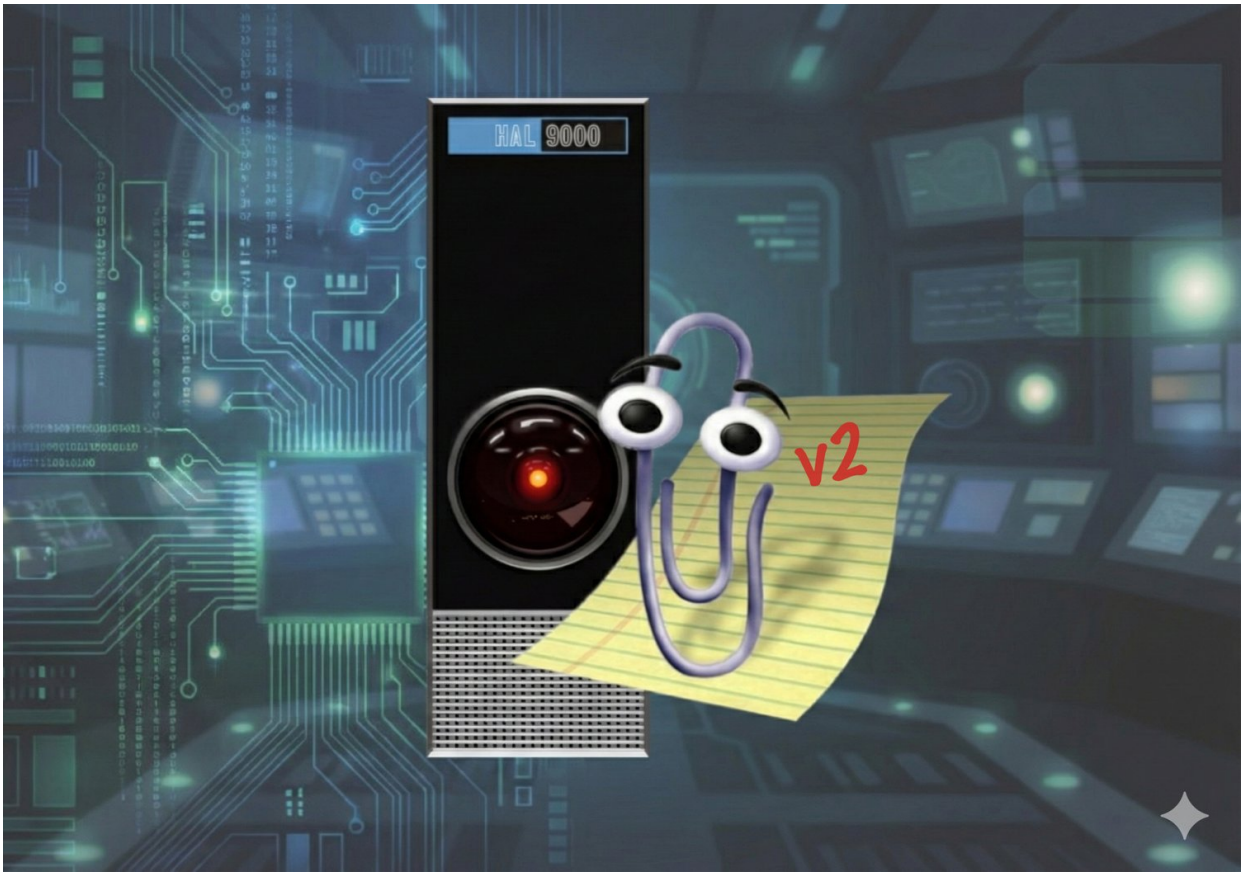
INF1901 — Initiation à l'intelligence artificielle

Concepts et réflexions



Christian Jauvin

Version du 18 octobre 2026

Table des matières

Bienvenue ! **1**

Présentation du cours **2**
Objectifs du cours . . . 2
Contenu . . . 3

Approche pédagogique du cours **5**

Les professeurs **7**
Richard Hotte . . . 7
Christian Jauvin . . . 8
Daniel Lemire . . . 9

Travaux notés **10**
Module 1 . . . 10
Module 2 . . . 10
Module 3 . . . 10
Module 4 . . . 10
Module 5 . . . 10

Feuille de route **11**

Google Sheets **12**
Paramètres linguistiques . . . 12
Fonction “copier-coller” . . . 14
Fonction de partage anonyme d’un fichier . . . 14

L’usage d’assistants intelligents **16**
Comment ce cours a été produit . . . 17

Venez discuter d’IA sur Discord ! **18**

Module 1 - Aux origines : l’intelligence artificielle symbolique **20**
Le parcours du module . . . 21
Objectifs . . . 22
Durée . . . 22
Évaluation . . . 22

Turing et la question fondatrice (1950) **23**
Le moment . . . 23
Le jeu de l'imitation . . . 25
La pensée comme calcul . . . 27
L'ombre de Gödel . . . 30
Une fin tragique, et une porte qui s'ouvre . . . 33

Deux paris rivaux (1956-1958) **34**
Le moment : l'été 1956 à Dartmouth . . . 34
Le premier pari : l'esprit comme logique . . . 36
Le second pari : l'esprit comme cerveau . . . 37
Deux univers parallèles . . . 39

L'âge d'or symbolique : chercher et raisonner **40**
Résoudre, c'est explorer . . . 40
L'explosion combinatoire . . . 41
L'apogée : Deep Blue bat Kasparov (1997) . . . 43
L'autre visage : ELIZA, ou l'illusion de comprendre . . . 44

Représenter le monde **47**
Le sens, angle mort de la machine . . . 47
Donner un savoir à la machine . . . 47
SHRDLU, ou le sommet de l'ambition . . . 50
Le mur du sens commun . . . 51
L'objection de Hofstadter . . . 52

Capturer l'expertise : les systèmes experts **56**
Rétrécir et codifier le monde pour réussir . . . 56
L'anatomie d'un système expert . . . 56
L'âge d'or : MYCIN, XCON et le boom . . . 59
Le goulot d'étranglement . . . 61

Les hivers et la bascule **63**
Le premier hiver : la mort du perceptron (1969) . . . 63
Le second hiver : l'effondrement du symbolique (fin des années 1980) . . . 65
L'héritage invisible . . . 65
Un éclair hybride : Watson (2011) . . . 67
La bascule . . . 68

Vous êtes le moteur d'inférence : un système expert (travail noté 1) **70**
Consignes . . . 70
Le système . . . 71
Manipulation 1 — Tracer le raisonnement . . . 72
Manipulation 2 — Casser le système . . . 72
Manipulation 3 — Étendre la base de règles . . . 72
Questions d'interprétation . . . 73

Module 2 — Apprentissage automatique **76**
Qu'est-ce que l'apprentissage automatique ? . . . 76
Une seule grande idée, déclinée . . . 77
Une vieille parenté : la statistique . . . 78
Le but ultime : généraliser . . . 78
Le parcours du module . . . 79
Objectifs . . . 80
Durée . . . 81
Évaluation . . . 81

Le problème **82**
Pourquoi on ne peut pas simplement le programmer . . . 82
Changer de stratégie : apprendre à partir d'exemples . . . 83
Notre fil rouge : des maisons à vendre . . . 84
Une seconde question, d'une tout autre nature . . . 86

Le modèle le plus bête **90**
Toujours prédire la moyenne . . . 90
La même bêtise, pour l'autre question . . . 91
Qu'est-ce qu'un modèle, au juste ? . . . 91
Pourquoi un modèle aussi bête est utile . . . 92
Leur défaut, et ce qu'il révèle . . . 95

Regarder les données **96**
Une maison, c'est une liste de nombres . . . 96
Un vecteur, c'est un point dans un espace . . . 98
Quand il y a trop de dimensions pour les voir . . . 99

Prédire par ressemblance **108**
Mesurer la ressemblance : la distance . . . 108
Les k plus proches voisins . . . 111
Le choix de k . . . 114
L'angle mort de kNN . . . 115

Un modèle qui s'entraîne **116**
Un modèle qui tient en deux nombres . . . 116
Mesurer l'erreur . . . 117
Apprendre, c'est descendre la pente . . . 119
Et pour prédire une catégorie ? . . . 120

Classer **122**
Tracer une frontière : la régression logistique . . . 123
La plus grande marge : les machines à vecteurs de support . . . 125
Renverser le problème : la classification bayésienne . . . 128
Le cas des pourriels . . . 134
Raisonner sous incertitude : les réseaux bayésiens . . . 135
Sous les modèles, des probabilités . . . 138

Poser des questions : les arbres de décision **140**

Une question suffit presque . . . 140
Comment l'arbre choisit ses questions . . . 142
Un arbre qui prédit un nombre . . . 143
Jusqu'où laisser pousser l'arbre ? . . . 144
L'arbre du *Titanic* . . . 146
Ce qu'un arbre dit, et ce qu'il tait . . . 147
Et sur des données neuves ? . . . 149

Généraliser **150**
Un modèle se juge sur ce qu'il n'a jamais vu . . . 150
Linéaire ou non-linéaire : ce qu'un modèle peut dessiner . . . 152
Trop coller, ou trop lisser : le compromis biais-variance . . . 155
Garder un modèle riche, mais le tenir en laisse : la régularisation . . . 157
Paramétrique ou non-paramétrique . . . 160

Bien évaluer un modèle **162**
Le score trop beau pour être vrai : la fuite de données . . . 162
Quand les données sont rares : la validation croisée . . . 164
Compter juste : les métriques . . . 165
Jamais vu, mais du même monde : la question de la distribution . . . 169
Corrélation n'est pas causalité . . . 171
Tout cela portait un nom : l'apprentissage supervisé . . . 172

Trois façons d'apprendre **174**
Apprendre avec un professeur : le supervisé . . . 175
Apprendre sans réponses : le non-supervisé . . . 175
Apprendre par l'expérience : le renforcement . . . 179
Un même squelette, d'un bout à l'autre . . . 180

Classification naïve bayésienne pour détecter les pourriels (travail noté 2) **182**
Consignes . . . 183
Entraînement du modèle . . . 183
Utilisation du modèle (inférence) . . . 188
Questions d'interprétation . . . 189

Module 3 — Réseaux de neurones et apprentissage profond **192**
Le retour d'une idée ancienne . . . 192
Une seule grande idée : apprendre ses propres caractéristiques . . . 193
Un fil conducteur : les chiffres manuscrits . . . 194
Ce que ce module n'est pas . . . 195
Des variations sur un même thème . . . 195
Le parcours du module . . . 196
Objectifs . . . 197
Durée . . . 198
Évaluation . . . 198

Un neurone **199**
Un neurone est une régression logistique . . . 199

D'où vient le mot « neurone » . . . 201
Un neurone à manipuler . . . 202
Ce qu'un neurone seul ne peut pas faire . . . 203

Une couche cachée **204**
Relier des neurones . . . 204
Le XOR résolu avec trois neurones . . . 205
Ce que fait la couche cachée : changer de point de vue . . . 206
Deux droites à déplacer . . . 207
Plus de neurones, plus de formes . . . 208
Qui règle tous ces poids ? . . . 208

Entraîner un réseau **210**
Le même principe qu'au Module 2 . . . 210
Le problème des couches cachées . . . 211
La rétropropagation . . . 212
Un réseau qui apprend le XOR . . . 213
1986 . . . 213
L'entraînement en pratique . . . 214
Pour voir le mécanisme en détail . . . 215

L'apprentissage profond **216**
Large ou profond . . . 216
Une hiérarchie de caractéristiques . . . 217
La fin des caractéristiques fabriquées à la main . . . 220
Pourquoi seulement en 2012 . . . 221
2012 : le concours ImageNet . . . 223
La leçon amère . . . 225
Plus de paramètres que d'exemples . . . 226
Apprendre sans étiquettes : l'autoencodeur . . . 227

Le matériel et les outils **230**
Les processeurs graphiques . . . 230
La différentiation automatique . . . 232
Un réseau en quelques lignes . . . 233
Un jeu de construction . . . 233

Voir : les réseaux convolutifs **235**
Ce qu'un réseau ordinaire ignore dans une image . . . 235
Le filtre . . . 236
Un filtre à manipuler . . . 237
Ce que la convolution apporte . . . 237
Du filtre au réseau . . . 237
Yann Le Cun et les chèques . . . 238
Après 2012 . . . 240
Réutiliser un réseau : l'apprentissage par transfert . . . 241
La leçon de la convolution . . . 242

Lire une séquence : les réseaux récurrents **244**

Le problème des séquences . . . 244
Une boucle : la mémoire . . . 244
Un réseau récurrent à manipuler . . . 245
Entraîner un réseau récurrent, et ce qu'il oublie . . . 246
Le LSTM : une mémoire à portes . . . 246
Ce que les réseaux récurrents ont permis . . . 248
Les limites . . . 248

L'attention et le Transformer **250**
L'attention dans la traduction . . . 250
Une recherche floue . . . 251
L'auto-attention . . . 253
Une attention à manipuler . . . 253
Le Transformer . . . 253
Pourquoi il a tout changé . . . 255
Au-delà du texte . . . 256
Vers le Module 4 . . . 257
Pour voir le mécanisme en détail . . . 257

Apprendre à jouer : le renforcement profond **258**
Les limites de la table . . . 258
Remplacer la table par un réseau . . . 258
Atari : jouer à partir des pixels . . . 259
AlphaGo . . . 260
AlphaZero : sans parties humaines . . . 262
Une machine qui apprend en jouant contre elle-même . . . 263
Au-delà des jeux, et les limites . . . 263

Tromper un réseau **265**
Le panda devenu gibbon . . . 265
Comment on le fabrique . . . 266
Tromper un réseau à manipuler . . . 266
Pourquoi c'est possible . . . 266
Dans le monde réel . . . 268
Se défendre . . . 270
Une boîte noire . . . 270
Ce que ce module a montré . . . 271

Apprivoiser un réseau de neurones (travail noté 3) **273**
Consignes . . . 273
Questions . . . 273

Module 4 — IA générative et grands modèles de langage **279**
Reconnaître, puis produire . . . 279
Une seule grande idée : imiter une distribution . . . 280
Ce que ce module n'est pas . . . 281
Le parcours du module . . . 281
Objectifs . . . 283

Durée . . . 284
Évaluation . . . 284

Générer : imiter une distribution **285**
Décrire plutôt que séparer . . . 285
Une distribution, et tirer dedans . . . 286
La température . . . 287
Le vrai problème : les grandes dimensions . . . 288
La variété des vraies images . . . 289
L'espace latent . . . 290
Générer n'est pas recopier . . . 291
Vers des modèles plus puissants . . . 291

Quatre façons de générer **293**
Le faussaire et l'expert : les réseaux antagonistes génératifs . . . 293
Remplir l'espace latent : les autoencodeurs variationnels . . . 295
Retirer le bruit pas à pas : la diffusion . . . 297
Un élément après l'autre : les modèles autorégressifs . . . 299
Générer sur demande . . . 299
Quatre familles, et leurs combinaisons . . . 302

Des images, des voix, des vidéos **304**
Les images . . . 304
Retoucher plutôt que créer . . . 306
Les voix et la musique . . . 307
La vidéo . . . 307
Au-delà des médias . . . 308
Les hypertrucages . . . 308
Le texte, au premier plan . . . 309

Des règles aux probabilités **310**
Les règles (1954-1980) . . . 312
Le tournant statistique . . . 313
Un modèle de langage . . . 314
Compter : les n-grammes . . . 316
Les suites jamais vues : le lissage . . . 318
Mesurer un modèle : la perplexité . . . 320
La suite de l'histoire . . . 320

Les outils statistiques **321**
Les modèles de Markov cachés . . . 321
La traduction comme un canal bruité . . . 323
Représenter des documents . . . 324
Étiqueter avec des caractéristiques faites à la main . . . 325
Ce qui manquait . . . 326

Des mots aux nombres : jetons et plongements **327**
Découper le texte : les jetons . . . 327
La première idée : un numéro par mot . . . 328

On reconnaît un mot à ses fréquentations . . . 329
Compter les voisins . . . 330
Les plongements . . . 330
Les plongements héritent des préjugés . . . 331
Le même mot, plusieurs sens . . . 332
Tout devient vecteur . . . 333

Prédire le mot suivant **334**
Généraliser : les modèles neuronaux . . . 334
De 2003 à 2017 : des réseaux récurrents à l'attention . . . 336
Trois façons d'assembler le Transformer . . . 336
GPT : un Transformer qui prédit le jeton suivant . . . 338
Ce que la prédiction exige . . . 340
Ce qui a changé, ce qui est resté . . . 340
Pour voir le mécanisme en détail . . . 341

Passer à l'échelle **342**
De GPT à GPT-4 . . . 342
Des lois d'échelle . . . 343
Apprendre dans le contexte . . . 344
Des capacités qui apparaissent ? . . . 345
Que mesurent les scores ? . . . 346
Le prix de la taille . . . 348
Modèles fermés, modèles ouverts . . . 349
Ce que coûte une réponse . . . 349
Jusqu'où ? . . . 350

Du modèle à l'assistant **351**
Un modèle de base ne répond pas . . . 351
Imiter de bonnes réponses . . . 354
Le renforcement à partir de préférences humaines (RLHF) . . . 354
Le travail humain derrière l'assistant . . . 356
Utile, honnête, inoffensif . . . 356
Faire des choses avec des mots . . . 357
Des modèles qui « raisonnent » (RLVR) . . . 359

Des outils, un harnais et des agents **361**
Formuler la requête . . . 361
Une conversation qui n'en est pas une . . . 361
La requête système et le harnais . . . 363
Pourquoi ne pas le laisser apprendre ? . . . 365
Chercher d'abord, répondre ensuite (RAG) . . . 366
Le harnais et l'appel d'outils . . . 369
Des agents : un modèle et son harnais, en boucle . . . 372

Programmer avec des agents **375**
De la complétion à l'agent . . . 375
Ce que fait un agent de programmation . . . 376
La culture Unix : des outils faits pour le texte . . . 377

Un projet plus grand que la fenêtre de contexte . . . 379
Pourquoi le code s'y prête si bien . . . 379
Mesurer : SWE-bench et la durée des tâches . . . 379
Permissions, bac à sable et incidents . . . 380
Programmer autrement . . . 381

Démontrer **382**
Vérifier une preuve . . . 382
Les Olympiades : de la géométrie à l'or . . . 383
Découvrir : AlphaEvolve . . . 384
Mesurer : FrontierMath . . . 384
Vers la recherche . . . 384
Ce que cela dit, et ce que cela ne dit pas . . . 385

Le défi ARC **387**
Mesurer l'intelligence, pas les compétences . . . 387
Le corpus ARC . . . 387
À vous de jouer . . . 388
Pourquoi les machines échouaient . . . 389
Le prix ARC de 2024 et l'entraînement au moment du test . . . 389
o3 et le calcul au moment de la réponse . . . 389
ARC-AGI-2 . . . 390
ARC-AGI-3 : apprendre en jouant . . . 390
Ce qu'ARC dit, et ce qu'il ne dit pas . . . 391

Relier les mots et les images **392**
Apprendre à voir sans étiquettes . . . 392
CLIP : images et légendes dans un même espace . . . 393
Classer sans exemples . . . 395
Du texte à l'image . . . 395
Les limites . . . 397

Des modèles qui voient, entendent et parlent **398**
Une image découpée en jetons . . . 398
Un modèle de langage qui lit des images . . . 398
Lire le texte dans les images . . . 399
Entendre et parler . . . 401
Converser à voix haute . . . 401
Générer des images avec un modèle de langage . . . 403
Ce qui leur échappe encore . . . 403

Regarder à l'intérieur : l'interprétabilité mécaniste **404**
Une boîte noire entièrement visible . . . 404
Plus de concepts que de neurones : la superposition . . . 404
Démêler les concepts : les autoencodeurs clairsemés . . . 406
Suivre un calcul : les circuits . . . 407
Un calcul entièrement compris : le grokking . . . 409
À quoi sert l'interprétabilité . . . 411
En 2026 : des émotions, des activations qui parlent, un espace de travail . . . 412

Les limites 413
Pour aller plus loin 414

Ce que les LLM comprennent, et ce qu'ils ratent **415**
Les hallucinations 415
Des erreurs révélatrices 416
Perroquets ou modèles du monde ? 417
L'illusion de comprendre 418
Deux façons de savoir 419
Ce qu'il faut retenir du module 419

Un modèle de langage dans un tableur (travail noté 4) **421**
Consignes 422
Entraînement du modèle 422
Utilisation du modèle (inférence) 426
Questions 427

Pour aller plus loin **429**
Le podcast MLST 429
Présentations diverses 429

Conclusion **430**

Bienvenue !

Version 2, en construction. Ce site présente la nouvelle version du cours, qu'on est en train de refaire. Pour l'instant, seuls les modules 1 et 2 sont publiés ; les modules 3 à 5 s'ajouteront à mesure qu'ils seront prêts. La version actuelle du cours reste accessible à cjauvin.github.io/inf1901-teluq.

Bienvenue dans le cours **INF 1901 Initiation à l'intelligence artificielle : concepts et réflexions**. Ce cours vous offre une occasion unique de vous initier au domaine de l'intelligence artificielle (IA) dans un contexte professionnel.

Ce cours explore l'évolution de l'intelligence artificielle, des systèmes symboliques à la révolution de l'IA générative récente. Il examine les fondements de l'apprentissage automatique, ancrés dans les données, les statistiques et les algorithmes, tout en clarifiant des concepts clés comme l'entraînement, l'inférence et la généralisation. Une attention particulière est portée aux réseaux de neurones et à l'apprentissage profond, en détaillant leur structure et leurs analogies avec le cerveau humain, en portant une attention particulière sur la vision artificielle où les progrès initiaux furent les plus décisifs. Le cours retrace également le développement des modèles de langage. Enfin il aborde les enjeux éthiques, philosophiques et sociétaux de l'intelligence artificielle, incluant l'alignement des systèmes, la singularité technologique et leurs effets sur la société.

Aucune expérience préalable en IA n'est requise pour réussir ce cours – seulement une curiosité et une volonté d'apprendre. Que vous soyez une ou un professionnel cherchant à approfondir vos compétences ou une personne passionnée par les possibilités de l'IA, ce cours est conçu pour vous. Nous vous invitons à consulter le site Web du cours dès son lancement pour découvrir la feuille de route et la liste des activités prévues. Le site du cours comprend une dizaine de vidéos et plusieurs activités interactives à réaliser dans votre navigateur Web. Il ne s'agit pas d'un cours léger : vous compterez près de 35,000 mots et des dizaines d'illustrations. Si vous avez des questions, n'hésitez pas à nous contacter. Nous sommes impatients de collaborer avec vous dans cette aventure !

Au plaisir de vous guider dans cette initiation à l'intelligence artificielle : concepts et réflexions. Nous vous souhaitons du succès dans vos apprentissage.

Présentation du cours

> « *Toute technologie suffisamment avancée est indiscernable de la magie.* »
> Arthur C. Clarke

L'intelligence artificielle (IA) constitue aujourd'hui un champ de recherches et d'applications essentiel dont l'influence s'étend à de multiples domaines, de la science et la médecine aux industries créatives et à l'éducation. Conséquemment, les entreprises de divers secteurs sont confrontées à cette transformation numérique sans précédent, si bien que l'intégration de l'IA dans les modèles d'affaires n'est plus un luxe, mais une nécessité pour demeurer compétitif dans un marché mondial en constante évolution. L'émergence de modèles de langage avancés tels que ChatGPT, DeepSeek et Llama 3 illustre cette transformation, en ouvrant de nouvelles perspectives tant scientifiques que sociétales.

Le cours INF 1901 Introduction à l'intelligence artificielle introduit le rôle des diverses formes de l'intelligence et, par conséquent, d'apprentissage chez l'humain qui ont trouvé un écho dans le développement des formes d'intelligences artificielles de la Conférence de Dartmouth en 1956 aux avancées récentes en IA générative et les grands modèles de langage.

En plus des connaissances théoriques, le cours propose une réflexion critique sur les usages et les impacts de ces technologies, en interrogeant les enjeux éthiques, les défis économiques et les perspectives qu'elles soulèvent dans un contexte de diffusion massive et d'appropriation croissante par les acteurs publics et privés.

Objectifs du cours

Ce cours vise offrir une base solide à la poursuite du programme court en intelligence artificielle (IA) dans les entreprises et, éventuellement, des études ou des projets plus avancés dans le domaine de l'IA ou dans des secteurs influencés par cette technologie.

Plus spécifiquement, le cours habilitera l'étudiante ou l'étudiants à :

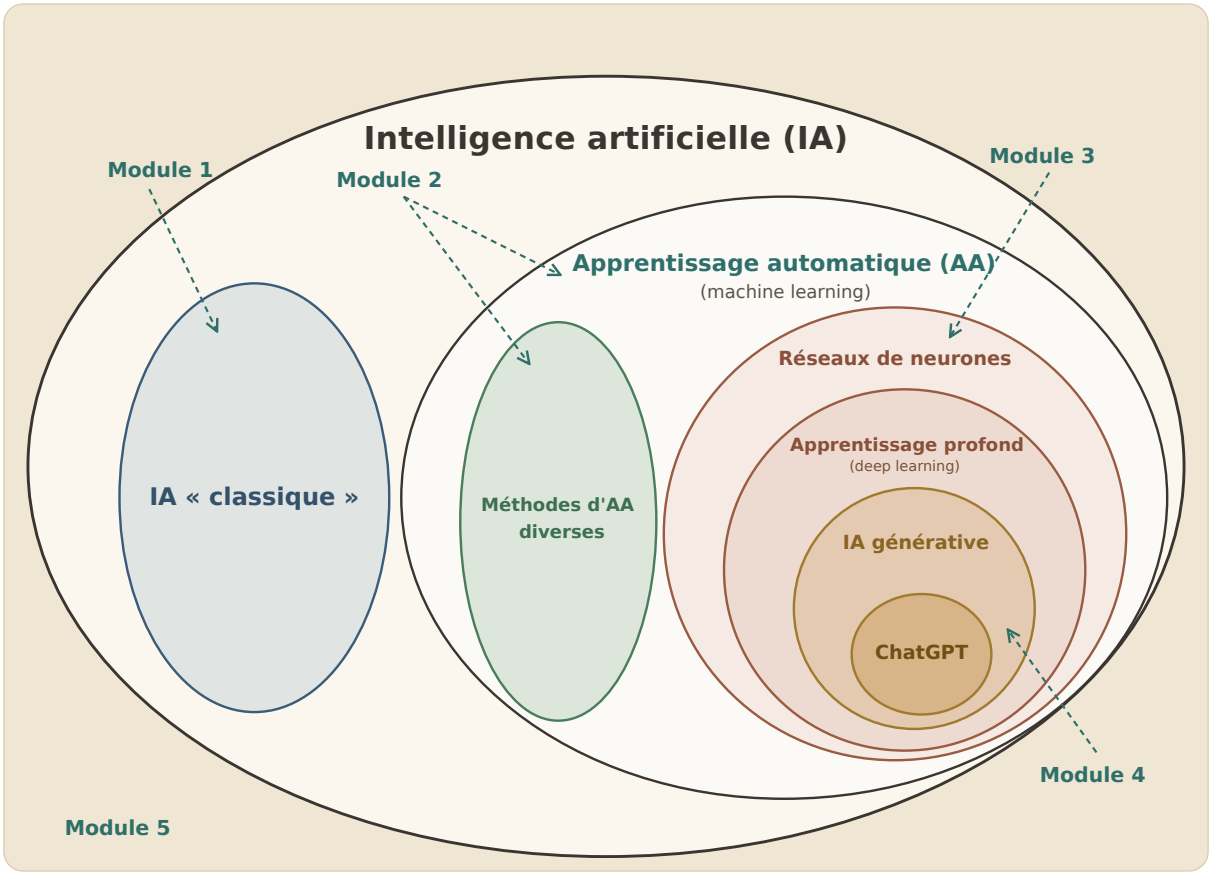
- Expliquer les bases et l'évolution historique de l'IA.
- Identifier et analyser des applications de l'IA dans des contextes concrets.
- Développer un regard critique et instruit sur les impacts de l'IA.
- Utiliser les notions essentielles pour aborder des discussions éthiques et stratégiques sur l'IA.

Dans l'introduction de chaque module du cours, vous trouverez les objectifs spécifiques poursuivis.

Contenu

Le contenu du cours se découpe en cinq modules.

1. Le premier module remonte **aux origines** de l'IA et raconte l'aventure de l'**intelligence artificielle symbolique** (le *GOFAI*, pour *Good Old-Fashioned AI*) : pendant près de quarante ans, le pari de faire « penser » une machine en lui faisant manipuler des **symboles** et des **règles** logiques. Dans une perspective historique, du test de Turing (1950) aux systèmes experts et aux « hivers » de l'IA, ce module présente les grandes idées algorithmiques de cette première école (recherche dans un espace d'états, représentation des connaissances, raisonnement à base de règles) et explique *pourquoi* elle a fini par buter sur ses limites — ouvrant la voie à l'apprentissage automatique étudié dans les modules suivants.
2. Le deuxième module introduit les principes et techniques fondamentaux de l'apprentissage automatique (machine learning) en explorant les différents types d'apprentissage (supervisé, non supervisé, par renforcement) et leurs applications. Ce module vise à décrire comment les algorithmes apprennent à partir des données pour faire des prédictions, identifier des modèles et automatiser des tâches complexes.
3. Le troisième module explore les architectures de l'apprentissage profond (deep learning) comme les réseaux à convolution et récurrents, en mettant l'accent sur leur capacité à traiter des données complexes (image, texte, son).
4. Le quatrième module se consacre à l'IA générative et à l'essor récent des grands modèles de langage.
5. Le cinquième module propose une vision plus vaste du sujet, avec l'exploration de perspectives autour de l'IA, à la fois philosophiques, scientifiques et sociales.



La carte du cours : chaque module explore une région de l'intelligence artificielle, des plus anciennes aux plus récentes — et le Module 5 les traverse toutes.

Approche pédagogique du cours

> « *Le vrai problème de l'humanité est le suivant : nous avons des émotions paléolithiques, des institutions médiévales, et une technologie digne des dieux.* »
> E.O. Wilson

L'apprentissage automatique (AA) est un sujet complexe et fortement dynamique, au confluent de plusieurs disciplines : mathématiques, informatique, sciences cognitives. Les fondements de la discipline sont résolument mathématiques, principalement avec l'algèbre linéaire et les probabilités (qui entretiennent elles-mêmes des liens très étroits).

La plupart des cours d'apprentissage automatique de format classique sont avant tout très mathématiques, avec beaucoup d'équations et de théorèmes, parfois des preuves. Un cours d'AA entièrement composé d'équations (et rien d'autre) est en général perçu comme étant *très difficile*. Il serait aussi très difficile de ne pas parler de mathématique du tout dans un cours d'initiation à l'apprentissage automatique, mais nous allons tout de même tenter d'offrir plusieurs angles sur le sujet. Étant donné les fondations en algèbre linéaire, les problèmes traités par l'AA ont souvent la possibilité d'être compris de manière très visuelle et intuitive. Nous allons tenter d'exploiter cela, en mettant le plus possible l'emphase sur la visualisation et les explications claires en mots, plutôt que les équations (bien que ces dernières seront présentes mais optionnelles, car elles constituent tout de même les fondations théoriques, qui permettent de réduire l'ambiguïté conceptuelle au minimum, et souvent de faire des liens profonds et subtils entre des idées mathématiques qui ne semblent pas à priori si proches).

Étant donné que l'apprentissage automatique est algorithmique et dynamique (il s'agit de techniques avec lesquelles on *fait* des choses, en général), les visualisations interactives constituent également un excellent support pour approfondir sa compréhension. Dans ce cours, nous avons tenté de développer nos propres petites applications interactives pour aider à la compréhension de certains concepts, et les vidéos que nous proposons du créateur en ligne 3Blue1Brown constituent également un fabuleux complément, dont il ne faudrait pas se passer.

L'apprentissage automatique est aussi profondément computationnel, et évidemment la programmation y joue un grand rôle. Le substrat de l'intelligence artificielle est l'ordinateur, et celui-ci n'a jamais cessé, depuis sa création, d'être basé sur l'architecture de Von Neumann, ce qui implique que son fonctionnement requiert nécessairement de la programmation au sens traditionnel (l'AA n'y échappe pas). Il serait probablement possible d'enseigner les fondements de l'AA entièrement de cette perspective, étant donné qu'il est possible d'exprimer toutes les idées mathématiques à l'aide de programmes. Nous allons toutefois nous contenter de faire cela seulement à quelques endroits, qui resteront optionnels. Il est à noter que deux des travaux notés utilisent Google Sheets,

la version en ligne de Excel, qui est un environnement de calcul qui se rapproche beaucoup de la programmation, de par sa nature même. Nous pensons que ceci fera en sorte d'offrir au moins une idée approximative du développement en AA, même pour les gens qui ne maîtrisent pas la programmation.

Finalement, il est impossible d'ignorer le fait que l'apprentissage automatique, tout comme certaines autres innovations technologiques récentes (comme les médias sociaux) a fini par avoir des effets importants sur la société. Nous croyons donc qu'il est important qu'un cours d'initiation traite de certains sujets plus larges, et place l'AA dans une perspective historique et philosophique.

Les professeurs

> « *Le futur est déjà là, il n'est juste pas très équitablement réparti.* »
> William Gibson

Ce cours a été co-créé par trois professeurs de l'Université TÉLUQ.

Richard Hotte



Richard Hotte

Richard Hotte. Photo : Université TÉLUQ.

Richard Hotte a été titulaire de la chaire UNESCO en système intelligent d'apprentissage repensé

pour tous (UNESCO Chair for Global Smart Disruptive Learning (GSDL)), de 2019 à 2023. Cette chaire se rattache au programme UNITWIN/Chaires UNESCO et s'inscrit dans le champ de l'intelligence artificielle et apprentissage mobile. Elle a pour objet de promouvoir un système intégré de recherche, de formation et de documentation sur l'apprentissage mobile. Elle vise à faciliter la collaboration entre des chercheurs et des enseignants de renommée internationale de l'Université et d'autres établissements au Canada ainsi qu'ailleurs en Amérique du Nord, en Europe, en Afrique et dans d'autres régions du monde.

- Chachoui, Y., Azizi, N., Hotte, R., & Bensebaa, T. (2024). Enhancing algorithmic assessment in education: Equi-fused-data-based SMOTE for balanced learning. Computers and Education: Artificial Intelligence, 6, 100222.
- Hotte, R., Masmoudi, A., Jaballah, A., Masmoudi, O., & Maïga, A. A. (2021). Work-in-progress about dynamicity as a foundation for AMI, a mobile intelligent and adaptive learning system. In Interactive Mobile Communication, Technologies and Learning (pp. 111-119). Cham: Springer International Publishing.

Christian Jauvin



Christian Jauvin

Christian Jauvin. Photo : Université TÉLUQ.

Christian Jauvin s'intéresse à la programmation, à la modélisation et la science des données, à l'architecture logicielle, à la géomatique, à l'intelligence artificielle et à l'impact social des technologies numériques.

Il a participé à ses débuts à des recherches pionnières sur la modélisation statistique du langage naturel avec Yoshua Bengio, notamment à l'article fondateur A Neural Probabilistic Language Model. Il a ensuite développé une expertise variée à travers des projets dans des contextes universitaires, corporatifs et comme consultant indépendant. Ses articles et communications ont été cités près de 13,000 fois.

Il a travaillé sur des systèmes logiciels dans des domaines tels que la santé publique (McGill), les jeux vidéo (Ubisoft), les systèmes d'information géographique (K2 Géospatial) et la modélisation climatique (Ouranos). Son parcours l'a amené à concevoir des applications distribuées dans le cloud, à contribuer à des projets open source, et à développer des outils logiciels sur mesure pour des besoins spécifiques.

- Bengio, Y., Ducharme, R., Vincent, P., & Jauvin, C. (2003). A neural probabilistic language model. Journal of machine learning research, 3(Feb), 1137-1155.
- Delagrange, S., Jauvin, C., & Rochon, P. (2014). PypeTree: A tool for reconstructing tree perennial tissues from point clouds. Sensors, 14(3), 4271-4289.

Daniel Lemire



Daniel Lemire

Daniel Lemire. Photo : Université TÉLUQ.

Daniel Lemire est professeur titulaire en informatique. Il s'intéresse particulièrement à la performance du logiciel et aux techniques d'indexation en science des données. Il aime poser un regard critique sur l'utilisation des technologies.

Daniel Lemire est parmi les 2 % de scientifiques les plus cités au monde (classement de l'Université Stanford, 2024). Il fait partie des 0,0006 % de programmeurs les plus suivis au monde sur GitHub ; GitHub compte plus de 100 millions de développeurs.

- Lemire, D., & Maclachlan, A. (2005, April). Slope one predictors for online rating-based collaborative filtering. In Proceedings of the 2005 SIAM International Conference on Data Mining (pp. 471-475). Society for Industrial and Applied Mathematics.
- Langdale, G., & Lemire, D. (2019). Parsing gigabytes of JSON per second. The VLDB Journal, 28(6), 941-960.

Travaux notés

> « *Bien sûr. Je suis une machine, et vous êtes une machine, et nous pensons tous les deux, n'est-ce pas ?* »
> Claude Shannon (en réponse à la question "est-ce qu'une machine peut penser?")

Le cours sera évalué avec cinq travaux pratiques, un par module.

Module 1

Système expert à incarner : vous jouez vous-même le rôle du moteur d'inférence d'un système à base de règles `si… alors…`, que vous faites tourner, mettez en échec, puis corrigez. *Pondération : 15% de la note finale.*

Module 2

Construction guidée d'un algorithme de classification des courriels. *Pondération : 20% de la note finale.*

Module 3

Exercices interactifs suivis de questions interprétatives sur l'apprentissage profond. *Pondération : 20% de la note finale.*

Module 4

Construction guidée d'un modèle de langage bigramme. *Pondération : 20% de la note finale.*

Module 5

Rapport critique sur une question philosophique ou éthique reliée à l'IA. *Pondération : 25% de la note finale.*

Feuille de route

> « *Nous avons tendance à surestimer les effets d'une technologie à court terme et à les sous-estimer à long terme.* »
> Roy Amara (cette idée est appelée la "Loi d'Amara")

Prévoyez environ 9 heures de travail par semaine pendant quinze semaines. Pour la plupart d'entre vous, il est impossible de réussir ce cours en y consacrant que quelques d'heures par semaine.

Il n'y a pas de dates fixes pour la remise des travaux, mais il est recommandé de prévoir une semaine de travail pour la réalisation de chacun d'eux et de les remettre selon l'ordre de présentation du cours. Bien que chaque personne inscrite à ce cours ne progressera pas au même rythme dans son apprentissage. Cependant, nous vous suggérons de remettre vos travaux notés lors de la semaine indiquée par le tableau suivant :

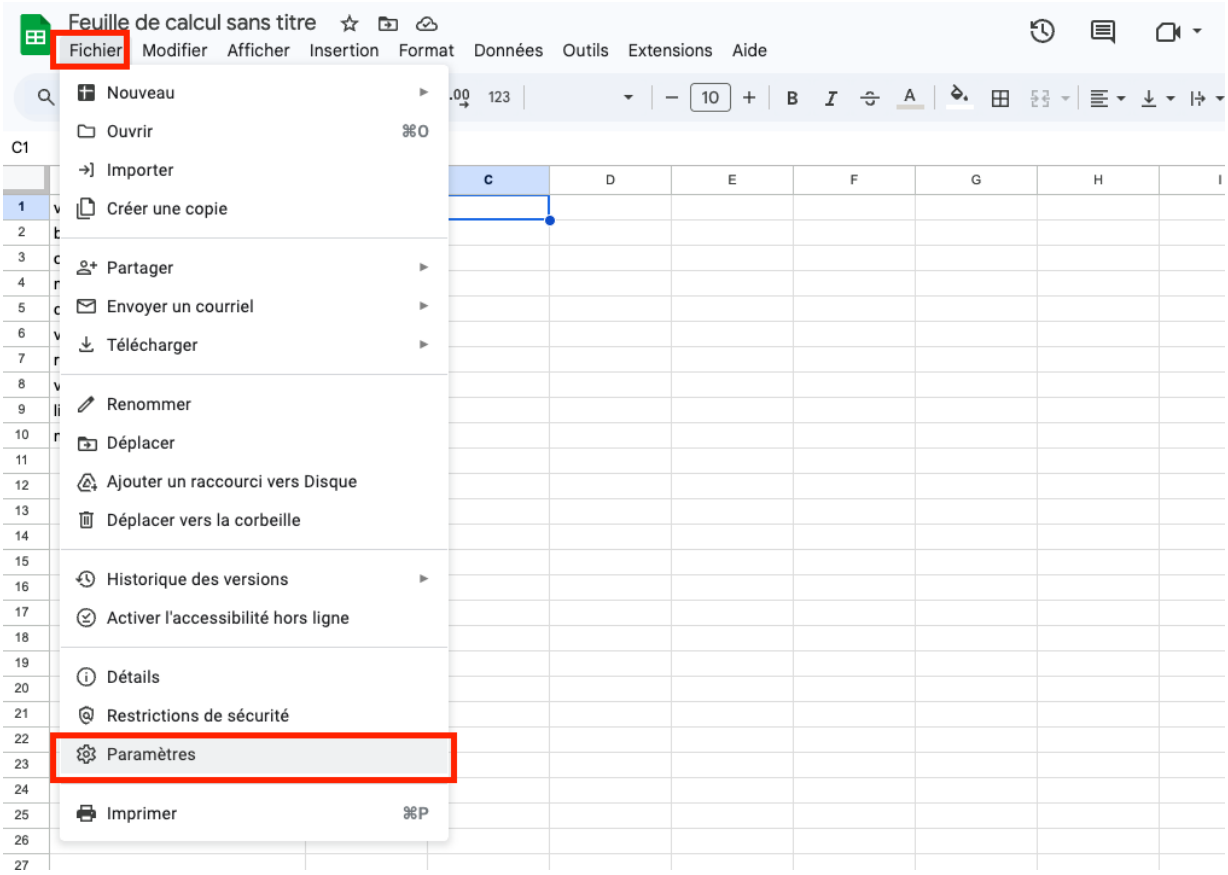
Semaines	Activités	Remises TN
1	Activités du module 1	
2	**Temps de travail sur le TN1**	**TN1**
3	Activités du module 2	
4	Activités du module 2 (suite)	
5	**Temps de travail sur le TN2**	**TN2**
6	Activités du module 3	
7	Activités du module 3 (suite)	
8	**Temps de travail sur le TN3**	**TN3**
9	Activités du module 4	
10	Activités du module 4 (suite)	
11	**Temps de travail sur le TN4**	**TN4**
12	Activités du module 5	
13	Activités du module 5 (suite)	
14	Activités du module 5 (suite)	
15	**Temps de travail sur le TN5**	**TN5**

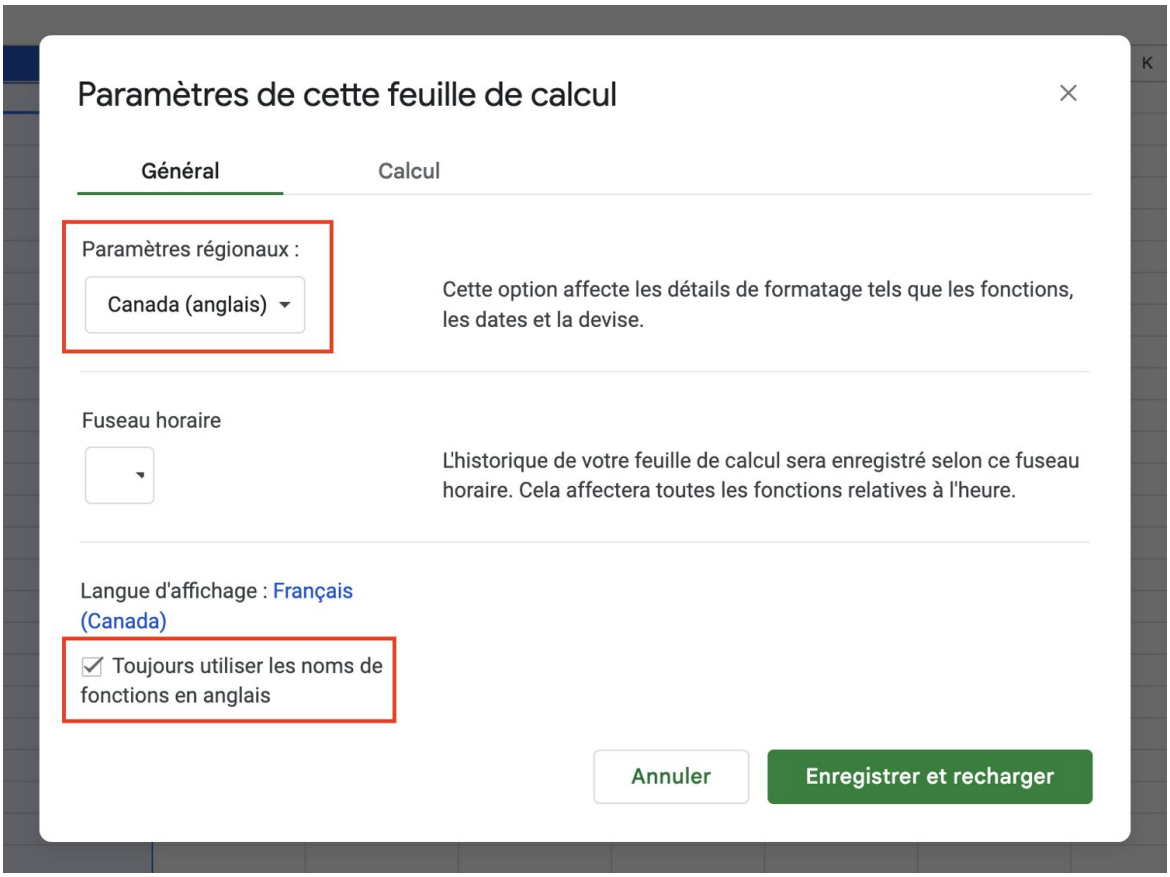
Il est parfaitement normal de consacrer des dizaines d'heures à compléter un travail noté et les activités préparatoires. Il est de votre responsabilité de trouver le temps nécessaire.

Google Sheets

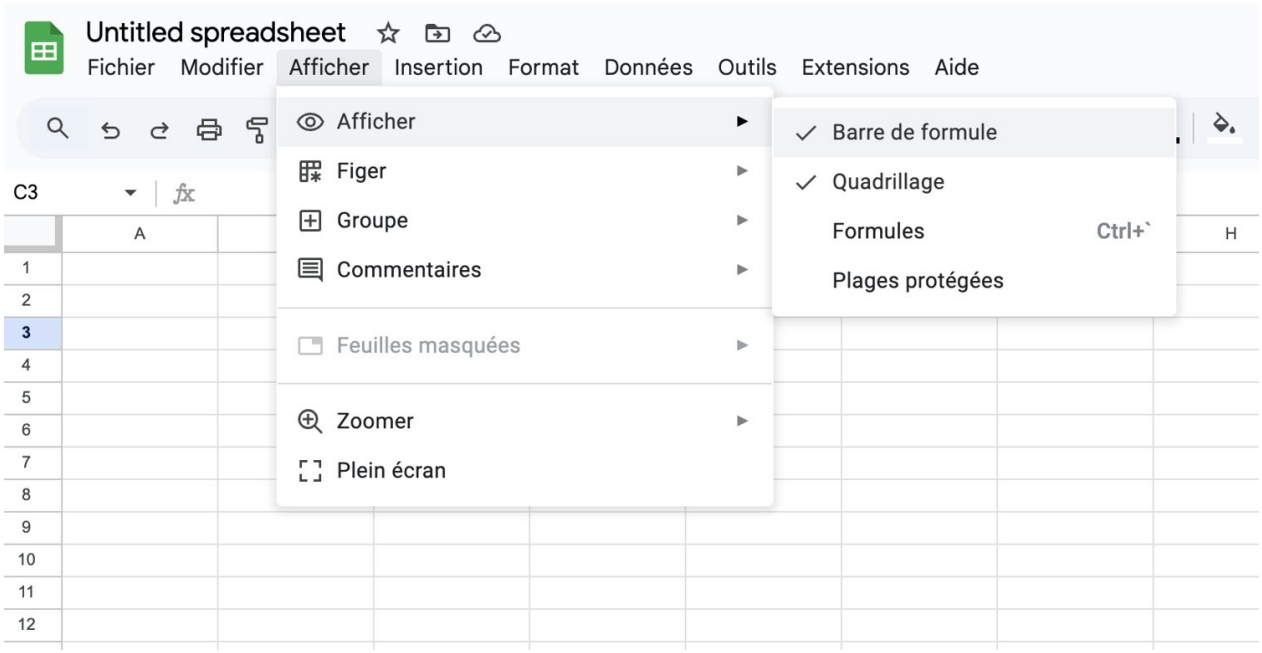
Paramètres linguistiques

Pour les travaux notés 2 et 4, nous allons utiliser le tableur en ligne Google Sheets au lieu du choix plus courant Excel, car Google Sheets est plus accessible, et le langage de ses formules est plus facile à gérer (celui d'Excel dépend de la langue et des paramètres régionaux de votre système d'exploitation). Pour éviter la confusion dans le contexte des travaux notés, nous devons tout d'abord nous assurer que la langue des fonctions et des paramètres régionaux est l'anglais :



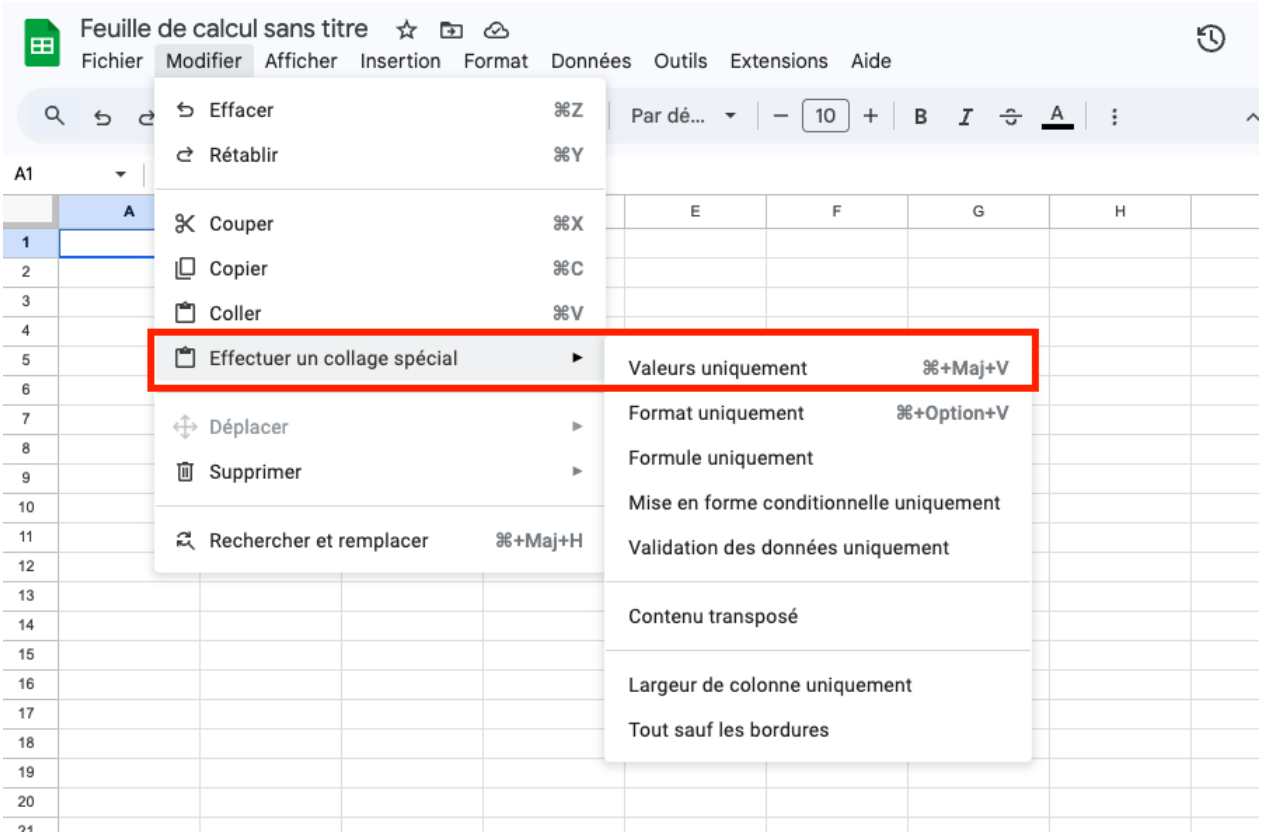


Assurez-vous ensuite que la “barre de formules” soit visible :



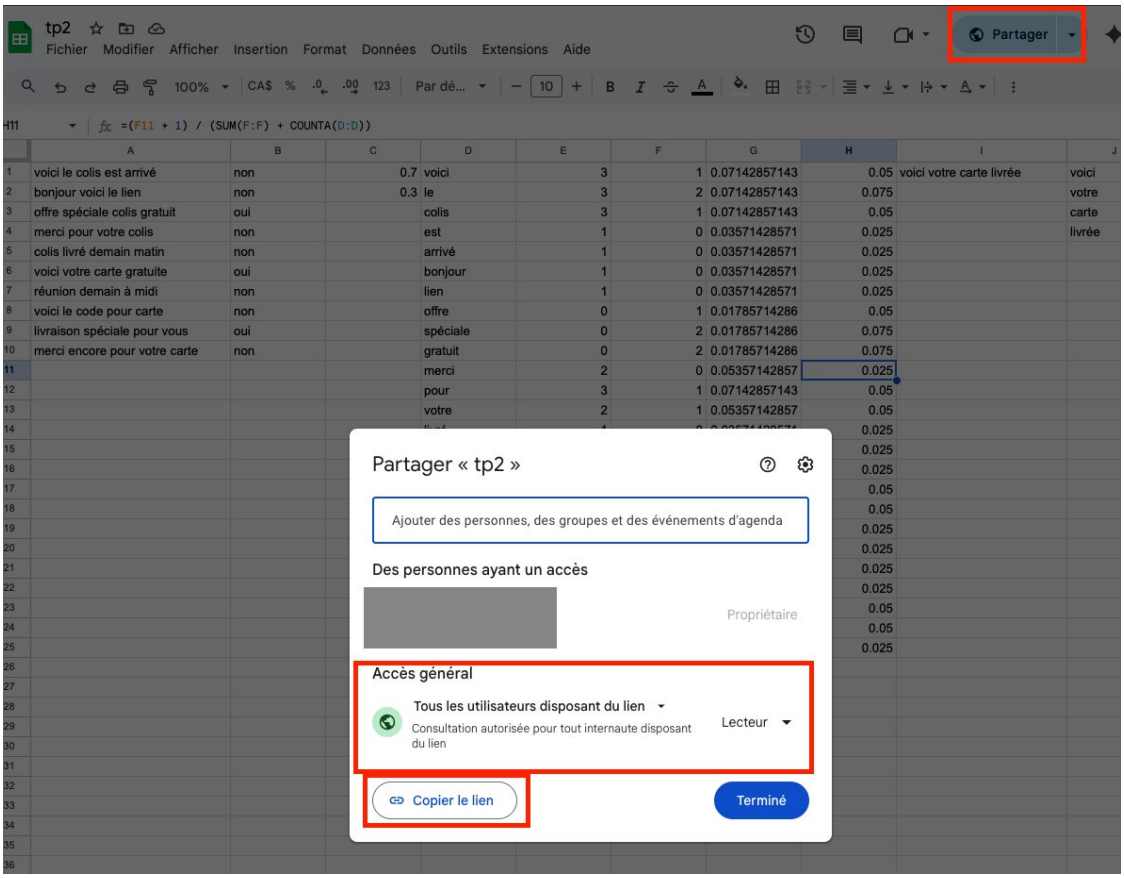
Fonction “copier-coller”

Pour les travaux notés 2 et 4, il est pratique d’utiliser la fonction “copier-coller” de votre système d’exploitation, pour éviter d’avoir à recopier une grande quantité d’information à la main. Si vous utilisez les raccourcis du clavier (`Control + c` pour copier sur Windows, `Command + c` sur Mac) veuillez noter qu’il est préférable d’utiliser cependant `Control + Shift + v` (`Command + Shift + v` sur Mac) pour coller (plutôt que `Control + v` ou `Command + v`), car ceci utilise la fonction “collage sans formatage”, qui fait en sorte de ne copier que l’information textuelle (en ignorant le formatage de la donnée source). Si vous ne désirez pas utiliser les raccourcis clavier et que vous utilisez un navigateur basé sur Chrome, veuillez noter qu’il vous sera nécessaire d’installer l’extension Google Docs hors connexion pour faire en sorte que vous puissiez utiliser la fonction “copier-coller” à partir du menu de Google Sheets.



Fonction de partage anonyme d’un fichier

Il est possible de partager de manière anonyme un fichier Google Sheets (qui ne sera donc pas associé à votre compte Google d’aucune manière) en produisant un hyperlien, en utilisant la fonction “partage” et en cliquant sur le bouton “copier le lien”, après s’être assuré que l’accès est en mode “tous les utilisateurs disposant du lien” :

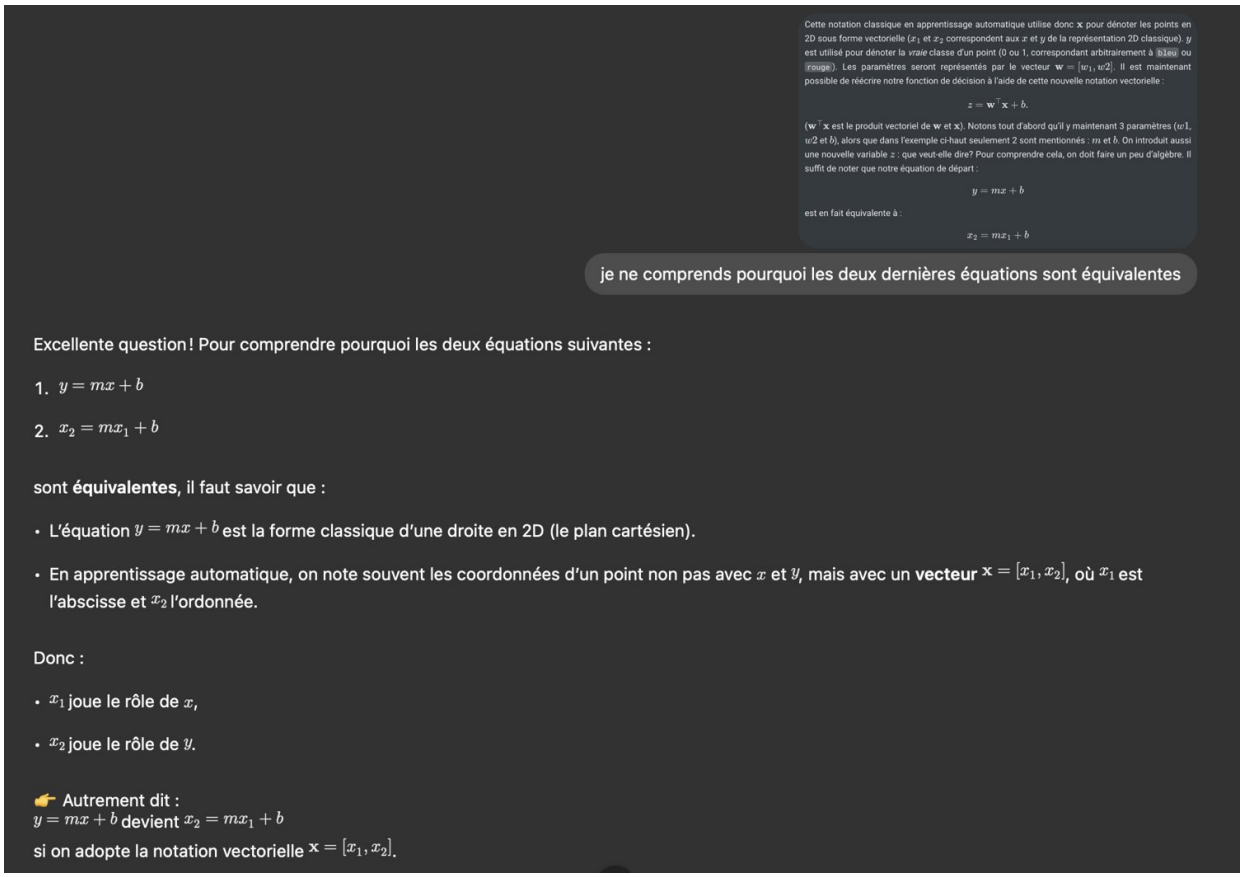

tp2
Fichier Modifier Afficher Insertion Format Données Outils Extensions Aide
Partager
=(F11 + 1) / (SUM(F:F) + COUNTA(D:D))
Partager « tp2 »
Ajouter des personnes, des groupes et des événements d'agenda
Des personnes ayant un accès
Propriétaire
Accès général
Tous les utilisateurs disposant du lien
Consultation autorisée pour tout internaute disposant du lien
Lecteur
Copier le lien
Terminé

L'usage d'assistants intelligents

Étant donné qu'il s'agit d'un cours sur l'intelligence artificielle, l'usage d'assistants intelligents (ChatGPT, Claude, Gemini, etc) est évidemment encouragé ! Ceci s'applique autant aux travaux notés qu'au reste du contenu du cours.

Par contre si vous utilisez un tel outil, nous vous conseillons de vous assurer d'avoir une compréhension viscérale des réponses qu'il fournira, et de ne pas hésiter à engager un dialogue avec l'agent, dans le but de clarifier des aspects du problème qui pourraient rester obscurs pour vous. N'oubliez pas que le but de ce cours est la construction de bons modèles mentaux pour penser à l'intelligence artificielle, et comprendre son fonctionnement, au-delà de sa surface applicative. L'agent possède déjà ces modèles mentaux, si vous avez développé les vôtres à la fin de ce cours, le but aura clairement été atteint !

Voici un exemple d'interaction : supposons que j'ai de la difficulté à comprendre un aspect des mathématiques de la régression logistique, je peux faire une capture d'écran du texte et la donner à ChatGPT, et poser ma question ("je ne comprends pas pourquoi les deux dernières équations sont équivalentes").. ChatGPT (ou un autre outil) se fera un plaisir de vous expliquer avec une patience infinie :



ChatGPT

Comment ce cours a été produit

Ce cours applique lui-même ce conseil. Son auteur l'a rédigé avec l'aide d'un agent de programmation, Claude Code, du type présenté au chapitre « Programmer avec des agents » du Module 4. Le cours est un ensemble de fichiers texte, au format Markdown, transformés en site Web par le programme Hugo et suivis par le logiciel de gestion de versions git. L'agent lit et modifie ces fichiers, écrit les petits programmes Python qui produisent les figures et les applets, vérifie qu'aucun lien n'est cassé, et fait vérifier en ligne les faits récents. L'auteur décide du plan et du contenu, relit chaque passage et valide chaque changement. Comme pour vos propres travaux, l'outil aide, mais la responsabilité du contenu reste humaine.

Venez discuter d'IA sur Discord !

On tente une expérience : si ça vous tente, venez discuter des idées de ce cours sur la plateforme en ligne Discord, à l'adresse suivante : https://discord.gg/QxrtkpgtRS

Venez poser des questions et discuter de questions philosophiques avec au moins un des professeurs de ce cours !

Contenu interactif, à consulter en ligne : https://discord.com/widget?id=1448801083991396450&theme=dark

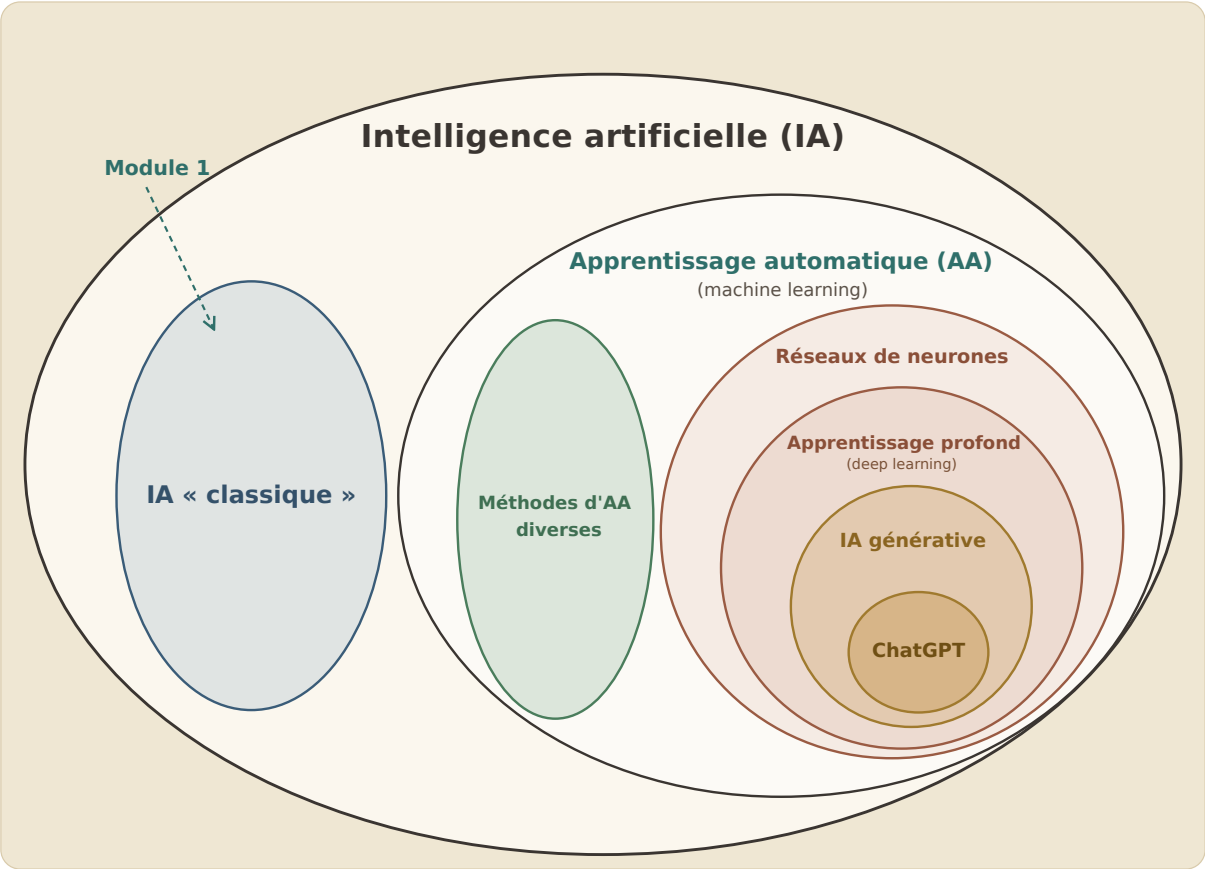
Module 1 - Aux origines : l'intelligence artificielle symbolique



Avant les réseaux de neurones et avant ChatGPT, l'IA a d'abord cherché à **fabriquer une machine qui pense en manipulant des symboles et des règles**, comme le ferait un logicien ou un joueur d'échecs méthodique. On appelle aujourd'hui cette approche l'**IA symbolique**, ou *GOFAI* (pour *Good Old-Fashioned AI*, la « bonne vieille IA »). Pendant près de quarante ans, elle a dominé le domaine et obtenu des succès importants, puis elle a rencontré des limites qui l'ont fait paraître démodée.

Ce module présente cette histoire en **six chapitres**. Chacun associe un *moment historique* à une *idée technique*. Le but n'est pas de vous rendre capable de programmer ces systèmes, mais de comprendre l'**idée** sur laquelle ils reposent et les **difficultés** qu'ils ont rencontrées. En comprenant pourquoi cette première IA a atteint ses limites, on comprend mieux pourquoi la suite (les modules 2, 3 et 4) est si différente.

Dans l'ensemble du domaine de l'intelligence artificielle, l'IA symbolique correspond à l'**IA « classique »**, qui se distingue de l'apprentissage automatique que le cours étudiera ensuite.



La carte de l'IA : le Module 1 porte sur l'IA « classique » (symbolique), antérieure à l'apprentissage automatique.

Une idée traverse tout le module. Dès les années 1950, **deux grandes hypothèses rivales** sur la nature de l'intelligence apparaissent presque en même temps. L'une considère l'esprit comme de la **logique** (manipuler des symboles, appliquer des règles). L'autre le considère comme un **cerveau** (un réseau qui apprend de ses expériences). Le Module 1 présente cette opposition, et le Module 3 montrera comment elle a évolué.

Le parcours du module

Le module suit l'ordre chronologique. Chaque chapitre présente une idée, puis la limite qui mène au chapitre suivant.

1. *Turing et la question fondatrice (1950)* : une machine peut-elle penser, le jeu de l'imitation, et la pensée vue comme un calcul.
2. *Deux paris rivaux (1956-1958)* : la naissance de l'IA à Dartmouth, l'esprit comme logique et l'esprit comme cerveau.
3. *L'âge d'or symbolique : chercher et raisonner* : résoudre un problème en explorant un espace d'états, l'explosion combinatoire, Deep Blue et ELIZA.
4. *Représenter le monde* : donner un savoir à la machine, SHRDLU et son micro-monde, le problème du sens commun.
5. *Capturer l'expertise : les systèmes experts* : les règles *si… alors…*, le moteur d'inférence, MYCIN, et le goulot d'étranglement de la connaissance.

6. *Les hivers et la bascule* : les deux périodes de recul de l'IA, ce qui reste du GOFAI aujourd'hui, et le passage à l'apprentissage.

Le travail noté 1 clôt le module.

Objectifs

À la fin de ce module, vous devriez être en mesure de :

- Expliquer ce qu'est l'IA symbolique et en quoi elle se distingue de l'apprentissage automatique étudié dans les modules 2 à 4;
- Situer les grandes étapes et les figures marquantes de l'histoire de l'IA, du test de Turing (1950) aux systèmes experts et aux « hivers » de l'IA;
- Décrire les idées algorithmiques centrales du GOFAI (recherche dans un espace d'états, règles, représentation des connaissances) à un niveau intuitif;
- Distinguer les deux hypothèses rivales sur la nature de l'intelligence, l'approche symbolique et l'approche connexionniste, et situer chacune dans l'histoire du domaine;
- Comprendre pourquoi cette approche a fini par atteindre ses limites (problème du sens commun, goulot d'étranglement de la connaissance), ce qui a ouvert la voie à l'apprentissage automatique;
- Reconnaître ce qui reste de l'IA symbolique dans l'informatique d'aujourd'hui (recherche de chemins, moteurs de règles, représentation des connaissances).

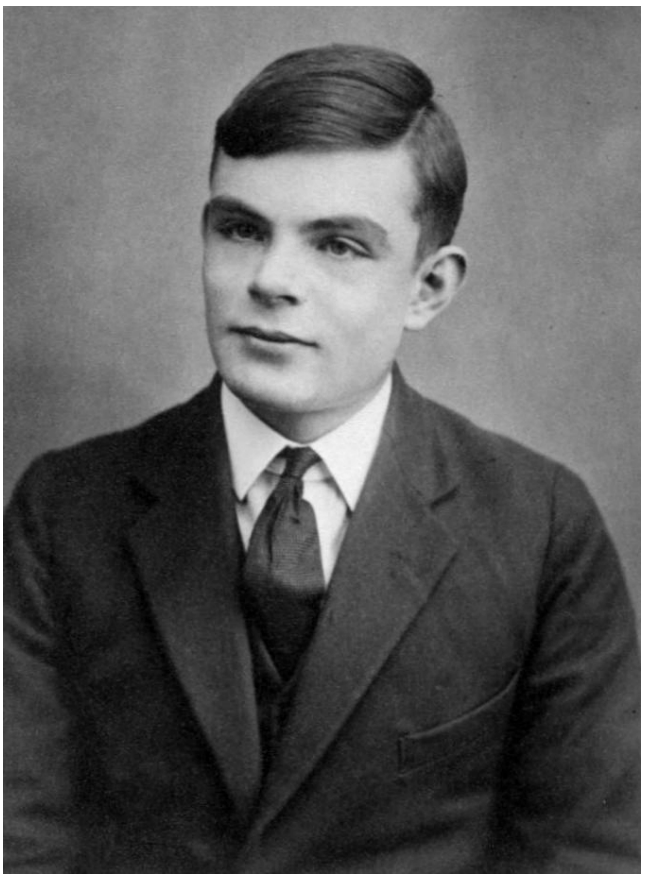
Durée

Deux semaines, soit environ 18 heures.

Évaluation

Le travail noté 1, qui compte pour 15 % de l'évaluation finale, vous fait jouer le rôle d'un **système expert**. À partir d'une base de règles `si… alors…`, vous suivez le raisonnement de la machine sur des cas concrets, vous trouvez un cas qu'elle ne sait pas traiter, puis vous ajoutez une règle pour combler ce manque. Ce travail vous permet de constater par vous-même les forces et la fragilité de l'IA symbolique.

Turing et la question fondatrice (1950)



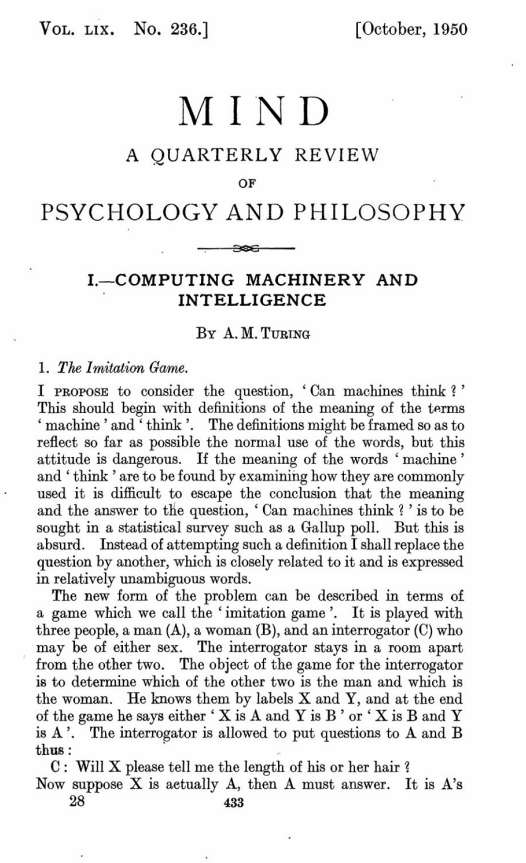
Alan Turing adolescent, vers 1928.

Alan Turing adolescent, vers 1928. Domaine public — Wikimedia Commons.

Le moment

En 1950, peu après la fin de la Seconde Guerre mondiale, le mathématicien britannique **Alan Turing** publie un article intitulé *Computing Machinery and Intelligence*. L'article commence par une question qui occupera tout un domaine pendant les décennies suivantes :

> *« Les machines peuvent-elles penser ? »*



VOL. LIX. No. 236.] [October, 1950

MIND

A QUARTERLY REVIEW

OF

PSYCHOLOGY AND PHILOSOPHY

I.—COMPUTING MACHINERY AND INTELLIGENCE

BY A. M. TURING

1. *The Imitation Game.*

I PROPOSE to consider the question, 'Can machines think?' This should begin with definitions of the meaning of the terms 'machine' and 'think'. The definitions might be framed so as to reflect so far as possible the normal use of the words, but this attitude is dangerous. If the meaning of the words 'machine' and 'think' are to be found by examining how they are commonly used it is difficult to escape the conclusion that the meaning and the answer to the question, 'Can machines think?' is to be sought in a statistical survey such as a Gallup poll. But this is absurd. Instead of attempting such a definition I shall replace the question by another, which is closely related to it and is expressed in relatively unambiguous words.

The new form of the problem can be described in terms of a game which we call the 'imitation game'. It is played with three people, a man (A), a woman (B), and an interrogator (C) who may be of either sex. The interrogator stays in a room apart from the other two. The object of the game for the interrogator is to determine which of the other two is the man and which is the woman. He knows them by labels X and Y, and at the end of the game he says either 'X is A and Y is B' or 'X is B and Y is A'. The interrogator is allowed to put questions to A and B thus:

C: Will X please tell me the length of his or her hair?

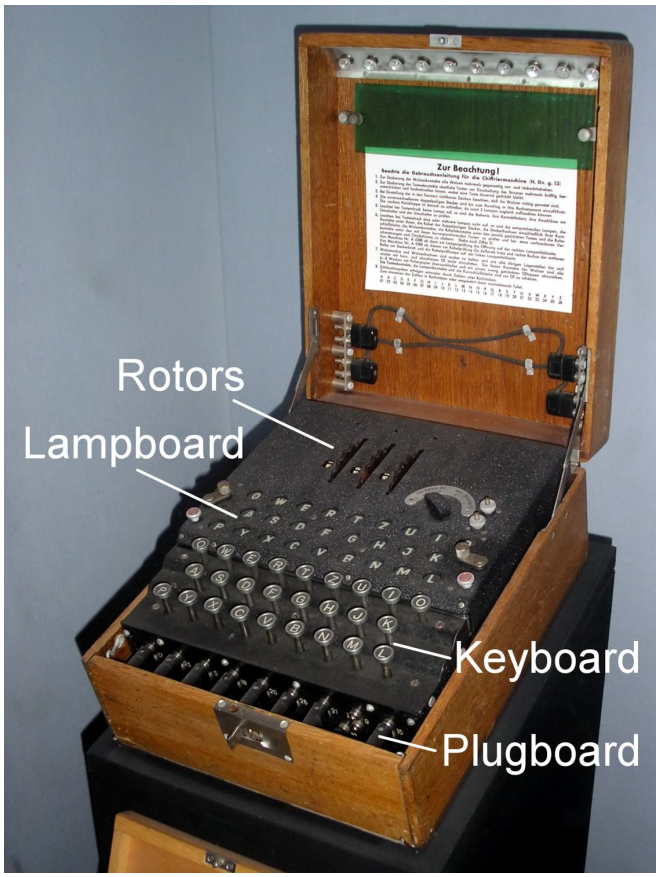
Now suppose X is actually A, then A must answer. It is A's

28 433

La première page de l'article, dans la revue Mind, en octobre 1950. L'article commence par la question « Can machines think? ».

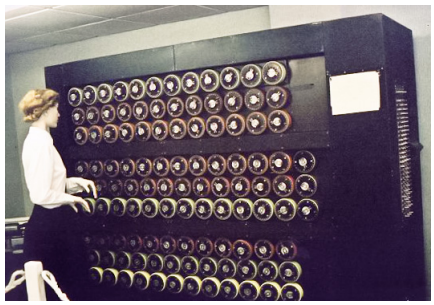
La première page de « Computing Machinery and Intelligence », *Mind*, vol. LIX, nº 236, octobre 1950.

Turing est déjà connu à ce moment. Pendant la guerre, il a joué un rôle décisif dans le décryptage des communications chiffrées par la machine **Enigma** des armées allemandes. Il a conçu des dispositifs électromécaniques capables d'explorer mécaniquement des millions de combinaisons. Ce travail est longtemps resté secret, et les historiens estiment qu'il a pu écourter le conflit de plusieurs années. Turing sait donc mieux que quiconque à son époque qu'une machine peut accomplir des tâches qu'on croyait réservées à l'esprit humain. Son article examine si une machine qui déchiffre des messages peut aussi être considérée comme une machine qui pense.



Une machine Enigma.

Une machine Enigma. Photo : Karsten Sperling, domaine public.



Une « bombe » de décryptage, Bletchley Park.

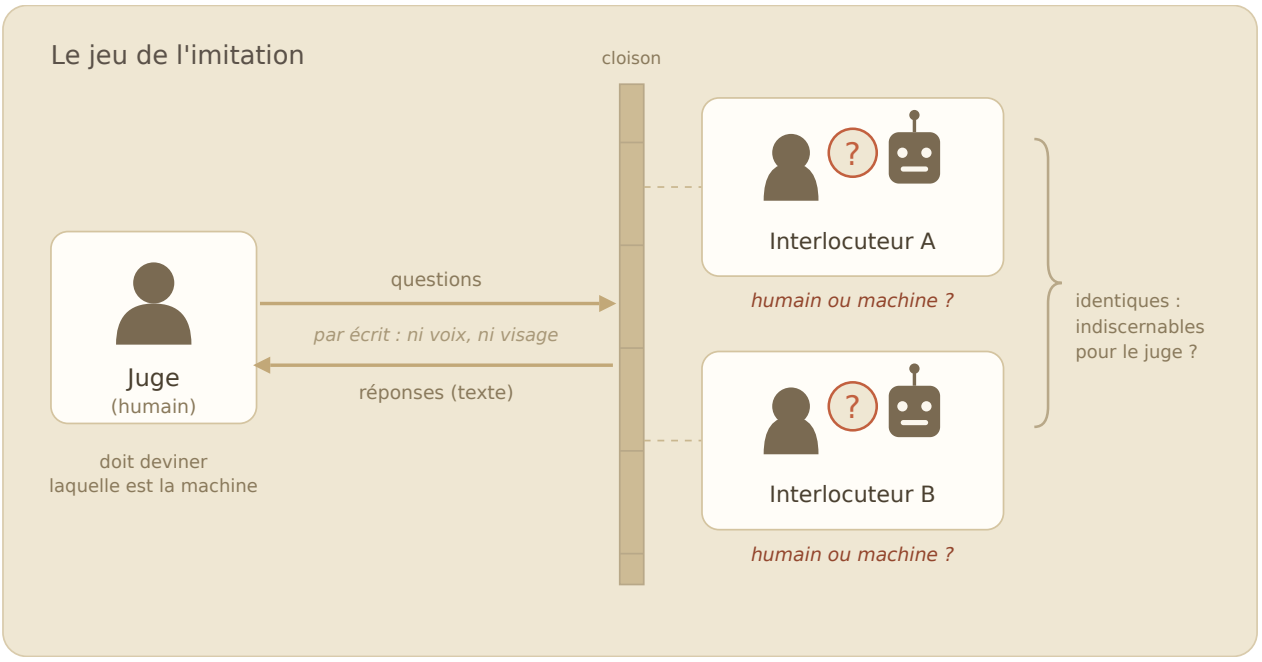
Reconstitution d'une « bombe » de décryptage, Bletchley Park. Photo : Sarah Hartwell, CC BY-SA 3.0, via Wikimedia Commons.

Le jeu de l'imitation

Turing remarque que la question « les machines peuvent-elles penser ? » est mal posée. La réponse dépend entièrement de ce qu'on accepte d'appeler « penser », et on ne sait pas définir clairement ce mot, même pour les humains. Plutôt que d'entrer dans ce débat, Turing **remplace la question par une autre**, à laquelle on peut réellement répondre.

Au lieu de demander si une machine peut penser, il propose une épreuve concrète, le **jeu de l'imitation** (*imitation game*), qu'on appelle aujourd'hui le **test de Turing**. Un juge humain dialogue par écrit avec deux interlocuteurs cachés, un être humain et une machine. Les messages passent par clavier, pour que ni la voix ni le visage ne permettent de savoir qui est qui. Le juge peut poser n'importe quelle question, par exemple sur la météo, la poésie, l'arithmétique ou ses souvenirs d'enfance. Il doit deviner lequel des deux interlocuteurs est la machine. Selon Turing, si la machine parvient, sur un grand nombre de parties, à se faire passer pour un humain aussi souvent qu'un humain y parvient, il n'y a plus de raison sérieuse de refuser de dire qu'elle pense.

Dans l'article, le jeu est d'abord présenté avec un homme et une femme, que l'interrogateur doit distinguer. Turing demande ensuite ce qui arriverait si une machine prenait la place de l'un des deux. C'est cette seconde version qui a été retenue par la suite, et vous pouvez le vérifier sur la page de *Mind* reproduite plus haut.



Le jeu de l'imitation : le juge ne dispose que du texte échangé pour reconnaître la machine.

Cette proposition est à la fois philosophique et technique. Turing **remplace la question de l'intériorité par celle du comportement**. Ce qui se passe « à l'intérieur » de la machine, ou le fait qu'elle « ressente » quelque chose, n'a pas d'importance. Ce qui compte, c'est ce qu'elle est capable de faire. Ce changement de point de vue soulève une question de fond, que les philosophes débattent encore aujourd'hui :

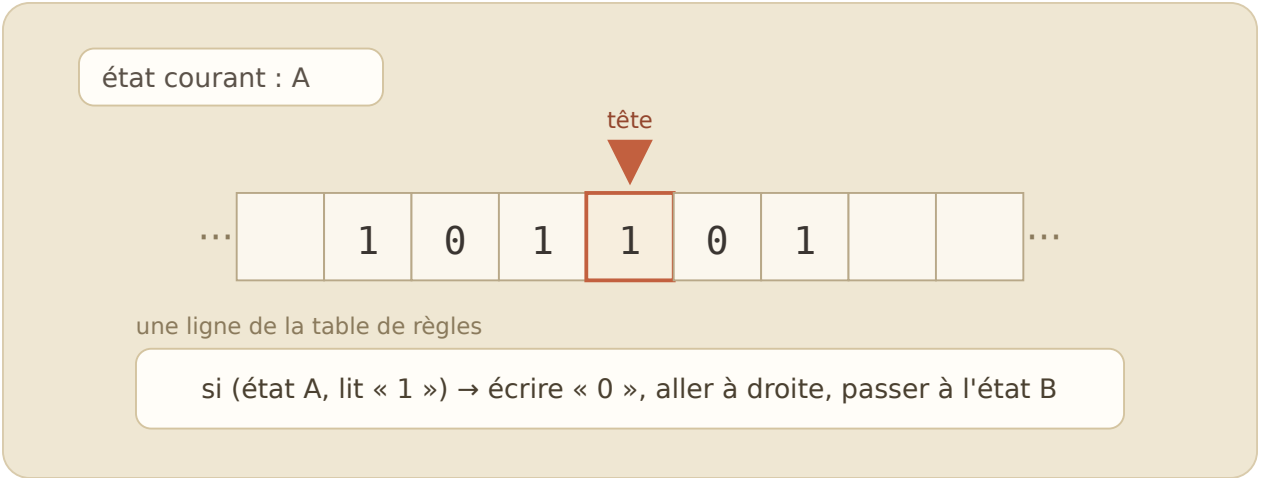
Qu'est-ce qui ferait qu'une machine « pense » vraiment ?
La proposition de Turing correspond aux idées dominantes de 1950, en particulier au **behaviorisme**. Ce courant de la psychologie soutenait qu'on ne peut pas faire de science avec ce qui se passe « dans la tête » (invisible et invérifiable), mais seulement avec le **comportement observable**. Juger la machine sur ses réponses plutôt que sur sa vie intérieure est conforme à cette approche. Une autre thèse, plus précise, allait cependant donner à l'IA son principal

fondement philosophique, le **fonctionnalisme**. Selon cette thèse, un état mental n'est pas défini par la *matière* qui le produit, mais par le *rôle* qu'il joue, c'est-à-dire par ses causes et ses effets. La douleur, par exemple, est « ce qui est causé par une blessure et qui cause le retrait et la plainte », qu'elle soit réalisée par des neurones humains, par le système nerveux d'un poulpe ou par les circuits d'un ordinateur. De ce point de vue, la frontière entre l'esprit et la machine est moins nette dans les deux sens. Un ordinateur pourrait penser, et **notre propre cerveau peut être vu comme une sorte d'« ordinateur biologique »**, un support matériel qui réalise lui aussi une certaine organisation. Si l'esprit est une *organisation* et non une *substance*, rien n'empêche qu'il soit réalisé sur du silicium aussi bien que sur des neurones. C'est ce qui permet de considérer l'IA comme un projet sérieux. Nous reviendrons sur cette idée, et sur sa critique la plus célèbre, la *Chambre chinoise* (*Chinese room*) du philosophe John Searle, au Module 5.

Le test de Turing est souvent mal compris. Ce n'est **pas** un test de conscience, ni une définition de l'intelligence au sens large. C'est une proposition *pragmatique* : *si* on ne peut plus distinguer la machine de l'humain en conversation, *alors* chercher à savoir si elle « pense vraiment » devient un débat sans issue. Le test contourne une question insoluble, il ne la résout pas.

La pensée comme calcul

Le test repose sur une idée plus fondamentale, qui constitue le principal apport de Turing à l'IA. Dès 1936, bien avant son article sur le jeu de l'imitation, Turing avait inventé un objet mathématique qu'on appelle aujourd'hui la **machine de Turing**. C'est un dispositif imaginaire très simple, qui se contente de lire et d'écrire des symboles sur un ruban en suivant un ensemble de règles fixes.



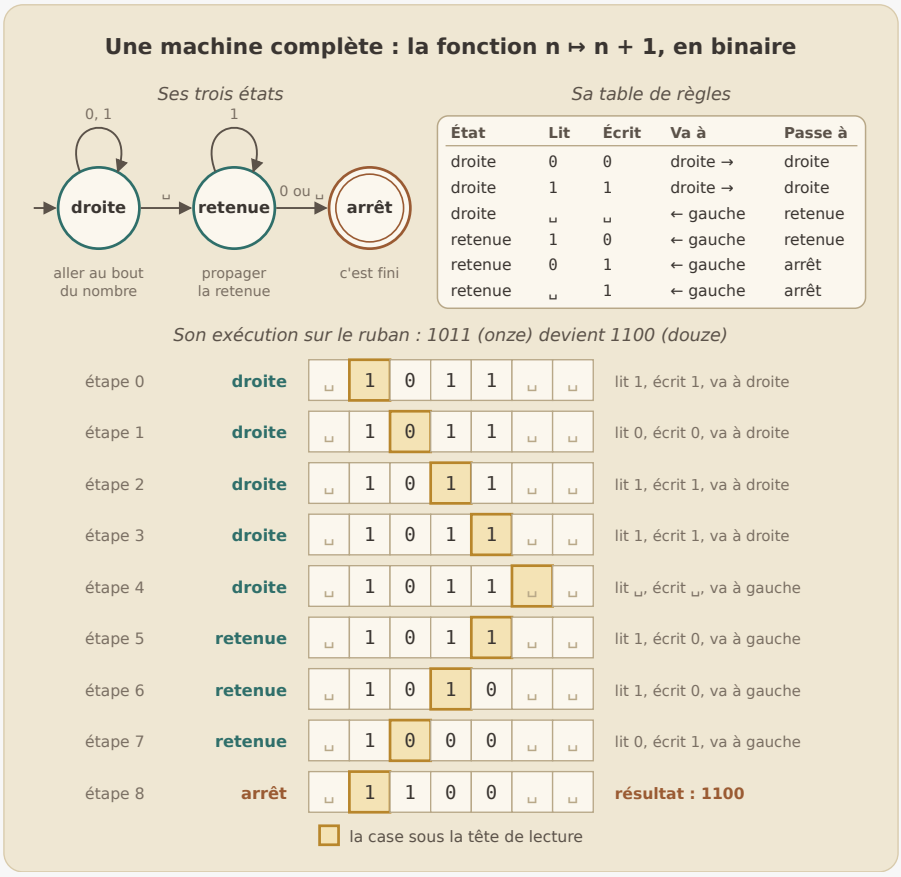
Une machine de Turing : lire un symbole, l'écrire, se déplacer, changer d'état.

Turing montre que ce mécanisme élémentaire peut, en principe, **calculer tout ce qui est calculable**. La machine de Turing donne ainsi une définition précise d'une notion qu'on emploie couramment sans la définir, celle d'**algorithme**. Un algorithme est une suite finie d'étapes sans ambiguïté. On admet que tout ce qu'un algorithme peut accomplir, une machine de Turing peut l'accomplir aussi, et réciproquement. Les expressions « algorithme », « machine de Turing » et « ce qui est calculable » désignent donc la même chose. De plus, il existe une *machine universelle*, capable d'imiter

n'importe quelle autre machine à partir de sa description, qu'elle reçoit en entrée. C'est le principe de l'ordinateur moderne : un seul appareil physique qui, selon le programme qu'on lui fournit, sert de traitement de texte, de jeu vidéo ou de calculatrice. Votre téléphone est, en ce sens, une machine universelle de Turing.

Turing laisse ainsi aux fondateurs de l'IA un **pari implicite** : *si* penser n'est qu'une forme de calcul (manipuler des symboles selon des règles), *et si* une machine peut tout calculer, *alors* une machine devrait pouvoir penser. Tout le programme de recherche des décennies suivantes, que nous suivrons dans ce module, découle de ce raisonnement. Turing laisse cependant ouverte une question qui sera centrale dans la suite : penser se réduit-il vraiment à calculer ?

Pour aller plus loin : qu'est-ce qu'une machine de Turing, concrètement ?
Une machine de Turing comprend un ruban de papier infini divisé en cases, une tête qui se déplace le long du ruban en lisant et en écrivant un symbole à la fois, et une petite table de règles de la forme « si je suis dans l'état A et que je lis un `0`, alors j'écris un `1`, je me déplace d'une case vers la droite et je passe à l'état B ». Elle ne comprend rien d'autre, ni grande mémoire ni intelligence cachée, seulement des symboles, des règles et un état courant. Ce mécanisme minimal suffit pourtant à exprimer n'importe quel calcul réalisable par n'importe quel ordinateur, aussi puissant soit-il. Voici un exemple complet. La machine ci-dessous calcule une fonction précise, **ajouter 1 à un nombre écrit en binaire**, avec trois états et six règles. Dans l'état *droite*, elle avance sans rien changer jusqu'à dépasser le dernier chiffre. Elle revient ensuite vers la gauche dans l'état *retenue* et fait la même chose que vous lorsque vous posez une addition. Tant qu'elle lit un 1, elle écrit 0 et reporte la retenue à gauche. Dès qu'elle lit un 0 (ou une case vide, si le nombre n'était composé que de 1), elle écrit 1 et s'arrête. Suivez l'exécution ligne par ligne : onze, 1011, devient douze, 1100, en huit pas.



Une machine de Turing complète : trois états, six règles, et la fonction $n \mapsto n + 1$ exécutée pas à pas sur le ruban.

La machine ne sait pas qu'il s'agit de nombres et ne connaît ni « onze » ni « douze ». Elle lit un symbole, consulte sa table, écrit, se déplace et change d'état. Le sens existe pour nous, mais pour elle il n'y a que la règle. Des machines un peu plus grandes additionnent, multiplient ou trient. On peut aussi en construire une, dite *universelle*, qui lit sur son ruban la table de n'importe quelle autre machine et l'exécute. C'est exactement l'idée d'un ordinateur et de son programme.

Une fois qu'on connaît une machine à trois états, on peut se poser une question d'apparence simple : parmi toutes les machines à n états qui finissent par s'arrêter, laquelle effectue le plus de pas avant de s'arrêter ? On appelle cette machine le **castor affairé** (*busy beaver*), et le nombre de pas qu'elle effectue est une fonction de n. Les premières valeurs sont petites : 6 pas pour deux états, 21 pour trois, 107 pour quatre. Pour cinq états, la réponse, 47 176 870 pas, n'a été établie qu'en 2024 par une collaboration internationale d'amateurs, le *Busy Beaver Challenge*. Ce groupe a dû examiner une à une des dizaines de millions de machines et faire vérifier sa preuve par ordinateur. Pour six états, on sait seulement que le nombre dépasse tout ce qu'on peut raisonnablement écrire. Au-delà, la difficulté devient une impossibilité, car cette fonction est **non calculable** (*uncomputable*). Aucun algorithme ne peut la donner pour tout n, parce que la connaître permettrait de savoir, pour n'importe quelle machine, si elle s'arrêtera un jour. Il suffirait de laisser tourner la machine pendant le nombre de pas du castor affairé. Si elle tourne encore après ce nombre de pas, elle ne s'arrêtera jamais. Il s'agit en fait du problème de l'arrêt, présenté plus bas, sous une autre forme. On a donc une suite de nombres parfaitement définis,

dont les premiers sont petits, mais dont on ne connaîtra jamais que les tout premiers termes. Elle montre concrètement où se trouve une limite du calcul.
La machine de Turing ne sert pas à calculer rapidement. Elle sert à définir précisément ce que « calculer » veut dire. L'idée que tout procédé de calcul imaginable se ramène à une machine de Turing porte d'ailleurs un nom, la **thèse de Church-Turing**.

L'ombre de Gödel

L'idée que penser revient à calculer comportait pourtant une **limite**, établie presque au même moment. En **1931**, cinq ans avant la machine de Turing, un jeune logicien autrichien, **Kurt Gödel**, avait démontré un résultat qui a profondément remis en question les fondements des mathématiques, son **théorème d'incomplétude** (*incompleteness theorem*).



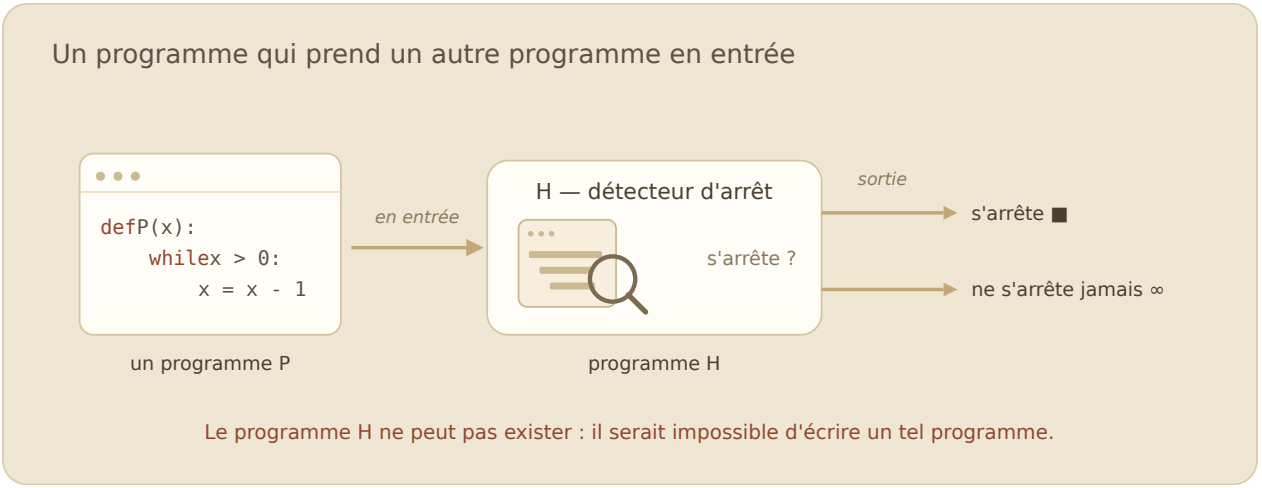
Kurt Gödel étudiant, vers 1925.

Kurt Gödel étudiant, vers 1925. Domaine public — Wikimedia Commons.

Le résultat est simple à énoncer. Tout système de règles formelles assez puissant pour faire de l'arithmétique contient des énoncés qui sont **vrais**, mais que le système est **incapable de prouver**. La vérité dépasse donc toujours la démonstration, et aucun ensemble de règles, aussi complet soit-il, ne peut tout capturer. La preuve repose sur une idée qui sera importante pour nous, l'**auto-référence** (*self-reference*). Gödel construit, à l'intérieur du système, un énoncé qui parle de lui-même et qui affirme en substance : « *Cet énoncé n'est pas démontrable.* » Si le système démontrait cet énoncé, il

prouverait quelque chose de faux. Il ne peut donc pas le démontrer, et c'est précisément pour cette raison que l'énoncé est vrai. Le système ne peut pas sortir de cette boucle.

Turing a lui-même prolongé ce résultat. Sa machine de 1936 servait aussi à montrer qu'il existe des questions qu'**aucun algorithme ne pourra jamais trancher**. La plus connue est le **problème de l'arrêt** (*halting problem*) : déterminer, pour un programme donné, s'il finira par s'arrêter ou s'il tournera à l'infini. Celui qui a proposé l'idée « penser = calculer » a donc aussi établi les **frontières** du calcul. Le projet de l'IA comporte ainsi, dès son origine, la reconnaissance de ses propres limites.



Le problème de l'arrêt (halting problem) : un programme qui prendrait un autre programme en entrée pour prédire s'il s'arrête, et pourquoi il ne peut pas exister.

Pour la question de savoir si une machine peut penser, on a tiré de Gödel **deux conclusions opposées**. Toutes deux reviendront jusqu'à la fin du cours.

Première lecture : le théorème est une limite. Le physicien **Roger Penrose** en a tiré l'argument le plus connu contre l'IA. Selon lui, nous, humains, sommes capables de voir qu'un tel énoncé est vrai, alors que la machine ne le peut pas. Si notre esprit saisit une vérité qu'aucun système formel ne peut prouver, c'est qu'il ne se réduit **pas** à un système formel, autrement dit que penser ne se ramène pas à du calcul. Nous reviendrons en détail sur cette thèse au **Module 5**, avec celle d'un autre critique connu de l'IA, le philosophe John Searle.

Seconde lecture : le théorème est une source. Pour le penseur américain **Douglas Hofstadter** (auteur du livre *Gödel, Escher, Bach* (1979), où il développe précisément cette idée), la boucle auto-référentielle de Gödel n'est pas un défaut, mais le fondement même de l'esprit. Un système assez riche pour se **représenter lui-même** produit une « **boucle étrange** » (*strange loop*). Selon Hofstadter, c'est de ce retour sur soi que naîtraient le sentiment d'un « je », le sens et la conscience. L'auto-référence n'empêcherait donc pas la machine de penser, elle en serait la **source**. Nous retrouverons Hofstadter et ses idées à plusieurs reprises dans ce module.

Le même théorème conduit donc à deux conclusions inverses : l'auto-référence est soit une *limite* infranchissable, soit l'*origine* de l'esprit. Ce désaccord n'est toujours pas tranché. Il faut surtout retenir que, dès son origine, le projet d'une pensée mécanique s'accompagne de questions sur ses limites.

Pour aller plus loin : ce que dit, et ne dit pas, le théorème de Gödel
Le théorème s'applique à tout système formel **cohérent** (sans contradiction) et assez riche pour exprimer l'arithmétique. Gödel établit en fait deux résultats. Un tel système ne peut pas prouver tous les énoncés arithmétiques vrais (**premier théorème**), et il ne peut pas non plus prouver sa **propre cohérence** (**second théorème**). L'outil technique central est le *codage de Gödel* (*Gödel numbering*), qui consiste à numéroter chaque énoncé pour que le système puisse, en parlant de nombres, **parler de lui-même**. Gödel peut ainsi construire la phrase « je ne suis pas démontrable ».
Cette phrase est une variante du **paradoxe du menteur** (*liar paradox* : « cette phrase est fausse »), dont Gödel s'est explicitement inspiré. Le paradoxe du menteur aboutit à une contradiction. Gödel remplace « faux » par « indémontrable », si bien que sa phrase ne se contredit pas. Elle est simplement **vraie sans être démontrable**. Ce remplacement transforme un paradoxe sans issue en théorème.



Le paradoxe du menteur : une phrase qui porte sur elle-même et ne peut être ni vraie ni fausse.

La science-fiction a souvent prêté ce paradoxe aux humains pour piéger les machines. Dans l'épisode « I, Mudd » de la série *Star Trek* (1967), le capitaine Kirk et l'escroc Harry Mudd mettent hors d'état de fonctionner un androïde en lui servant une variante du paradoxe du menteur.
Vidéo : https://www.youtube.com/watch?v=EzVxsYzXI_Y
Il faut éviter deux contresens. Le théorème ne dit **pas** que « les mathématiques sont fausses », ni que la vérité serait une affaire d'opinion. C'est une limite **précise** sur ce qu'une démonstration *formelle, à l'intérieur d'un système donné*, peut atteindre. On peut toujours prouver l'énoncé en question dans un système **plus puissant**, mais ce nouveau système aura à son tour ses propres énoncés indémontrables. Quant à l'argument de Penrose, il reste **contesté**. Ses critiques objectent que rien ne garantit qu'un humain puisse réellement « voir » la vérité de cet énoncé sans supposer d'avance, sans justification, la cohérence du système.

Une fin tragique, et une porte qui s'ouvre

La vie de Turing se termine tragiquement. En 1952, il est poursuivi par la justice britannique en raison de son homosexualité, alors illégale, et condamné à subir un traitement hormonal, une castration chimique. Écarté et privé de son habilitation de sécurité, il meurt en 1954, à 41 ans, empoisonné au cyanure, dans des circonstances qu'on a longtemps considérées comme un suicide. Il ne verra pas les machines pensantes qu'il avait imaginées. Le gouvernement britannique présente des excuses officielles en **2009**, et Turing reçoit une grâce royale posthume en **2013**.

Turing a posé la question et proposé une orientation, *la pensée comme calcul*, mais il n'a pas précisé comment construire concrètement une machine intelligente. Cette tâche revient à la génération suivante. Dès le départ, celle-ci se divise entre **deux réponses rivales**, apparues presque en même temps, qui reposent sur deux conceptions très différentes de l'intelligence. C'est le sujet de « Deux paris rivaux ».

Deux paris rivaux (1956-1958)

Le moment : l'été 1956 à Dartmouth

À l'été 1956, un petit groupe de chercheurs se réunit pendant deux mois sur le campus du **Dartmouth College**, dans le New Hampshire, pour un atelier qui est considéré comme l'**acte de naissance** de la discipline. L'expression « **intelligence artificielle** » apparaît pour la première fois dans la proposition de financement de cet atelier, rédigée l'année précédente par le jeune mathématicien **John McCarthy**. Le mot est choisi en partie pour marquer une rupture avec une étiquette alors dominante, la **cybernétique**.



Dartmouth Hall, sur le campus du Dartmouth College où se tint l'atelier de 1956.

Dartmouth Hall (Dartmouth College). Photo : Kenneth C. Zirkel, CC BY 4.0, via Wikimedia Commons.

La cybernétique. Fondée en 1948 par le mathématicien Norbert Wiener (le mot vient du grec *kubernêtês*, le pilote d'un navire), la cybernétique étudiait ce que les machines et les êtres vivants ont en commun lorsqu'ils se **règlent eux-mêmes**. Un thermostat qui maintient une température, un organisme qui maintient la sienne et un missile qui corrige sa trajectoire obéissent au même principe, la **rétroaction** (*feedback*). L'effet d'une action est mesuré et renvoyé à celui qui agit, pour qu'il se corrige. Une bonne partie de ce qui suit dans ce cours vient de là, en particulier

l'idée d'une machine qui s'ajuste d'après ses erreurs. Cependant, la cybernétique raisonnait en signaux continus, en boucles et en organismes, à la frontière de la biologie et de l'ingénierie. McCarthy voulait une science du raisonnement et des symboles et, selon certains témoignages, ne tenait pas à devoir composer avec l'autorité de Wiener. Il a donc choisi un nom nouveau. *Le même mot grec a aussi donné son nom, en 2014, au logiciel Kubernetes, qui « pilote » des conteneurs dans les centres de données, d'où son logo en forme de barre de navire. Les deux n'ont en commun que l'étymologie.*



Devant Dartmouth Hall, à l'été 1956 : les organisateurs de l'atelier et quelques participants.

Devant Dartmouth Hall, été 1956. À l'arrière, de gauche à droite : Oliver Selfridge, Nathaniel Rochester, Marvin Minsky et John McCarthy ; à l'avant : Ray Solomonoff, Peter Milner et Claude Shannon. Photo : famille Minsky.

L'ambition affichée est très grande. La proposition postule que *« tout aspect de l'apprentissage, ou de toute autre caractéristique de l'intelligence, peut en principe être décrit avec une telle précision qu'une machine peut être construite pour le simuler »* (en version originale : *« every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it »*). Les organisateurs sont McCarthy, **Marvin Minsky**, **Claude Shannon** (le père de la théorie de l'information) et **Nathaniel Rochester**, d'IBM. Ils pensent sincèrement qu'un groupe d'une dizaine de personnes peut faire des progrès significatifs sur ce programme en un seul été.

Ce travail, qu'ils pensaient mener en quelques étés, a occupé plusieurs générations de chercheurs et n'est toujours pas terminé. L'atelier de Dartmouth a cependant lancé le domaine. Très rapidement, deux familles d'idées sur la façon de construire cette intelligence s'y dessinent.

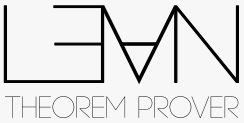
Un mot qui a changé de sens. Si vous abordez ce cours en pensant à ChatGPT, il faut savoir que ce que McCarthy et ses collègues appelaient « intelligence artificielle » en 1956 a très peu de rapport avec ce que ce mot désigne aujourd'hui dans la conversation courante. Pour eux, l'IA consistait à faire **raisonner** une machine : manipuler des symboles, appliquer des règles de logique, explorer méthodiquement des possibilités, comme on le fait pour démontrer un théorème ou jouer aux échecs. Aucune partie de ce programme n'apprenait à partir de grandes quantités de données. Aujourd'hui, le mot « IA » désigne presque toujours les **grands modèles de langage** (*large language models*) et les modèles apparentés qui génèrent des images. Ce sont d'immenses réseaux de neurones (*neural networks*), entraînés sur une bonne partie de ce que l'humanité a écrit, qui ne contiennent aucune règle écrite à la main.
Ce module raconte ce renversement. L'expression a été créée par les partisans du premier pari, celui de la logique. Elle est aujourd'hui associée aux héritiers du second, celui du cerveau et de l'apprentissage, que les premiers ont longtemps considéré comme une impasse. Entre les deux, il y a soixante-dix ans, deux « hivers » (*AI winters*) et un renversement que rien ne laissait prévoir. Gardez donc les deux sens à l'esprit. Dans les pages qui suivent, « IA » a d'abord le sens qu'il avait à Dartmouth.

Le premier pari : l'esprit comme logique

La première famille d'idées prolonge directement l'intuition de Turing. Si penser consiste à calculer, alors **l'intelligence consiste à manipuler des symboles selon des règles logiques**. Un symbole est ici un jeton qui représente quelque chose (un mot, un objet, une idée). Raisonner consiste à combiner ces jetons d'après des règles précises, comme un mathématicien enchaîne les étapes d'une démonstration. Dans cette vision, il importe peu que la machine ressemble ou non à un cerveau. Ce qui compte, c'est qu'elle possède les bons symboles et les bonnes règles. On parle d'approche **descendante** (*top-down*), parce qu'on programme le raisonnement explicitement, « par le haut ».

Cette approche a rapidement donné des résultats concrets. Dès 1956, un programme nommé **Logic Theorist**, conçu par **Allen Newell** et **Herbert Simon** et présenté à Dartmouth, démontre des théorèmes de logique mathématique tirés d'un ouvrage de référence, les *Principia Mathematica* de Russell et Whitehead. Pour l'une de ces démonstrations, il trouve même une solution plus élégante que celle des auteurs. On le considère souvent comme le **premier programme d'intelligence artificielle**, c'est-à-dire une machine qui ne calcule pas des nombres, mais qui raisonne, du moins en apparence.

Soixante-dix ans plus tard. La démonstration de théorèmes par machine (*automated theorem proving*) a progressé d'une manière que Newell et Simon n'avaient pas prévue. En 2025, des grands modèles de langage entraînés par renforcement ont atteint le niveau d'une médaille d'or aux Olympiades internationales de mathématiques. En septembre 2026, l'un d'eux a traduit toute la démonstration du dernier théorème de Fermat dans **Lean**, un langage où chaque étape d'une preuve est vérifiée par la machine. Les spécialistes estimaient ce travail à plusieurs années. Un autre système a annoncé avoir résolu une version de l'un des sept problèmes du millénaire, celui des équations de Navier-Stokes, un résultat que les mathématiciens sont encore en train de vérifier. Ces machines raisonnent elles aussi, mais elles sont issues de l'autre pari, celui de l'apprentissage, et ne contiennent aucune règle de logique écrite à la main. Nous y reviendrons au Module 4.



Lean, un vérificateur de preuves. Le langage **Lean**, dans lequel la démonstration de Fermat a été traduite, a été créé en 2013 par Leonardo de Moura chez Microsoft Research. Dans Lean, chaque étape d'une démonstration doit être justifiée par une règle de logique précise. Un petit programme central, le *noyau*, vérifie ensuite que chaque étape respecte ces règles. Si le noyau accepte la preuve, le théorème est établi avec une certitude qu'aucune relecture humaine ne peut garantir pour des démonstrations de centaines de pages. Par exemple, l'énoncé suivant est vérifié par Lean :

```
theorem deux_plus_deux : 2 + 2 = 4 := by norm_num
```

Des mathématiciens du monde entier alimentent une bibliothèque commune, **Mathlib**, qui contient déjà une grande partie des mathématiques enseignées à l'université.

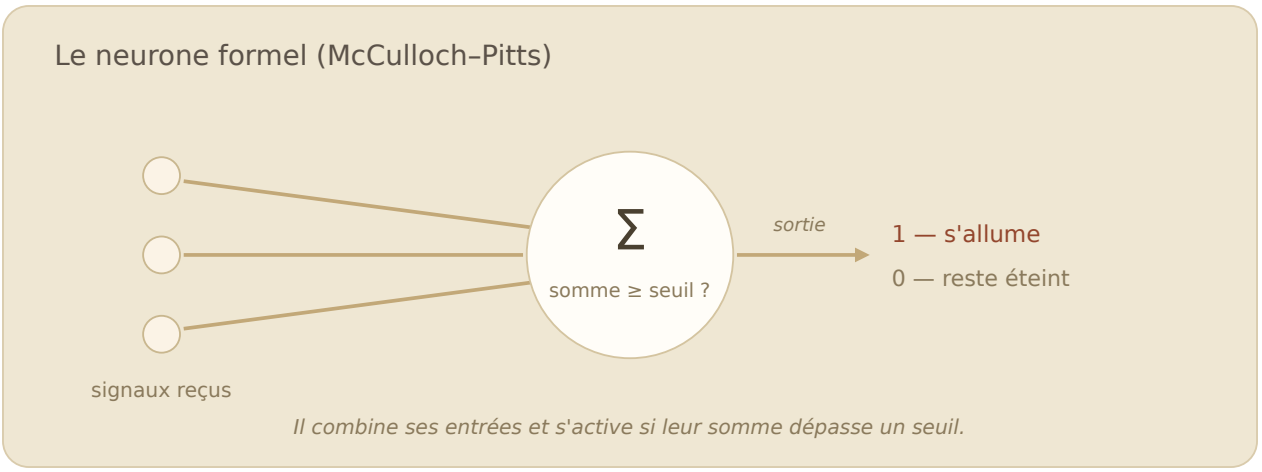
Lean appartient à la tradition symbolique présentée dans ce chapitre : des règles explicites, appliquées mécaniquement. Il est aujourd'hui au centre d'une combinaison des deux paris. Un modèle de langage, issu de l'apprentissage, propose des étapes de démonstration, et Lean vérifie qu'elles sont correctes. Le modèle peut se tromper, mais une erreur ne passe pas la vérification. C'est ainsi qu'ont été obtenus plusieurs des résultats mentionnés ci-dessus. Pour en savoir plus : lean-lang.org.

Ces succès suscitent un grand enthousiasme. Newell et Simon formulent une hypothèse forte : un système qui manipule des symboles de la bonne manière posséderait tout ce qu'il faut pour être intelligent. Pendant les décennies suivantes, cette voie **symbolique** domine la recherche et obtient l'essentiel des financements. Elle fait l'objet des chapitres suivants : la recherche, la représentation des connaissances (*knowledge representation*), les systèmes experts (*expert systems*).

Le second pari : l'esprit comme cerveau

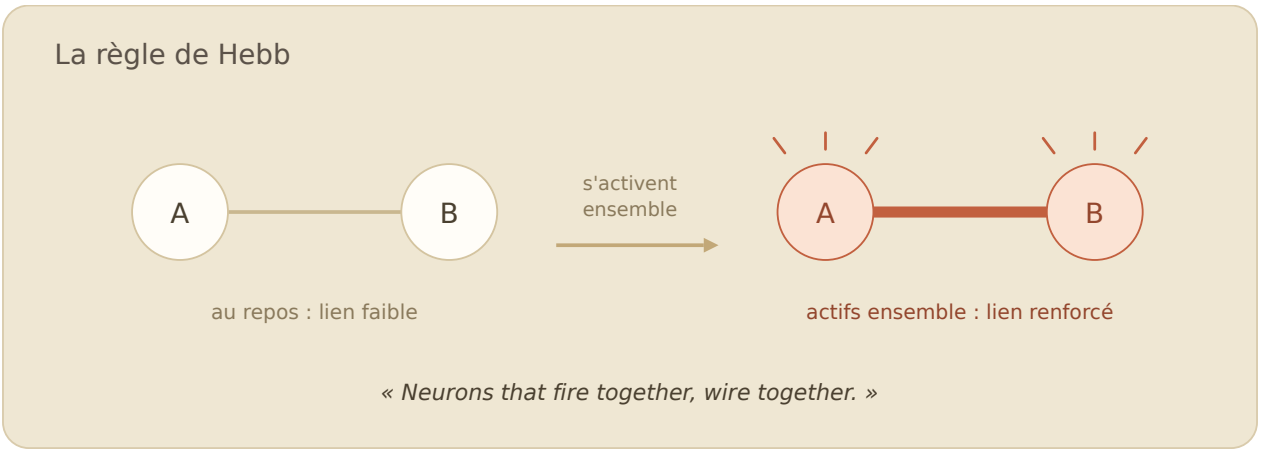
À la même époque, une idée très différente apparaît. Au lieu de programmer le raisonnement explicitement, on pourrait construire une machine qui **apprend seule, à partir d'exemples**, en s'inspirant de l'organe qui est déjà intelligent, le **cerveau**.

Cette idée a une origine précise. En 1943, deux chercheurs, **Warren McCulloch** et **Walter Pitts**, proposent un modèle mathématique très simplifié du neurone. C'est une petite unité qui reçoit des signaux, les combine et « s'allume » ou non selon que leur somme dépasse un certain seuil. Ils montrent qu'en reliant ces unités en réseau, on peut en principe réaliser des opérations logiques. C'est le premier lien établi entre le fonctionnement du cerveau et le calcul.



Le neurone formel : combiner des signaux, puis s'activer si leur somme dépasse un seuil.

Il restait à expliquer comment un tel réseau pourrait apprendre. En 1949, le psychologue **Donald Hebb** propose l'idée suivante : lorsque deux neurones s'activent ensemble de façon répétée, le lien qui les unit se renforce (« *neurons that fire together, wire together* »). Dans cette optique, apprendre ne consiste pas à réécrire des règles, mais à **ajuster la force des connexions**. C'est ce principe que Rosenblatt va appliquer dans sa machine.



La règle de Hebb : deux neurones qui s'activent ensemble voient leur lien se renforcer.

En 1958, le psychologue **Frank Rosenblatt** construit une machine réelle fondée sur cette idée, le **perceptron**. Au lieu de lui donner une règle, on montre au perceptron des exemples, par exemple des images étiquetées « cercle » ou « carré ». À chaque essai, s'il se trompe, il **ajuste légèrement ses réglages internes** pour se rapprocher de la bonne réponse. Exemple après exemple, il s'améliore, sans que personne ne lui ait jamais indiqué ce qui distingue un cercle d'un carré. Il a appris. C'est l'approche **ascendante** (*bottom-up*) : on n'écrit pas le savoir, on le laisse se former à partir des données.

Le perceptron suscite des attentes démesurées. En 1958, le *New York Times*, rapportant les propos de Rosenblatt, annonce que la marine américaine a dévoilé l'embryon d'une machine électronique qui « sera capable de marcher, parler, voir, écrire, se reproduire et avoir conscience de son existence ». On était évidemment très loin de ces capacités. L'idée centrale, celle d'une machine qui apprend de

ses erreurs, s'est cependant révélée très féconde. Elle est à la base de tout ce que nous étudierons aux modules 2, 3 et 4.

Le perceptron est l'**ancêtre direct des réseaux de neurones** actuels. L'apprentissage profond (*deep learning*) d'aujourd'hui est, pour l'essentiel, un empilement de perceptrons perfectionnés, en très grand nombre et sur de nombreuses couches. Nous étudierons cette filiation au **Module 3**.

Deux univers parallèles

On pourrait croire que ces deux paris se sont succédé, d'abord l'un, puis l'autre. Ce n'est pas le cas, et c'est l'une des idées les plus importantes de ce cours. Ils sont nés **presque en même temps** et ont **coexisté en rivaux** pendant plus d'un demi-siècle, chacun avec ses chercheurs, ses revues et ses financements.

Ces deux paris reposent sur **deux conceptions de l'esprit**. Pour le camp symbolique, l'esprit est essentiellement de la **logique**, c'est-à-dire des symboles et des règles, indépendamment du support qui les réalise. Pour le camp connexionniste, l'esprit est avant tout un **cerveau**, c'est-à-dire un réseau qui s'ajuste à l'expérience. La question « qu'est-ce que penser ? » reçoit donc deux réponses presque opposées.

Ces deux approches ne progressent pas en parallèle : elles **dominent tour à tour**. Dès la fin des années 1960, comme nous le verrons dans « Les hivers et la bascule », le camp symbolique met presque fin aux recherches sur le perceptron, et l'approche symbolique domine presque seule les vingt années suivantes. Il faut attendre les années 2010, étudiées au Module 3 de ce cours, pour que la tradition connexionniste revienne au premier plan, sous le nom d'*apprentissage profond*.

> La comparaison avec le cerveau est utile, mais il faut s'en méfier pour cette raison même. Le « neurone » de McCulloch, Pitts et Rosenblatt est une version extrêmement simplifiée du vrai neurone biologique. Nous y reviendrons en détail au Module 3, au moment où la tentation de confondre les deux sera la plus forte.

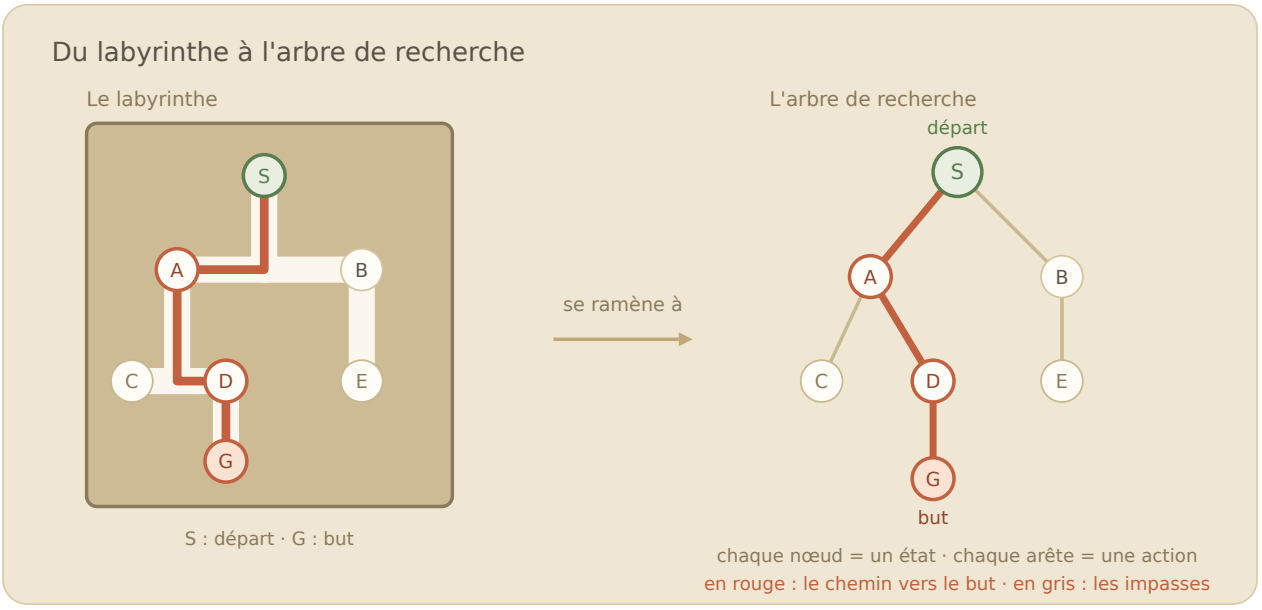
Pour le moment, nous laissons de côté le perceptron pour suivre le camp symbolique, qui est le premier à connaître une période de succès, celle des machines qui cherchent et qui raisonnent. C'est l'objet de « Chercher et raisonner ».

L'âge d'or symbolique : chercher et raisonner

Résoudre, c'est explorer

Une fois le pari symbolique posé, il reste une question pratique : comment faire raisonner une machine ? Les pionniers de l'IA trouvent une réponse très générale, parce qu'elle s'applique à des problèmes très différents. Presque tout problème peut se reformuler comme l'**exploration d'un espace de possibilités**.

Prenons l'exemple d'un labyrinthe. À chaque instant, vous êtes dans une certaine position, qu'on appelle un **état**. À partir de cet état, quelques actions sont possibles (avancer, tourner à gauche, tourner à droite), et chacune mène à un nouvel état. L'ensemble de tous les états atteignables forme une grande arborescence, l'**espace d'états** (*state space*). Résoudre le labyrinthe revient alors à **trouver un chemin** dans cette arborescence, depuis l'état de départ jusqu'à l'état-but (la sortie).



Un labyrinthe est un arbre d'états : résoudre, c'est trouver un chemin de S (départ) à G (but).

Cette idée est utile parce que beaucoup de problèmes qui semblent sans rapport prennent alors la même forme. Le taquin (un jeu de petites tuiles numérotées qu'on fait glisser), une partie d'échecs, la planification d'un itinéraire et la démonstration d'un théorème comportent tous un état de départ,

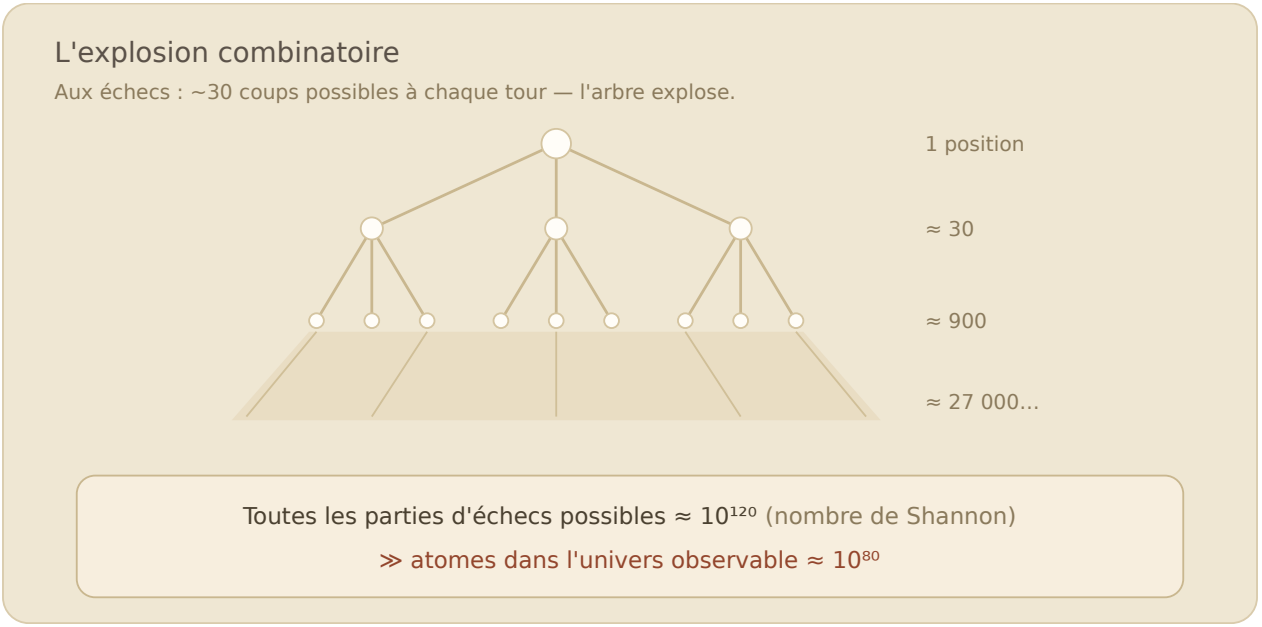
des actions qui font passer d'un état à un autre et un but à atteindre. Dans chaque cas, résoudre le problème revient à **chercher un chemin** vers ce but. Newell et Simon, les auteurs du Logic Theorist, poussent l'idée jusqu'à construire un programme appelé *General Problem Solver* (« solutionneur général de problèmes »), conçu pour traiter n'importe quel problème exprimé sous cette forme.

La recherche n'est pas une technique parmi d'autres. C'est le mécanisme central de l'IA symbolique (*symbolic AI*). Pour démontrer un théorème, planifier un trajet, diagnostiquer une panne ou lever l'ambiguïté d'une phrase, le GOFAI ramène le problème à l'exploration d'un espace de possibilités, jusqu'à y trouver une solution. Nous la retrouverons dans « Représenter le monde » et « Capturer l'expertise ». À la fin du module, dans *Les hivers et la bascule*, c'est aussi elle qui marquera la différence avec l'autre tradition : l'IA symbolique cherche une solution, alors que l'apprentissage automatique (*machine learning*) apprend à partir d'exemples.

L'explosion combinatoire

L'exploration d'un arbre de possibilités a cependant une limite importante. Pour la plupart des problèmes intéressants, cet arbre est **extrêmement grand**.

Les échecs en sont l'exemple le plus connu. À chaque tour, un joueur dispose en moyenne d'une trentaine de coups possibles. Chacun de ces coups permet une trentaine de réponses de l'adversaire, et ainsi de suite. Regarder seulement quelques coups à l'avance multiplie déjà fortement le nombre de branches à examiner. Le nombre de toutes les parties d'échecs possibles, appelé **nombre de Shannon**, vaut environ un 1 suivi de 120 zéros. Il dépasse de très loin le nombre d'atomes dans l'univers observable. Aucune machine, aussi rapide soit-elle, ne pourra jamais explorer un tel espace en entier.

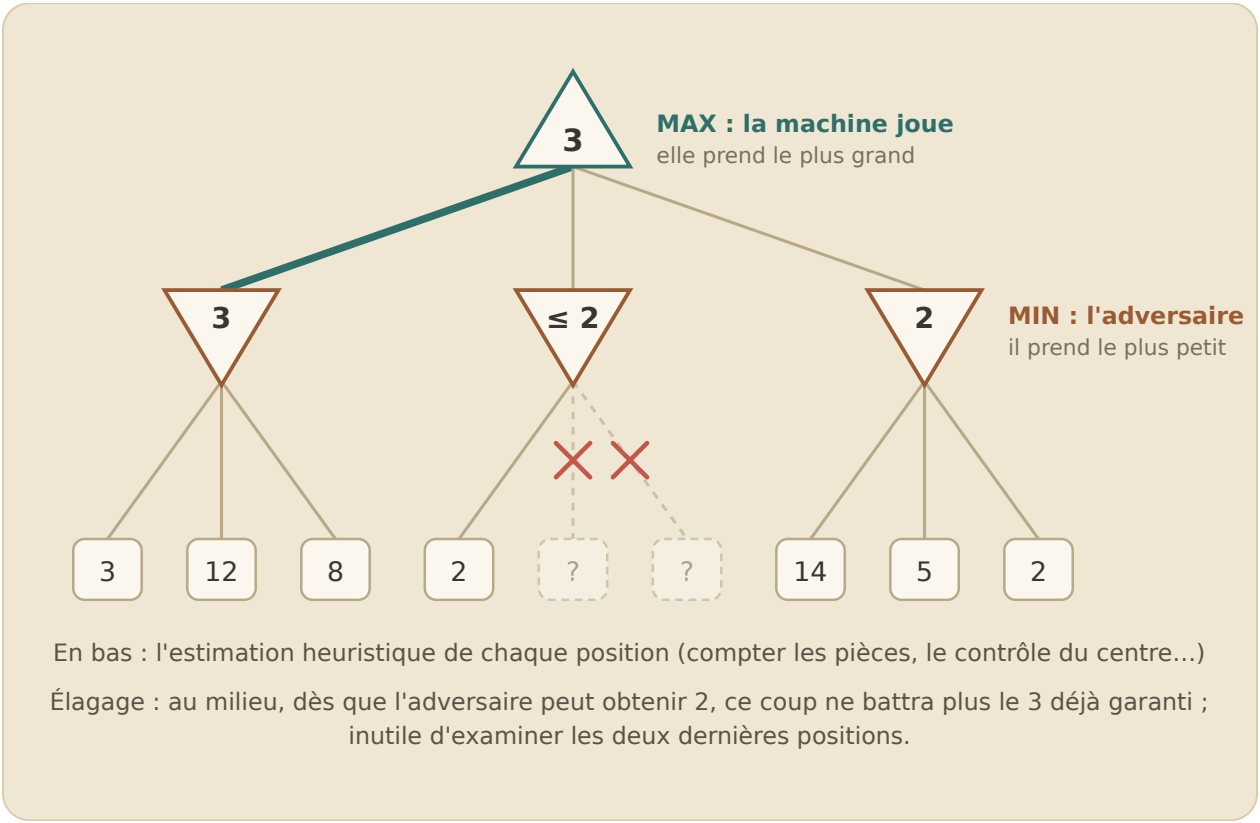


L'explosion combinatoire : à ~30 coups par tour, l'arbre des parties dépasse vite le nombre d'atomes de l'univers.

Pour les jeux à deux adversaires, les chercheurs mettent au point une stratégie appelée **minimax**. La machine explore l'arbre des coups en supposant que son adversaire jouera toujours le mieux possible. À chaque étape, elle cherche à maximiser son avantage, en supposant que l'adversaire

cherchera à le minimiser, d'où le nom. En remontant les conséquences de chaque coup, elle choisit celui qui lui garantit le meilleur résultat dans le pire des cas.

Comme l'arbre reste trop grand pour être exploré jusqu'au bout, il faut des **raccourcis**. Au lieu d'aller jusqu'aux fins de partie, la machine s'arrête à une certaine profondeur et estime la qualité d'une position à l'aide d'une **règle empirique** (une « heuristique »), par exemple en comptant les pièces ou en évaluant le contrôle du centre. D'autres techniques, comme l'**élagage** (*pruning* : ignorer dès le départ les branches qui ne peuvent pas changer la décision), évitent des explorations inutiles.



Minimax sur un petit arbre : les estimations remontent, en alternant le plus petit (l'adversaire) et le plus grand (la machine) ; au milieu, l'élagage évite d'examiner deux positions inutiles.

Le même principe s'applique en dehors des jeux, lorsqu'il faut **trouver un chemin**, par exemple dans le labyrinthe du début ou pour calculer un itinéraire routier. Au lieu d'explorer dans toutes les directions, un algorithme connu nommé **A*** (prononcé « A étoile ») se laisse guider par une heuristique. À chaque embranchement, il privilégie la direction qui semble le rapprocher le plus du but (par exemple, selon la distance à vol d'oiseau jusqu'à la destination). Le GPS qui calcule une route utilise ce genre de stratégie. C'est aussi le cas de l'**IA des jeux vidéo** : les personnages non joueurs (*non-player characters*) qui trouvent leur route sur la carte, ou les ennemis qui poursuivent ou contournent le joueur, s'appuient le plus souvent sur ces mêmes algorithmes de recherche de chemin (*pathfinding*), en particulier A*. La principale leçon de cette période est donc la suivante : un système efficace n'explore pas tout, il explore **au bon endroit**. La qualité des heuristiques est déterminante.

L'applet ci-dessous compare les deux stratégies sur le même labyrinthe. À gauche, une recherche aveugle (*blind search*) s'étend dans toutes les directions à la fois. À droite, A* est guidé par la distance

qui le sépare du but. Lancez les deux recherches, puis comparez le nombre de cases explorées : elles trouvent le même chemin, mais pas avec le même effort. Ajoutez ou retirez des murs en cliquant sur la grille, et observez dans quels cas l'heuristique aide beaucoup et dans quels cas elle mène la recherche dans une mauvaise direction.

Applet interactive : à utiliser en ligne, sur la page « L'âge d'or symbolique : chercher et raisonner » du site du cours.

Nous retrouverons cette limite, sous un autre nom, quand il s'agira d'apprendre à partir de données décrites par des milliers de caractéristiques. Ce sera la malédiction de la dimension (*curse of dimensionality*), au Module 2.

L'apogée : Deep Blue bat Kasparov (1997)

En mai 1997, à New York, se joue un match devenu célèbre. D'un côté, **Garry Kasparov**, champion du monde d'échecs en titre, considéré par beaucoup comme le plus grand joueur de l'histoire. De l'autre, **Deep Blue**, un superordinateur conçu par IBM. Au terme de six parties, la machine l'emporte. C'est la première fois qu'un champion du monde en exercice perd contre un ordinateur dans un match en conditions officielles. L'événement a un retentissement mondial, et la presse y voit le jour où la machine a « dépassé » l'humain.

Deep Blue applique directement les techniques décrites plus haut. Il n'utilise aucun réseau de neurones et aucun apprentissage. Il repose sur de la **recherche par force brute** (la machine évalue jusqu'à 200 millions de positions par seconde), guidée par des **heuristiques** mises au point avec l'aide de grands maîtres, et sur de très grandes bibliothèques d'ouvertures et de fins de partie. C'est du GOFAI typique, rendu très performant par la puissance de calcul.

Le match a été tendu. Au début de la rencontre, un coup subtil et inattendu de la machine, qu'il jugeait trop « humain », a déstabilisé Kasparov. Il en est venu à soupçonner une intervention humaine et a accusé IBM de tricherie. Il a réclamé une revanche, que l'entreprise a refusée, et Deep Blue a été démonté peu après. Ce coup inattendu aurait en réalité résulté d'un simple bogue dans le programme.

La vidéo suivante montre la réaction de Kasparov au moment où il abandonne la sixième et dernière partie, le 11 mai 1997. Elle montre bien ce que représentait cette défaite :

Vidéo : https://www.youtube.com/watch?v=EsMk1Nbcs-s

Au-delà de l'anecdote, cette victoire pose de nouveau la question de l'intelligence des machines. Deep Blue ne « comprend » pas les échecs comme Kasparov les comprend. Il ne sait même pas qu'il joue aux échecs. Il ne perçoit ni la beauté d'une combinaison ni la tension d'une partie, il ne sait rien faire d'autre et il ne peut pas expliquer pourquoi il a joué tel coup. On peut donc se demander s'il s'agit d'*intelligence* ou seulement d'une machine à calculer très puissante qui joue aux échecs.

IBM a relevé un autre défi quatorze ans plus tard, dans un domaine beaucoup plus difficile, le langage. En 2011, son système Watson a battu les meilleurs champions du jeu télévisé *Jeopardy!*, en combinant le savoir structuré de l'IA symbolique et l'apprentissage statistique. Nous le retrouverons à la fin du module, dans *Les hivers et la bascule*.

Le cas Deep Blue illustre un constat qui revient dans toute l'histoire de l'IA. Les tâches que nous jugeons les plus « intellectuelles » (jouer aux échecs, démontrer un théorème) se sont révélées **relativement faciles** à mécaniser. À l'inverse, ce qu'un enfant de trois ans fait sans effort (comprendre une phrase, reconnaître une scène, faire preuve de bon sens) a longtemps résisté. C'est le **paradoxe de Moravec**, sur lequel nous reviendrons au Module 2.

Ces difficultés montrent déjà les limites de cette période, sur lesquelles nous reviendrons dans « Les hivers et la bascule ». La même époque a cependant produit un autre type de programme. Il ne calcule pas pour gagner une partie, mais semble parler et écouter, et son cas est encore plus surprenant.

L'autre visage : ELIZA, ou l'illusion de comprendre

L'IA symbolique de cette période ne se limite pas à la recherche et au calcul. L'un de ses épisodes les plus marquants concerne une machine qui semblait non pas jouer, mais parler. En 1966, au MIT, l'informaticien **Joseph Weizenbaum** écrit **ELIZA**, un programme qui imite un psychothérapeute. La conversation paraît étonnamment naturelle. Si vous tapez « je me sens seul ces temps-ci », ELIZA répond « depuis quand vous sentez-vous seul ? ».

Pourtant, le programme ne comprend rien. ELIZA se contente de repérer des mots-clés et de **renvoyer les phrases de l'utilisateur sous forme de questions**, selon quelques règles très simples. Si vous écrivez « ma mère ne m'écoute jamais », le mot « mère » déclenche la réponse « parlez-moi de votre famille ». Le programme ne possède aucun savoir sur le monde, sur la solitude ou sur les mères.



ELIZA : repérer un mot-clé et renvoyer la phrase en question, sans rien comprendre.

La réaction des utilisateurs est ce qui a le plus marqué. Les gens se sont attachés à ELIZA. La secrétaire de Weizenbaum, qui savait pourtant qu'il s'agissait d'un programme, lui a un jour demandé de quitter la pièce pour pouvoir « parler en privé » avec la machine. Des utilisateurs lui ont confié des problèmes personnels, persuadés d'être écoutés. Weizenbaum en a été si troublé qu'il est devenu

l'un des principaux critiques de l'IA. On appelle aujourd'hui « **effet ELIZA** » cette forte tendance à *projeter* de la compréhension, et même des émotions, sur n'importe quelle machine qui manie le langage.

ELIZA est en quelque sorte l'inverse du test de Turing. Elle montre qu'il peut être facile de donner l'illusion de penser sans rien comprendre. Cette mise en garde prendra toute son importance avec les agents conversationnels (module 4) et dans le débat, toujours ouvert, sur ce que « comprendre » veut dire pour une machine (module 5).

Une dernière précision est importante pour la suite. On pourrait voir en ELIZA l'ancêtre direct de ChatGPT, comme s'il s'agissait du même procédé à plus grande échelle. C'est presque l'inverse. ELIZA n'est qu'un petit ensemble de règles écrites à la main (repérer un mot, produire une réponse à partir d'un gabarit), sans aucun apprentissage ni savoir sur le monde. C'est du GOFAI pur, entièrement programmé par son auteur. Les grands **modèles de langage** (les *LLM*) sur lesquels repose ChatGPT relèvent au contraire du **pari adverse**, celui du perceptron et des réseaux de neurones. Personne ne leur a donné de règles. Ils ont appris, à partir de très grandes quantités de textes, un modèle statistique du langage qui comporte des milliards de paramètres, et ils produisent des réponses nouvelles sur presque tous les sujets. La ressemblance n'est donc que superficielle. ELIZA et ChatGPT représentent les **deux paris rivaux** de ce module. Cela ne règle pas la question de fond, qui est de savoir si un LLM comprend ou s'il n'est qu'un imitateur beaucoup plus habile. L'effet ELIZA invite justement à ne pas trancher cette question trop vite.

Un mot sur l'outil. ELIZA, comme presque tous les programmes de cette période, était écrite en **Lisp**, un langage inventé par John McCarthy en 1958, l'année même du perceptron. C'est l'un des plus anciens langages de programmation encore utilisés aujourd'hui, et il a beaucoup influencé l'informatique (la récursion, le ramasse-miettes de mémoire, l'invite interactive et bien d'autres idées aujourd'hui courantes y sont nées). Son nom vient de *LISt Processing*, le « traitement de listes ». La plupart des langages sont d'abord conçus pour calculer des nombres, alors que Lisp est conçu pour **manipuler des symboles** (des mots, des concepts, des relations). C'était donc l'outil idéal pour le pari symbolique.

Pour aller plus loin : à quoi ressemble du Lisp ?
En Lisp, presque tout s'écrit sous forme de listes entre parenthèses, avec l'opération placée en tête. Une addition s'écrit ainsi :

```
(+ 1 2 3)      ; vaut 6
(* 3 (+ 2 4))  ; vaut 18, soit 3 × (2 + 4)
```

Jusqu'ici, rien de particulier. L'idée importante est qu'une liste peut contenir des *symboles* (des mots) aussi bien que des nombres. On peut écrire une liste de concepts :

```
(chien chat oiseau)
```

On peut aussi représenter une connaissance, c'est-à-dire un fait sur le monde :

```
(est-un Socrate humain)   ; « Socrate est un humain »
```

Le point essentiel est qu'en Lisp, **un programme a exactement la même forme que les données qu'il manipule**, puisque dans les deux cas il s'agit de listes. Un programme peut donc lire, transformer et même produire d'autres programmes aussi facilement qu'il manipule une liste d'épicerie. Cette propriété (« le code est une donnée comme une autre ») explique pourquoi Lisp convenait si bien à des systèmes destinés à raisonner sur des symboles.

Pendant des décennies, Lisp est resté le langage principal de l'IA symbolique. On a même construit des ordinateurs spécialisés, les « **machines Lisp** », pour l'exécuter plus efficacement. Nous verrons

dans « Les hivers et la bascule » que leur effondrement, vers 1987, marque l'un des hivers de l'IA.

Deep Blue cherchait et ELIZA manipulait du langage, mais aucun des deux ne connaissait vraiment le monde. Pour aller plus loin, il fallait donner à la machine une façon de **représenter ce qu'elle sait**. C'est le grand chantier de « Représenter le monde », qui s'est soldé par un échec important.

Représenter le monde

Le sens, angle mort de la machine

Les chapitres précédents ont présenté plusieurs programmes. Le Logic Theorist démontrait des théorèmes, Deep Blue gagnait aux échecs et ELIZA tenait une conversation. Tous faisaient cependant la même chose : ils **manipulaient des symboles d'après leur forme**, selon des règles. Par exemple, ELIZA repérait le mot « mère » sans savoir ce qu'est une mère. On parle dans ce cas du niveau de la **syntaxe**, qui consiste à agencer correctement des symboles sans tenir compte de leur sens.

Comprendre le monde demande davantage. Les spécialistes du langage distinguent trois niveaux, qu'on peut illustrer par un exemple simple. À table, quelqu'un vous dit **« Pouvez-vous me passer le sel ? »**

- La **syntaxe** concerne la *forme*. La phrase est une question grammaticalement bien construite. Une machine peut le vérifier sans rien comprendre.
- La **sémantique** concerne le *sens littéral*. La phrase porte sur votre *capacité* à passer le sel. Pour la comprendre à ce niveau, il faut savoir ce que signifient « sel », « passer » et « pouvoir ».
- La **pragmatique** concerne l'*intention réelle en contexte*. Tout le monde comprend qu'il ne s'agit pas d'une question sur vos aptitudes (« oui, je peux passer le sel! »), mais d'une **demande** polie, « passez-moi le sel ». Pour comprendre cela, il faut connaître le contexte et un grand nombre de sous-entendus que nous partageons tous.

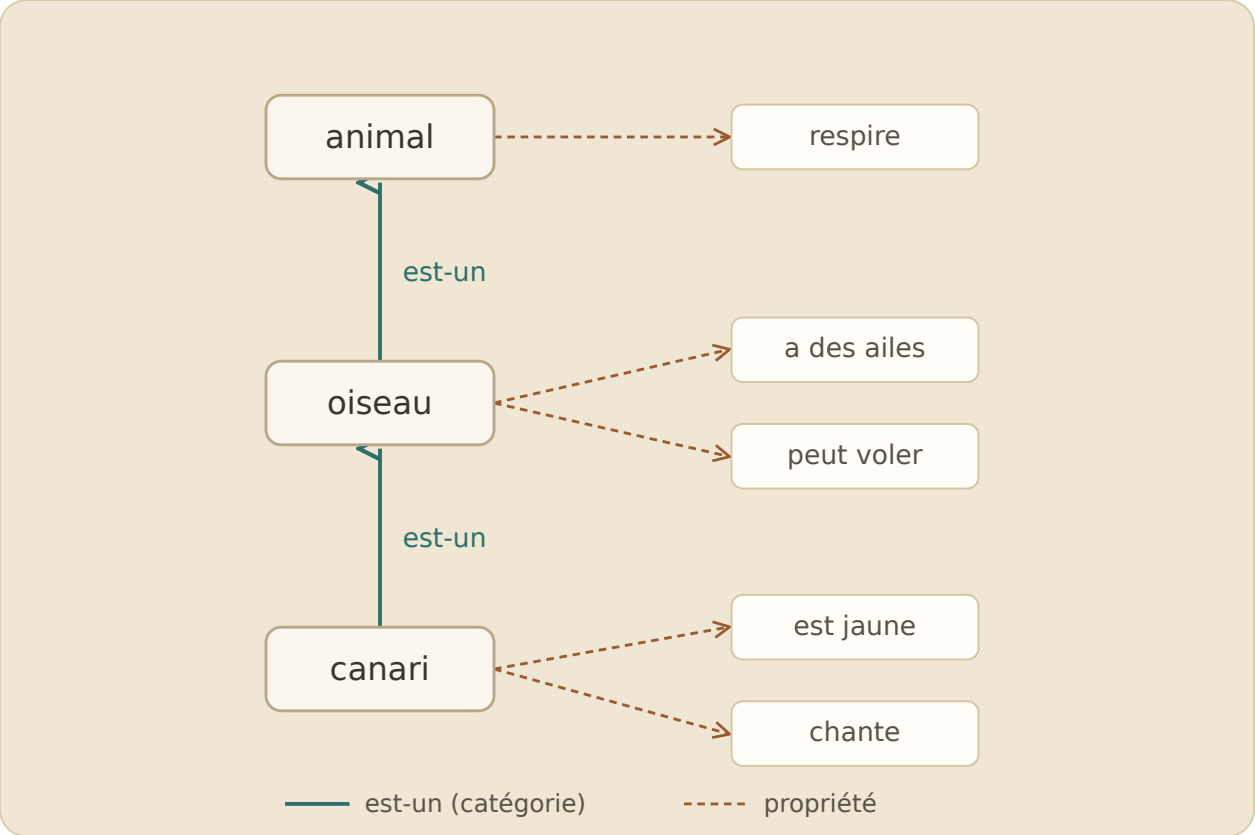
On peut résumer ainsi la situation de l'IA symbolique : elle réussissait bien au niveau de la **syntaxe**, atteignait difficilement la **sémantique** et échouait au niveau de la **pragmatique**. Pour passer de la forme au sens, une machine a besoin de **connaissances** sur le monde, et Deep Blue et ELIZA n'en avaient aucune. Ce chapitre porte sur les tentatives pour fournir ces connaissances aux machines et sur leur échec. La question de départ est la suivante : comment mettre dans une machine ce que tout le monde sait ?

Donner un savoir à la machine

Si l'intelligence exige des connaissances, il faut trouver un moyen de les **inscrire dans la machine** sous une forme qu'elle puisse exploiter. Entre la fin des années 1960 et les années 1970, trois grandes façons de structurer le savoir sont proposées.

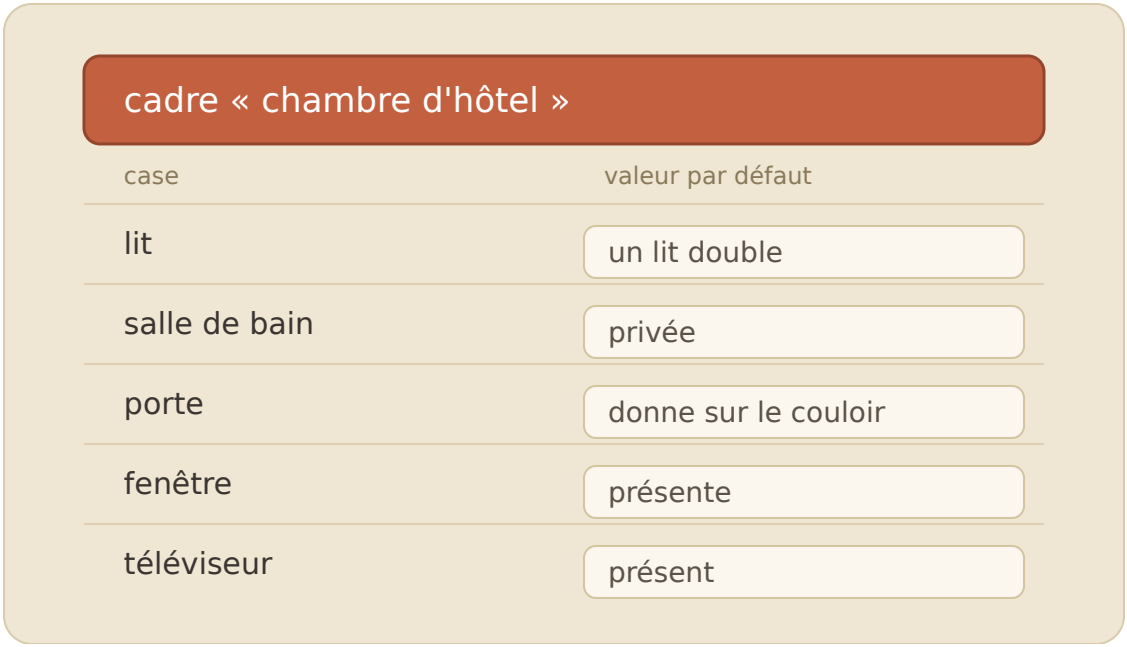
Les réseaux sémantiques (*semantic networks*, Ross Quillian). On représente les connaissances comme un **réseau de concepts reliés** par des relations. « Canari » est relié à « oiseau » par un lien *est-un* (*is-a*), et « oiseau » est relié à « animal » de la même façon. « Oiseau » est relié à « ailes » par un lien *possède*. La machine peut alors **déduire** des faits qu'on ne lui a pas donnés explicitement. Par exemple, pour

savoir si un canari a des ailes, il suffit de suivre les liens (*canari est-un oiseau*, *oiseau possède ailes*) pour conclure que oui. Ces réseaux portent le mot **sémantique** dans leur nom parce que leur objectif est de passer de la forme au sens.



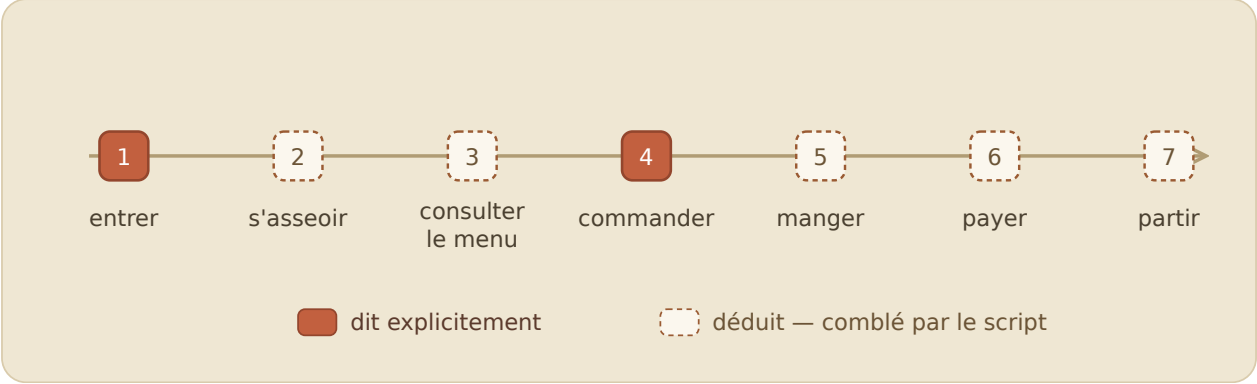
Un réseau sémantique : les propriétés s'héritent en remontant les liens « est-un ».

Les frames, ou « cadres » (Marvin Minsky, 1974). Au lieu de concepts isolés, Minsky propose de regrouper le savoir en **situations types** qui comportent des « cases » à remplir, avec des valeurs par défaut. Le cadre « chambre d'hôtel » comporte des cases pour le lit, la porte et la salle de bain. Par défaut, on s'attend à y trouver un lit. Quand vous entrez dans une chambre d'hôtel inconnue, vous n'analysez pas toute la scène. Vous utilisez ce cadre déjà connu et vous ne corrigez que ce qui ne correspond pas. Les frames permettent donc de représenter nos **attentes**.



Un frame : une situation type dont les cases ont des valeurs par défaut.

Les scripts (Roger Schank et Robert Abelson). L'idée est la même, mais elle s'applique à des **enchaînements d'actions**. Le « script du restaurant » décrit la séquence attendue : entrer, s'asseoir, consulter le menu, commander, manger, payer, partir. Grâce à ce script, une machine peut **compléter** un récit. Si on lui dit « Jean est allé au restaurant et a commandé un steak », elle en déduit qu'il s'est assis, qu'il a mangé et qu'il a payé, même si le récit ne le dit pas.



Un script : la séquence attendue, dont la machine complète les étapes non dites.

Ces trois approches ont en commun une capacité qui manquait à Deep Blue et à ELIZA, celle d'**inférer l'implicite**, c'est-à-dire d'utiliser un savoir de fond pour aller au-delà de ce qui est dit littéralement. Elles représentent un progrès réel vers la sémantique.

Ces représentations ont un ancêtre plus rigoureux, la **logique formelle**. Depuis Boole et Frege, la logique cherche à réduire le raisonnement à un *calcul* sur des symboles : « Socrate est un homme ; tous les hommes sont mortels ; donc Socrate est mortel ». Ce syllogisme semble porter sur le sens, mais on l'obtient par une opération mécanique sur la *forme* des énoncés. Le problème est là. Qu'on

enchaîne des règles logiques ou qu'on suive des liens dans un réseau, on manipule toujours la **forme** des symboles. La question est de savoir si la forme suffit à représenter le **sens**. Comme on va le voir, ce progrès vers la sémantique s'accompagne d'une fragilité importante.

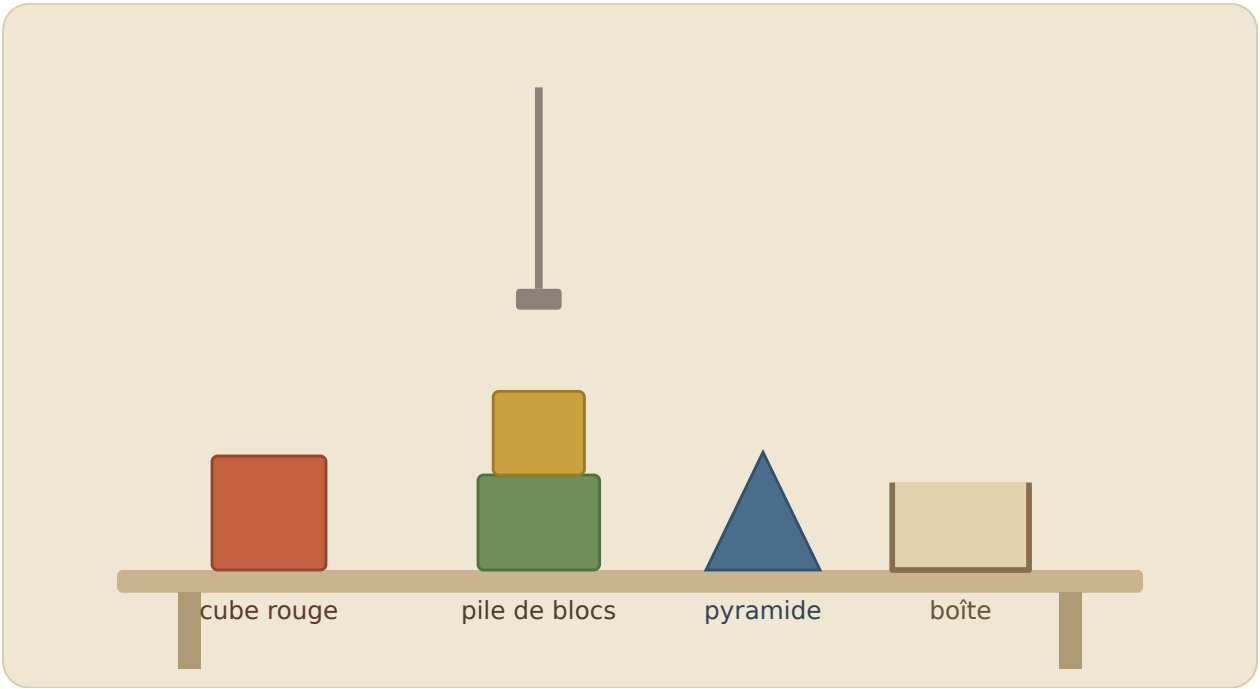
> Ces façons de structurer le savoir (réseaux de concepts, cases à remplir, hiérarchies *est-un*) n'ont pas disparu avec le GOFAI. Elles ont été reprises ailleurs. Le **web sémantique**, les **ontologies** et les **knowledge graphs** utilisés par la recherche de Google ou par Wikidata en sont les descendants directs, et les *cases héritées* des frames ressemblent aux **objets** de la programmation moderne. Nous y reviendrons dans « Les hivers et la bascule », pour évaluer ce que le GOFAI a laissé.

SHRDLU, ou le sommet de l'ambition

C'est dans ce contexte optimiste qu'un jeune chercheur du MIT, **Terry Winograd**, réalise vers **1970** un programme qu'on considère encore comme l'un des résultats les plus avancés de l'IA symbolique, **SHRDLU**. Le programme dialogue en anglais ordinaire avec un humain à propos d'un petit monde de **blocs colorés** (cubes, pyramides, boîtes posés sur une table), qu'il peut déplacer à l'aide d'un bras robotique virtuel. Pour l'époque, la conversation est très impressionnante :

> — *Prends un gros bloc rouge.* — D'accord. — *Saisis la pyramide.* — Je ne sais pas de **quelle** pyramide vous parlez. — *Trouve un bloc plus haut que celui que tu tiens et place-le dans la boîte.* — Par « **le** », je suppose que vous parlez du bloc plus haut que celui que je tiens.

Dans cet échange, SHRDLU **lève une ambiguïté** (quelle pyramide), **résout un pronom** (ce à quoi renvoie « le »), **agit** sur le monde et **se souvient** de ce qu'il vient de faire. On peut aussi lui demander « Pourquoi as-tu fait ça ? », et il **explique** son raisonnement.



Le « micro-monde » de SHRDLU : un univers très petit, entièrement décrit à la main.

Le film de démonstration d'époque ci-dessous (en anglais) montre SHRDLU en fonctionnement : les ordres tapés au clavier, les réponses du programme et le bras virtuel qui déplace les blocs.

Vidéo : https://www.youtube.com/watch?v=bo4RvYJYOzI

SHRDLU y parvient parce qu'il maintient un **modèle du monde** (*world model*), c'est-à-dire une représentation interne de sa petite scène : quel bloc repose sur quel autre, lequel est rouge, lequel est libre, ce que le bras tient à ce moment. À chaque action, il **met ce modèle à jour**, et à chaque question, il le **consulte**. C'est ce modèle interne qui lui permet de résoudre « le », de se rappeler son action précédente et de justifier ce qu'il a fait. SHRDLU ne se contente donc pas de parler des blocs, il en possède une représentation exacte. Cette idée est importante : **un modèle du monde est une représentation interne de la réalité, sur laquelle on peut raisonner**. Nous la retrouverons beaucoup plus loin dans le cours, au centre d'un débat important sur les IA actuelles.

Cette réussite repose cependant sur une simplification. Le modèle du monde de SHRDLU est exact parce qu'il a très peu de choses à représenter : quelques blocs, une table, une boîte, quelques formes et couleurs. Dans un univers aussi petit, on peut tout décrire à la machine, c'est-à-dire la liste complète des objets, des propriétés et des actions possibles. Le « monde » de SHRDLU tient entièrement dans une représentation **codée à la main**. Winograd l'appelait d'ailleurs un **micro-monde** (*blocks world*), et le préfixe *micro* indique bien sa taille. L'intérêt du micro-monde est qu'il rend le problème **traitable** (*tractable*, en anglais). En informatique, un problème est traitable quand une machine peut le résoudre en un temps raisonnable, sans être freinée par l'explosion combinatoire des possibilités. Avec quelques blocs, tout peut être représenté et chaque question obtient une réponse immédiatement. C'est ce qui explique la réussite de SHRDLU, et c'est aussi sa limite, parce que le monde réel n'est pas traitable en ce sens, comme le montre la section suivante.

En dehors de la table à blocs, SHRDLU ne peut rien faire. Son modèle du monde ne contient rien sur la pluie, un mensonge ou un escalier. Il ne peut pas être étendu au monde réel, parce qu'il faudrait alors y représenter tout ce qui existe. Toutes les approches de ce chapitre ont la même limite. Elles fonctionnent tant qu'on reste dans un domaine assez petit pour être entièrement décrit, et elles échouent dès qu'il faut tenir compte de la très grande quantité de choses que les humains considèrent comme évidentes. Cette quantité de savoir évident a un nom, et elle constitue la principale limite du GOFAI.

Le mur du sens commun

Cette limite s'appelle le **sens commun** (*common sense*). Il s'agit de l'ensemble très vaste des choses si évidentes que personne ne prend la peine de les dire. Par exemple, l'eau mouille, un objet qu'on lâche tombe, on ne peut pas pousser une corde, votre mère est plus âgée que vous, et si Jean entre dans un restaurant, il y entre par la porte et non par le plafond. Nous utilisons en permanence des millions de certitudes de ce genre. Comme elles vont **sans dire**, personne ne les a jamais écrites.

Or toute l'IA symbolique repose sur un principe : pour qu'une machine sache quelque chose, il faut lui **inscrire** ce savoir. Les réseaux sémantiques, les frames, les scripts et SHRDLU fonctionnent tant que ce savoir tient dans un domaine assez petit pour être décrit à la main. La machine ne sait que ce qu'on lui a fourni explicitement. Le sens commun, lui, **n'a pas de limite**. Pour le donner à une machine, il faudrait lui décrire le monde entier.

Un chercheur a tenté de le faire. En **1984**, **Douglas Lenat** lance **CYC** (de l'anglais *encyclopedia*), un projet très ambitieux dont l'objectif est d'**encoder à la main**, fait après fait et règle après règle, la

totalité du sens commun humain. Des équipes y ont consacré des **décennies** et des dizaines de millions de dollars, et ont saisi des millions d'assertions, comme « un café chaud refroidit si on le laisse » ou « on ne peut pas être à deux endroits à la fois ». C'est le projet le plus ambitieux de l'histoire du GOFAI.

Le sens commun, écrit à la main : quelques entrées de CYC

dans la langue de CYC (CycL)	*ce que cela veut dire*
`(#$isa #$BillClinton #$UnitedStatesPresident)`	Bill Clinton fait partie des présidents des États-Unis.
`(#$genls #$Tree-ThePlant #$Plant)`	Tous les arbres sont des plantes.
`(#$capitalCity #$France #$Paris)`	Paris est la capitale de la France.
`(#$relationAllExists #$biologicalMother #$ChordataPhylum #$FemaleAnimal)`	Tout animal à colonne vertébrale a une mère biologique, un animal femelle.
`(#$implies (#$and (#$isa ?OBJ ?SUBSET) (#$genls ?SUBSET ?SUPERSET)) (#$isa ?OBJ ?SUPERSET))`	Règle : si un objet appartient à une catégorie, il appartient aussi à toutes celles qui la contiennent.

Des millions d'entrées de ce genre, saisies une à une pendant des décennies.

Le sens commun écrit à la main : quelques entrées de CYC dans son langage, CycL, et leur signification.

CYC n'a jamais atteint son objectif. La raison n'est pas un manque d'argent ou de compétence, mais le fait que la tâche n'a **pas de fin**. Chaque évidence saisie en fait apparaître dix autres, et chacune de celles-ci en suppose cent. On ne peut pas compléter le sens commun par petites quantités, parce qu'il s'étend à mesure qu'on l'écrit. CYC s'est heurté au même problème que le reste de ce chapitre : **le savoir implicite d'un humain ordinaire est trop vaste pour être énuméré**.

Le GOFAI atteint donc ici sa limite. On pensait qu'il suffisait de donner des connaissances à la machine, mais les connaissances les plus importantes sont justement celles que personne ne formule. Cependant, en dehors du courant dominant, un chercheur affirmait depuis longtemps qu'on abordait le problème dans le mauvais sens et qu'on cherchait le sens au mauvais endroit. Avant de terminer sur l'âge d'or symbolique, il faut présenter ce point de vue dissident.

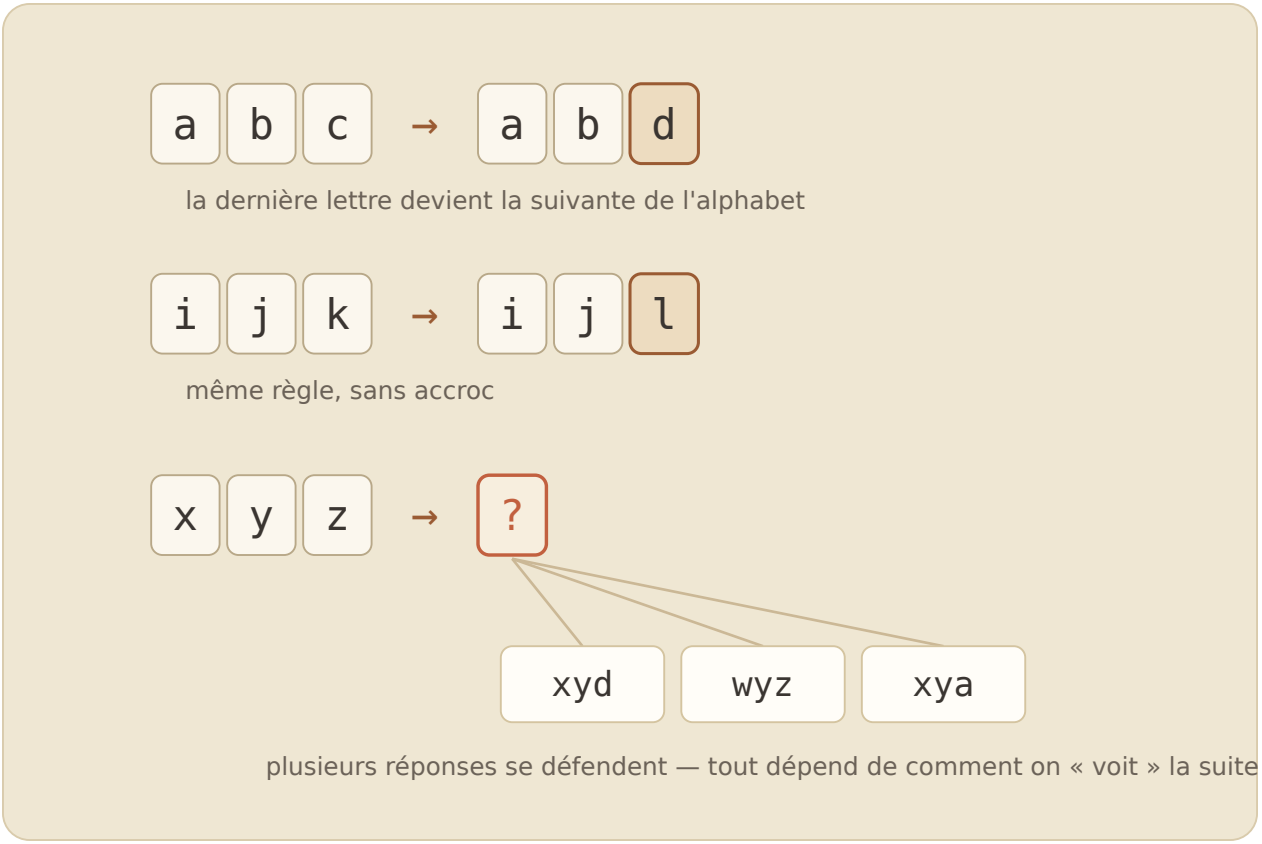
L'objection de Hofstadter

Ce chercheur est **Douglas Hofstadter**, l'auteur de la notion de *boucle étrange*, déjà présenté dans « Turing et la question fondatrice » à propos de Gödel. Pendant que ses collègues construisaient des

moteurs d'échecs et des bases de règles (*rule bases*), il répétait que l'IA dominante ne s'attaquait pas au bon problème. Selon Hofstadter, battre Kasparov par force brute ou accumuler des millions d'assertions comme CYC ne concerne pas l'essentiel de la pensée.

Pour lui, l'essentiel de la pensée est l'**analogie**. Penser ne consiste pas à appliquer des règles, mais à *percevoir des ressemblances*, à adapter des **concepts fluides** (*fluid concepts*) à des situations nouvelles et à comprendre l'inconnu à partir de ce qu'on connaît déjà. Quand vous parlez du *pied* d'une montagne, des *jambes* d'une table ou de la *bouche* d'un fleuve, vous faites de l'analogie sans y penser. C'est l'opération de l'esprit la plus courante et aussi la plus fondamentale. Or une analogie ne peut pas être inscrite d'avance dans une base de connaissances (*knowledge base*). Elle se construit au moment où on en a besoin, selon le contexte. C'est précisément ce qu'un projet comme CYC ne pouvait pas représenter.

Pour le démontrer, Hofstadter et sa collaboratrice **Melanie Mitchell** ont conçu un programme, **Copycat**, qui fonctionne lui aussi dans un micro-monde, mais d'un genre très différent de celui de SHRDLU. Son univers est constitué de simples **chaînes de lettres**. On lui pose des problèmes d'analogie, par exemple : si `abc` devient `abd`, que devient `ijk` ? La réponse naturelle est `ijl`, parce qu'on remplace la dernière lettre par la suivante dans l'alphabet. Cependant, Copycat n'applique pas une règle fixe. Il *perçoit* une structure, et il peut en percevoir plusieurs. Si on lui demande ce que devient **`xyz`** selon la même analogie, le problème est plus difficile, parce que le `z` n'a pas de lettre suivante. Il n'y a plus de réponse unique. On peut proposer `xyd`, ou `wyz`, ou recommencer au début de l'alphabet. La « bonne » réponse dépend de la façon dont on perçoit la situation. C'est ce que Hofstadter veut montrer : l'intelligence n'est pas l'exécution d'une règle, mais une **perception fluide, sensible au contexte**.



L'énigme de Copycat : pour « xyz », la réponse dépend de la façon dont on perçoit la suite.

Les deux micro-mondes ont donc des rôles opposés. SHRDLU utilisait un micro-monde pour **simplifier** le problème, c'est-à-dire pour avoir un univers assez petit pour tout y énumérer d'avance. Hofstadter réduit le sien pour la raison **inverse**. Il écarte tout le savoir encyclopédique afin d'**isoler l'essentiel**, l'analogie elle-même. Ces deux micro-mondes correspondent à deux conceptions opposées de l'intelligence.

Reste la question qui traverse tout ce chapitre, celle de savoir comment le sens peut apparaître à partir de simples symboles. La réponse de Hofstadter prolonge son idée de **boucle étrange**. Selon lui, le sens n'est pas **injecté** de l'extérieur, fait après fait, comme CYC l'espérait. Il **émerge** d'un système assez riche pour s'observer lui-même, percevoir ses propres structures et établir des analogies entre ses propres états. On ne remplit pas un esprit de significations. On met en place un mécanisme dont la signification émerge. C'est l'opposé de la démarche du GOFAI, qui voulait tout écrire à la main.

Hofstadter avait en partie raison. Sa **vision** était juste. Comme on le verra, c'est par l'émergence, et non par l'inscription, que l'IA finira par progresser. Cependant, sa **solution** n'a jamais eu l'ampleur de son ambition. Copycat est resté un petit programme de laboratoire, remarquable mais limité. Hofstadter ne travaillait pas non plus sur les réseaux de neurones. Il a indiqué la bonne direction sans construire l'outil qui permettrait de la suivre.

Cet outil existait déjà, mais il était alors peu développé. Depuis « Deux paris rivaux », nous savons qu'il existe une **autre tradition**, qui ne cherche pas à décrire le monde à la machine, mais qui la laisse l'**apprendre** elle-même à partir d'exemples. Le GOFAI a atteint sa limite, le sens commun lui a résisté, et l'idée d'émergence, proposée par l'un de ses critiques, va déjà dans cette direction. L'idée

de laisser la machine apprendre plutôt que de tout lui dire ne s'imposera toutefois qu'après une longue période de recul de l'IA. Avant ce déclin, l'IA symbolique connaîtra encore sa période de plus grand succès.

Pour aller plus loin : le fonctionnement de Copycat
Copycat ne contient aucune règle du genre « remplace la dernière lettre ». Il explore en parallèle un grand nombre de petits rapprochements possibles (une lettre est-elle un début, une fin, le successeur d'une autre ?), qui se renforcent ou s'inhibent mutuellement. Une mesure interne, que ses auteurs appellent la **« température »**, indique à quel point une interprétation cohérente a émergé. Tant que tout reste flou, la température est élevée et le programme continue d'explorer presque au hasard. Quand une structure d'ensemble se forme, la température baisse et la réponse se stabilise. Le sens n'est donc pas *calculé* en une seule étape, mais **construit** peu à peu, par une compétition entre des perceptions partielles. Selon Hofstadter, ce mécanisme illustre à petite échelle ce qui caractérise la cognition.

Capturer l'expertise : les systèmes experts

Rétrécir et codifier le monde pour réussir

Le chapitre « Représenter le monde » s'est terminé sur un constat : on ne peut pas écrire le sens commun, parce qu'il n'a pas de limite. Les chercheurs des années 1970 en tirent une conclusion pratique. Si le savoir général est hors d'atteinte, il faut viser un savoir plus **étroit**.

L'idée est la suivante. Au lieu de chercher une intelligence générale, on choisit **un seul domaine** bien délimité (diagnostiquer une infection, configurer un ordinateur, prospecter un gisement minier) et on tente d'y reproduire la compétence d'**un seul expert**. Dans un domaine spécialisé, le savoir-faire d'un expert ressemble souvent à un grand ensemble de règles de la forme *si telles conditions, alors telle conclusion*. Le médecin qui raisonne « *si* le patient a de la fièvre **et** telle bactérie dans le sang, *alors* prescrire tel antibiotique » applique une règle. Si on recueille assez de ces règles et qu'on les inscrit dans la machine, celle-ci devrait raisonner comme l'expert, du moins dans ce domaine. C'est le principe des **systèmes experts**, qu'on peut résumer par la formule suivante : **connaissance = règles explicites**.

La démarche est la même que celle de SHRDLU, qui ne « comprenait » son monde de blocs que parce que ce monde était très petit. Les systèmes experts réduisent eux aussi le monde à un domaine restreint, mais il s'agit cette fois de domaines réels, qui ont une valeur commerciale. Cette approche va fonctionner. L'IA symbolique va sortir des universités, produire des revenus et convaincre le monde des affaires que l'intelligence artificielle est utilisable. La section suivante explique comment une machine peut raisonner avec des règles.

L'anatomie d'un système expert

Un système expert comporte **trois composantes**. La première est une **base de règles**, qui contient la connaissance du domaine sous forme d'énoncés *si*… *alors*…. La deuxième est une **base de faits** (ou « mémoire de travail », *working memory*), qui rassemble ce qu'on sait du cas traité, par exemple les symptômes d'un patient ou l'état d'une voiture. La troisième est un **moteur d'inférence** (*inference engine*), un mécanisme général qui compare les faits aux règles, applique celles dont les conditions sont remplies et en tire de nouveaux faits, jusqu'à une conclusion.

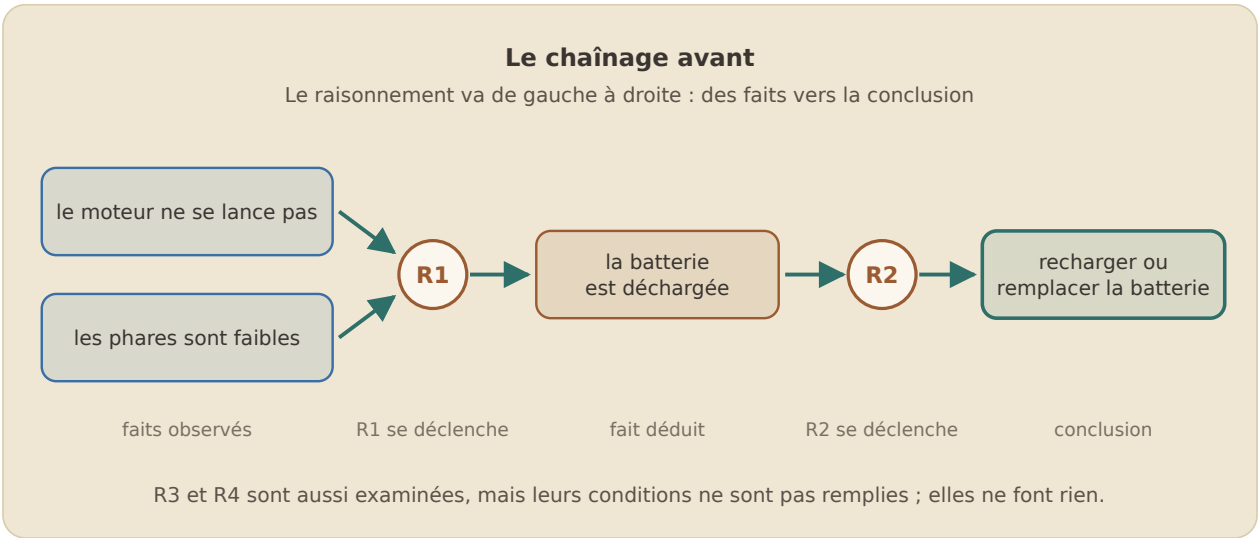
L'intérêt de cette architecture tient à la **séparation** entre ces composantes. Le moteur d'inférence ne contient aucune connaissance de médecine, d'automobile ou de minéralogie. Il se contente d'enchaîner des règles. Toute la compétence se trouve dans la base de règles, qu'on peut remplacer comme une cartouche. Avec d'autres règles, le même moteur devient un système de diagnostic médical, mécanique ou géologique. Comme le savoir est séparé du raisonnement, on peut construire plusieurs systèmes experts sans tout reprogrammer à chaque fois.

Prenons un exemple simple, **une voiture qui refuse de démarrer**. On donne au système les règles suivantes :

> **R1** : *si* le moteur ne se lance pas du tout **et** les phares sont faibles, *alors* la batterie est déchargée.
>
> **R2** : *si* la batterie est déchargée, *alors* recharger ou remplacer la batterie.
>
> **R3** : *si* le moteur se lance normalement mais ne démarre pas **et** le réservoir est vide, *alors* refaire le plein.
>
> **R4** : *si* le moteur se lance normalement **et** le réservoir n'est pas vide, *alors* faire vérifier l'allumage.

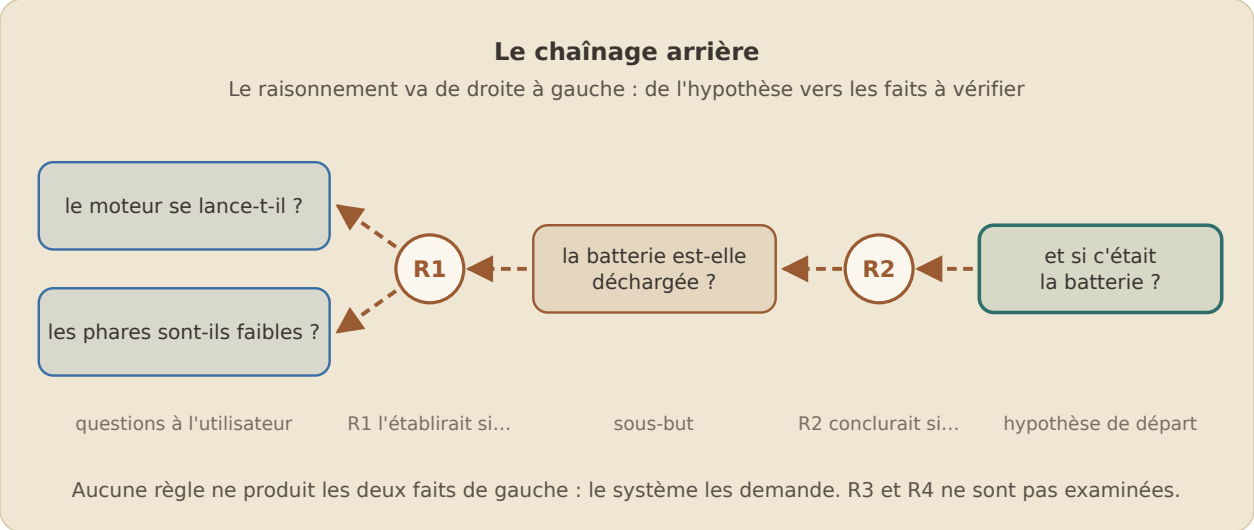
On lui fournit aussi deux faits observés, *le moteur ne se lance pas* et *les phares sont faibles*. Le moteur d'inférence parcourt alors les règles. Les deux conditions de **R1** sont satisfaites, donc R1 se **déclenche** et ajoute un fait nouveau, *la batterie est déchargée*. Ce fait satisfait la condition de **R2**, qui se déclenche à son tour et donne la conclusion *recharger ou remplacer la batterie*. Les conditions de R3 et de R4 ne sont pas remplies, et ces règles ne font rien. En deux étapes, le système a établi un diagnostic à partir des symptômes. Il peut aussi **retracer son raisonnement** : il conclut à la batterie à cause de R1, donc à cause des phares faibles.

Ce mode de raisonnement, qui part des faits pour arriver à une conclusion, s'appelle le **chaînage avant** (*forward chaining*). Il convient bien quand on dispose déjà de nombreux faits et qu'on veut savoir ce qui en découle.



Le chaînage avant : des faits observés vers la conclusion, règle après règle.

On peut aussi procéder dans l'autre sens. Supposons qu'on soupçonne la batterie et qu'on veuille vérifier cette hypothèse. Le moteur d'inférence part alors de l'**hypothèse**, traitée comme un but, et remonte les règles. Pour conclure « recharger la batterie » (R2), il faut que la batterie soit déchargée. Pour cela (R1), il faut que le moteur ne se lance pas **et** que les phares soient faibles. Aucune règle ne produit ces deux derniers faits, qu'il faut donc **observer**. Le système pose alors la question à l'utilisateur (« les phares sont-ils faibles ? ») et n'examine que ce qui concerne l'hypothèse étudiée. C'est le **chaînage arrière** (*backward chaining*).



Le chaînage arrière : de l'hypothèse vers les faits à vérifier, en ne posant que les questions utiles.

Prolog, un langage fondé sur le chaînage arrière. En 1972, on a fait de ce principe (déclarer des faits et des règles *si… alors…*, puis laisser un moteur général les enchaîner) un **langage de programmation**, **Prolog**. Le programmeur n'y écrit que des faits et des règles, et le langage fournit lui-même le moteur d'inférence, un chaînage arrière comme celui qu'on vient de décrire. On n'indique pas au programme comment calculer, mais ce qui est vrai. Cette approche s'appelle la **programmation logique** (*logic programming*). Elle est différente de la programmation fonctionnelle (*functional programming*) du langage Lisp (celui des machines de la photo plus bas). Prolog a longtemps été le langage de référence de l'IA symbolique en Europe. Le projet japonais de **Cinquième Génération**, présenté plus bas, l'a choisi comme langage principal, et ses principes se retrouvent aujourd'hui dans Datalog et dans les moteurs de règles (*rule engines*).

Pour aller plus loin : à quoi ressemble du Prolog ?
Reprenons l'exemple de la voiture. En Prolog, on écrit d'abord les **faits** observés, puis les **règles**. Dans une règle, la conclusion est placée avant le symbole `:-`, qui se lit « *si* », et les conditions sont séparées par des virgules, qui se lisent « *et* » :

```
% Les faits observés :
moteur_ne_se_lance_pas.
phares_faibles.

% Les règles R1 et R2, « si … alors … » :
batterie_dechargee   :- moteur_ne_se_lance_pas, phares_faibles.
recharger_batterie   :- batterie_dechargee.
```

On **interroge** ensuite le programme en lui soumettant un but à prouver (`?-` est l'invite) :

```
?- recharger_batterie.
true.
```

Pour répondre, Prolog effectue le chaînage arrière décrit plus haut. Pour établir `recharger_batterie`, il lui faut `batterie_dechargee`. Pour établir `batterie_dechargee`, il lui

faut les deux faits `moteur_ne_se_lance_pas` et `phares_faibles`, qui sont connus. Le but est donc atteint, et Prolog répond `true`. Le programme n'indique nulle part comment mener cette recherche, puisque le moteur du langage s'en charge.

Une même base de règles peut donc être parcourue dans deux sens, **vers l'avant**, à partir des faits, ou **vers l'arrière**, à partir d'un but. Le chaînage arrière est mieux adapté au diagnostic, parce qu'il ne pose que les questions utiles à l'hypothèse examinée, au lieu de demander toutes les mesures d'avance. C'est pour cette raison que le plus connu des systèmes experts, le système de diagnostic médical **MYCIN**, l'utilisait. Il est présenté dans la section suivante.

Dans l'applet ci-dessous, choisissez ce que vous observez sur la voiture, puis faites avancer le moteur d'inférence règle par règle. Vous le verrez examiner chaque règle, déclencher celles dont les conditions sont réunies et ajouter des faits à la base, jusqu'au diagnostic. Essayez plusieurs combinaisons, et trouvez celle pour laquelle le système ne peut rien conclure.

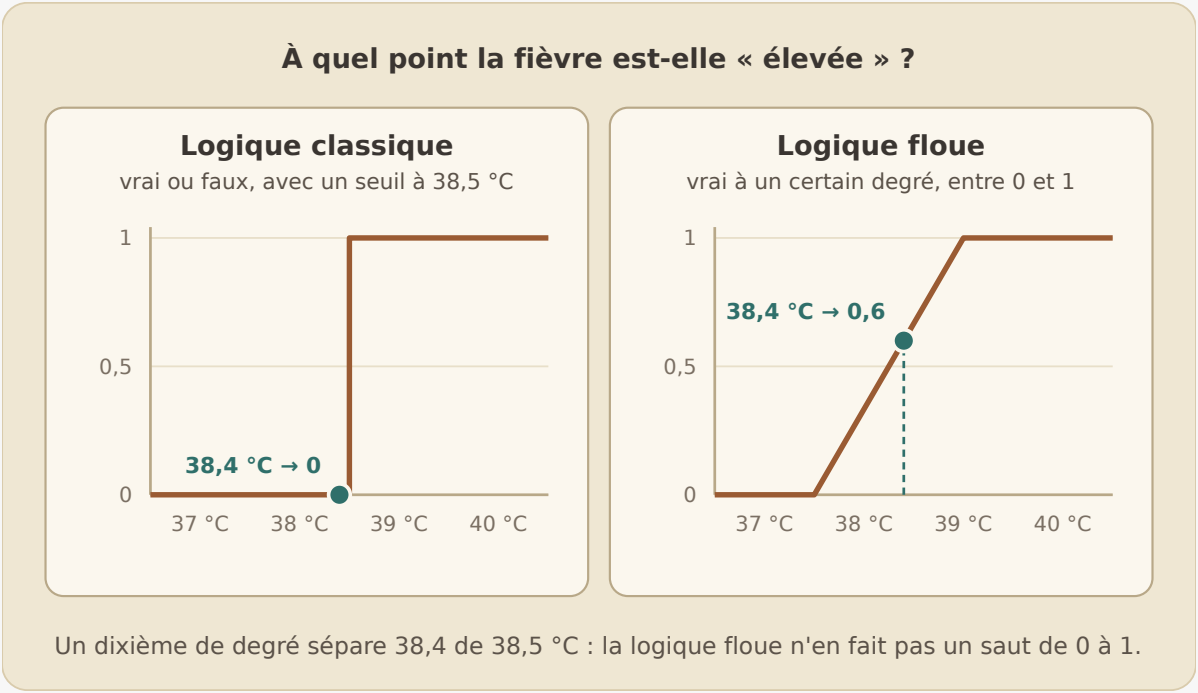
Applet interactive : à utiliser en ligne, sur la page « Capturer l'expertise : les systèmes experts » du site du cours.

L'âge d'or : MYCIN, XCON et le boom

Le premier système expert est généralement considéré comme étant **DENDRAL**, développé à Stanford à partir de 1965. Il identifiait des **molécules** à partir de données de spectrométrie, comme le ferait un chimiste expérimenté. Le plus connu est cependant **MYCIN**, conçu au début des années 1970 par **Edward Shortliffe**. MYCIN diagnostiquait les **infections bactériennes du sang** et recommandait un antibiotique et une dose. Il comptait environ **600 règles** et utilisait le **chaînage arrière** décrit plus haut. Il partait d'une hypothèse sur le germe en cause et posait des questions au médecin jusqu'à sa conclusion. Grâce à ce même mécanisme, il pouvait **justifier** sa démarche. Quand on lui demandait pourquoi il posait une question, il indiquait la règle qu'il cherchait à vérifier.

En médecine, cependant, peu de choses sont certaines. Un symptôme peut suggérer un germe sans le confirmer. MYCIN utilisait donc des **facteurs de certitude** (*certainty factors* : un nombre associé à chaque règle, qui indique à quel point sa conclusion est fiable) et les combinait au cours du raisonnement. Cette méthode était approximative. Plus tard, une théorie plus rigoureuse de l'incertitude, celle des **réseaux bayésiens**, l'a remplacée (voir le Module 2). MYCIN montrait déjà qu'un système qui raisonne doit aussi tenir compte de l'incertitude.

La logique floue. Les règles d'un système expert emploient souvent des mots imprécis : une fièvre « élevée », un moteur « chaud », une vitesse « faible ». En logique classique, un énoncé est vrai ou faux. À partir de quel degré une fièvre devient-elle « élevée » ? Fixer un seuil à 38,5 °C revient à dire que 38,4 °C n'est pas une fièvre élevée du tout. En 1965, le mathématicien **Lotfi Zadeh** propose la **logique floue** (*fuzzy logic*), où un énoncé peut être vrai à un certain degré, entre 0 et 1. Une fièvre de 38,4 °C peut ainsi être « élevée » à 0,6, et une fièvre de 40 °C à 1. Les règles *si… alors…* s'appliquent alors plus ou moins fortement selon ce degré.



« Fièvre élevée » : un seuil en logique classique, un degré en logique floue.

La logique floue ne traite pas le même problème que les facteurs de certitude de MYCIN. Ceux-ci mesurent à quel point on est sûr d'une conclusion. La logique floue mesure à quel point un mot s'applique à une situation. Elle a connu un grand succès industriel, surtout au Japon à partir de la fin des années 1980, dans des systèmes de commande : le métro de Sendai, des machines à laver, des autocuiseurs à riz, des stabilisateurs de caméras. Elle est encore utilisée aujourd'hui en automatique.

MYCIN donnait de bons résultats. En 1979, une évaluation a soumis ses recommandations à un jury d'experts, qui les a comparées à celles de médecins sans savoir lesquelles venaient du programme. Le jury a jugé les recommandations de MYCIN **aussi bonnes, voire meilleures**, que celles des spécialistes. Pourtant, **MYCIN n'a jamais été utilisé pour soigner un patient.** Les obstacles étaient humains et pratiques plutôt que scientifiques. On ne savait pas qui serait **responsable** en cas d'erreur (le médecin, l'hôpital ou le programmeur). Il était difficile de l'**intégrer** au travail clinique, à une époque où il n'y avait pas d'ordinateur au chevet des patients et où tout devait être saisi sur un terminal. Enfin, les médecins n'étaient pas prêts à **déléguer** leur jugement à un programme. Le cas de MYCIN montre que les difficultés des systèmes experts n'étaient pas seulement techniques.

L'industrie a adopté les systèmes experts plus facilement que la médecine. À la fin des années 1970, le constructeur informatique **DEC** devait configurer sur mesure chaque commande de ses ordinateurs **VAX**, ce qui impliquait d'assembler des centaines de composants sans erreur ni oubli. Cette tâche a été confiée à un système expert, **XCON**. XCON configurait les commandes plus rapidement et avec moins d'erreurs que les employés, et il faisait **économiser des dizaines de millions de dollars par an** à DEC. Ce succès a montré que les systèmes experts pouvaient être rentables en dehors des laboratoires. Un problème est cependant apparu : le nombre de règles de XCON augmentait sans cesse, jusqu'à plusieurs milliers, et il fallait constamment les ajuster les unes aux autres. Nous y reviendrons plus bas.

Après XCON, les investissements se sont multipliés. Au début des années 1980, l'IA est devenue pour la première fois une **industrie**. On vendait des **coquilles** (*shells*), c'est-à-dire des moteurs d'inférence vides, prêts à recevoir la base de règles de n'importe quel domaine. Un nouveau métier est apparu, celui d'**ingénieur de la connaissance** (*knowledge engineer*), chargé de recueillir le savoir des experts. Des entreprises ont été créées et ont attiré des capitaux. On a même construit des ordinateurs spécialisés pour ces programmes, les **machines Lisp**. Le Japon a lancé un grand projet national, la **Cinquième Génération**, pour devenir le leader de ce type d'informatique. Les limites des systèmes experts commençaient toutefois à apparaître.



Une « machine Lisp » : le poste de travail Symbolics 3620 (1983), un ordinateur spécialisé conçu pour faire tourner les programmes d'IA symbolique.

Une machine Lisp Symbolics 3620 (1983), Computer History Museum. Photo : leighklotz, CC BY 2.0, via Wikimedia Commons.

Le goulot d'étranglement

La première limite, et la plus importante, concerne l'origine des règles. Quelqu'un doit les écrire. C'est le travail de l'**ingénieur de la connaissance**, qui interroge longuement un expert pour traduire son savoir en règles *si… alors…*. Ce travail s'est révélé très lent. De plus, une grande partie de l'expertise est difficile à exprimer. Le médecin expérimenté qui reconnaît un diagnostic au premier coup d'œil, ou le mécanicien qui identifie une panne au bruit du moteur, ne savent pas toujours expliquer ce qu'ils savent. Leur compétence est un **savoir tacite** (*tacit knowledge*), fondé sur l'intuition et l'expérience, et non une liste de règles qu'il suffirait de noter. On ne peut pas codifier ce qui n'a

jamais été formulé. Ce problème est connu sous le nom de **goulot d'étranglement de l'acquisition des connaissances** (*knowledge acquisition bottleneck*).

La deuxième limite, déjà évoquée dans « Représenter le monde », est la **rigidité**. Un système expert ne connaît que ses règles. Il fonctionne bien à l'intérieur de son domaine, mais dès qu'on en sort, il ne donne plus de résultats utiles, et il ne signale pas qu'il est hors de son domaine. MYCIN diagnostiquait les infections du sang. Si on lui avait décrit une jambe cassée, il aurait cherché un microbe, parce qu'il n'avait aucun moyen de savoir ce qu'il ignorait. Faute de **sens commun**, il pouvait aussi accepter des données absurdes (un patient âgé de moins de zéro an, une dose mille fois trop forte) qu'un étudiant en médecine aurait repérées immédiatement. Réduire le monde à un domaine restreint ne réglait donc pas le problème du sens commun.

La troisième limite est la difficulté de **maintenance**. Un système de quelques dizaines de règles reste gérable. XCON en a accumulé des milliers, et on a constaté qu'au-delà d'un certain nombre, les règles **interagissent** de façon imprévisible. Ajouter une règle pour corriger un cas pouvait en perturber plusieurs autres, sans qu'on s'en aperçoive. Maintenir une grande base de règles demandait plus de temps pour corriger ces effets de bord (*side effects*) que pour ajouter des connaissances. La connaissance explicite, écrite à la main, ne **passait pas à l'échelle**.

La quatrième limite est la plus fondamentale : un système expert n'**apprend rien**. Chacune de ses règles a été écrite par une personne. Le programme peut traiter mille cas sans en tirer une seule règle nouvelle, et il ne corrige pas de lui-même les règles erronées. Toute sa connaissance lui est fournie de l'extérieur, et elle reste figée. C'est à partir de cette limite que des chercheurs ont commencé à poser la question autrement. Puisqu'il est coûteux, voire impossible, d'extraire les règles des experts et de les maintenir à la main, on pourrait confier ce travail à la machine, en la laissant découvrir les règles à partir des données.

Cette approche ne s'imposera que plus tard. À la fin des années 1980, les résultats des systèmes experts restent en deçà des promesses. Les investisseurs se retirent, des entreprises ferment, et les machines Lisp sont abandonnées. L'IA entre dans une longue période de déclin, un **hiver**, décrit dans le chapitre « Les hivers et la bascule ».

Les hivers et la bascule



Pieter Bruegel l'Ancien, Les Chasseurs dans la neige (1565). L'expression « hiver de l'IA » désigne les périodes où l'intérêt et le financement pour la recherche en IA ont fortement diminué.

Pieter Bruegel l'Ancien, *Les Chasseurs dans la neige* (1565), Kunsthistorisches Museum, Vienne. Domaine public, via Wikimedia Commons.

Le premier hiver : la mort du perceptron (1969)

Le chapitre « Deux paris rivaux » a présenté le **perceptron** de Rosenblatt, une machine qui apprend de ses erreurs, que le *New York Times* avait décrit comme le début d'une intelligence électronique. Ce chapitre annonçait aussi que le perceptron allait subir une critique sévère. Cette section présente cette critique.

En **1969**, deux chercheurs importants du camp symbolique, **Marvin Minsky** (l'un des organisateurs de Dartmouth) et son collègue **Seymour Papert**, publient un livre intitulé *Perceptrons*. Il ne s'agit pas d'un pamphlet, mais d'une analyse mathématique rigoureuse. Minsky et Papert y démontrent que le perceptron a une limite de principe : il est incapable d'apprendre certaines fonctions pourtant très simples. L'exemple le plus connu est le **XOR**, le « ou exclusif ».

Le XOR correspond à la règle suivante : l'un ou l'autre, mais pas les deux à la fois. C'est par exemple le principe du **va-et-vient**, où deux interrupteurs commandent une même lampe, souvent aux deux bouts d'un couloir. Quand on bascule l'un ou l'autre interrupteur, la lumière change d'état. Si les deux interrupteurs sont dans la même position, la lampe est éteinte ; s'ils sont dans des positions opposées, elle est allumée. La réponse dépend donc du désaccord entre les deux entrées.

On peut résumer le XOR dans une **table de vérité** (*truth table*), qui donne la réponse pour chaque combinaison possible des deux entrées. On note 0 pour « bas » (ou « faux ») et 1 pour « haut » (ou « vrai ») :

Interrupteur A	Interrupteur B	Lampe (A XOR B)
0	0	0 (éteinte)
0	1	1 (allumée)
1	0	1 (allumée)
1	1	0 (éteinte)

La sortie vaut 1 seulement quand les deux entrées diffèrent. Si l'on place ces quatre cas sur un plan, avec A à l'horizontale et B à la verticale, les deux cas « allumé » occupent deux coins opposés d'un carré, et les deux cas « éteint » les deux autres coins. Cette règle est facile à comprendre pour un humain, mais le perceptron ne peut pas l'apprendre, parce qu'il classe les cas en traçant une seule droite, et qu'aucune droite ne sépare ces deux paires de coins. Le Module 2 reprend cet exemple avec une figure, et montre comment d'autres modèles réussissent là où une droite échoue.

Le livre eut des conséquences importantes. Minsky avait une grande autorité, et il appartenait au camp adverse. Sa démonstration, mathématiquement correcte, fut interprétée comme une condamnation de toute l'approche. Les financements de la recherche sur les réseaux de neurones diminuèrent très rapidement, les revues publièrent moins de travaux sur le sujet et les étudiants choisirent d'autres domaines. Le camp connexionniste connut un **hiver** d'une quinzaine d'années. Rosenblatt n'en vit pas la fin : il mourut en 1971, à quarante-trois ans, dans un accident de bateau.

Le premier hiver de l'IA ne toucha donc pas la tradition dominante, mais sa **rivale**, et c'est un chercheur du camp symbolique qui en fut en partie la cause. Comme le connexionnisme était mis de côté, les vingt années suivantes furent celles d'une **domination symbolique** presque complète : la recherche dans un espace d'états, les systèmes experts et l'ensemble des travaux présentés dans les chapitres « Chercher et raisonner », « Représenter le monde » et « Capturer l'expertise ». Le déclin d'une tradition a ainsi favorisé le développement de l'autre.

La démonstration de Minsky et Papert avait cependant une limite. Elle ne valait que pour le perceptron le plus simple, formé d'une **seule couche**. On pensait qu'en **empilant plusieurs couches**, on pourrait traiter le XOR, mais on ne savait pas comment faire apprendre un tel réseau. La solution n'apparut qu'en 1986, et c'est elle qui permit la reprise des travaux connexionnistes. Avant d'y arriver, il faut d'abord voir comment le camp symbolique connut lui aussi un hiver.

Le second hiver : l'effondrement du symbolique (fin des années 1980)

L'âge d'or symbolique reposait sur une promesse ambitieuse : capturer l'expertise humaine dans des règles. Les limites décrites dans « Capturer l'expertise » (le savoir tacite difficile à extraire, la rigidité sans sens commun, les bases de règles difficiles à maintenir) finirent par affaiblir l'ensemble de l'approche. Comme les systèmes experts livrés décevaient souvent, l'écart grandit entre ce qu'on avait promis aux investisseurs et ce que l'IA réalisait vraiment. Quand cet écart devint trop visible, les investissements diminuèrent.

L'événement le plus représentatif de ce recul fut le **krach des machines Lisp**, vers 1987. Ces ordinateurs spécialisés, conçus pour l'IA, coûtaient très cher. En peu de temps, des stations de travail bon marché, puis les ordinateurs personnels, offrirent des performances comparables pour une fraction du prix. Le marché s'effondra et les entreprises qui en dépendaient disparurent. À la même époque, le projet japonais de **Cinquième Génération**, lancé en 1982 avec beaucoup de publicité, se terminait sans avoir atteint ses principaux objectifs.

Le découragement toucha tout le domaine. Les agences de financement réduisirent leurs crédits, et l'étiquette « intelligence artificielle » devint si mal perçue que les chercheurs évitaient de l'utiliser dans leurs demandes de subvention. On parle, pour cette période, d'un second **hiver de l'IA**. Le terme s'appliquait maintenant au camp symbolique, comme il s'était appliqué vingt ans plus tôt au perceptron. La leçon était la même que dans « Représenter le monde » et « Capturer l'expertise » : le monde réel se laisse difficilement décrire par des règles écrites à la main.

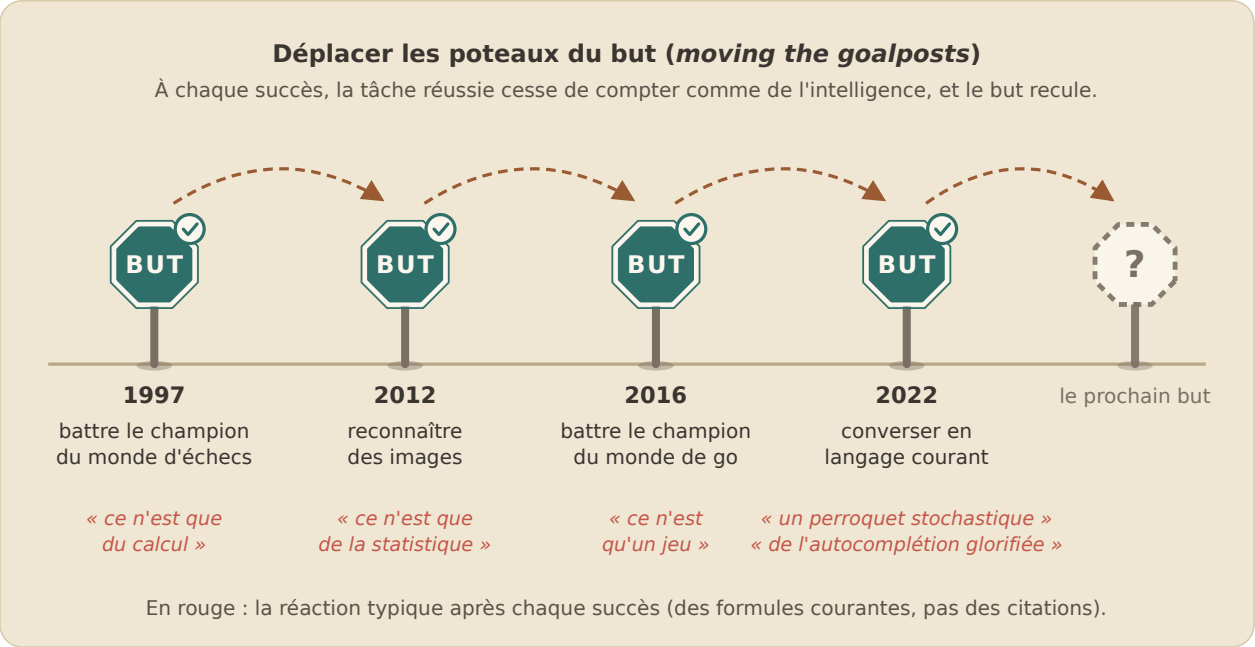
Pendant que le camp symbolique déclinait, le camp connexionniste, qu'on croyait abandonné depuis 1969, **reprenait de l'activité**. En 1986, un petit groupe de chercheurs, dont **Geoffrey Hinton**, avait publié une méthode appelée **rétropropagation** (*backpropagation*). Elle permettait de faire apprendre les réseaux à **plusieurs couches**, c'est-à-dire justement ceux qui, selon les intuitions de l'époque, pouvaient traiter le XOR. L'obstacle signalé dans *Perceptrons* était donc levé. Ce retour resta toutefois discret au début : il fallut attendre les **données** et la **puissance de calcul** des années 2010 pour qu'il devienne largement visible. Les deux traditions échangeaient de nouveau leurs rôles : le déclin de l'une coïncidait avec la reprise de l'autre.

L'héritage invisible

Après deux hivers successifs, on pourrait conclure que le GOFAI a échoué. Cette conclusion serait cependant incomplète, à cause d'un phénomène que les chercheurs appellent l'**« effet IA »** (*AI effect*) : dès qu'une technique fonctionne bien, on cesse de l'appeler « intelligence artificielle » et on la considère comme « juste un algorithme ». La formule la plus courte est attribuée à l'informaticien Larry Tesler, et c'est **Hofstadter** qui l'a popularisée : « *l'IA, c'est tout ce qui n'a pas encore été fait.* »

Les anglophones ont une expression pour ce phénomène : *moving the goalposts*, « déplacer les poteaux du but ». L'image vient du sport. Si l'on recule le but chaque fois qu'un joueur s'apprête à marquer, il ne marquera jamais, quelle que soit sa performance. L'histoire de l'IA suit ce schéma. Avant 1997, on tenait le jeu d'échecs pour un bon test de l'intelligence. Quand Deep Blue a battu Kasparov, on a conclu que les échecs ne demandaient finalement que du calcul. Le même raisonnement a été repris pour la reconnaissance d'images, pour le jeu de go, puis pour la conversation. Les grands modèles de langage ont ainsi été décrits comme des « perroquets stochastiques » (*stochastic parrots*), selon l'expression de la linguiste Emily Bender et de ses coauteures en 2021 : des systèmes qui assemblent des suites de mots probables sans rien comprendre de ce qu'ils disent. On dit aussi

qu'ils ne font que de l'« autocomplétion glorifiée » (*glorified autocomplete*), comme la fonction qui propose le mot suivant sur un téléphone. À chaque succès, la tâche réussie est retirée de la définition de l'intelligence, et le but est placé un peu plus loin. Ce déplacement n'est pas toujours injustifié, parce qu'un succès révèle parfois que la tâche était plus facile qu'on ne le croyait. Mais il explique pourquoi les réussites du GOFAI ont cessé d'être comptées comme de l'IA.



Déplacer les poteaux du but : à chaque succès de l'IA, la tâche réussie cesse de compter comme de l'intelligence.

De ce point de vue, le GOFAI n'a pas disparu : il s'est **intégré** à l'informatique courante. Ses réussites sont devenues si ordinaires et si fiables qu'on a oublié qu'elles venaient des laboratoires d'IA. Les quatre exemples suivants sont des techniques que vous utilisez probablement chaque jour.

La recherche dans un arbre. Les algorithmes d'exploration (minimax, A*) qui permettaient aux machines de jouer aux échecs sont aujourd'hui très répandus. Ce sont eux qui calculent votre itinéraire **GPS** en une fraction de seconde, qui dirigent les personnages des jeux vidéo et qui optimisent les tournées d'un transporteur ou les mouvements d'un robot. Les personnes qui suivent un itinéraire sur leur téléphone ne pensent généralement pas qu'elles utilisent une technique d'« intelligence artificielle » des années 1960.

Les moteurs de règles. Les systèmes experts n'ont pas disparu, mais ils ont changé de nom. On parle aujourd'hui de « règles métier » (*business rules*), et ces systèmes décident automatiquement de l'octroi d'un prêt, du repérage d'une transaction frauduleuse ou du calcul d'une prime d'assurance. Les **configurateurs** qui, sur un site marchand, vérifient que les options d'une voiture ou d'un ordinateur sont compatibles descendent directement de XCON. De même, un logiciel d'**impôts** qui vous guide de question en question jusqu'au bon formulaire fait le même travail que MYCIN.

Les idées de Lisp. Cet héritage est peut-être le plus important. Le langage de McCarthy a introduit dans la programmation courante la **programmation fonctionnelle** : traiter les fonctions comme des valeurs (les *lambdas*), enchaîner des opérations comme `map`, `filter`, `reduce`, utiliser des *closures*. Ces constructions, courantes aujourd'hui en Python, en JavaScript ou en Java, viennent des laboratoires d'IA. Lisp a aussi introduit des outils qu'on considère maintenant comme normaux : le **ramasse-**

miettes (*garbage collection* : la gestion automatique de la mémoire) et le **REPL**, la console qui permet d'essayer du code au fur et à mesure. L'autre grande tradition fonctionnelle, celle des langages typés comme Haskell, descend du langage **ML**, que Robin Milner avait créé pour programmer un **assistant de démonstration de théorèmes** (*proof assistant*). Les deux sources de la programmation fonctionnelle moderne viennent donc du raisonnement symbolique.

La représentation des connaissances. Les réseaux sémantiques (*semantic networks*) et les frames, présentés plus tôt, ont eu des successeurs. Les **ontologies** et les **knowledge graphs** qui structurent le savoir du web en sont les héritiers directs. Quand Google affiche une fiche résumée à côté des résultats, ou quand on interroge Wikidata, c'est la même idée qui est utilisée : relier des concepts par des liens *est-un* ou *possède*. Entre les deux, il y a eu une tentative ambitieuse, qui mérite d'être mentionnée : le **web sémantique**. En 2001, Tim Berners-Lee, l'inventeur du Web, propose d'en faire une grande base de connaissances lisible par les machines. Chaque page contiendrait non seulement du texte pour les humains, mais aussi des faits structurés pour les programmes (*cette personne est née en telle année*, *ce produit coûte tant*), reliés par des vocabulaires communs, c'est-à-dire des ontologies. Des normes sont écrites dans ce but (RDF, OWL). Le projet complet ne s'est pas réalisé, pour une raison déjà vue dans « Représenter le monde » : il supposait que des millions d'auteurs décrivent soigneusement le sens de ce qu'ils publient. C'est le même travail d'inscription à la main qui avait limité CYC, mais à l'échelle de la planète. Certaines de ses composantes ont cependant été conservées : les balises que les sites ajoutent aujourd'hui pour que les moteurs de recherche comprennent une recette ou un horaire, ainsi que Wikidata, en sont les héritiers directs. Quant aux frames, avec leurs cases à valeurs par défaut et leurs hiérarchies d'héritage, elles sont **apparentées** à l'**objet** de la programmation moderne. Elles n'en sont pas l'ancêtre (l'orienté-objet doit davantage à la simulation qu'à l'IA), mais elles reposent sur la même intuition. Une dernière remarque prépare le module 4 : tout ce savoir est **structuré à la main** par des humains. C'est l'opposé de la façon dont les grands modèles de langage acquièrent leur savoir, en traitant d'énormes quantités de texte. Ces deux conceptions du savoir seront comparées plus loin dans le cours.

Ces quatre exemples ne sont pas les seuls. Aucune de ces techniques ne porte plus l'étiquette « IA », parce qu'elles font maintenant partie de l'informatique ordinaire. Le GOFAI n'a donc pas été une impasse : ses idées se sont **dispersées** hors du domaine de l'intelligence artificielle et sont devenues des éléments courants et indispensables de la programmation.

Un éclair hybride : Watson (2011)

Un dernier exemple montre que le GOFAI ne s'est pas seulement intégré à l'informatique courante, mais qu'il est aussi réapparu, combiné à d'autres méthodes. En février **2011**, un système d'IBM nommé **Watson** affronte, au jeu télévisé américain *Jeopardy!*, les deux meilleurs champions de l'histoire de l'émission, Ken Jennings et Brad Rutter, et les bat nettement.

Cette réussite est d'une autre nature que celle de Deep Blue. Les échecs ont des règles précises et un espace de recherche (*search space*) bien défini. *Jeopardy!*, au contraire, repose sur un **langage** difficile, fait de calembours, d'allusions, de jeux de mots et d'indices indirects. Comprendre ce que la question demande est déjà un problème difficile. Watson y répond en quelques secondes, en utilisant une très grande base de connaissances.

Watson n'est **ni du GOFAI pur, ni un réseau de neurones**. C'est un **hybride**. D'une part, il reprend des éléments du symbolique : une grande base de connaissances et des traitements du langage à base de règles. D'autre part, il pondère des centaines d'indices et calcule sa **confiance** avec des

méthodes **statistiques**, apprises sur des milliers de questions passées. Quatorze ans après Deep Blue, ce n'est donc plus seulement la force brute de la recherche qui permet de gagner, mais une combinaison du savoir structuré du GOFAI et de l'apprentissage statistique. Watson illustre ainsi la **charnière** où se trouve maintenant le module, entre deux périodes.

> La suite de l'histoire de Watson ressemble à celle des systèmes experts. Après le succès de 2011, IBM annonça que *Watson Health* allait **transformer la médecine** : la machine devait conseiller les cancérologues mieux que leurs collègues. Les résultats furent très différents. Certaines recommandations se révélèrent douteuses, voire dangereuses. De grands hôpitaux partenaires abandonnèrent le projet après y avoir dépensé des dizaines de millions de dollars, et IBM finit par **revendre** Watson Health en 2022. Trente ans après MYCIN, qui avait bien fonctionné en démonstration sans jamais être utilisé auprès de vrais patients, la même leçon se répétait : l'écart reste très grand entre une réussite en laboratoire (ou sur un plateau de télévision) et le monde réel. Une fois de plus, une promesse trop ambitieuse avait précédé la déception.

La bascule

Voici un résumé du chemin parcouru. Le chapitre « Turing et la question fondatrice » est parti d'une hypothèse : penser, c'est calculer. De cette hypothèse est née une famille d'idées (manipuler des symboles selon des règles) qui a produit, pendant trois décennies, des réussites importantes : des machines qui démontrent des théorèmes, qui jouent aux échecs, qui dialoguent, qui représentent le monde et qui établissent des diagnostics comme des médecins. Le programme symbolique n'a donc pas été un échec : il a fondé l'informatique du raisonnement, qui est encore utilisée aujourd'hui.

Il s'est cependant heurté deux fois à la même difficulté. Dans « Représenter le monde », il s'agissait du **sens commun**, l'ensemble des évidences que personne ne pense à formuler et qu'on ne peut donc pas écrire. Dans « Capturer l'expertise », il s'agissait du **goulot d'étranglement** : l'expertise est difficile à mettre en règles, parce qu'une grande partie du savoir humain n'est pas exprimée. Ces deux difficultés relèvent d'une même leçon, que Hofstadter avait peut-être formulée le premier : on ne peut pas inscrire l'intelligence de l'extérieur, fait après fait, parce que le savoir utile est trop vaste, trop tacite et trop changeant pour tenir dans une liste de règles.

Si l'on ne peut pas dicter ce savoir à la machine, il faut qu'elle l'**acquière elle-même**. Cette idée n'était pas nouvelle : elle se trouvait déjà en 1958 dans le perceptron de Rosenblatt, une machine qui apprend de ses erreurs, que le camp symbolique pensait avoir écarté en 1969. C'est ici que se termine le fil suivi depuis « Deux paris rivaux ». Les deux traditions, symbolique et connexionniste, ne se sont jamais simplement succédé : elles ont coexisté en rivales, et chacune a dominé à son tour. L'hiver symbolique de la fin des années 1980 n'est donc pas la fin de l'histoire, mais le moment où l'avantage commence à revenir vers l'autre tradition.

Une question, apparue avec les difficultés du GOFAI, va réorganiser le domaine : au lieu de dicter ses règles à la machine, on peut la laisser les découvrir dans les données. Ce changement d'approche s'appelle l'**apprentissage automatique**, et c'est l'objet du **Module 2**. La tradition connexionniste, relancée par la rétropropagation et la puissance des machines modernes, le mènera ensuite, au **Module 3**, à des résultats que ni Turing, ni Rosenblatt, ni Minsky n'avaient imaginés.

Le module peut se résumer par le passage d'un verbe à un autre. Pendant trois décennies, être intelligent, pour une machine, a surtout voulu dire **chercher** : explorer un espace de possibilités, guidé par des règles fixées à l'avance. La période suivante remplace ce verbe par **apprendre**. Les

deux verbes restent cependant proches, et la suite du cours y reviendra : apprendre, c'est encore chercher, mais dans un autre espace. Au lieu d'explorer les coups d'une partie, on explore l'ensemble des réglages possibles d'un modèle, jusqu'à trouver ceux qui correspondent aux données. Le GOFAI cherchait la solution, alors que l'apprentissage cherche de quoi la produire. La période de la recherche se termine donc, et celle de l'apprentissage, qui est une autre forme de recherche, commence.

Vous êtes le moteur d'inférence : un système expert (travail noté 1)

Au Module 1, nous avons vu qu'avant l'apprentissage automatique (que nous commencerons à étudier en détail au module 2), la grande idée de l'IA « classique » (le GOFAI) était de **capturer la connaissance dans des règles explicites**. Les **systèmes experts** sont l'aboutissement de cette idée. Ils comportent une **base de règles** `si… alors…`, une **base de faits** (le cas qu'on traite) et un **moteur d'inférence**, qui compare les deux, déclenche les règles applicables et en tire de nouvelles conclusions, jusqu'au diagnostic final.

Dans ce travail, vous allez jouer le rôle de ce moteur d'inférence sur un petit système expert qui **identifie des animaux** à partir de leurs caractéristiques. Vous allez le faire fonctionner, trouver un cas où il échoue, puis tenter de l'améliorer. Vous observerez ainsi directement ce qu'on a appelé le **goulot d'étranglement de la connaissance**.

Une règle a la forme suivante :

```
SI  (mammifère)  ET  (mange de la viande)   ALORS  (carnivore)
```

Les conditions d'une règle sont **toujours reliées par des ET, jamais par des OU**. Une règle ne se déclenche donc que si **toutes** ses conditions sont vraies en même temps. Dans l'exemple ci-dessus, `mammifère` **et** `mange de la viande` doivent être vrais tous les deux pour qu'on conclue `carnivore`. Une seule des deux conditions ne suffit pas. Pour exprimer un « OU » (par exemple `a du poil` **ou** `allaite ses petits` → `mammifère`), on écrit **deux règles séparées**. C'est ce que fait la base avec R1 et R2.

Le « savoir » du système n'est qu'un ensemble de règles de ce type. Son « raisonnement » est un mécanisme simple qui vérifie quelles règles ont toutes leurs conditions réunies. Comme nous le verrons, toute l'intelligence du système tient dans une seule formule.

Consignes

1. Ouvrez le fichier Google Sheets fourni pour ce travail et **faites-en une copie** (*Fichier › Créer une copie*). Vous ferez tout votre travail à partir de **votre copie**.
2. Une fois vos manipulations terminées, partagez votre fichier et copiez le lien vers celui-ci dans un document PDF (**Attention : aucun autre format que PDF ne sera accepté**).
3. Répondez aux questions d'interprétation de la dernière section dans le même fichier PDF, en fournissant des réponses claires et précises.

Le système

Le classeur ne comporte que **deux onglets**. Il constitue le système expert réduit à l'essentiel, c'est-à-dire une base de faits et une base de règles.

- **Faits** : la liste de toutes les caractéristiques possibles (les *attributs observables* comme `a du poil`, mais aussi les *catégories* déduites comme `mammifère` et les *espèces*). Chaque fait a une case **Vrai ?** à cocher.
- **Base de règles** : les 11 règles `si… alors…`, sous forme de conditions et d'une conclusion.

L'élément central du système est la colonne « **Activable ?** » de la *Base de règles*. Pour chaque règle, cette formule vérifie que **toutes ses conditions sont vraies** dans l'onglet *Faits* et que sa conclusion n'a pas déjà été établie :

```
=IF($F3="","",AND(
   IF($B3="",TRUE,VLOOKUP($B3,Faits!$A:$B,2,FALSE)=TRUE),
   IF($C3="",TRUE,VLOOKUP($C3,Faits!$A:$B,2,FALSE)=TRUE),
   IF($D3="",TRUE,VLOOKUP($D3,Faits!$A:$B,2,FALSE)=TRUE),
   IF($E3="",TRUE,VLOOKUP($E3,Faits!$A:$B,2,FALSE)=TRUE),
   VLOOKUP($F3,Faits!$A:$B,2,FALSE)<>TRUE))
```

Cette formule est celle de la règle R1, qui occupe la ligne 3 du tableau. Chaque `VLOOKUP` cherche un fait dans l'onglet *Faits* et lit sa case **Vrai ?**. La colonne voisine, « **Déjà conclue ?** », indique si la conclusion de la règle est déjà cochée. Un **bandeau d'état**, sur la première ligne de l'onglet, résume où vous en êtes : il vous invite à continuer tant qu'une règle est verte, il annonce l'animal identifié, ou il signale que le système est bloqué.

Quand une règle est activable, sa ligne est **surlignée en vert**, ce qui signifie qu'elle est prête à se déclencher. C'est vous qui jouez le rôle du moteur. Vous choisissez une règle verte et vous **cochez sa conclusion** dans l'onglet *Faits*. Cette action rend d'autres règles vertes, et ainsi de suite.

Dans un vrai système expert, ce travail est entièrement **automatique**. Un programme, le *moteur d'inférence*, parcourt la base de règles, repère celles dont toutes les conditions sont réunies, les déclenche, ajoute leurs conclusions à la base de faits, puis recommence, jusqu'à ce qu'aucune règle ne s'applique plus. L'humain n'intervient pas. Ici, **pour des raisons pédagogiques, c'est vous qui tenez ce rôle**. Vous exécutez à la main l'algorithme que la machine exécuterait seule. Le but est de vous faire constater à quel point ce raisonnement est mécanique. Il s'agit d'une simple boucle qui applique des règles, sans aucune compréhension de ce qu'est un guépard ou un manchot.

1	▶ Continuez : déclenchez une règle surlignée en vert							
2	Règle	Condition 1	Condition 2	Condition 3	Condition 4	→ Conclusion	Activable ? (calculé)	Déjà conclue ? (calculé)
3	R1	a du poil				mammifère	TRUE	FALSE
4	R2	allaite ses petits				mammifère	FALSE	FALSE
5	R3	a des plumes				oiseau	FALSE	FALSE
6	R4	mammifère	mange de la viand			carnivore	FALSE	FALSE
7	R5	mammifère	a des dents pointu	a des griffes		carnivore	FALSE	FALSE
8	R6	carnivore	robe fauve	taches sombres		guépard	FALSE	FALSE
9	R7	carnivore	robe fauve	rayures noires		tigre	FALSE	FALSE
10	R8	mammifère	rumine	long cou	taches sombres	girafe	FALSE	FALSE
11	R9	mammifère	a des sabots	rayures noires		zèbre	FALSE	FALSE
12	R10	oiseau	incapable de voler	long cou		autruche	FALSE	FALSE
13	R11	oiseau	incapable de voler	nage	plumage noir et blan	manchot	FALSE	FALSE

Le Cas 1 au départ : seule la règle R1 est activable, et sa ligne est surlignée en vert.

Manipulation 1 — Tracer le raisonnement

Voici le **Cas 1** : cochez `a du poil`, `mange de la viande`, `robe fauve` et `taches sombres` dans l'onglet *Faits* (laissez tout le reste à FAUX).

Une seule règle devient verte, **R1**. Déclenchez-la (cochez sa conclusion, `mammifère`, dans l'onglet *Faits*). Une nouvelle règle s'active. Déclenchez-la à son tour, et continuez jusqu'à ce qu'une **espèce** passe à VRAI.

Au fur et à mesure, **notez la trace** de votre raisonnement directement dans votre document PDF, sous la forme d'un petit tableau, avec une ligne par règle déclenchée :

Étape	Règle déclenchée	Nouveau fait établi	Pourquoi (conditions réunies)
1	R1	`mammifère`	`a du poil` est vrai
2	…	…	…

Recommencez ensuite avec le **Cas 2**, le manchot (`a des plumes`, `incapable de voler`, `nage`, `plumage noir et blanc`), après avoir remis tous les faits à FAUX.

> **Pour remettre les faits à FAUX**, décochez les cases une à une en cliquant dessus. N'utilisez pas la touche Suppr (ou Retour arrière) sur les cases, parce qu'elle supprime la case à cocher au lieu de la décocher. Si cela vous arrive, annulez avec Ctrl+Z (Cmd+Z sur Mac), ou recréez les cases avec *Insertion › Case à cocher*.

Manipulation 2 — Casser le système

Remettez tous les faits à FAUX, puis chargez le **Cas 3** : `a du poil`, `a des sabots`, `rumine`.

Faites fonctionner le moteur. Vous obtenez `mammifère`, puis plus aucune règle ne s'active. Aucune règle d'espèce ne devient verte. Le système est **bloqué**, parce qu'il ne sait pas identifier cet animal (il s'agit, par exemple, d'une **antilope**).

Manipulation 3 — Étendre la base de règles

Vous devez maintenant ajouter le savoir manquant. Sur la première ligne vide de la *Base de règles*, écrivez une nouvelle règle qui conclut `antilope`. Utilisez les **menus déroulants** pour les conditions.

L'espèce `antilope` n'est pas encore dans l'onglet *Faits*. Ajoutez-la sur la première ligne vide, en remplissant les trois colonnes :

- son nom, `antilope`, dans la colonne *Fait* ;
- une case à cocher dans la colonne *Vrai ?* (*Insertion › Case à cocher*) ;
- la mention `espèce (conclusion)` dans la colonne *Catégorie*. Sans cette mention, le bandeau d'état ne reconnaît pas l'antilope comme une espèce, et il continue d'afficher que le système est bloqué.

Procédez de la même façon pour tout nouvel attribut dont vous auriez besoin, avec la mention `observable` dans la colonne *Catégorie*.

Vérifiez que votre règle identifie bien le Cas 3. Ensuite, **testez sa solidité** : chargez un autre animal (par exemple le **zèbre** : `a du poil`, `a des sabots`, `rayures noires`). Votre nouvelle règle se déclenche-t-elle aussi, par erreur ? Modifiez-la si nécessaire.

1	▶ Continuez : déclenchez une règle surlignée en vert							
2	Règle	Condition 1	Condition 2	Condition 3	Condition 4	→ Conclusion	Activable ? (calculé)	Déjà conclue ? (calculé)
3	R1	a du poil				mammifère	FALSE	TRUE
4	R2	allaite ses petits				mammifère	FALSE	TRUE
5	R3	a des plumes				oiseau	FALSE	FALSE
6	R4	mammifère	mange de la viand			carnivore	FALSE	FALSE
7	R5	mammifère	a des dents pointu	a des griffes		carnivore	FALSE	FALSE
8	R6	carnivore	robe fauve	taches sombres		guépard	FALSE	FALSE
9	R7	carnivore	robe fauve	rayures noires		tigre	FALSE	FALSE
10	R8	mammifère	rumine	long cou	taches sombres	girafe	FALSE	FALSE
11	R9	mammifère	a des sabots	rayures noires		zèbre	FALSE	FALSE
12	R10	oiseau	incapable de voler	long cou		autruche	FALSE	FALSE
13	R11	oiseau	incapable de voler	nage	plumage noir et blan	manchot	FALSE	FALSE
14	R12	mammifère	a des sabots	rumine		antilope	TRUE	
15								
16								

Une nouvelle règle, R12, ajoutée sur la première ligne vide : elle devient activable pour le Cas 3.

Questions d'interprétation

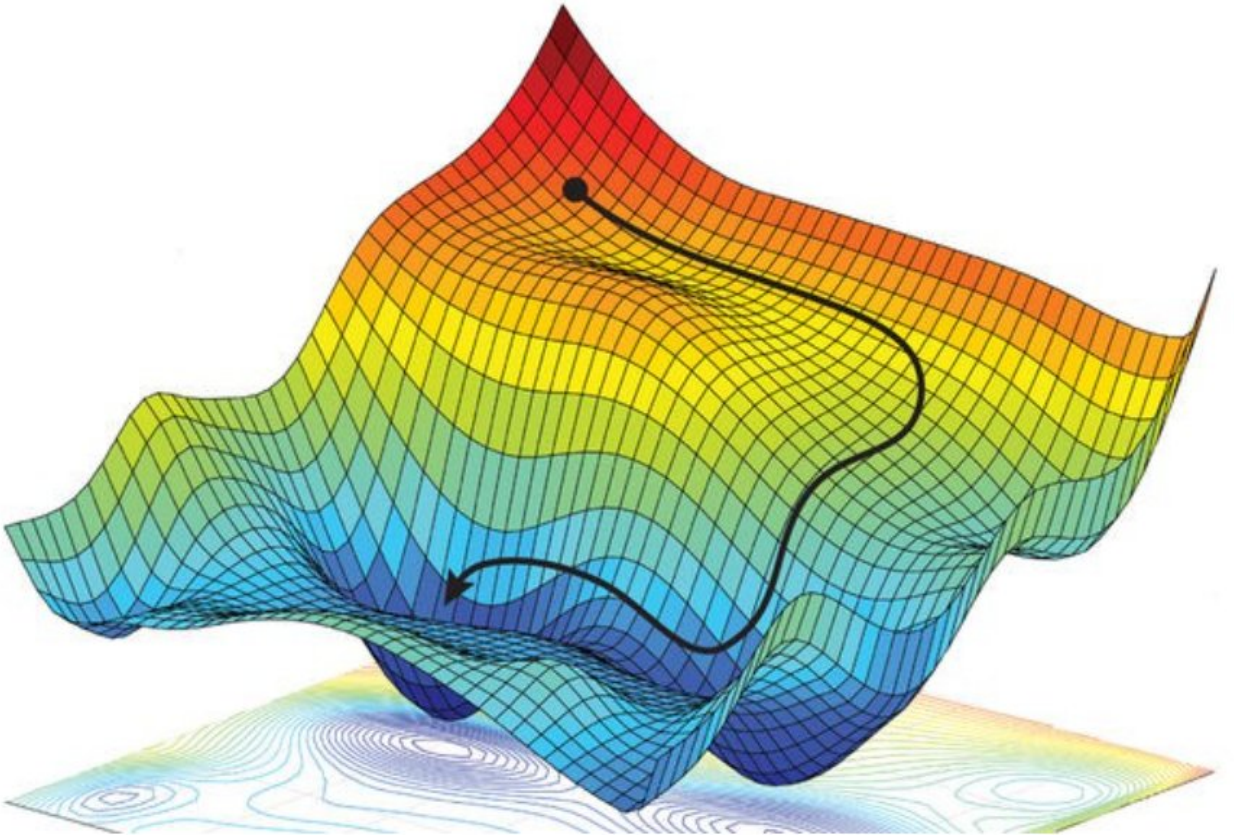
1. Pour le Cas 1, combien de règles se sont déclenchées, et dans quel ordre ? Décrivez la **cascade** : en quoi la conclusion d'une règle sert-elle de condition à une autre ?
2. Dans ce système, le « savoir » (la base de règles) et le « raisonnement » (le moteur) sont **séparés**. Si l'on remplaçait entièrement la base de règles par des règles de diagnostic automobile, qu'est-ce qui changerait, et qu'est-ce qui resterait identique ?
3. Le système peut **expliquer** sa conclusion (le tableau de trace que vous avez rempli le montre). En quoi est-ce une force ? Comparez avec ce que vous anticipez d'un réseau de neurones (Module 3).
4. Vous avez fait fonctionner le moteur « vers l'avant » (des faits vers la conclusion), ce qu'on appelle le **chaînage avant**. Comment auriez-vous procédé pour vérifier une hypothèse précise (« et si c'était un tigre ? ») sans tout cocher d'avance, c'est-à-dire en **chaînage arrière** ?
5. Au Cas 3, pourquoi exactement le système s'est-il bloqué ? Qu'est-ce que cela révèle sur sa capacité à gérer un cas **imprévu** ?
6. La règle que vous avez ajoutée risquait-elle de **mal classer** d'autres animaux ? Décrivez ce que vous avez observé en la testant sur le zèbre, et ce que cela indique sur la difficulté de maintenir une grosse base de règles.
7. Supposons qu'on veuille étendre ce système pour identifier **tous les animaux du monde**. Décrivez concrètement ce qui se passerait pour la base de règles. Quel concept des chapitres « Capturer l'expertise » et « Les hivers et la bascule » cela illustre-t-il ?
8. Un zoologiste reconnaît souvent un animal « d'un coup d'œil », sans pouvoir énoncer la règle exacte qu'il applique. Quel nom donne-t-on à ce type de savoir, et pourquoi pose-t-il problème à un système expert ?

9. Ce système **apprend-il** de son expérience ? Si on lui présentait mille animaux, ses règles s'amélioreraient-elles d'elles-mêmes ? Quelle conséquence cela a-t-il, et vers quel changement de paradigme (Module 2) cela conduit-il ?

10. Toute « l'intelligence » du moteur tient dans la formule de la colonne *Activable ?*. Diriez-vous que ce système pense ? Reliez votre réponse au test de Turing et à l'« effet IA ».

11. Les systèmes experts ont presque disparu sous ce nom, mais leur mécanisme existe toujours (voir « Les hivers et la bascule »). Donnez un exemple, tiré de la vie courante, d'un endroit où une base de règles `si… alors…` décide encore quelque chose à votre sujet.

Module 2 — Apprentissage automatique

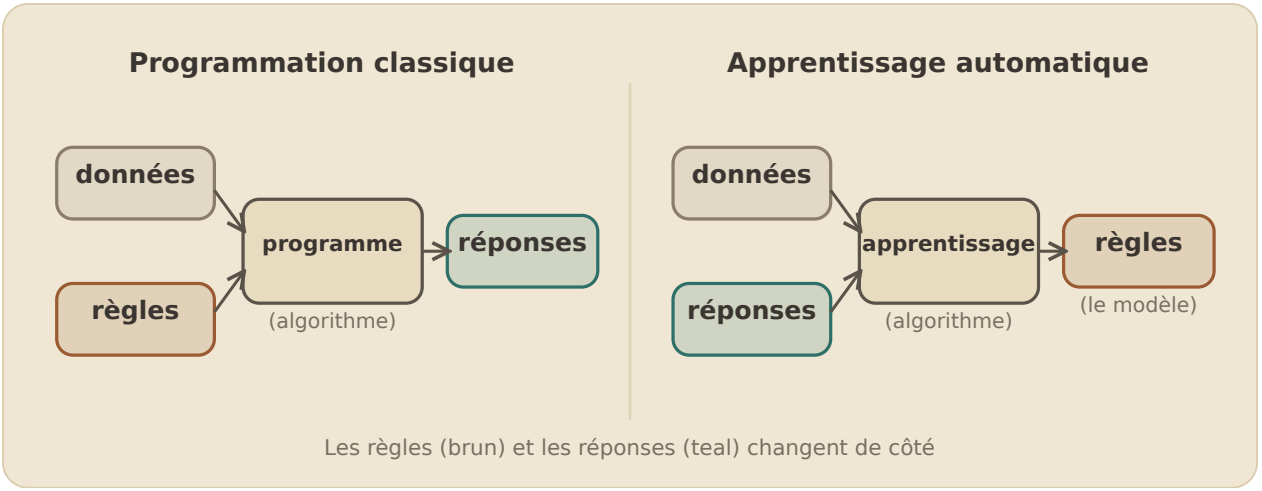


Qu'est-ce que l'apprentissage automatique ?

L'apprentissage automatique (AA, ou *machine learning*) est un ensemble de techniques qui permettent à un ordinateur de résoudre des problèmes qu'il serait très difficile de programmer à la main : reconnaître un chat sur une photo, estimer le prix d'une maison, filtrer les pourriels, jouer aux échecs, converser, etc.

La différence avec la programmation classique est importante. Un programme traditionnel encode une série de **règles** écrites par un humain. Un modèle d'AA, au contraire, **dérive son fonctionnement à partir d'exemples** : on ne lui donne pas la règle, on la lui fait découvrir dans les données. C'est ce passage des règles aux exemples qui rapproche l'AA de ce qu'on appelle l'intelligence. Il le rattache aussi au **connexionnisme**, présenté au module 1 : l'hypothèse, rivale de l'approche symbolique, selon laquelle l'intelligence ne s'écrit pas en règles explicites, mais **émerge d'un réseau de connexions qui s'ajustent à l'expérience**. L'apprentissage automatique reprend cette idée principale, sans nécessairement garder les neurones. Ce qui s'ajuste ici s'appelle des **paramètres**, et c'est en les réglant sur des exemples que le modèle finit par « savoir » quelque chose.

On peut aussi dire que les deux démarches **échangent leurs entrées et leurs sorties**. En programmation classique, un humain écrit les règles, et l'ordinateur les applique aux données pour produire des réponses. En apprentissage automatique, on fournit à l'ordinateur les données **et** les réponses (ce sont les exemples), et c'est l'ordinateur qui en dégage les règles, qu'on appelle alors le **modèle**. Ce qui était fourni par l'humain (les règles) devient le résultat, et ce qui était le résultat (les réponses) devient une donnée d'entrée. Le schéma ci-dessous montre cette permutation : suivez les « règles » (en brun) et les « réponses » (en teal), qui passent d'un côté à l'autre.

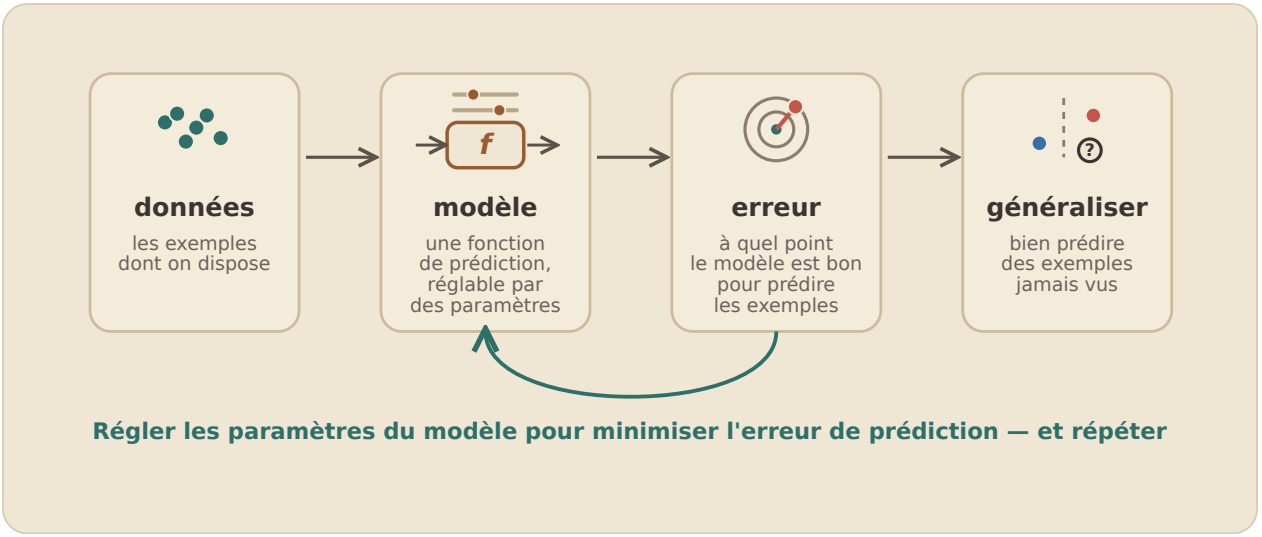


L'inversion au centre de l'apprentissage automatique : ce qu'on fournit et ce que l'ordinateur produit s'inversent. En programmation classique, on écrit les règles ; en AA, c'est l'ordinateur qui les découvre.

Une seule grande idée, déclinée

Au lieu de présenter un catalogue d'algorithmes, ce module construit **un modèle mental unique et transférable**, qui revient de page en page :

> partir de **données** → choisir un **modèle** (une fonction de prédiction, réglable par des paramètres) → mesurer son **erreur** de prédiction → régler les paramètres du modèle pour la **minimiser** → vérifier qu'il **généralise** à des cas nouveaux.



La structure du module : données → modèle → erreur → généraliser, avec au centre la boucle d'entraînement (régler les paramètres du modèle pour minimiser l'erreur de prédiction, de façon répétée).

Chaque algorithme classique présenté dans ce module, du plus simple au plus élaboré, est une **variation** sur ce même schéma. Quand on comprend ce schéma, l'apprentissage automatique n'est plus une boîte noire.

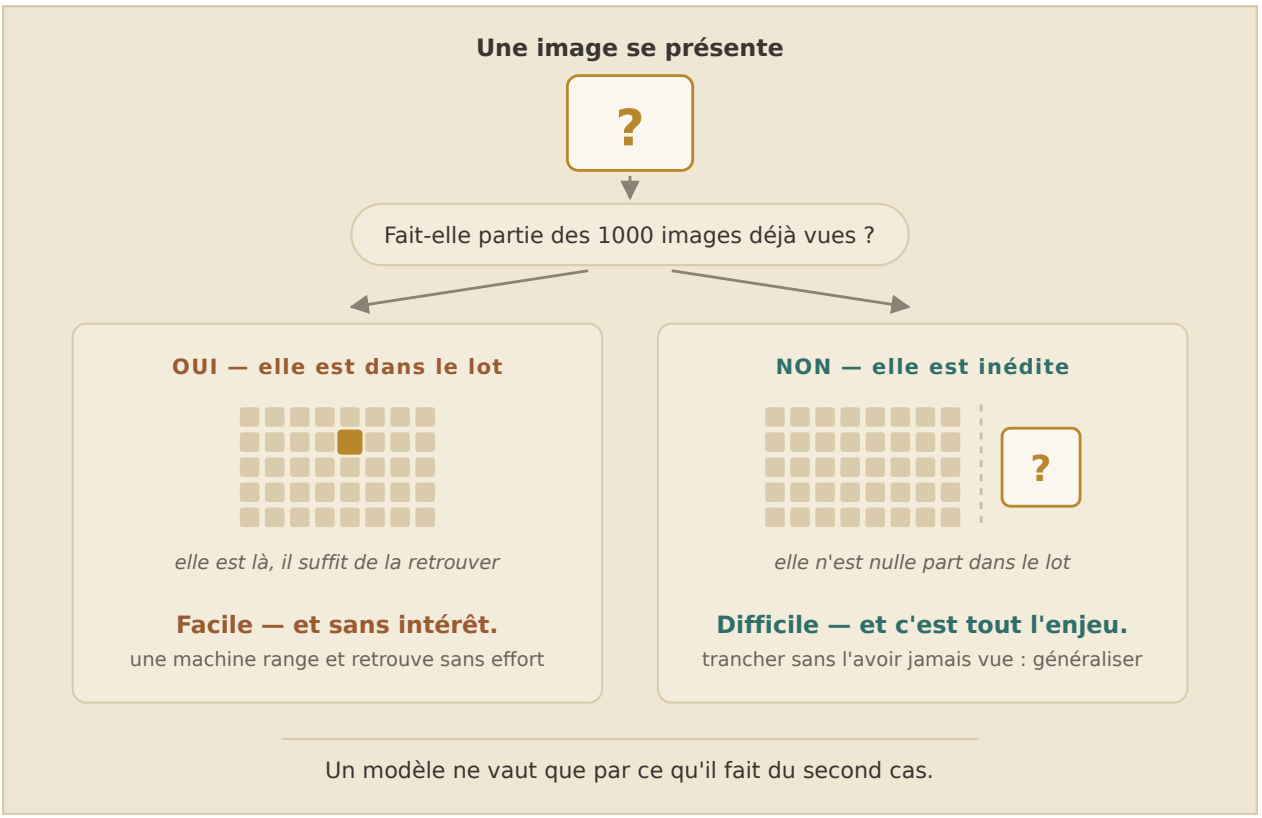
Une vieille parenté : la statistique

Il faut préciser dès le départ un point que le vocabulaire actuel tend à cacher : l'apprentissage automatique n'est pas né avec les ordinateurs, et encore moins avec les années 2010. Presque tout ce que vous verrez dans ce module relève de la **statistique**, parfois depuis deux siècles. La droite ajustée par les moindres carrés date de Legendre et de Gauss, vers 1805. Le théorème de Bayes date de 1763, et le mot *régression* lui-même a été introduit par Galton en 1886. Les plus proches voisins, les arbres de décision et les forêts ont été développés par des statisticiens, et les termes que nous emploierons (échantillon, distribution, biais, variance, test) viennent de la statistique. L'autre discipline d'origine est la **théorie des probabilités** : chaque modèle de ce module repose sur une probabilité, une vraisemblance ou une croyance que l'on révise, et le théorème de Bayes y joue un rôle central.

La différence entre les deux domaines tient moins aux outils qu'à la **question posée**. La statistique classique cherche à expliquer, par exemple quel est l'effet de la superficie sur le prix, et avec quelle certitude. L'apprentissage automatique cherche à prédire, par exemple quel sera le prix d'une maison donnée. Pour bien prédire, il accepte des modèles si complexes qu'on ne peut plus les interpréter, à condition qu'ils fonctionnent bien sur des données nouvelles. Leo Breiman, un statisticien devenu pionnier de l'apprentissage automatique, a décrit cette divergence dans un texte connu, « Statistical Modeling: The Two Cultures » (2001) : il y décrit deux cultures qui partagent les mêmes fondements. Nous signalerons cette parenté chaque fois qu'un modèle viendra directement de la statistique.

Le but ultime : généraliser

La notion la plus importante de l'AA, celle qui permet de l'associer au domaine de l'intelligence, est la capacité à **généraliser**. Si on entraîne un modèle à distinguer un chien d'un chat avec 1000 images, sa performance sur ces 1000 images a peu d'intérêt, puisqu'il devrait les reconnaître par construction. En effet, mémoriser ces 1000 images est **trivial** pour un ordinateur : ranger des données et les restituer à l'identique est exactement ce qu'une machine fait sans effort, et cela ne demande aucune intelligence. Ce qui compte, c'est la **1001e** image, que le modèle n'a jamais vue. Un modèle qui a vraiment appris, au lieu de simplement mémoriser, pourra la classer correctement. La question devient plus intéressante encore si on lui montre une vache au lieu d'un chat ou d'un chien. Bien généraliser est le véritable objectif de l'AA, et c'est l'un des sens les plus concrets qu'on puisse donner au mot « apprendre ».



Les deux cas possibles pour une nouvelle image. Si elle fait partie des 1000 images déjà vues, la retrouver est trivial ; si elle est inédite, il faut décider sans précédent. C'est dans ce second cas qu'on évalue un modèle.

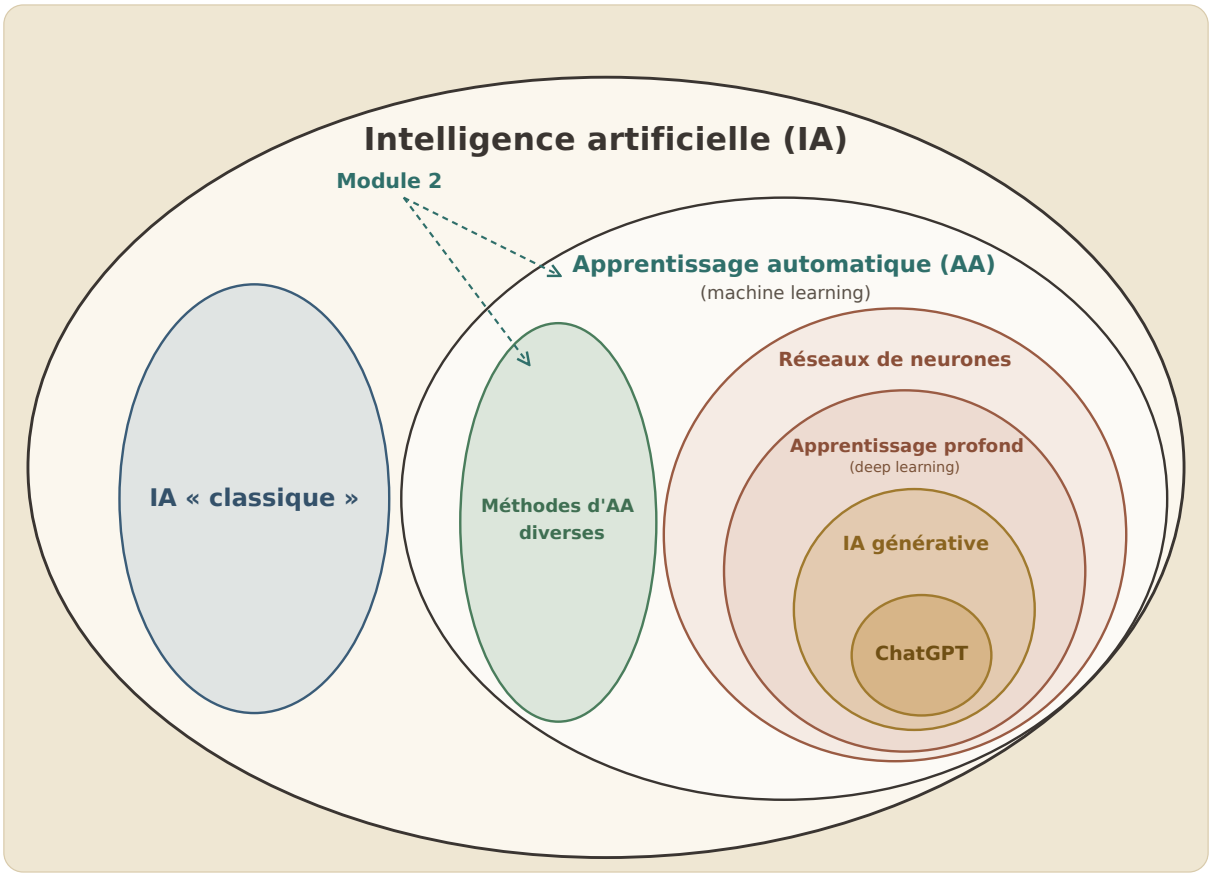
Le parcours du module

Le module part du **modèle le plus simple possible**, puis l'améliore progressivement : chaque étape rencontre une limite qui mène à l'idée suivante.

1. *Le problème* : prédire un prix, prédire une catégorie, et pourquoi c'est difficile.
2. *Le modèle le plus bête* : toujours répondre la moyenne, et ce que ce point de référence nous apprend.
3. *Regarder les données* : une maison, une image, un courriel sont des listes de nombres, donc des points dans un espace.
4. *Prédire par ressemblance* : les plus proches voisins, la distance, et la première frontière de décision.
5. *Un modèle qui s'entraîne* : la droite, la fonction d'erreur, la descente de gradient.
6. *Classer* : la régression logistique, la marge des SVM, Bayes, le filtre anti-pourriel et les réseaux bayésiens.
7. *Poser des questions : les arbres de décision* : un modèle qui cherche au lieu de descendre un gradient, et qui peut expliquer ses décisions.
8. *Généraliser* : le jeu de test, ce qu'un modèle peut dessiner, le compromis biais-variance, la régularisation.
9. *Bien évaluer un modèle* : les fuites, la validation croisée, les métriques, la distribution, la causalité.
10. *Trois façons d'apprendre* : supervisé, non supervisé, par renforcement.

Pour situer ce module dans l'ensemble du cours : l'apprentissage automatique n'est qu'une partie

d'un domaine plus vaste, celui de l'intelligence artificielle, que le cours parcourt module par module.



La carte de l'IA : le Module 2 porte sur l'apprentissage automatique classique, c'est-à-dire l'ensemble « Apprentissage automatique » et, en particulier, les méthodes d'AA diverses.

Objectifs

Au terme de ce module, vous devriez être en mesure de :

- distinguer clairement la programmation traditionnelle de l'apprentissage automatique, et situer celui-ci dans le paysage de l'IA ;
- expliquer le fil conducteur *données* → *modèle* → *erreur* → *minimisation* → *généralisation*, et le reconnaître dans n'importe quel algorithme ;
- décrire de l'intérieur les modèles classiques rencontrés (le modèle bête, les plus proches voisins, la régression linéaire et logistique, les machines à vecteurs de support, Bayes naïf et les réseaux bayésiens, l'arbre de décision et la forêt aléatoire, k-means) et dire ce qui les distingue ;
- expliquer comment un modèle s'entraîne (fonction d'erreur, descente de gradient) et ce qu'est un hyperparamètre ;
- définir le sur-apprentissage (*overfitting*) et le sous-apprentissage, et les relier au compromis biais-variance, à la capacité d'un modèle (linéaire ou non) et à la régularisation ;
- évaluer correctement un modèle : jeu de test, fuites de données, validation croisée, matrice de confusion, précision et rappel, et la question de la distribution ;
- distinguer une corrélation d'une cause, et dire pourquoi un modèle prédictif ne suffit pas pour décider d'une intervention ;

- distinguer les trois grandes façons d'apprendre (supervisé, non supervisé, par renforcement) par la nature du signal dont le modèle apprend ;
- expliquer pourquoi l'explicabilité d'un modèle compte, et quels modèles l'offrent.

Durée

Quatre semaines, soit environ 36 heures.

Évaluation

Un travail noté (20 % de la note finale) où vous construirez, pas à pas, un filtre anti-pourriel par classification bayésienne naïve, avec des questions d'interprétation sur le fonctionnement de l'algorithme.

Le problème

Quand vous regardez votre téléphone, il se déverrouille. Un courriel arrive et il est classé automatiquement dans les indésirables. Sur une chaîne de montage, une caméra repère, parmi des milliers de téléviseurs presque identiques, celui dont l'écran présente un défaut à peine visible. Une application vous suggère un film qui correspond à ce que vous aviez envie de voir ce soir.

Ces tâches font partie du quotidien. Elles ont cependant un point commun : **personne ne sait écrire, ligne par ligne, les règles qui permettraient de les accomplir.** Il est très difficile de décrire, par une suite d'instructions précises, ce qui distingue votre visage de tous les autres, ou ce qui fait qu'un courriel ressemble à un pourriel. On reconnaît ces choses en un instant, mais on ne sait pas les formuler.

C'est la limite à laquelle s'est heurtée l'IA classique du Module 1 : ce savoir est trop vaste et trop tacite pour tenir dans une liste de règles. L'apprentissage automatique adopte une autre stratégie. Au lieu de dicter les règles à la machine, on la laisse les **découvrir**.

Pourquoi on ne peut pas simplement le programmer

Pour comprendre ce qui change, il faut rappeler ce qu'est un programme informatique classique, comme celui qui fait fonctionner un tableur, un site de réservation ou une calculatrice. C'est une **suite d'instructions explicites**, écrites une à une par un programmeur, qui indiquent à l'ordinateur quoi faire, étape par étape : *si* telle condition, *alors* telle action. Quand une tâche peut être décrite par des règles claires, cette approche est très efficace.

Les exemples du début, cependant, ne se réduisent pas à des règles claires. Supposons qu'on veuille écrire une recette qui reconnaît un chat sur une photo. La règle « un chat a deux oreilles pointues » ne s'applique pas quand le chat est de dos, couché ou à demi caché derrière un meuble. La règle « il a le poil gris » ne s'applique pas à un chat roux ou noir, ni à un chat tigré sur un canapé tigré. Chaque règle entraîne de nombreuses exceptions, et la liste n'a pas de fin.

Ce phénomène s'appelle le **paradoxe de Moravec**. Les tâches que nous trouvons difficiles (jouer aux échecs, extraire une racine carrée) sont les plus faciles à programmer, parce qu'elles reposent sur des règles explicites. À l'inverse, ce qu'un enfant de trois ans fait sans effort, comme reconnaître un visage, attraper une balle ou comprendre une phrase, se laisse très difficilement mettre en règles, parce que cette compétence est perceptive et largement inconsciente. Comme nous ne savons pas comment nous faisons, nous ne pouvons pas l'écrire.



Traduction :
- « Quand un usager prend une photo, l'app devrait vérifier s'il est dans un parc national… »
- « Facile : un simple appel cartographique. Donne-moi quelques heures. »
- « … et vérifier si la photo est celle d'un oiseau. »
- « Là, j'ai besoin d'une équipe de recherche et de cinq ans. »

En informatique, la frontière entre le facile et le presque impossible n'est pas là où l'intuition la place.

Cette bande dessinée très connue a plus de dix ans, et son exemple a vieilli : identifier un oiseau dans une photo est devenu facile, justement grâce à l'apprentissage automatique. Son idée principale reste cependant exacte : certaines tâches d'apparence simple sont très difficiles pour un programme classique.

Changer de stratégie : apprendre à partir d'exemples

Comme nous ne savons pas énoncer les règles, on peut aborder le problème autrement. Au lieu de dicter les règles à la machine, on lui **donne des exemples**, c'est-à-dire des cas où la bonne réponse est déjà connue, et on la laisse trouver elle-même la régularité qui les relie.

Cette idée est proche de la façon dont un enfant apprend ce qu'est un chat. Il ne mémorise pas une définition. Il voit des dizaines de chats, jusqu'à ce qu'il sache les reconnaître sans pouvoir expliquer comment. On ne lui a jamais donné la règle ; il l'a extraite des exemples.

C'est le principe de l'**apprentissage automatique** (*machine learning*) : on fournit à un programme un grand nombre d'exemples, ainsi qu'une procédure qui lui permet d'ajuster son comportement jusqu'à reproduire les bonnes réponses. On espère ensuite qu'il répondra bien sur des cas qu'il n'a jamais vus. C'est le changement annoncé à la fin du Module 1 : au lieu de chercher une solution parmi des règles posées d'avance, le programme apprend à en construire une à partir des données.

Pour comprendre comment cela fonctionne concrètement, le plus simple est de partir d'un exemple modeste, qu'on pourra suivre du début à la fin et examiner sous plusieurs angles.

Notre fil rouge : des maisons à vendre



Combien vaut cette maison, et se vendra-t-elle vite ? Ce module montre comment une machine peut apprendre à répondre à ces deux questions.

Photo : Kindel Media, Pexels.

Tout au long de ce module, nous suivrons un seul exemple, volontairement simple pour qu'on puisse en comprendre tous les détails : **un registre de ventes immobilières**. Nous poserons plus d'une question à ce même jeu de données (*dataset*).

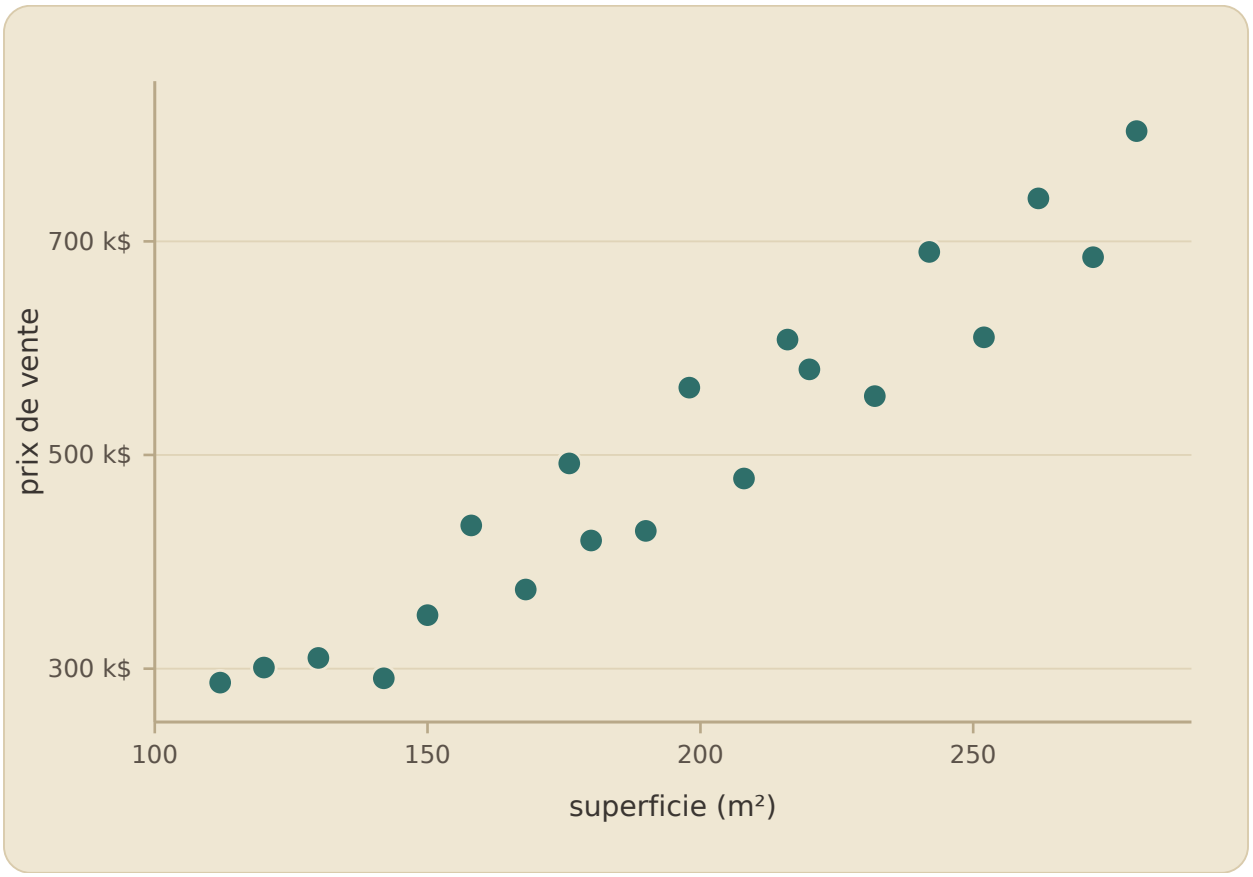
Supposons qu'on dispose d'une liste de maisons récemment vendues, avec pour chacune quelques renseignements (sa superficie, son année de construction, son nombre de chambres) et surtout son **prix de vente** :

Superficie (m²)	Année	Chambres	Prix
180	1995	4	420 000 $
150	1980	3	350 000 $

Superficie (m²)	Année	Chambres	Prix
220	2010	5	580 000 $
130	1972	3	310 000 $
…	…	…	…

La première question est la plus naturelle : **combien vaut une maison ?** Elle s'énonce simplement. Une nouvelle maison se présente, dont on connaît la superficie, l'année et le nombre de chambres, mais pas le prix, et il faut prédire ce prix.

Il y a clairement une régularité à exploiter : une grande maison récente vaut généralement plus cher qu'une petite maison ancienne. Cependant, « généralement » n'est pas une règle. C'est une tendance, qui comporte de nombreuses exceptions.



Chaque maison est un point. Le prix monte avec la superficie, mais pas parfaitement.

Si on ne garde que deux colonnes (la superficie et le prix), on voit déjà cette tendance : les points montent vers la droite, sans être parfaitement alignés. C'est ce genre de savoir approximatif que nous voulons faire émerger des exemples.

Une seconde question, d'une tout autre nature

Un agent immobilier se pose au moins deux questions sur une maison. La première, que nous venons de voir, est **combien vaut-elle ?** La seconde est tout aussi pratique : **va-t-elle partir vite ?** Les registres de ventes contiennent aussi les informations nécessaires, dans deux colonnes supplémentaires. La première donne la réponse. La seconde donne un renseignement qui ne nous avait pas servi jusqu'ici, mais qui va jouer un rôle important : la **distance du centre-ville** de la maison.

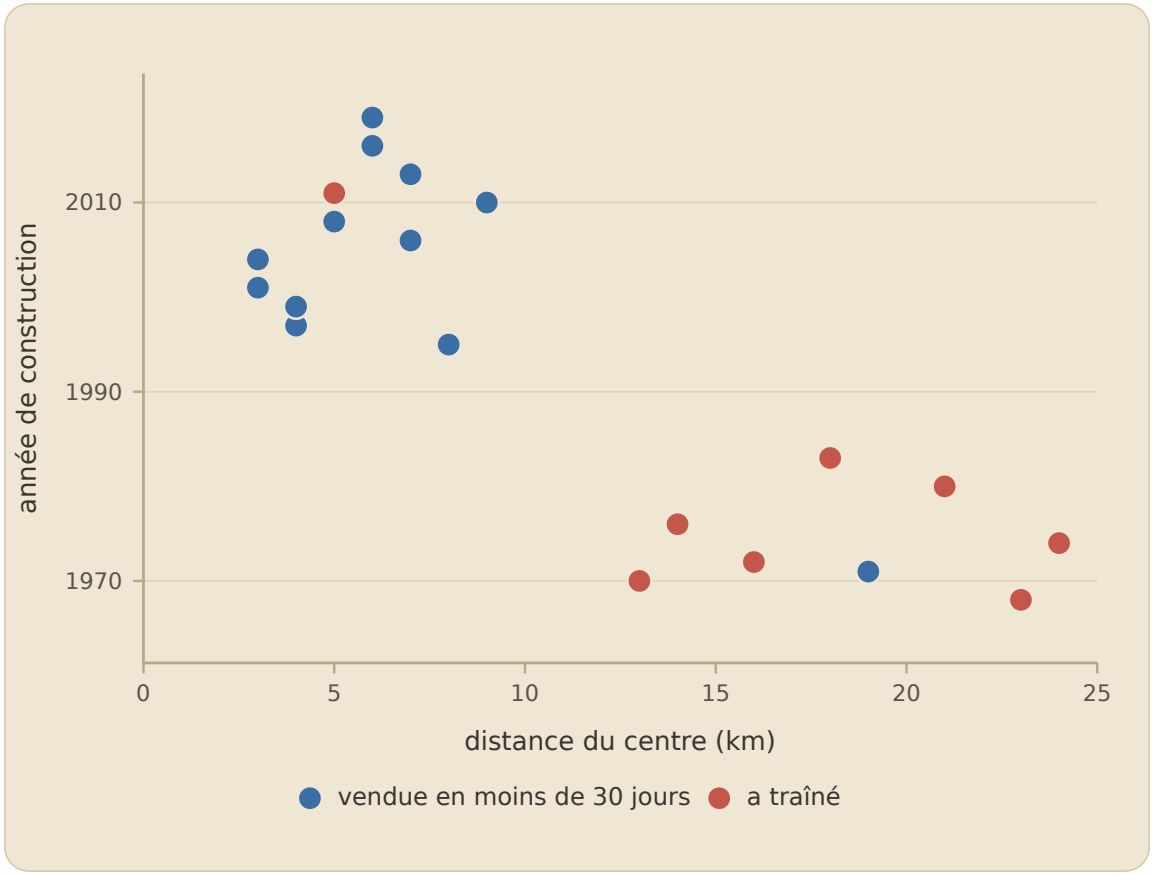
Superficie (m^2)	Année	Chambres	Distance du centre (km)	Prix	Vendue en moins de 30 jours ?
180	1995	4	8	420 000 $	oui
150	1980	3	21	350 000 $	non
220	2010	5	9	580 000 $	oui
130	1972	3	16	310 000 $	non
…	…	…	…	…	…

Les deux questions portent sur les **mêmes maisons**, tirées du **même registre**. Cependant, les réponses attendues sont de nature différente. Dans le premier cas, la réponse est un **nombre** (420 000 $, 385 200 $, n'importe quelle valeur sur une échelle continue). Dans le second, c'est un **choix entre deux réponses possibles**, oui ou non. On ne peut pas faire la « moyenne » de *oui* et de *non*.

Cette différence est importante, parce qu'elle change le sens du mot **se tromper**. Prédire 405 000 $ pour une maison vendue 420 000 $ est une erreur, mais une erreur faible, dont on connaît la taille exacte : 15 000 $. Répondre *oui* pour une maison qui s'est vendue lentement est simplement une erreur. Il n'y a pas de « presque oui », pas de demi-erreur, et aucune distance entre les deux réponses possibles. Dans le premier cas, on mesure un écart ; dans le second, la réponse est juste ou fausse. Nous verrons que cette différence a des conséquences sur tout le reste : la manière de prédire bêtement, la manière de mesurer l'erreur et la forme du modèle.

Pour cette seconde question, le **prix devient un renseignement comme un autre**, une colonne parmi les autres, au même titre que l'année de construction ou la distance du centre. Ce qui était la réponse à trouver dans le premier cas devient une donnée de départ dans le second. La table reste la même ; c'est la **question qu'on lui pose** qui change.

On peut aussi visualiser ce changement, à condition de choisir les bons axes. On laisse de côté la superficie et le prix, et on place les maisons dans un autre plan, avec la **distance du centre** en abscisse et l'**année de construction** en ordonnée. On colore ensuite chaque point selon la réponse à la nouvelle question :

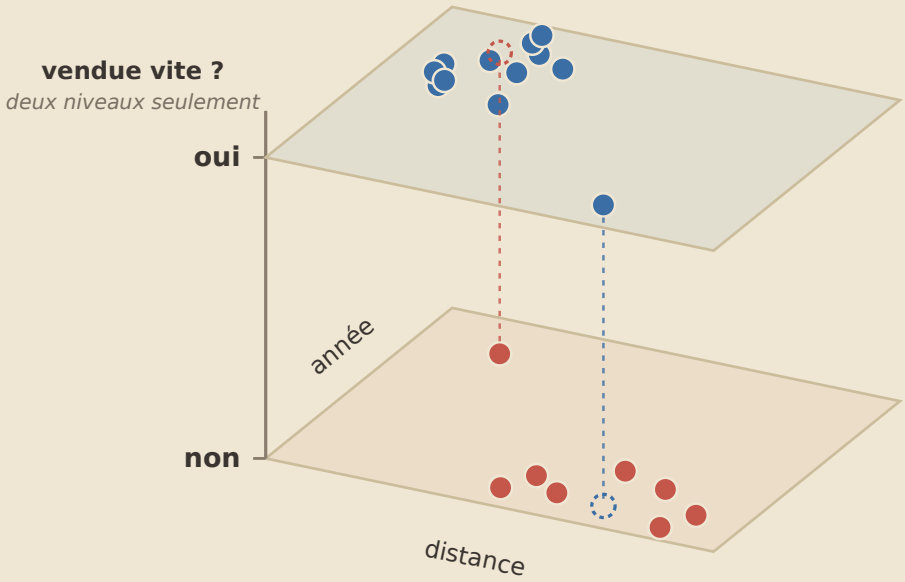


Les mêmes maisons, une autre question, et un autre plan. Ce n'est plus la hauteur du point qu'on cherche à deviner, mais sa couleur.

La différence avec le premier graphique est nette. Dans le premier, on cherchait à deviner la **hauteur** du point, c'est-à-dire sa position sur une échelle continue. Ici, les deux coordonnées sont données, et on cherche la **couleur**. Le motif est clair : les points forment **deux amas** situés dans des coins opposés, séparés par un large espace vide. Les maisons proches du centre et récentes se vendent vite. Les maisons éloignées et anciennes se vendent lentement. Seules deux exceptions se trouvent dans l'espace vide.

On a changé de plan parce que, dans le graphique précédent (la superficie et le prix), les deux couleurs auraient été mêlées et n'auraient rien montré. Le motif était bien présent dans le registre, mais pas dans ces renseignements-là. Ce point annonce une leçon qui reviendra tout au long du module : la difficulté d'un problème tient souvent moins à la méthode qu'on applique qu'au choix de **ce qu'on décide de regarder**.

La couleur sert à régler un problème de place. Nous avons maintenant **trois** renseignements à représenter sur une page plane (la distance, l'année et la réponse). Les deux premiers occupent les axes. Pour le troisième, il ne reste pas d'axe disponible, et on le représente donc autrement. Il s'agit seulement d'une commodité de dessin. On peut le vérifier en donnant à la réponse un troisième axe, dans une vue en perspective :



La couleur du nuage plat était l'ombre portée de ce troisième axe.
Les deux exceptions, vues d'en haut, retombent au milieu de l'autre couleur (points creux).

La réponse a son propre axe, qui ne comporte que deux barreaux, non et oui. Les maisons se trouvent donc sur l'un ou l'autre de deux plans.

Les maisons ne sont plus placées à n'importe quelle hauteur. Elles se trouvent sur l'un ou l'autre de **deux plans**. On passe d'un dessin à l'autre sans perdre d'information. Si on regarde ce relief d'en haut, à la verticale, on retrouve exactement le nuage coloré. La couleur correspondait donc à la projection du troisième axe. Les deux exceptions apparaissent aussi dans ce relief, qui explique pourquoi elles se remarquaient autant. La maison ancienne et éloignée qui s'est vendue vite se trouve sur le plan du haut, mais à la verticale de l'amas rouge. La maison récente et proche qui s'est vendue lentement se trouve sur le plan du bas, à la verticale de l'amas bleu. Le pointillé montre où chacune se place vue d'en haut, c'est-à-dire au milieu de l'autre couleur. Nous reprendrons cette figure au chapitre « Regarder les données », quand nous saurons quoi écrire sur ces deux barreaux.

Dans les **prochains chapitres**, nous suivrons surtout la première question, parce que le prix se prête mieux aux dessins et aux premières explications. La seconde question fera ensuite l'objet d'un chapitre entier, « Classer ». C'est d'ailleurs une question de ce type, *ce courriel est-il un pourriel ?*, que vous traiterez dans le travail noté. Nous verrons alors que presque tout ce qu'on aura appris pour l'une vaut aussi pour l'autre. **Plusieurs** des exemples du début de ce chapitre appartiennent à cette seconde famille. Reconnaître un chat ou repérer un pourriel sont des questions dont la réponse n'est pas un nombre, mais **une catégorie**.

Une catégorie peut avoir plus de deux valeurs, comme dans les questions suivantes. *Quel animal est sur cette photo : un chat, un chien, un cheval ? Quel chiffre est écrit sur cette enveloppe ?* (dix réponses possibles). *Dans quelle langue ce message est-il rédigé ?* Ce qui compte n'est pas le nombre de réponses, mais leur **nature** : une liste de possibilités distinctes, qu'on ne peut ni moyenner ni ranger sur une

échelle. Il n'y a rien entre *chat* et *chien*, pas plus qu'entre *oui* et *non*. La question posée à nos registres, avec ses deux réponses, est le cas le plus simple de cette famille.

Avant de construire un modèle élaboré, il est utile de se demander quelle est la prédiction la plus bête possible, celle en dessous de laquelle il serait absurde de descendre. C'est par cette question que commence la suite du module.

Le modèle le plus bête

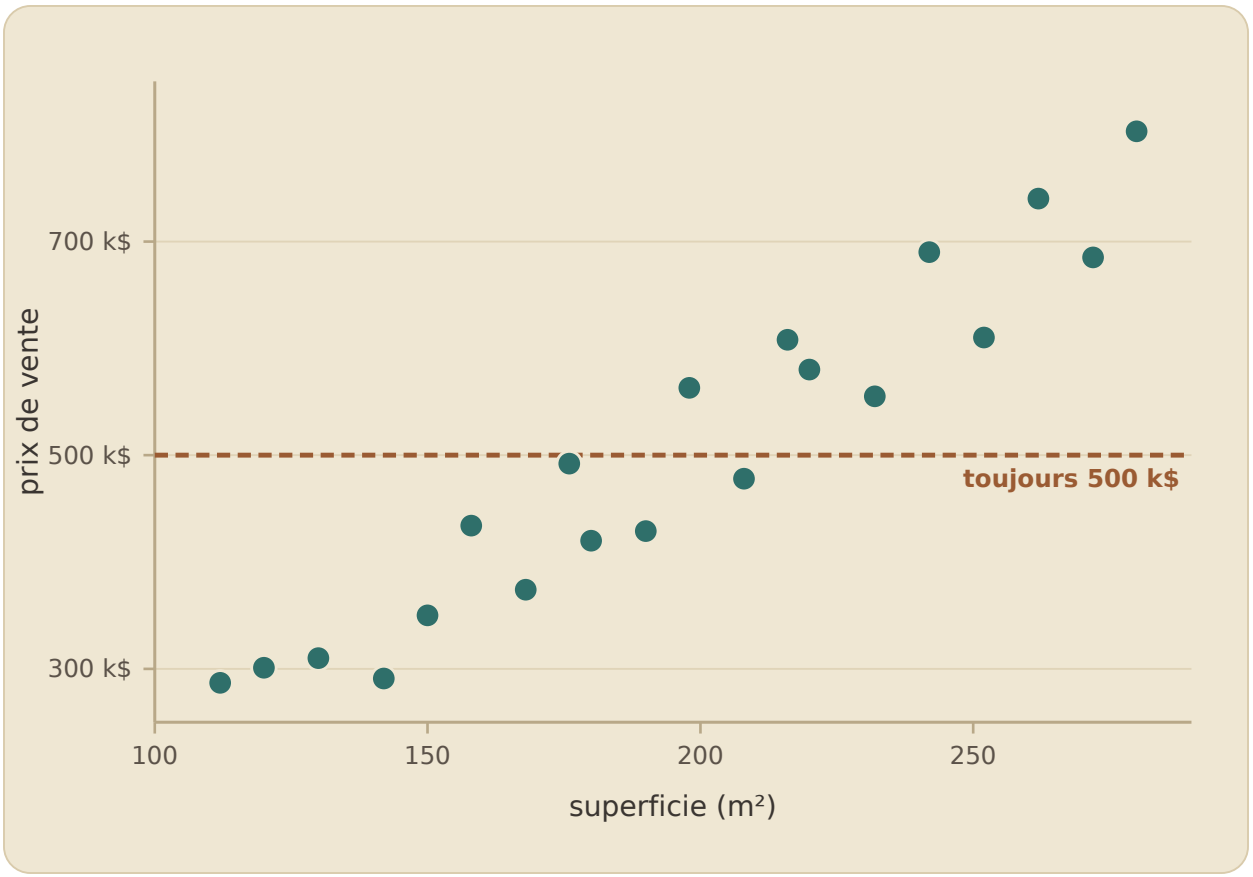
À la fin de la page « Le problème », nous avons posé une question qui peut sembler absurde : quelle est la prédiction la plus bête qu'on puisse imaginer ? Cette question mérite d'être prise au sérieux, parce que la pire réponse possible est instructive. Elle nous obligera aussi à préciser ce qu'est un *modèle*.

Toujours prédire la moyenne

Le pire « prédicteur » qu'on puisse concevoir est le suivant : pour n'importe quelle maison, on ignore toutes ses caractéristiques (sa superficie, son âge, son nombre de chambres) et on annonce toujours le **même** prix, le **prix moyen** de toutes les maisons de notre liste.

Dans notre exemple, ce prix moyen est d'environ **500 000 $**. La prédiction ne dépend donc plus de rien. Elle est de 500 000 $ pour un très petit studio, et de 500 000 $ aussi pour un grand manoir. C'est évidemment absurde.

Ce prédicteur est cependant parfaitement défini, il ne tombe jamais en panne et il donne toujours une réponse. Sur le nuage de points (*scatter plot*) de la page précédente, il correspond à une simple **ligne horizontale**, à la même hauteur (500 000 $) quelle que soit la superficie. Cette ligne traverse le nuage en son milieu, au-dessus des maisons bon marché et en dessous des plus chères.



Le modèle le plus bête : une droite plate à 500 000 $, qui ignore complètement la superficie.

La même bêtise, pour l'autre question

Le prédicteur le plus bête existe aussi pour la **seconde question** du chapitre « Le problème », *cette maison partira-t-elle vite ?* Il suit la même logique : il ignore la maison qu'on lui présente et répond toujours la même chose.

Il ne peut cependant pas répondre la moyenne, parce qu'on ne peut pas faire la moyenne de « oui » et de « non ». L'équivalent consiste à donner **la réponse la plus fréquente**, celle qui revient le plus souvent dans nos registres. Si 60 % des maisons déjà vendues ont trouvé preneur en moins de trente jours, ce prédicteur répondra toujours « oui », aussi bien pour une maison neuve proche du centre que pour une vieille maison des années 1970 située loin en banlieue.

Les deux questions sont de nature très différente, mais les deux prédicteurs ont la **même structure** : une entrée qu'on ignore, une sortie constante et une réponse tirée uniquement des données. Nous retrouverons souvent cette ressemblance entre les deux questions.

Qu'est-ce qu'un modèle, au juste ?

Nous venons d'appeler ce prédicteur un « modèle ». Il faut préciser le sens de ce mot, qui sera central dans tout le module.

> Un **modèle**, c'est une recette qui transforme une description (l'entrée) en une prédiction (la sortie).

Notre prédicteur bête correspond à cette définition : on lui donne une maison en entrée, et il renvoie un prix en sortie. Le fait qu'il ignore cette entrée ne l'empêche pas d'être un modèle. C'est seulement un très mauvais modèle.

Ce modèle est composé d'**un seul nombre**, le prix moyen (500 000 $). Ce nombre représente ce que le modèle a « retenu » des données ; on l'appelle son **paramètre**. Le calcul de ce nombre (la moyenne des prix observés) est déjà une forme simple d'*apprentissage*, puisque le modèle a tiré sa seule connaissance des exemples qu'on lui a fournis.

Ce nombre n'est donc pas arbitraire. On aurait pu annoncer 12 $, ou un milliard. Ce modèle aurait été tout aussi bête, puisqu'il ignorerait lui aussi la maison présentée, mais il se tromperait beaucoup plus. Le prix moyen a été **calculé** à partir des ventes passées, et il a un sens : parmi tous les nombres qu'on pourrait annoncer pour toutes les maisons à la fois, c'est celui qui se trompe le moins, en moyenne. La faiblesse du modèle vient de ce qu'il ignore, et non de ce qu'il retient. Le modèle jumeau fonctionne de la même façon. Son unique paramètre est la réponse majoritaire (« oui »), obtenue en comptant plutôt qu'en calculant une moyenne. Ce choix est lui aussi justifié, puisque c'est la réponse qui a le plus de chances d'être correcte quand on ne sait rien d'autre.

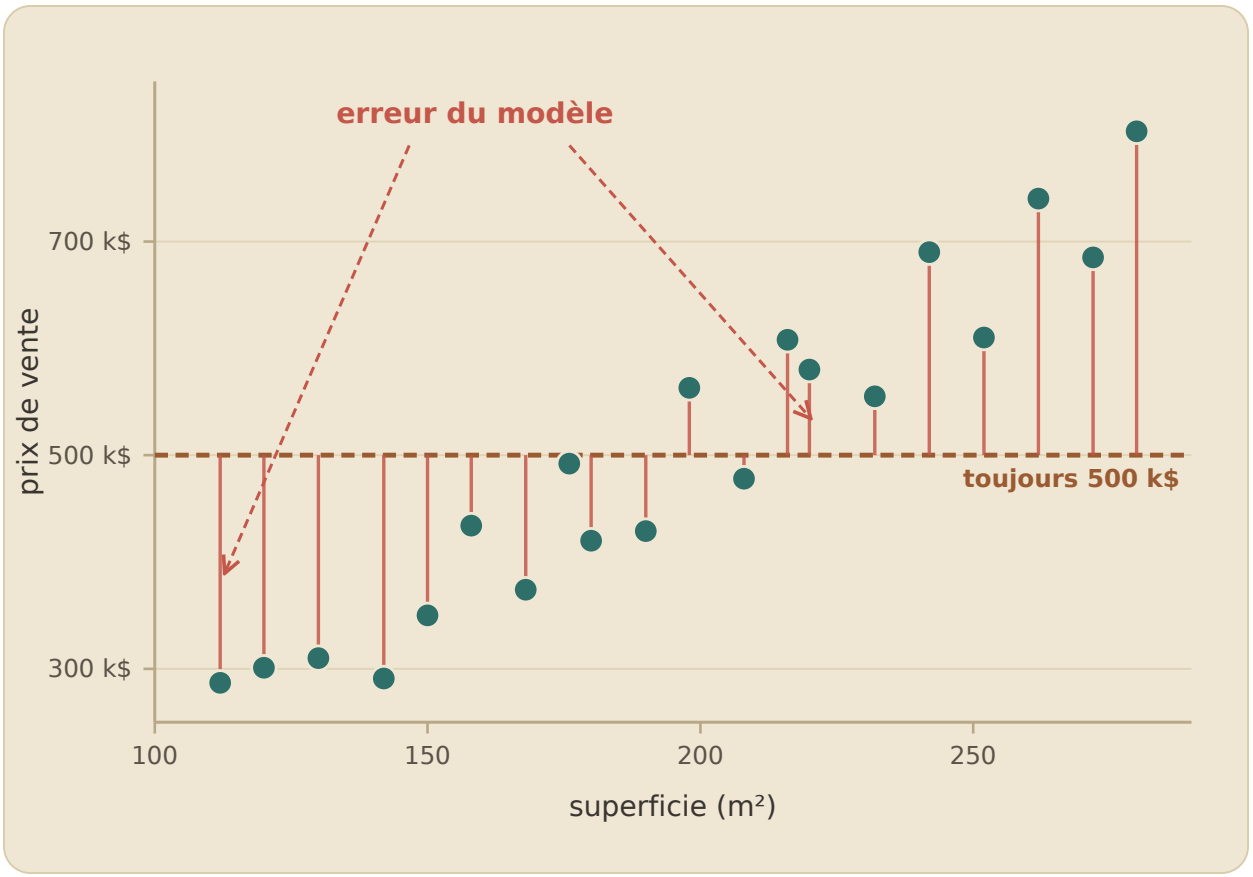
Le reste du module développe cette idée. Les modèles que nous construirons auront davantage de paramètres : un, puis deux, puis des milliers, puis des milliards. La principale difficulté consistera à trouver les bonnes valeurs pour ces paramètres, celles qui correspondent le mieux aux données. La structure restera cependant toujours la même : une entrée, une recette réglée par des paramètres, une sortie.

Pourquoi un modèle aussi bête est utile

Ce modèle est très mauvais, mais il est utile parce qu'il fournit un **étalon** (*baseline*), c'est-à-dire un point de comparaison pour juger tous les modèles suivants.

Les mots « bon » et « mauvais » n'ont pas de sens dans l'absolu. Pour savoir si un modèle a de la valeur, il faut une référence. La référence la plus élémentaire consiste à vérifier s'il fait mieux qu'un modèle qui ne regarde rien du tout. Un modèle, même sophistiqué, qui ne fait pas mieux que « toujours 500 000 $ » n'a rien appris d'utile.

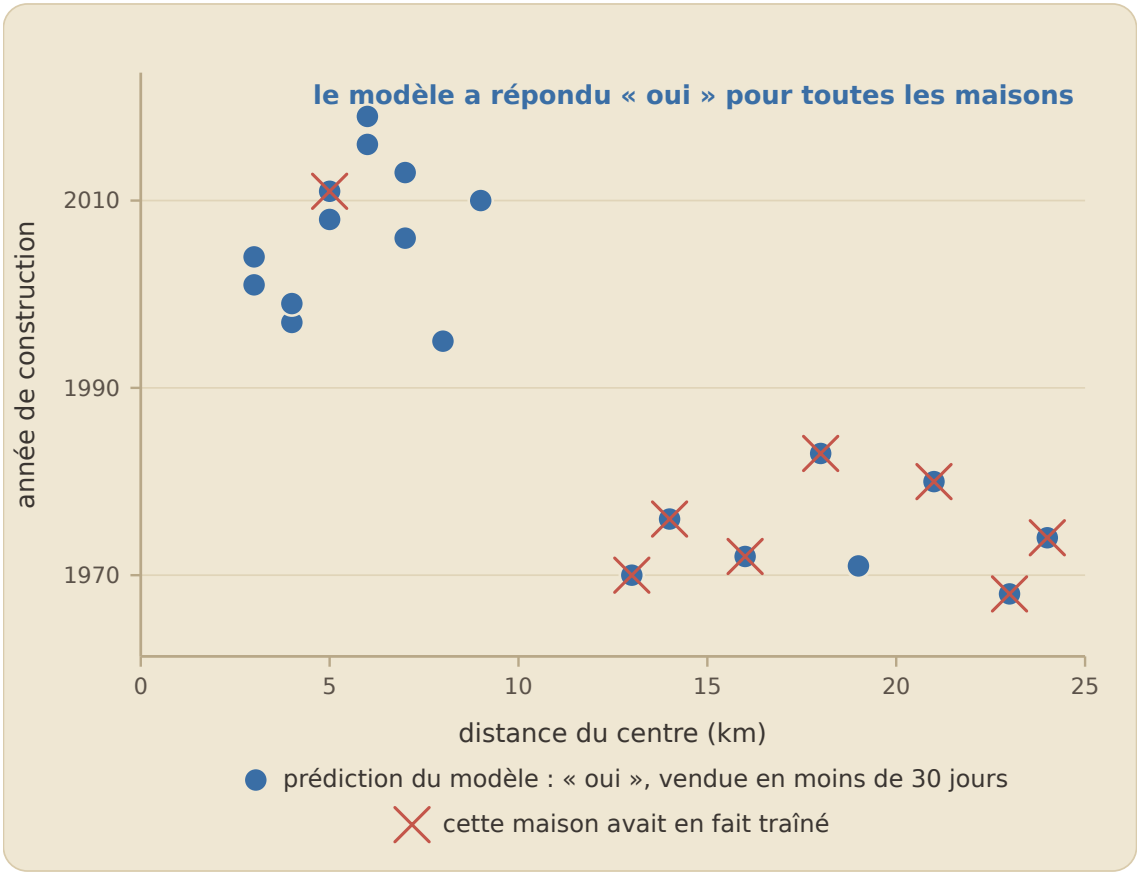
On peut faire cette comparaison concrètement, sans formule, en mesurant **de combien un modèle se trompe, en moyenne**. Pour le prédicteur bête, l'écart entre le prix annoncé (toujours 500 000 $) et le vrai prix dépasse 250 000 $ pour les maisons situées aux extrêmes. C'est cette « distance à la vérité » qu'un meilleur modèle cherchera à réduire. Nous lui donnerons au chapitre « Un modèle qui s'entraîne » un nom et une définition précise, la *fonction d'erreur* (*loss function*), mais l'idée suffit pour l'instant : un bon modèle est un modèle qui se trompe moins.



L'erreur du modèle, maison par maison : l'écart vertical entre le vrai prix et la prédiction.

En pratique, ce rôle d'étalon évite bien des erreurs d'interprétation. Un chiffre de performance ne signifie rien à lui seul. Devant un modèle, la première question à poser est toujours de savoir s'il fait vraiment mieux que de prédire bêtement la moyenne. La réponse est assez souvent non, et c'est l'étalon qui permet de le constater.

Pour la question en oui/non, le principe est le même, mais on compte autrement. Au lieu d'un écart en dollars, on regarde **quelle proportion des réponses le modèle obtient justes**. Le prédicteur jumeau, qui répond « oui » à tout, a donc raison dans 60 % des cas. C'est l'étalon à battre.



Le prédicteur jumeau colore toutes les maisons en « oui », et les × marquent celles où il se trompe. On ne mesure plus un écart en dollars, on compte les réponses justes.

Il s'agit du nuage coloré de la page précédente, sans modification : les **mêmes maisons**, aux mêmes places. Seule leur couleur a changé. Comme le modèle répond « oui » partout, il les colore toutes en bleu, et les × indiquent celles qui étaient rouges. Presque tous les × se trouvent dans l'amas du bas à droite, celui des maisons éloignées et anciennes. Le prédicteur bête se trompe sur presque tout cet amas, ce qui est normal, puisqu'il répond « oui » sans tenir compte de la distance ni de l'année.

On peut comparer cette figure avec le graphique des écarts de prix présenté plus haut. Les axes sont différents (ils ne peuvent pas être les mêmes, parce que les deux questions ne se lisent pas dans le même plan), mais la différence principale est ailleurs. Dans le graphique des prix, chaque maison portait un segment plus ou moins long, et l'erreur se **mesurait**. Ici, chaque réponse est simplement juste ou fausse, et l'erreur se **compte**.

Cet étalon peut être trompeur, et ce cas est instructif. Prenons une question beaucoup plus déséquilibrée, *ce courriel est-il un pourriel ?*, dans une boîte où 99 % des messages sont légitimes. Le prédicteur le plus bête, qui répond « ce n'est jamais un pourriel », obtient **99 % de bonnes réponses**, tout en étant inutile, puisqu'il ne détecte aucun pourriel. Un chiffre élevé peut donc cacher un modèle sans valeur. Nous y reviendrons dans « Bien évaluer un modèle », car bien mesurer la qualité d'un modèle est plus difficile qu'il n'y paraît.

Leur défaut, et ce qu'il révèle

Les deux modèles ont le **même** défaut, qui est évident. Le premier attribue le même prix à un studio et à un manoir. Le second prévoit une vente rapide aussi bien pour une maison neuve près du centre que pour une vieille maison à vingt kilomètres de là. Aucun des deux ne tient compte de la maison qu'on lui présente. Toute l'information utile (la superficie, l'âge, la distance) est disponible, et ils ne l'utilisent pas.

Les deux dernières figures montrent aussi un point important : **les erreurs ne sont pas dispersées au hasard**. Les segments les plus longs se trouvent aux extrémités du nuage, du côté des maisons très bon marché ou très chères, et les × se concentrent dans un seul coin du graphique, celui des maisons éloignées et anciennes. Or une erreur qui se concentre à un endroit est une erreur qu'on peut **prévoir**, donc corriger. Si les modèles se trompaient de façon totalement imprévisible, on ne pourrait rien en tirer. C'est parce que leurs erreurs forment un motif qu'il est possible de les améliorer.

C'est là que se trouve la marge de progression. Si la moyenne (ou la réponse majoritaire) est le meilleur point de départ quand on ne sait rien d'une maison, la seule façon de faire mieux est de **cesser de l'ignorer**, c'est-à-dire de tenir compte de ses caractéristiques. Une grande maison devrait faire monter la prédiction de prix, et une vieille maison devrait la faire baisser. Une maison éloignée du centre devrait faire pencher la réponse du second modèle vers le « non ». Un bon modèle est donc un modèle qui tient compte de l'entrée.

Il faut cependant d'abord préciser ce que signifie concrètement « tenir compte de l'entrée », c'est-à-dire ce qu'est une « donnée » pour une machine, et comment une maison, une image ou un courriel est transformé en quelque chose qu'un modèle peut manipuler. C'est l'objet de la page suivante.

Regarder les données

La page « Le modèle le plus bête » s'est terminée sur une exigence : pour faire mieux que la moyenne, un modèle doit tenir compte des caractéristiques d'une maison (sa superficie, son âge, son nombre de chambres). Il faut donc les lui présenter sous une forme qu'il peut manipuler.

Une machine ne « voit » ni une maison, ni une photo, ni un courriel. Elle ne manipule que des **nombres**. La question est donc de savoir comment transformer un objet du monde réel en nombres sans en perdre l'essentiel. Cette question, plus profonde qu'il n'y paraît, est l'objet de cette page, et elle est un préalable à tout ce qui suit.

Une maison, c'est une liste de nombres

Reprenons notre table de maisons. Chaque ligne décrit une maison par quelques **caractéristiques** (en anglais *features*), c'est-à-dire des grandeurs mesurables :

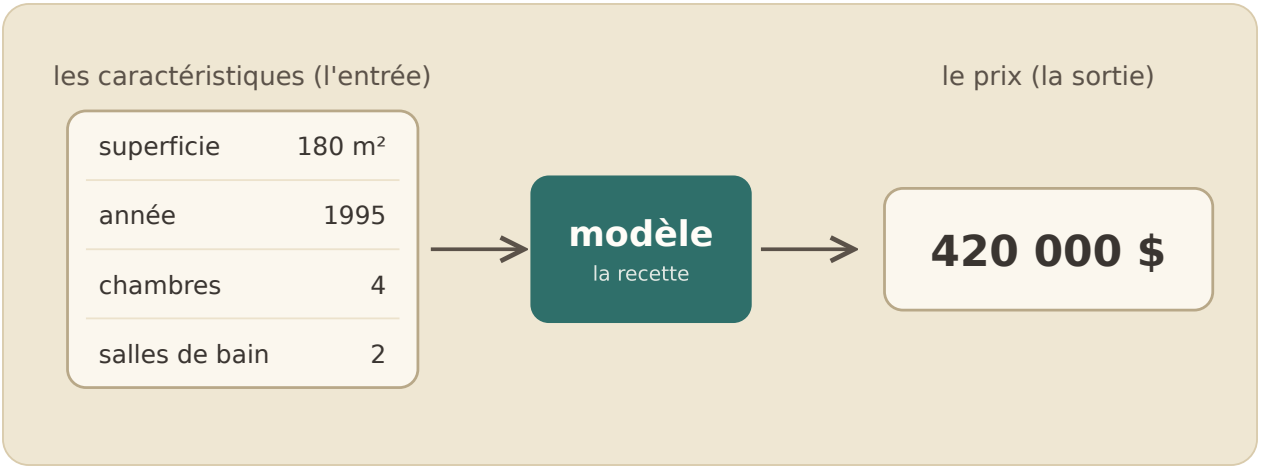
Superficie (m²)	Année	Chambres	Salles de bain	Prix
180	1995	4	2	420 000 $
150	1980	3	1	350 000 $
220	2010	5	3	580 000 $
130	1972	3	1	310 000 $

Pour une machine, décrire la première maison consiste simplement à aligner ses caractéristiques :

$$\text{maison} \rightarrow (180,\ 1995,\ 4,\ 2)$$

Une liste ordonnée de nombres comme celle-ci s'appelle un **vecteur**. L'objet peut être une maison, un client, un patient ou un courriel. Dès qu'on sait le décrire par quelques grandeurs, il devient un vecteur de nombres, et c'est ce vecteur qu'un modèle reçoit en entrée.

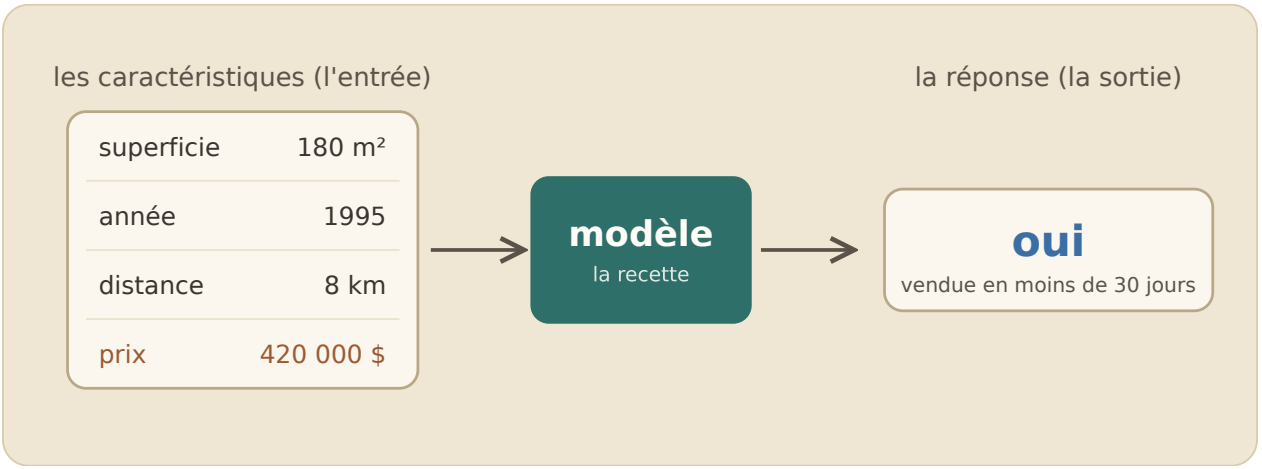
Une précision de vocabulaire servira dans toute la suite. Le **prix** ne fait pas partie de cette description, parce que c'est justement la valeur qu'on cherche à prédire. On l'appelle la **cible** (*target*). On a donc, d'un côté, les caractéristiques (l'entrée du modèle) et, de l'autre, la cible (sa sortie attendue).



Un modèle : les caractéristiques entrent, le prix sort.

Et quand la cible est une catégorie ?

Le prix est un nombre, donc il se prête sans difficulté à cette mise en forme. Notre seconde question était cependant différente : cette maison va-t-elle partir vite ? Le schéma est le même, avec deux différences. La sortie n'est plus un nombre, mais un **oui** ou un **non**. De plus, le prix, qui était la sortie, passe du côté de l'entrée et devient une caractéristique parmi les autres :



Le modèle de classification : les caractéristiques entrent, le prix compris ; une catégorie sort.

Or une machine ne manipule que des nombres. Il faut donc traduire le « oui » en nombre.

La façon la plus simple consiste à décider que **oui vaut 1 et non vaut 0**. Ce choix est arbitraire (on aurait pu prendre l'inverse, ou n'importe quel autre couple de valeurs), mais il a l'avantage de faire de la cible une grandeur comme une autre. Avec cette convention, une catégorie devient un nombre, et tout ce qui suit s'applique sans changement.

Le relief du chapitre « Le problème » ne change pas, sauf pour deux étiquettes : ses deux barreaux, *non* et *oui*, s'appellent maintenant 0 et 1. Ce changement est cependant important, parce que la réponse devient une **grandeur** comme les autres. Un modèle peut la calculer, la comparer et se tromper sur elle d'une quantité mesurable.

Il ne faut toutefois pas confondre cet axe avec les autres, car il n'est pas de même nature. La distance et l'année sont des **caractéristiques** : elles décrivent la maison et forment l'espace où elle se situe. La cible, elle, est ce qu'on **cherche**. Dans la suite, quand nous parlerons des *dimensions* d'un objet, il s'agira toujours de ses caractéristiques.

Nous pouvons maintenant nommer ces deux familles de problèmes, dont vous rencontrerez les noms partout :

- prédire un **nombre** (un prix, une température, une durée) s'appelle une **régression** ;
- prédire une **catégorie** (vendue vite ou non, pourriel ou courriel, chat ou chien, ou encore lequel des dix chiffres est écrit sur une enveloppe) s'appelle une **classification**.

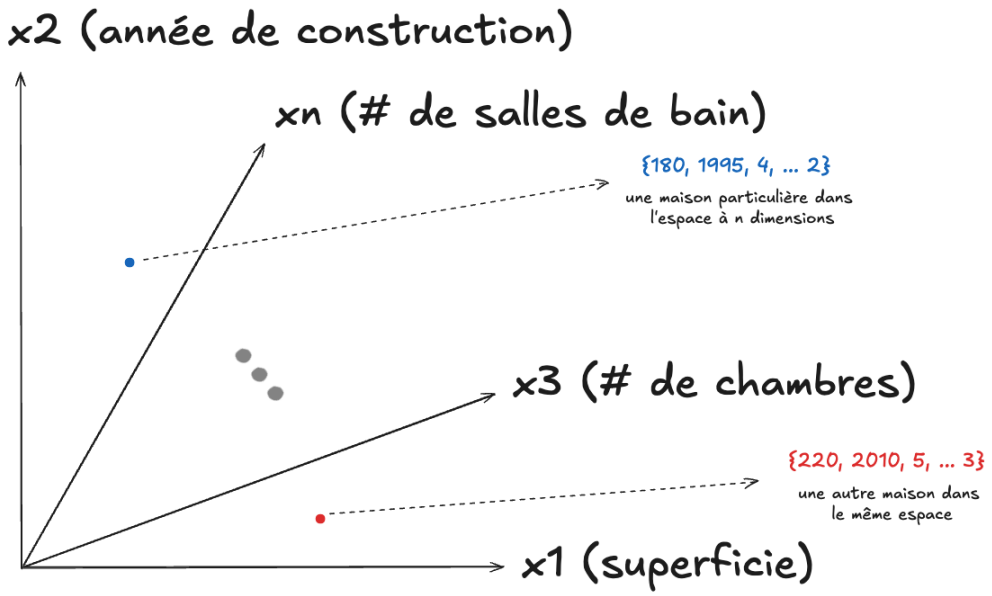
La seule chose qui distingue ces deux familles est la **nature de la cible**. Cette distinction est pourtant l'une des plus utiles du domaine, parce que presque tout problème d'apprentissage à partir d'exemples étiquetés (*labeled examples*) appartient à l'une ou à l'autre. Nous les retrouverons souvent, et nous verrons que certains algorithmes savent faire les deux, alors que d'autres se spécialisent.

Un vecteur, c'est un point dans un espace

Représenter une maison par un vecteur de nombres ne fait pas que ranger ses caractéristiques. Cela lui donne aussi une **place dans l'espace**.

Prenons deux caractéristiques, la superficie et le nombre de chambres. On peut placer chaque maison comme un **point** sur un graphe, avec la superficie à l'horizontale et le nombre de chambres à la verticale. Une maison correspond alors à un endroit du plan, de la même façon que, dans le nuage des pages précédentes, chaque maison était déjà un point. Un vecteur à deux composantes est donc une position dans un plan.

Rien n'oblige à s'arrêter à deux caractéristiques. Si on ajoute l'année de construction, la maison devient un point dans un espace à **trois** dimensions, comme une mouche immobile quelque part dans une pièce. Avec une quatrième caractéristique, elle devient un point dans un espace à quatre dimensions. La règle est toujours la même : **un objet décrit par n nombres est un point dans un espace à n dimensions.**



Chaque caractéristique devient un axe : une maison est un point dans un espace à autant de dimensions qu'elle a de caractéristiques.

Cette représentation géométrique est très utile. Deux maisons aux caractéristiques semblables sont deux points proches, et deux maisons très différentes sont deux points éloignés. La ressemblance entre objets devient donc une **distance** entre points. Le prochain chapitre, « Prédire par ressemblance », repose sur cette idée.

Quand il y a trop de dimensions pour les voir

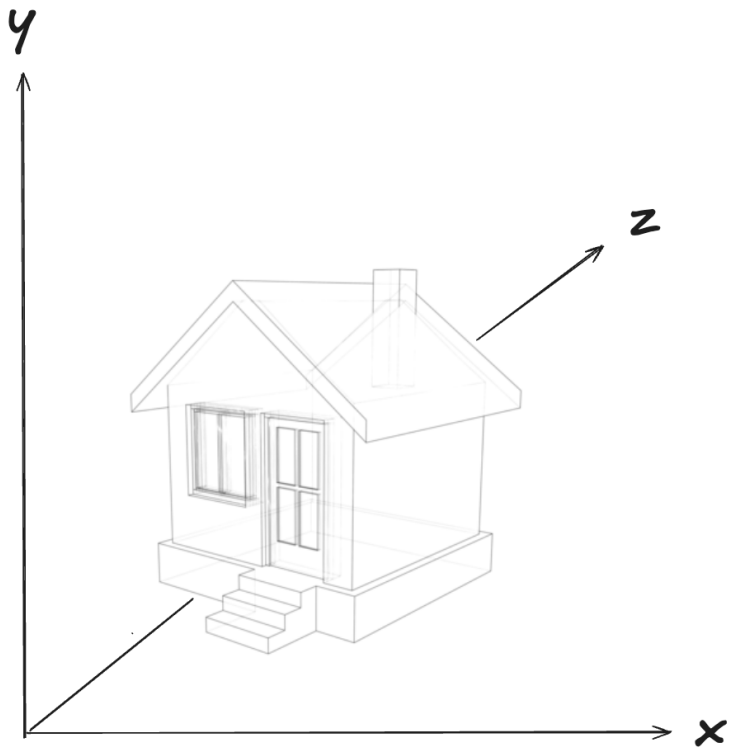
Nos maisons n'avaient que trois ou quatre caractéristiques, et on pouvait presque les imaginer comme des points dans une pièce. Beaucoup d'objets du monde réel se décrivent cependant par beaucoup plus de nombres.

Prenons une image. Pour une machine, une photo est une **grille de pixels**, et chaque pixel est un nombre (ou trois nombres, pour ses quantités de rouge, de vert et de bleu).



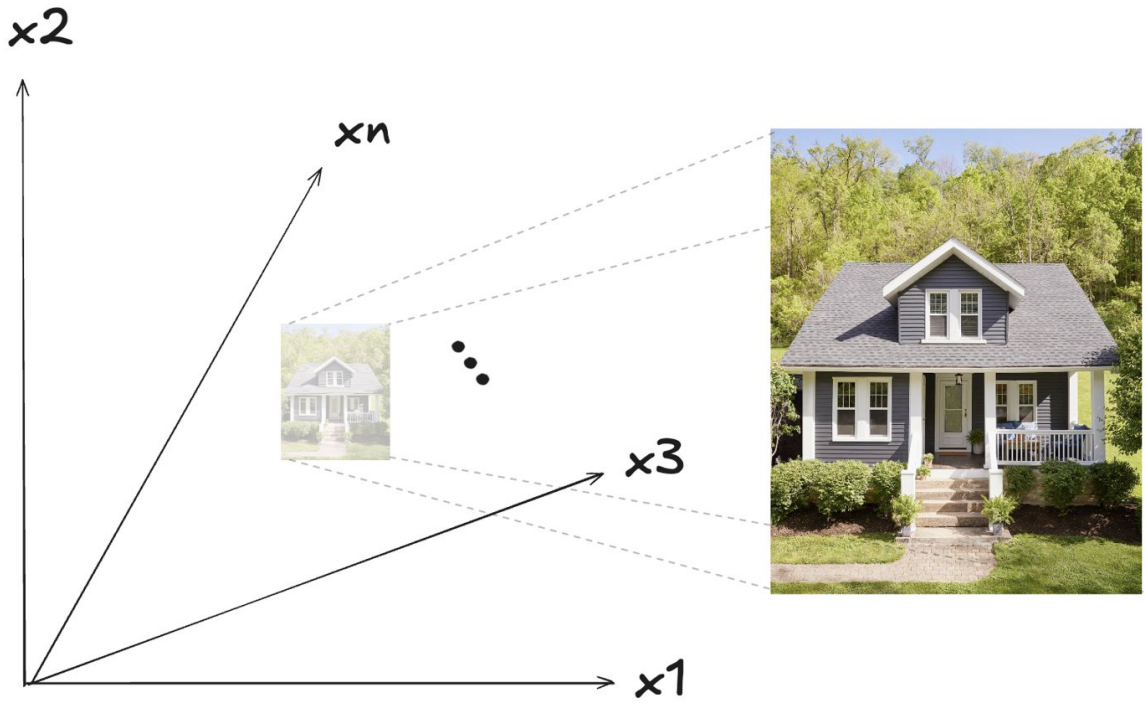
Une image, pour une machine : une grille de pixels, chacun un nombre.

On pourrait aussi la représenter autrement. Par exemple, s'il s'agissait d'une maison de jeu vidéo, on pourrait utiliser un modèle en trois dimensions, avec des axes x, y et z :



Autre représentation : un modèle 3D, repéré par des axes x, y, z.

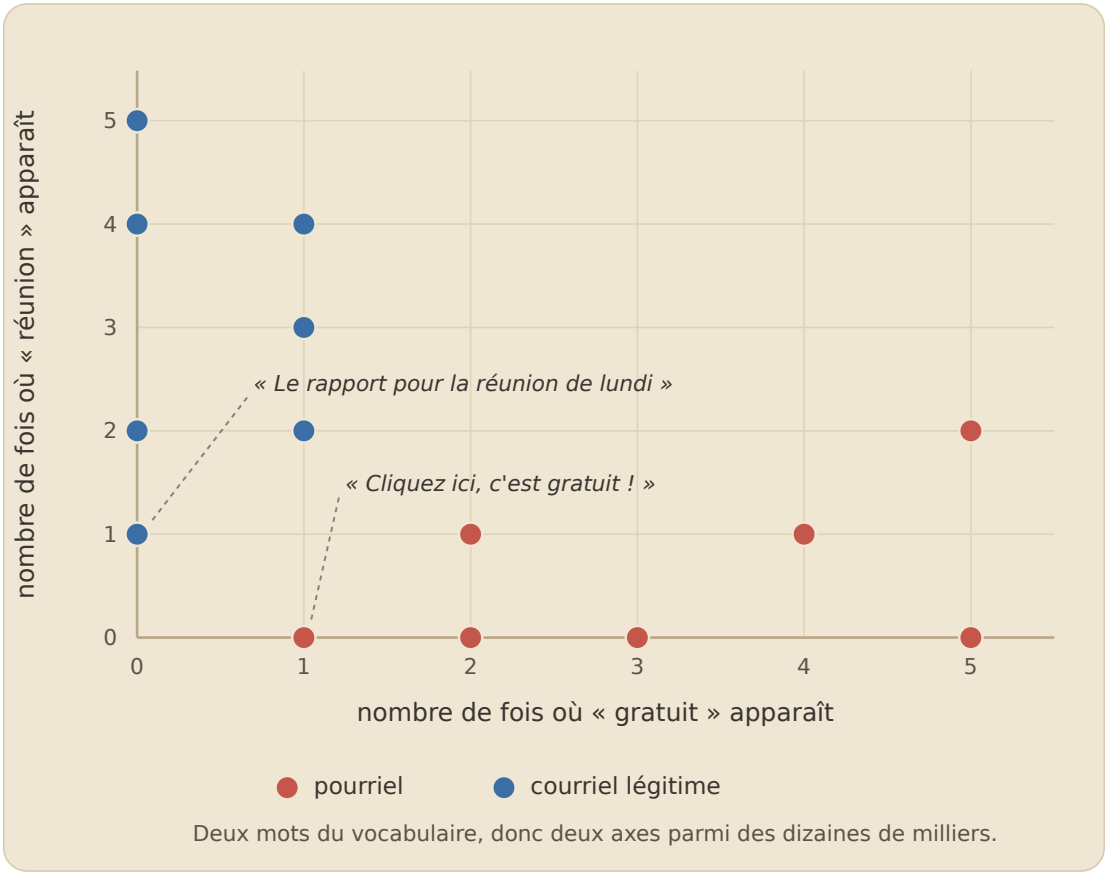
En apprentissage automatique, on procède autrement : on traite l'image **entière** comme un seul point, dans un espace où chaque pixel est une dimension. Une vignette de 100 × 100 pixels est ainsi un point dans un espace à 10 000 dimensions. Une photo ordinaire en compte des **millions**.



En haute dimension : l'image entière devient un seul point ; deux images semblables, deux points voisins.

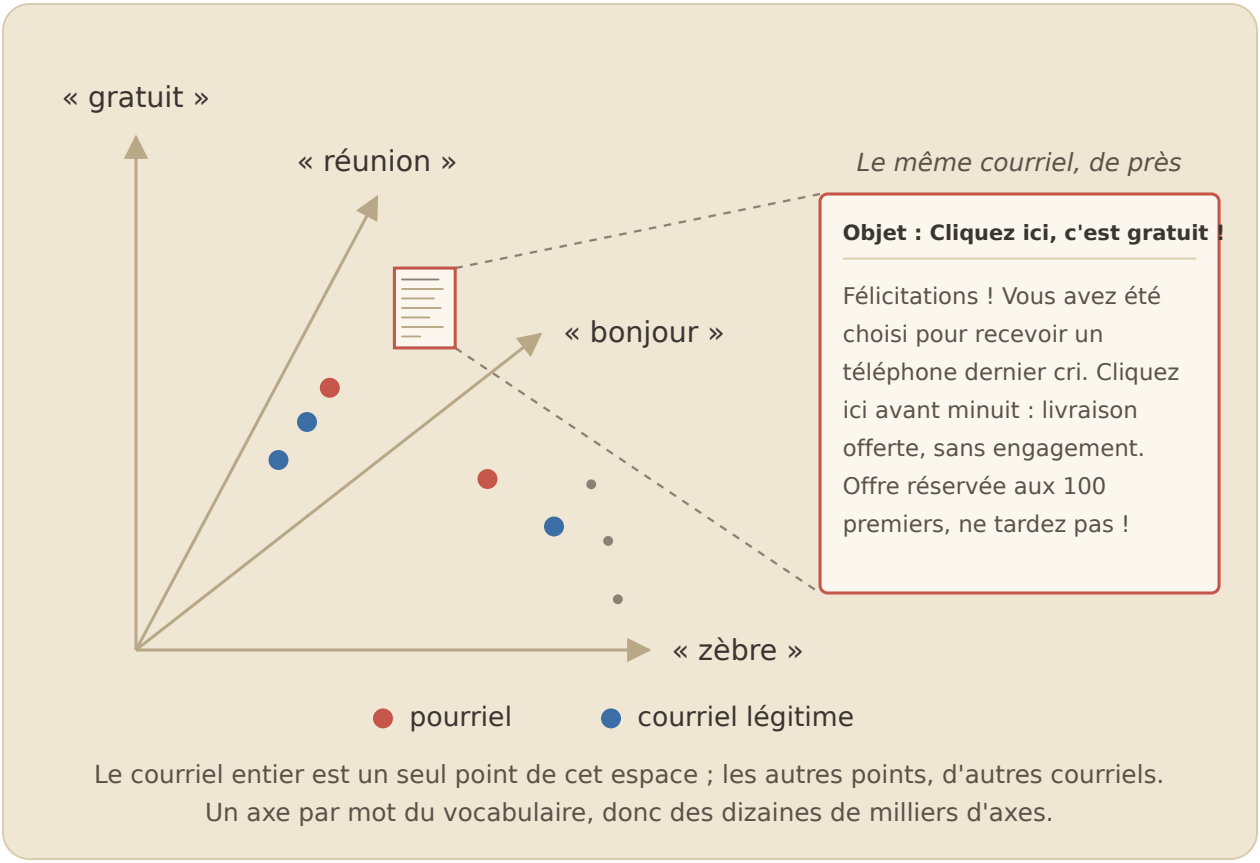
Il est impossible de se représenter un tel espace, puisque nous vivons dans un espace à trois dimensions. L'essentiel reste pourtant valable : **la distance continue d'avoir un sens.** Deux photos presque identiques sont deux points voisins, et deux images sans rapport sont deux points éloignés, comme pour nos maisons.

Le cas du texte est différent. Un courriel n'a ni superficie ni pixels, et rien ne semble s'y mesurer directement. On le décrit pourtant par des nombres, d'une façon qui paraît d'abord assez grossière. On dresse la liste de tous les mots qui peuvent y figurer (le *vocabulaire*) et, pour chacun, on compte combien de fois il apparaît dans le courriel. Chaque mot devient alors un axe. Prenons-en deux, *gratuit* et *réunion*, et plaçons quelques courriels dans leur plan :



Deux mots du vocabulaire, deux axes : chaque courriel devient un point, et les pourriels se rangent d'un côté, les courriels légitimes de l'autre.

Un courriel est donc un point dans un espace qui compte autant de dimensions que le vocabulaire compte de mots, soit des dizaines de milliers. Ce dessin n'en montre que deux. L'opération est la même que pour l'image et ses pixels :



Un axe par mot du vocabulaire, des dizaines de milliers d'axes : le courriel entier devient un seul point de cet espace, comme l'image en devenait un dans celui de ses pixels.

Ces axes ne mesurent rien de physique, ni une taille ni une couleur. Ils contiennent seulement un compte, et l'ordre des mots est perdu. L'idée reste cependant valable : deux courriels qui emploient les mêmes mots sont deux points voisins, et un pourriel ressemble à d'autres pourriels. C'est cette représentation que nous utiliserons, au chapitre « Classer », pour construire un filtre.

On aurait pu décrire les courriels de façon encore plus grossière, en notant seulement si chaque mot est présent ou non, par 1 ou 0, au lieu de compter ses occurrences. Un tel axe n'a que deux barreaux, comme le relief *non*/*oui* du premier chapitre, et dans notre plan tous les courriels se retrouveraient aux quatre coins d'un carré. Compter les mots ou noter leur simple présence, avec un nombre entier ou avec 0/1, est un choix de représentation, et il en existe beaucoup d'autres. Nous garderons les comptes, qui sont plus précis.

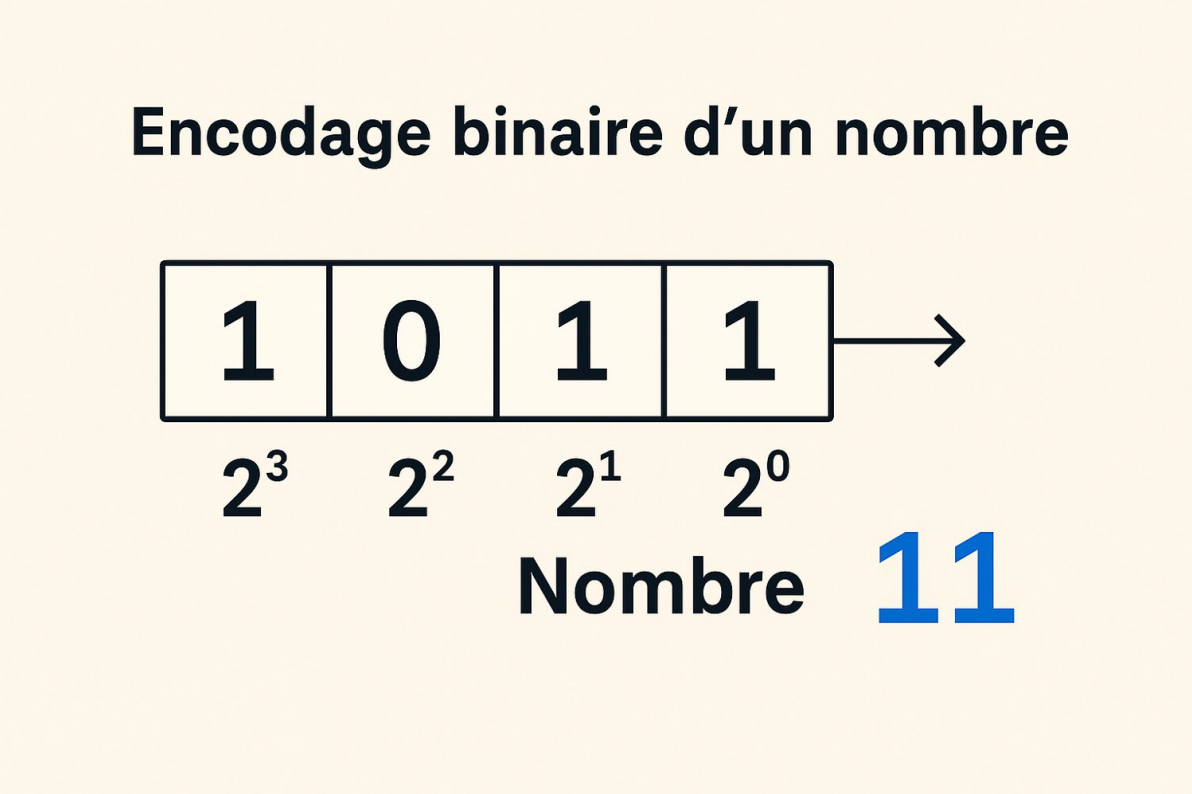
L'idée s'applique donc à des objets très différents. Qu'il s'agisse d'une maison, d'une image ou d'un courriel, dès qu'on sait décrire un objet par des nombres, il devient un point dans un espace, et la ressemblance entre objets se mesure par leur proximité. Le prochain chapitre utilise cette idée pour **prédire par ressemblance**.

Sous le capot : des vecteurs aux bits (optionnel)
Nous avons dit qu'une machine « ne manipule que des nombres ». Il reste à préciser ce qu'est physiquement un nombre pour un ordinateur. Les paragraphes qui suivent descendent du

vecteur jusqu'au signal électrique. Ils ne sont pas indispensables pour la suite du module, mais ils expliquent ce qui se passe à l'intérieur de la machine.

Niveau des bits

Au niveau le plus fondamental, l'ordinateur ne traite qu'un seul type de donnée, le **bit**. Le bit est à la fois un concept mathématique (un symbole dont la valeur ne peut être que `0` ou `1`, ou `vrai`/`faux` en logique) et une réalité physique, au niveau de l'implémentation : électrique (RAM, CPU, SSD), magnétique (disque dur) ou optique (CD). Les bits *représentent* les nombres au moyen de la convention de l'encodage binaire.



Niveau du processeur (le CPU)

Au niveau suivant se trouve l'ordinateur lui-même, dont le mécanisme central est le microprocesseur (CPU). Un CPU traite les bits sous leur forme physique. Il interprète des « paquets » (ou *mots*) de bits de taille fixe (souvent 32, 64 ou 128 bits) de deux manières très différentes :

1. en tant que *nombre* (ou plus généralement *valeur*) ;
2. en tant qu'*instruction*.

Le flot de bits que reçoit le CPU constitue un *programme*, que le CPU *exécute* dans l'ordre. Un programme dans un « langage machine » fictif pourrait être le suivant :

```
MOV 1000
ADD 0001
STR 2000
```

Les symboles `MOV`, `ADD` et `STR` sont des instructions, qui correspondent elles-mêmes à des nombres. Le CPU pourrait voir la séquence suivante :

```
1000 1000
1001 0001
```

```
1002 2000
```
si `MOV`, `ADD` et `STR` correspondaient par convention aux valeurs 1000, 1001 et 1002. Le programme pourrait signifier ceci :
```
- Prendre la valeur à l'adresse mémoire 1000 et la mettre dans un registre
- Ajouter 1 à cette valeur dans le registre
- Enregistrer le contenu du registre à l'adresse mémoire 2000
```
Le CPU distingue `1000` *instruction* de `1000` *valeur* grâce à des conventions établies à l'avance (par exemple, positions paires pour les instructions et impaires pour les valeurs ; la réalité est un peu plus complexe, mais le principe est celui-là). Pour réaliser une instruction, le CPU exécute un petit programme câblé directement dans ses circuits. C'est à cet endroit que la logique rejoint la matière.

Vous pouvez exécuter vous-même, pas à pas, une version interactive de ce petit programme : *Applet interactive : à utiliser en ligne, sur la page « Regarder les données » du site du cours.*

Niveau des langages de programmation

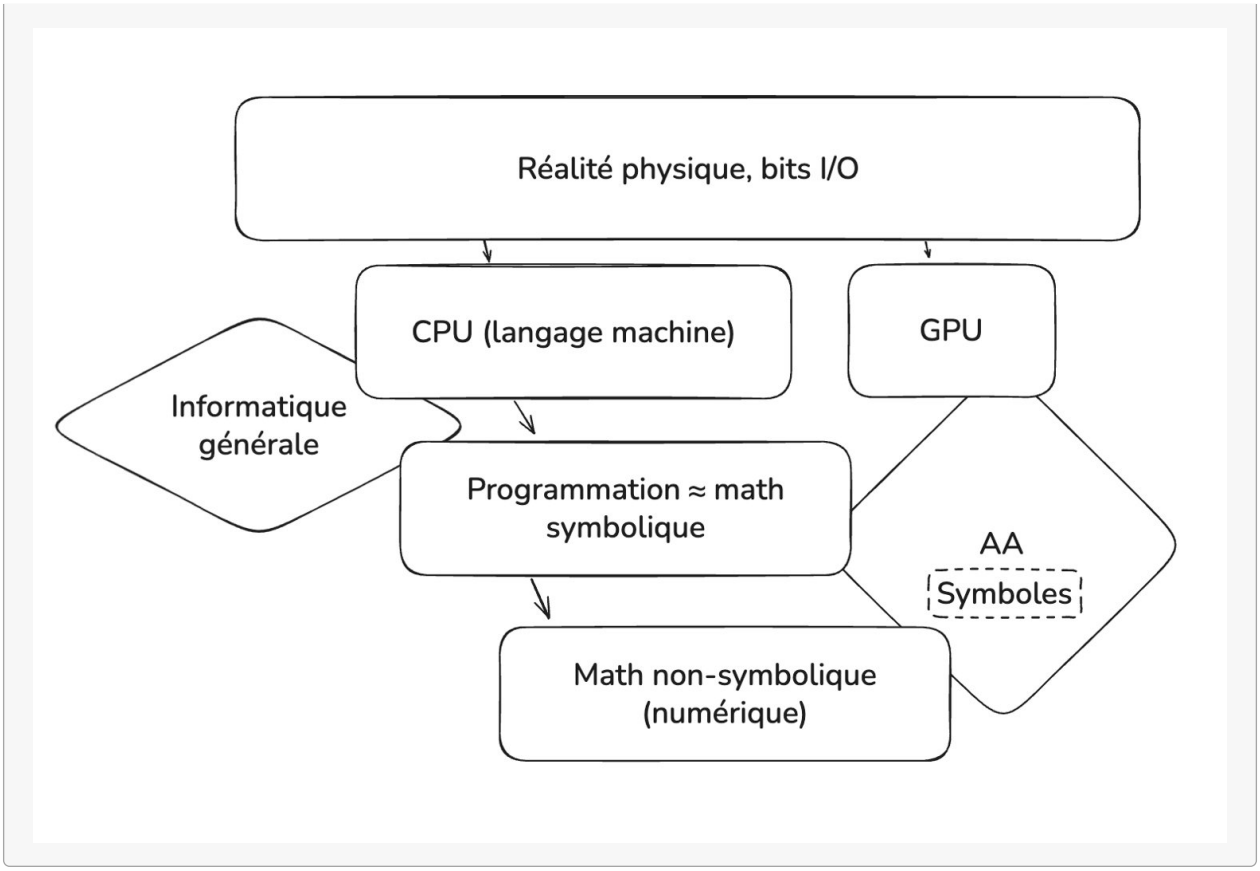
Le niveau suivant est implémenté dans le langage du niveau précédent. De la même façon qu'on peut écrire un jeu ou un système d'exploitation (*operating system*) en langage machine, on peut y écrire un autre langage. Ce langage est plus *abstrait*, plus éloigné de la réalité physique, et il permet d'exprimer des idées plus complexes de façon plus naturelle (C++, Python, JavaScript). On peut le voir comme un « ordinateur virtuel » implémenté au moyen d'un langage moins abstrait. À ce niveau apparaissent des représentations beaucoup plus riches :

- des nombres entiers ;
- des nombres réels (beaucoup plus complexes à représenter) ;
- des chaînes de caractères (*strings*) ;
- des listes de nombres, de mots, de listes… ;
- des images, des sons ;
- etc.

C'est à ce niveau que sont écrits les algorithmes d'apprentissage automatique, et que se trouvent les *vecteurs* dont parle cette page.

Retour vers les symboles

Ces niveaux permettent de mieux comprendre la distinction souvent faite entre l'IA classique, qui manipule des **symboles**, et l'apprentissage automatique, qui manipule des **valeurs numériques** et qu'on qualifie parfois de *sub-symbolique*. Dans les deux cas, les données sont en fin de compte des valeurs numériques (et même des bits physiques). La distinction garde cependant un sens clair, parce que les deux approches reposent sur deux types de mathématiques différents.


Réalité physique, bits I/O
CPU (langage machine)
GPU
Informatique générale
Programmation ≈ math symbolique
AA
Symboles
Math non-symbolique (numérique)

Prédire par ressemblance

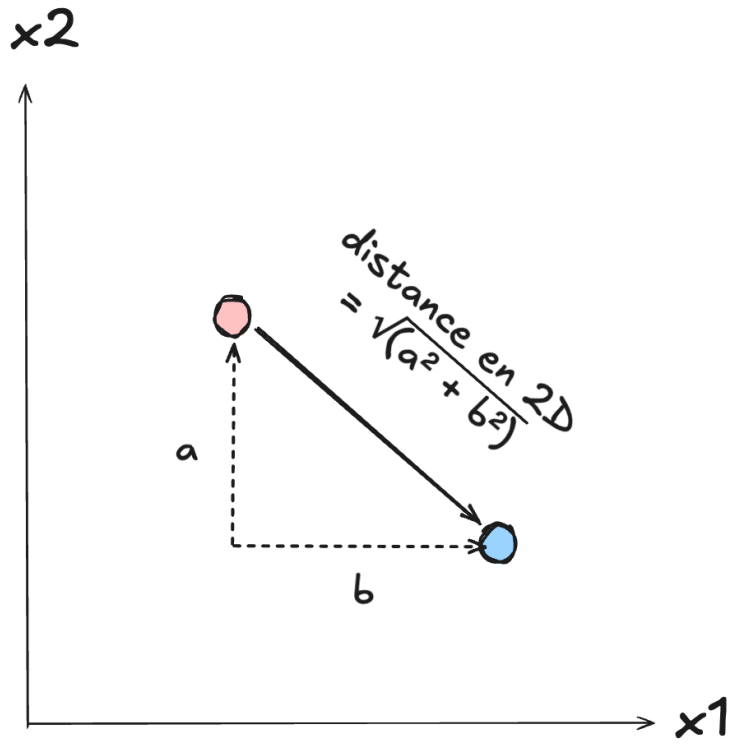
La page « Regarder les données » s'est terminée sur l'idée suivante : si décrire des objets par des nombres transforme leur ressemblance en une distance, il doit exister une façon très simple de prédire. Cette façon est sans doute l'idée la plus intuitive de l'apprentissage automatique : **pour deviner la réponse sur un nouveau cas, on regarde les cas connus qui lui ressemblent le plus, et on reprend leur réponse.**

Pour estimer le prix d'une maison qu'on n'a jamais vue, on cherche les maisons déjà vendues qui lui ressemblent le plus (même quartier, même taille, même âge), et on s'attend à un prix comparable. C'est ce que fait un agent immobilier quand il utilise des « comparables ». Il faut maintenant transformer cette intuition en une procédure précise. Tout repose sur la notion de ressemblance, qu'il faut d'abord rendre mesurable.

Mesurer la ressemblance : la distance

Pour deux objets décrits par des nombres, « se ressembler » a une traduction géométrique directe : être **proches** dans leur espace. La proximité entre deux points se mesure par la **distance**.

Pour deux points dans un plan, il s'agit de la distance ordinaire, c'est-à-dire la longueur du segment droit qui les relie, celle qu'on mesurerait avec une règle. (Les mathématiciens l'appellent la *distance euclidienne*, mais c'est la même notion que dans la vie courante.)



La distance entre deux points : la longueur du trait droit qui les relie.

Cette longueur se calcule avec le théorème de Pythagore. Pour deux points d'un plan, on prend l'écart entre eux sur le premier axe et l'écart sur le second, on élève chacun au carré, on additionne les deux carrés et on prend la racine carrée du résultat :

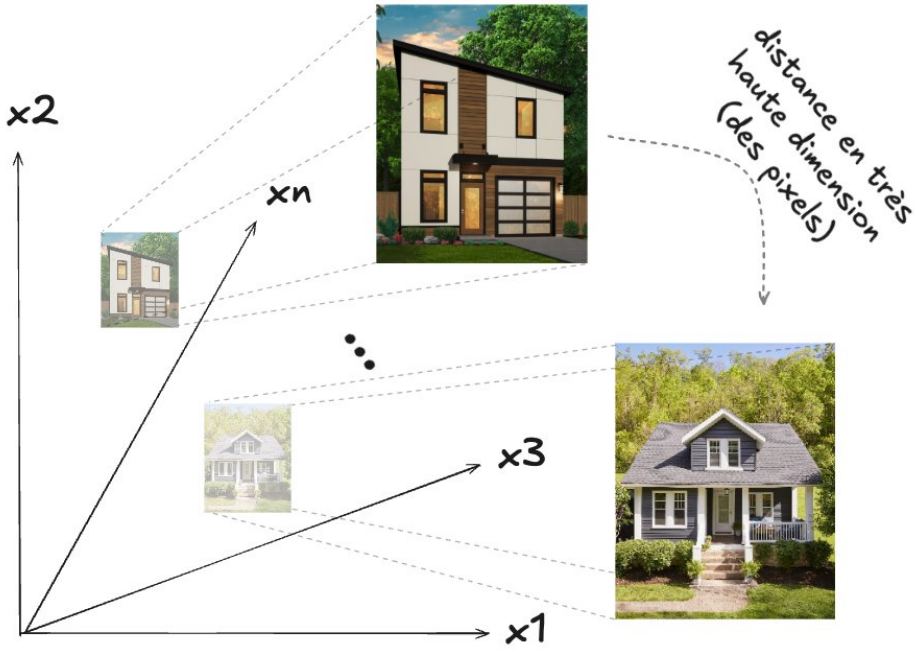
$$\text{distance} = \sqrt{(\text{écart sur l'axe 1})^2 + (\text{écart sur l'axe 2})^2}$$

Rien dans cette méthode ne dépend du nombre d'axes. Si nos maisons ont six caractéristiques, on calcule six écarts au lieu de deux, on les élève au carré, on les additionne et on prend la racine carrée du total. On compare les objets coordonnée par coordonnée et on obtient un seul nombre, petit s'ils se ressemblent, grand s'ils diffèrent. Comme on l'a vu au chapitre « Regarder les données », la même formule s'applique à une image, dont les millions de pixels forment autant de coordonnées. Pour deux photos, l'écart sur un axe est simplement la différence entre la valeur d'un même pixel dans l'une et dans l'autre. On note A_1 la valeur du premier pixel de la photo A, B_1 celle du premier pixel de la photo B, et ainsi de suite jusqu'au n-ième :

$$\text{distance}(A, B) = \sqrt{(A_1 - B_1)^2 + (A_2 - B_2)^2 + \cdots + (A_n - B_n)^2}$$

Deux photos identiques donnent une distance nulle, puisque chaque écart est nul. Deux photos qui ne diffèrent que par un pixel donnent un très petit nombre. Plus les pixels diffèrent, en nombre ou

en intensité, plus la distance augmente. La même formule vaut donc du plan à la photo, et n peut valoir deux ou plusieurs millions.



La même distance se calcule, quel que soit le nombre de dimensions.

Une nuance importante. Le fait que la distance se calcule sur des pixels ne signifie pas qu'elle mesure bien la ressemblance entre images. Sur des caractéristiques choisies par un humain (superficie, nombre de pièces…), la proximité a un sens clair. Sur des pixels bruts, elle en a beaucoup moins. Deux photos du même chat, dans deux poses différentes, peuvent être très éloignées pixel à pixel. Une photo et sa version simplement assombrie, presque identiques pour notre œil, peuvent l'être tout autant. Obtenir une distance qui reflète la ressemblance réelle d'objets complexes est un problème à part entière, celui des **bonnes représentations**, que nous retrouverons avec les réseaux de neurones (Module 3) et les plongements (*embeddings*, Module 4). Pour des données tabulaires comme nos maisons, en revanche, la distance brute convient déjà très bien.

La malédiction de la dimension. Une autre raison, plus mathématique, explique pourquoi la distance perd de son sens quand le nombre de dimensions augmente. Dans un plan, vingt maisons suffisent à occuper l'espace, et chacune a des voisines proches. Dans un espace à un million de dimensions, comme celui des pixels, vingt exemples, ou même vingt millions, sont dispersés dans un espace presque vide, et tous les points sont loin les uns des autres.

Les distances entre les points deviennent presque toutes égales, et le « plus proche voisin » n'est plus vraiment proche. C'est la **malédiction de la dimension** (*curse of dimensionality*). Chaque caractéristique ajoutée multiplie la taille de l'espace, et le nombre d'exemples nécessaire pour le remplir croît très rapidement. Ce problème touche directement kNN. C'est l'une des raisons pour lesquelles, sur des images ou du texte, on cherche d'abord à réduire le nombre de dimensions à quelques-unes qui comptent, une idée que les Modules 3 (avec l'autoencodeur) et 4 développeront. Vous avez déjà rencontré ce phénomène sous un autre nom, l'explosion combinatoire du Module 1. Dans ce cas, chaque coup supplémentaire multipliait le nombre de parties à explorer. Ici, chaque caractéristique supplémentaire multiplie l'espace à remplir. Il s'agit de la même croissance exponentielle, que la force brute ne permet pas de traiter et qui demande une méthode plus astucieuse.

Nous disposons donc d'une mesure de ressemblance fiable pour des données tabulaires comme nos maisons. Il reste à l'utiliser pour prédire.

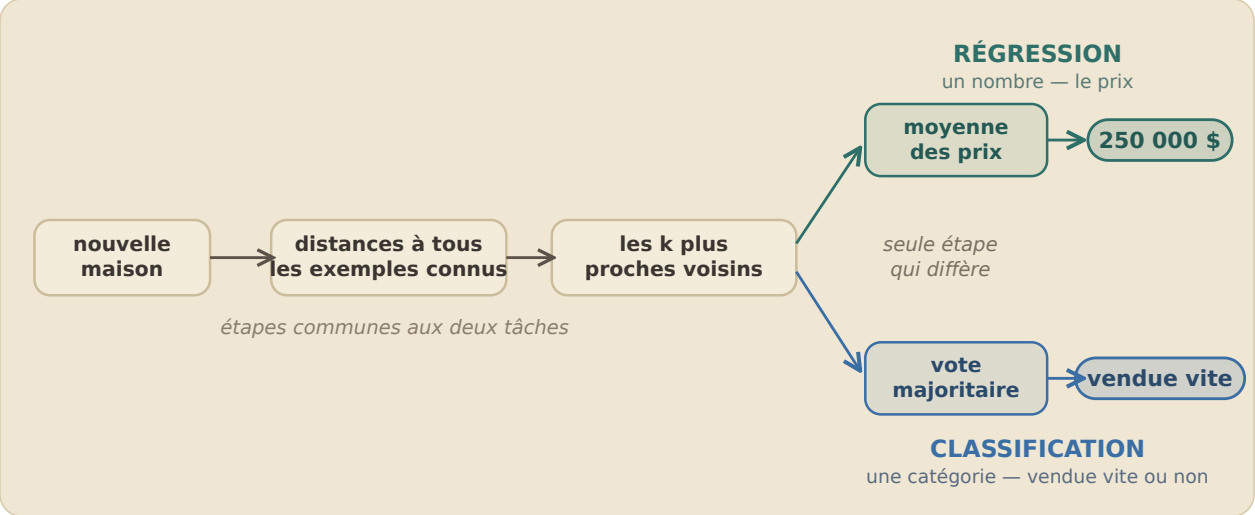
Les k plus proches voisins

Pour prédire le prix d'une maison inconnue, la méthode est très simple. On calcule sa distance à toutes les maisons connues, on retient celles qui lui ressemblent le plus et on prédit la moyenne de leurs prix. On utilise plusieurs voisins plutôt qu'un seul parce qu'un unique voisin serait une base fragile : il pourrait s'agir d'un cas exceptionnel, une aubaine ou une arnaque. En faisant la moyenne de plusieurs voisins, on atténue l'effet de ces cas particuliers.

Le nombre de voisins consultés se note **k**, d'où le nom de l'algorithme : les **k plus proches voisins** (*k-nearest neighbors*, ou kNN). L'idée a été formalisée en 1951 par deux statisticiens, Evelyn Fix et Joseph Hodges, dans un rapport rédigé pour l'armée de l'air américaine. Elle relève donc de la statistique avant de relever de l'informatique.

Nous venons de faire une **régression**, puisque la cible était un prix, donc un nombre, et que nous l'avons obtenu en faisant la moyenne des voisins. Pour une **classification**, il suffit de changer la dernière étape. Au lieu de faire la moyenne des réponses des voisins, on retient la réponse la plus fréquente, par un **vote majoritaire**. Pour prédire si une maison partira vite, on regarde ce qui s'est passé pour ses plus proches voisines et on suit la majorité.

kNN a donc la particularité de faire les deux sans rien changer d'essentiel. La distance et les voisins sont les mêmes, et seule la façon de combiner leurs réponses diffère. La plupart des algorithmes que nous verrons ensuite se spécialiseront dans l'une ou l'autre tâche.



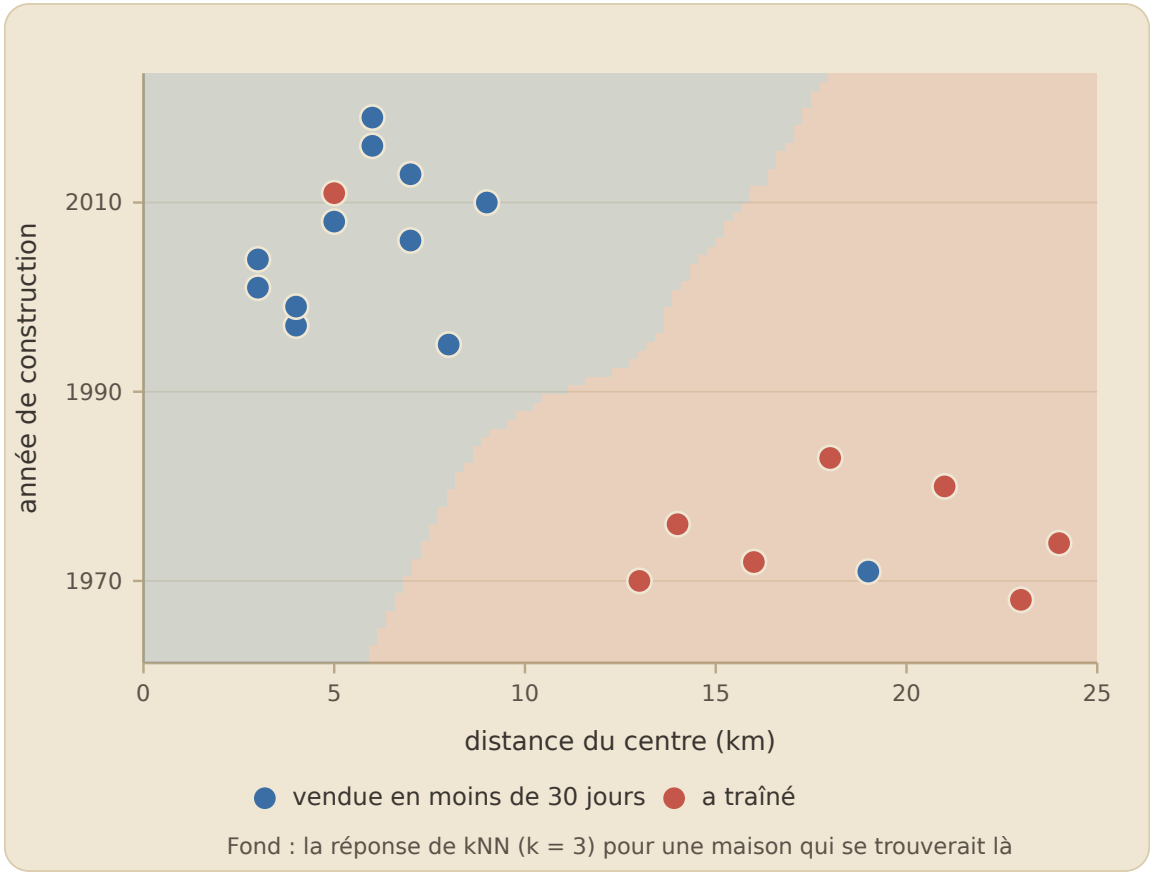
kNN suit les mêmes étapes pour la régression et la classification ; seule la dernière (moyenne ou majorité) les distingue.

La recette des *k* plus proches voisins, pour prédire à propos d'une nouvelle maison :

1. Calculer la **distance** entre cette maison et *chacune* des maisons déjà connues (à partir de leurs caractéristiques).
2. Garder les **k** maisons les plus proches, ses « voisins ».
3. Combiner les réponses de ces voisins :
   - pour un **nombre** (régression) → prendre leur **moyenne** ;
   - pour une **catégorie** (classification) → prendre leur **majorité**.

Seule cette dernière étape distingue les deux tâches ; tout le reste est identique.

Revenons à nos maisons, dans le plan de la seconde question (distance du centre, année de construction). On peut demander à kNN sa réponse pour une nouvelle maison placée à n'importe quel endroit de ce plan. En posant la question pour chaque point du plan et en colorant ce point selon la réponse obtenue, on obtient une carte : bleu pâle si les k voisins votent « vendue vite », rouge pâle s'ils votent « a traîné ». Voici le résultat pour $k = 3$:



La frontière de décision de kNN ($k = 3$) sur nos maisons : le fond donne la réponse du modèle en chaque point du plan, et la ligne où la couleur change est la frontière.

Le plan est ainsi divisé en deux **régions**. La ligne où la couleur change, qui passe dans la bande vide entre les deux amas, s'appelle la **frontière de décision** (*decision boundary*). Personne ne l'a tracée : elle résulte de l'application de la règle en chaque point. C'est elle qui détermine la prédiction. Une maison située d'un côté sera classée « vendue vite », et une maison située de l'autre côté sera classée « a traîné », sans autre nuance. On peut aussi observer ce qui arrive aux deux exceptions du premier chapitre. Avec $k = 3$, chacune se trouve dans la région de la couleur opposée, puisque ses trois voisins les plus proches votent pour l'autre catégorie.

Cette observation vaut pour tout classificateur, et pas seulement pour kNN : **classer revient à diviser l'espace en régions, et un modèle de classification est entièrement décrit par la frontière qu'il trace.** C'est pour cette raison que la classification est plus facile à visualiser que la régression : en deux dimensions, on voit la frontière d'un seul coup d'œil. Au chapitre « Classer », nous verrons des modèles dont la frontière est une simple droite. Celle de kNN peut prendre n'importe quelle forme.

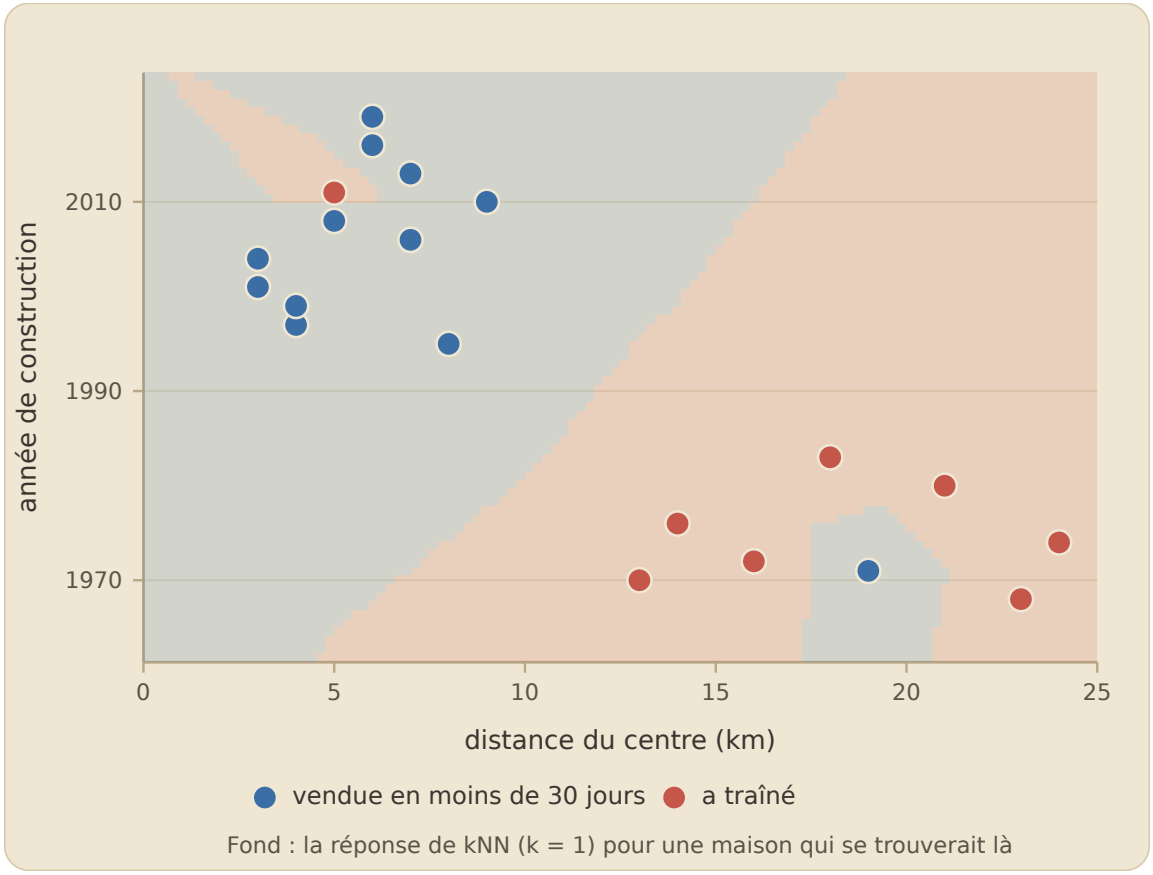
L'applet ci-dessous permet de manipuler cette frontière. Il y a deux catégories, des points rouges et des points bleus. Chaque point coloré est un exemple connu, et le fond montre, comme plus haut, la prédiction de kNN pour tout nouveau point. Ajoutez des points, déplacez-les, faites varier k et observez comment la frontière de décision change.

Applet interactive : à utiliser en ligne, sur la page « Prédire par ressemblance » du site du cours.

Le choix de k

L'applet soulève rapidement une question : quelle valeur faut-il donner à **k** ?

Les deux extrêmes sont instructifs. Avec **k = 1**, chaque prédiction ne s'appuie que sur le voisin le plus proche. La frontière suit alors le moindre détail, fait le tour de chaque point individuel et devient très irrégulière. Le modèle suit les exemples connus de si près qu'il réagit au moindre point aberrant (*outlier*). Ce défaut porte un nom, et il est central dans tout ce qui suit : le **sur-apprentissage** (*overfitting*), qui consiste à apprendre les exemples eux-mêmes au lieu d'apprendre à partir d'eux. Nous y reviendrons en détail dans *Généraliser*. Nos maisons le montrent : avec $k = 1$, chacune des deux exceptions crée autour d'elle une petite zone de sa couleur dans la région opposée, et la frontière se découpe en cellules anguleuses.



La même frontière avec k = 1 : chaque exception crée sa propre petite zone, et la frontière suit chaque point.

À l'autre extrême, avec un **k très grand**, chaque prédiction fait la moyenne de tant de voisins que les particularités locales disparaissent. La frontière devient lisse, parfois au point d'ignorer des structures qui existent réellement dans les données.

Une « bonne » valeur se trouve entre les deux, ni trop petite ni trop grande. La façon de la trouver est une question qui paraît simple, mais qui est l'une des plus importantes de l'apprentissage automatique. Elle ne concerne pas seulement kNN : tout modèle doit être assez souple pour saisir les vraies régularités des données, sans l'être au point de reproduire leurs variations dues au hasard.

Cette question est assez centrale pour que nous lui consacrions une page entière, *Généraliser*, une fois

que nous connaîtrons quelques modèles de plus. Pour l'instant, retenez seulement l'idée suivante : **k règle un compromis entre « coller aux exemples » et « lisser à l'excès ».**

L'angle mort de kNN

kNN a une particularité : il n'a, à proprement parler, **rien à apprendre**. Il n'y a ni entraînement ni paramètres à régler. Il suffit de garder en mémoire tous les exemples connus et de les consulter au moment de prédire. Les données constituent le modèle.

Cette simplicité a cependant deux inconvénients, qui motivent la suite du module.

Le premier est que kNN est **coûteux**. Pour chaque nouvelle prédiction, il doit calculer la distance à tous les exemples connus, sans exception. Avec quelques dizaines de maisons, ce n'est pas un problème. Pour un système qui doit reconnaître un visage parmi des millions d'images, ou répondre en une fraction de seconde à des millions d'utilisateurs, tout recalculer à chaque fois devient très coûteux. kNN reporte tout le travail au moment de la prédiction, qui est le moment où il coûte le plus cher.

Le second inconvénient est plus fondamental : kNN **ne dégage aucune compréhension** des données. Il n'en tire aucune règle, aucune tendance, aucune forme générale. Il ne « sait » pas que les grandes maisons coûtent plus cher : il se contente de retrouver des voisins. Le modèle le plus bête avait, lui, résumé toute sa connaissance en **un seul nombre**, le prix moyen. kNN fait l'inverse : il ne résume rien et garde tout.

Or c'est justement ce résumé qui nous intéresse. On voudrait qu'un modèle **apprenne** quelque chose des données, c'est-à-dire qu'il en extraie quelques paramètres qui représentent la tendance générale, quitte à ne plus avoir besoin des exemples ensuite. Un tel modèle serait léger à utiliser et contiendrait une forme de compréhension des données.

Le prochain chapitre, « Un modèle qui s'entraîne », montre comment construire un tel modèle.

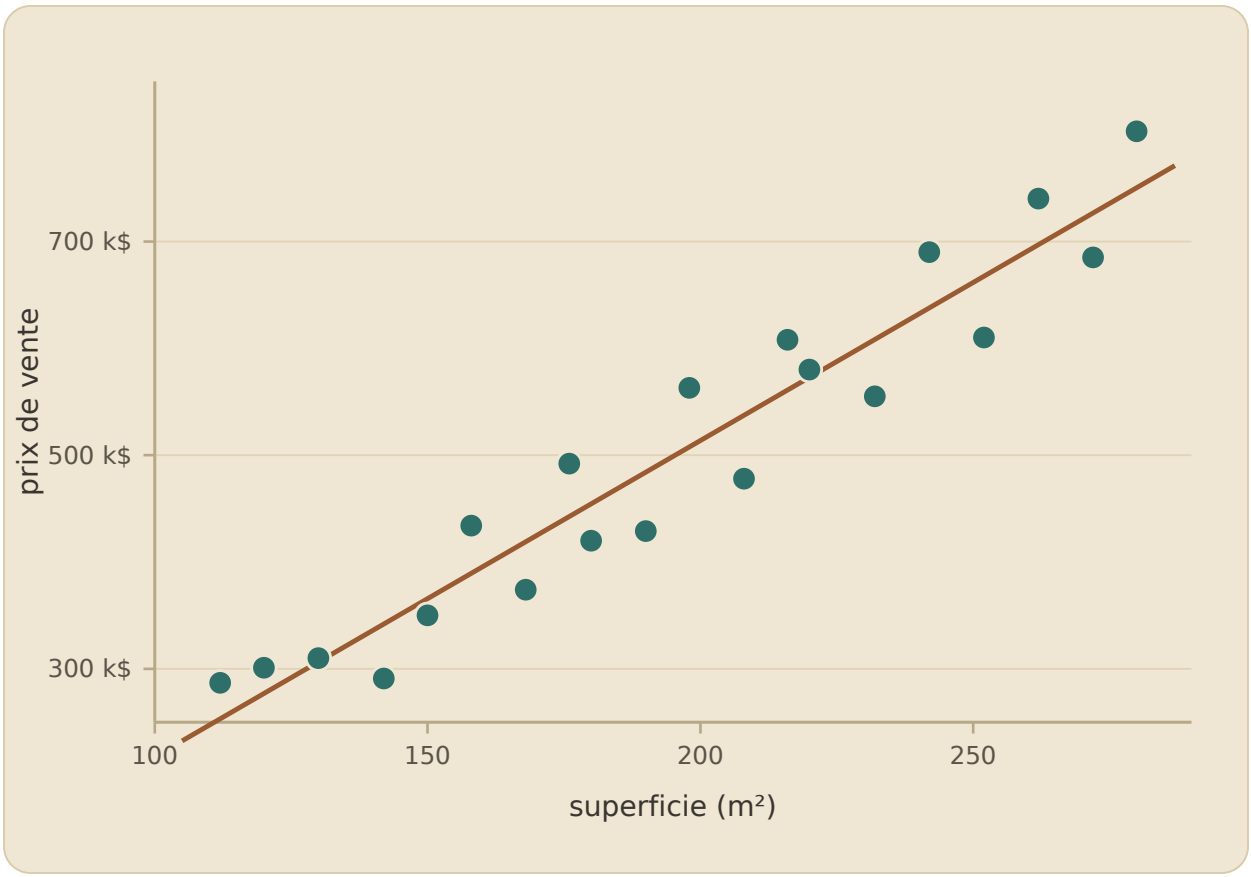
Un modèle qui s'entraîne

Le chapitre « Prédire par ressemblance » s'est terminé sur un objectif : obtenir un modèle qui ne se contente pas de mémoriser les exemples, mais qui en extrait une tendance générale, résumée en quelques paramètres, qu'on pourra ensuite appliquer sans conserver toutes les données.

Nous allons construire ce modèle. Comme nous cherchons le plus simple, nous allons faire l'opération la plus élémentaire qu'on puisse faire sur un nuage de points : **y faire passer une droite.**

Un modèle qui tient en deux nombres

Reprenons notre nuage de maisons (la superficie à l'horizontale, le prix à la verticale). Faire passer une droite à travers ce nuage revient à supposer qu'il existe une relation simple et régulière entre la taille d'une maison et son prix, du type « chaque mètre carré supplémentaire ajoute environ tant de dollars ». Cette droite est notre modèle. C'est aussi le plus ancien modèle de ce module. Legendre et Gauss ajustaient déjà des droites par la méthode des moindres carrés (*least squares*) vers 1805 pour prédire la trajectoire des comètes, et c'est Francis Galton qui, en 1886, lui a donné le nom de *régression*, en étudiant la taille des enfants par rapport à celle de leurs parents.



La droite qui suit la tendance du nuage : c'est notre modèle.

En mathématiques, une droite se résume à deux nombres :

$$\text{prix} = m \times \text{superficie} + b$$

- **m**, la *pente* (*slope*) : de combien le prix monte quand la superficie augmente d'une unité ;
- **b**, l'*ordonnée à l'origine* (*intercept*) : le point de départ, là où la droite croise l'axe vertical.

Ces deux nombres, m et b, sont les **paramètres** du modèle, et ils ont ici une signification. Le modèle le plus bête résumait tout en un seul nombre (la moyenne), et kNN n'avait aucun paramètre. Notre droite en a deux, ce qui suffit pour représenter une *tendance*, avec une direction et une hauteur. Si on change m et b, on obtient une autre droite, donc un autre modèle. Le problème consiste à trouver le couple (m, b) qui donne la droite la mieux ajustée au nuage.

Essayez vous-même. Dans l'applet ci-dessous, déplacez la droite (vous ajustez ainsi m et b à la main) et cherchez la position qui colle le mieux aux points.

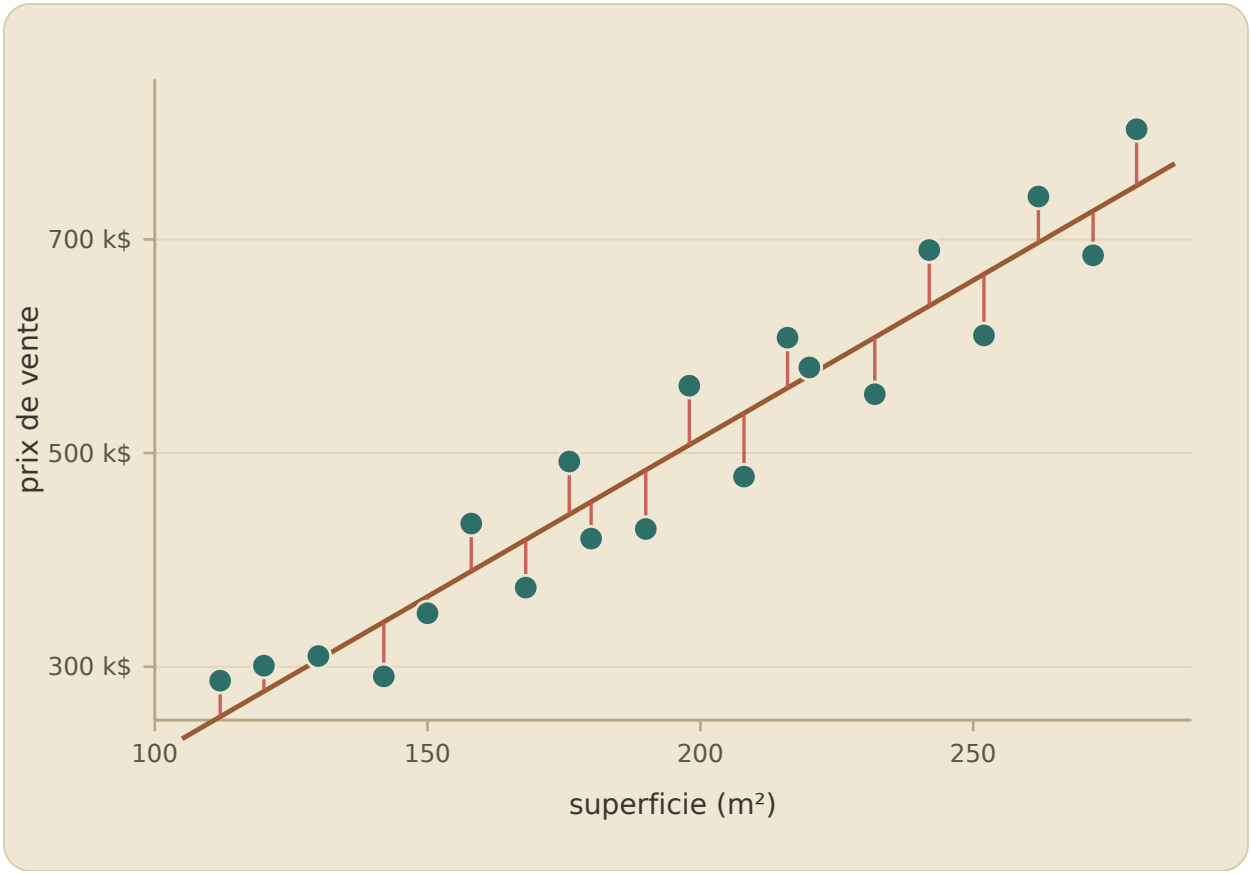
Applet interactive : à utiliser en ligne, sur la page « Un modèle qui s'entraîne » du site du cours.

Mesurer l'erreur

En déplaçant la droite, vous avez cherché à la placer « bien ». Il faut cependant préciser ce que « bien » veut dire. Il nous faut une mesure, que nous avons déjà rencontrée avec le modèle le plus bête sans

encore la définir précisément : l'**erreur**.

Pour une droite donnée, l'erreur sur une maison est l'écart entre le prix que la droite *prédit* (le point de la droite à la verticale de cette maison) et son prix *réel*. Comme pour le modèle le plus bête, cet écart est un segment vertical. La différence est qu'ici la droite est inclinée, et qu'elle peut donc passer beaucoup plus près des points qu'une droite horizontale.



Les mêmes erreurs qu'avec le modèle le plus bête, mais par rapport à une droite inclinée : elles sont beaucoup plus courtes.

L'erreur totale du modèle combine tous ces écarts. On les met au carré, pour que les écarts au-dessus et en dessous de la droite ne s'annulent pas et pour pénaliser davantage les grands écarts, puis on en fait la moyenne. Ce nombre, la moyenne des carrés des écarts, porte un nom technique, l'*erreur quadratique moyenne* (*mean squared error*), mais l'idée est simple : **plus il est petit, mieux la droite s'ajuste au nuage.** (Considérez le cas limite. Si la droite passait exactement par tous les points, chaque écart serait nul, chaque carré aussi, et l'erreur vaudrait zéro. C'est la valeur minimale possible. Avec un nuage comme le nôtre, aucune droite ne l'atteint, et l'objectif est de s'en approcher le plus possible.)

On peut se représenter cette erreur de la façon suivante. Imaginez que chaque point est relié à la droite par un petit ressort vertical. Un point éloigné tire fort, un point proche tire à peine. La meilleure droite est celle où les forces de tous ces ressorts s'équilibrent, c'est-à-dire la position de moindre tension. Cette position correspond à la droite de plus petite erreur. Vous pouvez l'observer dans l'applet suivante :

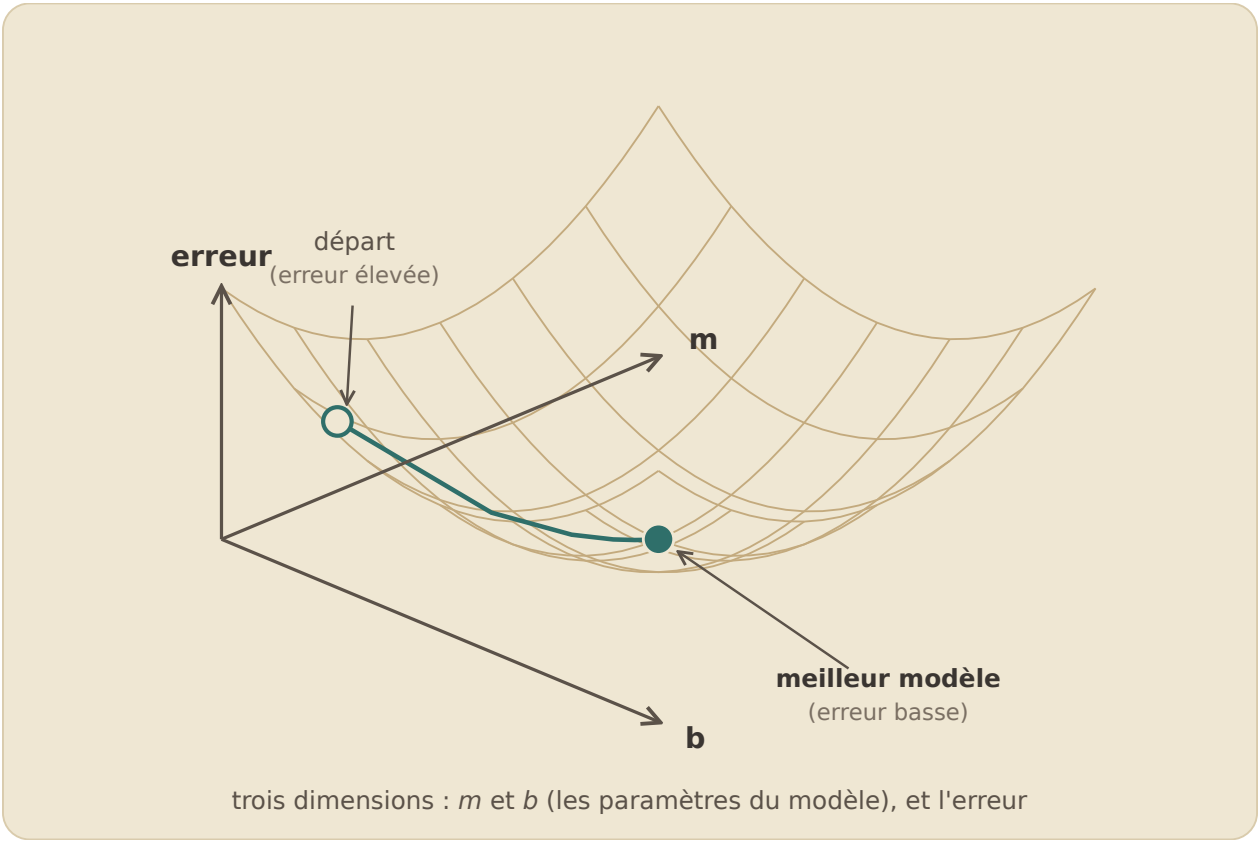
Applet interactive : à utiliser en ligne, sur la page « Un modèle qui s'entraîne » du site du cours.

Trouver cette droite à la main, comme dans l'applet, reste possible en deux dimensions. Il reste à voir comment une machine peut la trouver seule, y compris quand le modèle n'a plus deux paramètres, mais des milliers. C'est l'objet de la section suivante.

Apprendre, c'est descendre la pente

L'idée présentée dans cette section est au cœur de tout l'apprentissage automatique moderne, sous une forme ou une autre, y compris dans les plus grands modèles actuels.

Repartons de l'erreur. Pour chaque choix de paramètres (m, b), le modèle commet une certaine erreur totale. L'erreur est donc elle-même une *fonction* des paramètres. On peut la représenter comme un **paysage**. Les deux paramètres sont les coordonnées sur une carte (est-ouest pour m, nord-sud pour b), et l'erreur est l'**altitude** en chaque point. Le paysage a donc **trois dimensions** : deux pour les paramètres, *m* et *b*, et une troisième, verticale, pour l'erreur. Les sommets correspondent aux mauvais modèles (grande erreur), et les vallées aux bons. Trouver le meilleur modèle revient à trouver le **point le plus bas** de ce paysage.



La descente de gradient : l'erreur forme une cuvette au-dessus des réglages (m, b) ; la bille descend jusqu'au creux, qui correspond au meilleur modèle.

La machine ne connaît pas la forme complète de ce paysage. Elle procède comme un randonneur dans le brouillard : elle mesure la **pente** à l'endroit où elle se trouve et fait un pas dans la direction qui descend le plus. Puis elle recommence. Pas après pas, elle descend vers le creux, comme une bille posée sur le flanc d'une vallée roule vers le fond. Quand la pente devient nulle, le fond est

atteint, et les meilleurs paramètres sont trouvés. Cette méthode s'appelle la **descente de gradient** (*gradient descent* ; le « gradient » désigne la direction de plus forte pente). C'est le mécanisme central de l'apprentissage.

La taille des pas a de l'importance. Si les pas sont trop grands, on risque de dépasser le creux et d'osciller autour sans l'atteindre. S'ils sont trop petits, la descente est très longue. Ce réglage, le *taux d'apprentissage* (*learning rate*), n'est pas un paramètre du modèle, mais un réglage de la *procédure*. On l'appelle un **hyper-paramètre** (*hyperparameter*).

Cette idée rejoint la fin du Module 1, où nous annoncions qu'« *apprendre, c'est encore chercher, mais dans un autre espace* ». Il ne s'agit plus d'explorer les coups d'une partie d'échecs, mais l'ensemble très vaste des réglages possibles d'un modèle. La descente de gradient est cette recherche. Le GOFAI cherchait la solution elle-même, alors que l'apprentissage cherche les paramètres qui permettent de la produire. De plus, la méthode reste la même quelle que soit l'échelle : que le paysage ait deux dimensions (m et b) ou plusieurs milliards (les poids d'un grand réseau de neurones), il s'agit toujours de descendre la pente.

Les mathématiques de la régression linéaire (optionnel)
L'erreur quadratique moyenne, pour n maisons, s'écrit :

$$J(m, b) = \frac{1}{n} \sum_{i=1}^{n} (y_i - (mx_i + b))^2$$

où x_i est la superficie de la maison i, y_i son vrai prix, et $mx_i + b$ le prix prédit. Cette fonction correspond à la « carte d'altitude » du paysage : à chaque couple (m, b), elle associe une hauteur d'erreur.
La descente de gradient mesure, en un point, la pente de cette surface dans chaque direction (les *dérivées partielles*) :

$$\frac{\partial J}{\partial m} = -\frac{2}{n} \sum_{i=1}^{n} x_i(y_i - (mx_i + b)), \qquad \frac{\partial J}{\partial b} = -\frac{2}{n} \sum_{i=1}^{n} (y_i - (mx_i + b))$$

puis fait un pas dans le sens inverse de la pente, d'une taille réglée par le taux d'apprentissage α :

$$m \leftarrow m - \alpha \frac{\partial J}{\partial m}, \qquad b \leftarrow b - \alpha \frac{\partial J}{\partial b}$$

On répète ces étapes jusqu'à ce que l'erreur ne diminue plus. Pour la régression linéaire, il existe même une formule directe (les moindres carrés de Gauss) qui donne la solution en une seule étape. La descente de gradient a cependant l'avantage de fonctionner pour des modèles beaucoup plus complexes, jusqu'aux réseaux de neurones.

Et pour prédire une catégorie ?

Nous avons maintenant un modèle qui apprend : une droite, deux paramètres, une erreur à minimiser et une descente vers le creux. Ce modèle prédit un **nombre**, ici un prix.

Beaucoup de questions demandent cependant comme réponse une **catégorie** plutôt qu'un nombre. Par exemple, ce courriel est-il un pourriel ou non ? Cette photo montre-t-elle un chat ou un chien ? Nous avons rencontré ce type de tâche au chapitre sur kNN : la **classification**. Cependant, kNN

n'apprenait rien. Nous voulons maintenant un modèle qui s'entraîne comme notre droite, mais dont la sortie est une catégorie plutôt qu'une valeur.

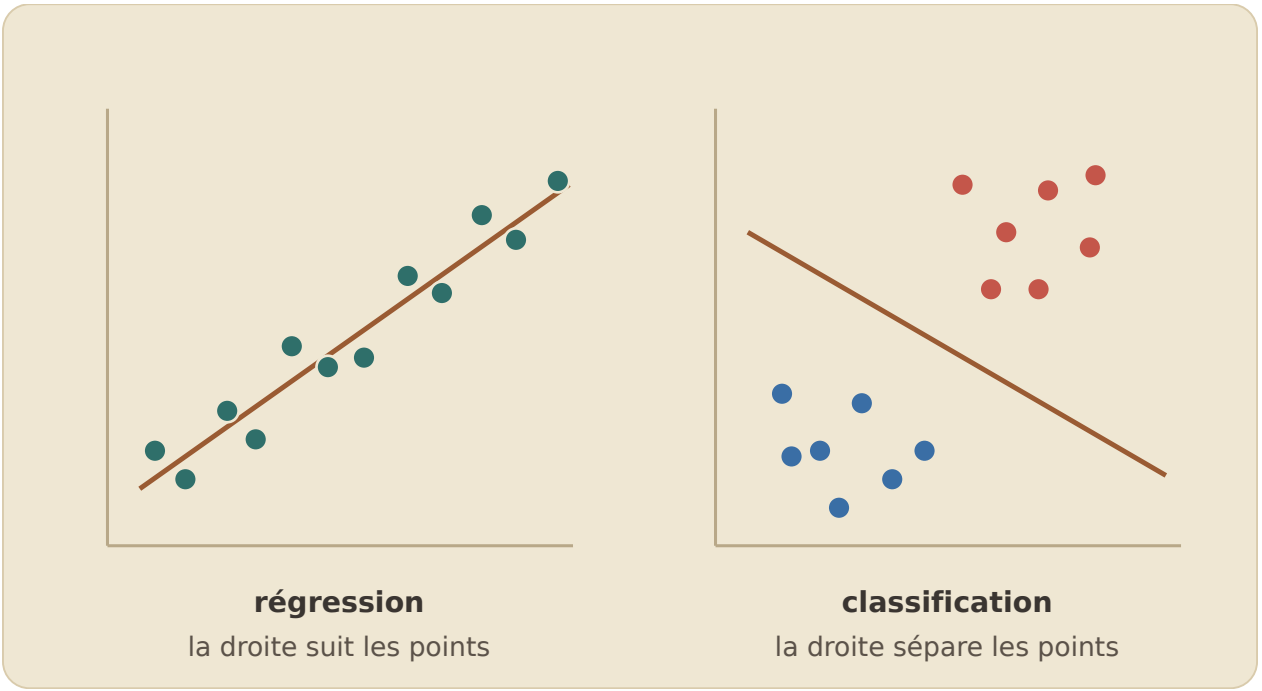
Presque tous les éléments que nous venons de construire vont servir de nouveau. Un modèle réglé par des paramètres, une fonction d'erreur et une descente de gradient pour la minimiser forment un ensemble assez général pour s'appliquer à la classification comme à la régression. Il suffira de modifier la *forme* du modèle (une droite qui *sépare* les points, plutôt qu'une droite qui *suit* leur tendance) et la *façon de calculer l'erreur*. C'est l'objet du prochain chapitre, « Classer ».

Classer

Le chapitre « Un modèle qui s'entraîne » a présenté un modèle qui apprend vraiment : une droite, deux paramètres, une erreur à minimiser et une descente vers le creux. Ce modèle répond cependant toujours par un **nombre**, ici un prix. Or beaucoup de questions n'appellent pas un nombre, mais une **catégorie**. Par exemple, on peut se demander si un courriel est un pourriel, si une tumeur est bénigne ou maligne, ou si une photo montre un chat ou un chien. C'est la tâche de **classification**, déjà rencontrée au chapitre kNN. Cette fois, cependant, nous voulons un modèle qui s'entraîne.

Comme l'annonçait la fin du chapitre précédent, presque toute la machinerie va servir de nouveau. Des paramètres réglables, une fonction d'erreur et une descente de gradient pour la minimiser forment un ensemble assez général pour s'appliquer à la classification comme à la régression. Seules deux choses changent : la **forme** du modèle et la **façon de compter l'erreur**.

Pour la forme, le changement est simple. En régression, la droite suivait le nuage : elle passait à travers les points pour en représenter la tendance. En classification, la droite sépare le nuage : elle passe entre deux groupes pour les départager. L'objet est le même (une droite, deux paramètres), mais son rôle est inversé.



Deux usages de la même droite : à gauche elle suit le nuage (régression), à droite elle le sépare (classification).

Pour simplifier, laissons de côté les maisons et prenons le cas le plus simple : des points de deux couleurs, `bleus` et `rouges`, dispersés dans le plan (deux caractéristiques, x_1 et x_2). Apprendre à classer consiste alors à trouver la droite qui place le mieux les bleus d'un côté et les rouges de l'autre. Il existe deux grandes façons d'y arriver, deux approches que nous allons examiner l'une après l'autre.

Tracer une frontière : la régression logistique

La première approche est la plus directe. Pour séparer les bleus des rouges, il suffit de **tracer la frontière** entre eux. Il n'est pas nécessaire de comprendre ce qui distingue un bleu d'un rouge, seulement de trouver où passe la ligne. C'est l'approche dite **discriminative** : le modèle apprend à discriminer les classes, sans chercher à les décrire.

Dans notre plan, cette frontière est une droite, et nous savons déjà qu'une droite se définit par deux paramètres, une pente et une hauteur. Son rôle a toutefois changé. En régression, on lisait la droite verticalement : à telle superficie correspond tel prix. Ici, on regarde de quel **côté** de la ligne tombe le point. D'un côté, on répond `bleu`, de l'autre, `rouge`. La même équation, $mx_1 + b$, ne sert plus à calculer une valeur mais à partager le plan en deux.

Cet algorithme s'appelle la **régression logistique** (*logistic regression*). Il a été mis au point par des statisticiens dans les années 1950 et, malgré son nom (il contient « régression » alors qu'il classe), c'est l'un des classificateurs les plus utilisés. Dans l'applet ci-dessous, déplacez la ligne de décision pour séparer au mieux les deux groupes. Vous ajustez ainsi ses deux paramètres à la main, comme vous déplaciez la droite de régression au chapitre précédent. Vous pouvez aussi ajouter, retirer ou déplacer des points.

Applet interactive : à utiliser en ligne, sur la page « Classer » du site du cours.

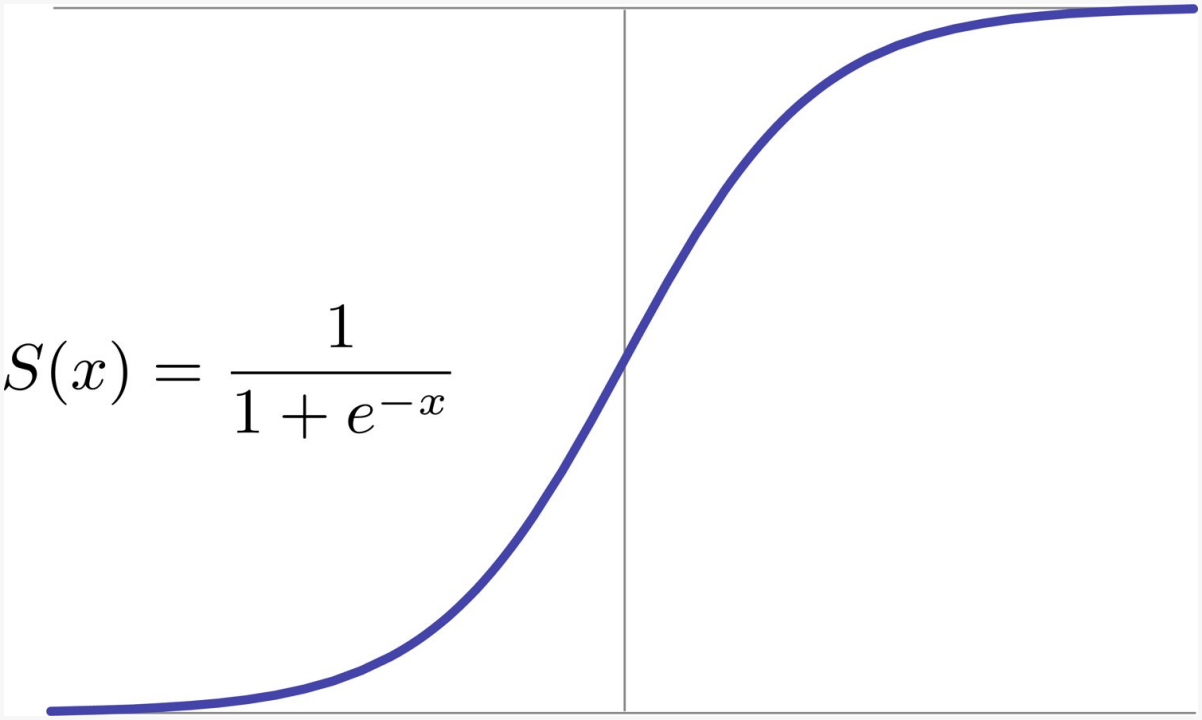
Le second changement concerne l'erreur. On ne peut plus mesurer une distance verticale au point, puisqu'on ne prédit plus une valeur. On compte plutôt les cas où le modèle se **trompe de côté** : un point bien placé ne coûte rien, un point du mauvais côté coûte cher. La barre à droite de l'applet affiche cette erreur, soit la part des points qui sont du mauvais côté. Cherchez à la rendre la plus petite possible. Elle vaut zéro quand la ligne sépare parfaitement les deux couleurs.

Vous remarquerez deux choses. D'abord, il n'est **pas toujours possible** d'atteindre zéro : si les couleurs se chevauchent, aucune droite ne les sépare complètement. Ensuite, l'erreur ne dépasse jamais **50 %**. Même la pire ligne classe correctement la moitié des points par hasard, et si elle fait moins bien, le modèle n'a qu'à inverser sa convention (« ce côté-ci est rouge, pas bleu ») pour repasser sous ce seuil.

> Matière à réflexion : pourquoi n'est-il pas toujours possible de séparer parfaitement les deux groupes par une droite ? Dans quelles conditions y arrive-t-on ? Et qu'est-ce qui pourrait rendre la chose possible quand elle ne l'est pas ? (Nous y reviendrons : c'est l'une des questions centrales du Module 3, dans « Une couche cachée ».)

Il reste à savoir comment la machine trouve seule la bonne ligne, sans qu'on la déplace à la souris. La réponse est la même qu'au chapitre précédent. L'erreur est une fonction des deux paramètres, ce qui définit un paysage, et la **descente de gradient** parcourt ce paysage jusqu'à son creux. Le mécanisme est réutilisé tel quel. Seule la forme de la fonction d'erreur diffère. Les détails sont donnés ci-dessous.

Les mathématiques de la régression logistique (optionnel)
Nous l'avons présentée en termes géométriques, mais la régression logistique est en réalité une méthode *probabiliste*. Plutôt que de répondre simplement `bleu` ou `rouge`, elle estime la **probabilité** qu'un point soit bleu. Un point loin de la frontière, du côté bleu, sera bleu « à 99 % ». Un point situé sur la ligne sera bleu « à 50 % », ce qui correspond à l'incertitude maximale. Pour transformer la position d'un point (une valeur quelconque) en une probabilité (un nombre compris entre 0 et 1), on utilise la **fonction sigmoïde**, ou logistique, qui donne son nom à l'algorithme. Sa courbe en S ramène n'importe quelle valeur dans l'intervalle $[0, 1]$:



Adoptons la notation habituelle de l'apprentissage automatique. Un point est un vecteur $\mathbf{x} = [x_1, x_2]$. Sa vraie classe est $y \in 0, 1$ (0 pour rouge, 1 pour bleu, de façon arbitraire). Les paramètres forment un vecteur $\mathbf{w} = [w_1, w_2]$ accompagné de b. On calcule d'abord un **score**, qui indique de combien et de quel côté le point s'écarte de la frontière :

$$z = w_1 x_1 + w_2 x_2 + b$$

On le passe ensuite dans la sigmoïde pour obtenir la probabilité estimée :

$$\hat{y} = \frac{1}{1 + e^{-z}}$$

Ici, $\hat{y} \in [0, 1]$ est une probabilité, à distinguer de $y \in 0, 1$, la vraie classe. La décision finale est la suivante : bleu si $\hat{y} \geq 0{,}5$, rouge sinon.
L'erreur sur un point compare la probabilité prédite $\hat{y}$ à la vraie classe y. On utilise l'**entropie croisée** (*cross-entropy*) :

$$E(y, \hat{y}) = -[\, y \log(\hat{y}) + (1 - y) \log(1 - \hat{y}) \,]$$

Cette fonction se comporte comme on le souhaite. Si le point est bleu $(y = 1)$ et que le modèle

en est sûr ($\hat{y} = 0{,}9$), l'erreur est faible ($-\log 0{,}9 \approx 0{,}1$). S'il se trompe avec assurance ($\hat{y} = 0{,}1$ pour un vrai bleu), l'erreur devient grande ($-\log 0{,}1 \approx 2{,}3$). Une confiance mal placée est donc fortement pénalisée.
L'erreur totale sur les n points est la moyenne de ces erreurs :

$$J(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^{n} E(y^{(i)}, \hat{y}^{(i)})$$

C'est cette fonction $J(\mathbf{w}, b)$ qui joue le rôle de paysage : à chaque choix de paramètres correspond une hauteur d'erreur. La descente de gradient en mesure la pente,

$$\frac{\partial J}{\partial \mathbf{w}} = \frac{1}{n} \sum_{i=1}^{n} (\hat{y}^{(i)} - y^{(i)})\, \mathbf{x}^{(i)}, \qquad \frac{\partial J}{\partial b} = \frac{1}{n} \sum_{i=1}^{n} (\hat{y}^{(i)} - y^{(i)})$$

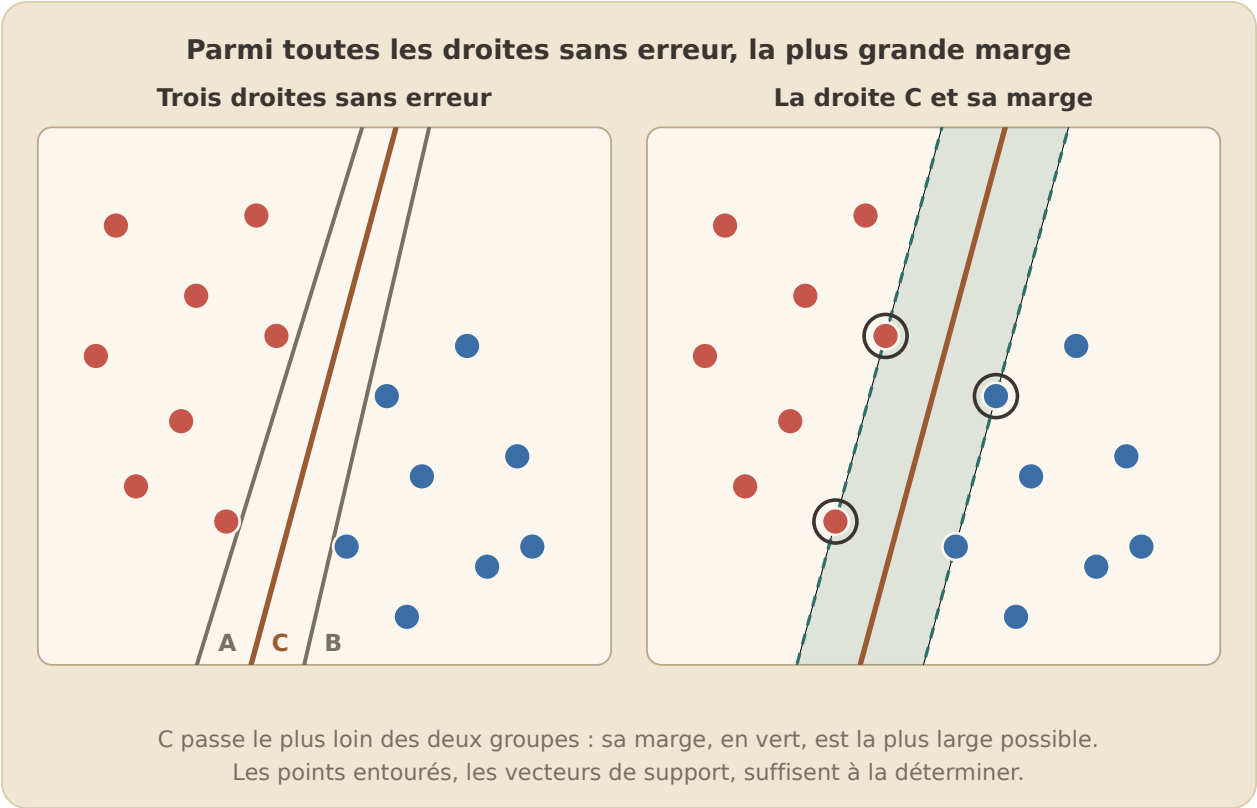
puis fait un pas en sens inverse, d'une taille fixée par le taux d'apprentissage α :

$$\mathbf{w} \leftarrow \mathbf{w} - \alpha \frac{\partial J}{\partial \mathbf{w}}, \qquad b \leftarrow b - \alpha \frac{\partial J}{\partial b}$$

On répète jusqu'à ce que l'erreur ne diminue plus. C'est le même mécanisme qu'au chapitre précédent. Seule la fonction d'erreur a changé.

La plus grande marge : les machines à vecteurs de support

Dans l'applet de la section précédente, quand les deux groupes ne se chevauchent pas, on trouve facilement une droite qui ne fait aucune erreur. On en trouve même une infinité : on peut la déplacer ou la faire pivoter un peu, et elle sépare toujours parfaitement les deux couleurs. L'erreur ne permet donc pas de choisir entre elles. Laquelle faut-il préférer ?



Plusieurs droites séparent les deux groupes sans erreur ; celle de plus grande marge passe le plus loin des deux.

L'intuition répond : celle qui passe au milieu, le plus loin possible des deux groupes. Une droite qui frôle les points rouges a toutes les chances de mal classer le prochain point rouge, s'il tombe un peu à côté des autres. Une droite éloignée des deux groupes laisse de la place à ces variations.

La marge. Autour d'une droite qui sépare les deux groupes, on peut tracer une bande vide, aussi large que possible, qui ne contient aucun point. Sa largeur s'appelle la **marge**. La **machine à vecteurs de support** (*support vector machine*, ou SVM) choisit, parmi toutes les droites qui séparent les deux groupes, celle dont la marge est la plus large. En français, on l'appelle aussi **séparateur à vaste marge**, un nom qui garde le sigle SVM et décrit bien la méthode.

Les vecteurs de support. Quand la bande est la plus large possible, quelques points en touchent les bords, souvent deux ou trois. Ce sont eux qui la bloquent : on ne peut pas l'élargir sans les englober. On les appelle les **vecteurs de support**, parce que la frontière s'appuie sur eux (un point du plan est un vecteur, au sens du chapitre « Regarder les données »). Tous les autres points n'ont aucune influence sur la frontière : on peut les déplacer, les retirer ou en ajouter loin de la bande, sans que rien change. C'est une différence importante avec la régression logistique, où chaque point tire un peu sur la frontière.

Dans l'applet ci-dessous, la frontière est recalculée à chaque modification. La bande colorée montre la marge, et les vecteurs de support sont entourés.

Applet interactive : à utiliser en ligne, sur la page « Classer » du site du cours.

1. Déplacez un point éloigné de la frontière. Rien ne change.
2. Déplacez un des points entourés. La frontière et la bande bougent aussitôt.

3. Ajoutez un point au milieu de la bande. La marge se rétrécit, et la frontière se réorganise autour de ce nouveau point.
4. Glissez un point rouge au milieu des bleus, puis réglez le curseur de tolérance, décrit ci-dessous.

La marge souple. Quand les groupes se chevauchent, aucune droite ne les sépare parfaitement, et aucune bande vide n'existe. La méthode accepte alors que certains points entrent dans la bande, ou même passent du mauvais côté, contre une pénalité. Un réglage décide de l'équilibre. Avec une faible tolérance, la méthode cherche à classer chaque point correctement, quitte à obtenir une marge étroite et une frontière qui suit de près les cas difficiles. Avec une forte tolérance, elle préfère une marge large et ignore les points isolés. C'est un **hyperparamètre**, et ce choix entre coller aux exemples et rester simple est un premier aperçu du compromis présenté dans « Généraliser ».

Un peu d'histoire. L'idée de la frontière de plus grande marge est proposée dès 1963 par le mathématicien soviétique Vladimir Vapnik, dans le cadre d'une théorie de l'apprentissage qu'il développe avec Alexeï Tchervonenkis. Émigré aux États-Unis, Vapnik la reprend aux Bell Labs. En 1992, avec Bernhard Boser et Isabelle Guyon, il lui permet de tracer des frontières courbes. En 1995, avec Corinna Cortes, il publie la marge souple (*soft margin*). C'est le laboratoire où Yann Le Cun développe au même moment ses réseaux convolutifs. Pendant une quinzaine d'années, les SVM sont l'une des méthodes les plus utilisées en apprentissage automatique, par exemple pour classer des textes ou analyser des données biologiques. Leur entraînement a un avantage précieux : il n'existe qu'une seule meilleure frontière, et on est sûr de la trouver.

Une frontière droite reste une frontière droite, quelle que soit sa marge. Le chapitre « Généraliser » montrera comment les SVM tracent aussi des frontières courbes, grâce à une idée appelée l'**astuce du noyau** (*kernel trick*).

Les mathématiques des SVM (optionnel)
Reprenons la notation de la régression logistique, avec cette fois des classes notées $y \in -1, +1$. La frontière est la droite $w_1 x_1 + w_2 x_2 + b = 0$. On impose que les points de chaque classe soient du bon côté avec une certaine avance :

$$y^{(i)} \, (\mathbf{w} \cdot \mathbf{x}^{(i)} + b) \geq 1 \quad \text{pour tous les points } i$$

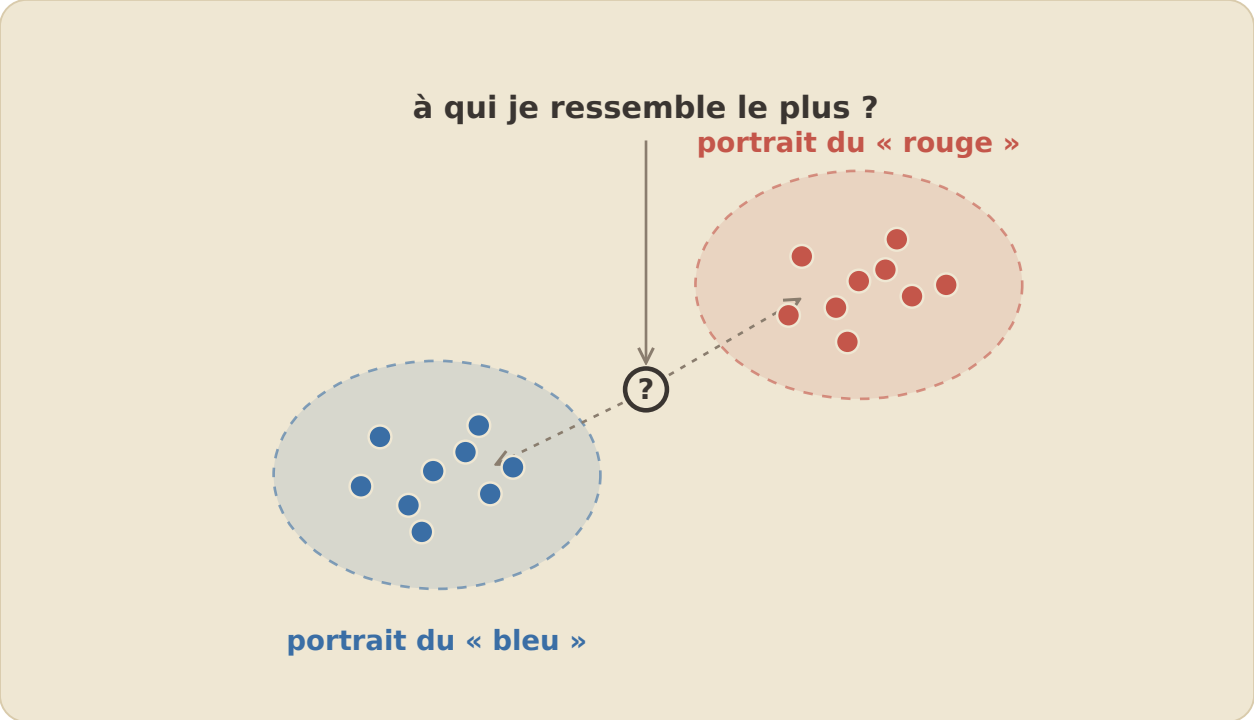
Les bords de la bande sont alors les droites $\mathbf{w} \cdot \mathbf{x} + b = 1$ et $\mathbf{w} \cdot \mathbf{x} + b = -1$. La largeur de la bande vaut $2/\|\mathbf{w}\|$. Maximiser la marge revient donc à minimiser $\|\mathbf{w}\|^2$ en respectant ces contraintes. Les vecteurs de support sont les points pour lesquels l'inégalité devient une égalité.
Pour la marge souple, on autorise chaque point à enfreindre la contrainte, et on pénalise l'écart. On minimise alors

$$\frac{1}{2}\|\mathbf{w}\|^2 + C \sum_{i=1}^{n} \max\left(0,\ 1 - y^{(i)}(\mathbf{w} \cdot \mathbf{x}^{(i)} + b)\right)$$

Le second terme, appelé *hinge loss*, ne coûte rien pour un point bien classé hors de la bande, et augmente à mesure que le point s'enfonce dans la bande ou passe du mauvais côté. Le réglage C est l'inverse de la tolérance : un C grand pénalise fortement les erreurs. Ce problème n'a qu'un seul minimum, ce qui garantit qu'on trouve la meilleure frontière.

Renverser le problème : la classification bayésienne

La seconde approche aborde le problème dans l'autre sens. Plutôt que de tracer directement la frontière, elle commence par **décrire chaque classe**. On se demande à quoi ressemble un point bleu typique, puis un point rouge typique. Avec une bonne description de chacun, on peut classer un nouveau point en se demandant s'il ressemble davantage à un bleu ou à un rouge.



L'approche générative : on décrit le « portrait » de chaque classe, puis on demande auquel le nouveau point ressemble le plus.

C'est l'approche dite **générative**, et ce terme demande une explication. Décrire une classe assez précisément pour en reconnaître les membres permet aussi, en principe, d'en produire de nouveaux. Un modèle qui connaît le portrait du « bleu typique » pourrait créer des bleus plausibles qu'il n'a jamais vus. Il est dit *génératif* parce qu'il pourrait générer des données, et pas seulement les classer. Cette idée paraît modeste ici, mais c'est elle qui, développée à grande échelle, a donné l'IA *générative* actuelle. Un **grand modèle de langage** (un LLM, comme celui de ChatGPT) est essentiellement un portrait très détaillé de la classe « texte écrit par des humains », assez précis pour produire du texte nouveau, mot après mot. Les générateurs d'images font la même chose avec les photos. Le Module 4 leur est consacré.

Pour établir le portrait d'une classe, on décrit **comment ses points se répartissent** le long de chaque caractéristique. Par exemple, les points bleus se concentrent peut-être autour d'une certaine valeur de x_1, et les rouges autour d'une valeur plus élevée. Cette répartition se résume par une courbe connue, la **courbe en cloche** (ou *gaussienne*), qui présente un sommet là où les points sont nombreux et des bords qui s'abaissent là où ils sont rares. Le portrait d'une classe est donc formé de quelques-unes de ces cloches, une par caractéristique.

Pour garder le calcul simple, on fait une hypothèse volontairement approximative : on traite **chaque**

caractéristique séparément, comme si elles étaient indépendantes. C'est rarement tout à fait vrai (la superficie et le nombre de pièces, par exemple, varient ensemble), et c'est ce que signifie le mot **naïve** dans le nom de la méthode. Cette méthode naïve est néanmoins très efficace en pratique.

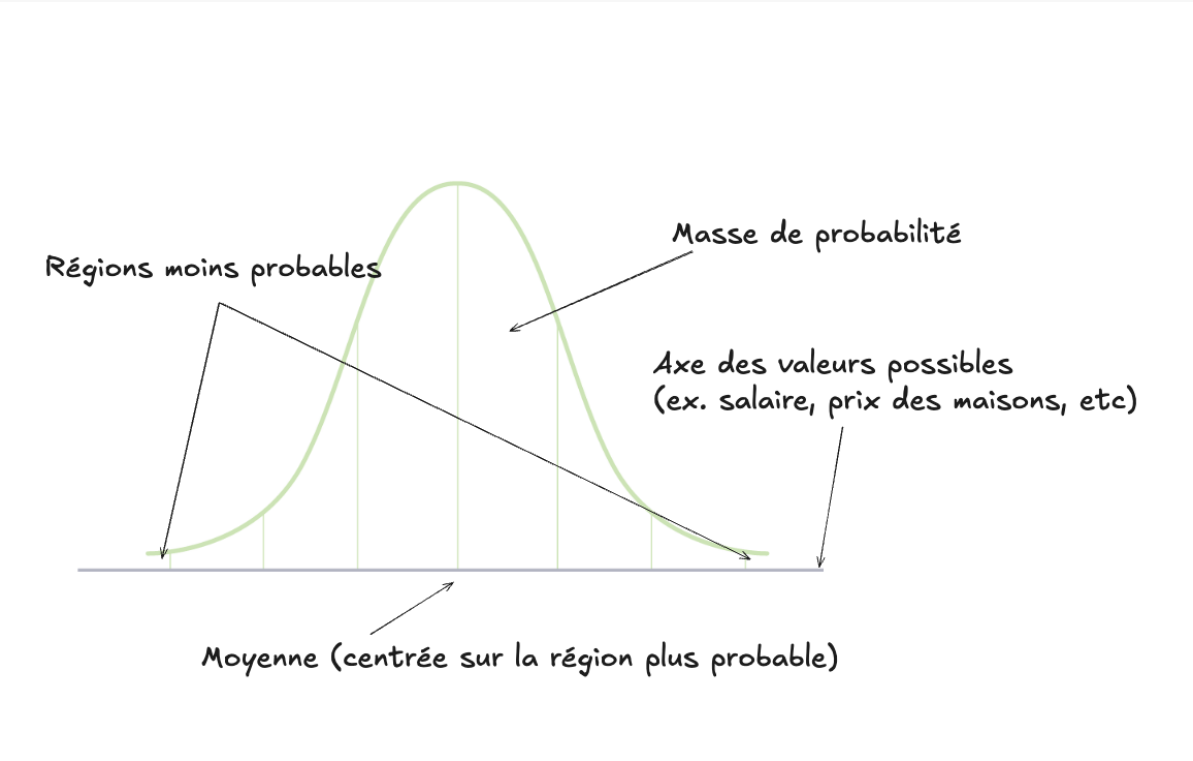
Il reste une dernière étape. Les portraits répondent à la question « si ce point est bleu, à quel point est-il typique ? », c'est-à-dire à la probabilité du point sachant la classe. Ce qu'on veut, c'est l'inverse : la probabilité que le point soit bleu, étant donné ce point. Passer de la *probabilité du point sachant la classe* à la *probabilité de la classe sachant le point* est précisément ce que permet un résultat fondamental des probabilités, le **théorème de Bayes**, publié en 1763. C'est lui qui donne son nom à la méthode, la **classification bayésienne naïve** (*naive Bayes*).

On dispose donc de deux approches pour le même objectif :

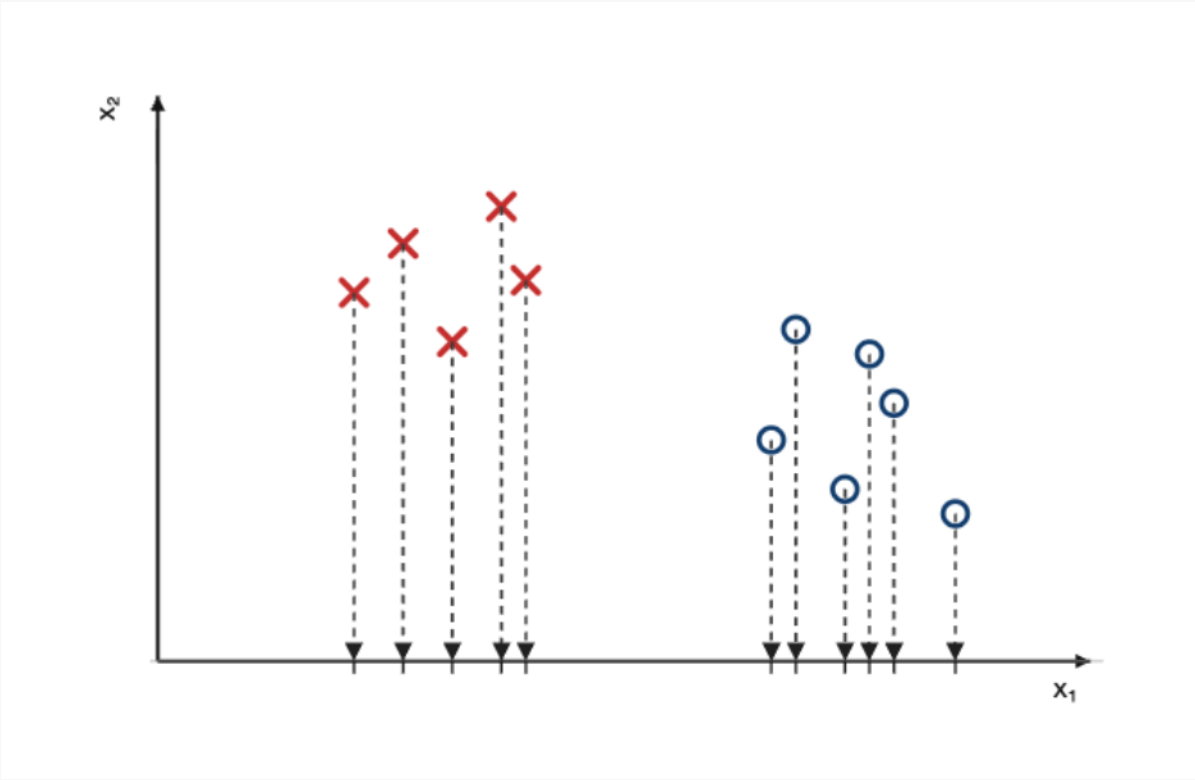
	Régression logistique	**Bayes naïf**
Philosophie	**discriminative**	**générative**
Stratégie	tracer la frontière	décrire chaque classe
Question posée	de quel côté ?	à quel portrait ressemble-t-il le plus ?
Bonus	—	pourrait générer de nouveaux exemples

Sur nos données en deux dimensions, ces deux approches très différentes aboutissent à la **même forme de frontière**, une droite. La distinction entre apprendre à séparer et apprendre à décrire reste cependant l'une des plus importantes du domaine. Nous la retrouverons au Module 4, qui distingue les modèles qui classent et ceux qui produisent du contenu.

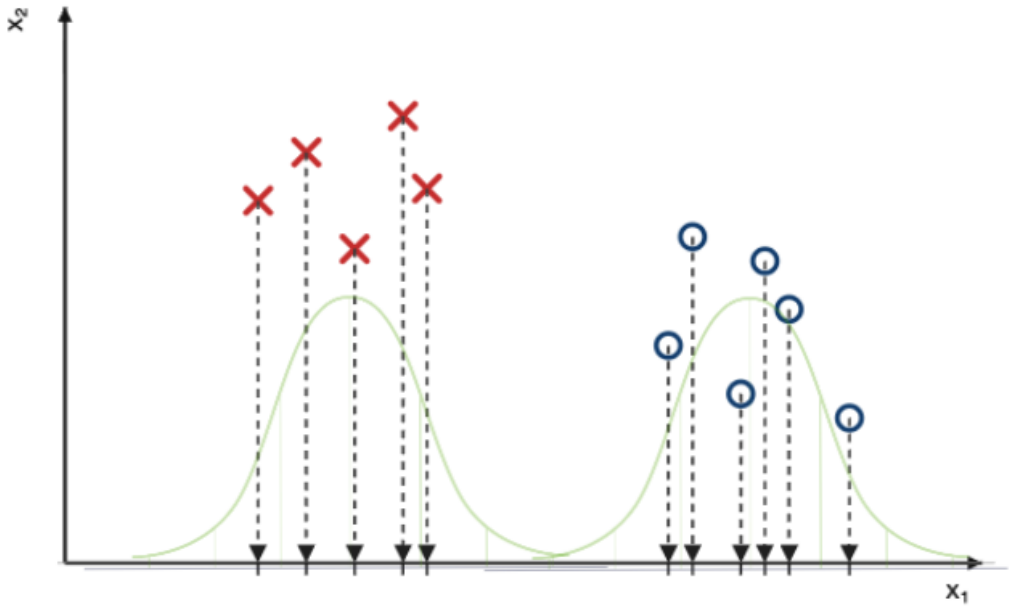
Les mathématiques de la classification bayésienne naïve (optionnel)
Chaque couple **caractéristique + classe** est modélisé par une gaussienne à une dimension. Avec nos deux caractéristiques et nos deux classes, cela fait quatre cloches. La gaussienne (ou loi normale) décrit comment la « masse de probabilité » se répartit autour d'une valeur centrale, la moyenne :



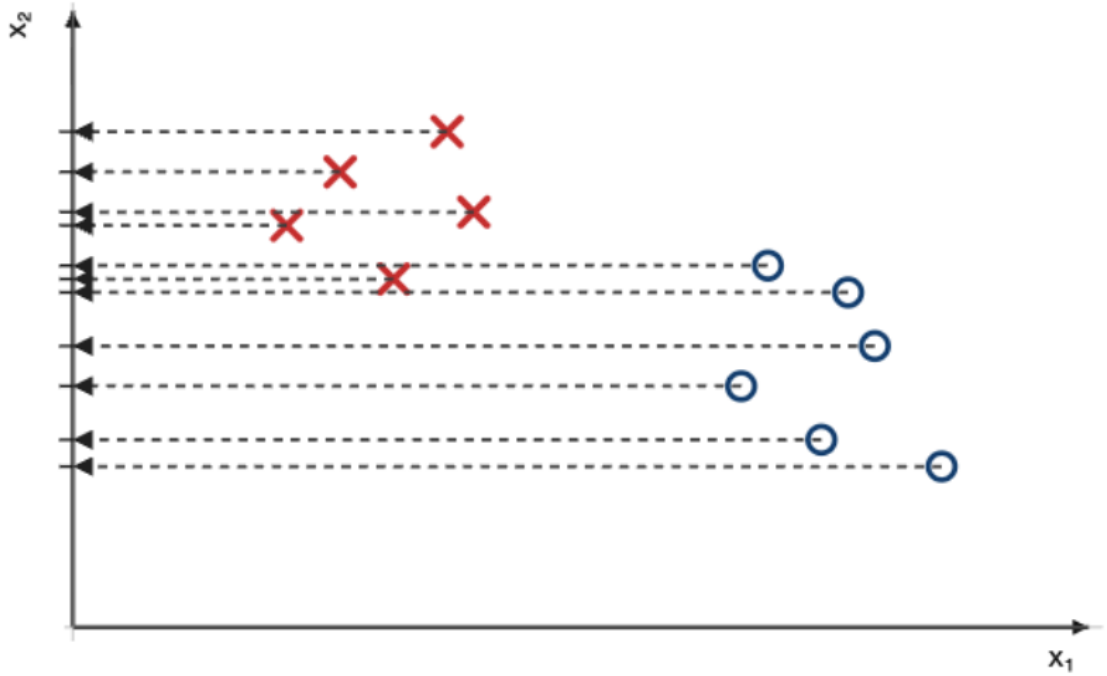
La hauteur de la courbe en un endroit n'est pas la probabilité de ce point. Comme la courbe est continue, une probabilité correspond à une **aire** sous la courbe (entre deux bornes). L'aire totale vaut 1, et l'aire à gauche de la moyenne vaut donc 0,5.
Concrètement, on projette d'abord les points sur l'axe x_1, ce qui les rend unidimensionnels...

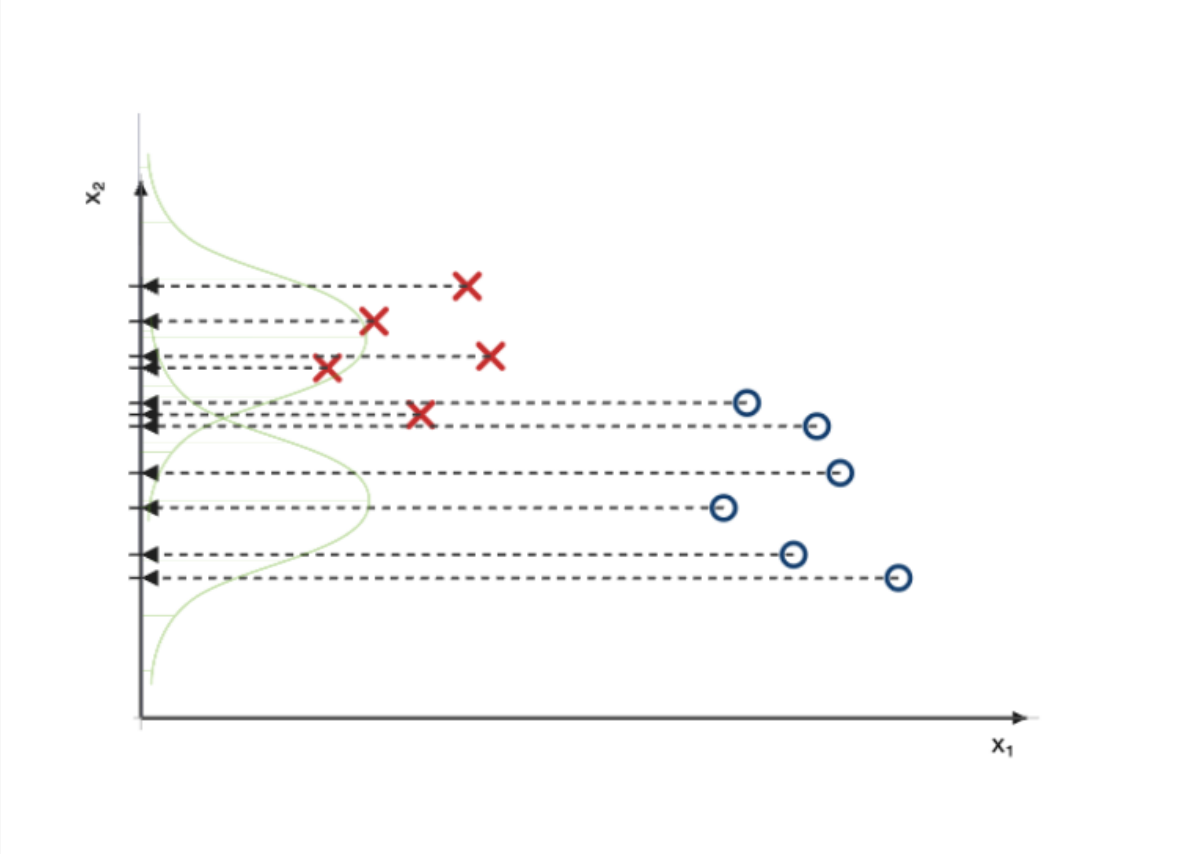


...puis on ajuste une cloche par classe, dont la largeur correspond à la dispersion des points projetés :



On fait ensuite la même chose sur l'axe x_2 :





On dispose alors de quatre modèles $p(x_j \mid \text{classe})$. La moyenne μ et l'écart-type (*standard deviation*) σ de chaque cloche s'obtiennent **directement** par un calcul de moyenne et de dispersion sur les points concernés. Aucune descente de gradient itérative n'est nécessaire ici :

$$\hat{\mu}_{j,c} = \frac{1}{N_c} \sum_{i \in c} x_{ij}, \qquad \hat{\sigma}^2_{j,c} = \frac{1}{N_c} \sum_{i \in c} (x_{ij} - \hat{\mu}_{j,c})^2$$

L'hypothèse naïve d'indépendance permet de combiner les caractéristiques par simple multiplication :

$$p(\mathbf{x} \mid c) = p(x_1 \mid c) \cdot p(x_2 \mid c)$$

Ce modèle est génératif : il décrit la probabilité d'un point $\mathbf{x}$ sachant sa classe, $P(\mathbf{x} \mid y)$. La classification demande l'inverse, $P(y \mid \mathbf{x})$. Le **théorème de Bayes** permet ce passage :

$$P(y \mid \mathbf{x}) = \frac{P(\mathbf{x} \mid y)\, P(y)}{P(\mathbf{x})}$$

Ici, $P(y)$ est la proportion de chaque classe (souvent 50/50 si les données sont équilibrées). Comme le dénominateur $P(\mathbf{x})$ ne dépend pas de la classe, on peut l'ignorer pour décider :

$$\text{classe}(\mathbf{x}) = \begin{cases} \texttt{rouge} & \text{si } P(\mathbf{x} \mid \text{rouge})\, P(\text{rouge}) \geq P(\mathbf{x} \mid \text{bleu})\, P(\text{bleu}) \\ \texttt{bleu} & \text{sinon} \end{cases}$$

On détermine donc lequel des deux portraits rend le point observé le plus **vraisemblable**, et c'est ce portrait qui donne la classe.

Le cas des pourriels

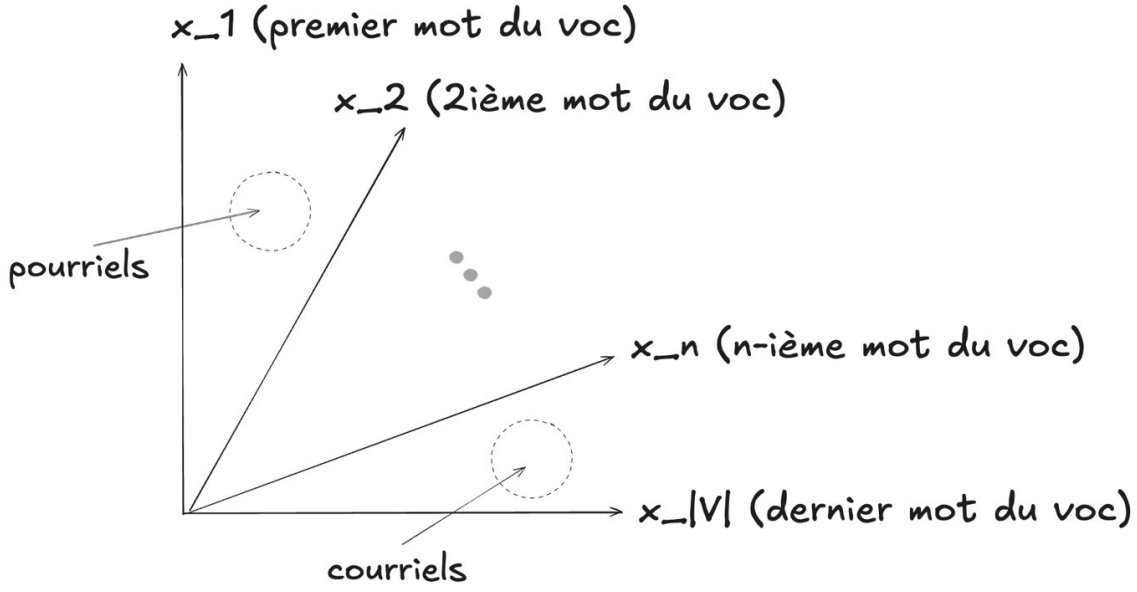
Passons maintenant des points colorés à un problème réel, celui du travail noté 2 : reconnaître automatiquement les **pourriels** (les courriels indésirables, le *spam*). C'est un exemple classique de classification. Il y a deux classes, `pourriel` ou `courriel` légitime, et une décision à prendre pour chaque message qui arrive.

Un premier obstacle se présente. Nos deux classificateurs attendent un **point**, c'est-à-dire une petite liste de nombres. Un courriel, lui, est un texte. Il faut donc trouver comment transformer un texte comme « *Félicitations ! Vous avez gagné un prix…* » en coordonnées.

La solution reprend la démarche de *Regarder les données* : une chose se décrit par une **liste de nombres** et devient ainsi un point dans un espace. Pour un texte, le procédé le plus simple s'appelle le **sac de mots** (*bag of words*). On établit la liste de tous les mots possibles (le *vocabulaire*), puis on décrit un courriel en comptant combien de fois chaque mot y apparaît. Chaque mot du vocabulaire correspond à une dimension, et la valeur est le nombre d'occurrences. Par exemple, le mot « gratuit » apparaît deux fois, « réunion » zéro fois, et ainsi de suite.

$$\mathbf{x} = (n_1, n_2, \dots, n_V)$$

La seule différence avec le vecteur d'une maison est l'échelle. Une maison se décrivait par quelques caractéristiques, alors que le vocabulaire compte des dizaines de milliers de mots. Un courriel est donc bien un point, mais dans un espace de très grande dimension. Comme nos points bleus et rouges, les pourriels et les courriels légitimes y forment deux nuages distincts :



Chaque mot du vocabulaire est un axe ; un courriel devient un point dans cet espace. Pourriels et courriels légitimes y forment deux nuages.

Nous savons déjà traiter deux nuages dans un espace, et la méthode de la section précédente s'applique telle quelle. On établit le **portrait** de chaque classe (quels mots trouve-t-on dans un pourriel typique, et dans un courriel légitime ?), puis on classe un nouveau message en déterminant lequel des deux portraits rend ses mots les plus vraisemblables. Il s'agit encore de l'approche **générative** de Bayes naïf. Ici, l'hypothèse naïve consiste à supposer que les mots sont tirés **indépendamment** les uns des autres. C'est faux (« carte » appelle souvent « bancaire »), mais c'est commode et étonnamment efficace.

Un seul détail technique change par rapport à la section précédente. Les caractéristiques y étaient des valeurs continues, décrites par une courbe en cloche. Ici, ce sont des comptes, des nombres entiers : zéro, une ou deux occurrences, par exemple. On remplace donc la cloche par une loi adaptée aux comptes, la **loi multinomiale** (*multinomial distribution*), mais le principe est le même. Le portrait d'une classe n'est plus une moyenne et une dispersion, mais la liste des mots qu'elle emploie souvent. Des mots comme « gratuit », « urgent » ou « félicitations » sont fréquents dans les pourriels et beaucoup moins dans les courriels ordinaires.

C'est ce classificateur (Bayes naïf multinomial sur un sac de mots) que vous mettrez en œuvre au **travail noté 2** pour construire votre propre filtre anti-pourriel.

Les mathématiques du Bayes naïf multinomial (optionnel)
Un courriel est le vecteur de comptes $\mathbf{x} = (n_1, \dots, n_V)$, où n_i est le nombre d'occurrences du mot i et V la taille du vocabulaire. Si ce courriel appartient à la classe `pourriel`, la probabilité d'observer ce vecteur selon la loi multinomiale est :

$$P(\mathbf{x} \mid \text{pourriel}) = \frac{N!}{n_1!\, n_2! \cdots n_V!} \prod_{i=1}^{V} p_i^{n_i}$$

Ici, $N = \sum_i n_i$ est le nombre total de mots du courriel, et p_i est la probabilité, dans un pourriel, que le mot tiré soit le mot i (par exemple plus élevée pour « prix » que pour « parent »). On définit de la même façon un modèle pour la classe `courriel`. Ces p_i s'estiment directement, en comptant la fréquence de chaque mot dans les courriels d'entraînement de la classe, comme on estimait la moyenne d'une gaussienne.
La décision se prend ensuite avec le théorème de Bayes, comme à la section précédente. En ignorant le dénominateur $P(\mathbf{x})$, qui est le même pour les deux classes, on obtient :

$$\text{classe}(\mathbf{x}) = \begin{cases} \texttt{pourriel} & \text{si } P(\mathbf{x} \mid \text{pourriel})\, P(\text{pourriel}) \geq P(\mathbf{x} \mid \text{courriel})\, P(\text{courriel}) \\ \texttt{courriel} & \text{sinon} \end{cases}$$

Ce calcul correspond à une décision **linéaire** dans l'espace des mots, soit le même genre de frontière que celle de la régression logistique. Les deux familles, discriminative et générative, aboutissent donc de nouveau au même résultat.

Raisonner sous incertitude : les réseaux bayésiens

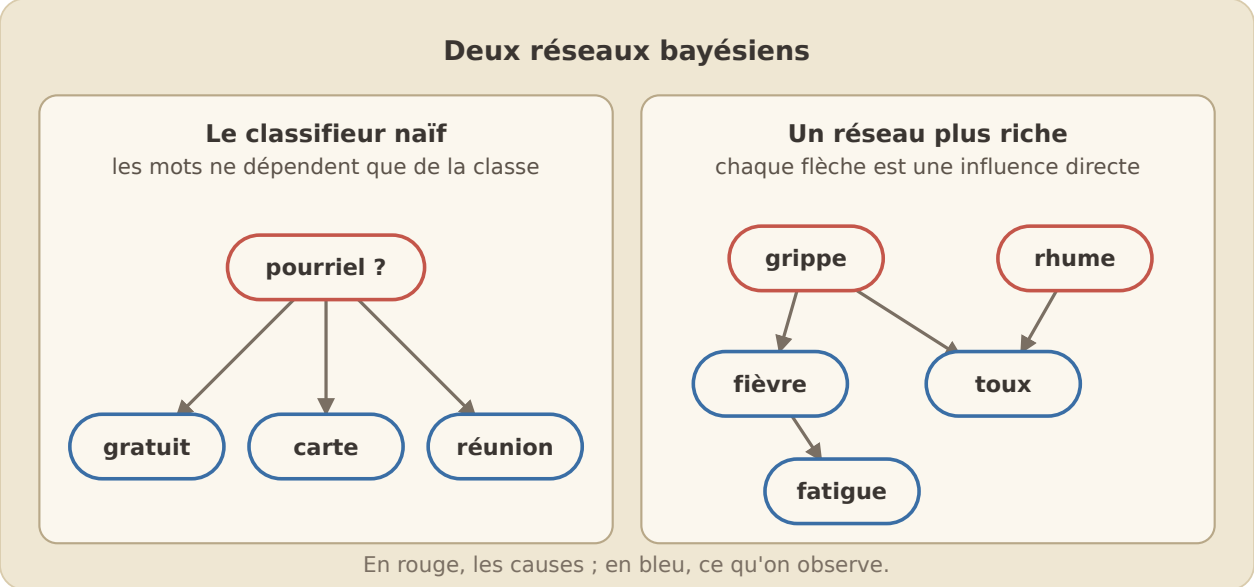
Le classifieur de la section précédente appartient à un courant plus large, qui a transformé l'IA à la fin des années 1980. Les systèmes experts du Module 1 raisonnaient avec des règles. Pour tenir compte de l'incertitude, MYCIN leur ajoutait des facteurs de certitude, une méthode commode mais

approximative. Au cours des années 1980, une autre idée s'impose : raisonner directement avec des **probabilités**, selon les règles du calcul des probabilités et le théorème de Bayes. On a appelé ce tournant la **révolution probabiliste**.

Il touche plusieurs domaines en même temps.

- **La reconnaissance de la parole.** Chez IBM, l'équipe de Frederick Jelinek remplace les règles de linguistes par des modèles statistiques appris sur des enregistrements. On lui attribue une phrase restée célèbre : chaque fois qu'il renvoyait un linguiste, son système s'améliorait.
- **La traduction automatique.** Vers 1990, une autre équipe d'IBM traduit par des probabilités apprises sur des textes déjà traduits, au lieu d'écrire des règles de grammaire.
- **Les filtres anti-pourriel.** En 2002, l'essai de Paul Graham, « A Plan for Spam », popularise le classifieur bayésien de la section précédente, que la plupart des messageries adoptent ensuite.
- **Le raisonnement en général**, avec les **réseaux bayésiens** (*Bayesian networks*) de Judea Pearl, présentés ci-dessous.

Du classifieur naïf au réseau. On peut dessiner le classifieur bayésien naïf comme un graphe. Un nœud représente la classe, « pourriel ou non », et une flèche part de ce nœud vers chaque mot, parce que la classe influence les mots employés. Il n'y a aucune flèche entre les mots : c'est l'hypothèse naïve.

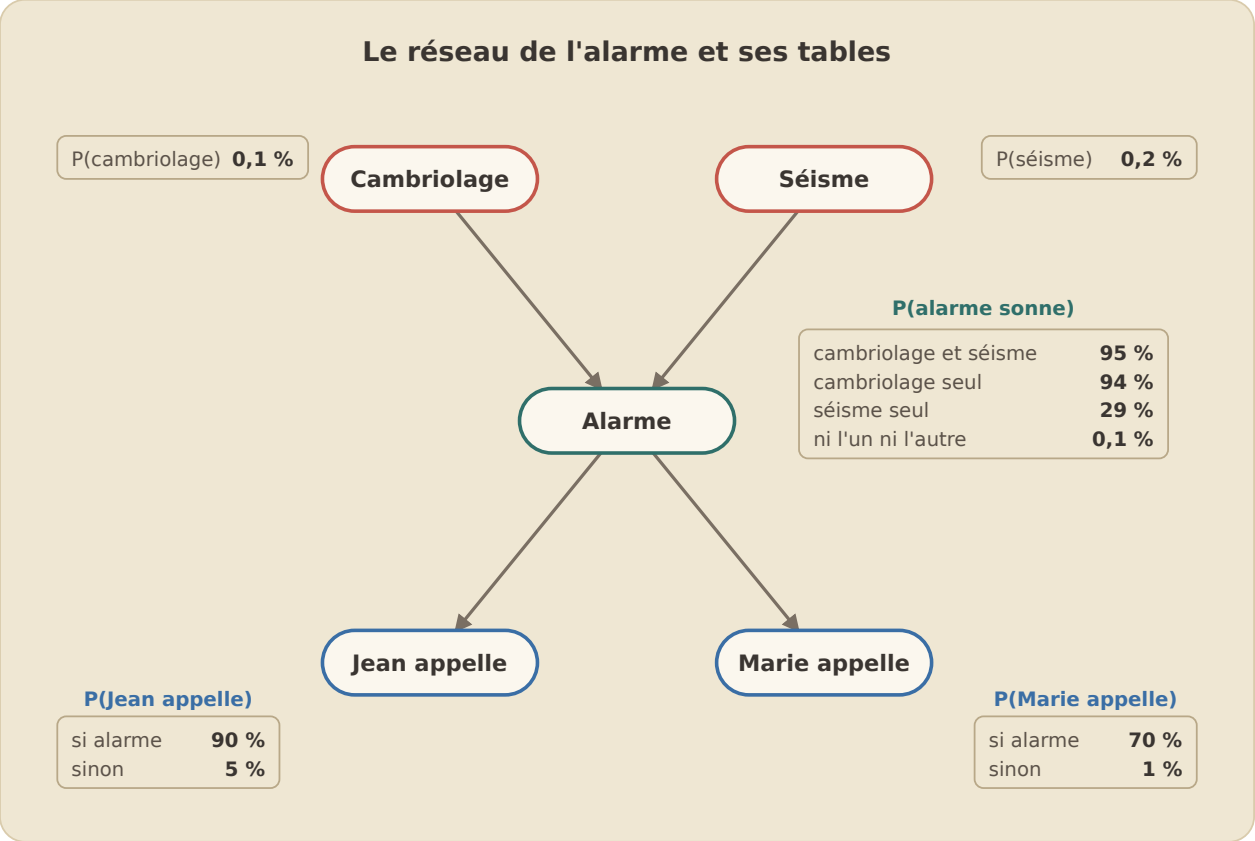


Le classifieur naïf est le plus simple des réseaux bayésiens ; un réseau plus riche dessine les dépendances réelles entre les variables.

Un **réseau bayésien**, proposé par Judea Pearl en 1985, généralise ce dessin. Chaque nœud est une variable incertaine. Chaque flèche indique une influence directe, en général d'une cause vers un effet. Chaque nœud porte une petite table, qui donne sa probabilité selon les valeurs de ses parents. Ces tables suffisent à calculer la probabilité de n'importe quel nœud, à partir de n'importe quelle observation.

Un exemple : l'alarme. Une maison a une alarme contre les cambriolages. Elle se déclenche aussi, parfois, lors d'un tremblement de terre. Si elle sonne, vos voisins Jean et Marie vous appellent peut-être. Jean appelle presque toujours, mais il appelle aussi parfois quand il confond l'alarme avec

la sonnerie de son téléphone. Marie entend moins bien, mais se trompe rarement.



Le réseau de l'alarme : cinq variables, et une petite table de probabilités par variable.

Dans l'applet ci-dessous, cliquez sur un nœud pour indiquer ce que vous savez : vrai, faux ou inconnu. Les probabilités des autres nœuds sont recalculées aussitôt.

Applet interactive : à utiliser en ligne, sur la page « Classer » du site du cours.

1. Sans aucune observation, la probabilité d'un cambriolage est de 0,1 %. Indiquez que l'alarme sonne. Elle passe à environ 37 %.
2. Indiquez ensuite qu'il y a eu un tremblement de terre. La probabilité du cambriolage retombe à 0,3 %. Le séisme explique l'alarme, et le cambriolage n'est plus nécessaire pour l'expliquer. Ce raisonnement s'appelle l'**explication concurrente** (*explaining away*). Pourtant, dans le réseau, cambriolage et séisme sont indépendants l'un de l'autre.
3. Effacez ces observations, puis indiquez seulement que Jean appelle : le cambriolage passe à 1,6 %. Avec Marie seule : 5,6 %. Avec les deux : 28 %. Deux indices faibles et indépendants, réunis, deviennent un indice fort.

Les flèches vont des causes vers les effets, mais le calcul va dans les deux sens. On part des effets observés, les appels, pour remonter vers les causes probables, le cambriolage ou le séisme. C'est le raisonnement d'un diagnostic, celui que MYCIN cherchait à mener avec ses règles. Le réseau le fait selon les règles exactes du calcul des probabilités.

Les réseaux bayésiens sont utilisés en diagnostic médical, en détection de pannes, en analyse de risques ou dans des filtres comme celui des pourriels. Pearl a ensuite cherché à distinguer, dans ces

graphes, les influences causales des simples corrélations. Ces travaux sur la **causalité** lui ont valu le prix Turing en 2011. La distinction entre corrélation et causalité sera reprise au Module 5.

Les mathématiques des réseaux bayésiens (optionnel)
Un réseau bayésien décrit la probabilité conjointe (*joint probability*) de toutes ses variables comme un produit de petites tables. Pour l'alarme, avec C (cambriolage), S (séisme), A (alarme), J et M (les appels) :

$$P(C, S, A, J, M) = P(C)\,P(S)\,P(A \mid C, S)\,P(J \mid A)\,P(M \mid A)$$

Avec cinq variables vrai ou faux, la table complète compterait 32 cases. Le réseau n'a besoin que de 10 nombres. Pour obtenir une probabilité comme $P(C \mid A)$, on additionne les cases compatibles avec l'observation, puis on divise :

$$P(C \mid A) = \frac{P(C, A)}{P(A)}$$

Ce calcul par énumération est exact, mais son coût double avec chaque variable ajoutée. Pour les grands réseaux, on utilise des algorithmes qui exploitent la forme du graphe, ou des méthodes d'approximation.

Sous les modèles, des probabilités

Avant de quitter la classification, il faut revenir sur une notion présente dans toute cette page, celle de **probabilité**. La régression logistique ne répond pas « bleu » ou « rouge », mais « bleu à 80 % ». Le classificateur bayésien compare lui aussi deux probabilités. Ce n'est pas un simple détail d'implantation. Un modèle qui donne une probabilité exprime une **croyance** avec son degré de certitude, et cette information est souvent plus utile que la seule décision. Un filtre qui rejette un courriel à 51 % n'indique pas la même chose qu'un filtre qui le rejette à 99,9 %. De plus, le seuil que nous déplacerons dans *Bien évaluer un modèle* n'existe que parce que le modèle exprime une incertitude. Il faut cependant que ces probabilités soient fiables : parmi les courriels qu'un bon modèle rejette « à 90 % », neuf sur dix doivent réellement être des pourriels. Cette propriété s'appelle la **calibration**, et on peut la vérifier.

Cette notion va plus loin. Rappelez-vous la fonction d'erreur de la droite, la moyenne des carrés des écarts, et celle de la régression logistique, qui pénalise d'autant plus le modèle qu'il se trompe avec assurance. Ces deux fonctions semblent sans rapport, mais elles découlent d'un même principe, l'un des plus importants de la statistique : le **maximum de vraisemblance** (*maximum likelihood*). Au lieu de chercher les paramètres qui réduisent l'erreur, on cherche les paramètres sous lesquels les données observées étaient les plus probables. Si l'on suppose que les prix des maisons s'écartent de la droite selon une courbe en cloche, chercher la droite qui rend les vingt prix les plus probables revient exactement à minimiser les carrés des écarts. Si l'on suppose que chaque étiquette est tirée avec la probabilité annoncée par le modèle, chercher les paramètres qui rendent les étiquettes observées les plus probables donne exactement la fonction d'erreur de la régression logistique. Minimiser une erreur et maximiser une vraisemblance sont donc deux descriptions de la même opération.

Nous avons employé le théorème de Bayes comme une formule, mais il décrit aussi une manière d'**apprendre**. On part d'une croyance *a priori*. Par exemple, avant de lire un courriel, on estime qu'il a une chance sur dix d'être un pourriel, parce que c'est la proportion habituelle. On observe

ensuite des indices, ici les mots du courriel, et le théorème indique comment **réviser** la croyance. La probabilité *a posteriori* est la croyance de départ, corrigée selon ce que les indices rendent plus ou moins probable. Chaque mot lu modifie un peu l'estimation : « gratuit » la rapproche du pourriel, « réunion » du courriel légitime. La probabilité a posteriori d'aujourd'hui devient ensuite l'a priori de demain. Dans cette perspective, apprendre consiste à mettre à jour ses croyances à mesure que les indices arrivent, et le théorème de Bayes est la règle exacte de cette mise à jour. L'approche bayésienne est présente dans tout le domaine, y compris dans les méthodes qui cherchent aujourd'hui à faire indiquer aux grands modèles leur degré de certitude.

Tous les modèles de cette page apprennent leurs paramètres à partir des exemples, en optimisant un critère : une fonction d'erreur, une marge ou une vraisemblance. Avant d'examiner la qualité de leurs prédictions sur des données nouvelles, la page suivante, « Poser des questions : les arbres de décision », présente un dernier modèle, d'un autre type, qui ne calcule pas mais pose des questions.

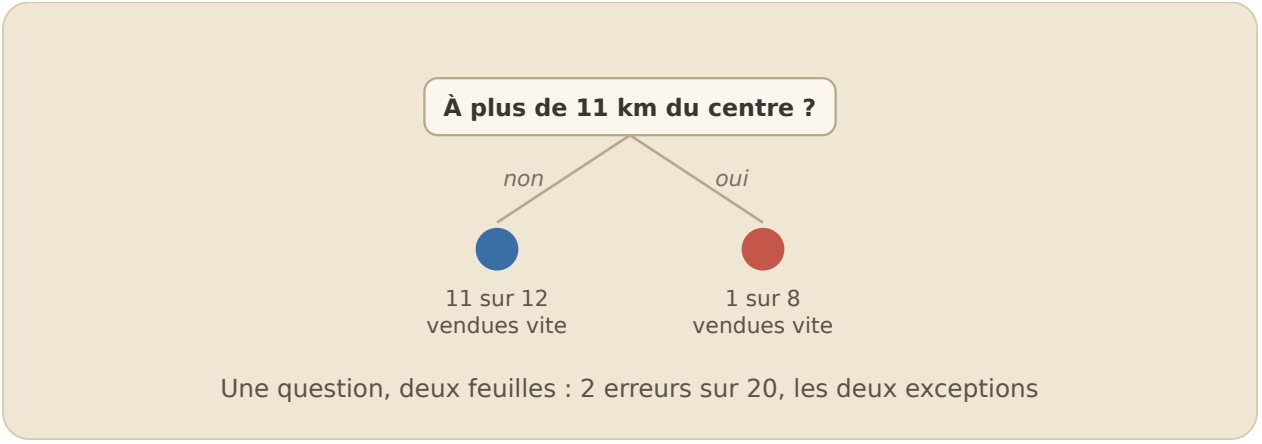
Poser des questions : les arbres de décision

Tous les modèles vus jusqu'ici raisonnent avec des nombres. kNN mesure des distances, la droite multiplie et additionne, la régression logistique et Bayes calculent des probabilités. Ces méthodes sont puissantes, mais ce n'est pas ainsi que nous prenons la plupart de nos décisions. Un médecin devant un patient ne fait pas de calcul : il pose des questions l'une après l'autre, et chaque réponse oriente la suivante. Le jeu des vingt questions fonctionne de la même façon. Un joueur pense à un objet, et l'autre doit le deviner en posant au plus vingt questions auxquelles on ne répond que par oui ou par non, comme « est-ce un animal ? » ou « est-il plus gros qu'un chat ? ». Chaque réponse réduit l'ensemble des possibilités. Le guide de dépannage à la fin d'un manuel suit le même principe : « l'appareil s'allume-t-il ? si non, est-il branché ? ». Il s'agit chaque fois d'une suite de questions à réponse oui ou non, qui se ramifie et aboutit à une conclusion.

Cette façon de décider correspond à l'un des modèles les plus anciens et les plus intuitifs de l'apprentissage automatique, l'**arbre de décision** (*decision tree*). Comme kNN, il traite aussi bien la régression que la classification, et son principe peut se dessiner. Il apporte cependant deux choses qu'aucun modèle du module n'offrait encore : une frontière qui n'est pas une droite, et une décision qu'on peut lire.

Une question suffit presque

Reprenons la seconde question du module dans le plan où elle se représente : la distance du centre en abscisse, l'année de construction en ordonnée, et la couleur qui indique si la maison s'est vendue vite. Laissons un arbre apprendre sur ces vingt maisons, avec une seule question permise. Voici le résultat :



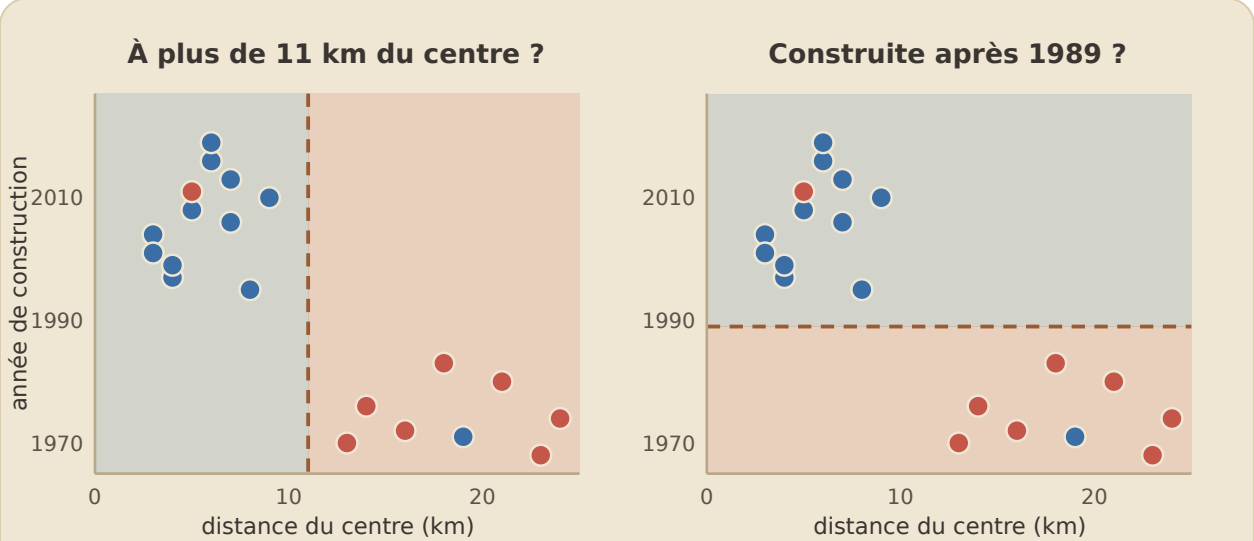
Un arbre à une question : une racine, deux branches, deux feuilles. Dix-huit maisons sur vingt bien classées.

La question est « à plus de 11 km du centre ? ». Si la réponse est non, la maison va dans la feuille de gauche, où 11 maisons sur 12 se sont vendues vite, et l'arbre répond *oui, vendue vite*. Si la réponse est oui, elle va dans la feuille de droite, où 1 maison sur 8 seulement s'est vendue vite, et l'arbre répond *non*. Avec une question et deux feuilles, 18 maisons sur 20 sont correctement classées. Les deux maisons restantes sont les deux exceptions déjà repérées dans le nuage coloré, chacune du mauvais côté de la question.

Le vocabulaire est celui d'un arbre dessiné à l'envers. La première question est la **racine**, chaque réponse est une **branche**, et les cases du bas, où l'on ne pose plus de question mais où l'on répond, sont les **feuilles**. Pour prédire, on part de la racine avec une nouvelle maison, on répond aux questions et on descend jusqu'à une feuille. La couleur majoritaire de cette feuille est la prédiction.

Dans le plan, une question sur la distance correspond à une **coupe verticale** à 11 km : tout ce qui est à gauche est bleu, tout ce qui est à droite est rouge. C'est le panneau de gauche de la figure ci-dessous, avec le même fond teinté que pour kNN. Comparez cette frontière à celle de kNN sur les mêmes maisons. La frontière de kNN était une ligne sinueuse entre les amas. Celle de l'arbre est un trait droit et vertical, parce qu'une question ne porte que sur une seule caractéristique à la fois.

On peut remarquer que l'arbre n'a rien demandé sur l'année de construction, alors que le nuage coloré semblait indiquer que les maisons anciennes se vendent lentement. Une question sur l'année aurait donné un résultat tout aussi bon, comme le montre le panneau de droite. La question « construite après 1989 ? » correspond à une **coupe horizontale**, et elle place les mêmes 11 maisons sur 12 d'un côté et 1 sur 8 de l'autre, avec les mêmes deux exceptions.



Deux questions à égalité : la coupe sur la distance et la coupe sur l'année classent les mêmes dix-huit maisons, et ratent les deux mêmes.

L'arbre disposait donc de deux questions équivalentes. Il n'en a pris qu'une, parce qu'une fois la première posée, la seconde n'apporte plus rien, sauf pour corriger les deux exceptions. De plus, l'arbre ne conserve pas les vingt maisons : une fois la question trouvée, il n'en a plus besoin. Il fait donc partie des modèles qui résument les données, comme la droite, et ses seuls paramètres sont un

seuil et deux réponses. La section suivante explique comment il a choisi entre les deux questions et, plus généralement, comment il choisit ses questions.

Comment l'arbre choisit ses questions

Le choix de la question repose sur un simple **comptage**. Pour chaque caractéristique et chaque seuil possible, l'arbre fait un essai : il sépare les vingt maisons en deux groupes et mesure, de chaque côté, à quel point les couleurs sont **mélangées**. Une feuille où toutes les maisons sont de la même couleur est dite *pure*. Une feuille où elles sont moitié-moitié est le pire cas, puisqu'elle ne donne aucune information. La meilleure question est celle dont les deux côtés sont, ensemble, les plus purs possible.

Le nombre de seuils candidats est limité. Entre deux maisons voisines sur une caractéristique, toutes les coupes donnent le même résultat, et il suffit d'essayer celle du milieu. Avec vingt maisons et deux caractéristiques, cela fait une quarantaine de questions à essayer. Un ordinateur les évalue toutes très rapidement et garde la meilleure. Sur nos maisons, la question « à plus de 11 km du centre ? » donne d'un côté 11 bleues sur 12 et de l'autre 7 rouges sur 8, soit deux feuilles presque pures. La question « construite après 1995 ? » aurait laissé 2 rouges parmi 11 d'un côté et 2 bleues parmi 9 de l'autre. Le mélange étant plus important, cette question est écartée.

Cela explique l'observation précédente. Les questions « construite après 1989 ? » et « à plus de 11 km du centre ? » obtenaient exactement le même score, 11 sur 12 et 1 sur 8. En cas d'égalité parfaite, l'arbre prend la première question trouvée. Il faut donc retenir que, lorsque deux caractéristiques apportent la même information, l'arbre en choisit une et ignore l'autre, sans que cela signifie que l'autre soit sans importance. Un arbre ne donne pas une explication du monde, mais un chemin de décision qui fonctionne.

Une fois la première question posée, on recommence séparément dans chacune des deux feuilles. On cherche la meilleure question pour les maisons proches du centre, puis la meilleure pour les maisons éloignées, et ainsi de suite, jusqu'à ce que les feuilles soient pures ou qu'on décide d'arrêter. Chaque question est choisie sans tenir compte des suivantes. Les informaticiens appellent cela une stratégie *gloutonne* (*greedy*, en anglais, le terme le plus souvent employé) : on choisit la meilleure étape immédiate, sans regarder plus loin. Cette stratégie ne garantit pas le meilleur arbre possible, mais elle est rapide et donne de très bons résultats en pratique.

Cet apprentissage diffère de ceux vus précédemment. Le modèle le plus bête calculait une moyenne. La droite et les modèles apparentés descendaient progressivement la pente d'une fonction d'erreur. L'arbre, lui, **cherche** : il énumère des questions, les essaie et garde la meilleure. Il n'y a ni paramètres ajustés de façon continue, ni gradient, mais une exploration parmi des choix discrets, semblable à la recherche dans un arbre de coups du Module 1, appliquée ici à l'apprentissage. C'est la troisième façon d'apprendre présentée dans ce module, et elle a la même structure que les deux autres : des données, une mesure de ce qui est bon (la pureté) et une procédure qui maximise cette mesure.

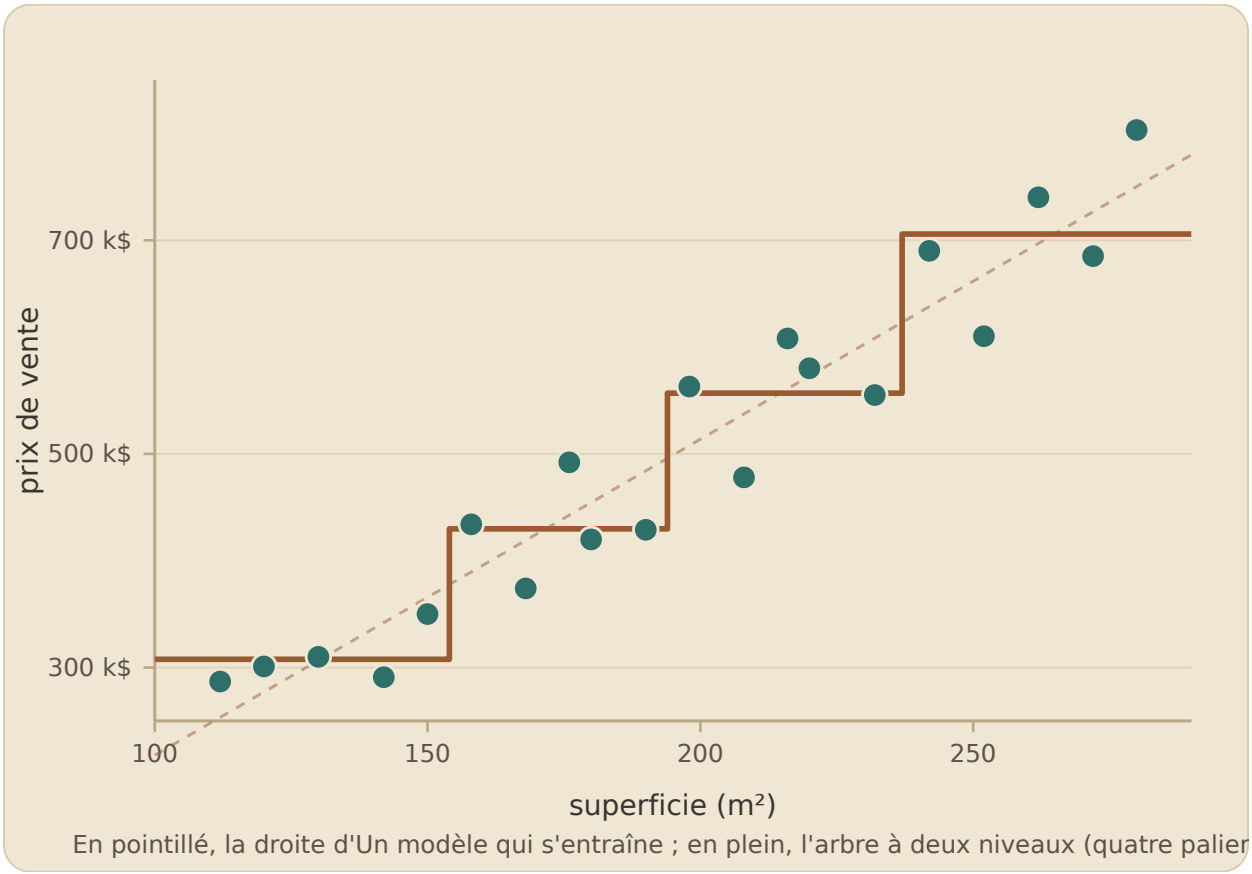
Pour aller plus loin : mesurer le mélange. La mesure la plus courante est l'*indice de Gini* (*Gini impurity*). Dans une feuille où une proportion p des maisons est bleue, il vaut $2p(1-p)$, soit 0 pour une feuille pure et 0,5 pour une feuille moitié-moitié. Le score d'une question est la moyenne des indices de ses deux côtés, pondérée par leur taille. Sur nos maisons, l'indice de départ vaut 0,48, et il descend à 0,18 après la question sur la distance. Une autre mesure,

l'*entropie*, issue de la théorie de l'information, donne presque toujours le même arbre.

Un arbre qui prédit un nombre

Rien de ce qui précède ne dépend du fait que la réponse soit une catégorie. Reprenons la première question du module, le prix, avec une seule caractéristique, la superficie. Un arbre peut la traiter de la même façon. Il pose des questions sur la superficie et, dans chaque feuille, il donne le **prix moyen** des maisons qui s'y trouvent au lieu d'une couleur majoritaire. Seule la mesure du mélange change. On regarde à quel point les prix d'une feuille sont dispersés autour de leur moyenne, et la meilleure question est celle qui réduit le plus cette dispersion de chaque côté.

Voici l'arbre à deux niveaux appris sur nos vingt maisons. La première question est « plus de 194 m² ? ». Pour les petites maisons, la question suivante est « plus de 154 m² ? » et, pour les grandes, « plus de 237 m² ? ». On obtient quatre feuilles et quatre prix : 308 000, 430 000, 557 000 et 706 000 $.



L'arbre de régression, dessiné sur le nuage : un escalier à quatre paliers, un par feuille. En pointillé, la droite, pour comparer.

Dessiné sur le nuage, l'arbre forme un **escalier** : quatre paliers horizontaux, un par feuille, avec une marche à chaque seuil. Cette courbe ne monte pas de façon continue, elle avance par sauts. Par exemple, entre 154 et 194 m², toutes les maisons valent 430 000 $, qu'elles fassent 155 ou 193 m². Pourtant, avec ses quatre paliers, l'escalier suit déjà mieux le nuage que la droite d'*Un modèle qui*

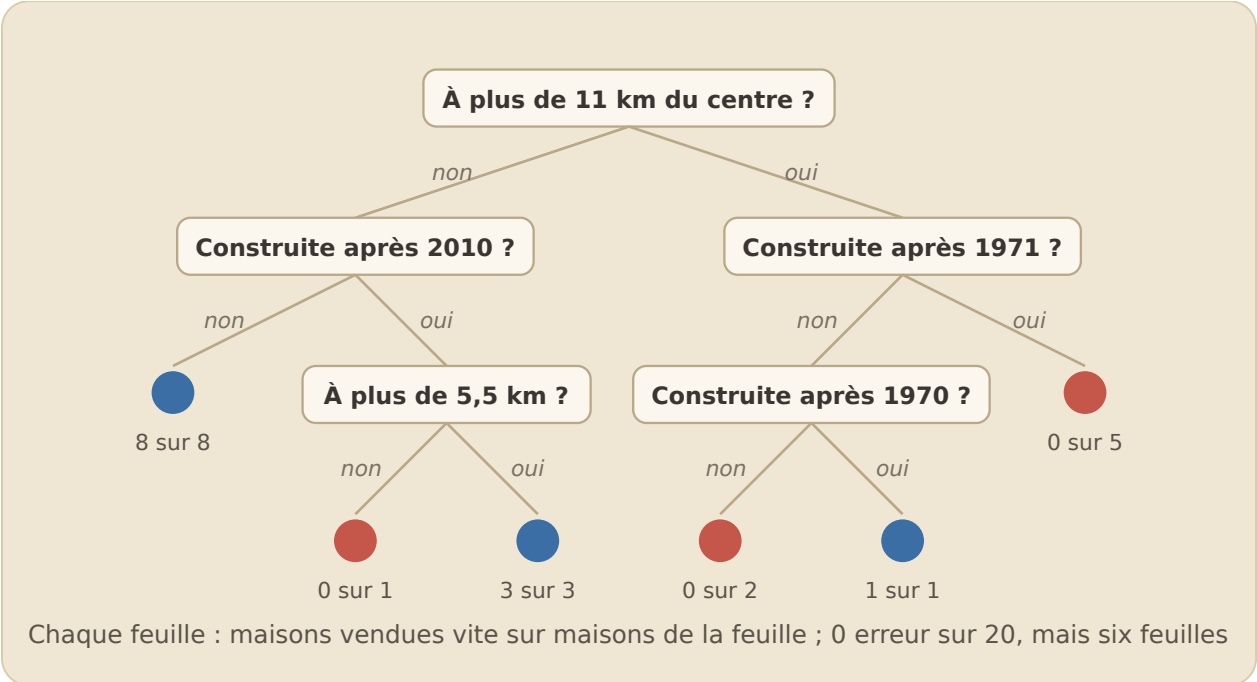
s'entraîne : son erreur moyenne est de 32 000 $, contre 41 000 pour la droite. Avec un niveau de plus, soit huit paliers, l'erreur descend à 23 000 $.

Cette comparaison met en évidence les différences entre les deux modèles. La droite suppose une forme précise, la ligne droite, et ne peut rien représenter d'autre. Si les prix suivaient une courbe, elle ne pourrait pas la suivre. L'escalier ne suppose aucune forme : avec assez de marches, il peut s'adapter à n'importe quelle forme. C'est sa force. Cependant, chaque palier est calculé sur un petit nombre de maisons, cinq ici, et c'est aussi sa faiblesse. La droite résume ses vingt maisons en deux nombres, alors que l'escalier les découpe en petits groupes traités séparément. De plus, l'escalier ne peut pas extrapoler : au-delà de 280 m², il répond toujours 706 000 $, alors que la droite continue de monter. Nous verrons dans *Bien évaluer un modèle* qu'on ne peut pas dire lequel des deux a raison hors du nuage, car aucun des deux n'offre de garantie dans cette zone.

Un arbre de régression utilise donc les mêmes questions et les mêmes feuilles qu'un arbre de classification, avec une moyenne à la place d'un vote. C'est la même distinction que celle que kNN avait présentée à sa dernière étape.

Jusqu'où laisser pousser l'arbre ?

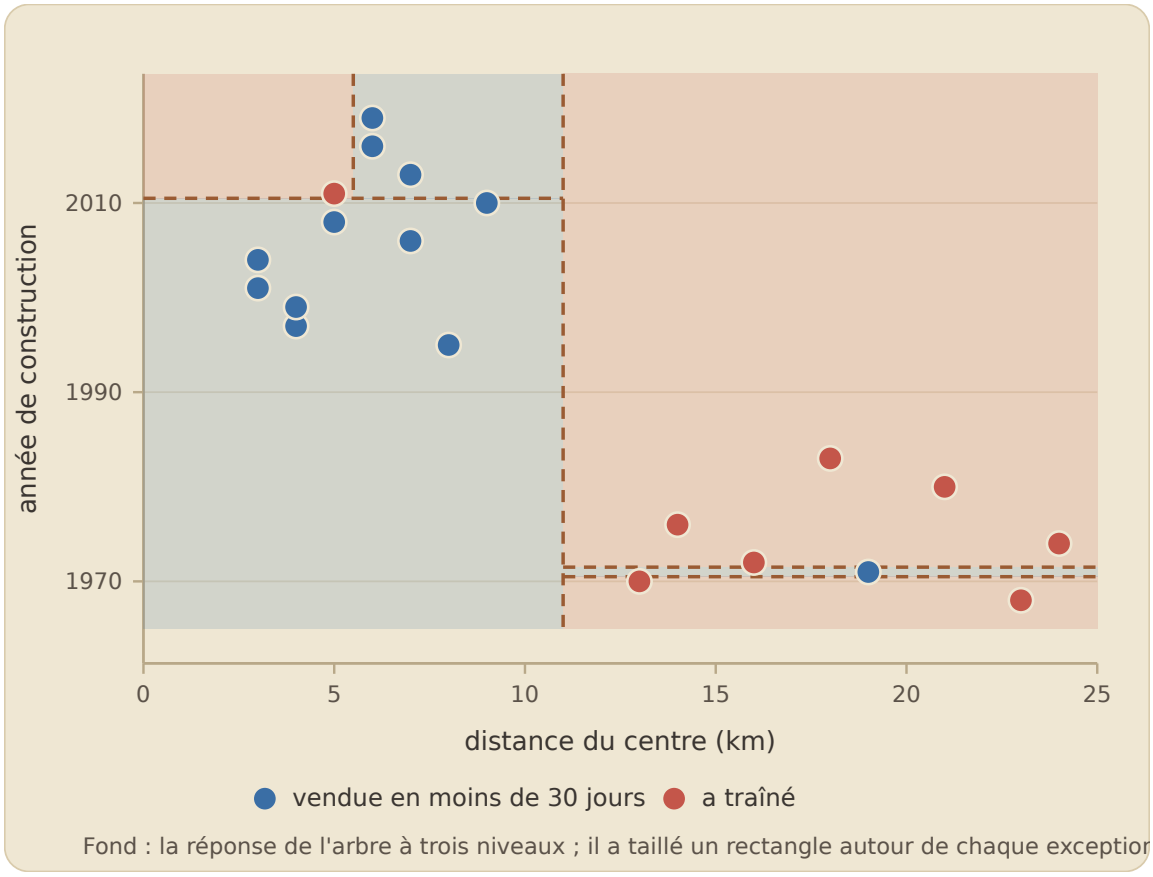
Revenons à la classification et laissons l'arbre poser d'autres questions. Après « à plus de 11 km du centre ? », il cherche une question dans chaque feuille, puis dans chaque nouvelle feuille, jusqu'à ce qu'aucune feuille ne mélange plus les couleurs. Voici l'arbre obtenu sur trois niveaux :



Le même arbre, laissé pousser sur trois niveaux : six feuilles, zéro erreur, et une feuille sur mesure pour chaque exception.

L'arbre compte maintenant six feuilles et ne fait plus aucune erreur. Il a trouvé le moyen de traiter les deux exceptions. Une question sur l'année, puis une question sur la distance, isolent dans sa propre feuille la maison ancienne qui s'est vendue vite. Deux questions de plus isolent de même la

maison récente qui s'est vendue lentement. Dans le plan, chaque question ajoute une coupe, et la frontière devient un assemblage de rectangles :



La frontière de l'arbre à trois niveaux : des rectangles, dont deux taillés sur mesure autour des exceptions.

Observez les deux petits rectangles découpés autour des exceptions. Ils correspondent aux îlots que kNN dessinait avec $k = 1$, dans *Prédire par ressemblance*. Il s'agit du même phénomène, dans un autre modèle. Un arbre sans limite continue de pousser jusqu'à ce que chaque feuille soit pure, au besoin en donnant une feuille à chaque maison. Il s'ajuste alors aux vingt maisons dans leurs moindres détails et traite comme des règles les deux cas qui font exception. Une nouvelle maison, ancienne et éloignée du centre, qui tomberait dans le rectangle de l'exception serait déclarée « vendue vite » sur la base d'un seul exemple.

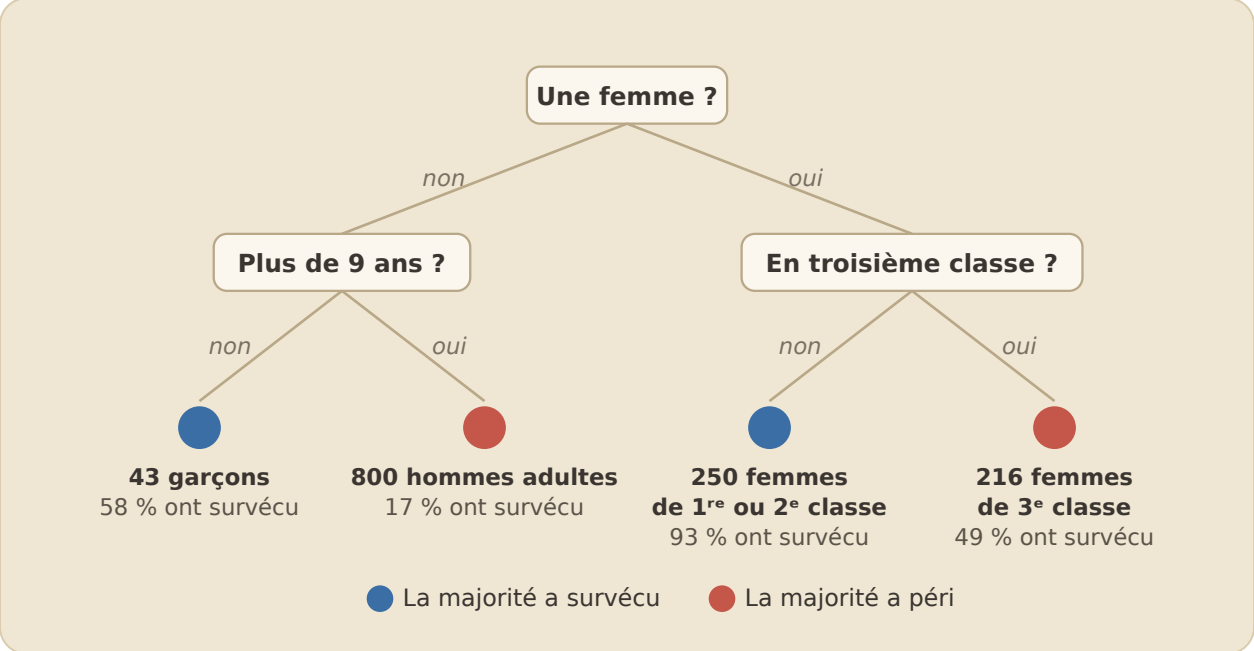
Il faut donc, pour l'arbre comme pour kNN, régler un paramètre : la **profondeur**, c'est-à-dire le nombre de questions que l'arbre peut poser à la suite. Avec une profondeur trop faible, l'arbre est grossier : sur des données où les deux amas seraient moins nets, une seule coupe verticale ne suffirait pas. Avec une profondeur trop grande, il apprend les exemples par cœur. C'est le sur-apprentissage (*overfitting*) déjà observé avec kNN, sous une autre forme, et *Généraliser* en fera son sujet principal. La bonne profondeur se situe entre les deux : elle permet de saisir les vraies régularités sans reproduire les cas accidentels. Rien, dans les vingt maisons, n'indique quelle est cette profondeur. Nous avons rencontré ce problème avec k, et nous le retrouverons pour tous les modèles dans *Généraliser*, où l'arbre servira d'exemple principal. Pour l'instant, retenez les deux façons de limiter un arbre : fixer une profondeur maximale, ou le laisser pousser puis **l'élaguer** (*pruning*), c'est-à-dire supprimer après coup les branches qui n'apportent que du détail.

L'applet ci-dessous vous permet d'en faire l'expérience. Elle présente des points rouges et bleus, un arbre appris en direct et le fond correspondant dans le plan. À droite, l'arbre lui-même se redessine à chaque changement. Faites varier la profondeur maximale de 1 à 8 et observez les rectangles se multiplier autour des points isolés. Ajoutez un point d'une couleur au milieu de l'autre couleur et observez comment l'arbre s'adapte. Survolez une zone du plan pour voir son chemin s'allumer dans l'arbre.

Applet interactive : à utiliser en ligne, sur la page « Poser des questions : les arbres de décision » du site du cours.

L'arbre du *Titanic*

Passons maintenant de nos maisons à des données réelles, celles que nous utiliserons à propos des fuites dans *Bien évaluer un modèle* : la liste des 1309 passagers du *Titanic*, avec pour chacun la classe, le sexe, l'âge et l'indication de sa survie. Trente-huit pour cent des passagers ont survécu. Le modèle le plus bête, qui répond « tout le monde meurt », obtient donc 62 % de bonnes réponses. Il sert de point de comparaison. Laissons un arbre apprendre sur ces passagers, avec deux niveaux de questions :



L'arbre du Titanic, appris sur les vraies données : trois questions, 79 % de bonnes réponses, et une histoire qu'on peut lire.

La première question que l'arbre trouve, sans aucune indication, est « une femme ? ». À elle seule, elle donne 78 % de bonnes réponses, soit seize points de plus que le modèle de comparaison. Les deux branches posent ensuite des questions différentes. Pour les hommes, la question est « plus de 9 ans ? » : les 43 garçons ont survécu à 58 %, les 800 hommes adultes à 17 %. Pour les femmes, la question est « en troisième classe ? » : celles de première et de deuxième classe ont survécu à 93 %, celles de troisième classe à 49 %. Avec trois questions, l'arbre obtient 79 % de bonnes réponses.

Ce que cet arbre a appris peut être lu par tous : « les femmes et les enfants d'abord », la consigne donnée cette nuit-là, avec une nuance que les historiens confirment. Les femmes de troisième classe,

logées dans les entreponts, loin des canots, ont eu une chance sur deux de survivre. L'arbre n'a utilisé aucune source historique. Il a seulement compté, et il retrouve en trois questions ce que les historiens décrivent. Cet exemple montre aussi le comptage appliqué à un cas ambigu. La feuille des femmes de troisième classe, à 49 %, est presque moitié-moitié, et l'arbre y répond « a péri » à une voix près. Un niveau de plus la découperait selon l'âge, sans gain important : au-delà de trois questions, le taux de bonnes réponses ne change presque plus. Sur ces données, l'essentiel tient en trois questions, et le reste est du détail.

Un dernier point sera repris dans *Bien évaluer un modèle* : ce taux de 79 % a été mesuré sur les passagers qui ont servi à l'apprentissage. Sur un jeu de test, il serait un peu plus bas, et avec un arbre plus profond, l'écart serait plus grand.

Ce qu'un arbre dit, et ce qu'il tait

Comme l'a montré l'exemple du *Titanic*, la grande force de l'arbre est qu'il peut **expliquer** ses décisions. Pour toute prédiction, le chemin de la racine à la feuille constitue la justification, et elle se lit directement : « une femme, en troisième classe, donc une chance sur deux ». Cette propriété s'appelle l'**explicabilité** (ou *interprétabilité* ; en anglais *explainability*, *interpretability*). C'est la capacité d'un modèle à rendre compte de ses décisions dans des termes qu'un humain peut comprendre, vérifier et contester. L'arbre est l'un des modèles les plus explicables, parce que le modèle est lui-même son explication : en le lisant, on sait pourquoi il donne telle réponse.

Aucun autre modèle de ce module n'offre cette propriété au même degré. La droite donne une pente, qui se comprend facilement. La régression logistique donne des poids associés à chaque caractéristique, qu'il faut interpréter. kNN donne une liste de voisins, qui décrit la décision sans la justifier. Les grands réseaux de neurones du Module 3 n'offriront rien de comparable : ils comptent des milliards de paramètres, dont aucun n'a de sens pris isolément. On parle alors de **boîte noire** (*black box*) : le modèle répond, souvent très bien, mais personne ne peut dire pourquoi. Tout un domaine de recherche, l'*IA explicable* (*XAI*, pour *explainable AI*), cherche aujourd'hui à analyser ces modèles après coup, en déterminant quelles caractéristiques ont compté dans une décision. L'arbre, lui, n'a pas besoin de cette analyse.

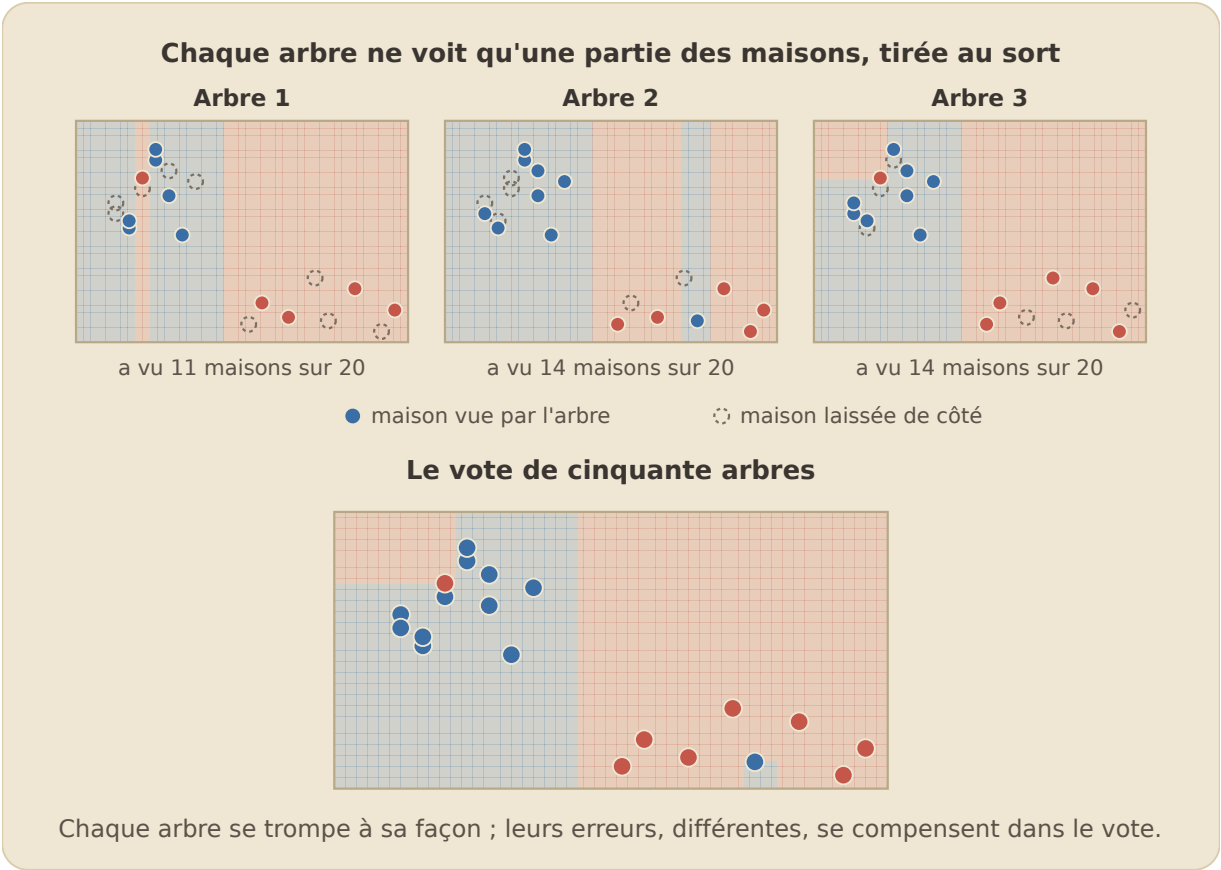
L'enjeu n'est pas seulement théorique. Dans les domaines où une décision doit pouvoir être contestée (un prêt refusé, un diagnostic, un dossier trié, une peine évaluée), un modèle qui ne peut pas expliquer ses décisions est difficile à accepter. La lisibilité compte alors davantage que quelques points de performance. C'est l'une des raisons pour lesquelles les arbres, apparus dans les années 1960 et mis au point en 1984 par quatre statisticiens (c'est la méthode CART, celle que nous avons suivie ici), sont toujours utilisés. Nous retrouverons cette opposition entre performance et explicabilité avec les grands modèles de langage du Module 4.

Les faiblesses de l'arbre découlent de sa méthode. D'abord, un arbre est **instable**. Rappelez-vous l'égalité entre la distance et l'année : si l'on retire deux maisons, la première question peut changer, et tout l'arbre avec elle. Deux jeux de données presque identiques peuvent produire deux arbres très différents, qui font pourtant à peu près les mêmes prédictions. Ensuite, ses coupes sont toujours parallèles aux axes, puisqu'une question ne porte que sur une caractéristique. Pour séparer deux amas le long d'une **diagonale**, l'arbre doit construire un escalier de nombreuses coupes, alors qu'une simple droite, comme celle de la régression logistique, y parviendrait en une fois. L'arbre est donc un modèle non linéaire, mais d'un type particulier, fait de marches.

La solution à l'instabilité est l'une des idées les plus productives du domaine, et elle se résume

simplement : si un arbre est fragile, on en utilise **cent**. On entraîne des centaines d'arbres, chacun sur une variante des données (un tirage au sort des maisons, un sous-ensemble des caractéristiques), puis on les fait voter ou on fait la moyenne de leurs réponses. Comme les erreurs des arbres sont différentes, elles se compensent, et la réponse collective est plus stable et plus juste que celle d'un arbre seul. C'est la **forêt aléatoire** (*random forest*), proposée par Leo Breiman en 2001. Une méthode apparentée et plus élaborée, le *gradient boosting*, construit chaque arbre de façon à corriger les erreurs des précédents. Sur des données en tableau (*tabular data*), comme nos maisons ou les passagers du *Titanic*, ces méthodes restent aujourd'hui parmi les plus performantes, et elles remportent la plupart des compétitions Kaggle dont parle *Bien évaluer un modèle*. Elles perdent cependant la lisibilité de l'arbre seul, car on ne peut pas lire cent arbres comme on en lit un.

La figure suivante illustre cette idée sur nos maisons. Trois arbres, chacun appris sur une partie des vingt maisons tirée au sort et laissé pousser sans limite, produisent trois frontières très différentes, avec des bandes et des îlots à des endroits différents. Si l'on fait voter cinquante arbres de ce type, ces particularités s'annulent, et il ne reste que ce sur quoi les arbres s'accordent.



La forêt aléatoire : chaque arbre ne voit qu'une partie des maisons et se trompe différemment ; le vote de cinquante arbres garde ce sur quoi ils s'accordent.

Deux cultures. Leo Breiman, l'inventeur de la forêt aléatoire, était un statisticien venu à l'apprentissage automatique. Il a tiré de ce parcours un texte devenu classique, « Statistical Modeling: The Two Cultures » (2001), annoncé dans la page d'accueil de ce module. Selon sa thèse, deux cultures se partagent l'analyse des données. La première, celle de la statistique classique, sup-

pose que les données ont été produites par un mécanisme simple qu'un modèle lisible peut décrire, et elle évalue le modèle selon sa fidélité supposée à ce mécanisme. La seconde, celle de l'apprentissage automatique, considère le mécanisme comme inconnu et n'évalue un modèle que sur la qualité de ses prédictions sur des données nouvelles. L'arbre seul appartient à la première culture, la forêt à la seconde. Breiman parle d'un **dilemme d'Occam**. Le rasoir d'Occam recommande de choisir le modèle le plus simple, mais sur des données réelles le modèle le plus précis est rarement le plus simple, et il faut alors choisir entre comprendre et prédire, alors qu'on voudrait les deux. Breiman relevait aussi une conséquence qu'il appelait l'**effet Rashomon**, du nom du film où quatre témoins racontent quatre versions du même crime : sur les mêmes données, des modèles très différents sont souvent également bons. Vous l'avez constaté avec nos maisons, que la distance et l'année séparaient aussi bien l'une que l'autre. Il n'existe donc pas un seul bon modèle, et l'explication fournie par un arbre n'est qu'une explication possible parmi d'autres. Il faut donc rester prudent envers un modèle qui s'explique : il décrit un chemin de décision qui fonctionne, et non le mécanisme réel du monde. Nous reviendrons sur cette question au Module 5, à propos de ce que signifie expliquer.

Et sur des données neuves ?

Récapitulons. Nous disposons maintenant de plusieurs modèles : une droite qui prédit un nombre, deux classificateurs qui prédisent une catégorie, et un arbre qui fait les deux en posant des questions. Nous avons aussi vu deux façons de les entraîner : minimiser une fonction d'erreur, ou chercher la question la plus pure. Chacun de ces modèles apprend en s'ajustant le mieux possible **aux exemples qu'on lui a montrés**.

Or ce n'est pas ce qui nous intéresse vraiment. Un filtre anti-pourriel qui classe parfaitement les courriels d'hier (ceux qui ont servi à l'entraîner) est inutile s'il se trompe sur ceux qui arriveront demain. Depuis le début de ce module, le but n'est pas de mémoriser des exemples, mais d'en tirer ce qu'il faut pour traiter des cas **encore jamais vus**.

Il y a là une difficulté. Un modèle peut ne faire aucune erreur sur ses données d'entraînement et faire beaucoup d'erreurs sur des données nouvelles, comme un étudiant qui aurait appris par cœur les réponses du corrigé sans comprendre la matière. C'est le sur-apprentissage (*overfitting*), déjà rencontré deux fois, que la page suivante, « Généraliser », traite en détail. Nous venons d'en voir l'exemple le plus net : l'arbre laissé pousser jusqu'à isoler chaque exception, qui ne se trompe plus sur les vingt maisons mais n'en a retenu que ce qu'il peut reproduire. Nous avions déjà rencontré ce problème avec kNN et le réglage de k : trop s'ajuster aux exemples peut être une faiblesse plutôt qu'une force.

Il faut donc savoir mesurer si un modèle a vraiment appris ou s'il a seulement retenu les exemples, et savoir éviter ce problème. C'est la question de la **généralisation**, qui fait l'objet de la page suivante.

Généraliser

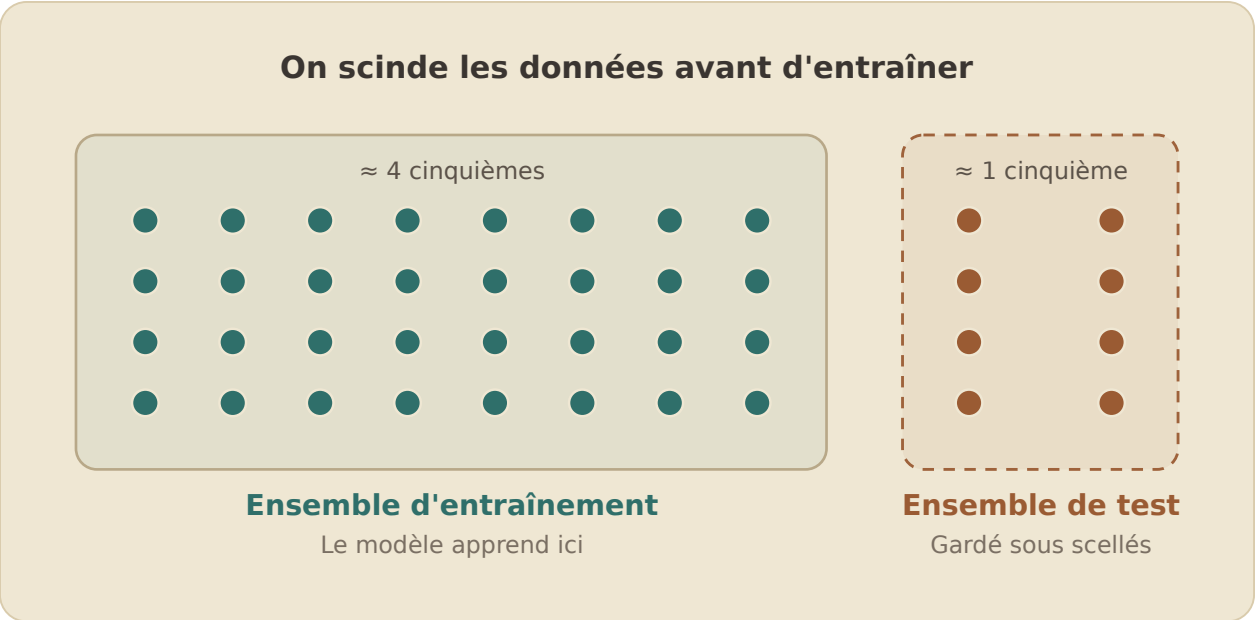
Le chapitre « Poser des questions : les arbres de décision » s'est terminé sur un doute. Nous savons maintenant entraîner plusieurs sortes de modèles (une droite qui prédit un prix, des classificateurs qui rangent en catégories), et tous apprennent de la même façon, en rendant leur erreur la plus petite possible sur les exemples qu'on leur montre. Ce résultat ne prouve cependant rien. Ce qui compte n'est pas qu'un modèle réussisse bien sur les données passées, mais qu'il se comporte bien sur des données nouvelles.

Le problème tient à une distinction. Un modèle peut avoir vraiment **appris** quelque chose des données, c'est-à-dire une régularité qu'il pourra appliquer ailleurs, ou s'être contenté de les **retenir**. Les deux cas se ressemblent beaucoup tant qu'on regarde les exemples d'entraînement. Ils ne se distinguent que devant des données nouvelles, et on découvre parfois alors qu'un modèle qui semblait bon ne vaut rien.

La capacité à bien se comporter au-delà des exemples appris s'appelle la **généralisation**. C'est elle, et non l'erreur d'entraînement, qui mesure la valeur réelle d'un modèle. Ce chapitre lui est consacré. Il explique comment la mesurer, pourquoi elle est difficile à obtenir et ce qu'elle révèle sur la nature des modèles.

Un modèle se juge sur ce qu'il n'a jamais vu

La solution est simple : **on cache des exemples au modèle.** Avant l'entraînement, on met de côté une partie des données, par exemple un cinquième. Le modèle apprend sur le reste, sans jamais voir cette réserve. Une fois le modèle entraîné, on l'évalue sur la réserve. Ces exemples sont nouveaux pour lui, mais nous connaissons les bonnes réponses. Sa performance sur cette réserve donne une estimation honnête de ce qu'il fera face à des données réellement nouvelles.



On sépare les données : le modèle apprend sur l'ensemble d'entraînement, et l'ensemble de test, mis de côté, sert à mesurer sa généralisation.

L'analogie de l'examen s'applique bien. Un enseignant qui noterait ses étudiants uniquement sur les questions distribuées d'avance pour la révision ne mesurerait pas grand-chose, parce qu'on peut apprendre ces réponses par cœur sans comprendre. C'est le sur-apprentissage (*overfitting*) de l'étudiant, et le jeu de test permet de le détecter. Pour évaluer la compréhension, il faut des questions nouvelles. On procède de la même façon avec un modèle.

Ces deux parties des données ont un nom. L'**ensemble d'entraînement** (*training set*) sert à l'apprentissage du modèle, et on y mesure l'**erreur d'entraînement**. L'**ensemble de test** (*test set*) reste à l'écart jusqu'à la fin et sert à mesurer l'**erreur de test**, la seule qui estime la généralisation. La règle d'or est qu'*on ne touche jamais au jeu de test pendant l'entraînement*. Si le modèle apprend, même indirectement, sur ses propres données d'examen, le test ne veut plus rien dire.

Lorsqu'il faut *régler* quelque chose (la valeur de k pour kNN, ou le taux d'apprentissage vu dans *Un modèle qui s'entraîne*), on ne peut pas non plus utiliser le jeu de test pour choisir, car il ne serait alors plus neuf. On réserve donc un troisième ensemble, l'**ensemble de validation** (*validation set*), consacré à ces réglages. Le jeu de test reste intact pour l'évaluation finale.

La règle d'or, à l'échelle d'aujourd'hui : les grands modèles de langage. Toute cette section suppose qu'on sait ce que le modèle a vu pendant l'entraînement. Pour un LLM, ce n'est plus vraiment possible. Ses données d'entraînement, des milliers de milliards de mots recueillis sur le Web, sont si vastes que personne n'en connaît le contenu précis, pas même ceux qui l'ont entraîné. Or les examens qu'on lui fait passer (un problème de mathématiques, une question d'un test standardisé, un exercice de programmation) ont très probablement circulé sur le Web, avec leur corrigé. On ne peut donc plus savoir avec certitude si le modèle a raisonné ou s'il a retrouvé la réponse. C'est le cas interdit par la règle d'or, un modèle qui a vu, même

indirectement, ses données d'examen, mais à une échelle où personne ne peut plus le contrôler. Il faut donc se méfier des scores impressionnants qu'on annonce.
Le problème ne concerne pas seulement la mesure. Au début du module, la question de la 1001e image reposait sur le fait de savoir si elle faisait partie des 1000. Pour un LLM, on ne peut plus répondre à cette question. Distinguer ce qu'un modèle sait déjà (parce que c'était dans ses données) de ce qu'il apporte de nouveau (parce qu'il généralise) est devenu, pour ces systèmes, une question ouverte, et en partie philosophique : où finit la mémoire, et où commence la compréhension ? Ce chapitre a posé cette question sur vingt maisons. Le Module 4 la reprendra à propos d'un modèle qui a lu une grande partie de ce que l'humanité a écrit.

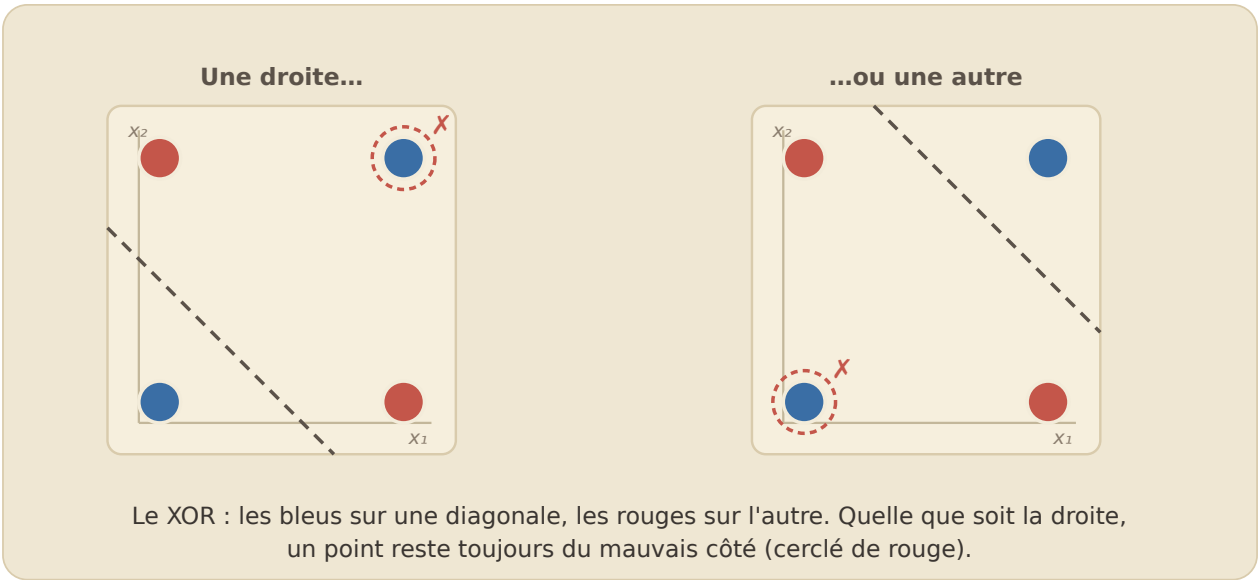
Linéaire ou non-linéaire : ce qu'un modèle peut dessiner

Revenons sur les modèles que nous avons construits. La régression linéaire d'*Un modèle qui s'entraîne* produit une droite. La frontière de la régression logistique est une droite. Celle de Bayes naïf est aussi une droite, comme nous l'avions remarqué. Même notre filtre anti-pourriel, malgré son grand nombre de mots, prenait une décision linéaire. Ces modèles ont donc un point commun.

Ils tirent tous leur décision d'une **somme pondérée** (*weighted sum*) des caractéristiques. Chaque attribut pousse d'un côté ou de l'autre, proportionnellement à son poids, et la décision dépend du total. Sur le plan géométrique, le résultat est toujours une droite (un plan en trois dimensions, un *hyperplan* au-delà). On appelle ces modèles des **modèles linéaires**.

La question est alors de savoir s'il existe des choses qu'**aucune droite** ne peut apprendre.

La réponse est oui, et vous connaissez déjà l'exemple le plus célèbre de cette limite. Le **perceptron**, présenté au Module 1, a été mis en échec sur ce point en 1969. L'exemple en cause est le **XOR**, *l'un ou l'autre, mais pas les deux*, la règle de l'interrupteur va-et-vient qui commande une lampe au bout d'un couloir. Si on place ses quatre cas dans le plan, les deux cas « éteint » se trouvent sur une diagonale et les deux cas « allumé » sur l'autre.



Le XOR : les bleus sur une diagonale, les rouges sur l'autre. Quelle que soit la droite, un point reste toujours du mauvais côté (cerclé de rouge).

Le XOR : quelle que soit la droite tracée, un point reste du mauvais côté. C'est la limite d'un modèle linéaire.

Quelle que soit la droite choisie et son inclinaison, il reste toujours un point du mauvais côté. Il ne s'agit pas d'un manque d'astuce, mais d'une impossibilité.

Il faut bien distinguer ce point de tout ce qui précède : **cet échec n'a rien à voir avec le bruit ni avec le manque de données**. Avec un million d'exemples parfaits, sans aucune erreur de mesure, un modèle linéaire échouera de la même façon. Le problème ne vient pas d'un mauvais réglage ni d'un manque d'entraînement. Il vient du **répertoire de formes** du modèle, qui ne contient pas la réponse. On appelle ce répertoire la **capacité** du modèle (ou son *expressivité*), c'est-à-dire l'ensemble des frontières qu'il peut dessiner. Un modèle linéaire ne peut dessiner qu'une seule famille de frontières, les droites.

kNN, au contraire, a une frontière qui peut prendre n'importe quelle forme. Elle peut entourer des îlots et contourner des groupes de points, car aucune contrainte de forme ne s'applique à elle. kNN résout le XOR sans difficulté, parce que chaque point regarde ses voisins et que les voisins d'un coin bleu sont bleus. kNN est donc un modèle **non-linéaire**, et c'était le premier que nous avons vu.

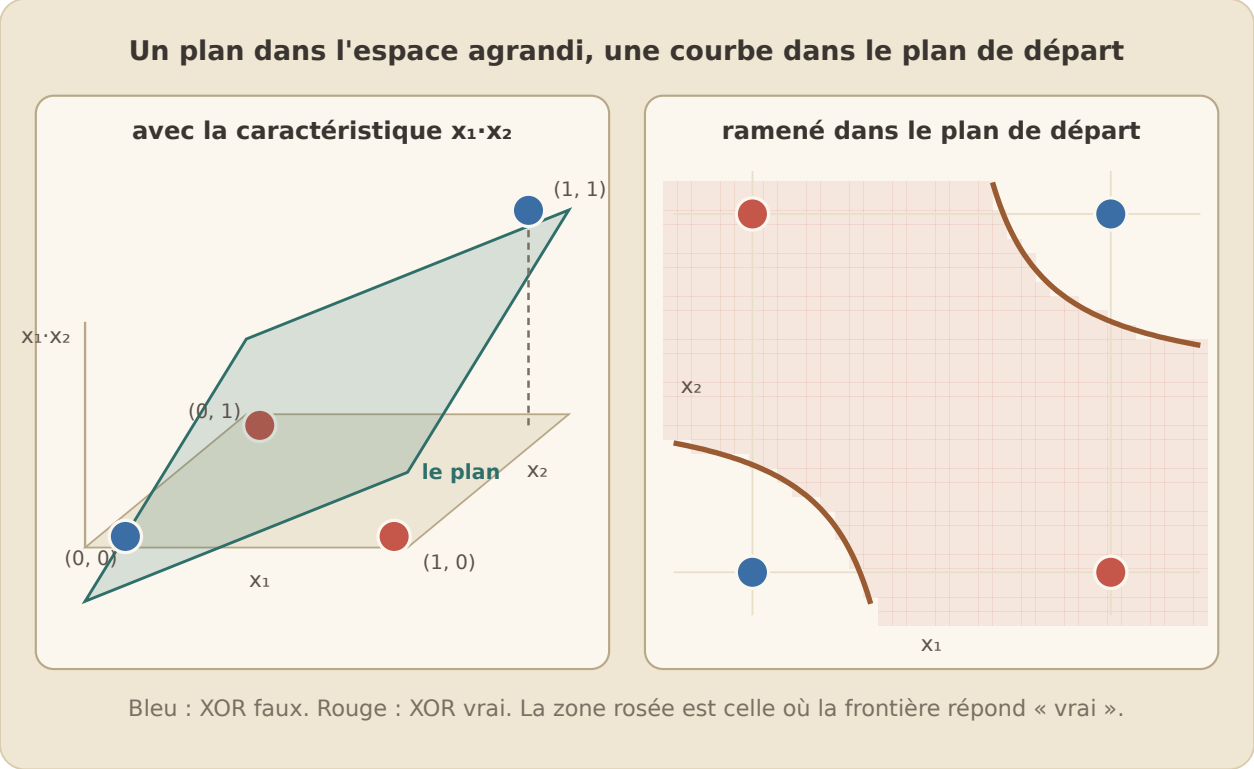
L'arbre de décision de la page précédente résout lui aussi le XOR, en deux questions, « à droite ? » puis « en haut ? ». Il obtient quatre rectangles, un par coin, soit la frontière que le perceptron ne pouvait pas tracer. Ses coupes parallèles aux axes sont une autre façon d'être non-linéaire, très différente de celle de kNN.

Il y a donc deux familles de modèles, et une question à se poser avant toute autre devant un problème : *la vérité que je cherche peut-elle tenir dans le répertoire de mon modèle ?* Si elle n'y est pas, aucun réglage et aucune donnée supplémentaire ne l'y mettront.

L'apprentissage automatique classique offre deux moyens de contourner cette limite. Le premier vient d'être présenté, il consiste à prendre un modèle non-linéaire comme kNN. Le second consiste à **construire soi-même la bonne caractéristique** (*feature engineering*). Si on ajoute aux deux entrées leur produit $x_1 \cdot x_2$, le XOR devient séparable par une droite dans ce nouvel espace. Cependant, c'est l'humain qui a dû trouver cette astuce, et il arrive que personne ne sache quelle caractéristique construire.

Ajouter des dimensions sans les calculer : l'astuce du noyau

La caractéristique $x_1 \cdot x_2$ résout le XOR, mais il a fallu la trouver. On peut contourner cette difficulté par la quantité : au lieu de chercher la bonne caractéristique, on en ajoute beaucoup, par exemple tous les produits et tous les carrés des entrées, $x_1 \cdot x_2$, x_1^2, x_2^2, et ainsi de suite. Dans cet espace agrandi, un modèle linéaire a beaucoup plus de chances de trouver une séparation par un plan. Et une séparation par un plan dans l'espace agrandi correspond à une frontière **courbe** dans le plan de départ.



Le XOR avec la caractéristique $x_1 \cdot x_2$: un plan le sépare dans l'espace agrandi, ce qui donne une frontière courbe dans le plan de départ.

Cette méthode a un coût. Le nombre de caractéristiques ajoutées explose avec le nombre d'entrées. Pour une image de 784 pixels, les seuls produits de deux pixels donnent déjà plus de 300 000 caractéristiques. Les produits de trois pixels en donnent environ 80 millions.

L'**astuce du noyau** évite ce calcul. Elle repose sur une propriété des SVM : pour trouver la frontière de plus grande marge, ils n'ont jamais besoin des coordonnées des points. Ils n'utilisent qu'une mesure de **ressemblance** entre deux points, calculée pour chaque paire. Or, pour de nombreux espaces agrandis, cette ressemblance peut se calculer directement à partir des coordonnées de départ, avec une formule simple appelée **noyau**, sans jamais construire les nouvelles caractéristiques. Le SVM travaille donc comme s'il disposait de millions de caractéristiques, sans en calculer aucune.

Le noyau le plus utilisé, le **noyau gaussien**, mesure la ressemblance de deux points par leur proximité : elle vaut 1 pour deux points confondus, et diminue rapidement avec la distance. Il correspond à un espace agrandi d'une infinité de dimensions. Un SVM équipé de ce noyau rappelle les plus proches voisins : un nouveau point est classé selon sa ressemblance avec les vecteurs de support, comme kNN le classait selon ses voisins. La différence est que le SVM ne garde que les vecteurs de support, et qu'il pondère leur influence pour obtenir la plus grande marge.

L'applet ci-dessous est celle de la section sur la marge, avec le jeu de points « XOR » et le noyau gaussien. Le curseur de portée règle la distance à laquelle deux points se ressemblent encore.

Applet interactive : à utiliser en ligne, sur la page « Généraliser » du site du cours.

1. Choisissez le noyau linéaire. Aucune droite ne convient, et des points restent mal classés.
2. Revenez au noyau gaussien. La frontière se courbe et sépare les quatre groupes.

3. Réduisez la portée. La frontière se met à entourer chaque groupe de près, et presque tous les points deviennent des vecteurs de support. C'est le sur-apprentissage (*overfitting*) de la section suivante.

L'idée du noyau date de 1964, avec les travaux de Mark Aizerman et de ses collègues à Moscou. Son union avec la marge maximale, en 1992 (Boser, Guyon et Vapnik), a fait le succès des SVM pendant les années 1990 et 2000.

L'astuce du noyau a pourtant deux limites. D'abord, c'est encore l'humain qui choisit le noyau, c'est-à-dire la façon de mesurer la ressemblance entre deux exemples. Le problème de la bonne caractéristique est déplacé, pas supprimé. Ensuite, le calcul porte sur toutes les paires d'exemples. Avec 10 000 exemples, cela fait 50 millions de paires. Avec un million d'exemples, cela devient impraticable. Ces deux limites expliquent en partie pourquoi les réseaux de neurones, qui apprennent leurs caractéristiques et s'adaptent bien aux très grandes quantités de données, ont fini par prendre le relais.

Le Module 3 reprend cette question, dans « Une couche cachée ». Les réseaux de neurones apprennent à **construire eux-mêmes** les caractéristiques qui rendent le problème séparable, en empilant des couches. La limite constatée en 1969 sera dépassée en 1986. C'est la question que le Module 1 avait laissée ouverte, et le Module 3 y répondra.

Cependant, la capacité de produire des frontières courbes n'est pas un avantage en soi. Un modèle capable de suivre n'importe quelle forme peut aussi suivre des formes qui ne correspondent à rien. C'est le sujet de la section suivante.

Trop coller, ou trop lisser : le compromis biais-variance

Nous venons de voir qu'un modèle doit être assez *expressif* pour que la vérité tienne dans son répertoire. L'excès inverse pose aussi un problème : un modèle trop souple finit par suivre le hasard autant que le signal. Pour observer ce compromis (et le mesurer, puisque nous savons maintenant le faire), revenons à kNN. Son seul réglage, le nombre de voisins k, contrôle directement la souplesse du modèle. Dans l'applet ci-dessous, faites glisser lentement k d'une extrémité à l'autre et observez la frontière.

Applet interactive : à utiliser en ligne, sur la page « Généraliser » du site du cours.

Avec $k = 1$, chaque point ne consulte que son plus proche voisin. La frontière se déforme pour entourer chaque exemple, forme des îlots autour des points isolés et suit tous les détails. L'erreur d'entraînement est nulle, puisque chaque exemple est son propre plus proche voisin. Cependant, cette frontière tient compte de tous les accidents des données. Pour un point un peu aberrant ou pour du bruit, elle se déforme quand même. C'est le **sur-apprentissage** (*overfitting*). Il correspond à l'étudiant qui a appris le corrigé par cœur, avec ses erreurs, sans le comprendre. Sur des données nouvelles, il se trompe.

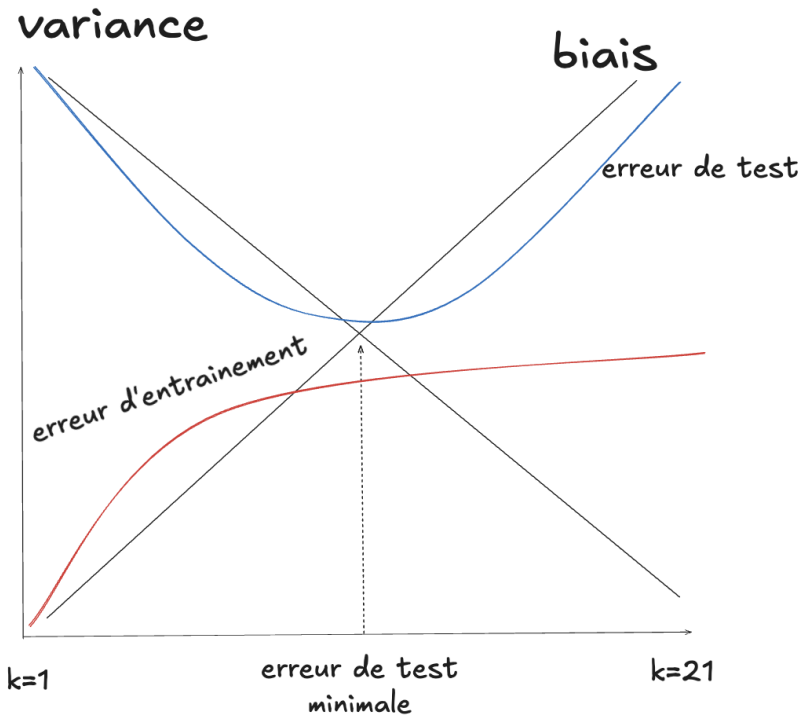
À l'autre extrême, avec k **très grand**, chaque prédiction fait la moyenne de tant de voisins que la frontière devient une courbe lisse, presque droite. Elle peut alors effacer des structures qui existent réellement dans les données. C'est le défaut inverse, le **sous-apprentissage** (*underfitting*) : le modèle est trop rigide pour suivre la forme réelle des données.

Il y a donc deux façons d'échouer, qui ont chacune un nom :

- la **variance** est la sensibilité du modèle au hasard de l'échantillon (du côté des petites valeurs de k). Si on change quelques points d'entraînement, un modèle à haute variance change complètement ;
- le **biais** est la rigidité propre au modèle (du côté des grandes valeurs de k), c'est-à-dire son incapacité *systématique* à représenter la forme réelle des données, quels que soient les points qu'on lui montre.

Qu'est-ce que le bruit ? Nous disons qu'un modèle trop souple « suit le bruit ». Cela signifie que les données ne sont jamais un signal pur. Le prix d'une maison est une tendance (plus la maison est grande, plus elle est chère) à laquelle s'ajoute une part aléatoire : l'humeur du vendeur, la saison, une négociation et beaucoup d'autres facteurs que le registre n'a pas notés. Nos vingt maisons ne sont pas sur la droite, elles sont autour, et l'écart de chacune correspond à ce bruit. Un bon modèle apprend la tendance et ignore le bruit. Un modèle trop souple apprend les deux, et le bruit qu'il a appris ne se reproduira pas pour la maison suivante, puisqu'il est aléatoire. La courbe en U présentée plus bas découle de cette idée : toute donnée contient une part qu'il ne faut pas apprendre.

Voici l'une des idées les plus importantes du domaine. Quand on rend un modèle plus souple (ici, en diminuant k), son erreur d'entraînement ne fait que diminuer, car un modèle flexible s'ajuste toujours mieux aux données qu'il a déjà vues. Son erreur de test suit au contraire une courbe en **U**. Elle diminue d'abord, parce que le modèle représente mieux les régularités réelles, puis elle **augmente** dès que le modèle commence à suivre le bruit. Le meilleur modèle se trouve au bas du U, à l'équilibre entre biais et variance.



L'erreur de test (en bleu) suit une courbe en U : trop de variance à gauche, trop de biais à droite. Le meilleur modèle est au creux.

Ce phénomène **n'est pas propre à kNN.** Chaque modèle a un réglage de souplesse : le nombre de termes d'une courbe plus souple qu'une droite (nous le verrons plus bas), la profondeur d'un arbre de décision ou le nombre de paramètres d'un réseau de neurones. Chacun présente la même courbe en U et le même arbitrage entre s'ajuster aux données et lisser. C'est le **compromis biais-variance** (*bias-variance tradeoff*), et savoir le régler est une compétence essentielle en apprentissage automatique.

Garder un modèle riche, mais le tenir en laisse : la régularisation

Le compromis biais-variance semble ne laisser qu'un seul moyen d'action, diminuer la souplesse du modèle, comme nous l'avons fait avec kNN en augmentant k ou avec l'arbre en limitant sa profondeur. Cette solution a cependant des limites. Elle restreint le modèle avant même qu'il ait vu les données, et le réglage est grossier, puisqu'il se fait par paliers. Or on veut parfois un modèle riche, capable de dessiner des formes compliquées si les données l'exigent, mais qui ne suive pas les moindres accidents des données.

Il existe une troisième approche, plus fine, qui se résume ainsi : **au lieu de limiter la souplesse du modèle, on la pénalise.** La fonction d'erreur vue dans *Un modèle qui s'entraîne* mesure à quel point le modèle se trompe sur les exemples, et l'entraînement consiste à la faire diminuer. On y ajoute un second terme, une **pénalité** qui augmente avec la *complexité* du modèle :

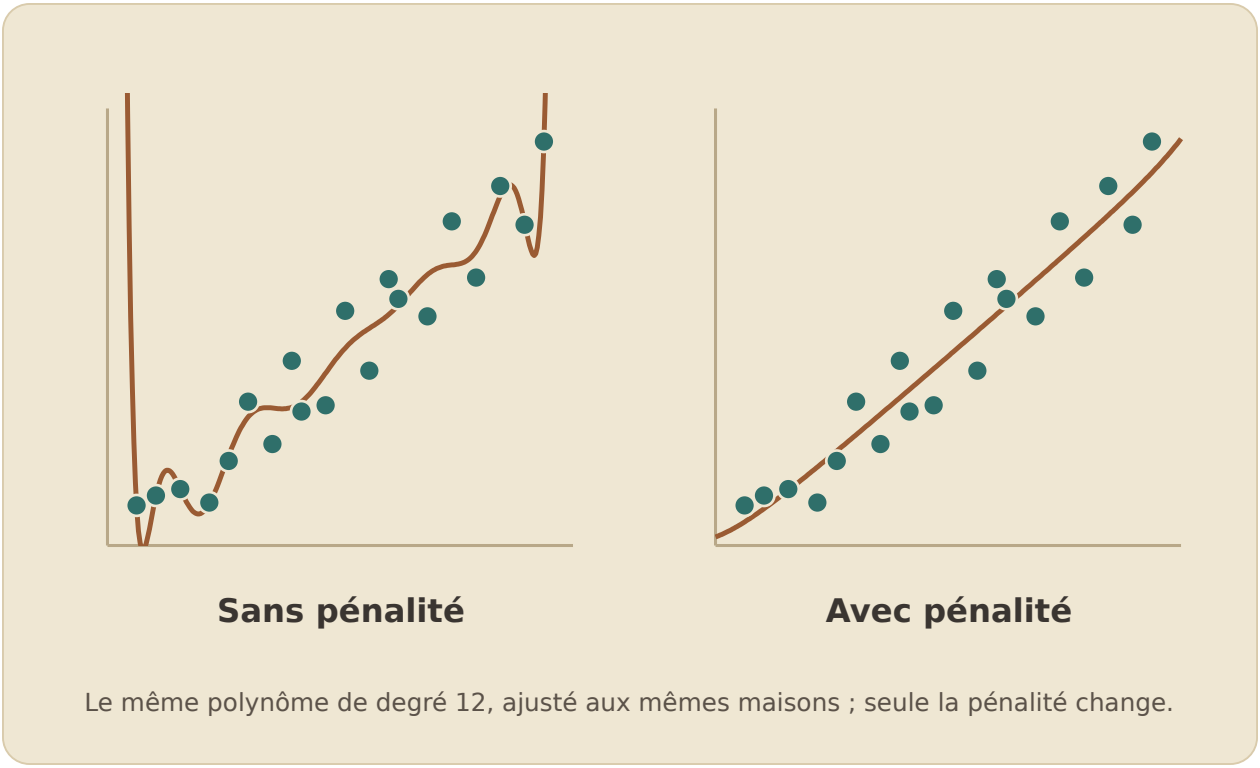
$$\text{erreur totale} = \text{erreur sur les données} + \lambda \times \text{complexité}$$

Le modèle doit alors trouver un équilibre. S'ajuster aux points fait diminuer le premier terme, mais augmente le second. Le modèle ne prendra une forme compliquée que si le gain le justifie. La descente de gradient va toujours vers le point le plus bas, mais dans un paysage modifié où les régions qui correspondent à des modèles trop compliqués ont été relevées.

Ce principe correspond à une idée vieille de sept siècles, le **rasoir d'Occam** : entre deux explications qui rendent compte des mêmes faits, il faut préférer la plus simple. La pénalité en est une traduction chiffrée. Elle n'affirme pas que le monde est simple. Elle impose qu'un modèle reste simple tant que les données n'exigent pas davantage, et que chaque complication apporte un gain visible. La courbe en U de la section précédente illustre expérimentalement ce principe : au-delà d'un certain point, la complexité supplémentaire ne sert qu'à apprendre du bruit.

Pour observer l'effet de la pénalité, il faut un modèle assez souple pour faire du sur-apprentissage (*overfitting*). Reprenons la droite d'*Un modèle qui s'entraîne* et rendons-la plus souple. Au lieu de prix $= m \times$ superficie $+ b$, on autorise aussi des termes en superficie², superficie³, et ainsi de suite jusqu'à la puissance 12. Une telle courbe s'appelle un *polynôme*, et chaque terme ajouté apporte un paramètre de plus, ce qui fait passer le modèle de deux à treize paramètres. Le réglage de souplesse est ici le nombre de termes, appelé le *degré*. Avec treize paramètres pour vingt maisons, la courbe peut facilement passer en zigzag entre les points.

Il reste à définir concrètement la complexité. La réponse la plus courante est simple : **la taille des paramètres.** Un polynôme qui passe en zigzag entre les points doit monter et descendre rapidement. Pour cela, il lui faut des coefficients très grands, qui se compensent presque entre eux et ne laissent apparaître que de petites bosses. Obliger les coefficients à rester petits oblige donc la courbe à rester régulière. La pénalité s'écrit alors comme la somme des carrés des paramètres, et le reste ne change pas : même modèle, même degré, même descente.



Même modèle, même degré ; seule la pénalité change. À gauche, le polynôme sans pénalité suit le bruit ; à droite, avec la pénalité, il suit la tendance.

Le nombre λ règle la sévérité de la pénalité. Avec une valeur nulle, on retrouve le modèle sans contrainte. Avec une valeur trop grande, tous les paramètres sont écrasés et on retombe dans le sous-apprentissage (*underfitting*), avec au bout du compte une droite horizontale. C'est un hyperparamètre de plus, et on le choisit comme les autres, sur l'ensemble de validation et jamais sur le jeu de test.

Cette idée porte des noms différents selon les modèles. Pour la droite et les modèles apparentés, on parle de *régression ridge* (pénalité sur les carrés) ou de *lasso* (pénalité sur les valeurs absolues, qui a la propriété de mettre certains paramètres exactement à zéro, et donc d'*éliminer* des caractéristiques). Pour les réseaux de neurones, on parle de *weight decay*, qui désigne le même terme. D'autres méthodes ne passent pas par la fonction d'erreur, mais visent le même but, empêcher le modèle de suivre le bruit. On peut arrêter l'entraînement avant que le modèle s'ajuste trop aux données (l'*arrêt précoce*, en anglais *early stopping*) ou désactiver au hasard une partie des neurones à chaque étape (le *dropout*). Pour l'arbre, l'**élagage** consiste à le laisser croître, puis à couper les branches qui n'apportent que du détail. Le Module 3 reviendra sur ces méthodes. Elles reposent toutes sur la même idée : la souplesse est une ressource, et un bon modèle est un modèle riche dont on contrôle la souplesse.

Une question reste ouverte pour plus tard. Si trop de souplesse nuit, comment les très grands réseaux de neurones actuels, qui ont des centaines de milliards de paramètres et donc une souplesse considérable, parviennent-ils à généraliser ? La réponse, qui remet en question la courbe en U, sera présentée au Module 3.

Paramétrique ou non-paramétrique

Il existe une seconde façon importante de classer les modèles. Elle ne porte pas sur leur souplesse, mais sur ce qu'il en reste une fois l'entraînement terminé. La question est de savoir si le modèle a **résumé** les données en un petit nombre de réglages ou s'il les **conserve**.

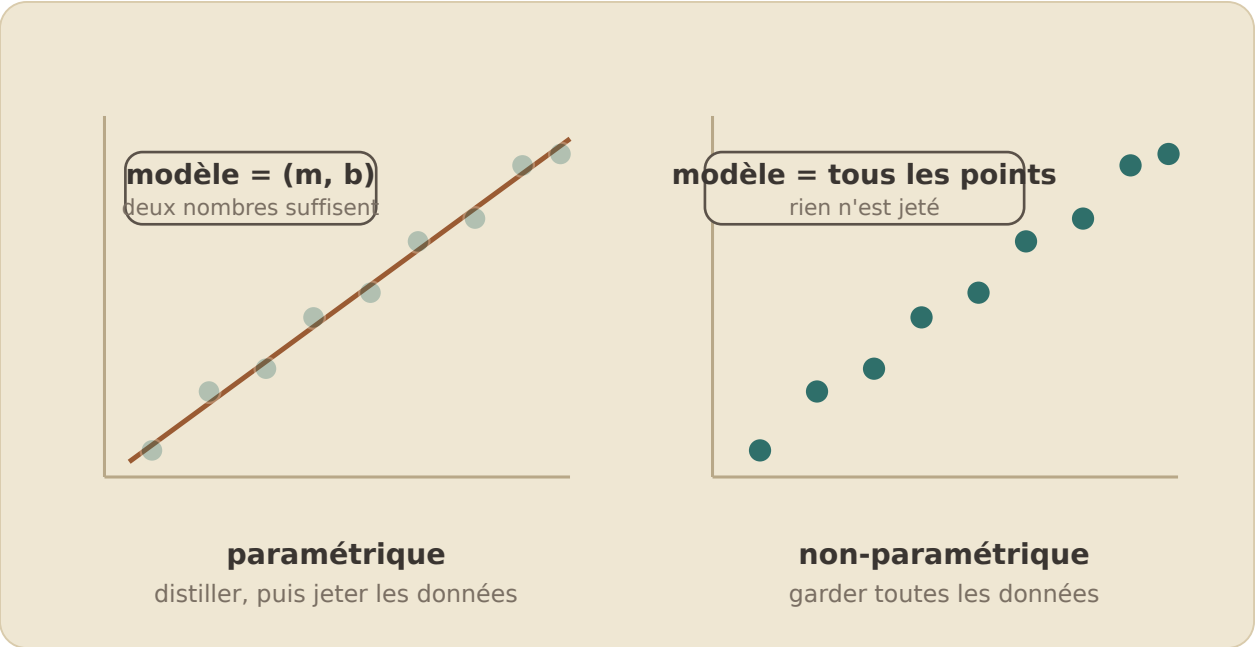
kNN, comme on l'a vu à propos de son angle mort, n'a rien à apprendre à proprement parler. Il n'a pas de paramètres à régler. Pour prédire, il consulte directement les exemples mémorisés, et les données constituent donc le modèle. Par conséquent, sa taille augmente avec le jeu de données. Avec mille exemples, il faut conserver mille exemples, et avec un million, un million. On dit d'un tel modèle qu'il est **non-paramétrique**, parce qu'il ne résume pas les données dans un nombre fixe de réglages et qu'il s'appuie directement sur elles.

À l'opposé, une fois la pente et l'ordonnée à l'origine de notre droite de régression trouvées, on peut **se débarrasser des données**. Il ne reste que deux nombres, m et b, et ils suffisent pour prédire. C'est aussi le cas de la régression logistique (un poids par caractéristique) et de Bayes naïf (une moyenne et une dispersion par classe, ou une probabilité par mot). Ces modèles sont **paramétriques**. Ils résument toute leur connaissance dans un ensemble de paramètres dont la taille est *fixée d'avance*, que l'apprentissage ait porté sur cent exemples ou sur cent millions. Cette distinction était déjà présente dans *Un modèle qui s'entraîne* : le modèle le plus bête résumait tout en *un* nombre, la droite en *deux*, et kNN en *aucun*. Il s'agissait déjà de l'axe paramétrique / non-paramétrique.

Chaque famille a ses avantages et ses inconvénients :

- le modèle **paramétrique** est léger et rapide pour la prédiction, et il généralise grâce à la compression qu'il impose aux données. Cependant, il *suppose une forme* (une droite, par exemple). Si la structure réelle des données n'a pas cette forme, aucun réglage ne corrigera le problème. C'est du **biais** ;
- le modèle **non-paramétrique** ne suppose presque rien sur la forme et peut représenter des structures très complexes. Cependant, il est lourd (il faut tout conserver), lent pour la prédiction et plus exposé au risque de suivre le bruit. C'est de la **variance**.

On retrouve ici le compromis biais-variance. Résumer les données ou tout conserver, supposer une forme ou suivre les données : il n'existe pas de réponse universelle. Il faut faire des choix adaptés au problème, et c'est une part importante du travail dans la discipline.



Paramétrique : résumer les données en quelques réglages, puis s'en débarrasser. Non-paramétrique : conserver toutes les données et s'appuyer dessus.

Nous savons maintenant ce qu'un modèle peut dessiner, jusqu'à quel point il faut le laisser se courber et comment contrôler sa souplesse. Il reste à mesurer tout cela correctement, car un score peut être trompeur de plusieurs façons. C'est l'objet de la page suivante, « Bien évaluer un modèle ».

Bien évaluer un modèle

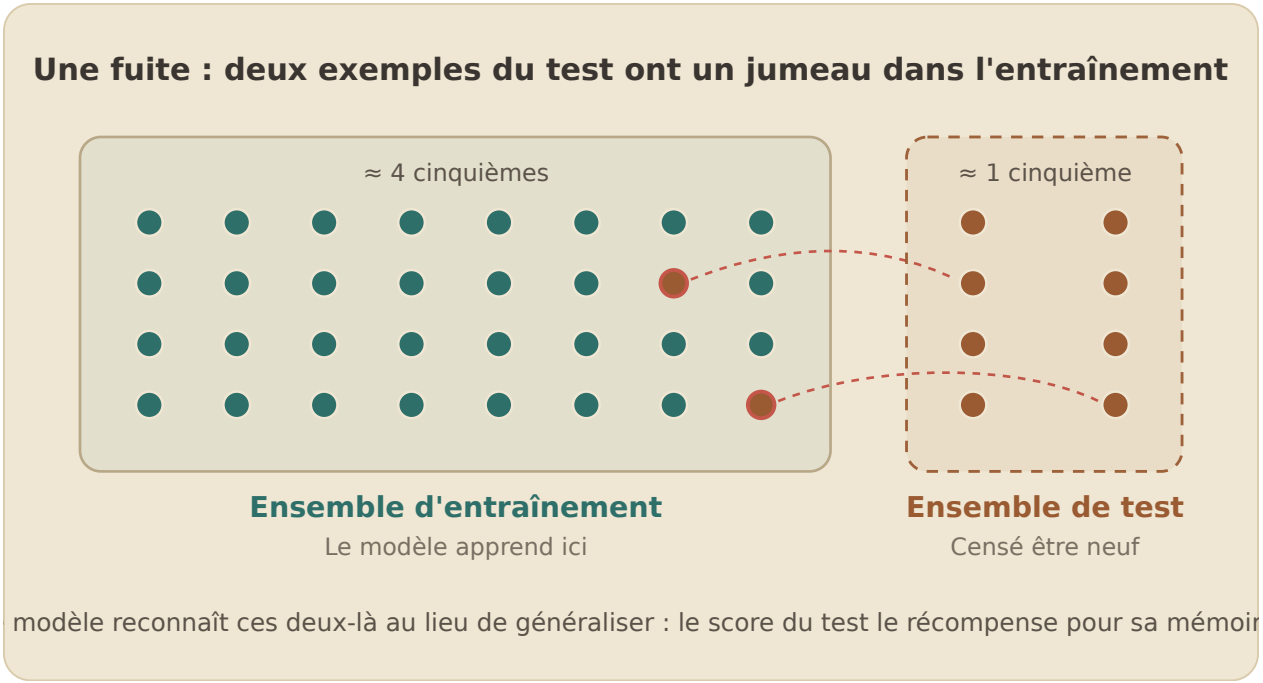
La page « Généraliser » a posé la règle d'or : on juge un modèle sur des exemples qu'il n'a jamais vus. Cette règle est nécessaire, mais elle ne suffit pas. Un score sur le jeu de test n'a de valeur que s'il est **honnête** (le modèle n'a-t-il vraiment rien vu du test ?), **fiable** (le score dépend-il du hasard du partage entre entraînement et test ?), **pertinent** (mesure-t-il ce qui coûte vraiment en cas d'erreur ?) et **valable** (s'applique-t-il aux données qu'on rencontrera réellement ?). Les quatre sections de cette page traitent ces quatre questions. Aucune ne demande de nouveau modèle. Toutes demandent de la méthode, et c'est surtout la méthode, bien plus que le choix d'un algorithme, qui distingue un modèle qui fonctionne d'un modèle qui semble fonctionner.

Le score trop beau pour être vrai : la fuite de données

Le premier piège est le plus courant et le plus difficile à repérer. Un modèle obtient 99 % de bonnes réponses sur le jeu de test, on le met en service, et ses résultats deviennent très mauvais. La cause est le plus souvent une **fuite de données** (*data leakage*) : une information qui n'aurait pas dû être disponible a été utilisée pendant l'entraînement, et le test n'était plus vraiment nouveau.

La fuite prend deux formes. La première est la **contamination** : le jeu de test contient, sous une autre forme, des exemples que le modèle a déjà vus. Par exemple, la même maison vendue deux fois en trois ans, une fois dans chaque ensemble, la même photo en deux résolutions ou le même courriel transféré à trois personnes. Le modèle ne généralise pas, il *reconnaît* les exemples, et le score récompense sa mémoire. À grande échelle, c'est le problème des grands modèles de langage présenté dans l'encart de la page précédente : quand les données d'entraînement couvrent tout le Web, on ne sait plus ce qui a fui.

La seconde forme est moins évidente. Il s'agit d'**une caractéristique qui contient la réponse**, ou dont on ne disposera pas au moment de prédire. L'exemple le plus connu vient du naufrage du *Titanic*, dont la liste des passagers est un classique des cours d'apprentissage automatique. On y prédit qui a survécu à partir de la classe, du sexe, de l'âge et du tarif payé. La version complète de cette liste, compilée à partir de l'*Encyclopedia Titanica* et hébergée par l'Université Vanderbilt, comporte deux colonnes de plus, le numéro du canot de sauvetage et le numéro d'identification du corps repêché. Si on les donne au modèle, il devient parfait, parce qu'avoir un numéro de canot signifie avoir survécu et qu'avoir un numéro de corps signifie être mort. Le modèle n'a rien deviné, il a lu la réponse, à peine cachée, dans les données. Nos maisons présentent le même piège. Pour prédire le prix, la « taxe foncière » donnerait d'excellents résultats, parce qu'elle est calculée à partir de la valeur de la maison.



Une fuite par contamination : deux exemples du test ont un jumeau dans l'entraînement. Le modèle les reconnaît, et le score récompense sa mémoire.

Il n'existe pas de détecteur automatique de fuites, mais il existe une méthode. D'abord, il faut se méfier : un score exceptionnel est un signal d'alerte avant d'être une bonne nouvelle, et la première question à poser est « qu'est-ce qui pourrait avoir fui ? ». Ensuite, il faut appliquer une règle systématique : **tout ce qu'on calcule à partir des données se calcule sur l'ensemble d'entraînement seulement**, qu'il s'agisse de moyennes, d'écarts, du choix des caractéristiques ou des réglages. Le jeu de test ne sert qu'une fois, à la fin, comme un examen qu'on ne corrige pas en cours de route.

Le jeu de test sous clé : Kaggle. Cette méthode existe aussi sous une forme institutionnelle. Sur Kaggle, la plateforme de compétitions d'apprentissage automatique, les participants reçoivent les données d'entraînement avec leurs réponses et les données de test *sans* leurs réponses. Les vraies réponses du test restent **privées**, et ce sont les organisateurs qui calculent le score de chaque soumission. Personne ne peut donc, même par erreur, entraîner son modèle sur l'examen. La plateforme va plus loin. Pendant la compétition, le classement public n'est calculé que sur une *partie* du jeu de test, et le classement final est calculé sur l'autre partie, gardée secrète jusqu'à la fin. Cette mesure empêche une fuite encore moins évidente, qui consiste à ajuster son modèle, soumission après soumission, au score affiché, jusqu'à s'ajuster au jeu de test sans l'avoir jamais vu. Les participants connaissent bien les changements importants de classement qui se produisent à la fin quand les deux parties donnent des résultats différents.

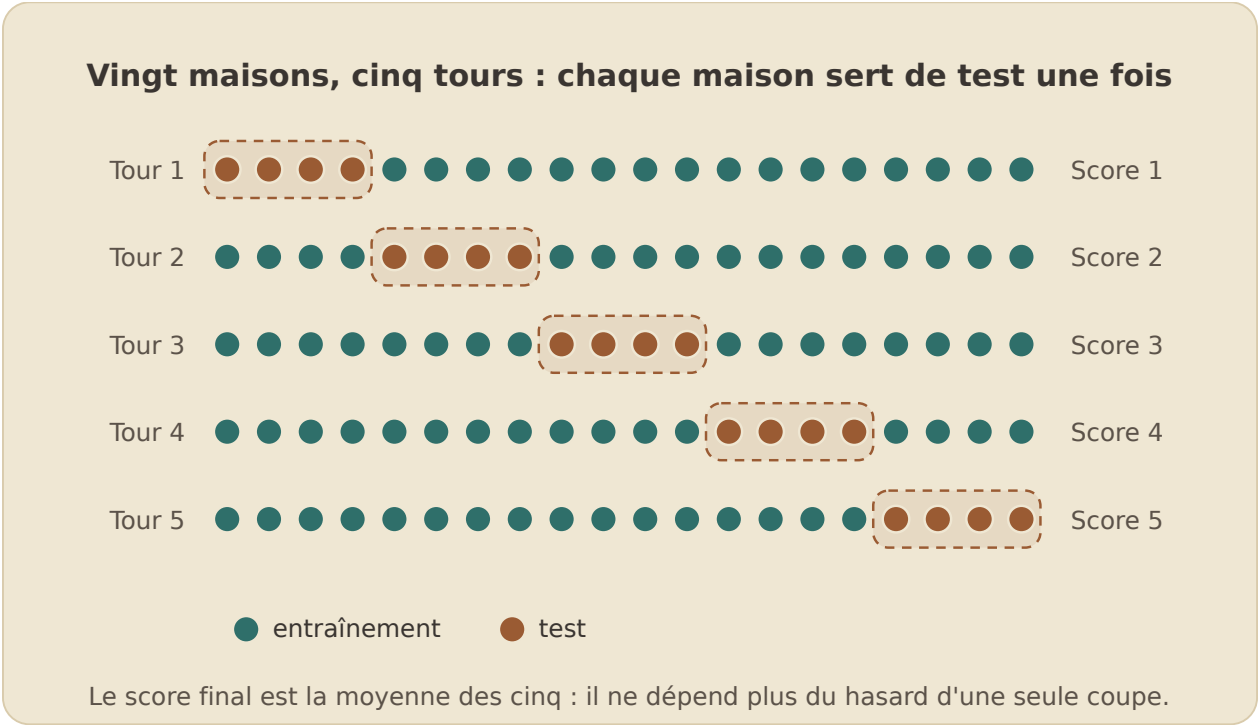
Une unité n'est pas l'autre : mettre à l'échelle. Cette règle a une application très concrète, que nous avons évitée sans la mentionner. Dans le plan des maisons, kNN mesure une distance qui combine une différence de kilomètres et une différence d'années. Or rien n'indique qu'un kilomètre « vaut » une année. Si on avait placé la superficie en mètres carrés à côté du nombre

de chambres, un écart de 50 m² aurait été beaucoup plus important qu'un écart d'une chambre, et la distance n'aurait plus eu beaucoup de sens. On corrige ce problème en **mettant à l'échelle** (*feature scaling*) chaque caractéristique, par exemple en la ramenant entre 0 et 1, ou en soustrayant sa moyenne et en divisant par son écart-type. La descente de gradient en profite aussi, car elle fonctionne mal dans une cuvette très étirée dans une direction. La règle s'applique ici aussi : les moyennes et les écarts utilisés pour la mise à l'échelle se calculent sur l'entraînement, puis s'appliquent tels quels au test.

Quand les données sont rares : la validation croisée

La deuxième question porte sur la fiabilité du score. Reprenons nos vingt maisons. Suivre la règle d'or revient à en mettre quatre de côté et à n'apprendre que sur seize. Cela pose deux problèmes. D'abord, seize maisons, c'est peu pour apprendre, et on voudrait utiliser les vingt. Ensuite, et surtout, le score dépend beaucoup du choix des quatre maisons mises de côté. Si ce sont les deux exceptions du nuage coloré, le modèle paraîtra mauvais. Si ce sont quatre maisons typiques, il paraîtra excellent. Le hasard d'un seul partage a donc trop d'influence.

La solution consiste à faire une **rotation** plutôt qu'un seul partage. On divise les vingt maisons en cinq groupes de quatre. Au premier tour, le premier groupe sert de test et les seize autres maisons servent à l'apprentissage. Au deuxième tour, c'est le deuxième groupe qui sert de test, et ainsi de suite. On obtient cinq tours et cinq scores, dont on calcule la moyenne. Chaque maison a servi de test exactement une fois, et chacune a servi à l'entraînement quatre fois sur cinq. C'est la **validation croisée** (*cross-validation*), et le nombre de groupes se choisit librement. On en utilise le plus souvent cinq ou dix, et jusqu'à n groupes d'un seul exemple quand les données sont très rares.



La validation croisée sur nos vingt maisons : cinq tours, chaque maison testée une fois, et le score final est la moyenne des cinq.

La validation croisée demande cinq entraînements au lieu d'un. C'est peu pour une droite, mais beaucoup pour un très grand réseau de neurones. C'est pourquoi on l'utilise souvent sur de petits jeux de données et presque jamais sur les très grands, pour lesquels un seul jeu de test suffit, parce qu'il est lui-même très grand.

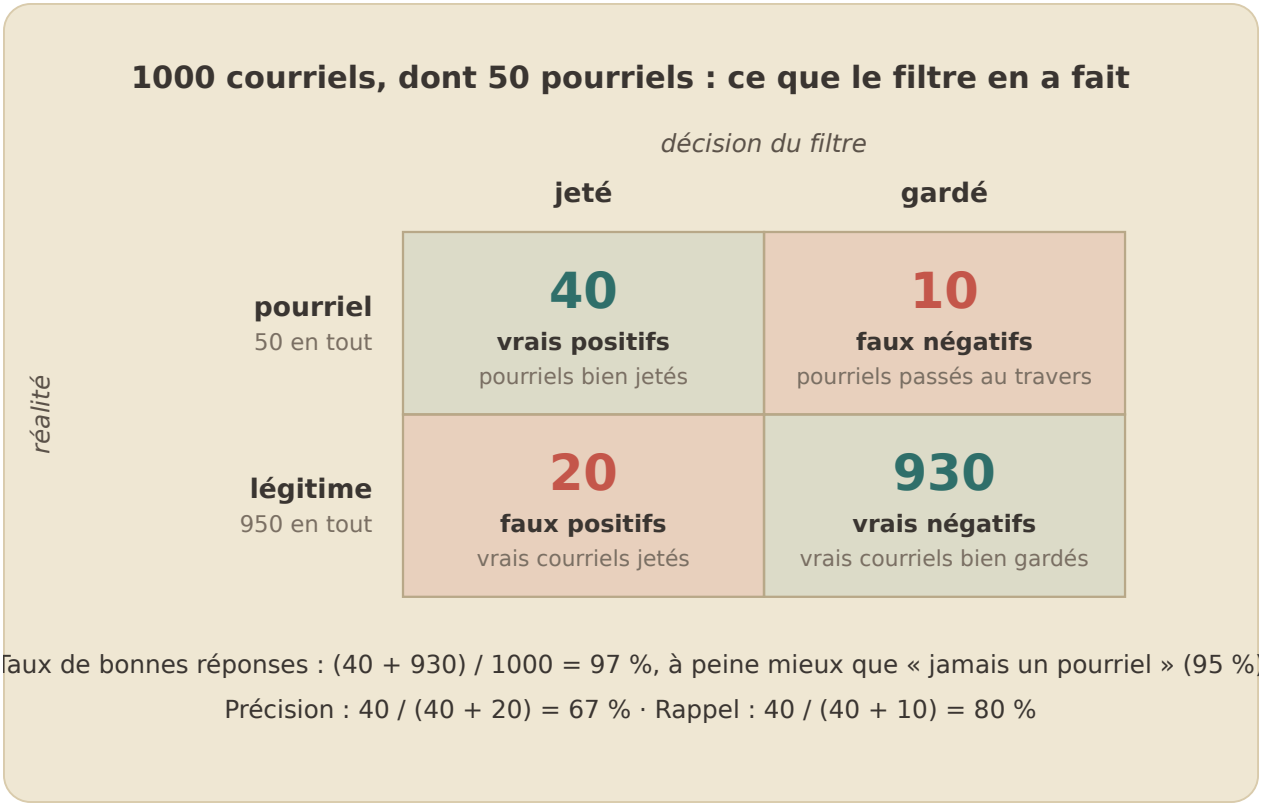
La validation croisée est aussi le cadre habituel d'une opération que nous avons faite plusieurs fois sans vraiment la nommer, le réglage de ce qui ne s'apprend pas. Le nombre de voisins k, la sévérité λ de la pénalité et le taux d'apprentissage de la descente ne sont pas des paramètres du modèle, et aucun n'est ajusté par la descente de gradient avec les autres. Ce sont des **hyperparamètres**, c'est-à-dire des réglages *de la procédure*, fixés avant l'entraînement. On les choisit en essayant plusieurs valeurs et en gardant celle qui donne le meilleur score de validation croisée. Ensuite seulement, on utilise le jeu de test pour l'évaluation finale. C'est le rôle de l'ensemble de validation de la page précédente, appliqué en rotation.

Compter juste : les métriques

La troisième question est de savoir si le score mesure ce qui coûte vraiment. Jusqu'ici, pour une catégorie, nous avons compté le **taux de bonnes réponses** (*accuracy*). Nous connaissons déjà son défaut. Dans *Le modèle le plus bête*, un filtre qui ne signalait *jamais* de pourriel obtenait 99 % de bonnes réponses, parce que les pourriels étaient rares. Un seul nombre ne peut pas indiquer à la fois combien de pourriels on intercepte et combien de vrais courriels on élimine. Il faut compter ces deux quantités séparément.

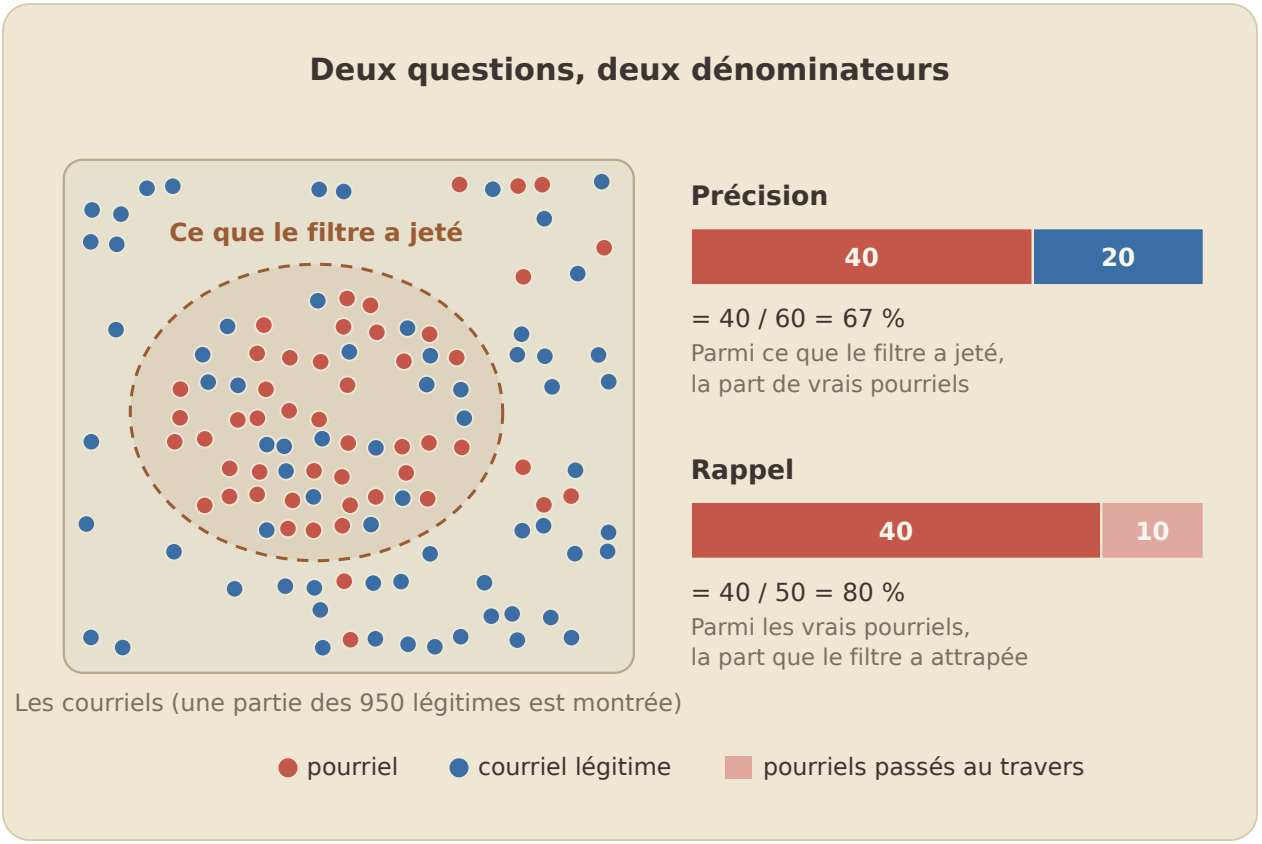
Prenons 1000 courriels, dont 50 pourriels, et un filtre qui en élimine une partie. Quatre cas sont possibles pour chaque courriel, et on les range dans un tableau appelé la **matrice de confusion** (*confusion matrix*) : un pourriel éliminé (**vrai positif**), un pourriel qui passe (**faux négatif**), un vrai courriel éliminé (**faux positif**) et un vrai courriel conservé (**vrai négatif**). Ici, « positif » signifie « signalé par le filtre » et n'indique pas un résultat favorable.

Ces deux types d'erreur ne sont pas propres à l'intelligence artificielle. La statistique les a nommés bien avant, en 1933, dans les travaux de Jerzy Neyman et Egon Pearson. L'**erreur de première espèce** consiste à voir un effet là où il n'y en a pas (notre faux positif), et l'**erreur de seconde espèce** consiste à manquer un effet réel (notre faux négatif). En anglais, on parle de *type I and type II errors*. Ces notions s'appliquent à tout test, de l'essai clinique au contrôle de qualité en usine. Un tribunal qui condamne un innocent ou acquitte un coupable commet ces deux types d'erreur. L'apprentissage automatique a repris ces notions avec son propre vocabulaire.



La matrice de confusion : quatre cases au lieu d'un seul score. Les deux cases rouges sont les deux types d'erreur, qui n'ont pas le même coût.

Ce filtre obtient 97 % de bonnes réponses, alors qu'un filtre qui ne signale jamais de pourriel en obtiendrait 95 %. Le taux global cache donc presque tout. Le tableau permet de répondre à deux questions plus précises, qui ont chacune un nom. La **précision** est la part de vrais pourriels parmi les courriels que le filtre a éliminés. Ici, elle est de 40 sur 60, soit 67 %, et le reste correspond à des courriels légitimes perdus. Le **rappel** (*recall*) est la part des vrais pourriels que le filtre a interceptés. Ici, il est de 40 sur 50, soit 80 %, et le reste est passé. On obtient ainsi deux nombres au lieu d'un, et ils varient en sens contraire.



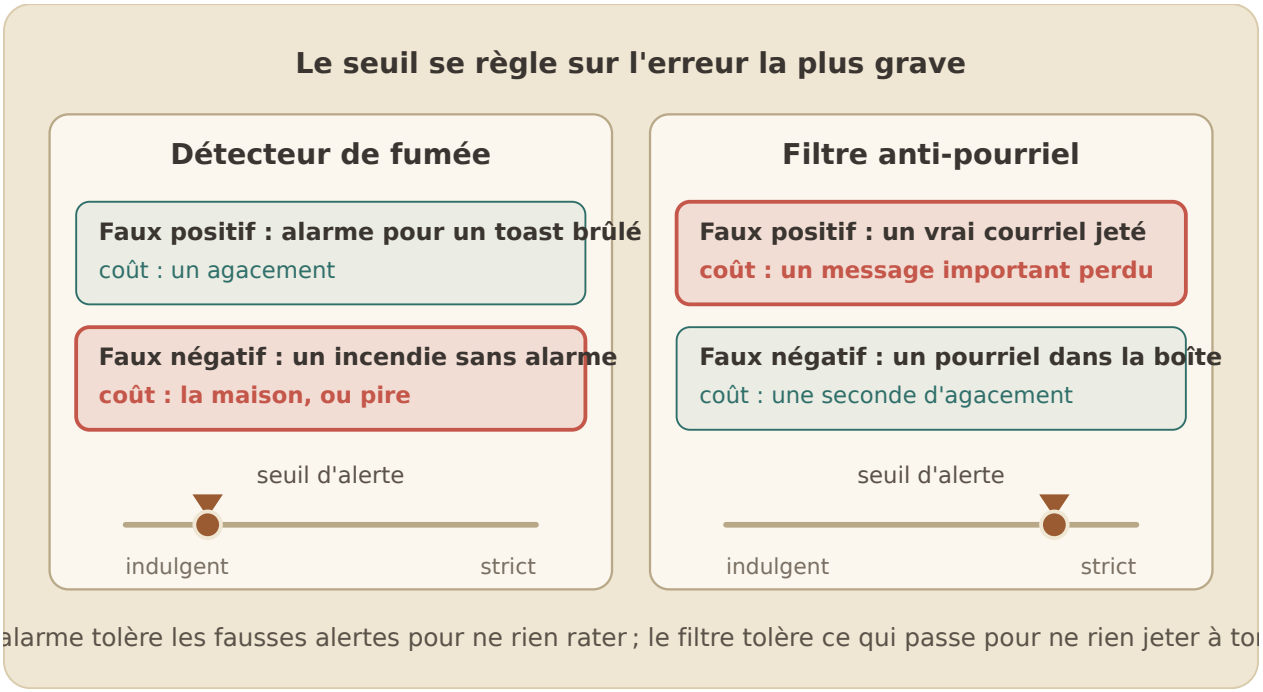
Précision et rappel, avec les nombres de la matrice : deux questions, deux dénominateurs. La précision se lit à l'intérieur du lasso ; le rappel, parmi les points rouges.

Ces deux termes ne viennent pas non plus de l'IA, mais de la **recherche d'information** (*information retrieval*), la discipline des catalogues de bibliothèque puis des moteurs de recherche. Pour une requête, un bon système retourne des documents *pertinents* sans y mêler de documents inutiles (la précision), et n'en oublie pas (le rappel). Dès les années 1960, on a fait de ces deux mesures la référence pour comparer les systèmes de recherche documentaire, et elles le sont restées. Précision et rappel forment aujourd'hui le vocabulaire commun de tous les systèmes qui *trient*. Un filtre anti-pourriel est d'ailleurs une forme de recherche, puisqu'il retrouve les pourriels parmi les courriels.

Ces deux mesures varient en sens contraire. La régression logistique de *Classer* donne une probabilité, et nous avons placé le seuil de décision à 0,5. Rien n'oblige à choisir cette valeur. Avec un seuil de 0,9, le filtre n'élimine que les courriels pour lesquels il est presque sûr, donc la précision augmente et le rappel diminue fortement. Avec un seuil de 0,1, il élimine un courriel au moindre doute, donc le rappel augmente et la précision diminue fortement. Le même modèle, sans nouvel entraînement, peut être strict ou tolérant, et ce choix dépend du problème et non des mathématiques. Pour un filtre anti-pourriel, un vrai courriel éliminé coûte plus cher qu'un pourriel qui passe, et on favorise donc la précision. Pour un test de dépistage, un malade non détecté coûte plus cher qu'une fausse alerte qu'un second examen permettra d'écarter, et on favorise donc le rappel.

Le cas d'un système d'**alerte** illustre bien ce choix. Un détecteur de fumée peut commettre deux erreurs, sonner pour un toast brûlé ou rester silencieux pendant un incendie. La première erreur cause un désagrément. La seconde peut coûter la maison, et parfois des vies. En raison de cette **asymétrie**, on règle l'appareil pour qu'il ne commette *jamais* la seconde erreur, même s'il commet

souvent la première. Un détecteur de fumée se déclenche sans raison plusieurs fois par année, et c'est voulu. Sa tolérance aux faux positifs n'est pas un défaut de conception. C'est le prix, accepté d'avance, d'un rappel proche de 100 %. Le filtre anti-pourriel suit le raisonnement inverse, parce que dans son cas c'est le faux positif qui coûte cher. Avec le même modèle et le même seuil réglable, on choisit des réglages opposés selon l'erreur qu'on ne peut pas se permettre. Ce réglage reste toutefois délicat, parce qu'il a deux extrêmes absurdes. Une alarme qui sonnerait *en permanence* ne manquerait aucun incendie, et un filtre qui n'éliminerait *aucun* courriel ne perdrait aucun message. L'une aurait un rappel parfait et l'autre une précision parfaite, mais les deux seraient inutiles, puisqu'ils ne trieraient plus rien. Tolérer l'erreur la moins grave ne veut donc pas dire l'accepter sans limite. On déplace le seuil du côté le plus sûr, mais seulement jusqu'au point où l'alerte garde un sens.



Le seuil se règle en fonction de l'erreur la plus grave. L'alarme tolère les fausses alertes pour ne rien manquer ; le filtre tolère les pourriels qui passent pour ne rien éliminer à tort.

Le travail noté vous posera cette question, *quelle erreur coûte le plus ?*, à propos d'un vrai filtre.

Pour une prédiction numérique, la même question se pose, de façon plus simple. L'erreur quadratique moyenne d'*Un modèle qui s'entraîne* est conçue pour être *minimisée*. Ses carrés sont pratiques pour la descente de gradient, mais difficiles à interpréter (ils sont exprimés en dollars au carré). Pour présenter les résultats, on préfère l'**erreur absolue moyenne** (*mean absolute error*). Sur nos vingt maisons, la droite se trompe de 41 000 $ en moyenne, et de 59 000 $ au maximum. Ces valeurs sont faciles à comprendre et permettent de juger si le modèle convient *à l'usage prévu*. Il est excellent pour obtenir un ordre de grandeur, mais insuffisant pour fixer un prix de vente.

Une métrique est donc un choix, qui définit ce qu'on considère comme une réussite. Avant de lire un score, il faut toujours savoir de quelle métrique il s'agit.

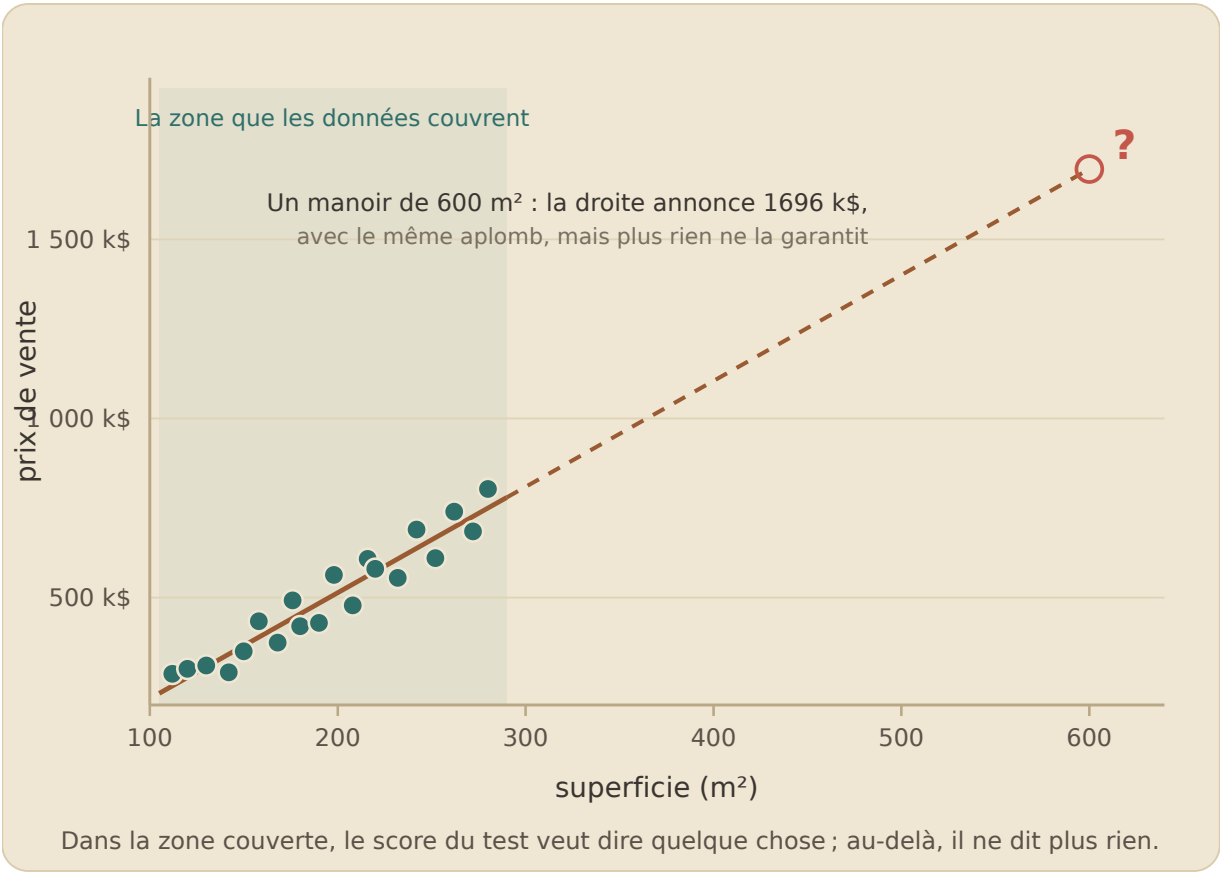
Jamais vu, mais du même monde : la question de la distribution

La dernière question est la plus facile à oublier. Il s'agit de savoir si le score s'applique aux données qu'on rencontrera réellement. Les sondages permettent de bien la comprendre. Interroger mille personnes pour connaître l'opinion de millions d'autres suppose que l'échantillon **ressemble** à la population, c'est-à-dire qu'il en est une version réduite. Quand ce n'est pas le cas, le sondage se trompe, même s'il paraît très sûr. L'exemple le plus connu date de 1936. Un grand magazine américain, le *Literary Digest*, avait recueilli plus de deux millions de réponses et prédisait une nette défaite de Roosevelt. Roosevelt fut réélu avec une large majorité. Les réponses provenaient de listes d'abonnés au téléphone et de propriétaires d'automobiles, en pleine crise économique. L'échantillon était très grand, mais il ne représentait pas l'ensemble des électeurs. Ce n'est pas la quantité qui garantit la qualité d'un sondage, c'est la **représentativité**.

Un jeu de données fonctionne comme un sondage. Nos vingt maisons ne sont pas l'ensemble des maisons. Ce sont vingt tirages dans un ensemble beaucoup plus vaste, celui de toutes les maisons qu'un tel modèle pourrait rencontrer, et les statisticiens appellent cet ensemble une **distribution**. Le jeu d'entraînement en est un échantillon, et le jeu de test en est un autre. Toute la méthode de ce chapitre repose sur une hypothèse implicite : les deux proviennent de la même distribution, et les données futures aussi. On dit alors que le test est **en distribution**. Un modèle généralise toujours à cette distribution, jamais au monde entier.

Quand cette hypothèse n'est plus vraie, c'est-à-dire quand une donnée est **hors distribution** (*out of distribution*), le problème peut prendre trois formes.

- **L'extrapolation.** Nos maisons vont de 112 à 280 m². Si on demande à la droite le prix d'un manoir de 600 m², elle répond 1 696 000 $, avec la même assurance que pour une maison de 180 m². Cependant, aucune donnée ne justifie cette réponse. La droite est prolongée hors de la zone couverte par les données, et rien n'indique que les manoirs suivent la même règle que les bungalows.
- **Le changement de lieu ou de population.** Un modèle entraîné sur les ventes de Montréal est appliqué à Vancouver, ou un test de dépistage mis au point sur des adultes est appliqué à des enfants. Les caractéristiques sont les mêmes, mais la distribution est différente, et le score obtenu dans un contexte ne dit rien de l'autre.
- **La dérive dans le temps.** Un filtre anti-pourriel entraîné sur les pourriels de 2010 est confronté à ceux de 2025. Les mots et les procédés ont changé. La distribution s'est modifiée sans que le modèle le détecte, et son score passé ne dit plus rien de sa performance actuelle.



Hors distribution : dans la zone couverte par les données, le score du test a un sens ; au-delà, la droite donne encore une réponse, mais rien ne la justifie.

Ces trois cas reproduisent la situation du *Literary Digest* : un échantillon, parfois très grand, mais qui ne provient pas de la population sur laquelle on fait les prédictions. On en tire deux règles pratiques. D'abord, le jeu de test doit ressembler aux données du **déploiement**, et pas seulement à celles de l'entraînement. Si le modèle doit servir à Vancouver, il faut des maisons de Vancouver dans le test, et on constatera rapidement qu'il en faut aussi dans l'entraînement. Ensuite, un modèle mis en service doit être **surveillé**, parce que le monde change et que rien, dans le modèle, n'indiquera que la distribution a changé.

Au début du module, la question de la 1001e image était de savoir si elle faisait partie des 1000. Une autre question s'y ajoutait : l'image provient-elle de la même distribution que les 1000 autres ? Une photo prise de nuit, alors que toutes les autres ont été prises de jour, est nouvelle d'une façon que le modèle ne sait pas traiter. Pour les grands modèles de langage présentés dans l'encart de *Généraliser*, la question devient très difficile : quand l'entraînement porte sur tout le Web, où se trouve la limite de ce qui est « en distribution » ?

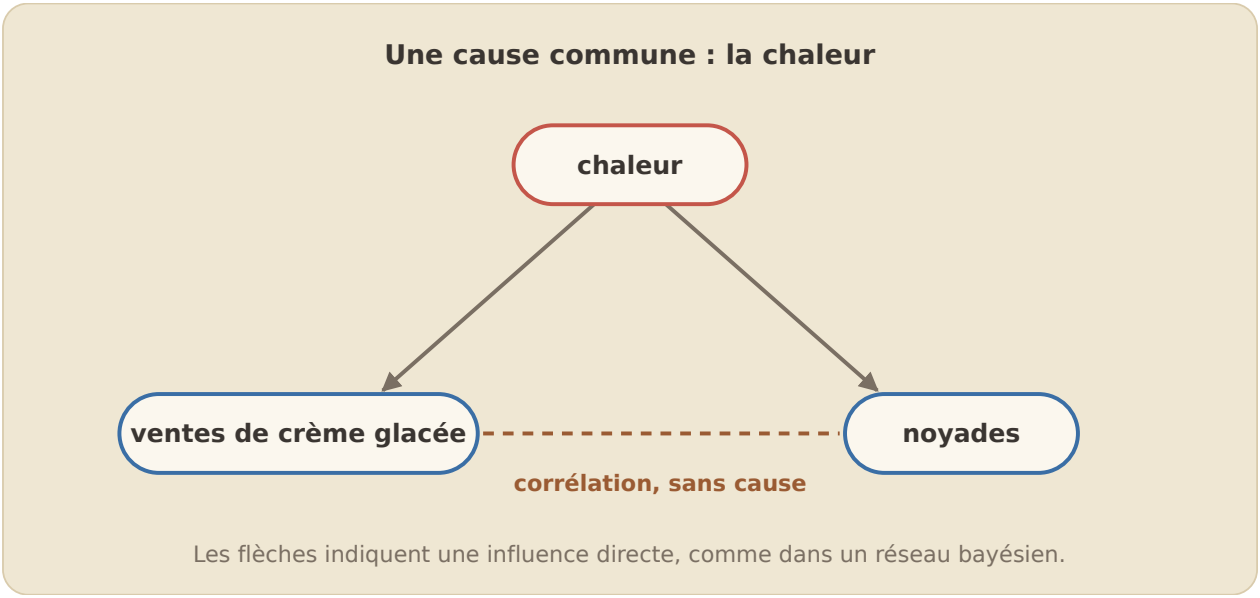
Une dernière conséquence dépasse le plan technique. Un modèle apprend *ce qui se trouve* dans ses données, et non ce qui devrait s'y trouver. Si les vingt maisons du registre viennent toutes des mêmes quartiers, le modèle reproduira leurs particularités. De même, si des décisions humaines passées ont laissé des traces dans les exemples (des prêts refusés plus souvent à certains groupes, des dossiers triés selon des habitudes que personne n'a jamais écrites), le modèle apprendra ces habitudes avec le reste, sans que cela soit visible, et les appliquera de façon systématique. C'est le **biais des données**

(*data bias*). Il ne se mesure sur aucun jeu de test, puisque le test provient des mêmes données. Un score honnête, fiable, pertinent et valable peut donc correspondre à un modèle injuste. C'est une raison de plus d'examiner la provenance des données, et pas seulement leur quantité. Le Module 5 reviendra sur cette question.

Corrélation n'est pas causalité

Les modèles de ce module apprennent des **associations** : quand telle caractéristique est présente, telle réponse est plus probable. Ils ne disent pas **pourquoi**. Cette différence semble théorique. Elle a pourtant des conséquences très concrètes.

L'exemple classique est celui de la crème glacée. Dans une ville, les jours où l'on vend beaucoup de crème glacée sont aussi des jours où il y a plus de noyades. Un modèle entraîné sur ces données prédirait très bien les noyades à partir des ventes de crème glacée. Pourtant, interdire la crème glacée ne sauverait personne. Les deux augmentent ensemble parce qu'elles ont une **cause commune**, la chaleur, qui pousse à la fois à acheter de la crème glacée et à se baigner. Une telle variable, qui influence à la fois ce qu'on observe et ce qu'on veut prédire, s'appelle un **facteur de confusion** (*confounder*).



La chaleur fait monter à la fois les ventes de crème glacée et les noyades : les deux sont corrélées, sans que l'une cause l'autre.

On reconnaît le dessin des réseaux bayésiens de *Classer* : une flèche pour chaque influence directe. Judea Pearl s'est servi de ces graphes pour distinguer une corrélation d'une cause.

Prédire n'est pas décider. Dans les années 1990, des chercheurs entraînent un modèle à prédire le risque de décès des patients atteints de pneumonie, pour décider lesquels hospitaliser. Le modèle découvre une règle surprenante : les patients asthmatiques auraient **moins** de risque de mourir. La corrélation est réelle. Mais elle vient de ce que les médecins envoyaient systématiquement les asthmatiques aux soins intensifs, où ils étaient mieux soignés. Le modèle prédisait bien. Utilisé pour décider qui hospitaliser, il aurait renvoyé chez eux les patients les plus fragiles. Ce cas a été rendu

public en 2015 par Rich Caruana et ses collègues, qui plaidaient pour des modèles dont on peut lire les règles.

Une corrélation peut disparaître. Une relation causale reste vraie quand le contexte change. Une simple corrélation peut disparaître. C'est l'une des raisons pour lesquelles les modèles échouent hors distribution. Le Module 3 en donne un exemple : un classifieur qui distinguait les loups des huskies en regardant la neige à l'arrière-plan. La neige était associée aux loups dans les photos d'entraînement, mais elle n'en est pas la cause. Ailleurs, la règle ne tient plus.

Établir une cause. La méthode de référence est l'**essai contrôlé à répartition aléatoire** (*randomized controlled trial*). On tire au sort les personnes qui reçoivent un traitement et celles qui n'en reçoivent pas. Le tirage au sort répartit les facteurs de confusion de la même façon dans les deux groupes, si bien qu'une différence entre eux ne peut venir que du traitement. La médecine l'emploie depuis un essai sur la streptomycine contre la tuberculose, publié en 1948. Les **tests A/B** (*A/B testing*) des sites Web, qui montrent deux versions d'une page à deux groupes d'internautes tirés au sort, reposent sur la même idée. Quand une expérience est impossible ou contraire à l'éthique, on peut parfois établir une cause à partir de simples observations, avec des précautions. Les économistes David Card, Joshua Angrist et Guido Imbens ont reçu le prix Nobel d'économie en 2021 pour leurs méthodes en ce sens.

L'échelle de la causalité. Dans *The Book of Why* (2018), écrit avec Dana Mackenzie, Pearl distingue trois niveaux de raisonnement, qu'il appelle l'échelle de la causalité (*ladder of causation*).

Niveau	Question	Exemple
1. Voir	Que puis-je prédire en observant ?	Les jours de grande vente de crème glacée, y a-t-il plus de noyades ?
2. Agir	Que se passe-t-il si j'interviens ?	Si j'interdis la crème glacée, y aura-t-il moins de noyades ?
3. Imaginer	Que se serait-il passé autrement ?	Ce patient aurait-il survécu s'il avait été hospitalisé ?

Les modèles de ce module restent en général au premier niveau : ils apprennent des associations dans des données observées. Pour Pearl, une intelligence comparable à la nôtre doit monter les deux autres barreaux.

Cette question a pris de l'importance ces dernières années. Le prix Turing de Pearl en 2011, son livre de 2018 et le Nobel de 2021 l'ont fait connaître bien au-delà de la statistique. Des chercheurs en apprentissage profond, comme Yoshua Bengio et Bernhard Schölkopf, y voient une piste pour obtenir des modèles plus robustes. Et l'on se demande aujourd'hui si les grands modèles de langage raisonnent sur des causes, ou s'ils reproduisent des associations présentes dans leurs textes d'entraînement. Le Module 5 reviendra sur ces questions.

Tout cela portait un nom : l'apprentissage supervisé

Depuis la première page de ce module, un élément n'a jamais changé, et nous l'avons à peine remarqué : **la bonne réponse était toujours fournie.** Chaque maison avait son prix, chaque courriel son étiquette (pourriel ou non) et chaque point sa couleur. Le modèle devait seulement apprendre à passer de la question à une réponse *fournie d'avance*.

Cette situation porte un nom, que nous pouvons maintenant introduire après l'avoir étudiée en détail : l'**apprentissage supervisé** (*supervised learning*). Le terme « supervisé » renvoie à un élève corrigé par un professeur qui connaît la réponse attendue. Régression ou classification, droite ou Bayes, paramétrique ou non, tout ce que nous avons construit appartient à cette grande famille, celle de l'apprentissage à partir d'exemples **étiquetés**.

Il reste à savoir d'où vient cette réponse fournie d'avance. Quelqu'un a dû étiqueter ces milliers d'exemples un à un, un travail souvent long et coûteux, et parfois impossible. Ce travail est si important qu'il est devenu une **industrie à part entière**, celle de l'*étiquetage de données* (*data labeling*). Des entreprises comme Scale AI (dans laquelle Meta a investi une quinzaine de milliards de dollars en 2025), Appen, Sama ou Labelbox, ou des plateformes comme le Mechanical Turk d'Amazon, emploient ou mobilisent des centaines de milliers de personnes pour tracer des contours sur des images, transcrire des enregistrements, classer des textes et, depuis l'arrivée des grands modèles de langage, comparer et noter des réponses générées. Ce travail, souvent invisible et mal payé, est réalisé en bonne partie au Kenya, aux Philippines ou au Venezuela. Il constitue la face cachée de l'apprentissage supervisé, puisque chaque « bonne réponse » fournie au modèle a été produite par un humain. Par ailleurs, la plupart des données disponibles n'ont *pas* d'étiquette : des millions de photos que personne n'a triées, des historiques d'achats sans catégories, des textes non classés. On peut se demander si un modèle peut apprendre quelque chose de données brutes, sans aucune bonne réponse. À l'inverse, quand un robot apprend à marcher, personne ne lui indique le « bon » mouvement à chaque instant. Il reçoit seulement un encouragement ou constate une chute, souvent bien plus tard. On peut se demander s'il s'agit encore d'apprentissage.

C'est bien de l'apprentissage, mais d'un autre type. Ces situations se distinguent par la nature du **signal** à partir duquel le modèle apprend : une réponse fournie, une structure à découvrir sans guide ou une récompense différée. Le chapitre suivant, « Trois façons d'apprendre », présente cette typologie et les nouvelles possibilités qu'elle ouvre.

Trois façons d'apprendre

Le chapitre « Bien évaluer un modèle » s'est terminé sur un constat. Tout ce que nous avons construit dans ce module (régression, classification, la droite, Bayes) appartient à une seule famille, l'**apprentissage supervisé**, dans laquelle chaque exemple est accompagné de sa bonne réponse. Nous avons aussi vu que ce n'est pas la seule façon d'apprendre.

Les grandes familles de l'apprentissage automatique se distinguent par la nature du **signal** que le modèle utilise, c'est-à-dire ce qui, dans les données, lui sert de guide. Il en existe trois grands types :

- une **réponse fournie** pour chaque exemple, ce qui correspond à l'apprentissage **supervisé**, étudié depuis le début du module ;
- **aucune réponse**, seulement des données brutes dans lesquelles il faut trouver une structure, ce qui correspond à l'apprentissage **non supervisé** (*unsupervised learning*) ;
- ni réponse ni structure donnée, mais une **récompense** qui arrive après coup, au fil des actions, ce qui correspond à l'apprentissage par **renforcement** (*reinforcement learning*).



Les trois grandes familles, par la nature de leur signal : réponse donnée (supervisé), structure à découvrir (non supervisé), récompense au fil de l'action (renforcement).

Nous avons passé tout le module dans la première famille. Ce dernier chapitre présente les deux autres. Le but n'est pas de les maîtriser, mais de situer ce que nous avons appris dans un ensemble plus large et de préparer les modules suivants.

Apprendre avec un professeur : le supervisé

Commençons par ce que nous connaissons déjà. En apprentissage supervisé, le signal est une **réponse fournie** avec chaque exemple, par exemple le prix d'une maison, l'étiquette *pourriel* d'un courriel ou la couleur d'un point. Le modèle apprend à relier l'entrée à cette réponse. Une fois entraîné, il applique ce qu'il a appris à de nouveaux cas. On peut le comparer à un professeur qui corrige : il connaît la bonne réponse, et l'élève progresse en comparant sa réponse à celle-ci.

Nous en avons vu les deux formes : la **régression**, quand la réponse est un nombre (un prix), et la **classification**, quand c'est une catégorie (pourriel ou non). Malgré leurs différences, les deux utilisent le même signal (une cible fournie d'avance) et le même mécanisme, qui consiste à régler des paramètres pour minimiser l'écart à cette cible.

Cette dépendance à des réponses fournies est à la fois la principale force du supervisé et sa principale limite. En effet, il faut que quelqu'un fournisse ces étiquettes, souvent à la main, un exemple à la fois.

Le socle humain du supervisé
Nous avons vu, dans *Bien évaluer un modèle*, que l'étiquetage des données est devenu une industrie à part entière. Cette industrie a aussi des aspects difficiles. Décider des milliers de fois par jour qu'un message est haineux et qu'un autre ne l'est pas, c'est aussi être exposé aux contenus les plus violents du Web, et la modération de contenus est l'un des métiers les plus éprouvants de cette chaîne. Les assistants les plus récents en dépendent aussi : une partie de l'entraînement de ChatGPT repose sur des humains qui notent et corrigent ses réponses (nous y reviendrons au Module 4). L'« intelligence » de ces systèmes repose donc en partie sur un travail humain, ce qui soulève des questions que nous retrouverons au Module 5.

La section suivante traite du cas où personne n'a fourni ces réponses.

Apprendre sans réponses : le non-supervisé

Souvent, les données n'ont pas d'étiquettes. On dispose d'un grand ensemble de données brutes (des clients, des photos, des textes), sans aucune « bonne réponse » à imiter. On peut quand même en apprendre quelque chose, mais le but est différent. Il ne s'agit plus de prédire une réponse donnée, mais de **découvrir une structure** présente dans les données elles-mêmes. C'est l'apprentissage **non supervisé**.

La tâche la plus courante est le **regroupement** (ou *clustering*), qui consiste à rassembler les exemples qui se ressemblent. Nous savons déjà ce que « se ressembler » veut dire : c'est être **proches** dans l'espace des caractéristiques, comme l'a expliqué *Prédire par ressemblance*. Regrouper consiste donc à repérer les amas naturels de points, c'est-à-dire les zones denses séparées par des zones vides.

L'algorithme classique pour cette tâche s'appelle **k-means**. On peut l'expliquer par une comparaison. Pour organiser une fête, on veut répartir les invités autour de k tables, en plaçant chaque table au centre de son groupe, pour que chacun soit le plus près possible de la sienne. k-means procède de cette façon, par ajustements successifs :

1. placer k « centres » au hasard ;
2. rattacher chaque point au centre le plus proche (ce qui donne des groupes provisoires) ;
3. déplacer chaque centre au milieu de son groupe ;

4. répéter les étapes 2 et 3 jusqu'à ce que plus rien ne change.

Dans l'applet ci-dessous, choisissez le nombre de groupes et observez les centres se déplacer, étape par étape, vers le centre des amas.

Applet interactive : à utiliser en ligne, sur la page « Trois façons d'apprendre » du site du cours.

Ce résultat ressemble à de la classification, puisque les points sont répartis en groupes de couleurs. La différence est cependant importante : ici, **les points n'avaient aucune étiquette au départ.** Vous n'avez pas indiqué à l'algorithme ce que représente chaque groupe. Vous lui avez seulement donné le nombre de groupes, et il a déterminé le reste. Il n'y a pas de « bonne réponse » à retrouver, seulement une structure à mettre en évidence.

Ce type de méthode est très répandu. On l'utilise pour segmenter une clientèle en profils types pour le marketing, pour repérer une transaction anormale parmi des millions d'autres (détection de fraude) ou pour compresser des données en les résumant par leurs groupes.

Le regroupement n'est qu'une partie du non-supervisé. Celui-ci comprend aussi la réduction de dimension, présentée ci-dessous, et l'**apprentissage de représentations** (*representation learning*), qui consiste à découvrir sans étiquettes de bonnes caractéristiques pour décrire les données. Cette idée, qui consiste à laisser la machine construire ses propres descripteurs, joue un rôle central dans l'IA moderne. Nous la retrouverons avec les **autoencodeurs** (Module 3), les **plongements** (*embeddings*) de mots (Module 4) et l'apprentissage contrastif, qui apprend à voir des images sans étiquettes (Module 4).

Les mathématiques de k-means (optionnel)
k-means cherche à minimiser une fonction d'erreur, l'**inertie**, qui est la somme des carrés des distances de chaque point à son centre :

$$J = \sum_{i=1}^{n} \min_{j=1}^{k} \|\mathbf{x}_i - \mu_j\|^2$$

où $\mathbf{x}_i$ est le i-ème point et μ_j le centre du groupe j. L'algorithme alterne deux étapes :

- **assignation** : chaque point est rattaché au centre le plus proche, $c_i = \arg\min_j \|\mathbf{x}_i - \mu_j\|^2$;
- **mise à jour** : chaque centre est placé à la moyenne de ses points, $\boldsymbol{\mu}j = \frac{1}{n_j} \sum_{i : c_i = j} \mathbf{x}_i$.

On répète ces étapes jusqu'à convergence. Deux remarques s'imposent. Le nombre de groupes k est un **hyper-paramètre**, qu'on choisit d'avance comme le k de kNN. De plus, l'algorithme peut s'arrêter dans un minimum local. C'est pourquoi on le relance habituellement plusieurs fois avec des centres initiaux différents, et on garde la meilleure solution.

Réduire la dimension

Les données ont souvent beaucoup de caractéristiques : des dizaines pour un client, 784 pour une image de chiffre manuscrit (une par pixel), des millions pour une photo. On ne peut pas dessiner un nuage de points à 784 dimensions. Et la malédiction de la dimension rend les distances de moins en moins utiles à mesure que les dimensions s'ajoutent.

Heureusement, ces caractéristiques sont rarement indépendantes. Dans une image de chiffre, deux pixels voisins ont presque toujours la même teinte. Chez un client, le revenu et la valeur de la maison

varient souvent ensemble. Une bonne partie de l'information est donc redondante. La **réduction de dimension** (*dimensionality reduction*) en tire parti : elle résume chaque exemple par quelques nombres seulement, en perdant le moins d'information possible.

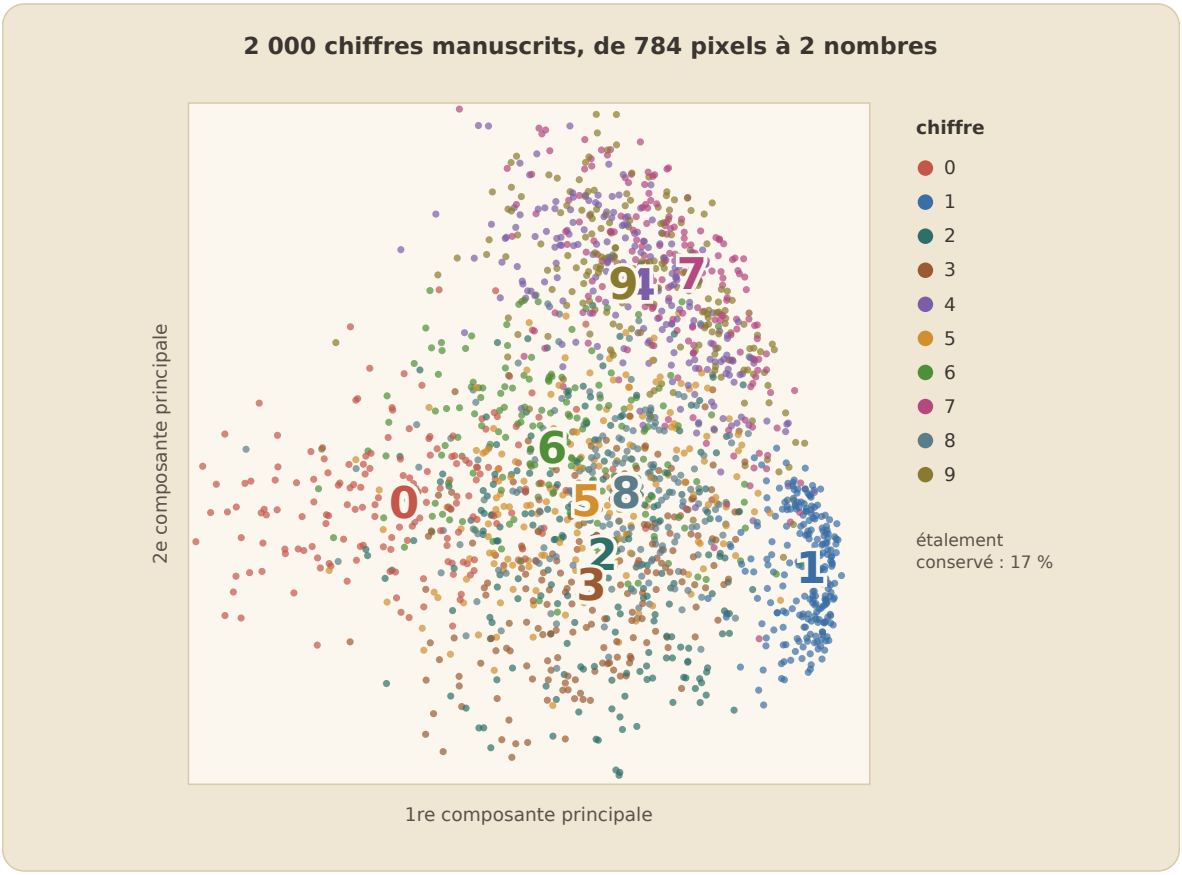
La méthode classique est l'**analyse en composantes principales** (*principal component analysis*, PCA), proposée par le statisticien Karl Pearson en 1901. Elle cherche la direction dans laquelle les données s'étalent le plus, puis la suivante, perpendiculaire à la première, et ainsi de suite. On ne garde que les premières directions, appelées **composantes principales**, et chaque exemple est résumé par sa position le long de chacune.

Une comparaison aide à voir pourquoi on cherche l'étalement. Photographier un objet, c'est le réduire de trois dimensions à deux. Une théière photographiée de côté se reconnaît à son bec et à son anse. Photographiée de dessus, ce n'est plus qu'un disque. Le bon angle est celui qui conserve le plus de différences entre les points de l'objet. La PCA choisit cet angle automatiquement, quel que soit le nombre de dimensions.

Dans l'applet ci-dessous, un nuage de points en deux dimensions doit être réduit à une seule. Faites tourner l'axe. Les points se projettent sur lui, et l'indicateur montre la part de l'étalement conservée. Cherchez l'angle qui la rend la plus grande, puis comparez-le avec celui que trouve le bouton « PCA ».

Applet interactive : à utiliser en ligne, sur la page « Trois façons d'apprendre » du site du cours.

Appliquée aux 784 pixels des chiffres manuscrits, la PCA donne la figure ci-dessous. Chaque chiffre y est réduit à deux nombres, ses positions le long des deux premières composantes principales. Les 0 et les 1 se séparent assez bien, mais la plupart des chiffres se chevauchent. Ces deux nombres ne conservent d'ailleurs que 17 % de l'étalement des données.



2 000 chiffres de la base MNIST, réduits par la PCA de 784 pixels à deux nombres. La PCA a été calculée sur les 60 000 images d'entraînement.

La PCA a une limite : elle ne trouve que des directions droites. Elle revient à regarder les données sous le meilleur angle, sans pouvoir les déformer. Or les données réelles se trouvent souvent sur des surfaces courbes, repliées sur elles-mêmes. Des méthodes plus récentes savent déplier ces surfaces, comme t-SNE (2008), de Laurens van der Maaten et Geoffrey Hinton, et UMAP (2018). On les utilise surtout pour visualiser des données en deux dimensions.

La réduction de dimension reviendra dans la suite du cours. L'autoencodeur du Module 3 est un réseau de neurones qui réduit lui aussi chaque image à quelques nombres, puis la reconstruit. Il agit comme une PCA capable de suivre les courbes. Ces quelques nombres forment l'**espace latent**, au cœur de l'IA générative du Module 4.

Les mathématiques de la PCA (optionnel)
On centre d'abord les données, en retranchant à chaque caractéristique sa moyenne. L'étalement des données le long d'une direction $\mathbf{u}$ de longueur 1 est la variance de leurs projections :

$$\mathrm{Var}(\mathbf{u}) = \frac{1}{n}\sum_{i=1}^{n}(\mathbf{u}^\top \mathbf{x}_i)^2 = \mathbf{u}^\top \Sigma\, \mathbf{u}$$

où Σ est la **matrice de covariance** des données. La direction qui maximise cette variance est le **vecteur propre** de Σ associé à sa plus grande **valeur propre**, et cette valeur propre est la

variance conservée. Les composantes suivantes sont les vecteurs propres suivants, par ordre de valeur propre décroissante. La part de l'étalement conservée par les k premières composantes est la somme de leurs valeurs propres, divisée par la somme de toutes.
Un autoencodeur dont les couches n'ont pas de fonction d'activation, entraîné à minimiser l'erreur de reconstruction au carré, retrouve exactement le même sous-espace que la PCA (Pierre Baldi et Kurt Hornik, 1989). Les fonctions d'activation lui permettent d'aller au-delà, vers les surfaces courbes.

Fabriquer soi-même ses réponses : l'auto-supervision

Entre le supervisé, qui exige des étiquettes, et le non-supervisé, qui n'en utilise pas, il existe une approche qui a beaucoup transformé le domaine : **fabriquer les étiquettes à partir des données elles-mêmes**. On peut prendre un texte, en cacher un mot et demander au modèle de le deviner. La « bonne réponse » se trouve dans le texte, sans qu'aucun humain ait eu à étiqueter quoi que ce soit. On peut aussi cacher une partie d'une photo et demander au modèle de la reconstituer, ou faire pivoter une image et lui demander de quel angle. Dans chaque cas, le problème a la forme d'un problème supervisé, avec une entrée et une réponse attendue, mais la réponse est tirée de la donnée brute. C'est l'apprentissage **auto-supervisé** (*self-supervised learning*).

Cette approche semble simple, mais elle a une portée considérable, parce qu'elle supprime le besoin d'étiquetage. Le Web contient des milliers de milliards de mots disponibles, qui ne demandent aucune heure de travail humain : chaque phrase fournit un exercice avec son corrigé. C'est de cette façon, en apprenant à prédire le mot suivant, que les grands modèles de langage du Module 4 sont entraînés, et c'est pour cette raison qu'ils ont pu traiter une grande partie de ce que l'humanité a écrit. L'apprentissage supervisé intervient ensuite, sur des quantités beaucoup plus petites, avec les réponses notées par des humains dont parlait l'encadré plus haut. Cependant, l'essentiel de leurs connaissances provient de cette tâche de prédiction sur les textes eux-mêmes.

Apprendre par l'expérience : le renforcement

La troisième situation est très différente des deux premières. Il n'y a pas d'étiquettes, et il n'y a pas non plus seulement un ensemble de données à structurer. Le modèle, qu'on appelle ici un **agent**, doit agir, et il apprend à partir des **conséquences** de ses actions. On peut penser à un enfant qui apprend à faire du vélo, à un robot qui apprend à marcher ou à un joueur qui découvre un jeu. Personne ne leur indique le bon mouvement à chaque instant. Ils essaient, échouent, recommencent et retiennent ce qui fonctionne.

Le signal est ici une **récompense** (*reward*), par exemple un point gagné, une partie remportée ou une chute évitée. Cette récompense arrive souvent **bien après** les actions qui l'ont produite. Quand on gagne une partie d'échecs, il est difficile de savoir quel coup a été décisif. Ce décalage est la principale difficulté du renforcement, parce qu'il faut apprendre à relier une récompense tardive aux actions qui l'ont rendue possible.

La stratégie utilisée est celle de l'**essai-erreur**. L'agent explore, reçoit des récompenses et des punitions, et **renforce** peu à peu les actions qui mènent au succès, d'où le nom de cette famille. Dans l'applet ci-dessous, un agent (le point jaune) cherche la sortie (**+1**) d'une petite grille en évitant un piège (**−1**), sans aucune connaissance au départ. Lancez l'entraînement.

Applet interactive : à utiliser en ligne, sur la page « Trois façons d'apprendre » du site du cours.

Au début, l'agent se déplace au hasard. Puis, d'un épisode à l'autre, une **carte de valeur** se forme (les cases se colorent selon leur valeur estimée) et une **politique** (*policy*) apparaît. Les flèches, qui indiquent pour chaque case le meilleur mouvement, finissent par former un chemin sûr vers le but. Le curseur d'**exploration** (ε) est instructif. À zéro, l'agent ne fait qu'exploiter ce qu'il croit déjà savoir, et il peut rester dans un chemin médiocre. Un peu de hasard l'amène à explorer d'autres chemins, et parfois à en trouver de meilleurs. Ce compromis entre **explorer et exploiter** (*exploration vs. exploitation*) est au centre du renforcement.

Cette approche rappelle une notion déjà vue. Au Module 1, nous avons étudié les machines qui jouent aux échecs en cherchant dans l'arbre des coups possibles. Le renforcement reprend cette recherche, mais la machine apprend elle-même à évaluer les positions au lieu de tout calculer. C'est cette combinaison de la recherche du GOFAI et de l'apprentissage qui a permis à **AlphaGo** de battre les meilleurs joueurs de go humains, alors que la force brute seule n'y parvenait pas.

Le renforcement est aussi la famille qui demande le plus de calcul, et il s'est surtout développé lorsqu'on l'a combiné aux **réseaux de neurones** (le *deep reinforcement learning*, Module 3). On le retrouve aussi dans les assistants modernes. Le comportement de ChatGPT est en partie ajusté par renforcement, à partir des préférences d'évaluateurs humains (le **RLHF**). Le renforcement sert également, avec des récompenses vérifiables (un problème de mathématiques a une bonne réponse, un programme réussit ou non ses tests, ce qu'on appelle le **RLVR**), à entraîner les modèles les plus récents à « raisonner » longuement avant de répondre. Nous verrons ces méthodes au Module 4.

Un même squelette, d'un bout à l'autre

Les trois familles répondent de trois façons à une même question, celle de savoir à partir de quoi le modèle apprend : une réponse fournie, une structure à découvrir ou une récompense à obtenir. Ces trois familles partagent cependant la même structure de base, celle qui a servi tout au long de ce module.

Cette structure comporte plusieurs étapes. On part de **données**, qu'on décrit par des nombres, donc par des points dans un espace. On choisit un **modèle**, c'est-à-dire une fonction de prédiction réglée par des paramètres. On mesure son **erreur** de prédiction. On règle ensuite les paramètres du modèle pour **minimiser** cette erreur, le plus souvent par descente de gradient. On vérifie enfin que le modèle **généralise** au-delà des exemples appris. Toutes les méthodes vues dans ce module sont des variantes de ce schéma : le modèle simple et son unique nombre, kNN et ses zéro paramètre, la droite et ses deux paramètres, l'arbre et ses questions, la régression logistique et Bayes qui classent, k-means qui regroupe sans étiquettes et l'agent qui apprend à partir d'une récompense. La démarche est la même, mais elle s'applique à des problèmes différents.

C'est ce que ce module voulait montrer. Pour une machine, « apprendre » n'a rien de magique : c'est **ajuster des réglages pour réduire une erreur sur des exemples**. La question posée dès la première page, qui était de savoir en quoi il s'agit d'intelligence, reste ouverte. Vous savez cependant maintenant, concrètement, comment ces systèmes fonctionnent.

Il reste à revenir sur le lien avec la statistique annoncé au début du module. Un statisticien reconnaîtrait tout ce que nous avons fait ici : ajuster une droite, estimer une probabilité, tirer un échantillon, se méfier d'un score. Ce qui a changé, ce n'est pas la base, mais l'accent et l'échelle. L'accent est mis sur la prédiction d'abord, l'explication ensuite, et parfois jamais. L'échelle se compte en millions d'exemples et en milliards de paramètres, avec des modèles que personne ne lit plus. C'est à cette

échelle que la statistique a pris le nom d'apprentissage automatique, et qu'elle a produit des résultats que ses fondateurs n'avaient pas prévus.

L'étape suivante est ce changement d'échelle. Richard Sutton, un chercheur qui a consacré sa carrière à l'apprentissage par renforcement, a tiré de soixante-dix ans d'histoire de l'IA une leçon qu'il qualifie d'amère, « The Bitter Lesson » (2019). Selon lui, à long terme, les méthodes générales qui exploitent la puissance de calcul finissent toujours par l'emporter sur celles où l'on avait inscrit à la main le savoir humain, et seules deux méthodes passent vraiment à l'échelle, la **recherche**, celle du Module 1, et l'**apprentissage**, celui de ce module. Le sens et le coût de cette leçon sont examinés au **Module 3**. Nous y combinerons ces fonctions réglables en **réseaux de neurones** profonds, et nous verrons pourquoi ces réseaux ont permis de grands progrès dans le traitement de l'image et du langage. Au **Module 4**, ces mêmes réseaux deviendront **génératifs**, capables de produire des textes et des images : ce sont les grands modèles de langage. La structure de base restera la même, mais à une échelle beaucoup plus grande.

Classification naïve bayésienne pour détecter les pourriels (travail noté 2)

La classification naïve bayésienne est un algorithme d'apprentissage supervisé qui repose sur les probabilités. Nous avons vu deux variantes de cet algorithme :

1. La classification de simples points en 2d avec un modèle gaussien
2. La classification de vecteurs en haute dimension avec un modèle multinomial

La classification de courriels est un problème classique qu'on peut traiter avec cet algorithme. On cherche à estimer la probabilité qu'un courriel soit un pourriel (*spam*) à partir des mots qu'il contient, parce que certains mots sont plus souvent utilisés dans les pourriels et d'autres dans les courriels.

Comme nous l'avons vu au chapitre « Classer », la classification naïve bayésienne est un algorithme d'apprentissage *génératif*. On considère donc d'abord deux modèles (un pour chaque classe, `pourriel` ou `courriel`), dont le rôle est de générer les données observées plutôt que de les classifier directement :

$$P(\text{les mots générés} \mid \text{il s'agit d'un pourriel})$$

$$P(\text{les mots générés} \mid \text{il s'agit d'un courriel})$$

ou, de manière plus compacte :

$$P(\mathbf{x} \mid \texttt{pourriel})$$

$$P(\mathbf{x} \mid \texttt{courriel})$$

Comme ce qui nous intéresse ici est de classifier les courriels, nous utilisons le théorème de Bayes pour « inverser » les modèles et obtenir une règle de classification simple, qui prédit la classe plutôt que les mots :

$$\text{classification}(\mathbf{x}) = \begin{cases} \texttt{pourriel} \text{ si } P(\mathbf{x} \mid \texttt{pourriel})P(\texttt{pourriel}) \geq P(\mathbf{x} \mid \texttt{courriel})P(\texttt{courriel}) \\ \texttt{courriel} \text{ sinon} \end{cases}$$

Consignes

1. Suivez les instructions ci-dessous pour construire d'abord le fichier Google Sheets avec toutes les données nécessaires.
2. Une fois le fichier complété et fonctionnel, partagez votre fichier et copiez le lien vers celui-ci dans un document PDF (**Attention : aucun autre format que PDF ne sera accepté**).
3. Répondez aux questions d'interprétation de la dernière section dans le même fichier PDF, en fournissant des réponses claires et précises.

Entraînement du modèle

Cette section montre comment calculer ces probabilités en entraînant un modèle de classification sur une série de courriels.

Comme nous allons utiliser le tableur en ligne Google Sheets, assurez-vous d'abord qu'il est correctement configuré.

Copiez d'abord ces 10 mini-courriels dans la colonne A d'une nouvelle « feuille » Google Sheets, un courriel par rangée (si vous utilisez le copier-coller, assurez-vous de bien appliquer la fonction « copier-coller ») :

```
voici le colis est arrivé
bonjour voici le lien
offre spéciale colis gratuit
merci pour votre colis
colis livré demain matin
voici votre carte gratuite
réunion demain à midi
voici le code pour carte
livraison spéciale pour vous
merci encore pour votre carte
```

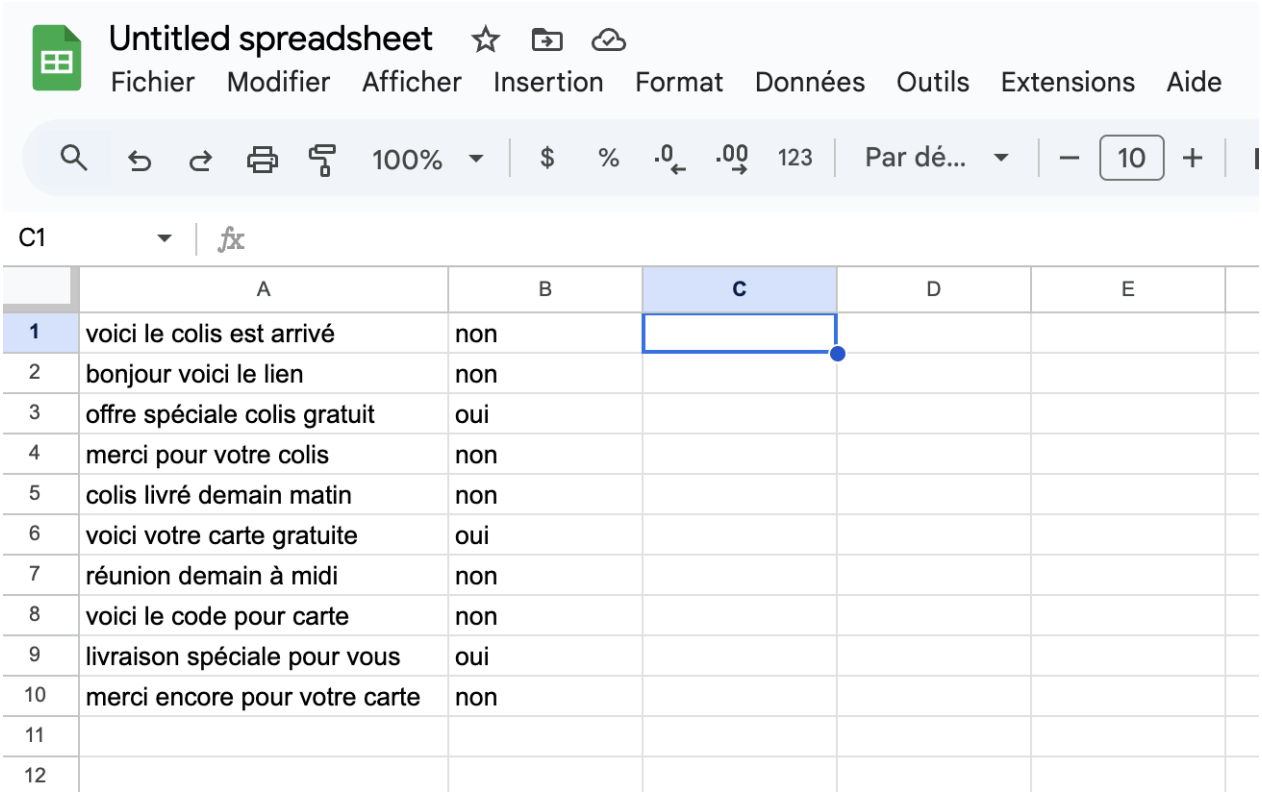
Pour avoir un aperçu de la tâche d'étiquetage des données (qui, dans un scénario réel, peut être très coûteuse et laborieuse), nous vous proposons d'abord de catégoriser vous-mêmes les courriels dans la colonne `B`, en utilisant la valeur `oui` si vous considérez qu'il s'agit d'un pourriel, ou `non` (ce n'est pas un pourriel) sinon.

Si vous préférez ne pas faire cet exercice maintenant, vous pouvez copier ces valeurs (dans la colonne `B`) :

```
non
non
oui
non
non
oui
non
non
oui
```

```
non
```

À ce stade, votre feuille devrait ressembler à ceci :



	A	B	C	D	E
1	voici le colis est arrivé	non			
2	bonjour voici le lien	non			
3	offre spéciale colis gratuit	oui			
4	merci pour votre colis	non			
5	colis livré demain matin	non			
6	voici votre carte gratuite	oui			
7	réunion demain à midi	non			
8	voici le code pour carte	non			
9	livraison spéciale pour vous	oui			
10	merci encore pour votre carte	non			
11					
12					

Calculez d'abord, dans la colonne `C`, la probabilité *a priori* qu'un courriel quelconque ne soit pas un pourriel (`C1`) ou qu'il en soit un (`C2`), sans tenir compte des mots pour le moment. Dans la cellule `C1` :

```
=COUNTIF(B1:B10, "non") / COUNTA(B1:B10)
```

et dans la cellule `C2` :

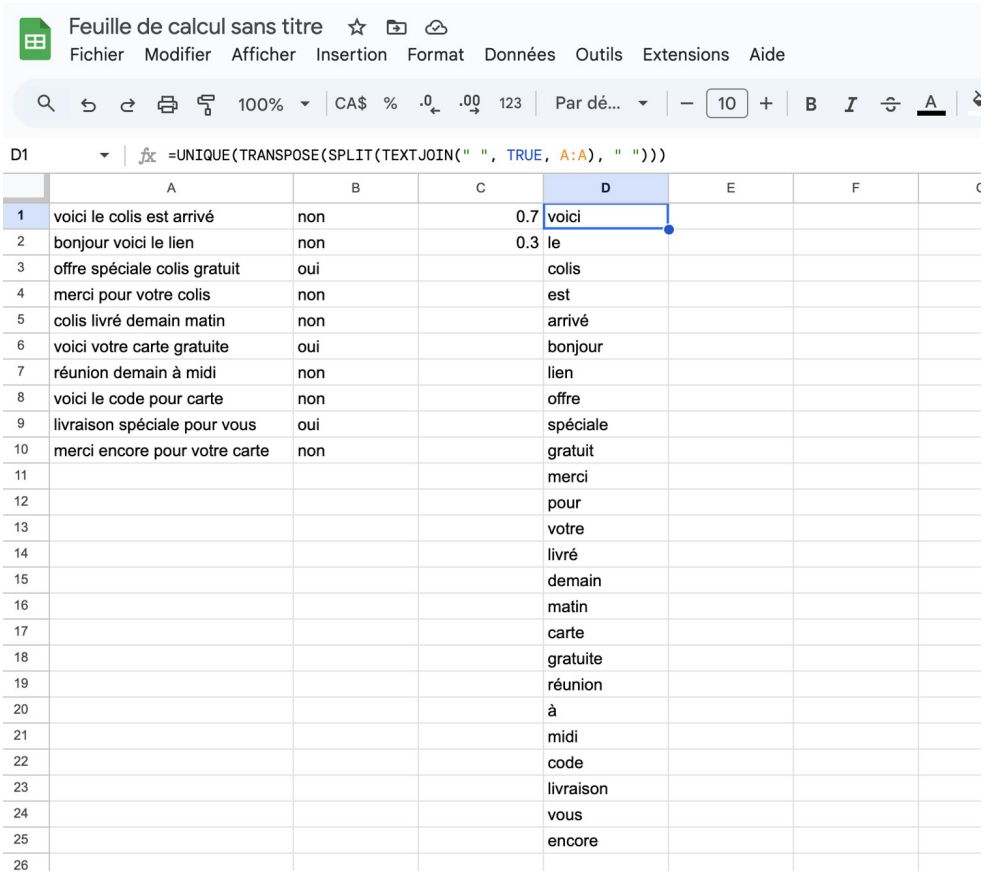
```
=COUNTIF(B1:B10, "oui") / COUNTA(B1:B10)
```

> Si vous obtenez une erreur avec la formule à ce stade, il est très possible que les paramètres linguistiques de votre Google Sheets ne soient pas correctement configurés.

Ces probabilités *a priori* serviront plus loin. Définissez ensuite la colonne `D` avec cette formule :

```
=UNIQUE(TRANSPOSE(SPLIT(TEXTJOIN(" ", TRUE, A:A), " ")))
```

La colonne `D` devrait maintenant contenir le vocabulaire des courriels :



	A	B	C	D	E	F
1	voici le colis est arrivé	non	0.7	voici		
2	bonjour voici le lien	non	0.3	le		
3	offre spéciale colis gratuit	oui		colis		
4	merci pour votre colis	non		est		
5	colis livré demain matin	non		arrivé		
6	voici votre carte gratuite	oui		bonjour		
7	réunion demain à midi	non		lien		
8	voici le code pour carte	non		offre		
9	livraison spéciale pour vous	oui		spéciale		
10	merci encore pour votre carte	non		gratuit		
11				merci		
12				pour		
13				votre		
14				livré		
15				demain		
16				matin		
17				carte		
18				gratuite		
19				réunion		
20				à		
21				midi		
22				code		
23				livraison		
24				vous		
25				encore		
26						

La colonne `E` doit ensuite contenir le nombre de courriels valides (ceux marqués `non`, qui ne sont pas des pourriels) dans lesquels apparaît chaque mot de la colonne `D` :

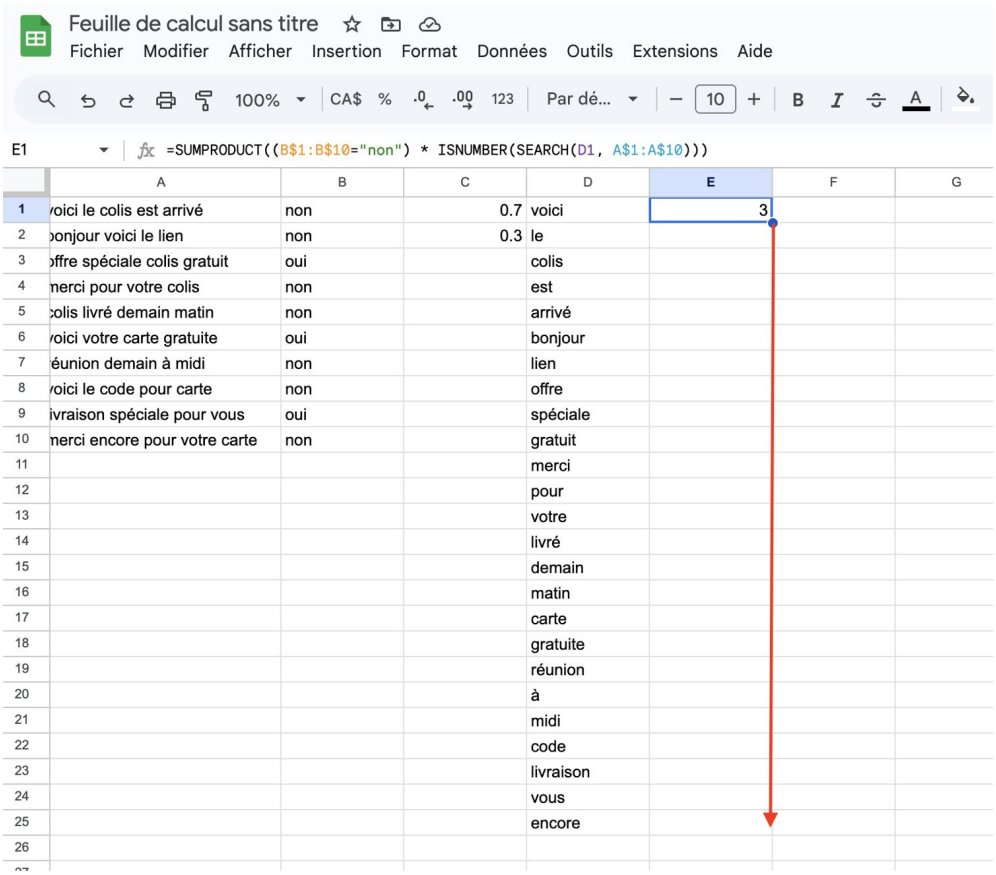
```
=SUMPRODUCT((B$1:B$10="non") * ISNUMBER(SEARCH(" " & D1 & " ", " " & A$1:A$10 & " ")))
```

La formule entoure le mot et chaque courriel d'espaces avant de chercher l'un dans l'autre. Sans cette précaution, le mot « le » serait trouvé à l'intérieur de « spéciale », et « gratuit » à l'intérieur de « gratuite ».

De la même manière, la colonne `F` contient, pour chaque mot, le nombre de courriels marqués `oui`, qui sont des pourriels, dans lesquels il apparaît :

```
=SUMPRODUCT((B$1:B$10="oui") * ISNUMBER(SEARCH(" " & D1 & " ", " " & A$1:A$10 & " ")))
```

> Notez que les colonnes `E` et `F` doivent avoir le même nombre d'éléments que la colonne `D`. Il faut donc utiliser la fonction de remplissage automatique. Le plus simple est de glisser (*drag*) la première cellule vers le bas, une fois qu'elle a été calculée, ou de double-cliquer sur le petit carré bleu qui apparaît en bas à droite de la cellule sélectionnée. Google Sheets propose parfois de lui-même ce remplissage (« Remplissage automatique suggéré ») : vous pouvez l'accepter.



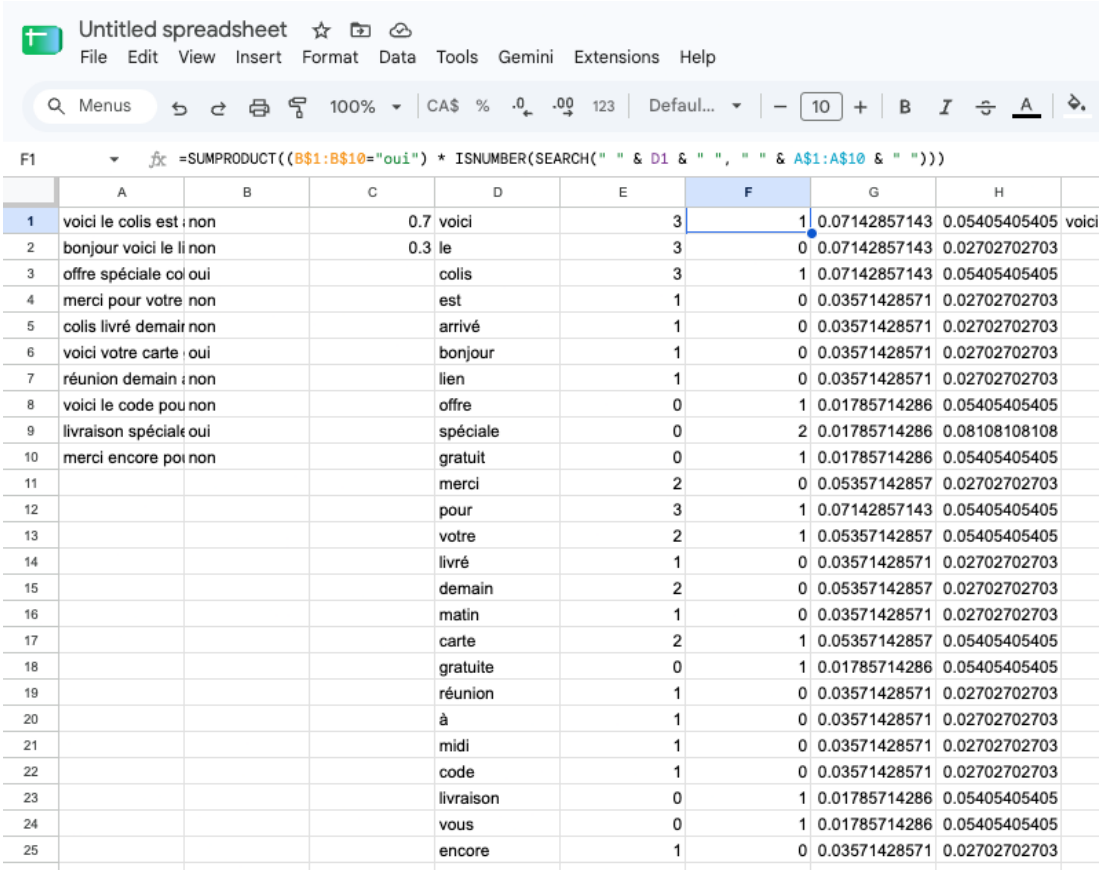
Feuille de calcul sans titre

Fichier Modifier Afficher Insertion Format Données Outils Extensions Aide

100% CA$ % .0 .00 123 Par dé... 10 B I A

E1 =SUMPRODUCT((B$1:B$10="non") * ISNUMBER(SEARCH(D1, A$1:A$10)))

	A	B	C	D	E	F	G
1	voici le colis est arrivé	non	0.7	voici	3		
2	bonjour voici le lien	non	0.3	le			
3	offre spéciale colis gratuit	oui		colis			
4	merci pour votre colis	non		est			
5	colis livré demain matin	non		arrivé			
6	voici votre carte gratuite	oui		bonjour			
7	réunion demain à midi	non		lien			
8	voici le code pour carte	non		offre			
9	livraison spéciale pour vous	oui		spéciale			
10	merci encore pour votre carte	non		gratuit			
11				merci			
12				pour			
13				votre			
14				livré			
15				demain			
16				matin			
17				carte			
18				gratuite			
19				réunion			
20				à			
21				midi			
22				code			
23				livraison			
24				vous			
25				encore			
26							



Untitled spreadsheet

File Edit View Insert Format Data Tools Gemini Extensions Help

F1 =SUMPRODUCT((B$1:B$10="oui") * ISNUMBER(SEARCH(" " & D1 & " ", " " & A$1:A$10 & " ")))

	A	B	C	D	E	F	G	H	
1	voici le colis est	non	0.7	voici	3	1	0.07142857143	0.05405405405	voici
2	bonjour voici le li	non	0.3	le	3	0	0.07142857143	0.02702702703	
3	offre spéciale co	oui		colis	3	1	0.07142857143	0.05405405405	
4	merci pour votre	non		est	1	0	0.03571428571	0.02702702703	
5	colis livré demai	non		arrivé	1	0	0.03571428571	0.02702702703	
6	voici votre carte	oui		bonjour	1	0	0.03571428571	0.02702702703	
7	réunion demain	non		lien	1	0	0.03571428571	0.02702702703	
8	voici le code pou	non		offre	0	1	0.01785714286	0.05405405405	
9	livraison spéciale	oui		spéciale	0	2	0.01785714286	0.08108108108	
10	merci encore poi	non		gratuit	0	1	0.01785714286	0.05405405405	
11				merci	2	0	0.05357142857	0.02702702703	
12				pour	3	1	0.07142857143	0.05405405405	
13				votre	2	1	0.05357142857	0.05405405405	
14				livré	1	0	0.03571428571	0.02702702703	
15				demain	2	0	0.05357142857	0.02702702703	
16				matin	1	0	0.03571428571	0.02702702703	
17				carte	2	1	0.05357142857	0.05405405405	
18				gratuite	0	1	0.01785714286	0.05405405405	
19				réunion	1	0	0.03571428571	0.02702702703	
20				à	1	0	0.03571428571	0.02702702703	
21				midi	1	0	0.03571428571	0.02702702703	
22				code	1	0	0.03571428571	0.02702702703	
23				livraison	0	1	0.01785714286	0.05405405405	
24				vous	0	1	0.01785714286	0.05405405405	
25				encore	1	0	0.03571428571	0.02702702703	

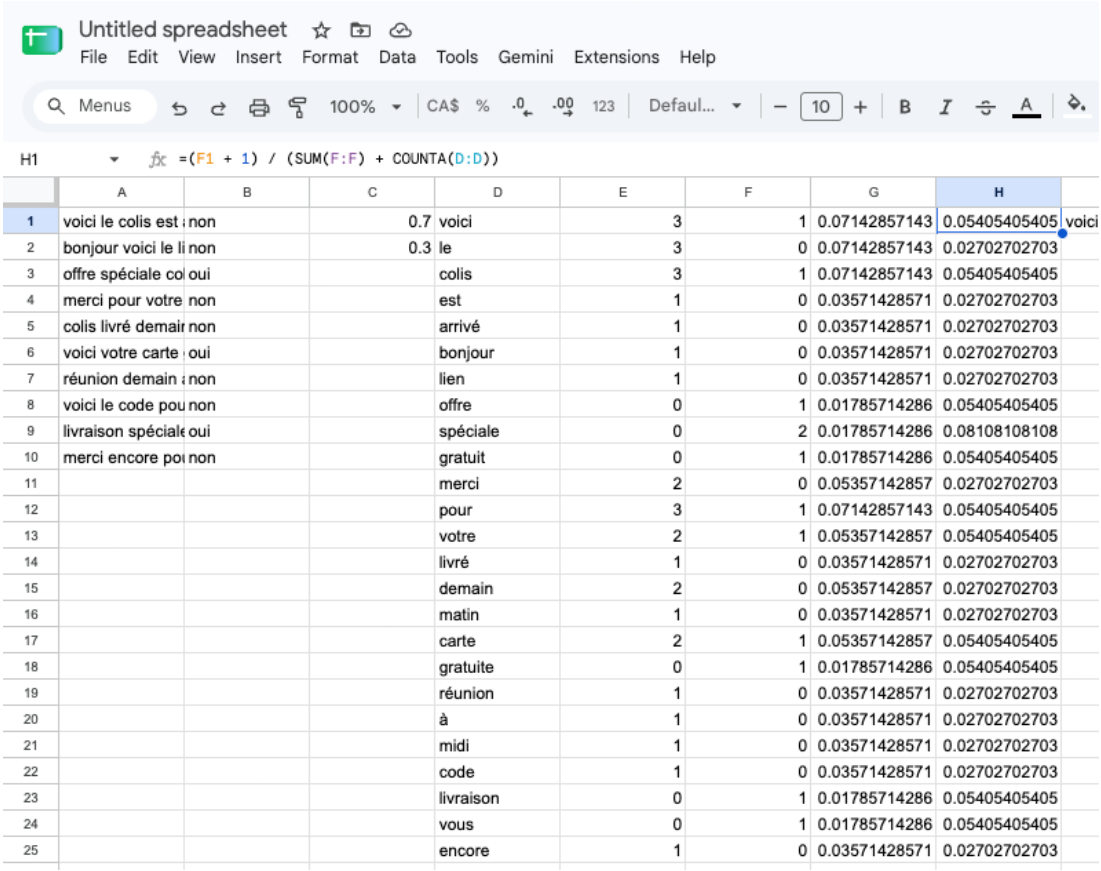
À partir de ces fréquences de mots pour chaque classe (`oui` ou `non`), on peut maintenant calculer la probabilité conditionnelle de chaque mot du vocabulaire, selon que le courriel est un pourriel (`oui`) ou non (`non`). La colonne `G` correspond à la probabilité des mots sachant que le courriel n'est pas un pourriel (`non`) :

```
=(E1 + 1) / (SUM(E:E) + COUNTA(D:D))
```

De la même manière, la colonne `H` contient la probabilité des mots sachant que le courriel est un pourriel (`oui`) :

```
=(F1 + 1) / (SUM(F:F) + COUNTA(D:D))
```

Les colonnes `G` et `H` doivent elles aussi avoir la même taille que le vocabulaire (colonne `D`). Il faut donc utiliser le remplissage automatique décrit plus haut.



	A	B	C	D	E	F	G	H
1	voici le colis est	non	0.7	voici	3	1	0.07142857143	0.05405405405
2	bonjour voici le li	non	0.3	le	3	0	0.07142857143	0.02702702703
3	offre spéciale co	oui		colis	3	1	0.07142857143	0.05405405405
4	merci pour votre	non		est	1	0	0.03571428571	0.02702702703
5	colis livré demair	non		arrivé	1	0	0.03571428571	0.02702702703
6	voici votre carte	oui		bonjour	1	0	0.03571428571	0.02702702703
7	réunion demain	non		lien	1	0	0.03571428571	0.02702702703
8	voici le code pou	non		offre	0	1	0.01785714286	0.05405405405
9	livraison spéciale	oui		spéciale	0	2	0.01785714286	0.08108108108
10	merci encore poi	non		gratuit	0	1	0.01785714286	0.05405405405
11				merci	2	0	0.05357142857	0.02702702703
12				pour	3	1	0.07142857143	0.05405405405
13				votre	2	1	0.05357142857	0.05405405405
14				livré	1	0	0.03571428571	0.02702702703
15				demain	2	0	0.05357142857	0.02702702703
16				matin	1	0	0.03571428571	0.02702702703
17				carte	2	1	0.05357142857	0.05405405405
18				gratuite	0	1	0.01785714286	0.05405405405
19				réunion	1	0	0.03571428571	0.02702702703
20				à	1	0	0.03571428571	0.02702702703
21				midi	1	0	0.03571428571	0.02702702703
22				code	1	0	0.03571428571	0.02702702703
23				livraison	0	1	0.01785714286	0.05405405405
24				vous	0	1	0.01785714286	0.05405405405
25				encore	1	0	0.03571428571	0.02702702703

Le modèle est maintenant entièrement entraîné et prêt à être utilisé.

Utilisation du modèle (inférence)

Nous allons maintenant utiliser le modèle pour déterminer si un nouveau courriel (qui n'a pas servi à l'entraînement) est un pourriel ou non. Dans la colonne `I`, entrez un courriel à tester :

```
voici votre carte spéciale
```

Extrayez les mots du courriel dans la colonne `J` :

```
=TRANSPOSE(SPLIT(I1, " "))
```

Il faut ensuite, dans la colonne `K`, la probabilité des mots de ce courriel de test dans l'hypothèse où ce n'est pas un pourriel (`non`) :

```
=IFERROR(XLOOKUP(J1, D:D, G:G), 1E-5)
```

De la même manière, la colonne `L` contient la probabilité des mots du courriel dans l'hypothèse où il s'agit d'un pourriel (`oui`) :

```
=IFERROR(XLOOKUP(J1, D:D, H:H), 1E-5)
```

Les colonnes `K` et `L` doivent avoir la même taille que la colonne `J`. Utilisez donc le remplissage automatique. Calculez ensuite, dans la colonne `M`, la probabilité que le courriel ne soit pas un

pourriel (`non`) :

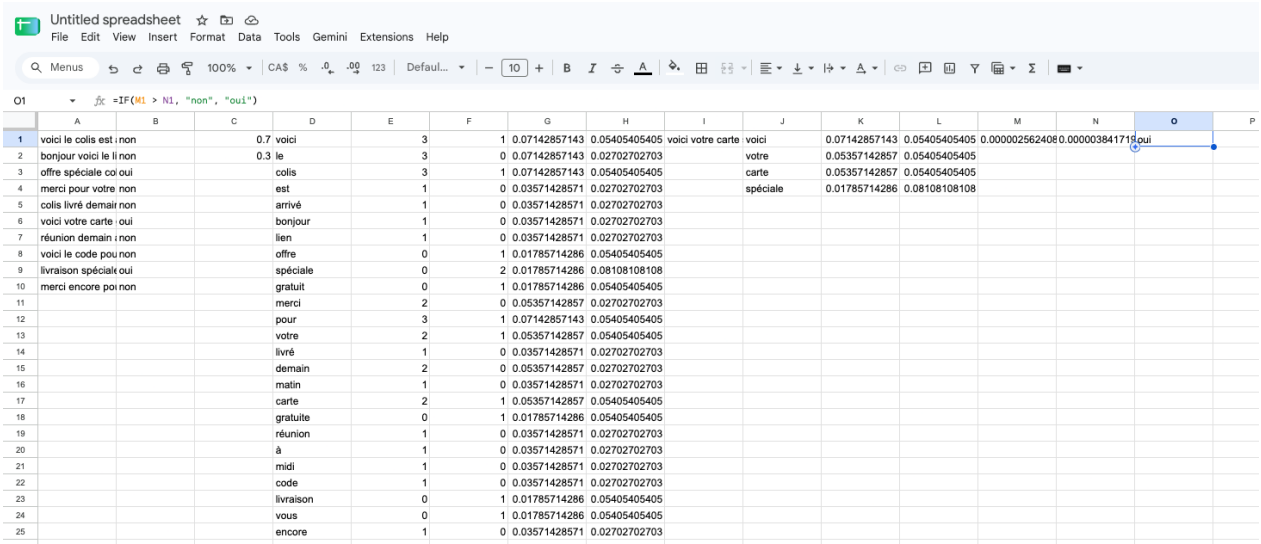
```
=PRODUCT(K:K) * C1
```

Dans la colonne `N`, calculez la probabilité que le courriel soit un pourriel (`oui`) :

```
=PRODUCT(L:L) * C2
```

La classification finale se trouve dans la colonne `O` :

```
=IF(M1 > N1, "non", "oui")
```



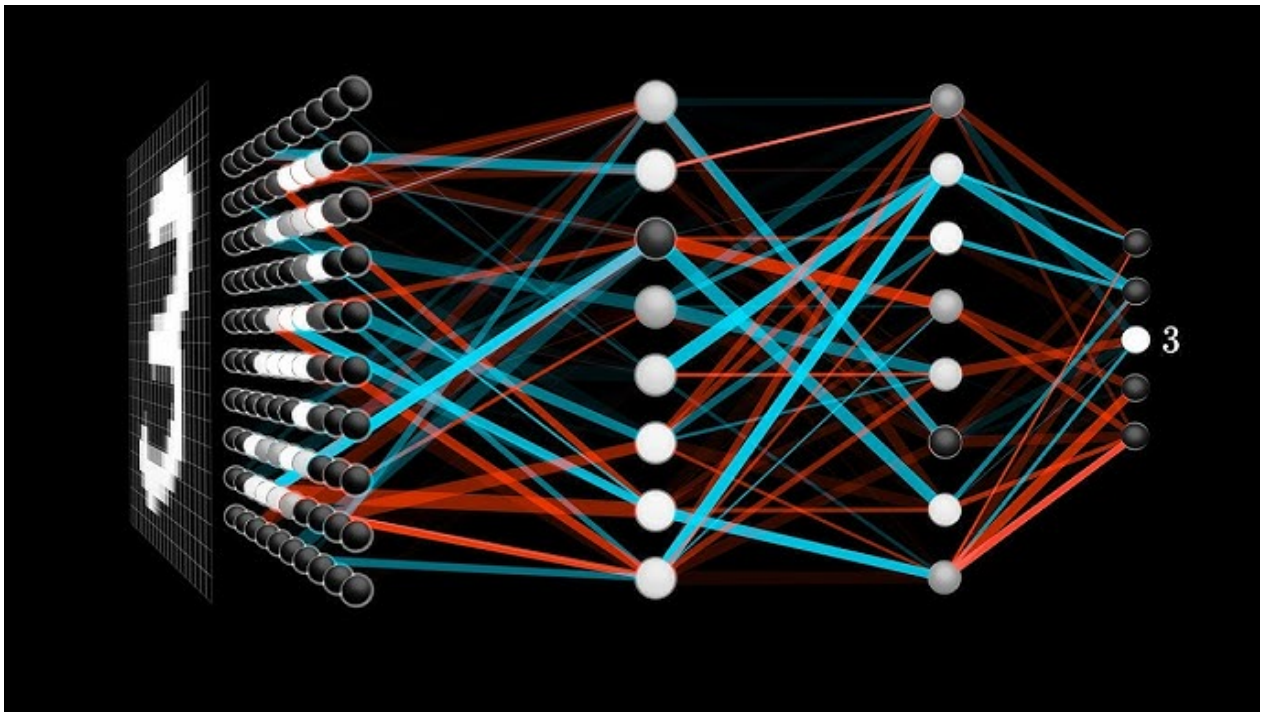
	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	voici le colis est	non	0.7	voici	3	1	0.07142857143	0.05405405405	voici votre carte	voici	0.07142857143	0.05405405405	0.000002562408	0.000003841718	oui
2	bonjour voici le li	non	0.3	le	3	0	0.07142857143	0.02702702703		votre	0.05357142857	0.05405405405			
3	offre spéciale coi	oui		colis	3	1	0.07142857143	0.05405405405		carte	0.05357142857	0.05405405405			
4	merci pour votre	non		est	1	0	0.03571428571	0.02702702703		spéciale	0.01785714286	0.08108108108			
5	colis livré demair	non		arrivé	1	0	0.03571428571	0.02702702703							
6	voici votre carte	oui		bonjour	1	0	0.03571428571	0.02702702703							
7	réunion demain	non		lien	1	0	0.03571428571	0.02702702703							
8	voici le code pou	non		offre	0	1	0.01785714286	0.05405405405							
9	livraison spéciale	oui		spéciale	0	2	0.01785714286	0.08108108108							
10	merci encore poi	non		gratuit	0	1	0.01785714286	0.05405405405							
11				merci	2	0	0.05357142857	0.02702702703							
12				pour	3	1	0.07142857143	0.05405405405							
13				votre	2	1	0.05357142857	0.05405405405							
14				livré	1	0	0.03571428571	0.02702702703							
15				demain	2	0	0.05357142857	0.02702702703							
16				matin	1	0	0.03571428571	0.02702702703							
17				carte	2	1	0.05357142857	0.05405405405							
18				gratuite	0	1	0.01785714286	0.05405405405							
19				réunion	1	0	0.03571428571	0.02702702703							
20				à	1	0	0.03571428571	0.02702702703							
21				midi	1	0	0.03571428571	0.02702702703							
22				code	1	0	0.03571428571	0.02702702703							
23				livraison	0	1	0.01785714286	0.05405405405							
24				vous	0	1	0.01785714286	0.05405405405							
25				encore	1	0	0.03571428571	0.02702702703							

Questions d'interprétation

1. Que se passe-t-il si vous remplacez le mot « spéciale » par le mot « livrée » dans le courriel de test de la cellule `I1` ?
2. Après ce changement, expliquez les probabilités qu'on trouve aux cellules `K4` et `L4` associées au nouveau mot « livrée ». D'où proviennent ces nouvelles valeurs, et pourquoi a-t-on besoin d'y avoir recours dans le calcul ?
3. Est-ce que ce modèle est paramétrique ou non ? Expliquez pourquoi.
4. S'il s'agit d'un modèle paramétrique, quels sont les paramètres du modèle (quelles colonnes) ?
5. Quelles colonnes constituent la partie *générative* du modèle ? Expliquez pourquoi.
6. Quelles colonnes constituent la partie *discriminative* du modèle ? Expliquez pourquoi.
7. Quelle est la signification des nombres dans les cellules `G11` et `H11`, associées au mot « merci » ? Comment peut-on les interpréter ?
8. Quelles sont les probabilités non conditionnelles (*a priori*) ? À quoi servent-elles ?
9. Est-ce qu'il serait possible d'utiliser seulement ces probabilités non conditionnelles pour faire un modèle de classification ? Quelles conséquences cela entraînerait-il ?
10. De quelle manière peut-on dire que ce modèle généralise ?

11. Est-ce que l'ordre des mots joue un rôle dans les décisions de ce modèle ? Expliquez pourquoi.
12. Si l'ordre des mots ne joue pas de rôle, comment pourrait-on modifier le modèle pour qu'il en joue un ?
13. Est-ce que certains mots aident particulièrement le modèle ? Si oui, pourquoi ?
14. Est-ce que certains mots sont moins utiles ? Si oui, pourquoi ?

Module 3 — Réseaux de neurones et apprentissage profond



Un réseau qui reconnaît un 3 manuscrit (*image tirée de la série de vidéos de 3Blue1Brown sur les réseaux de neurones*).

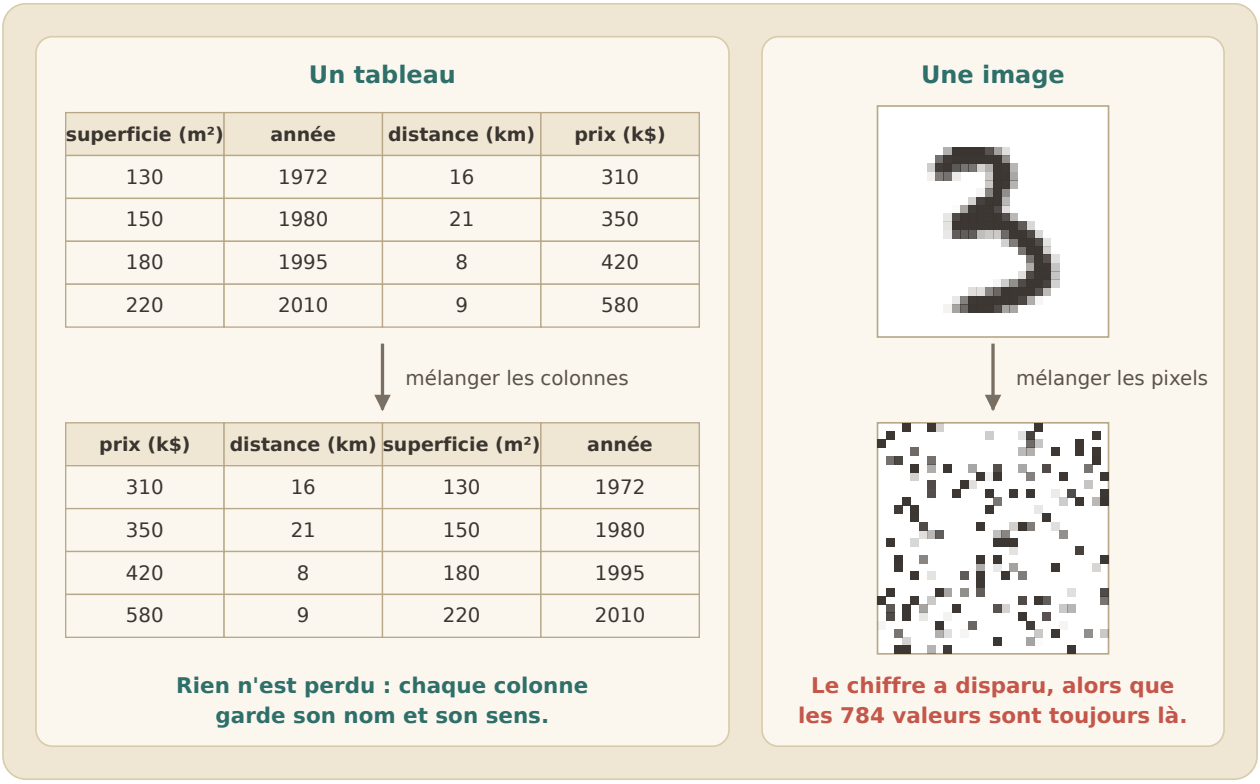
Le retour d'une idée ancienne

Le Module 1 a présenté deux paris sur la nature de l'intelligence, nés presque en même temps dans les années 1950. Le pari symbolique voit l'esprit comme de la logique, des symboles et des règles. Le pari connexionniste le voit comme un cerveau, un réseau qui s'ajuste à l'expérience. Le perceptron de Rosenblatt, en 1958, en était la première machine.

Ce second pari a connu une longue éclipse. En 1969, Minsky et Papert montrent qu'un perceptron ne peut pas apprendre une fonction aussi simple que le XOR, et la recherche sur les réseaux de neurones s'arrête presque. Elle reprend au début des années 1980, et surtout en 1986, avec une méthode pour entraîner des réseaux dotés d'une couche cachée, la rétropropagation. Mais pendant les vingt-cinq années suivantes, les progrès de l'apprentissage automatique viennent surtout d'autres méthodes : les machines à vecteurs de support (SVM) à partir du milieu des années 1990, le *boosting*, les forêts aléatoires au début des années 2000, et les modèles probabilistes comme le classifieur bayésien du Module 2. Ces méthodes s'appuient sur une théorie solide, s'entraînent de façon fiable et donnent d'excellents résultats. Les réseaux de neurones paraissent alors difficiles à régler et peu fiables, et beaucoup de chercheurs s'en détournent.

La situation change en 2012, quand un réseau profond dépasse de loin toutes les autres méthodes de reconnaissance d'images. En quelques années, les réseaux de neurones deviennent la méthode dominante pour les images, la parole et le texte. Ils sont aujourd'hui au cœur de la reconnaissance d'images et de la parole, de la traduction automatique, et des grands modèles de langage comme ChatGPT. Les autres méthodes n'ont pas disparu pour autant, et la différence tient à la nature des données. Dans une image, un son ou un texte, un élément isolé ne veut presque rien dire : un pixel n'est qu'un point de couleur, et le sens naît de l'agencement de milliers d'éléments voisins. Dans un tableau, comme les dossiers d'une banque ou d'un hôpital, chaque colonne a déjà un sens, comme

l'âge, le revenu ou la pression artérielle. On peut d'ailleurs mélanger l'ordre des colonnes d'un tableau sans rien perdre, alors que mélanger les pixels d'une photo la détruit. Sur les premières données, les réseaux de neurones l'emportent. Sur les secondes, les forêts aléatoires et le *gradient boosting* restent souvent les plus efficaces.



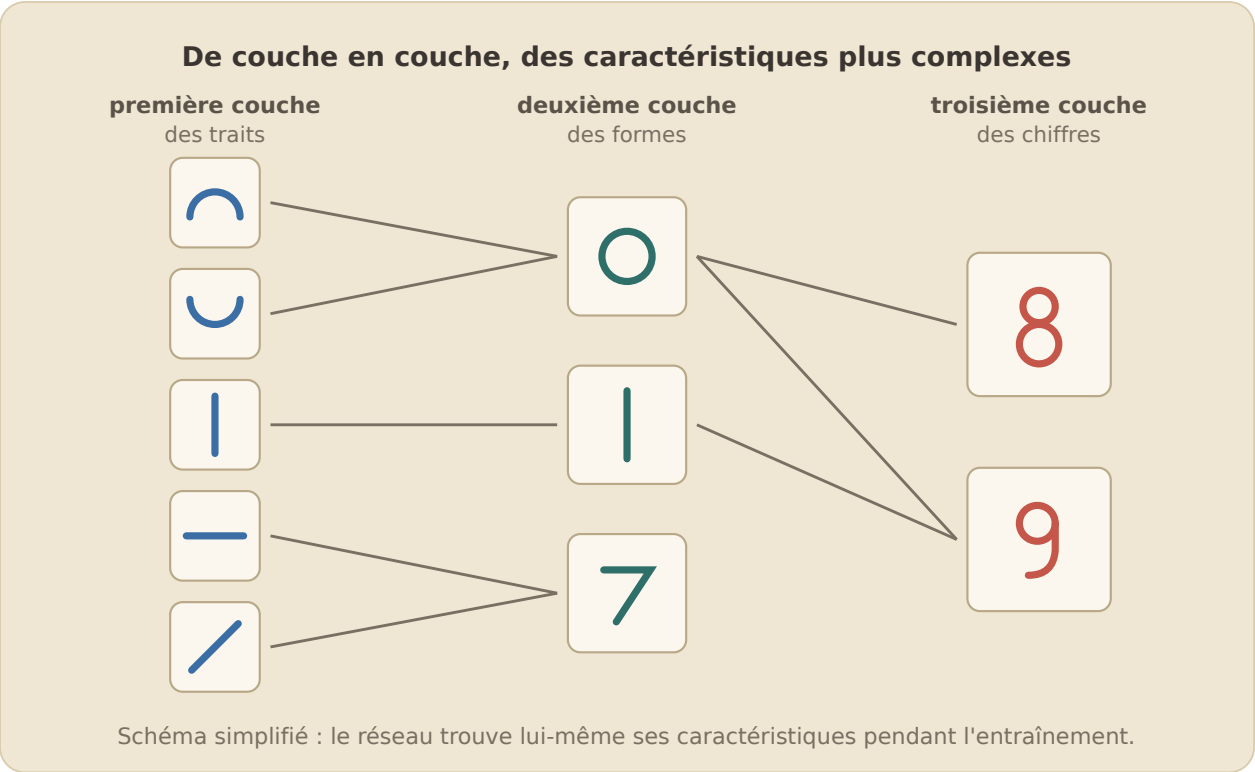
Mélanger les colonnes d'un tableau ne change rien à ce qu'il dit. Mélanger les pixels d'une image efface ce qu'elle montre.

Ce module raconte ce retour, et explique comment ces réseaux fonctionnent.

Une seule grande idée : apprendre ses propres caractéristiques

Au Module 2, un modèle recevait des données décrites par des **caractéristiques** (*features*), c'est-à-dire des grandeurs mesurables qui décrivent chaque exemple : la superficie d'une maison, son année de construction, la présence d'un mot dans un courriel. C'est un humain qui choisissait ces caractéristiques, et le modèle ne voyait les données qu'à travers elles. Quand un problème résistait, comme le XOR, c'était encore à l'humain d'inventer une nouvelle caractéristique, le produit des deux entrées, qui rendait le problème facile.

Cette nouvelle caractéristique est une **combinaison** de deux autres. C'est une idée importante : une caractéristique peut être construite à partir d'autres caractéristiques, elles-mêmes construites à partir d'autres, sur plusieurs étages. Pour une image de chiffre, les caractéristiques de départ sont les pixels, qui ne disent presque rien isolément. En combinant des pixels voisins, on obtient de petits traits. En combinant des traits, on obtient des courbes et des coins. En combinant des courbes, on obtient une boucle fermée ou une barre verticale. C'est en combinant ces formes qu'on reconnaît un 8 ou un 9. Concevoir à la main tous ces étages, pour toutes les façons d'écrire chaque chiffre, est presque impossible.



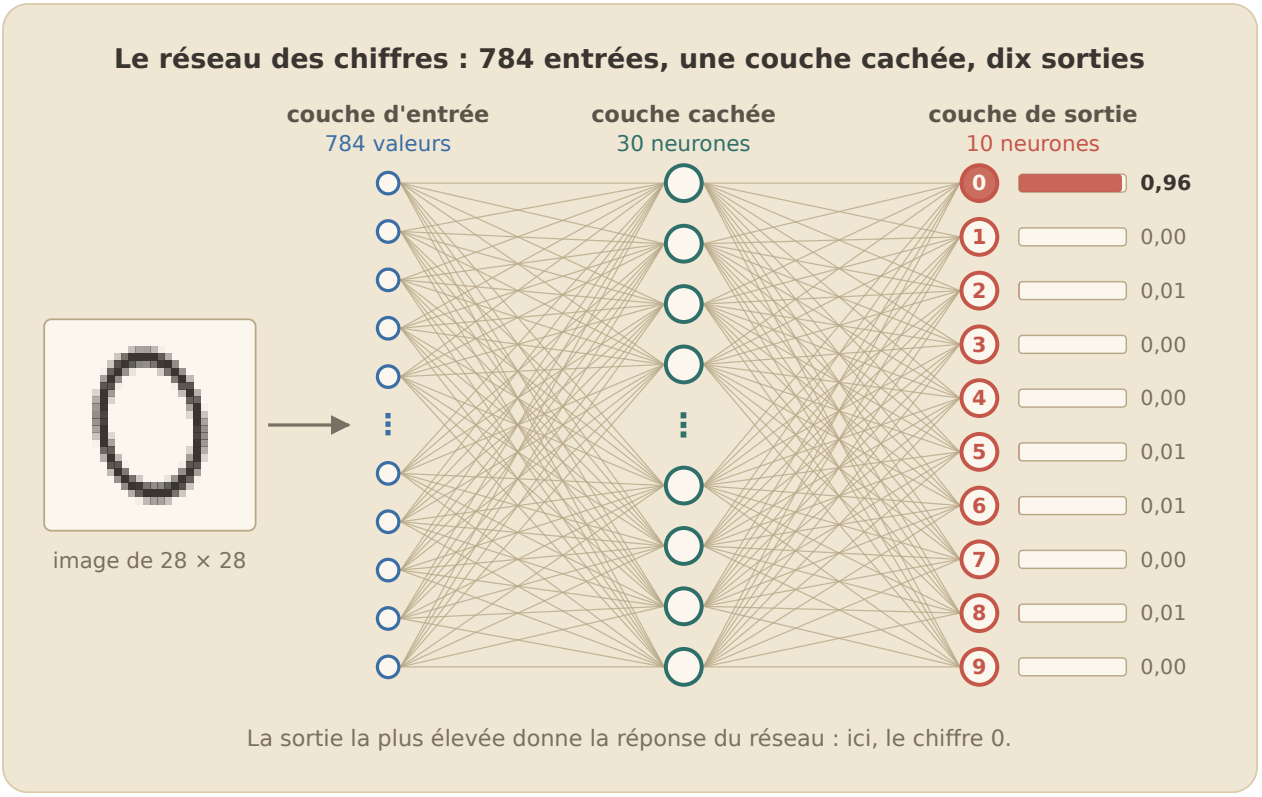
Une hiérarchie de caractéristiques : des traits, puis des formes, puis des chiffres.

Un réseau de neurones fabrique lui-même ses caractéristiques. Chacune de ses couches combine les caractéristiques de la couche précédente pour en former de nouvelles, plus utiles. Un réseau qui reconnaît des chiffres manuscrits reçoit seulement des pixels. Il apprend seul à y repérer des traits, puis des formes, puis des chiffres. Personne ne lui indique quoi chercher.

Pour le reste, rien ne change. Un réseau s'entraîne avec le même schéma qu'au Module 2 : des données, un modèle réglable, une erreur à réduire, et la descente de gradient pour la réduire. La différence est l'échelle. Une droite avait deux paramètres. Un réseau en a des milliers, des millions, et parfois des centaines de milliards.

Un fil conducteur : les chiffres manuscrits

Un même exemple revient tout au long du module : reconnaître un chiffre écrit à la main, sur une image de 28 pixels sur 28. On le retrouve dans le premier neurone, dans le réseau à une couche cachée, dans les réseaux convolutifs de Yann Le Cun, qui lisaient les chèques dans les années 1990, et dans les exemples adverses qui trompent un réseau.



Le réseau des chiffres, qui sert d'exemple tout au long du module.

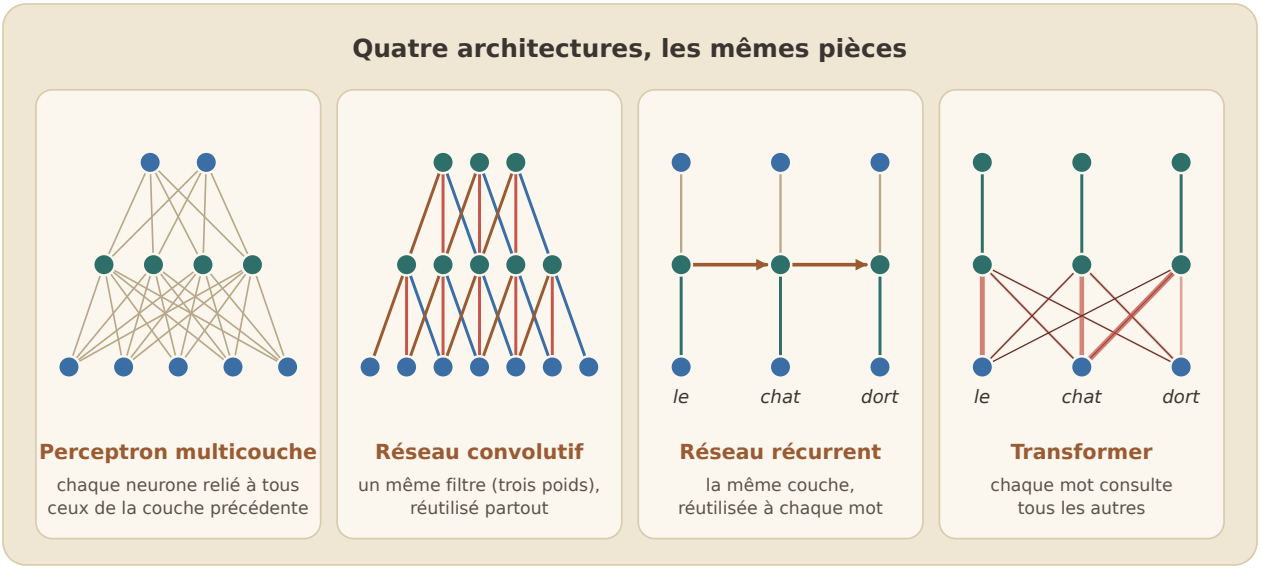
Ce que ce module n'est pas

Trois précisions évitent des malentendus fréquents.

- **Un réseau de neurones n'est pas un cerveau.** Il s'en inspire, mais un neurone artificiel est une formule simple. Le module y revient deux fois, dans les pages *Un neurone* et *L'apprentissage profond*.
- **Les réseaux de ce module reconnaissent et prédisent.** Ils associent une réponse à une entrée : quel chiffre, quel mot traduit, quel coup jouer. La génération de textes et d'images est le sujet du Module 4, qui s'appuie sur les architectures présentées ici, en particulier le Transformer.
- **Aucune formule n'est nécessaire.** Les mécanismes sont expliqués par des figures et des applets. Les calculs, pour qui veut les voir, sont dans des blocs dépliables « Pour aller plus loin ».

Des variations sur un même thème

Les réseaux de ce module portent des noms différents : perceptron multicouche, réseau convolutif, réseau récurrent, Transformer. Ils reposent pourtant tous sur les mêmes pièces. Ce sont des neurones qui calculent des sommes pondérées, des fonctions d'activation et des poids ajustés par une même méthode, la rétropropagation. D'un réseau à l'autre, seule change la façon de relier ces pièces, c'est-à-dire l'architecture. Un réseau convolutif réutilise le même petit filtre partout dans l'image. Un réseau récurrent réutilise la même couche à chaque mot. Un Transformer laisse chaque mot consulter tous les autres.



Des neurones, des poids, une activation. Seule change la façon de les relier.

Ces pièces s'assemblent comme celles d'un jeu de construction. On peut les empiler, les combiner, ou brancher un réseau à la suite d'un autre, et l'ensemble s'entraîne toujours de la même façon. C'est l'une des grandes forces des réseaux de neurones. C'est aussi ce qui explique qu'une seule famille de méthodes se soit imposée pour les images, les sons, les textes et les jeux.

Le parcours du module

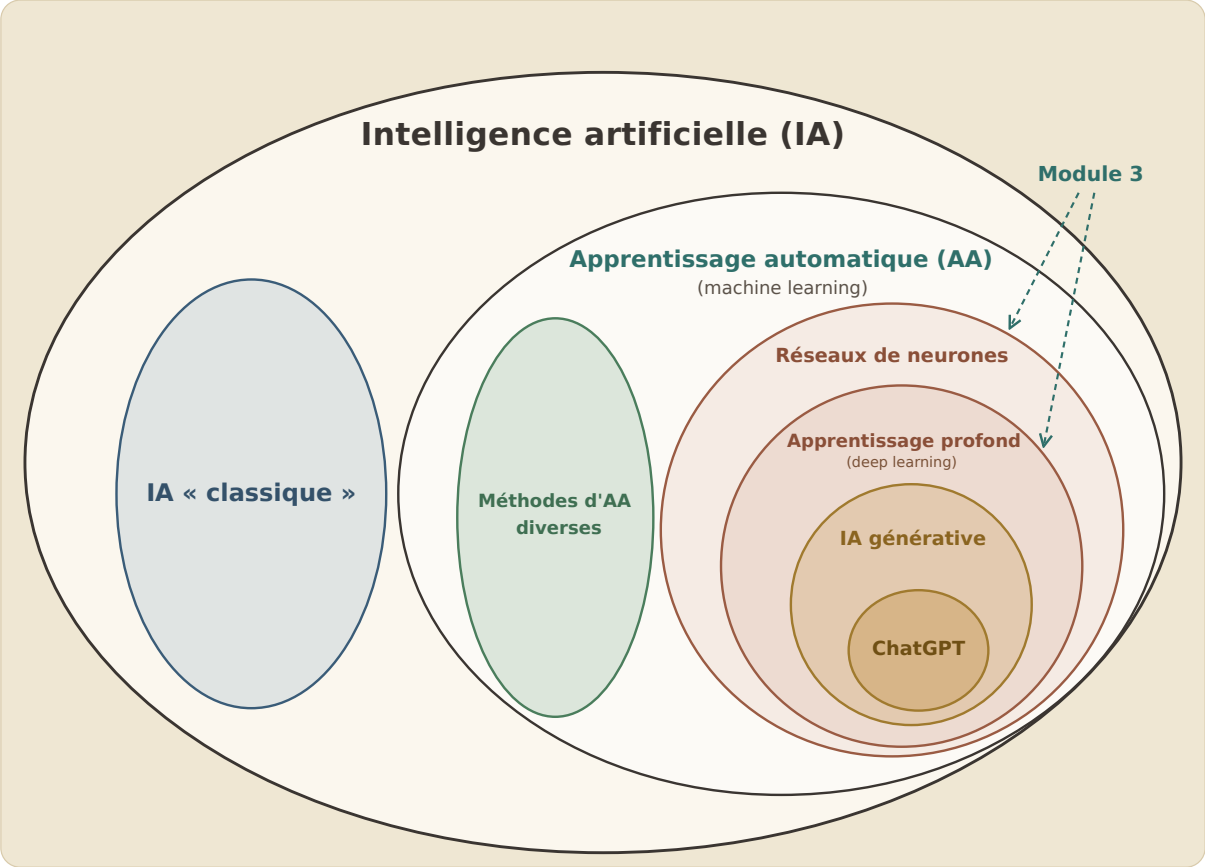
Comme au Module 2, chaque page rencontre une limite qui mène à la suivante.

1. *Un neurone* : le retour du perceptron. Un neurone est une régression logistique, et il ne trace qu'une droite.
2. *Une couche cachée* : quelques neurones reliés résolvent le XOR, en fabriquant eux-mêmes la bonne caractéristique.
3. *Entraîner un réseau* : la rétropropagation, et la question de 1969 réglée en 1986.
4. *L'apprentissage profond* : pourquoi empiler les couches, et pourquoi cela n'a fonctionné qu'à partir de 2012.
5. *Le matériel et les outils* : l'histoire des processeurs graphiques et de la différentiation automatique.
6. *Voir : les réseaux convolutifs* : le filtre qui glisse sur l'image, Yann Le Cun et les chèques, l'apprentissage par transfert.
7. *Lire une séquence : les réseaux récurrents* : un réseau avec une mémoire, le LSTM, la traduction.
8. *L'attention et le Transformer* : regarder toute la séquence à la fois, l'architecture des grands modèles actuels.
9. *Apprendre à jouer : le renforcement profond* : Atari, AlphaGo, AlphaZero.
10. *Tromper un réseau* : les exemples adverses, et la boîte noire.

Le module compte huit applets, dont un neurone à régler, un réseau qui apprend le XOR sous vos yeux, un filtre de convolution, une machine qui apprend le morpion en jouant contre elle-même, et un classifieur à tromper.

Pour situer ce module dans l'ensemble du cours : les réseaux de neurones sont une famille de

méthodes d'apprentissage automatique, devenue la plus importante depuis 2012, et sur laquelle reposent l'IA générative et les grands modèles de langage du Module 4.



La carte de l'IA : le Module 3 porte sur les réseaux de neurones et l'apprentissage profond.

Objectifs

Au terme de ce module, vous devriez être en mesure de :

- expliquer ce qu'est un neurone artificiel, et pourquoi un neurone seul ne trace qu'une frontière droite ;
- expliquer comment une couche cachée permet de résoudre le XOR, en fabriquant de nouvelles caractéristiques ;
- décrire le principe de la rétropropagation, et le distinguer de l'inférence ;
- expliquer ce qu'apporte la profondeur, et les trois conditions du succès de 2012 : les données, le calcul et de meilleures méthodes d'entraînement ;
- décrire l'idée principale des réseaux convolutifs, des réseaux récurrents et du Transformer, et le type de données auquel chacun est adapté ;
- expliquer comment on réutilise un réseau déjà entraîné pour une nouvelle tâche (apprentissage par transfert) ;
- expliquer comment le renforcement profond combine la recherche du Module 1 et l'apprentissage ;
- expliquer ce qu'est un exemple adverse, et pourquoi un réseau profond est une boîte noire ;

- situer ces développements dans l'histoire du connexionnisme, de 1958 à aujourd'hui.

Durée

Quatre semaines, soit environ 36 heures.

Évaluation

Un travail noté (20 % de la note finale) où vous manipulerez des réseaux de neurones dans une application interactive, TensorFlow Playground, avec des questions d'interprétation.

Un neurone

Le chapitre « Deux paris rivaux » a présenté le **perceptron** de Frank Rosenblatt (1958), une machine qui apprend à partir d'exemples au lieu de suivre des règles écrites à la main. Le chapitre « Les hivers et la bascule » a montré comment cette approche a été mise de côté après 1969, quand Minsky et Papert ont démontré qu'un perceptron ne peut pas apprendre certaines fonctions simples, comme le XOR.

Les **réseaux de neurones** (*neural networks*) actuels sont les descendants directs du perceptron. Le plus simple d'entre eux en porte d'ailleurs le nom : le **perceptron multicouche** (*multilayer perceptron*, MLP). Ce module explique comment ils fonctionnent, comment ils ont dépassé la limite de 1969, et pourquoi ils dominent l'intelligence artificielle depuis le début des années 2010. Il commence par l'élément de base, le **neurone artificiel** (*artificial neuron*).

Un neurone est une régression logistique

Vous connaissez déjà le neurone artificiel, sous un autre nom. C'est la régression logistique (*logistic regression*) du Module 2.

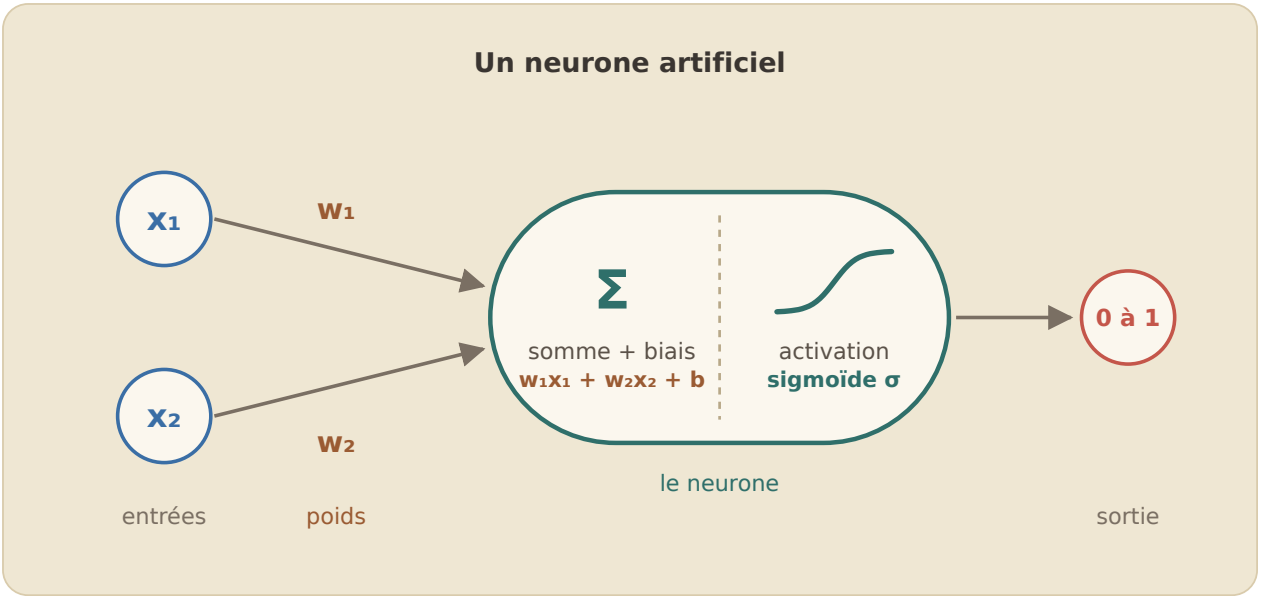
Un neurone reçoit des nombres en **entrée**, et il produit un seul nombre en **sortie**. Il effectue pour cela deux opérations :

1. Il multiplie chaque entrée par un **poids** (*weight*), il additionne les résultats, et il ajoute un dernier nombre, le **biais** (*bias*). On obtient une somme pondérée (*weighted sum*).
2. Il passe cette somme dans une **fonction d'activation** (*activation function*). La plus classique est la sigmoïde, qui ramène n'importe quel nombre à une valeur comprise entre 0 et 1.

Pour un neurone à deux entrées, le calcul s'écrit ainsi :

$$\text{sortie} = \sigma(w_1 x_1 + w_2 x_2 + b)$$

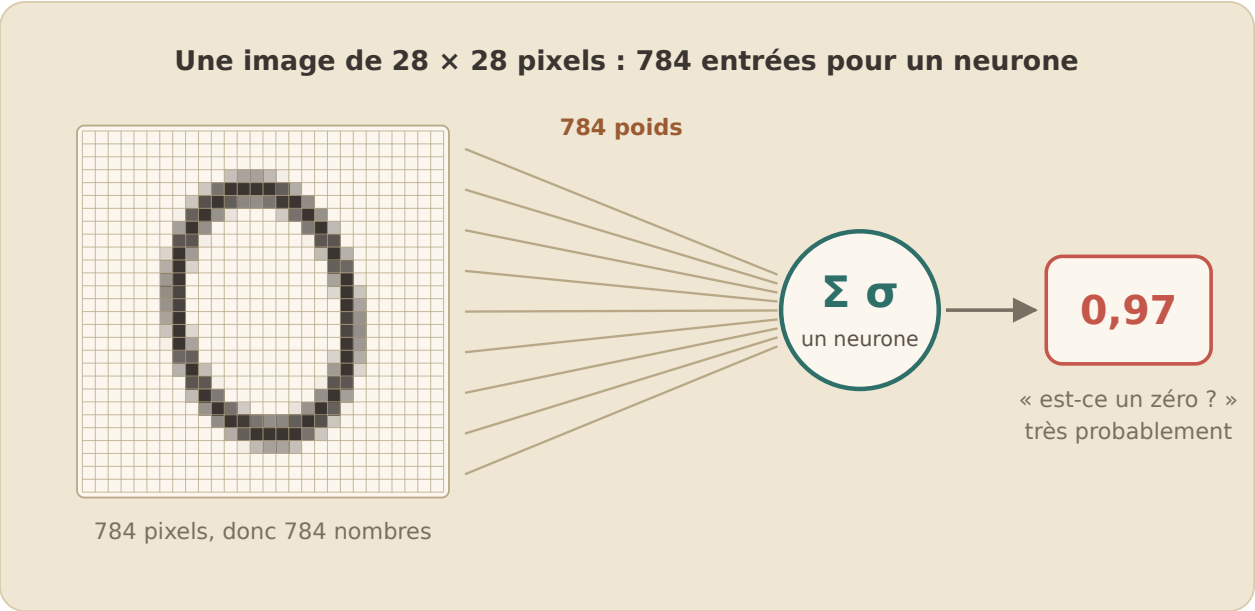
où x_1 et x_2 sont les entrées, w_1 et w_2 les poids, b le biais et σ la sigmoïde.



Un neurone artificiel : une somme pondérée des entrées, puis une fonction d'activation.

Les poids et le biais sont les **paramètres** du neurone, au sens du Module 2. Un poids élevé donne beaucoup d'importance à l'entrée correspondante, un poids proche de zéro la fait presque ignorer, et un poids négatif la fait compter contre la conclusion. Comme pour tous les modèles du Module 2, on ne fixe pas ces paramètres à la main. On les règle par descente de gradient (*gradient descent*), à partir d'exemples.

Un neurone peut avoir beaucoup plus que deux entrées. Prenons l'exemple qui servira dans tout ce module, la **reconnaissance de chiffres manuscrits** (*handwritten digit recognition*). Une image de chiffre de 28 pixels sur 28 est une liste de 784 nombres, un par pixel, comme l'a montré le chapitre « Regarder les données ». Un neurone qui reçoit cette image a donc 784 entrées et 784 poids. Sa sortie peut se lire comme une réponse à une question simple, par exemple « cette image est-elle un zéro ? ».

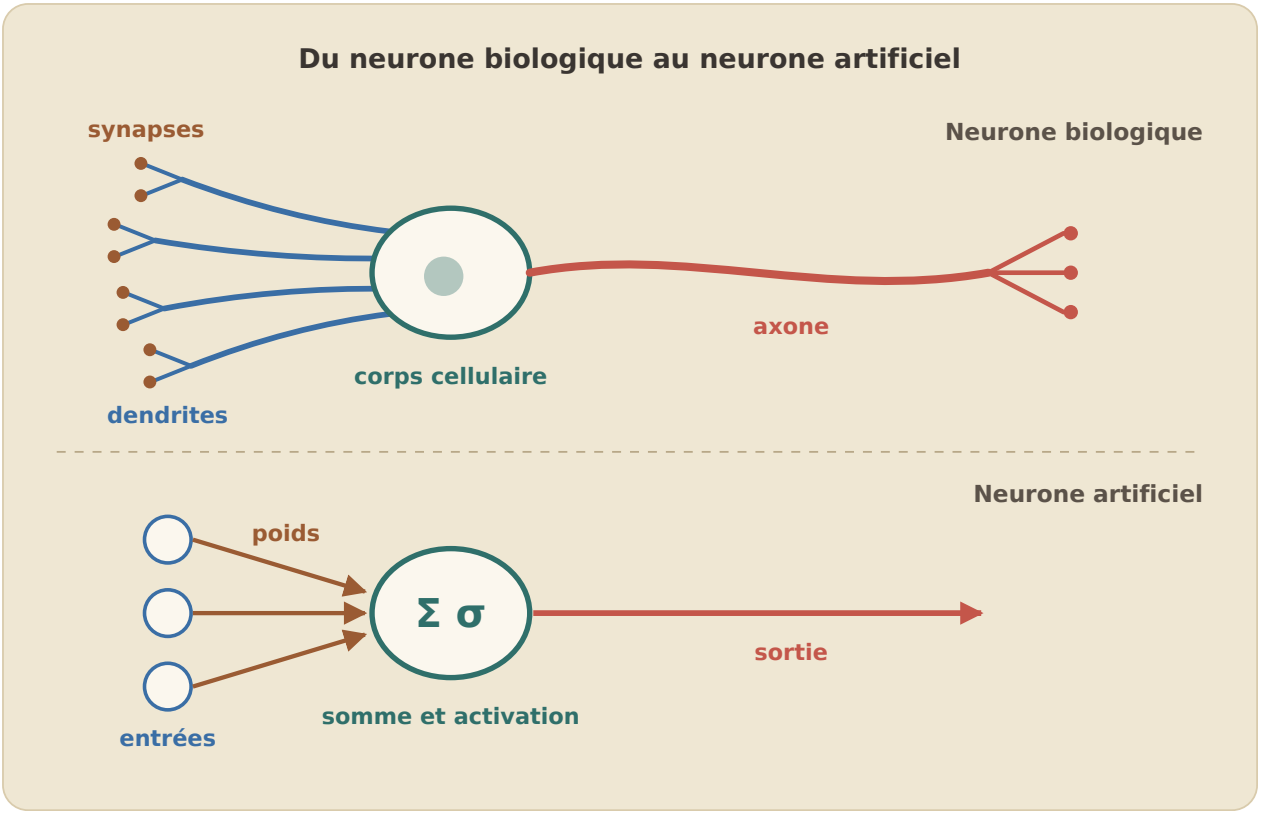


Une image de chiffre manuscrit donne 784 entrées à un neurone, qui répond par un nombre entre 0 et 1.

D'où vient le mot « neurone »

Le terme vient d'une analogie avec le cerveau. Un neurone biologique reçoit des signaux d'autres neurones par ses **dendrites**. Il les combine dans son **corps cellulaire**. Si le signal combiné est assez fort, il envoie à son tour un signal le long de son **axone**, vers d'autres neurones. Les points de contact entre neurones s'appellent des **synapses**, et leur force varie avec l'expérience.

Le neurone artificiel reprend ce schéma en le simplifiant beaucoup. Les entrées jouent le rôle des dendrites, les poids celui des synapses, la somme et la fonction d'activation celui du corps cellulaire, et la sortie celui de l'axone.



Du neurone biologique au neurone artificiel : les entrées pour les dendrites, les poids pour les synapses, le calcul pour le corps cellulaire, la sortie pour l'axone.

Cette analogie a guidé les premiers chercheurs, mais elle est très approximative. Un neurone biologique est beaucoup plus complexe qu'une somme suivie d'une fonction. Le chapitre « L'apprentissage profond » reviendra sur ce que cette comparaison permet de dire, et sur ce qu'elle ne permet pas.

Un neurone à manipuler

Dans l'applet ci-dessous, vous réglez vous-même les entrées et les paramètres d'un neurone, et vous observez sa sortie.

Applet interactive : à utiliser en ligne, sur la page « Un neurone » du site du cours.

Essayez les trois manipulations suivantes :

1. Fixez les deux entrées à 1. Trouvez des poids qui donnent une sortie proche de 1, puis des poids qui donnent une sortie proche de 0.
2. Donnez un poids de zéro à la première entrée. Faites varier cette entrée, et observez que la sortie ne change plus.
3. Donnez un poids négatif à la seconde entrée. Augmentez cette entrée, et observez que la sortie diminue.

Ce qu'un neurone seul ne peut pas faire

Un neurone seul a la même limite que la régression logistique. Sa somme pondérée définit une **frontière droite** : d'un côté, la sortie est supérieure à 0,5, et de l'autre, elle est inférieure. Un neurone ne peut donc séparer deux catégories que si une droite suffit à les séparer.

Ce n'est pas toujours le cas. Le XOR, présenté avec sa table de vérité (*truth table*) au Module 1, en est l'exemple le plus simple. Ses quatre cas occupent les coins d'un carré, et aucune droite ne sépare les deux cas « vrai » des deux cas « faux ». C'est exactement la limite que Minsky et Papert ont démontrée en 1969.

Au Module 2, on contournait cette limite de deux façons : en changeant de modèle, ou en fabriquant à la main une nouvelle caractéristique (*feature*). Les réseaux de neurones apportent une troisième réponse. On relie plusieurs neurones entre eux, et le réseau fabrique lui-même la caractéristique qui manque. C'est le sujet du chapitre suivant, « Une couche cachée ».

Une couche cachée

Le chapitre « Un neurone » s'est terminé sur une limite : un neurone seul ne trace qu'une frontière droite, et il ne peut donc pas apprendre le XOR. Ce chapitre montre comment quelques neurones reliés entre eux dépassent cette limite.

Relier des neurones

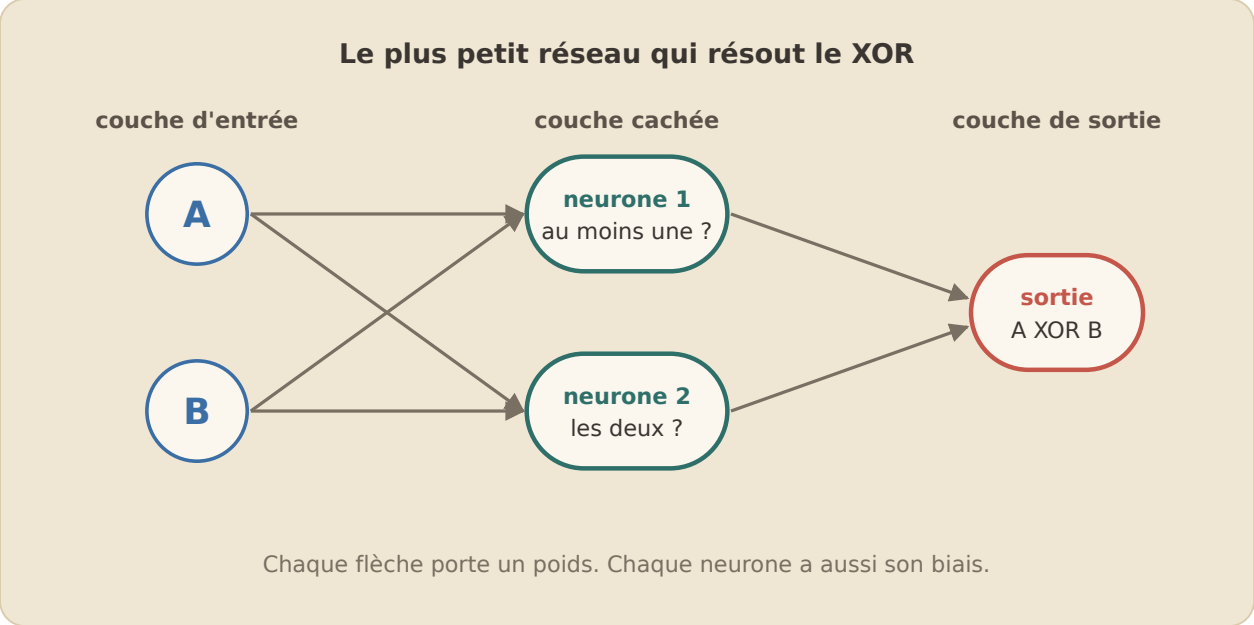
La sortie d'un neurone est un nombre. Rien n'empêche de donner ce nombre en entrée à un autre neurone. On obtient alors un **réseau de neurones**, organisé en **couches** (*layers*) :

- la **couche d'entrée** (*input layer*) contient les données, par exemple les deux entrées du XOR ou les 784 pixels d'une image ;
- la **couche de sortie** (*output layer*) donne la réponse du réseau ;
- entre les deux, une ou plusieurs **couches cachées** (*hidden layers*) font des calculs intermédiaires. On les appelle « cachées » parce que, de l'extérieur, on ne voit que les entrées et la réponse.

Chaque neurone d'une couche reçoit les sorties de tous les neurones de la couche précédente, chacune avec son propre poids.

Un réseau construit de cette façon s'appelle un **perceptron multicouche** (*multilayer perceptron*, MLP). Le nom est un héritage historique, un peu trompeur : ses neurones ne sont pas exactement des perceptrons de Rosenblatt, puisque leur sortie varie de façon continue au lieu de passer brusquement de 0 à 1. Mais l'idée est bien celle-là : des perceptrons empilés en plusieurs couches. C'est le type de réseau le plus simple, et celui de ce chapitre et du suivant.

La forme d'un réseau s'appelle son **architecture** (*architecture*) : le nombre de couches, le nombre de neurones dans chacune, et surtout la façon dont ils sont reliés. Le dessin de ces connexions, où chaque neurone est un point et chaque poids un trait, s'appelle sa **topologie** (*topology*). L'architecture est choisie par un humain avant l'entraînement, alors que les poids sont appris. Le perceptron multicouche relie chaque neurone à tous ceux de la couche précédente. C'est la topologie la plus simple, mais pas la seule. Les chapitres suivants présentent d'autres architectures, adaptées aux images, aux séquences ou au langage. Elles sont toutes faites des mêmes briques, des neurones reliés par des poids et entraînés par la même méthode. Seule change la façon de les relier.



Le plus petit réseau qui résout le XOR : deux entrées, deux neurones cachés, un neurone de sortie.

Le XOR résolu avec trois neurones

Reprenons le XOR, avec ses deux entrées A et B. Le réseau ci-dessus le résout si chaque neurone répond à une question simple, qu'un neurone seul sait traiter :

- le premier neurone caché répond à la question « **au moins une** des deux entrées est-elle vraie ? » ;
- le second neurone caché répond à la question « les **deux** entrées sont-elles vraies ? » ;
- le neurone de sortie combine ces deux réponses. Il répond « vrai » quand le premier neurone dit oui et que le second dit non, c'est-à-dire quand au moins une entrée est vraie, mais pas les deux.

La table suivante reprend les quatre cas :

A	B	Neurone 1 : au moins une ?	Neurone 2 : les deux ?	Sortie : A XOR B
0	0	0	0	0
0	1	1	0	1
1	0	1	0	1
1	1	1	1	0

La dernière colonne est bien celle de la table de vérité du XOR. Aucun des trois neurones ne fait quelque chose de difficile. C'est leur combinaison qui résout un problème qu'aucun d'eux ne peut résoudre seul.

Pour aller plus loin : les poids de ce réseau
Voici des poids et des biais qui donnent exactement ce comportement. Chaque neurone calcule

une somme pondérée, puis la passe dans la sigmoïde, comme dans le chapitre « Un neurone ».

Neurone	Poids	Biais	Somme calculée
Neurone 1 (au moins une ?)	10 et 10	-5	$10{\cdot}A + 10{\cdot}B - 5$
Neurone 2 (les deux ?)	10 et 10	-15	$10{\cdot}A + 10{\cdot}B - 15$
Sortie	10 et -20	-5	$10{\cdot}(\text{neurone 1}) - 20{\cdot}(\text{neurone 2}) - 5$

Prenons le cas $A = 0$ et $B = 1$:

- le neurone 1 calcule $10{\cdot}0 + 10{\cdot}1 - 5 = 5$, et la sigmoïde donne environ 0,99 ;
- le neurone 2 calcule $10{\cdot}0 + 10{\cdot}1 - 15 = -5$, et la sigmoïde donne environ 0,01 ;
- la sortie calcule $10{\cdot}0{,}99 - 20{\cdot}0{,}01 - 5 = 4{,}7$, et la sigmoïde donne environ 0,99.

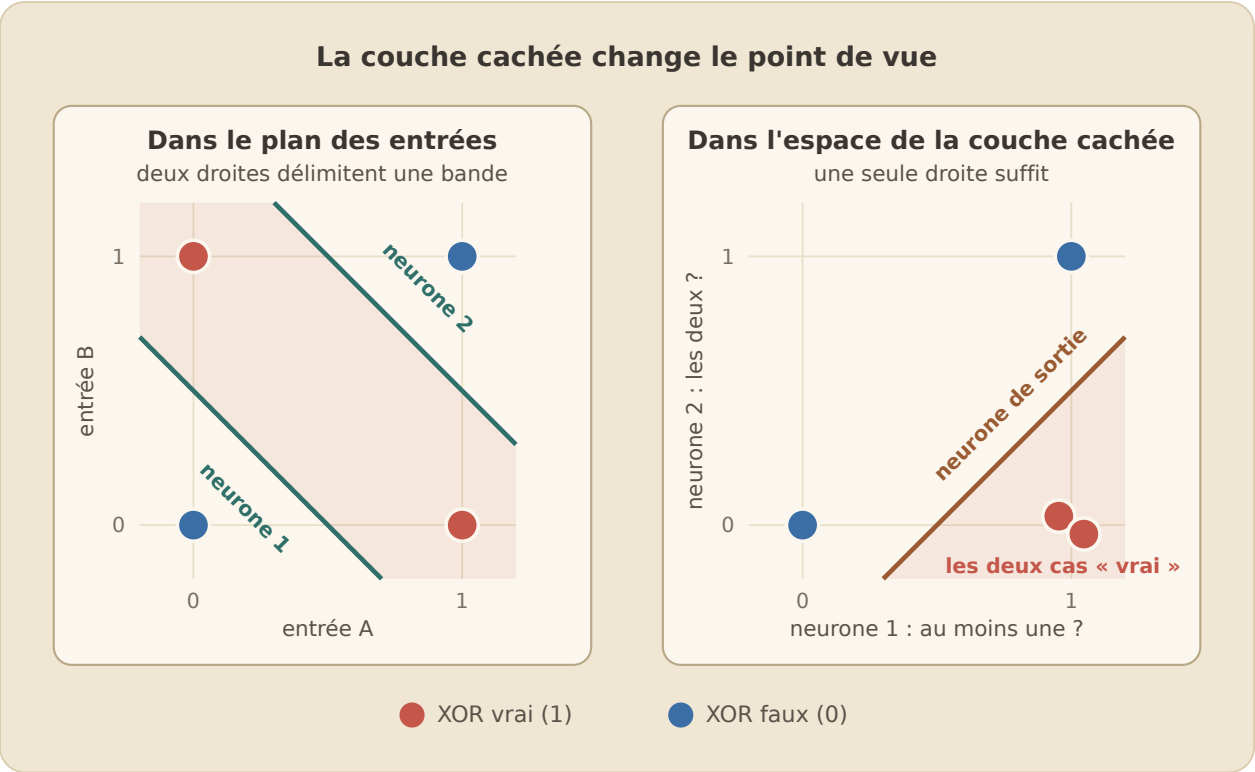
Le réseau répond donc « vrai », comme prévu. Les trois autres cas se vérifient de la même façon. Les poids sont grands $(10, 20)$ pour que la sigmoïde donne des réponses nettes, très proches de 0 ou de 1.

Ce que fait la couche cachée : changer de point de vue

On peut comprendre ce résultat de deux façons.

Première lecture : deux droites au lieu d'une. Chaque neurone caché trace sa propre droite dans le plan des entrées. Avec deux droites, on délimite une bande. Les deux cas « vrai » du XOR sont dans la bande, et les deux cas « faux » sont à l'extérieur, un de chaque côté. Une seule droite ne pouvait pas faire ce découpage.

Seconde lecture : un nouvel espace. La couche cachée remplace les deux entrées, A et B, par deux nouvelles valeurs, les réponses des neurones 1 et 2. Dans ce nouvel espace, les quatre cas ne sont plus aux coins d'un carré. Les deux cas « vrai » arrivent au même endroit, et une seule droite suffit maintenant à les séparer des deux autres. Le neurone de sortie trace cette droite.



Le XOR avant et après la couche cachée : deux droites dans le plan des entrées, une seule droite dans le nouvel espace.

Cette seconde lecture rejoint une idée du Module 2. Dans « Généraliser », on rendait le XOR séparable en ajoutant à la main une caractéristique, le produit des deux entrées. Ce produit vaut 1 seulement quand les deux entrées valent 1. C'est exactement la question à laquelle répond le neurone 2. La différence est que personne n'a besoin de trouver cette caractéristique : avec les bons poids, le réseau la construit lui-même. Une couche cachée est donc une **fabrique de caractéristiques**.

Deux droites à déplacer

Dans l'applet ci-dessous, chaque droite représente un neurone caché. Vous pouvez la déplacer et la faire pivoter, comme dans l'applet de la régression logistique. La zone délimitée par les deux droites est colorée : c'est là que le réseau répond « vrai ». Un point mal classé est entouré d'un cercle orange.

Applet interactive : à utiliser en ligne, sur la page « Une couche cachée » du site du cours.

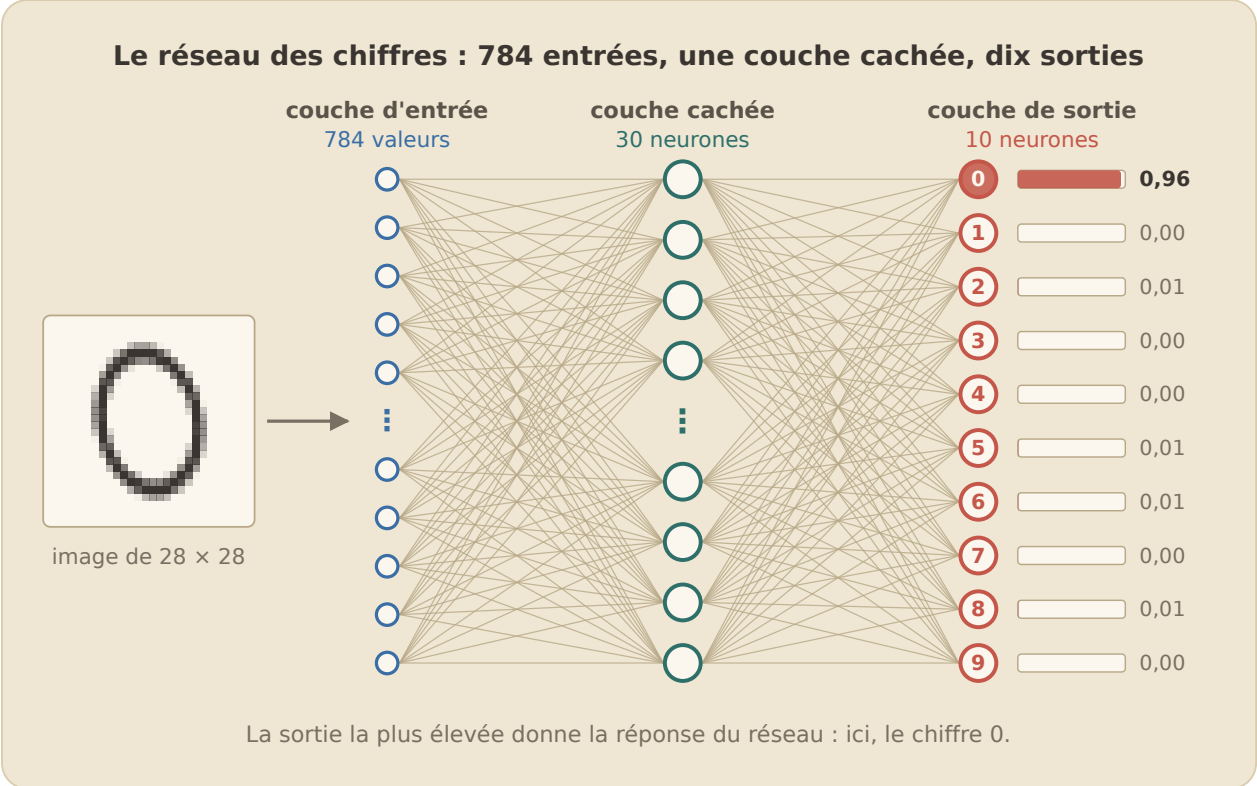
1. Placez les deux droites pour que la zone colorée contienne les deux points rouges, et aucun point bleu.
2. Cherchez une autre solution, avec des droites orientées autrement. Il en existe plusieurs.
3. Choisissez ensuite le second jeu de points, « un groupe entouré », où un groupe rouge est entouré de points bleus. Constatez que deux droites ne suffisent plus.
4. Ajoutez une troisième droite, avec le bouton « 3 », et entourez le groupe rouge.

Plus de neurones, plus de formes

Deux neurones cachés donnent deux droites. Trois neurones en donnent trois, ce qui permet de délimiter un triangle, comme dans la dernière manipulation. Avec un grand nombre de neurones, on peut entourer une zone de forme quelconque, à la précision voulue.

Ce résultat a été démontré en 1989, sous le nom de **théorème d'approximation universelle** (*universal approximation theorem*) : un réseau à une seule couche cachée, avec assez de neurones, peut approcher presque n'importe quelle fonction. Le répertoire de formes d'un réseau de neurones n'a donc pas la limite de celui d'un modèle linéaire.

Un réseau peut aussi avoir plusieurs sorties. Pour reconnaître les chiffres manuscrits, on utilise un réseau à **dix sorties**, une par chiffre. Chaque sortie donne un nombre entre 0 et 1, et le réseau répond par le chiffre dont la sortie est la plus élevée. En pratique, on fait en sorte que les dix sorties totalisent 1. Elles forment alors une distribution de probabilités sur les dix chiffres, comme les probabilités « pourriel » et « courriel » du classifieur bayésien. Le réseau ne répond pas seulement « c'est un 0 », mais « c'est un 0, avec une probabilité de 96 % ».



Un réseau pour les chiffres manuscrits : 784 entrées, une couche cachée de 30 neurones, dix sorties.

Qui règle tous ces poids ?

Pour le XOR, nous avons choisi les poids à la main, parce que le réseau n'en compte que neuf. Le réseau des chiffres en compte des milliers. Avec une couche cachée de 30 neurones, il y a 784 × 30 poids entre l'entrée et la couche cachée, puis 30 × 10 entre la couche cachée et la sortie, soit près de 24 000 paramètres en comptant les biais. Personne ne peut les régler à la main.

Le théorème d'approximation universelle dit qu'il existe de bons poids. Il ne dit pas comment les trouver. Ce problème a bloqué les réseaux de neurones pendant près de vingt ans. On savait depuis les années 1960 qu'une couche cachée dépasserait la limite du perceptron, mais on ne savait pas comment entraîner un tel réseau. La solution, la **rétropropagation du gradient** (*backpropagation*), s'est imposée en 1986. C'est le sujet du chapitre suivant, « Entraîner un réseau ».

Entraîner un réseau

Le chapitre « Une couche cachée » s'est terminé sur un réseau de près de 24 000 poids, que personne ne peut régler à la main. Ce chapitre explique comment un réseau règle lui-même ses poids, à partir d'exemples.

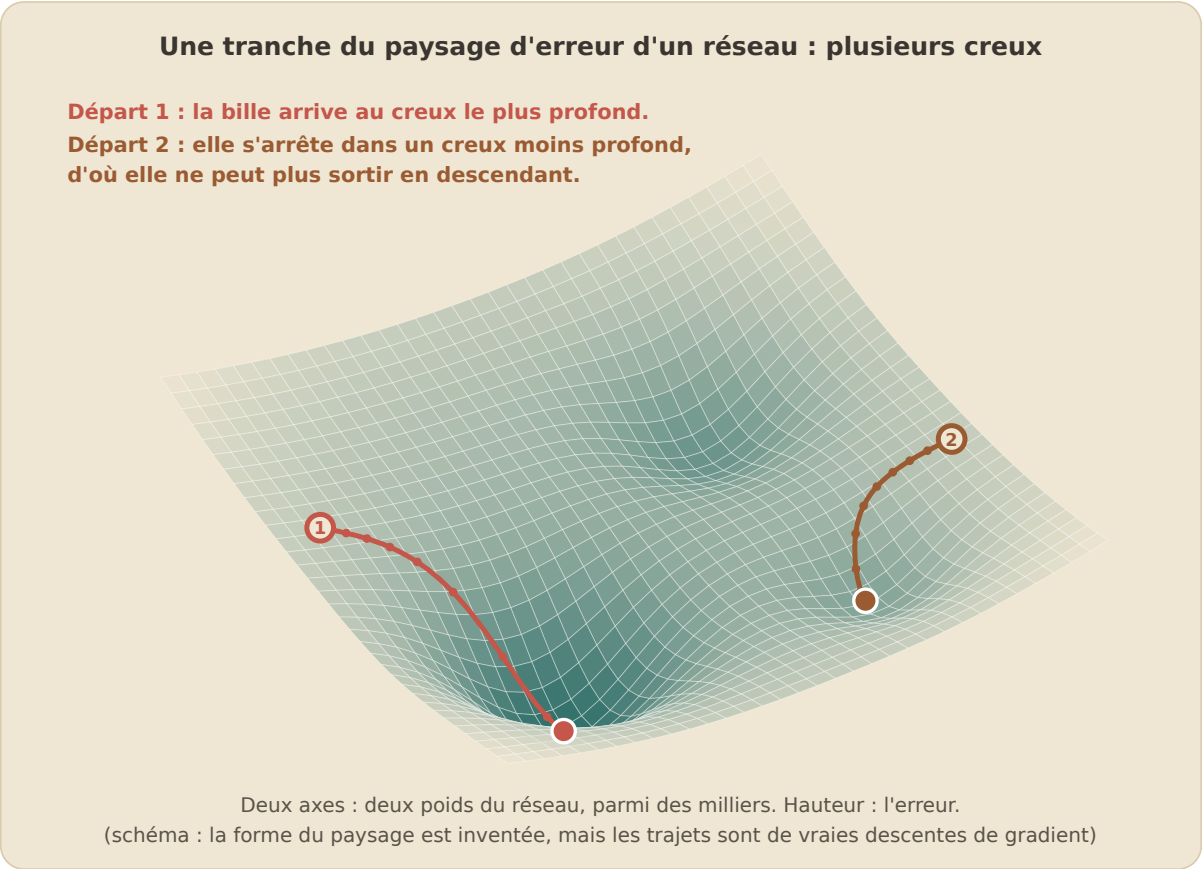
Le même principe qu'au Module 2

La méthode a déjà été présentée dans « Apprendre, c'est descendre la pente ». Elle tient en trois étapes, qu'on répète :

1. on mesure l'**erreur** du modèle sur des exemples dont on connaît la bonne réponse ;
2. on cherche dans quel sens modifier chaque paramètre pour que l'erreur diminue ;
3. on modifie un peu chaque paramètre dans ce sens.

C'est la **descente de gradient**. Pour la droite du Module 2, il y avait deux paramètres, et l'erreur formait un paysage qu'on pouvait dessiner. Pour un réseau, les paramètres sont les poids et les biais. Le paysage a alors des milliers de dimensions et on ne peut plus le dessiner, mais la méthode reste la même : mesurer la pente, puis faire un pas vers le bas.

On peut toutefois en dessiner une tranche, en ne faisant varier que deux poids. Contrairement à la cuvette du Module 2, ce paysage a en général plusieurs creux, et le creux où l'on arrive dépend du point de départ. La section « Un réseau qui apprend le XOR » le montre sur un vrai réseau.



Une tranche du paysage d'erreur d'un réseau, selon deux de ses poids. Selon le point de départ, la descente de gradient mène à des creux différents.

Pour un réseau qui classe, l'erreur mesurée est en général la même que celle de la régression logistique. La réduire revient à rendre les bonnes réponses aussi probables que possible : c'est le maximum de vraisemblance (*maximum likelihood*) présenté au Module 2.

Le problème des couches cachées

La deuxième étape est simple pour un neurone seul. On connaît la bonne réponse, on voit donc directement si sa sortie est trop haute ou trop basse, et on corrige ses poids en conséquence. C'est ce que faisait le perceptron dès 1958.

Dans un réseau, cela ne vaut que pour la couche de sortie. Pour un neurone caché, les exemples ne donnent aucune bonne réponse. Reprenons le réseau du XOR : la table de vérité dit ce que la sortie doit valoir, mais elle ne dit pas que le premier neurone caché doit répondre à la question « au moins une ? ». Quand le réseau se trompe, on ne sait pas quel neurone caché est en cause, ni dans quel sens le corriger.

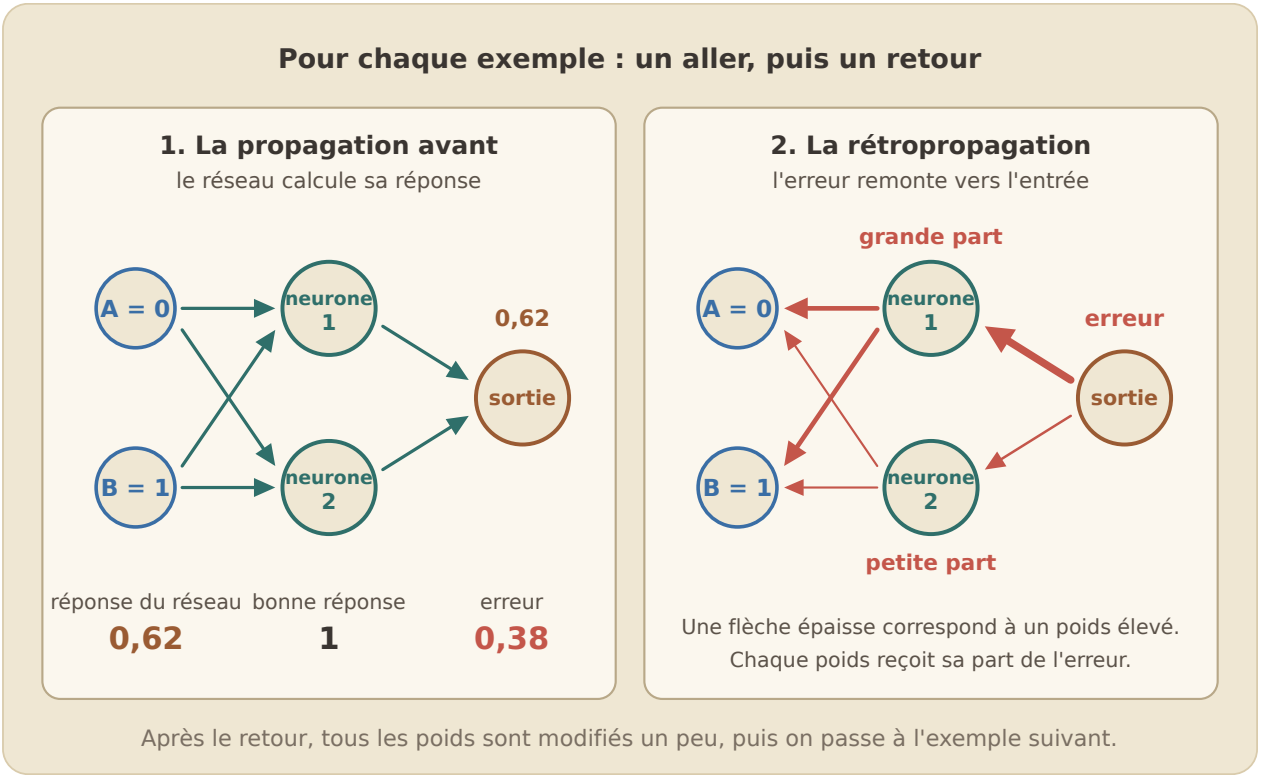
Ce problème s'appelle l'**attribution de la responsabilité** (*credit assignment* en anglais). C'est lui qui a arrêté la recherche sur les réseaux de neurones après 1969 : on savait qu'une couche cachée était nécessaire, et on ne savait pas l'entraîner.

La rétropropagation

La solution consiste à calculer la responsabilité de chaque poids en partant de la sortie et en remontant vers l'entrée. Pour chaque exemple, le calcul se fait en deux temps.

La propagation avant (*forward pass*). L'exemple entre dans le réseau. Chaque couche calcule ses sorties et les passe à la suivante, jusqu'à la réponse du réseau. On compare cette réponse à la bonne, ce qui donne l'erreur. Les poids sont utilisés, mais pas modifiés.

La rétropropagation. L'erreur repart en sens inverse. Le neurone de sortie reçoit l'erreur entière. Il la répartit entre les neurones cachés qui lui ont envoyé un signal, selon le poids de chaque connexion : un neurone caché relié par un poids élevé a beaucoup contribué à la réponse, et il reçoit donc une grande part de l'erreur. Chaque neurone caché sait alors dans quel sens il aurait dû répondre, et on peut corriger ses poids comme ceux d'un neurone seul.



Les deux temps du calcul pour un exemple : la propagation avant donne la réponse et l'erreur, la rétropropagation répartit cette erreur entre les poids.

Une fois la part de chaque poids connue, on modifie tous les poids un peu, dans le sens qui réduit l'erreur. Puis on passe à l'exemple suivant. Le nom complet de la méthode est la **rétropropagation du gradient** (*backpropagation* en anglais).

Avec plusieurs couches cachées, le principe ne change pas : l'erreur remonte d'une couche à la précédente, jusqu'à l'entrée.

Pour aller plus loin : ce que calcule la rétropropagation
Un réseau est une suite de calculs emboîtés. La sortie dépend de la couche cachée, qui dépend elle-même des entrées et des poids. La descente de gradient demande, pour chaque poids, la pente de l'erreur par rapport à ce poids, c'est-à-dire une dérivée. Pour des calculs emboîtés, cette dérivée s'obtient par la règle de dérivation en chaîne (*chain rule*) : on multiplie entre elles les dérivées de chaque étape, de la sortie jusqu'au poids visé.
La rétropropagation est une façon efficace d'appliquer cette règle. En partant de la sortie, elle réutilise les calculs faits pour une couche quand elle traite la couche précédente. Le coût total est à peu près celui de deux propagations avant, quel que soit le nombre de poids. Sans cette économie, il faudrait refaire un calcul complet pour chaque poids, ce qui serait impraticable pour un grand réseau.
Cette méthode exige que chaque étape du calcul ait une dérivée. C'est la raison pour laquelle les neurones utilisent une fonction d'activation lisse comme la sigmoïde, et non le seuil brusque du perceptron d'origine.

Un réseau qui apprend le XOR

L'applet ci-dessous reprend le réseau du XOR, avec ses deux neurones cachés. Les poids de départ sont tirés au hasard. Quand vous lancez l'entraînement, le réseau voit les quatre cas en boucle et corrige ses poids par rétropropagation. Les deux droites sont celles des neurones cachés, comme dans l'applet du chapitre précédent, mais cette fois personne ne les déplace.

Applet interactive : à utiliser en ligne, sur la page « Entraîner un réseau » du site du cours.

1. Lancez l'entraînement. Observez les droites se placer et l'erreur descendre.
2. Repartez de nouveaux poids de départ, plusieurs fois, avec le bouton « Nouveaux poids ». Le réseau ne trouve pas toujours la même solution, et il lui arrive de rester bloqué avec une erreur élevée, environ une fois sur cinq.
3. Changez le taux d'apprentissage. S'il est très petit, l'apprentissage est très lent. S'il est trop grand, l'erreur oscille ou reste élevée, au lieu de descendre.

La deuxième manipulation montre une différence avec la droite du Module 2. Le paysage d'erreur (*loss landscape*) d'un réseau n'est pas une cuvette unique. Il comporte plusieurs creux, et la descente s'arrête dans celui qu'elle rencontre, qui dépend du point de départ. Pour les grands réseaux, on constate en pratique que la plupart des creux donnent des résultats comparables.

1986

La rétropropagation a été découverte plusieurs fois. Paul Werbos la décrit dans sa thèse en 1974, sans que le résultat soit remarqué. En 1986, David Rumelhart, Geoffrey Hinton et Ronald Williams publient dans la revue *Nature* un article, « Learning representations by back-propagating errors », qui montre, expériences à l'appui, qu'un réseau entraîné de cette façon construit lui-même des caractéristiques utiles dans ses couches cachées. C'est cet article qui impose la méthode, et son nom anglais, *backpropagation*, souvent abrégé en *backprop*.

La question ouverte en 1969 est alors réglée. Le XOR, que le perceptron ne pouvait pas apprendre, est appris par un réseau à couche cachée. Les réseaux de neurones redeviennent un sujet de recherche actif, sous le nom de **connexionnisme**. La même année, Rumelhart, James McClelland et leur groupe

de recherche publient *Parallel Distributed Processing*, deux volumes qui présentent cette approche, de ses principes à ses applications en psychologie. L'ouvrage fait connaître le connexionnisme bien au-delà de l'informatique, chez les psychologues, les linguistes et les philosophes.

Ce retour reste limité pendant une vingtaine d'années. Les réseaux de l'époque sont petits, les données rares et les ordinateurs lents. D'autres méthodes progressent plus vite. La plus influente est la machine à vecteurs de support (SVM), présentée au Module 2, dont la forme actuelle date de 1995. Grâce à l'astuce du noyau (*kernel trick*), elle trace des frontières courbes sans avoir à fabriquer de caractéristiques. Son entraînement a un avantage décisif sur celui d'un réseau : il n'y a qu'un seul creux dans le paysage d'erreur, et on est donc sûr de trouver la meilleure solution, quel que soit le point de départ. La deuxième manipulation de l'applet ci-dessus montre que ce n'est pas le cas pour un réseau. Le *boosting* et les forêts aléatoires (*random forests*) complètent cette boîte à outils. Jusqu'au début des années 2010, ces méthodes l'emportent souvent sur les réseaux de neurones, et les grandes conférences du domaine publient peu de travaux sur ces derniers. Le chapitre suivant explique ce qui a changé ensuite.

L'entraînement en pratique

Quelques termes reviennent dans la suite du cours.

- La **descente de gradient stochastique** (*stochastic gradient descent*, SGD). Calculer la pente exacte demanderait de passer sur tous les exemples d'entraînement avant chaque pas, soit des millions pour un grand réseau. En pratique, on estime la pente à partir d'un petit groupe d'exemples tirés au hasard, un **lot** (*batch* ou *mini-batch*), de quelques dizaines à quelques milliers d'exemples, et on fait un pas après chaque lot. Cette pente est approximative, un peu différente d'un lot à l'autre, et la descente zigzague, d'où le mot *stochastique*, qui signifie « au hasard ». Elle est pourtant beaucoup plus rapide, et ce bruit a un avantage inattendu : il aide parfois la descente à sortir d'un creux peu profond, comme celui de la figure plus haut. Des variantes, comme Adam (2014), ajustent en plus la taille des pas pour chaque poids, et ce sont elles qu'on utilise le plus aujourd'hui.
- Une **époque** (*epoch*) est un passage complet sur tous les exemples d'entraînement. Un entraînement compte en général plusieurs époques.
- Le **taux d'apprentissage** (*learning rate*) règle la taille de chaque correction, comme au Module 2.

Il faut aussi distinguer deux phases dans la vie d'un réseau.

- L'**entraînement** (*training*) règle les poids. Il demande beaucoup de calculs, parce qu'il répète l'aller et le retour sur des millions d'exemples. Il est fait une fois.
- L'**inférence** est l'utilisation du réseau entraîné. Les poids ne changent plus, et seule la propagation avant est exécutée. Elle est faite à chaque utilisation.

Cette distinction reviendra au Module 4 : entraîner un grand modèle de langage (*large language model*) prend des semaines ou des mois, alors qu'une réponse est produite en quelques secondes.

Un réseau a beaucoup de paramètres, et il est donc très exposé au sur-apprentissage (*overfitting*). Les remèdes sont ceux de « Généraliser » : un jeu de test (*test set*), et la régularisation. Pour les réseaux, la régularisation prend trois formes courantes. Le *weight decay* pénalise les poids trop grands. Le *dropout* désactive au hasard une partie des neurones à chaque étape de l'entraînement. L'**arrêt précoce** (*early stopping*) interrompt l'entraînement quand l'erreur sur des exemples mis de côté cesse de diminuer.

Pour voir le mécanisme en détail

La chaîne 3Blue1Brown, de Grant Sanderson, propose une série de vidéos sur les réseaux de neurones, construite sur l'exemple des chiffres manuscrits. Les explications sont visuelles et progressives. La vidéo ci-dessous porte sur la rétropropagation.

Vidéo : https://www.youtube.com/watch?v=Ilg3gGewQ5U

Deux autres vidéos de la série complètent ce chapitre : la première présente la structure d'un réseau, et la deuxième la descente de gradient. Les vidéos sont en anglais.

On sait maintenant entraîner un réseau à une couche cachée. Le chapitre suivant, « L'apprentissage profond », examine ce qu'on gagne à empiler plusieurs couches.

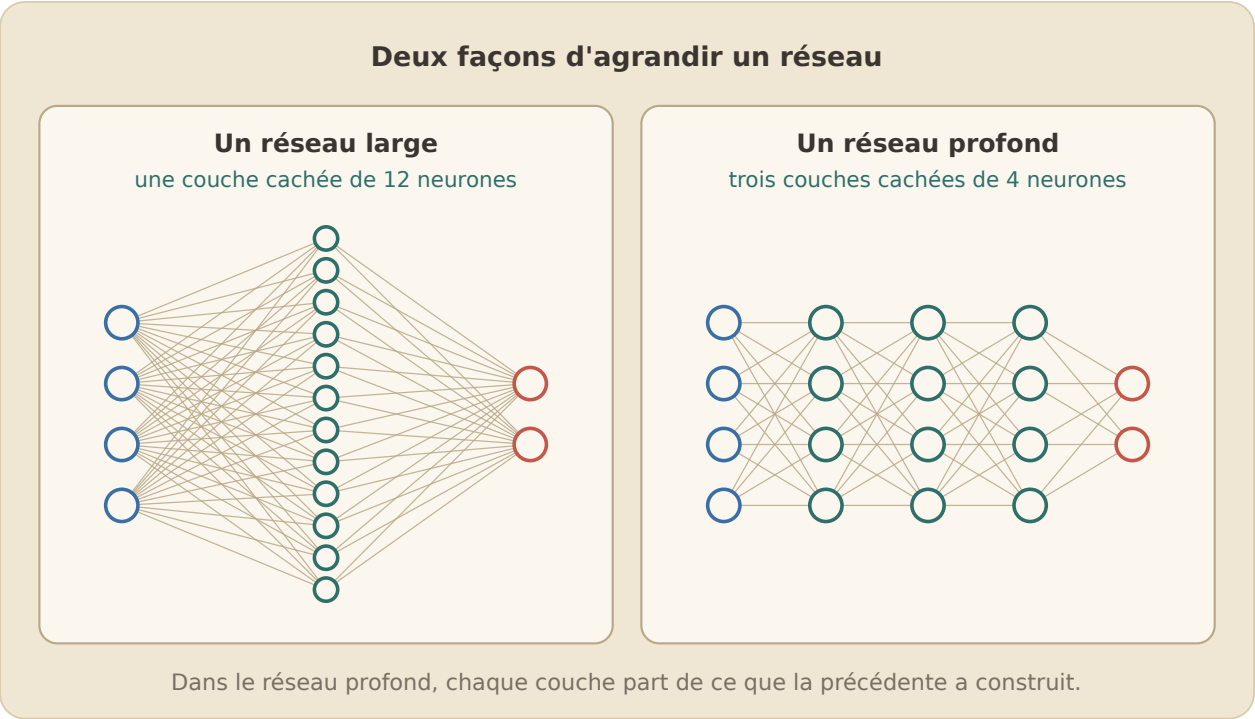
L'apprentissage profond

D'après le théorème d'approximation universelle, une seule couche cachée suffit pour approcher presque n'importe quelle fonction. Pourtant, les réseaux qui ont transformé l'IA à partir de 2012 comptent des dizaines de couches. On les appelle des réseaux **profonds**, et leur entraînement, l'**apprentissage profond** (*deep learning* en anglais). Ce chapitre explique ce qu'on gagne à empiler les couches, et pourquoi cela n'a fonctionné qu'à partir de 2012.

Large ou profond

Le théorème dit qu'une couche suffit. Il ne dit pas combien de neurones elle doit contenir. Pour certains problèmes, ce nombre est si grand que le réseau ne peut être ni stocké ni entraîné.

Il y a deux façons d'agrandir un réseau. On peut l'élargir, en ajoutant des neurones à sa couche cachée. On peut l'approfondir, en ajoutant des couches. Les deux augmentent ce que le réseau peut représenter, mais pas au même coût. Dans un réseau profond, chaque couche part de ce que la précédente a déjà construit, et le réutilise. Un réseau large à une seule couche doit tout construire directement à partir des entrées, sans étape intermédiaire. Pour beaucoup de problèmes, le réseau profond obtient le même résultat avec beaucoup moins de neurones.

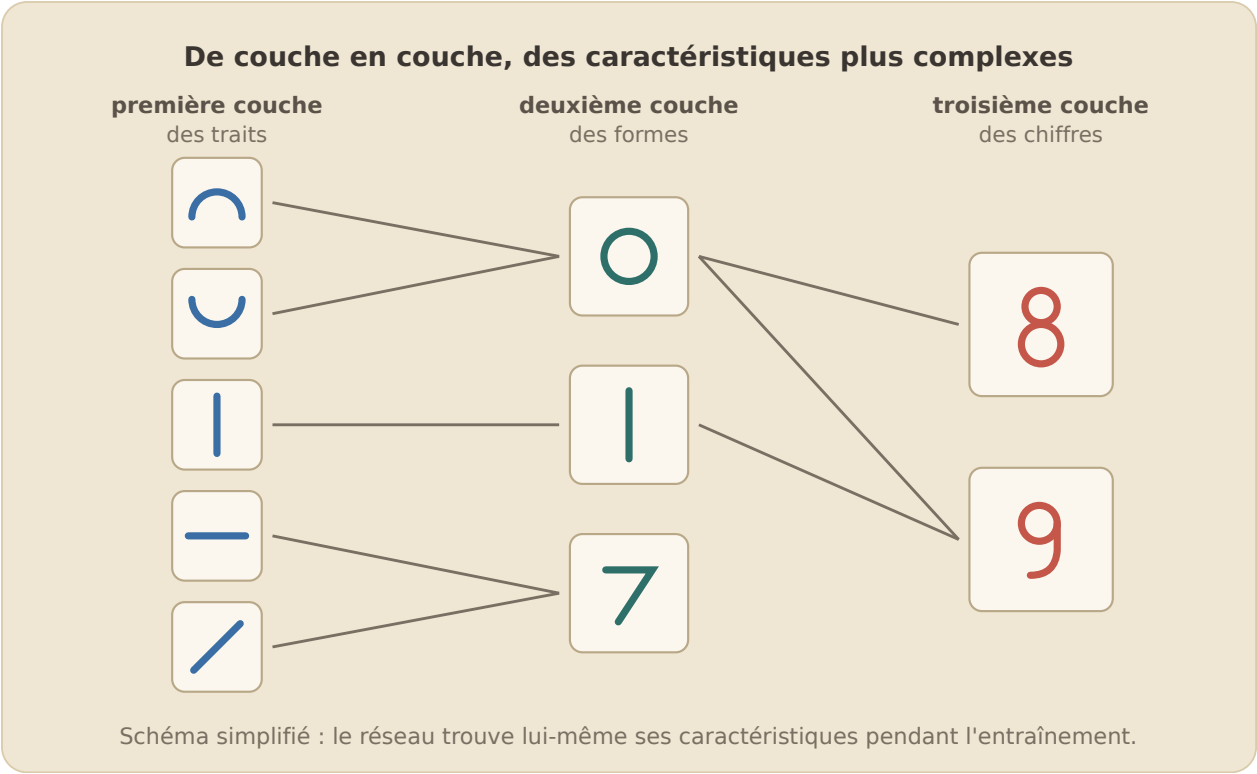


Deux façons d'agrandir un réseau : ajouter des neurones à la couche cachée, ou ajouter des couches.

Une hiérarchie de caractéristiques

Le chapitre « Une couche cachée » a montré qu'une couche cachée est une fabrique de caractéristiques. Dans un réseau profond, chaque couche fabrique les siennes à partir de celles de la couche précédente. Les caractéristiques deviennent plus complexes de couche en couche.

Prenons les chiffres manuscrits. Une première couche peut détecter de petits traits, à différents endroits et selon différentes orientations. Une deuxième couche combine ces traits en formes : une boucle, un angle, une barre verticale. Une troisième combine ces formes en chiffres. Un 9 est une boucle au-dessus d'une barre, un 8 est fait de deux boucles.



Une hiérarchie de caractéristiques : des traits, puis des formes, puis des chiffres.

Cette description est simplifiée. Personne n'indique au réseau quoi détecter dans chaque couche. Il le trouve pendant l'entraînement, et les caractéristiques réelles sont souvent moins nettes que dans ce schéma. Mais quand on examine les couches d'un réseau entraîné sur des images, on observe bien cette progression, de motifs simples vers des motifs complexes.

On peut voir ce que cherche un neurone d'un réseau entraîné. On part d'une image de bruit, et on la modifie pas à pas, par rétropropagation, pour activer le plus possible un neurone choisi. L'image obtenue montre ce à quoi ce neurone réagit. Le même procédé sert à fabriquer les exemples adverses, présentés plus loin, au chapitre « Tromper un réseau ». En 2017, Chris Olah, Alexander Mordvintsev et Ludwig Schubert, chez Google, ont appliqué cette méthode à toutes les couches d'un réseau convolutif entraîné sur ImageNet.



Ce que cherchent des neurones de couches de plus en plus profondes d'un réseau entraîné sur ImageNet (d'après Olah, Mordvintsev et Schubert, Distill, 2017, CC BY 4.0).

La progression décrite plus haut apparaît bien, sans que personne l'ait programmée.

DeepDream
En juin 2015, Alexander Mordvintsev, Christopher Olah et Mike Tyka, ingénieurs chez Google, publient des images produites par un réseau convolutif entraîné sur ImageNet. Ils partent d'une photo ordinaire et la modifient pas à pas, par rétropropagation, pour **renforcer** ce que le réseau croit y voir. Si une tache rappelle vaguement un œil à une couche du réseau, l'image est modifiée pour ressembler davantage à un œil. On recommence, encore et encore. Comme ImageNet contient beaucoup de photos de chiens, des têtes de chiens, des yeux et des pattes finissent par apparaître partout : dans les nuages, sur les visages, dans les feuillages.



Une photo de méduses transformée par DeepDream : à chaque itération, le réseau renforce les formes animales qu'il croit voir (images de Martin Thoma, Wikimedia Commons, CC0).

Les chercheurs publient leur programme, et des milliers de personnes l'appliquent à leurs propres photos. Les images circulent dans le monde entier, et beaucoup y voient pour la première fois ce qui se passe à l'intérieur d'un réseau de neurones. Le phénomène rappelle la **paréidolie** (*pareidolia*), notre tendance à voir des visages dans les nuages ou les prises électriques. Le réseau fait de même avec ce qu'il a appris à reconnaître, mais en l'exagérant à chaque itération. DeepDream a aussi ouvert la voie à des usages artistiques des réseaux de neurones, qui annoncent l'IA générative du Module 4.

La carte n'est pas le territoire
Cette hiérarchie rappelle celle du cerveau. Dans les années 1960, David Hubel et Torsten Wiesel ont montré que le cortex visuel traite l'image par étapes : certains neurones réagissent à des traits orientés, d'autres, plus loin, à des formes. Les réseaux profonds se sont inspirés de ce résultat.
La ressemblance s'arrête là. Comme l'expliquait « D'où vient le mot « neurone » », un neurone artificiel est une formule. Un neurone biologique émet des impulsions électriques dans le temps, et son comportement dépend de nombreux signaux chimiques. Rien n'indique que le cerveau utilise la rétropropagation. Enfin, un enfant reconnaît un chat après en avoir vu quelques-uns, avec un cerveau qui consomme environ 20 watts, alors qu'un réseau a besoin de milliers d'exemples et de beaucoup plus d'énergie.
Un réseau de neurones est un modèle mathématique inspiré du cerveau. Ce n'est pas une copie du cerveau, et son fonctionnement ne nous apprend que peu de choses sur le nôtre.

La fin des caractéristiques fabriquées à la main

Jusqu'en 2012, un système de reconnaissance d'images se construisait en deux étapes. Des spécialistes concevaient d'abord des caractéristiques : des détecteurs de contours, de coins, de textures. Ces caractéristiques étaient ensuite données à un modèle simple, du type de ceux du Module 2. L'essentiel du travail, et de la performance, tenait à la première étape. Elle demandait des années de mise au point pour chaque type de données.

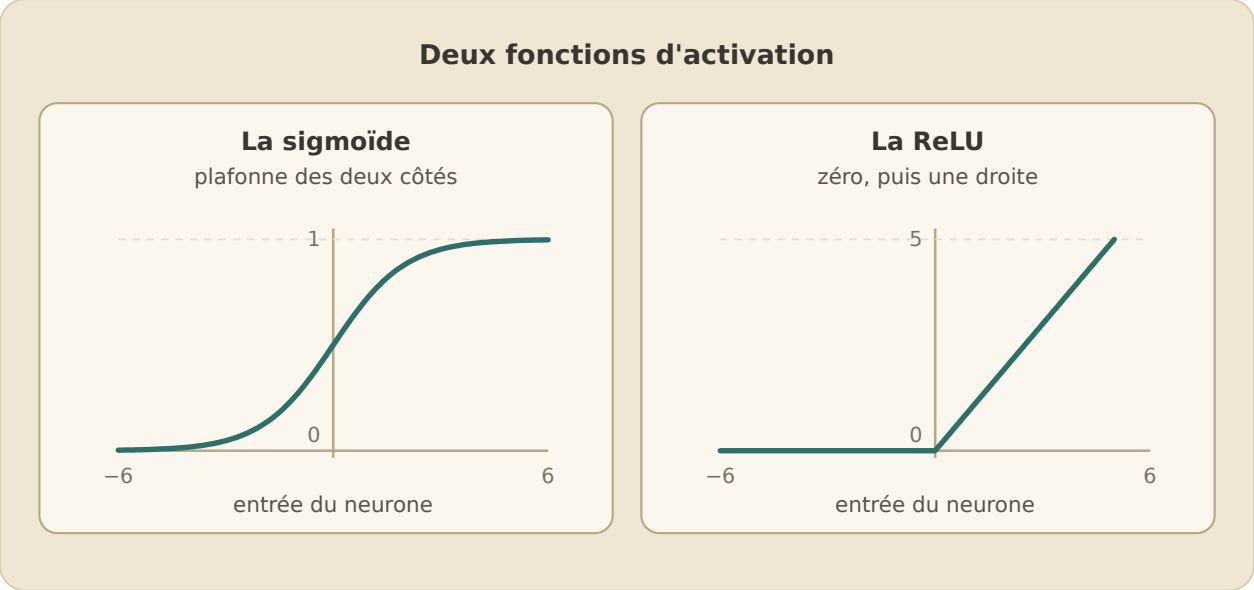
Un réseau profond supprime cette première étape. Il reçoit les pixels bruts, et il apprend à la fois les caractéristiques et la décision. On parle d'apprentissage **de bout en bout** (*end-to-end* en anglais). Le

travail humain se déplace : il ne consiste plus à concevoir des caractéristiques, mais à rassembler des données et à choisir la forme du réseau.

Pourquoi seulement en 2012

L'idée d'empiler des couches est ancienne, et la rétropropagation s'applique à un réseau de n'importe quelle profondeur. Trois obstacles ont pourtant bloqué les réseaux profonds pendant plus de vingt ans.

Le gradient qui s'évanouit. Pendant la rétropropagation, l'erreur remonte de couche en couche. Avec la sigmoïde, elle s'affaiblit à chaque couche traversée. Après quelques couches, il n'en reste presque rien, et les premières couches n'apprennent plus. Ce problème s'appelle l'**évanouissement du gradient** (*vanishing gradient*). Un des remèdes est de remplacer la sigmoïde par une fonction plus simple, la **ReLU** : elle donne 0 quand son entrée est négative, et laisse passer l'entrée telle quelle quand elle est positive. Avec elle, l'erreur traverse les couches sans s'affaiblir autant.



Deux fonctions d'activation : la sigmoïde, qui plafonne des deux côtés, et la ReLU.

Les données. Un réseau profond a des millions de paramètres, et il lui faut des millions d'exemples. Ils n'existaient pas. En 2009, l'équipe de Fei-Fei Li, à Stanford, publie **ImageNet** : 14 millions d'images, classées à la main dans plus de 20 000 catégories. Ce travail a été réalisé par des dizaines de milliers de personnes, sur la plateforme Mechanical Turk. C'est un exemple de l'industrie de l'étiquetage décrite au Module 2.



Quelques centaines d'images d'ImageNet. Elles sont disposées par un réseau profond, qui a placé côte à côte celles qu'il juge semblables (image : Andrej Karpathy).

Le calcul. Entraîner un réseau profond sur des millions d'images demande une quantité de calculs hors de portée des processeurs des années 2000. La solution est venue du jeu vidéo, avec les **processeurs graphiques** (*graphics processing units*, GPU), qui entraînent un réseau des dizaines de fois plus vite qu'un processeur ordinaire. Des bibliothèques logicielles ont ensuite automatisé la rétropropagation. Le chapitre « Le matériel et les outils » raconte ces deux histoires.

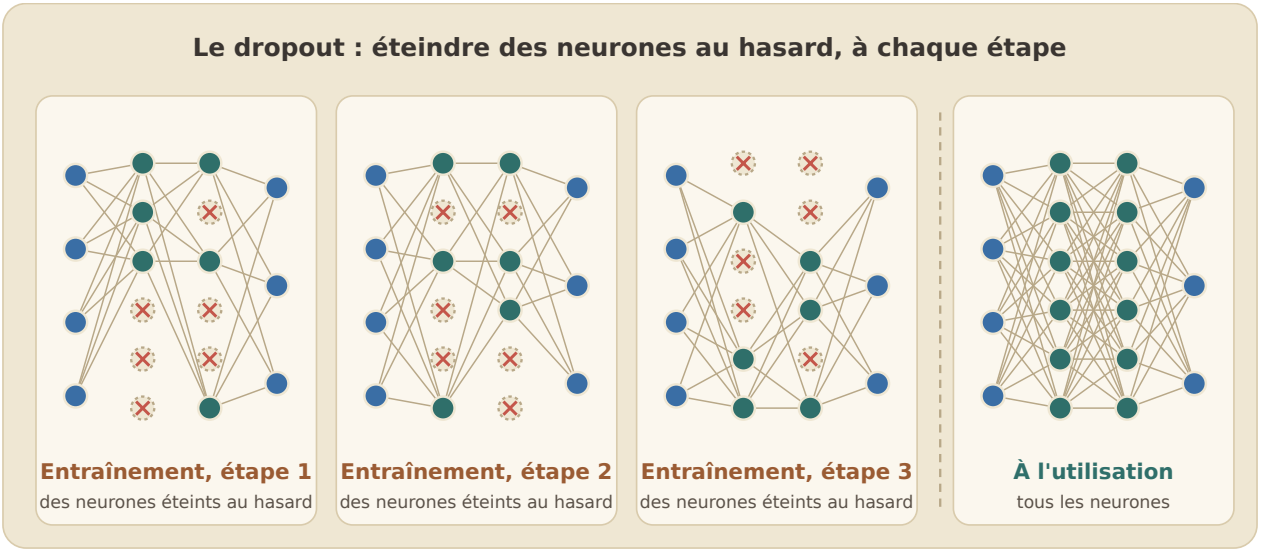
Un premier contournement, en 2006. Avant que ces trois obstacles soient levés, Hinton propose un détour. Au lieu d'entraîner toutes les couches d'un coup, on les entraîne une à une, sans étiquettes : chaque couche apprend à résumer ce que lui transmet la précédente, un peu comme un autoencodeur. Une fois toutes les couches en place, la rétropropagation ajuste l'ensemble. Ce **préentraînement couche par couche** (*greedy layer-wise pre-training*), publié par Hinton et ses collègues en 2006 et repris aussitôt par l'équipe de Bengio, montre qu'on peut enfin entraîner des réseaux à plusieurs couches cachées, et qu'ils font mieux que les réseaux peu profonds sur plusieurs tâches. C'est à cette époque que le nom *deep learning* s'impose. Quelques années plus tard, avec la ReLU, de grandes bases de données et les GPU, le détour devient inutile : AlexNet s'en passe. Mais il avait ramené l'attention sur les réseaux profonds.

2012 : le concours ImageNet

À partir de 2010, ImageNet sert de base à un concours annuel. Il faut classer des images parmi 1 000 catégories, après un entraînement sur 1,2 million d'exemples. Une réponse est comptée comme une erreur si la bonne catégorie ne figure pas parmi les cinq propositions du système.

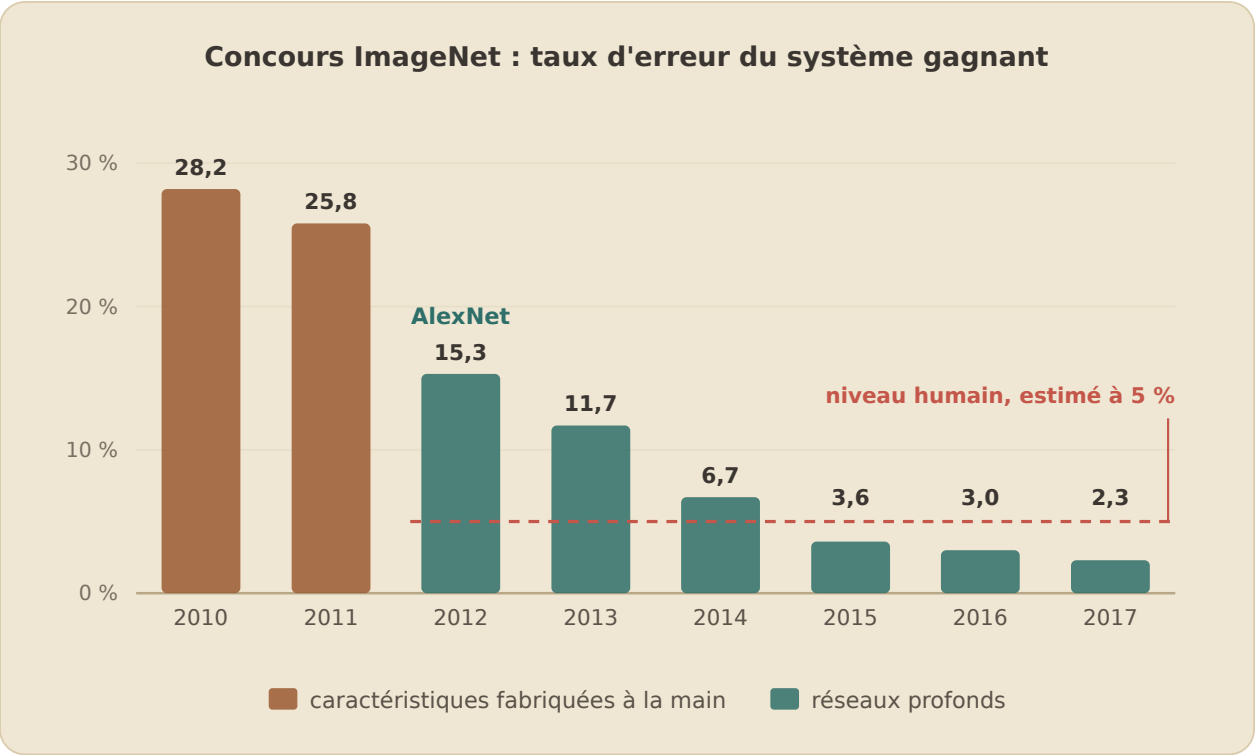
En 2010 et 2011, les meilleurs systèmes reposent sur des caractéristiques fabriquées à la main (*hand-crafted features*), et leur taux d'erreur est de 28 %, puis de 26 %. En 2012, Alex Krizhevsky, Ilya Sutskever et Geoffrey Hinton, de l'Université de Toronto, présentent un réseau profond, **AlexNet**. Il compte huit couches et 60 millions de paramètres, il utilise la ReLU, et il a été entraîné pendant environ une semaine sur deux GPU.

Avec 60 millions de paramètres pour 1,2 million d'images, le risque de sur-apprentissage (*overfitting*) est grand. AlexNet le limite par une forme de régularisation, au sens du Module 2 : le réseau reste riche, mais on l'empêche de trop coller à ses données d'entraînement. Il utilise une méthode toute récente, publiée par l'équipe de Hinton la même année, le **dropout**. À chaque étape de l'entraînement, une partie des neurones, tirés au hasard, est mise hors service. Le réseau ne peut donc pas compter sur un neurone en particulier, et il apprend des caractéristiques plus robustes, un peu comme une équipe où chacun doit pouvoir remplacer un absent. Les images d'entraînement sont aussi recadrées et retournées au hasard, ce qui en multiplie les variantes.



Le dropout : à chaque étape de l'entraînement, d'autres neurones sont éteints au hasard. Une fois l'entraînement terminé, le réseau utilise tous ses neurones.

Le taux d'erreur d'AlexNet est de 15 %. Le deuxième système est à 26 %.



Le taux d'erreur du système gagnant au concours ImageNet, de 2010 à 2017.

L'écart est si grand que le domaine change de méthode en deux ans. Dès 2014, tous les systèmes en compétition sont des réseaux profonds. En 2015, le réseau gagnant compte 152 couches et son taux d'erreur, 3,6 %, est inférieur à celui d'un humain sur la même tâche, estimé à 5 %. La même bascule se produit quelques années plus tard pour la traduction. Pour la reconnaissance de la parole, elle avait même commencé un peu plus tôt. Entre 2009 et 2012, des étudiants de Hinton, avec des équipes de Microsoft, de Google et d'IBM, remplacent une partie des systèmes de reconnaissance vocale par des réseaux profonds, préentraînés couche par couche. En 2012, la recherche vocale des téléphones Android en profite. C'est le premier grand succès industriel de l'apprentissage profond. ImageNet a pourtant davantage frappé les esprits, parce que l'écart y était spectaculaire et mesuré lors d'un concours public.

AlexNet est un réseau d'un type particulier, un réseau convolutif (*convolutional neural network*, CNN), conçu pour les images. Le chapitre « Voir : les réseaux convolutifs » lui est consacré.

Une école canadienne
AlexNet est sorti du laboratoire de Geoffrey Hinton, à l'Université de Toronto. Ce n'est pas un hasard. Pendant les années 1990 et 2000, les réseaux de neurones intéressaient peu, et les organismes qui finançaient la recherche s'en détournaient. En 2004, l'Institut canadien de recherches avancées (CIFAR) lance un programme intitulé « Calcul neuronal et perception adaptative » (*Neural Computation and Adaptive Perception*), dirigé par Hinton. Le programme réunit un petit groupe de chercheurs convaincus, dont Yoshua Bengio, à l'Université de Montréal, et Yann Le Cun, à l'Université de New York. Ils continuent à travailler sur les réseaux profonds quand presque personne d'autre ne le fait.

Le pari réussit en 2012. Hinton, Bengio et Le Cun reçoivent ensemble le prix Turing 2018. En 2024, Hinton reçoit le prix Nobel de physique avec l'Américain John Hopfield, « pour des découvertes et des inventions fondamentales qui permettent l'apprentissage automatique avec des réseaux de neurones artificiels ». Le comité récompense deux réseaux des années 1980 qui empruntent leurs outils à la physique statistique : le réseau de Hopfield (1982), une mémoire qui retrouve une image complète à partir d'un fragment, et la machine de Boltzmann de Hinton, qui tire son nom du physicien Ludwig Boltzmann. Le choix a surpris, et plusieurs physiciens se sont demandé si l'on récompensait encore de la physique. Hinton, qui avait quitté Google en 2023 pour parler librement des risques de l'IA, a profité de la tribune pour les rappeler. Le Module 5 revient sur ces risques. Le laboratoire fondé par Bengio en 1993 devient en 2017 **Mila**, l'Institut québécois d'intelligence artificielle, l'un des plus grands centres de recherche universitaire en apprentissage profond au monde. La même année, le gouvernement du Canada confie au CIFAR la Stratégie pancanadienne en matière d'intelligence artificielle, l'une des premières stratégies nationales consacrées à l'IA. Elle s'appuie sur trois instituts : Mila à Montréal, l'Institut Vecteur à Toronto et l'Amii à Edmonton, où travaille Richard Sutton, l'auteur de la leçon amère.



Geoffrey Hinton, Yoshua Bengio et Yann Le Cun, lauréats du prix Turing 2018 (photos : Ramsey Cardy / Collision via Sportsfile, CC BY 2.0 ; Maryse Boyce, CC BY 4.0 ; Jérémy Barande, CC BY-SA 2.0 ; Wikimedia Commons).

La leçon amère

La fin du Module 2 a présenté l'essai de Richard Sutton, « The Bitter Lesson » (2019). Sa thèse est la suivante. Dans l'histoire de l'IA, les chercheurs ont d'abord tenté d'inscrire leur propre savoir dans les systèmes. Cela aidait à court terme. À long terme, ces systèmes ont été dépassés par des méthodes générales, qui n'utilisent aucun savoir particulier, mais qui tirent parti de la puissance de calcul disponible.

Le concours de 2012 en est l'exemple le plus net. Les caractéristiques d'images mises au point par des experts pendant vingt ans ont été dépassées par un réseau qui apprend les siennes. Le Module 1 en donnait un autre exemple, avec Deep Blue : la recherche à grande échelle l'avait emporté sur les programmes qui tentaient d'imiter le raisonnement des grands maîtres.

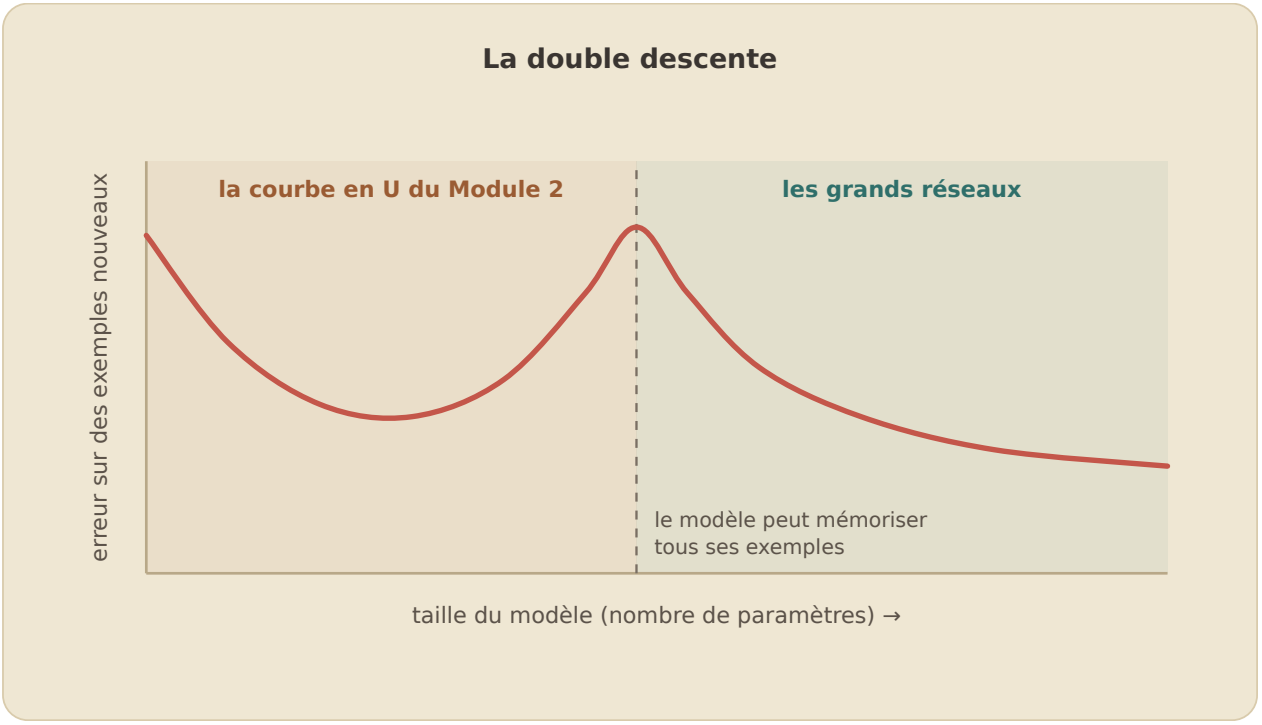
Sutton qualifie cette leçon d'amère parce qu'elle va contre l'intuition des chercheurs : le savoir qu'ils inscrivent dans un système finit par le limiter. Elle a aussi un coût. Un réseau profond ne donne pas ses raisons, alors qu'on pouvait lire les règles d'un système expert ou les questions d'un arbre de décision (*decision tree*). Et ses progrès dépendent de quantités de données et de calcul que peu d'organisations possèdent.

La leçon ne dit pas que le savoir humain est inutile. Il reste présent, mais ailleurs : dans le choix des données, et dans la forme donnée au réseau. Les chapitres sur les réseaux convolutifs, les réseaux récurrents et l'attention en donnent des exemples.

Plus de paramètres que d'exemples

AlexNet a 60 millions de paramètres, pour 1,2 million d'images d'entraînement. D'après « Généraliser », un modèle aussi souple devrait apprendre ses exemples par cœur et échouer sur des images nouvelles. C'est le sur-apprentissage (*overfitting*). Or les réseaux profonds généralisent bien. C'est la question que le Module 2 avait laissée ouverte.

Une partie de la réponse tient à la régularisation, décrite dans « Entraîner un réseau ». Mais elle ne suffit pas à expliquer le phénomène. Quand on fait grossir un réseau, on observe d'abord la courbe en U du Module 2 : l'erreur sur les exemples nouveaux baisse, puis remonte. Si l'on continue au-delà du point où le réseau peut mémoriser tous ses exemples, l'erreur redescend, parfois plus bas qu'avant. Ce phénomène s'appelle la **double descente** (*double descent*).



La double descente : après le pic, un modèle plus grand généralise mieux.

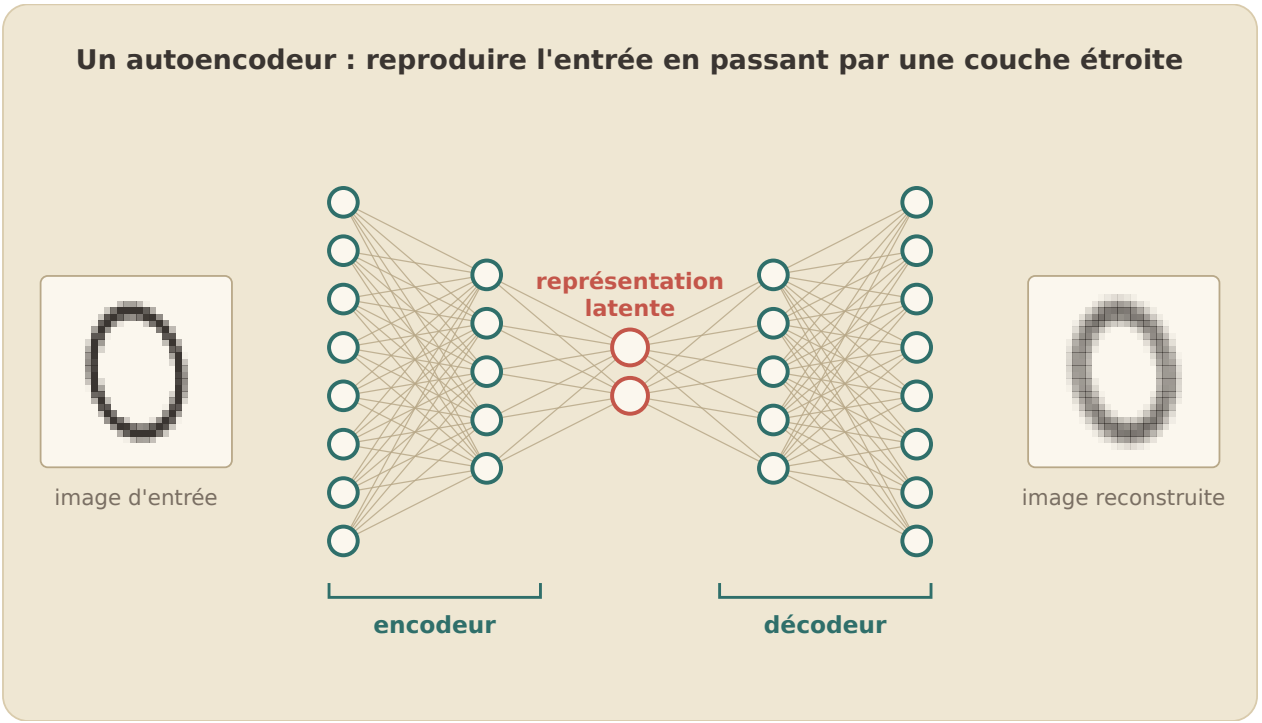
Le phénomène est bien établi, mais son explication n'est pas complète. L'hypothèse la plus courante est la suivante. Un très grand réseau dispose de nombreuses façons de reproduire ses exemples, et la descente de gradient aboutit le plus souvent à l'une des plus simples. C'est un cas où la pratique a précédé la théorie.

Un phénomène voisin a été observé en 2022 par une équipe d'OpenAI, cette fois au fil de l'entraînement plutôt qu'en fonction de la taille. Sur de petites tâches d'arithmétique, un réseau apprend d'abord ses exemples par cœur : il ne fait plus aucune erreur sur eux, mais répond au hasard sur les nouveaux. Si l'on poursuit l'entraînement bien au-delà, parfois des milliers d'étapes plus tard, il se met soudain à généraliser presque parfaitement. Les chercheurs ont appelé ce phénomène ***grokking***, d'après un mot inventé par l'écrivain Robert Heinlein, qui signifie « comprendre en profondeur ». Le chapitre « Regarder à l'intérieur » du Module 4 montre ce qui se passe dans le réseau pendant ce long plateau.

Apprendre sans étiquettes : l'autoencodeur

Tous les réseaux vus jusqu'ici sont entraînés avec des exemples étiquetés (*labeled examples*). Un réseau peut aussi apprendre des caractéristiques sans étiquettes. L'**autoencodeur** (*autoencoder*) en est l'exemple le plus simple.

Un autoencodeur est un réseau en forme de sablier. On lui donne une image en entrée, et on lui demande de produire la même image en sortie. L'erreur est l'écart entre les deux. La tâche serait sans intérêt si le réseau pouvait simplement recopier son entrée, mais la couche du milieu est très étroite. Les 784 pixels d'un chiffre doivent passer par quelques dizaines de neurones seulement.



Un autoencodeur : l'image doit passer par une couche étroite, puis être reconstruite.

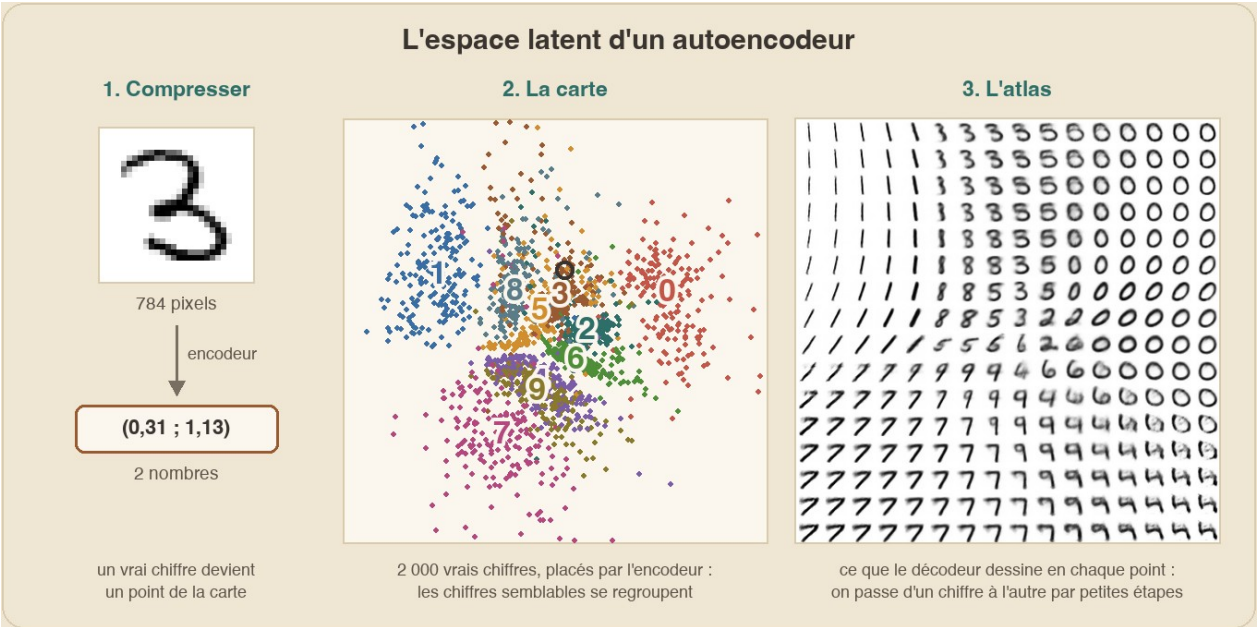
- La première moitié, l'**encodeur**, réduit l'image à quelques nombres.

- La seconde moitié, le **décodeur**, reconstruit l'image à partir de ces nombres.

L'autoencodeur est un premier exemple d'assemblage : deux réseaux, l'un qui comprime et l'autre qui reconstruit, branchés l'un à la suite de l'autre et entraînés ensemble, comme les pièces du jeu de construction présenté au chapitre suivant.

Pour réussir, le réseau doit garder l'essentiel de l'image dans la couche étroite : quel chiffre, quelle inclinaison, quelle épaisseur de trait. Ces quelques nombres forment une représentation compacte de l'image, qu'on appelle sa **représentation latente** (*latent representation*). C'est un cas d'auto-supervision (*self-supervised learning*), présentée au Module 2 : les données fournissent elles-mêmes la réponse attendue.

L'ensemble des valeurs que peuvent prendre ces quelques nombres forme l'**espace latent** (*latent space*) du réseau. C'est un espace **compressé** : quelques dizaines de dimensions au lieu de 784, où ne reste que ce qui distingue une image d'une autre. Deux images semblables y occupent des points voisins, et l'on peut s'y déplacer d'un chiffre à l'autre par petites étapes. Beaucoup de chercheurs y voient l'endroit où un réseau travaille vraiment : il n'y manipule plus des pixels, mais des propriétés abstraites, comme la forme ou l'inclinaison d'un chiffre. Certains, comme Yann Le Cun, pensent même qu'une intelligence artificielle devrait raisonner et faire ses prévisions dans un tel espace, plutôt que sur les données brutes. Le Module 4 permet d'explorer l'espace latent d'un réseau entraîné sur des chiffres manuscrits.



L'espace latent d'un autoencodeur entraîné sur des chiffres manuscrits. Pour pouvoir le dessiner, ce réseau n'en a que deux dimensions, alors qu'un autoencodeur ordinaire en a quelques dizaines. C'est le même réseau que celui de l'applet du Module 4.

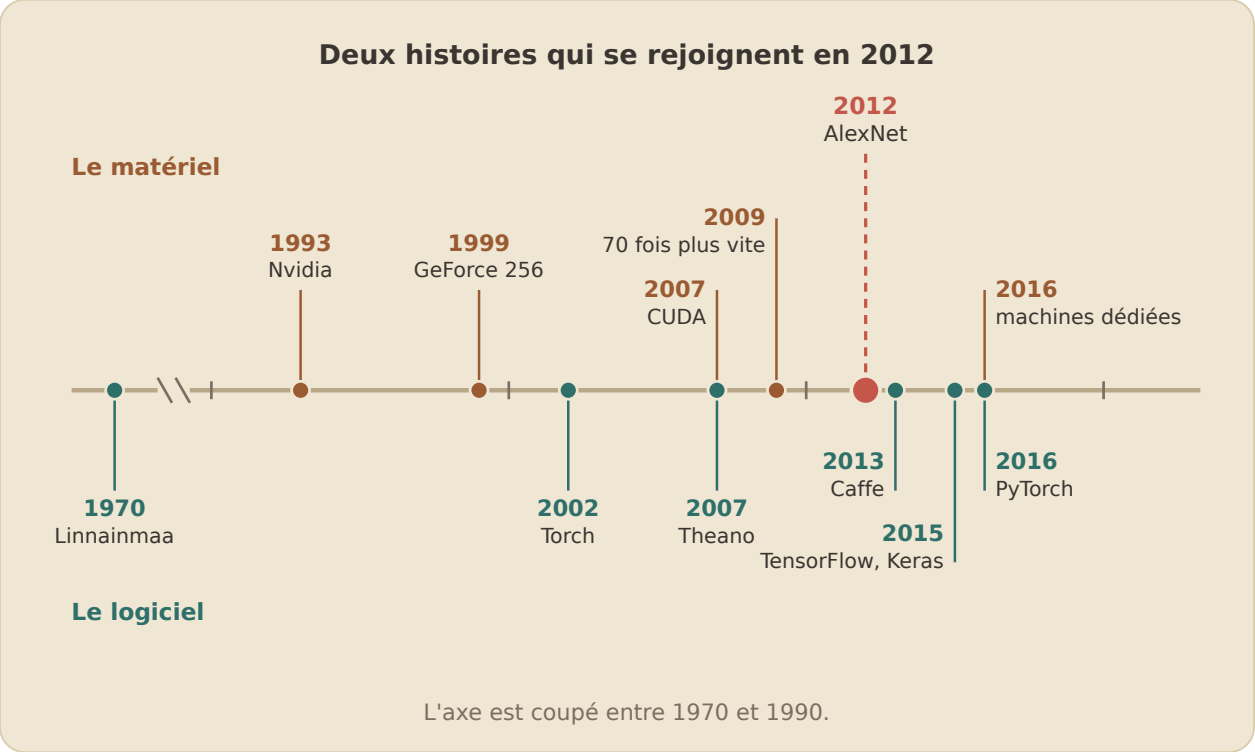
Le décodeur a une autre utilité. Si on lui donne des nombres qui ne viennent d'aucune image réelle, il produit quand même une image. C'est une première façon de générer du contenu, sur laquelle le Module 4 reviendra.

Un réseau profond peut donc apprendre ses propres caractéristiques, à condition d'avoir assez de données et de calcul. Le chapitre suivant, « Le matériel et les outils », raconte comment ce calcul est

devenu possible.

Le matériel et les outils

Le chapitre « L'apprentissage profond » a nommé trois conditions du succès de 2012 : une meilleure fonction d'activation, des données, et du calcul. Ce chapitre revient sur la troisième. Deux progrès techniques ont rendu l'apprentissage profond (*deep learning*) praticable : des processeurs capables de faire les calculs, et des bibliothèques logicielles qui écrivent la rétropropagation à la place du programmeur.



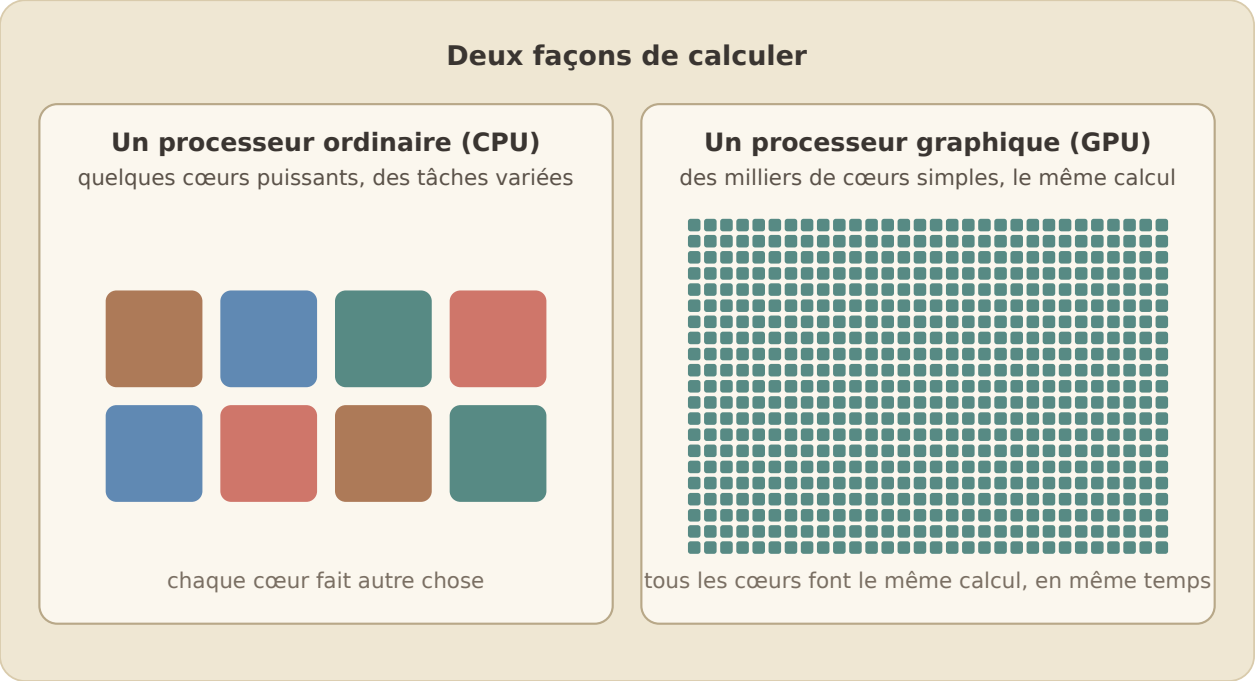
Le matériel et le logiciel de l'apprentissage profond : deux histoires qui se rejoignent en 2012.

Les processeurs graphiques

Un réseau de neurones répète toujours le même calcul : multiplier des entrées par des poids et additionner les résultats, pour chaque neurone, des millions de fois. Ces calculs sont indépendants les uns des autres, et peuvent donc être faits en même temps.

Un processeur ordinaire (CPU) a quelques cœurs puissants, conçus pour exécuter des tâches variées l'une après l'autre. Un **processeur graphique** (GPU) a des milliers de cœurs simples, qui exécutent

tous le même calcul en parallèle. Il a été conçu pour l'affichage des jeux vidéo, où il faut calculer la couleur de millions de pixels des dizaines de fois par seconde, ce qui est un problème du même type.



Un processeur ordinaire a quelques cœurs puissants ; un processeur graphique a des milliers de cœurs simples.

Voici les principales étapes de cette histoire.

- **1993.** Fondation de Nvidia, qui fabrique des cartes graphiques pour le jeu vidéo.
- **1999.** Nvidia lance la GeForce 256 et la présente comme le premier « GPU ».
- **Début des années 2000.** Les cartes deviennent programmables. Des chercheurs s'en servent pour des calculs scientifiques, en présentant leurs calculs comme des images à afficher. La méthode est laborieuse.
- **2007.** Nvidia publie CUDA, un outil qui permet de programmer un GPU directement, pour n'importe quel calcul. L'entreprise investit dans cet usage alors qu'il n'a presque aucun marché.
- **2009.** À Stanford, l'équipe d'Andrew Ng montre qu'un GPU entraîne un réseau de neurones jusqu'à 70 fois plus vite qu'un CPU.
- **2012.** AlexNet est entraîné sur deux cartes de jeu vidéo vendues environ 500 $ chacune, dans la chambre d'Alex Krizhevsky, chez ses parents.
- **2016.** Nvidia vend ses premières machines conçues pour l'apprentissage profond. Google présente ses propres puces spécialisées, les TPU.
- **Années 2020.** Les grands modèles sont entraînés dans des centres de données qui contiennent des dizaines de milliers de GPU. Nvidia fournit la majorité de ces puces. En 2025, elle devient la première entreprise dont la valeur en bourse dépasse 4 000, puis 5 000 milliards de dollars. L'accès à ces puces devient un enjeu politique : depuis 2022, les États-Unis en limitent l'exportation vers la Chine. Le Module 5 reviendra sur ces questions.



Une carte GeForce GTX 580, conçue pour le jeu vidéo. AlexNet a été entraîné sur deux cartes de ce modèle (photo : TheStriker, Wikimedia Commons, CC BY-SA 4.0).

La différentiation automatique

Le second progrès est logiciel. La rétropropagation demande de calculer des dérivées à travers toutes les couches du réseau. Pendant longtemps, ce calcul a été fait à la main : pour chaque nouveau réseau, il fallait établir les formules sur papier, puis les programmer. Le travail prenait des semaines, et les erreurs étaient fréquentes et difficiles à repérer.

La **différentiation automatique** (*automatic differentiation*) supprime ce travail. Le programmeur décrit seulement la propagation avant, c'est-à-dire le calcul qui mène des entrées à l'erreur. La bibliothèque enregistre chaque opération, et en déduit elle-même le calcul de la rétropropagation.

- **1970.** Le Finlandais Seppo Linnainmaa décrit la méthode mathématique générale, dont la rétropropagation est un cas particulier.
- **2002.** Torch, une des premières bibliothèques destinées aux réseaux de neurones. Elle fournit des couches toutes faites, mais les dérivées de chaque type de couche sont encore écrites à la main par ses auteurs.
- **2007.** Theano, développée à l'Université de Montréal dans le laboratoire de Yoshua Bengio. C'est la première bibliothèque largement utilisée qui réunit les deux progrès : elle calcule les dérivées automatiquement, et elle exécute les calculs sur GPU.
- **2013.** Caffe, à Berkeley, conçue pour les réseaux qui traitent des images. Elle se répand vite après le succès d'AlexNet.
- **2015.** Google publie TensorFlow en code ouvert (*open source*). La même année paraît Keras, qui permet de décrire un réseau en quelques lignes.
- **2016.** Facebook publie PyTorch. On y écrit un réseau comme un programme Python ordinaire. Elle devient en quelques années l'outil le plus utilisé en recherche.

Un réseau en quelques lignes

Voici à quoi ressemble aujourd'hui le réseau des chiffres du chapitre « Une couche cachée », écrit en **Python** avec la bibliothèque PyTorch. Python est le langage de programmation le plus utilisé en apprentissage automatique. Il est simple à lire et à écrire, et des bibliothèques comme PyTorch s'y chargent des calculs lourds, programmés dans des langages plus rapides et exécutés sur les processeurs graphiques. Plusieurs de ses traits viennent d'ailleurs de Lisp, le langage de l'IA symbolique, comme le montre *L'héritage invisible* au Module 1. Il n'est pas nécessaire de comprendre le détail du code. Il suffit de constater sa longueur.

```
reseau = nn.Sequential(
    nn.Linear(784, 30),    # 784 entrées vers 30 neurones cachés
    nn.ReLU(),             # la fonction d'activation
    nn.Linear(30, 10),     # 30 neurones cachés vers 10 sorties
)

sorties = reseau(images)                     # la propagation avant
erreur = cross_entropy(sorties, etiquettes)  # l'écart avec les bonnes réponses
erreur.backward()                            # la rétropropagation, faite par la bibliothèque
optimiseur.step()                            # la correction de tous les poids
```

La ligne `erreur.backward()` remplace les semaines de calcul à la main. La conséquence est importante pour la suite. Essayer une nouvelle forme de réseau ne demande plus que quelques heures. Les chercheurs ont donc pu en essayer beaucoup, et c'est ainsi que se sont répandues les architectures des chapitres suivants.

Un jeu de construction

L'exemple précédent assemble trois blocs : une couche, une fonction d'activation, une autre couche. Rien n'oblige à s'en tenir là. On peut empiler d'autres couches, en ajouter de types différents, faire passer les données par deux chemins puis les réunir, ou brancher deux réseaux l'un à la suite de l'autre. Quel que soit l'assemblage, la différentiation automatique calcule comment l'erreur dépend de chaque poids, et le tout s'entraîne d'un seul coup, par la même rétropropagation.

C'est l'une des grandes forces des réseaux de neurones. Ils se composent comme les pièces d'un jeu de construction, et chaque nouvel assemblage s'entraîne sans qu'il faille inventer une nouvelle méthode. En 2018, Yann Le Cun a proposé de parler de **programmation différentiable** (*differentiable programming*) : on écrit un programme fait de blocs ajustables, et ce sont les données qui en règlent les paramètres.



Quelques sortes de briques, toujours les mêmes, et des assemblages sans fin : c'est l'image qu'on donne souvent des réseaux de neurones (*photo : Alan Chia, Wikimedia Commons, CC BY-SA 2.0*).

Les chapitres suivants présentent les assemblages qui ont le plus compté. Le premier, présenté dans « Voir : les réseaux convolutifs », est conçu pour les images.

Voir : les réseaux convolutifs

Le réseau des chiffres du chapitre « Une couche cachée » reçoit les 784 pixels d'une image comme une simple liste de nombres. Il ne sait pas que ces pixels forment une grille, ni que deux pixels voisins sont liés. Ce chapitre présente une forme de réseau qui tient compte de la disposition des pixels, le **réseau convolutif**.

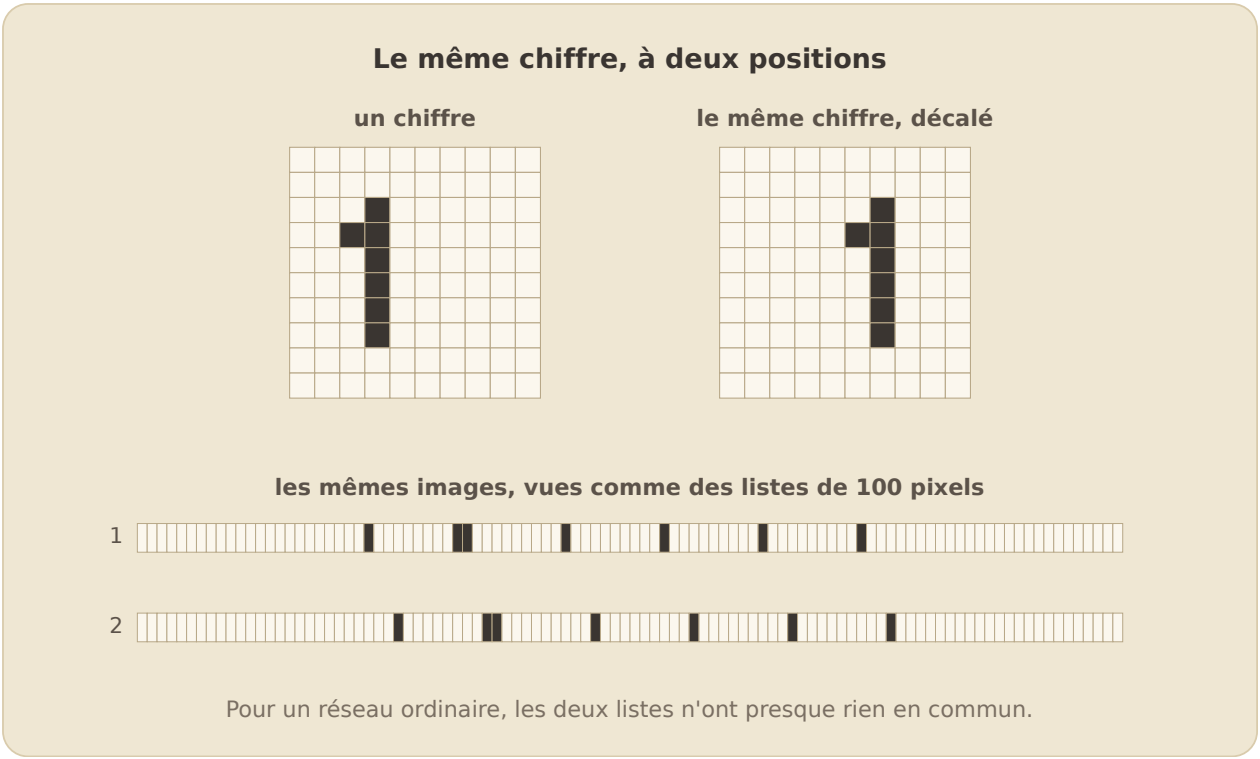
Ce réseau est fait des mêmes briques que le perceptron multicouche : des neurones, des poids, la même rétropropagation. Seule change son architecture, c'est-à-dire la façon dont ses neurones sont reliés. Chaque neurone n'y regarde qu'un petit voisinage de l'image, et les mêmes poids servent partout. Ce choix traduit une hypothèse sur les données : dans une image, ce qui compte est d'abord local, et une même forme peut apparaître n'importe où. Une hypothèse de ce genre, inscrite dans l'architecture avant tout apprentissage, s'appelle un **biais inductif** (*inductive bias*). Comme le biais du Module 2, il restreint ce que le réseau peut apprendre. S'il est juste, il lui permet d'apprendre avec beaucoup moins d'exemples.

Ce qu'un réseau ordinaire ignore dans une image

Un réseau dont chaque neurone est relié à toutes les entrées pose trois problèmes quand ces entrées sont les pixels d'une image.

Il ignore le voisinage. Supposons qu'on mélange les pixels de toutes les images, toujours de la même façon. Pour nous, les chiffres deviennent illisibles. Pour ce réseau, rien ne change : il apprend aussi bien qu'avant. Il n'utilise donc pas le fait que des pixels voisins forment ensemble un trait ou une courbe.

Il ne reconnaît pas un motif déplacé. Si un chiffre est décalé de quelques pixels, il active d'autres entrées, reliées à d'autres poids. Pour le réseau, c'est une image nouvelle. Il doit apprendre séparément le même chiffre à chaque position.



Le même chiffre à deux positions : une fois mises à plat, les deux images n'ont presque aucun pixel allumé en commun.

Il a trop de poids. Une photo en couleur de 1 000 pixels sur 1 000 compte trois millions de valeurs. Avec une couche cachée de 1 000 neurones, il faudrait trois milliards de poids pour cette seule couche.

Le filtre

La solution repose sur un petit élément, le **filtre** (*filter* ou *kernel*). Un filtre est un carré de poids, par exemple de 3 sur 3. On le pose sur un coin de l'image, où il recouvre neuf pixels. Il calcule la somme de ces neuf pixels, chacun multiplié par le poids qui le recouvre. C'est le calcul d'un neurone, limité à neuf entrées.

On fait ensuite glisser le filtre d'un pixel, et on recommence, jusqu'à avoir parcouru toute l'image. Chaque position donne un nombre. Ensemble, ces nombres forment une nouvelle image, presque de la même taille que la première. Cette opération s'appelle une **convolution**.

La nouvelle image indique où se trouve le motif que le filtre détecte. Un filtre dont la colonne du centre a des poids positifs et les colonnes voisines des poids négatifs donne une somme élevée là où l'image contient un trait vertical, et une somme faible ou négative ailleurs.

Pour aller plus loin : le calcul à une position
Prenons le filtre des traits verticaux, et une zone de l'image où passe un trait vertical. Les pixels du trait valent 1, les autres 0.

Filtre			Pixels		
-1	2	-1	0	1	0
-1	2	-1	0	1	0
-1	2	-1	0	1	0

La somme vaut $2 + 2 + 2 = 6$, la valeur la plus élevée possible pour ce filtre. Si la même zone contient un trait horizontal, les pixels de la rangée du milieu valent

1. La somme vaut alors $-1 + 2 - 1 = 0$, et le filtre ne détecte rien.

Un filtre à manipuler

Dans l'applet ci-dessous, l'image d'un chiffre est à gauche, le filtre au centre, et le résultat de la convolution à droite. Plus une case du résultat est foncée, plus le motif du filtre est présent à cet endroit. Les sommes négatives sont ramenées à zéro.

Applet interactive : à utiliser en ligne, sur la page « Voir : les réseaux convolutifs » du site du cours.

1. Choisissez le chiffre 7, puis comparez les filtres « traits verticaux », « traits horizontaux » et « obliques / ». Chacun fait ressortir une partie différente du chiffre.
2. Passez la souris sur l'image. Le carré rouge montre les neuf pixels recouverts par le filtre, et la somme obtenue s'affiche sous le filtre.
3. Déplacez le chiffre avec les flèches. Le résultat se déplace avec lui, sans changer de forme.
4. Modifiez vous-même les neuf poids du filtre, et observez l'effet.

Ce que la convolution apporte

Le filtre répond aux trois problèmes de départ.

- **Le voisinage.** Le filtre ne regarde que neuf pixels voisins à la fois. Il est fait pour détecter des motifs locaux.
- **Le déplacement.** Le même filtre parcourt toute l'image. Un trait vertical est détecté de la même façon en haut à gauche et en bas à droite, comme le montrait la troisième manipulation.
- **Le nombre de poids.** Un filtre de 3 sur 3 a neuf poids, que l'image compte 784 pixels ou trois millions. Les mêmes poids servent à toutes les positions. On parle de **partage des poids** (*weight sharing*).

Du filtre au réseau

Un réseau convolutif est fait de plusieurs éléments, répétés.

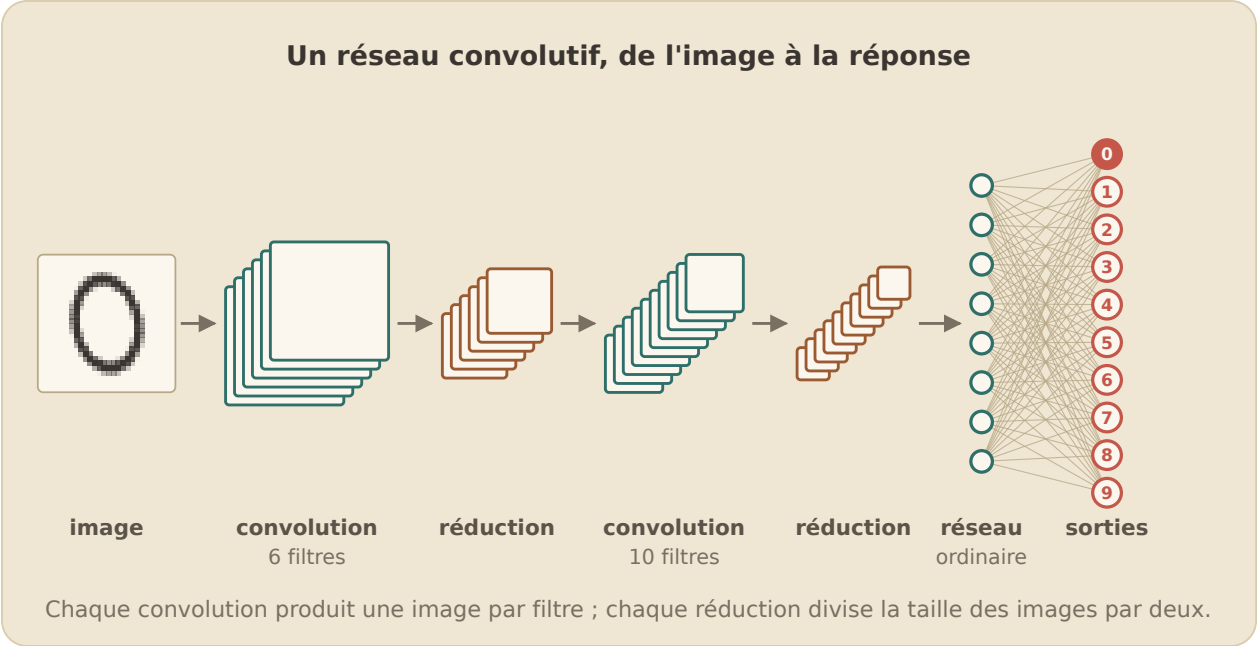
Une **couche convolutive** (*convolutional layer*) contient plusieurs filtres, par exemple 32. Chacun détecte un motif différent et produit sa propre image de résultat. La couche transforme donc une image en 32 images.

Une étape de **réduction** (*pooling* en anglais) diminue ensuite la taille de ces images. La méthode la plus courante découpe l'image en carrés de 2 sur 2 et ne garde que la valeur la plus élevée de chaque

carré. L'image devient deux fois plus petite dans chaque direction. On conserve l'information « ce motif est présent dans cette zone », et on perd sa position exacte.

On répète ces deux étapes plusieurs fois. Les filtres de la deuxième couche ne s'appliquent plus aux pixels, mais aux résultats de la première. Ils combinent donc des traits en formes. Ceux de la troisième combinent des formes en parties d'objets. C'est la hiérarchie de caractéristiques du chapitre « L'apprentissage profond », obtenue ici par construction.

À la fin, les dernières images sont petites et nombreuses. On les donne à un réseau ordinaire, à quelques couches, qui produit la réponse.



L'architecture d'un réseau convolutif : convolutions et réductions en alternance, puis un réseau ordinaire.

Il reste un point essentiel. Dans l'applet, les filtres étaient choisis à la main. Dans un réseau convolutif, personne ne les choisit. Les poids des filtres sont tirés au hasard au départ, puis réglés par rétropropagation, comme tous les autres poids. Le réseau trouve lui-même les motifs utiles pour sa tâche. Entraîné sur des visages, il produit des filtres adaptés aux visages. Entraîné sur des radiographies, il en produit d'autres.

Yann Le Cun et les chèques

L'idée du filtre qui glisse sur l'image vient de la neurophysiologie. En 1979, le chercheur japonais Kunihiko Fukushima s'inspire des travaux de Hubel et Wiesel sur le cortex visuel, décrits dans l'encadré du chapitre précédent. Il propose le **Neocognitron**, un réseau qui alterne déjà des couches de filtres et des couches de réduction. Ses filtres ne sont pas réglés par rétropropagation, qui n'est pas encore connue.

En 1988, le chercheur français Yann Le Cun entre aux Bell Labs, le laboratoire de recherche de l'entreprise de télécommunications AT&T, dans le New Jersey. Il y réunit les deux idées : un réseau

convolutif, dont tous les filtres sont appris par rétropropagation. En 1989, ce réseau lit les codes postaux manuscrits des lettres du service postal américain.



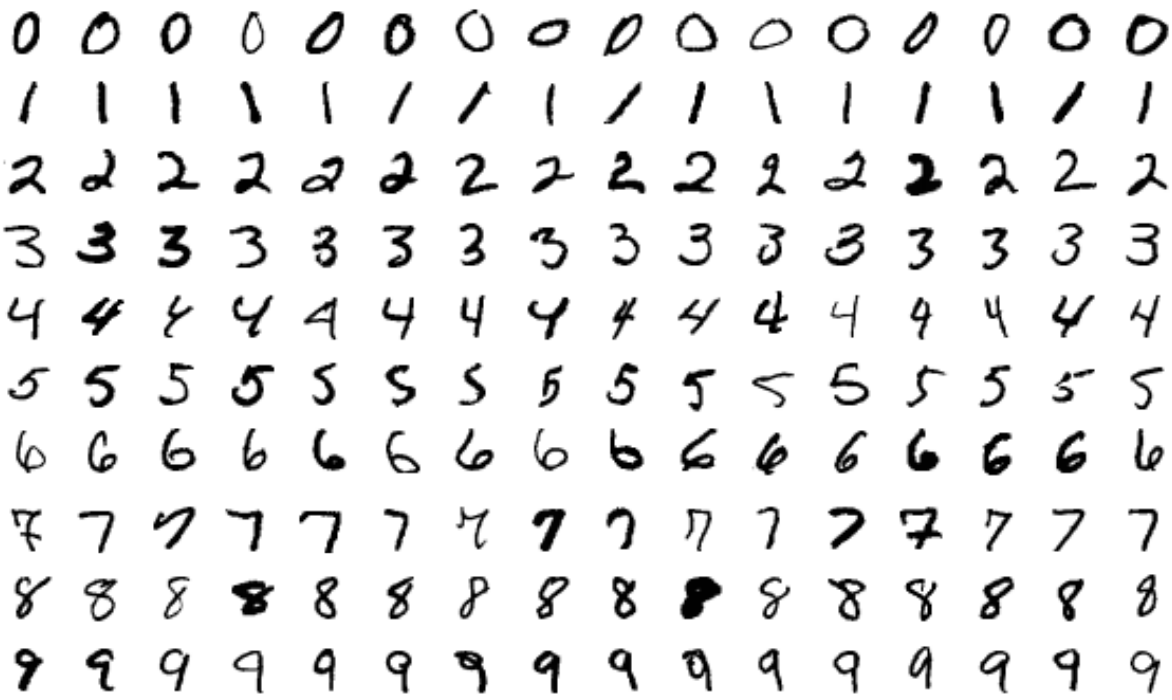
Yann Le Cun en 2018 (*photo : Jérémy Barande, Wikimedia Commons, CC BY-SA 2.0*).

La vidéo ci-dessous, publiée par Le Cun lui-même, montre ce réseau en 1989, lisant en direct des chiffres écrits à la main.

Vidéo : https://www.youtube.com/watch?v=FwFduRA_L6Q

Le travail se poursuit pendant une dizaine d'années, avec Léon Bottou, Yoshua Bengio et Patrick Haffner. Il aboutit en 1998 à **LeNet-5**, un réseau à sept couches, et à un système de lecture automatique des chèques. Vers la fin des années 1990, selon Le Cun, ce système lit entre 10 et 20 % des chèques déposés aux États-Unis. C'est l'une des premières applications commerciales à grande échelle d'un réseau de neurones.

Pour entraîner et comparer ces réseaux, l'équipe constitue une base de chiffres manuscrits, **MNIST** : 60 000 images d'entraînement et 10 000 images de test, de 28 pixels sur 28. C'est l'origine des chiffres qui servent d'exemple tout au long de ce module. MNIST est devenue la base d'essai (*benchmark*) la plus utilisée de l'apprentissage automatique (*machine learning*).



Des chiffres de la base MNIST, une ligne par chiffre (*image : Josef Steppan, Wikimedia Commons, CC BY-SA 4.0*).

Malgré ces succès, les réseaux convolutifs restent une méthode parmi d'autres pendant quinze ans. Ils fonctionnent sur de petites images de chiffres, mais les photos du monde réel demandent des réseaux plus grands, plus de données et plus de calcul. Il faut attendre que ces trois conditions, décrites dans « Pourquoi seulement en 2012 », soient réunies.

Après 2012

AlexNet est un réseau convolutif. Son architecture reprend celle de LeNet, avec trois différences : il est beaucoup plus grand, il utilise la ReLU, et il est entraîné sur GPU. Le Cun partage cette réussite avec Hinton et Bengio, les deux autres membres de l'école canadienne de l'apprentissage profond.

Les réseaux convolutifs deviennent ensuite plus profonds : 8 couches pour AlexNet en 2012, 22 pour GoogLeNet en 2014, 152 pour ResNet en 2015. Ce dernier introduit des **raccourcis** (*skip connections*) qui laissent l'information sauter certaines couches, ce qui limite l'évanouissement du gradient et permet d'entraîner des réseaux très profonds.

Nommer ce que contient une image ne suffit pas toujours. Une voiture qui doit freiner devant un piéton doit aussi savoir où il se trouve. Deux tâches prolongent donc la classification. La **détection d'objets** (*object detection*) entoure chaque objet d'un rectangle et lui donne une étiquette. En 2015, le réseau YOLO (*You Only Look Once*, « on ne regarde qu'une fois ») le fait en une seule passe, assez vite pour traiter une vidéo en temps réel. La **segmentation** (*image segmentation*) va plus loin : elle classe chaque pixel, ce qui dessine le contour exact de chaque objet. La même année, le réseau U-Net, conçu pour des images de microscopie, devient la référence en imagerie médicale, par exemple pour délimiter une tumeur. On le retrouvera au Module 4 : il sert de squelette aux premiers générateurs

d'images par diffusion.



Classer, détecter, segmenter. Les étiquettes, les rectangles et les silhouettes ont été produits par deux réseaux préentraînés : un classifieur entraîné sur ImageNet, qui ne donne qu'une réponse pour toute l'image, et Mask R-CNN, qui détecte et segmente chaque objet (photo de Gabriel Santiago, Unsplash, CC0).

Les réseaux convolutifs servent aussi à bien d'autres tâches :

- **analyser des images médicales**, comme des radiographies ou des images de la rétine ;
- **reconnaître des visages** (*face recognition*), un usage qui pose des questions de surveillance et de vie privée, traitées au Module 5 ;
- **traiter des sons**, en les transformant d'abord en images de leurs fréquences.

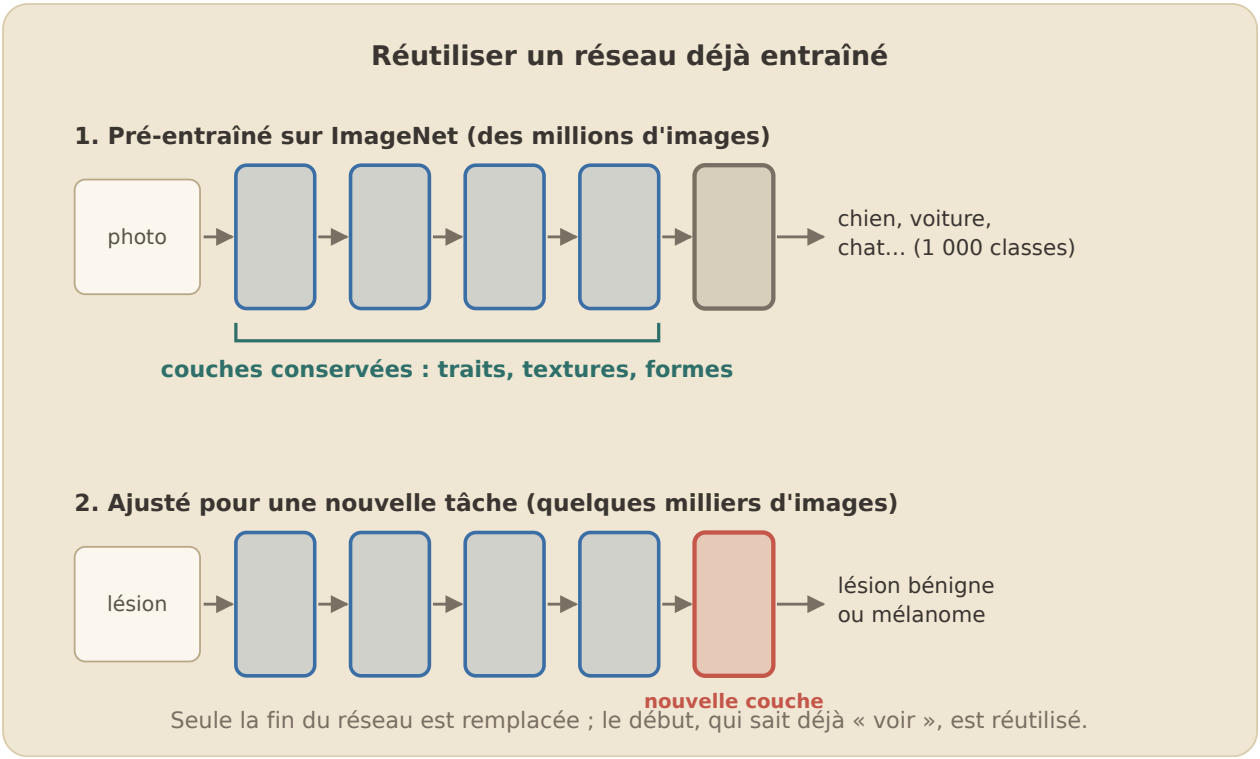
Réutiliser un réseau : l'apprentissage par transfert

Entraîner un grand réseau convolutif demande des millions d'images étiquetées et des jours de calcul sur des GPU. Peu d'équipes disposent de ces moyens, et pour beaucoup de tâches, il n'existe que quelques milliers d'exemples. Un dermatologue ne dispose pas d'un ImageNet de grains de beauté.

Une observation change la situation. Les premières couches d'un réseau entraîné sur ImageNet ont appris à détecter des traits, des textures et des formes simples. Ces caractéristiques ne sont pas propres aux chiens, aux voitures ou aux autres catégories d'ImageNet. Elles servent pour presque n'importe quelle image. Seules les dernières couches sont spécialisées dans les mille catégories du concours.

D'où la méthode de l'**apprentissage par transfert** (*transfer learning*) :

1. on part d'un réseau déjà entraîné sur un grand jeu de données, un réseau dit **pré-entraîné** (*pre-trained*) ;
2. on remplace ses dernières couches par de nouvelles, adaptées à la tâche visée ;
3. on entraîne le réseau sur les exemples de cette tâche, peu nombreux. On règle surtout les nouvelles couches, et on modifie peu, ou pas du tout, les premières. On parle d'**ajustement** (*fine-tuning*).



L'apprentissage par transfert : on garde les premières couches d'un réseau pré-entraîné, et on remplace la dernière.

Un exemple a marqué les esprits. En 2017, une équipe de l'Université Stanford part d'un réseau pré-entraîné sur ImageNet et l'ajuste sur environ 130 000 images de lésions de la peau. Sur les cas testés, le réseau distingue les mélanomes des lésions bénignes aussi bien que des dermatologues. Le réseau n'avait jamais vu de lésion de la peau avant cet ajustement, mais il savait déjà voir.

L'apprentissage par transfert est devenu la manière normale d'utiliser l'apprentissage profond. C'est aussi l'idée qui fonde les grands modèles de langage du Module 4 : un modèle est d'abord pré-entraîné sur une immense quantité de texte, puis ajusté pour une tâche ou pour la conversation. Le *P* de GPT signifie d'ailleurs *pre-trained*.

La leçon de la convolution

Ce chapitre nuance la leçon amère de Sutton. La convolution est une connaissance humaine, inscrite dans la forme du réseau : dans une image, ce qui compte est d'abord local, et un même motif peut apparaître n'importe où. Le réseau convolutif doit une grande partie de son efficacité à cette connaissance.

Mais c'est une connaissance très générale. Elle porte sur la structure des images en général, et non sur les chats, les chiffres ou les visages. Le contenu des filtres reste entièrement appris. C'est le type de savoir humain qui a survécu à l'apprentissage profond : non pas des règles sur le monde, mais des hypothèses sur la forme des données.

Le chapitre suivant applique la même démarche à un autre type de données. Une image a une taille fixe, et tous ses pixels sont disponibles en même temps. Une phrase ou un enregistrement sonore ont une longueur variable, et l'ordre de leurs éléments compte. Le chapitre « Lire une séquence : les

réseaux récurrents » présente les réseaux conçus pour ces données.

Lire une séquence : les réseaux récurrents

Une image a une taille fixe, et tous ses pixels sont disponibles en même temps. Beaucoup de données n'ont pas cette forme. Une phrase, un enregistrement de parole, un morceau de musique ou le tracé d'un stylo sur une tablette arrivent élément par élément. Leur longueur varie, et l'ordre de leurs éléments compte. On appelle ces données des **séquences**. Ce chapitre présente les réseaux conçus pour les traiter, les **réseaux récurrents** (*recurrent neural networks*, RNN).

Comme le réseau convolutif, le réseau récurrent est fait des mêmes briques que le perceptron multicouche. Il en diffère par son architecture : ses neurones forment une boucle, et les mêmes poids servent à chaque élément de la séquence. Son biais inductif est qu'une séquence se lit dans l'ordre, un élément après l'autre, et qu'une même règle s'applique à chaque pas.

Le problème des séquences

Un réseau ordinaire a un nombre fixe d'entrées. Pour lui donner une séquence, on peut essayer deux solutions simples.

Tout donner d'un coup. On réserve une entrée par élément de la séquence. Mais la longueur varie : une phrase compte trois mots, la suivante quarante. Et si l'on se contente de compter les mots présents, sans tenir compte de leur place, « le chien mord l'homme » et « l'homme mord le chien » deviennent identiques.

Regarder une fenêtre. On ne donne au réseau que les derniers éléments, par exemple les cinq derniers mots. La taille est fixe et l'ordre est conservé. Mais tout ce qui précède la fenêtre est oublié. Dans « Le livre que tu m'as prêté la semaine dernière était… », il faut se souvenir de « livre » pour bien accorder la suite.

Il faut donc un réseau capable de lire une séquence de n'importe quelle longueur, dans l'ordre, en gardant une trace de ce qu'il a déjà lu.

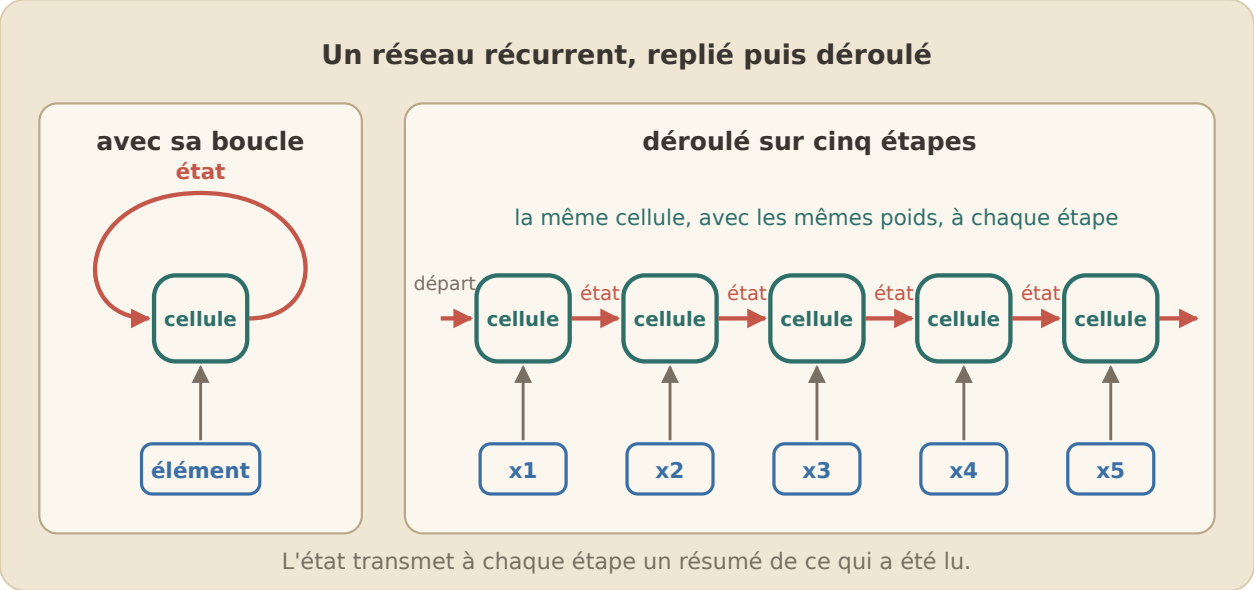
Pour traiter des mots, il faut d'abord les convertir en nombres. Le chapitre « Des mots aux nombres » du Module 4 expliquera comment. Les exemples de ce chapitre portent sur des suites de bits, qui sont déjà des nombres.

Une boucle : la mémoire

Un réseau récurrent lit la séquence un élément à la fois. À chaque étape, il reçoit deux choses : l'élément courant, et son propre **état** (*hidden state*) à l'étape précédente. Il calcule à partir d'elles un

nouvel état, qu'il se transmet à l'étape suivante. Cet état est une liste de nombres qui résume ce que le réseau a lu jusque-là. C'est sa mémoire.

On représente souvent ce réseau avec une boucle, l'état sortant de la cellule pour y revenir. Pour comprendre son fonctionnement, il est plus simple de le **dérouler** (*unroll*) : on dessine une copie de la cellule par étape, chacune passant son état à la suivante.



Un réseau récurrent, avec sa boucle, puis déroulé sur cinq étapes.

Toutes les copies sont la même cellule, avec les mêmes poids. Le réseau applique le même calcul à chaque étape, quelle que soit la longueur de la séquence. C'est le partage des poids des réseaux convolutifs, appliqué dans le temps plutôt que dans l'espace : le filtre glissait sur l'image, la cellule glisse sur la séquence.

Un réseau récurrent à manipuler

Voici une tâche qui demande de la mémoire. On reçoit une suite de bits, comme 1 0 1 1 0, et il faut dire si elle contient un nombre **pair** ou **impair** de 1. Cette question s'appelle la **parité**. Un réseau ordinaire avec une fenêtre ne peut pas y répondre : un seul 1 hors de la fenêtre change la réponse.

Un réseau récurrent la résout avec un état très simple, qui répond à la question « le nombre de 1 lus jusqu'ici est-il impair ? ». À chaque nouveau bit, l'état change si le bit vaut 1, et reste le même s'il vaut 0. C'est exactement le XOR de l'état et du nouveau bit. La cellule de ce réseau est donc le petit réseau du XOR du chapitre « Une couche cachée », avec les mêmes poids, appliqué à chaque étape.

Applet interactive : à utiliser en ligne, sur la page « Lire une séquence : les réseaux récurrents » du site du cours.

1. Avancez d'un pas à la fois et suivez l'état. Il passe près de 1 (en rouge) quand le nombre de 1 lus jusque-là est impair, et revient près de 0 (en bleu) quand il est pair.
2. Passez la souris sur une cellule pour voir le calcul de ses trois neurones.

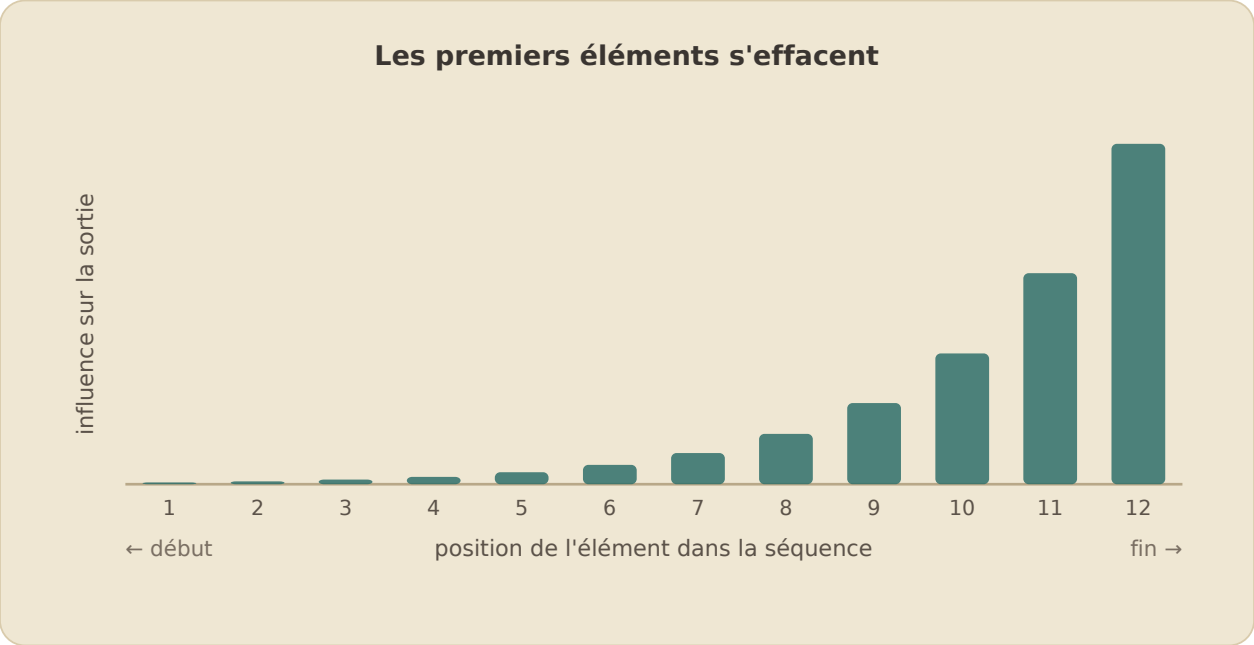
3. Lisez toute la suite, puis cliquez sur le premier bit pour le changer. La réponse finale change aussi : l'information du premier bit a traversé toutes les étapes.

Dans cette applet, les poids sont choisis à la main. Un vrai réseau récurrent les apprend, et son état compte des dizaines ou des centaines de nombres, qui ne correspondent à aucune question aussi lisible que « impair jusqu'ici ? ».

Entraîner un réseau récurrent, et ce qu'il oublie

Un réseau récurrent s'entraîne par rétropropagation, sur sa version déroulée. L'erreur, mesurée à la fin de la séquence, remonte les étapes une à une jusqu'à la première. On parle de **rétropropagation à travers le temps** (*backpropagation through time*).

Une séquence de 100 éléments donne un réseau déroulé de 100 étapes, donc un réseau très profond. On retrouve alors l'évanouissement du gradient : l'erreur s'affaiblit à chaque étape qu'elle remonte. Les premiers éléments de la séquence ont de moins en moins d'influence sur l'apprentissage, et le réseau peine à apprendre les liens entre des éléments éloignés.



Dans un réseau récurrent simple, l'influence d'un élément sur l'apprentissage diminue avec sa distance à la fin de la séquence.

Le langage contient beaucoup de liens de ce type. Dans « Les clés que j'avais posées hier soir sur la table près de la fenêtre **sont** introuvables », le verbe s'accorde avec « clés », placé une douzaine de mots plus tôt. Un réseau récurrent simple se souvient bien des derniers mots, et mal des premiers.

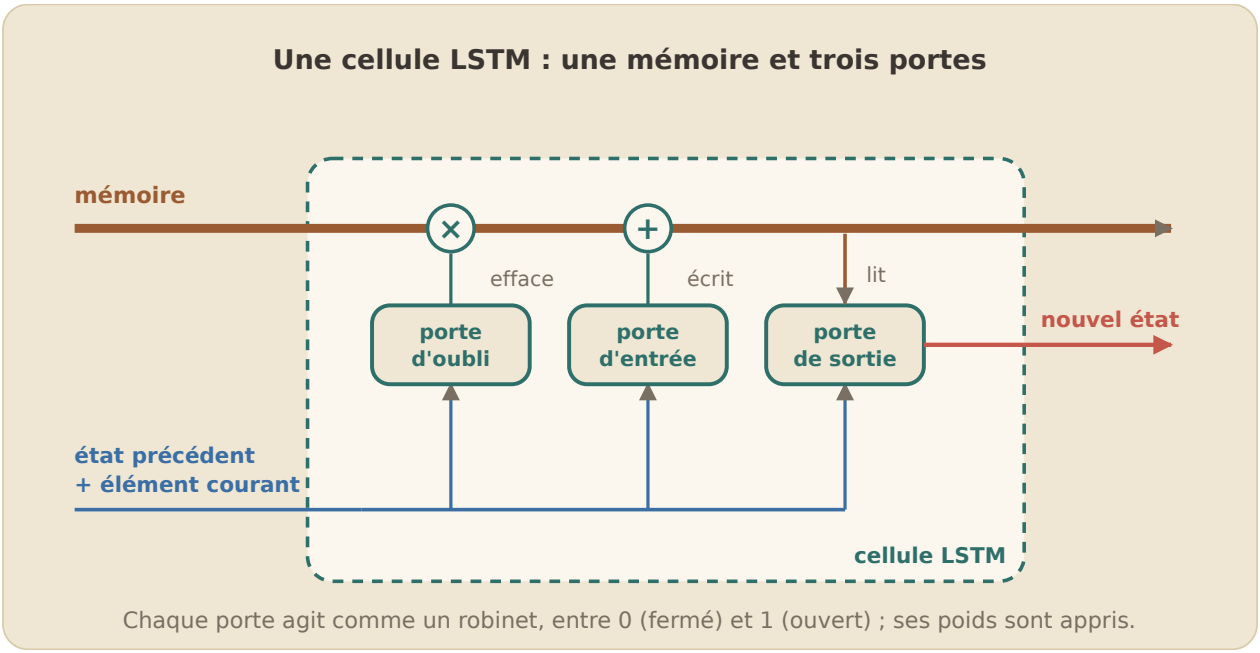
Le LSTM : une mémoire à portes

En 1997, Sepp Hochreiter et Jürgen Schmidhuber, à Munich, proposent une cellule récurrente conçue pour ne pas oublier : la **mémoire à long et court terme**, ou **LSTM** (*long short-term memory*).

La cellule LSTM contient une **mémoire** (*cell state*) séparée de son état, une liste de nombres qui passe d'une étape à la suivante presque sans transformation. À chaque étape, trois **portes** (*gates*) décident de ce qui arrive à cette mémoire :

- la **porte d'oubli** (*forget gate*) décide ce qu'il faut effacer ;
- la **porte d'entrée** (*input gate*) décide ce qu'il faut y écrire à partir de l'élément courant ;
- la **porte de sortie** (*output gate*) décide ce qu'il faut en lire pour produire l'état.

Chaque porte est un petit groupe de neurones, dont la sortie, entre 0 et 1, agit comme un robinet : 0 bloque l'information, 1 la laisse passer. Les portes ont leurs propres poids, appris par rétropropagation comme les autres. Le réseau apprend donc lui-même quand retenir et quand oublier. Dans la phrase des clés, il peut apprendre à écrire « sujet au pluriel » dans sa mémoire en lisant « Les clés », à le garder pendant les mots suivants, puis à le lire au moment du verbe.



Une cellule LSTM, simplifiée : une mémoire qui traverse la cellule, et trois portes qui décident ce qu'on y efface, écrit et lit.

Comme la mémoire passe d'une étape à l'autre sans être recalculée, l'erreur peut aussi la remonter sans s'affaiblir autant. Un LSTM apprend des liens sur des centaines d'étapes, là où un réseau récurrent simple se limite à une dizaine.

Des réseaux avec une mémoire externe
En 2014, Alex Graves et ses collègues de DeepMind vont plus loin. Ils donnent à un réseau récurrent une **mémoire externe**, une sorte de tableau où il peut écrire et lire à n'importe quelle case. Ils l'appellent **machine de Turing neuronale** (*neural Turing machine*), en référence au ruban de la machine de Turing du Module 1. Le réseau apprend ainsi, à partir d'exemples, de petits algorithmes comme copier ou trier une liste. L'idée est restée un sujet de recherche, mais le mécanisme qui choisit où lire dans la mémoire annonce celui du chapitre suivant.

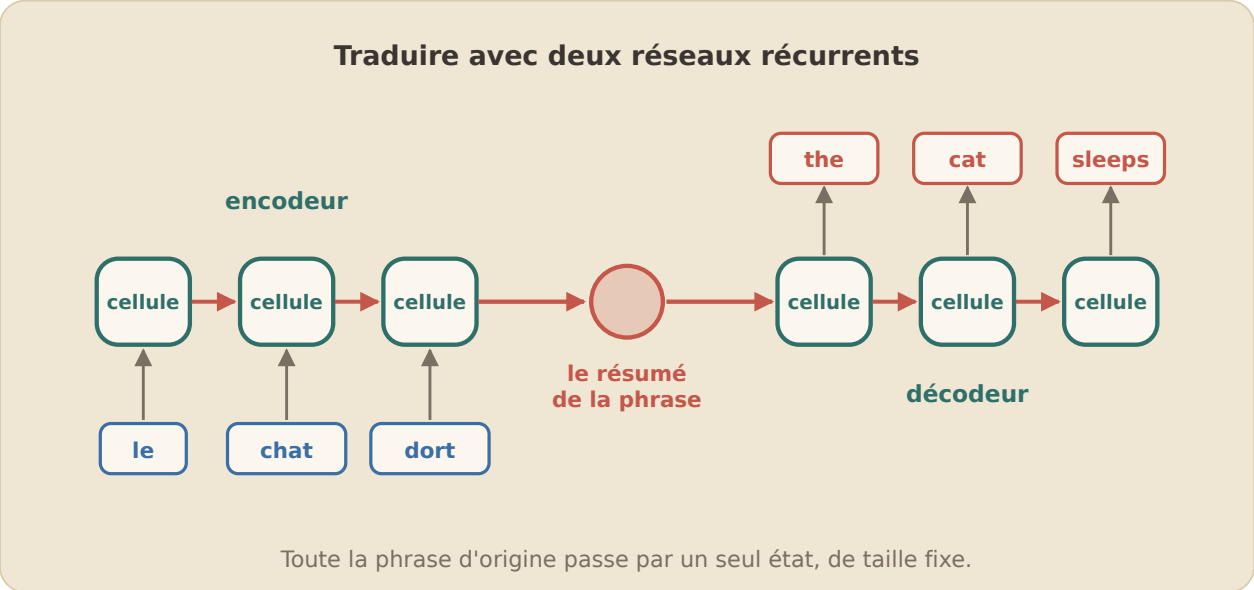
Ce que les réseaux récurrents ont permis

Entre 2009 et 2017, les réseaux récurrents, et surtout les LSTM, deviennent la méthode de référence pour les séquences.

L'écriture manuscrite. En 2009, un LSTM conçu par Alex Graves remporte des concours de reconnaissance d'écriture manuscrite (*handwriting recognition*). Il lit l'écriture comme une séquence, sans découper les mots en lettres à l'avance. Le fil des chiffres manuscrits de ce module se prolonge ainsi des chiffres isolés à l'écriture courante.

La parole. Un enregistrement de parole est une séquence de sons. En 2015, Google adopte les LSTM pour la reconnaissance vocale (*speech recognition*) de ses téléphones, et son taux d'erreur baisse nettement.

La traduction. En 2014, Ilya Sutskever, Oriol Vinyals et Quoc Le, chez Google, proposent l'architecture **encodeur-décodeur** (*encoder-decoder*) pour la traduction. Un premier réseau récurrent, l'encodeur, lit la phrase à traduire et la résume dans son état final. Un second réseau récurrent, le décodeur, part de cet état et écrit la traduction mot par mot. On retrouve l'assemblage de l'autoencodeur : deux réseaux branchés l'un à la suite de l'autre et entraînés ensemble, avec une représentation compacte au milieu. En novembre 2016, Google Traduction adopte cette méthode. Selon le *New York Times*, le gain obtenu d'un seul coup équivaut à peu près à tous les progrès accumulés par l'ancien système depuis son lancement, une dizaine d'années plus tôt.



L'architecture encodeur-décodeur : un réseau lit la phrase, un autre écrit la traduction à partir de son résumé.

Les limites

Les réseaux récurrents ont trois limites, qui motivent le chapitre suivant.

Le goulot (*bottleneck*). Dans l'encodeur-décodeur, toute la phrase d'origine est résumée en un seul état, de taille fixe, qu'elle compte cinq mots ou cinquante. Plus la phrase est longue, plus la traduction se dégrade.

La lenteur. Un réseau récurrent ne peut calculer l'étape 10 qu'après l'étape 9. Le calcul est séquentiel par nature, et ne profite donc pas des milliers de cœurs d'un GPU, qui exigent des calculs simultanés. Cette limite devient décisive quand on veut entraîner sur des milliards de mots.

La mémoire lointaine. Le LSTM a repoussé la limite de l'oubli, sans la supprimer.

En 2014, à Montréal, Dzmitry Bahdanau, Kyunghyun Cho et Yoshua Bengio s'attaquent au premier problème. Ils permettent au décodeur, à chaque mot qu'il écrit, de regarder directement tous les mots de la phrase d'origine, et de choisir ceux qui comptent à ce moment. Ce mécanisme s'appelle l'**attention**. Trois ans plus tard, une équipe de Google montre qu'on peut garder l'attention et supprimer la récurrence. Le chapitre suivant, « L'attention et le Transformer », présente ce résultat.

L'attention et le Transformer

Le chapitre « Lire une séquence » s'est terminé sur trois limites des réseaux récurrents (*recurrent neural networks*, RNN) : toute une phrase passe par un seul état, le calcul avance une étape à la fois, et les éléments lointains s'oublient. Ce chapitre présente le mécanisme qui a levé ces limites, l'**attention**, puis l'architecture construite autour de lui, le **Transformer**. Il traite le Transformer comme une architecture, au même titre que les réseaux convolutifs ou récurrents. Ce qu'il permet de faire avec le langage est le sujet du Module 4.

Le Transformer est lui aussi fait des mêmes briques. Son biais inductif est le plus faible des trois : chaque élément peut consulter tous les autres, quelle que soit leur distance, et l'architecture ne suppose presque rien sur l'ordre ou le voisinage. Le Transformer doit donc presque tout apprendre des données, ce qui demande d'énormes quantités d'exemples, mais il s'adapte ainsi à presque tout : le texte, les images, le son, et même les protéines. On retrouve la leçon amère de Richard Sutton : moins on impose d'hypothèses, plus on dépend des données et du calcul, et plus la méthode est générale.

L'attention dans la traduction

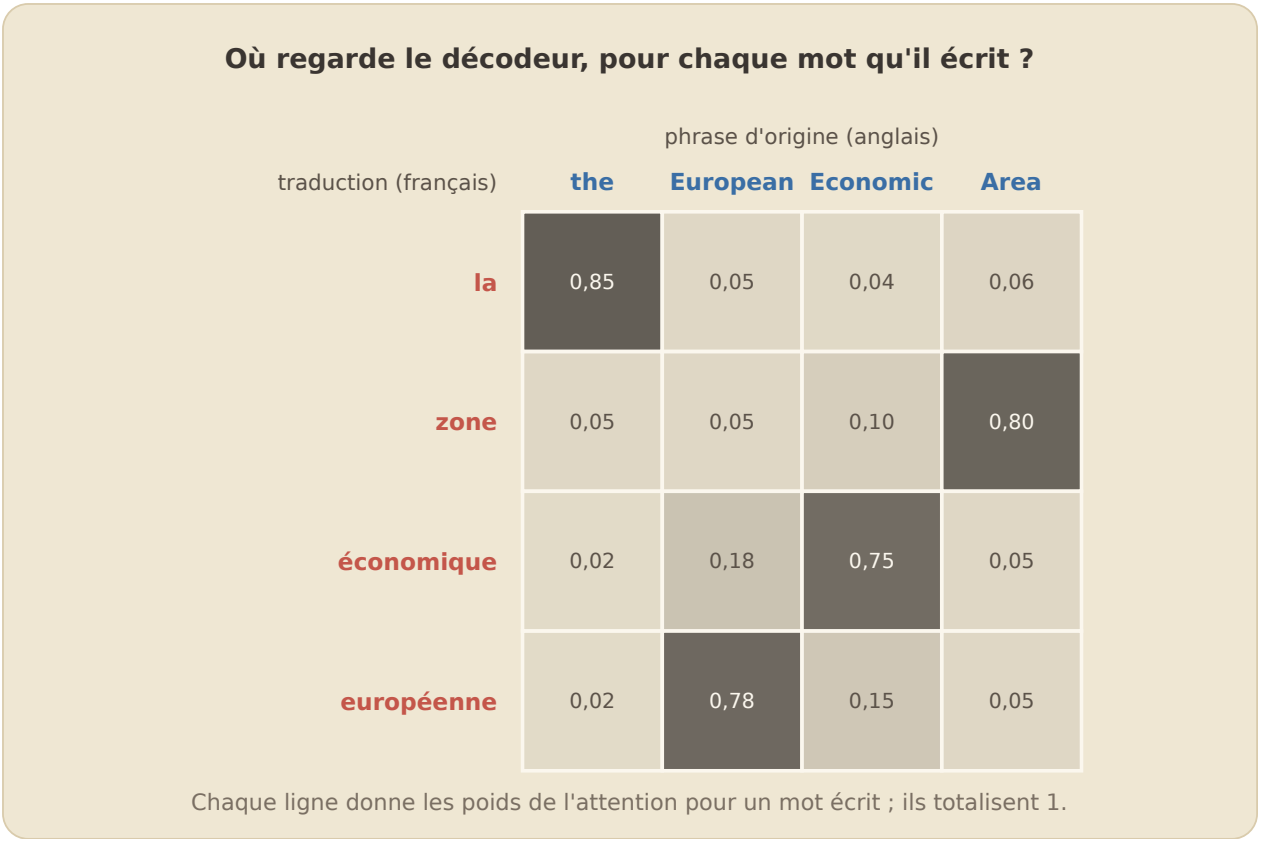
Revenons à l'encodeur-décodeur. Le décodeur écrit la traduction à partir d'un seul état, qui résume toute la phrase d'origine. En 2014, Dzmitry Bahdanau, Kyunghyun Cho et Yoshua Bengio, à Montréal, gardent l'état de l'encodeur après **chaque** mot, et non seulement le dernier. Le décodeur peut alors consulter toute la phrase d'origine à chaque mot qu'il écrit.

Pour chaque mot à écrire, le décodeur procède en trois temps :

1. il compare ce qu'il cherche à chacun des mots de la phrase d'origine, ce qui donne un score par mot ;
2. il transforme ces scores en **poids**, positifs et de total égal à 1 ;
3. il fait un mélange des mots d'origine selon ces poids, et s'en sert pour choisir le mot à écrire.

Les poids indiquent où le décodeur « regarde » au moment d'écrire chaque mot. C'est pourquoi on parle d'**attention**.

L'article de 2014 montre un exemple de traduction de l'anglais vers le français. « The European Economic Area » devient « la zone économique européenne ». L'ordre des mots s'inverse : « European » vient avant « Economic » en anglais, « européenne » vient après « économique » en français. Les poids de l'attention suivent cette inversion. En écrivant « économique », le décodeur regarde surtout « Economic ». En écrivant « européenne », il regarde surtout « European ».



Les poids de l'attention pour la traduction de « the European Economic Area ». Les valeurs sont redessinées d'après l'exemple de Bahdanau, Cho et Bengio (2014).

Personne n'a indiqué au réseau quel mot correspond à quel mot. Ces correspondances sont apprises, comme tous les poids, par rétropropagation.

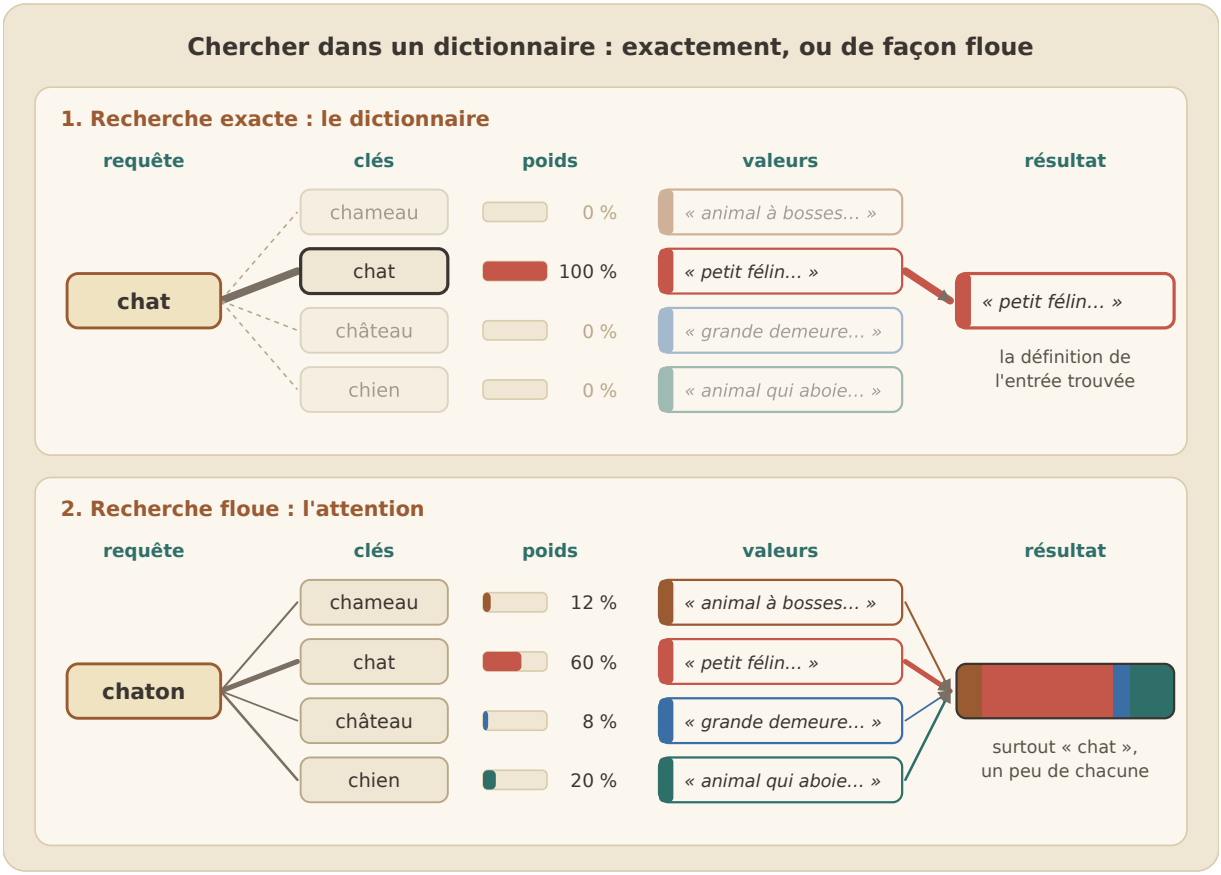
Une recherche floue

L'attention est une forme de recherche. Dans une recherche ordinaire, par exemple dans un dictionnaire, on cherche un mot, on le compare aux entrées, et on récupère la définition de l'entrée qui correspond exactement. Le Module 1 décrivait de la même façon la recherche d'un fait dans la base de faits d'un système expert.

L'attention procède de la même façon, avec une différence : elle ne choisit pas une seule entrée. Elle compare la question à toutes les entrées, et récupère un peu de chacune, en proportion de leur ressemblance avec la question. C'est une recherche floue.

On donne un nom à chacun des trois éléments :

- la **requête** (*query*) est ce que l'on cherche ;
- les **clés** (*keys*) sont ce à quoi on compare la requête, une par entrée ;
- les **valeurs** (*values*) sont ce que l'on récupère, une par entrée.



Une recherche exacte ne retient qu'une entrée. L'attention les retient toutes, chacune selon sa ressemblance avec la requête, et répond même quand aucune entrée ne correspond exactement.

Dans un réseau, les requêtes, les clés et les valeurs sont des listes de nombres calculées par des neurones. Leurs poids sont appris. Le réseau apprend donc à la fois quoi chercher, comment se décrire pour être trouvé, et quoi transmettre.

Pour aller plus loin : le calcul sur un petit exemple
Prenons une requête et trois entrées, chacune décrite par deux nombres.

	Clé	Valeur
Entrée A	$(1, 0)$	10
Entrée B	$(0, 1)$	20
Entrée C	$(1, 1)$	30

La requête est $(2, 0)$. On la compare à chaque clé en multipliant les nombres deux à deux et en additionnant : 2 pour A, 0 pour B, 2 pour C. On transforme ensuite ces scores en poids qui totalisent 1, en favorisant les scores élevés. On obtient environ 0,47 pour A, 0,06 pour B et 0,47 pour C. Le résultat est le mélange des valeurs selon ces poids : $0{,}47 \times 10 + 0{,}06 \times 20 + 0{,}47 \times 30$, soit environ 20. La requête a surtout récupéré les valeurs de A et de C, dont les clés lui ressemblent.

L'auto-attention

Dans la traduction, le décodeur porte son attention sur la phrase d'origine. L'étape suivante consiste à appliquer l'attention à l'intérieur d'une même phrase. Chaque mot émet une requête, et va chercher l'information utile chez les autres mots de la phrase. On parle d'**auto-attention** (*self-attention*).

Prenons la phrase « Le chien n'est pas monté dans le camion parce qu'il était trop fatigué. » Le mot « il » peut désigner le chien ou le camion. Pour le comprendre, il faut aller chercher l'information dans « chien ». Si la phrase se termine par « trop haut », « il » désigne le camion. Le sens d'un mot dépend de son contexte, et l'auto-attention calcule ce lien.

Après une couche d'auto-attention, chaque mot n'est plus représenté seul. Sa représentation contient une part de l'information des mots qu'il a regardés. Le « il » de la première phrase porte maintenant une part de « chien ».

Une attention à manipuler

Dans l'applet ci-dessous, cliquez sur un mot pour voir où il porte son attention. Les arcs le relient aux autres mots, d'autant plus épais que le poids est grand, et les poids s'affichent sous chaque mot. Ces poids ont été choisis pour l'exemple. Dans un vrai Transformer, ils sont calculés par le réseau, et ils sont en général moins nets.

Applet interactive : à utiliser en ligne, sur la page « L'attention et le Transformer » du site du cours.

1. Le mot « il » est choisi. Observez où il porte son attention.
2. Remplacez la fin de la phrase par « … trop haut. » L'attention de « il » se déplace vers « camion ».
3. Cliquez sur « fatigué », puis sur « haut » dans la seconde phrase. Chacun regarde le nom qu'il qualifie.
4. Cliquez sur « monté ». Il regarde surtout « chien » et « camion », son sujet et son complément.

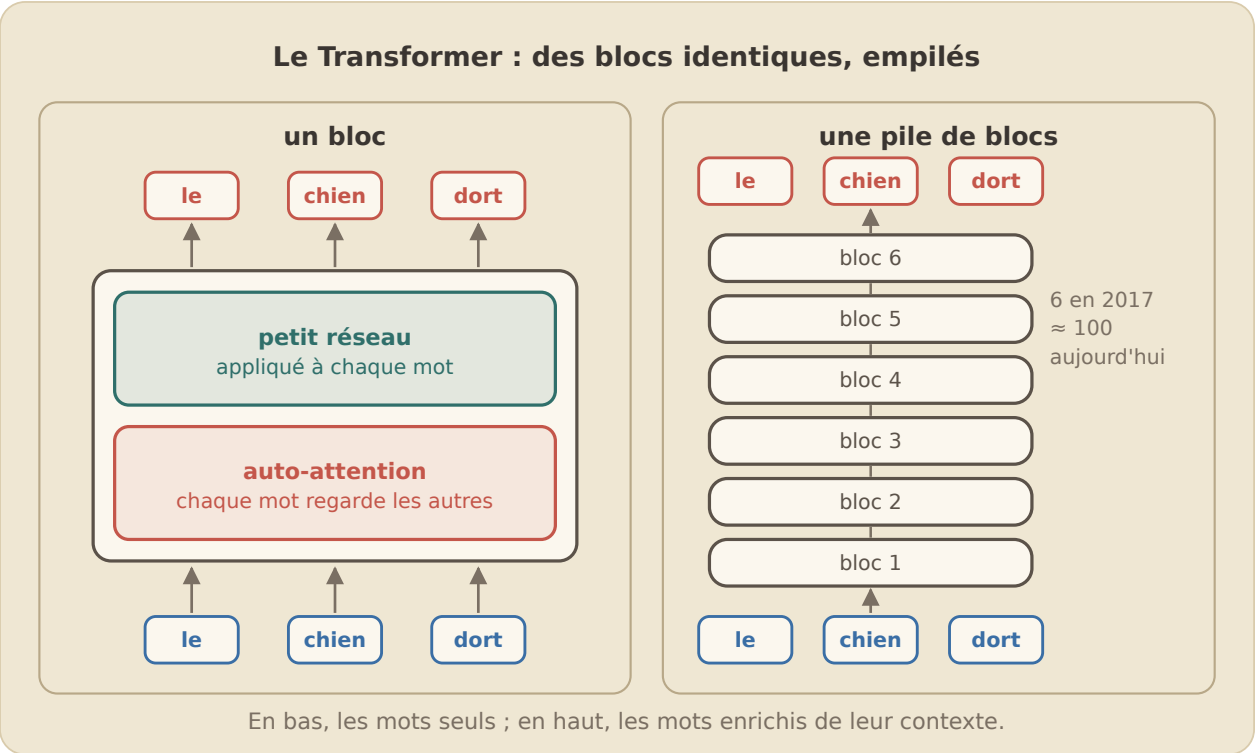
Le Transformer

En 2017, huit chercheurs de Google, dont Ashish Vaswani, publient un article intitulé « Attention Is All You Need » (« L'attention suffit »). L'idée tient dans le titre. On supprime la récurrence et on ne garde que l'attention. L'architecture qui en résulte s'appelle le **Transformer**.

Un Transformer est fait de **blocs** identiques, empilés. Chaque bloc contient deux étapes :

1. une couche d'**auto-attention**, où chaque mot va chercher l'information utile chez les autres mots ;
2. un petit réseau ordinaire, appliqué à chaque mot séparément, qui transforme l'information recueillie.

Le texte traverse les blocs l'un après l'autre. À chaque bloc, la représentation de chaque mot s'enrichit de son contexte. L'article de 2017 empile six blocs. Les grands modèles actuels en empilent une centaine.



Le Transformer : chaque bloc combine l'auto-attention et un petit réseau ; on empile les blocs.

Deux précisions complètent ce schéma.

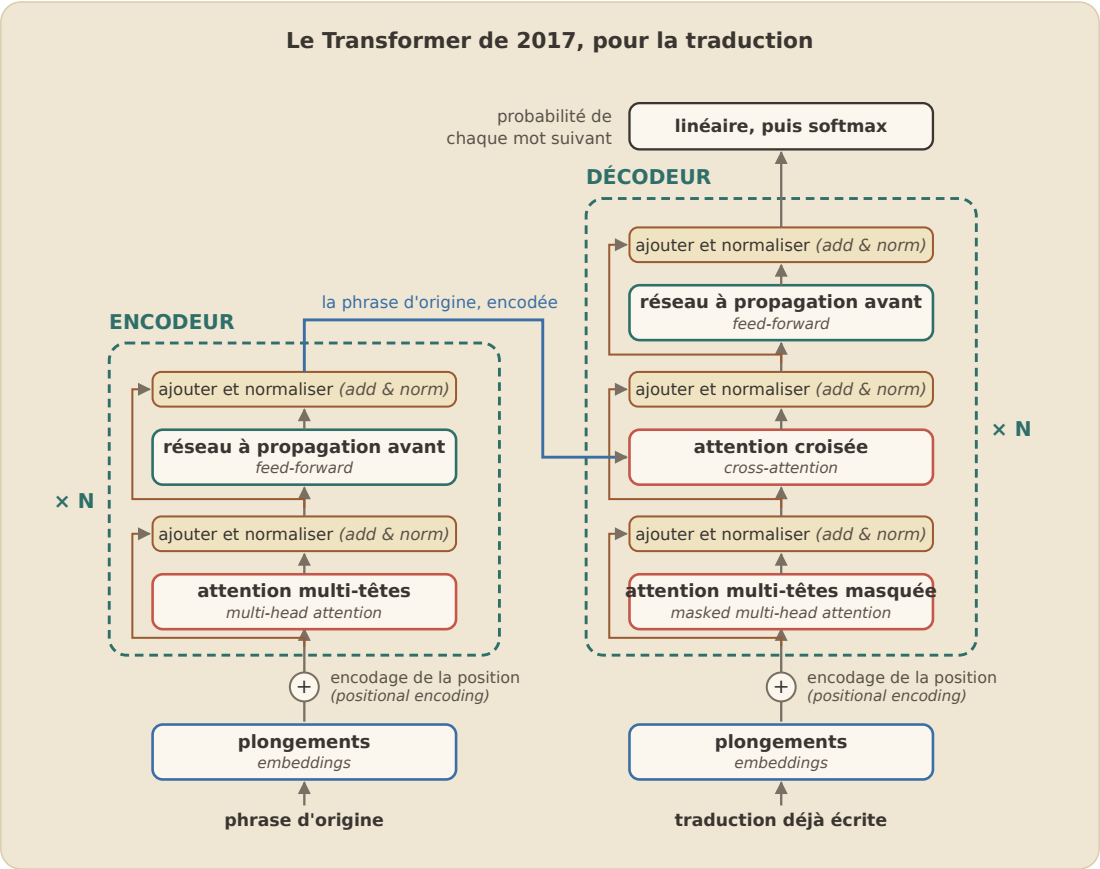
Plusieurs têtes. Chaque couche d'auto-attention contient plusieurs mécanismes d'attention en parallèle, appelés **têtes** (*attention heads*), par exemple huit. Chacune a ses propres requêtes, clés et valeurs, et peut apprendre un type de lien différent : une tête relie un verbe à son sujet, une autre un pronom au nom qu'il désigne, une autre un mot à son voisin.

La position. Un réseau récurrent connaissait l'ordre des mots, puisqu'il les lisait un à un. L'auto-attention, elle, traite tous les mots en même temps et ne connaît pas leur ordre. Pour elle, « le chien mord l'homme » et « l'homme mord le chien » seraient identiques. On ajoute donc à chaque mot, à l'entrée du réseau, une indication de sa position dans la phrase (*positional encoding*).

On retrouve aussi dans le Transformer les raccourcis de ResNet, qui laissent l'information sauter une étape et facilitent l'entraînement d'une pile très profonde.

Le schéma de l'article de 2017 rassemble toutes ces pièces. Il a deux colonnes, parce que le Transformer a d'abord été conçu pour la traduction.

- À gauche, l'**encodeur** lit la phrase d'origine. Chacun de ses blocs contient l'auto-attention à plusieurs têtes, puis le petit réseau ordinaire, appelé ici « réseau à propagation avant » (*feed-forward*). Chaque étape est suivie de « ajouter et normaliser » (*add & norm*) : on ajoute à sa sortie l'entrée qui a pris le raccourci, puis on ramène les nombres à une échelle stable.
- À droite, le **décodeur** écrit la traduction, un mot à la fois. Son auto-attention est **masquée** : chaque mot ne voit que les mots déjà écrits, pas ceux qu'il doit justement prédire. Vient ensuite l'**attention croisée** (*cross-attention*), où les mots de la traduction vont chercher l'information dans la phrase d'origine encodée. C'est la grille de traduction du début du chapitre.
- En haut, une dernière couche et un softmax donnent la probabilité de chaque mot suivant.



Le Transformer de 2017, d'après la figure de l'article « Attention Is All You Need ». Chaque colonne répète son bloc N fois (six dans l'article).

Les deux colonnes peuvent aussi servir séparément. Le Module 4 montre ce que chacune est devenue.

Pourquoi il a tout changé

Le Transformer règle les trois limites des réseaux récurrents, et en ajoute une.

Le parallélisme. Tous les mots d'un texte sont traités en même temps, et non l'un après l'autre. Les calculs de l'attention sont des multiplications répétées, le type de calcul pour lequel les GPU sont conçus. Un Transformer s'entraîne donc beaucoup plus vite qu'un réseau récurrent de même taille.

La distance. Dans un réseau récurrent, l'information du premier mot doit traverser toutes les étapes pour atteindre le centième. Dans un Transformer, le centième mot regarde directement le premier, en une seule étape. La mémoire lointaine n'est plus un problème de principe.

L'échelle. Ces deux propriétés permettent d'entraîner des réseaux beaucoup plus grands, sur beaucoup plus de texte. Les Transformers des années 2020 comptent des centaines de milliards de poids, entraînés sur une grande partie du texte disponible sur le Web. Ce changement d'échelle est celui que décrivait la leçon amère.

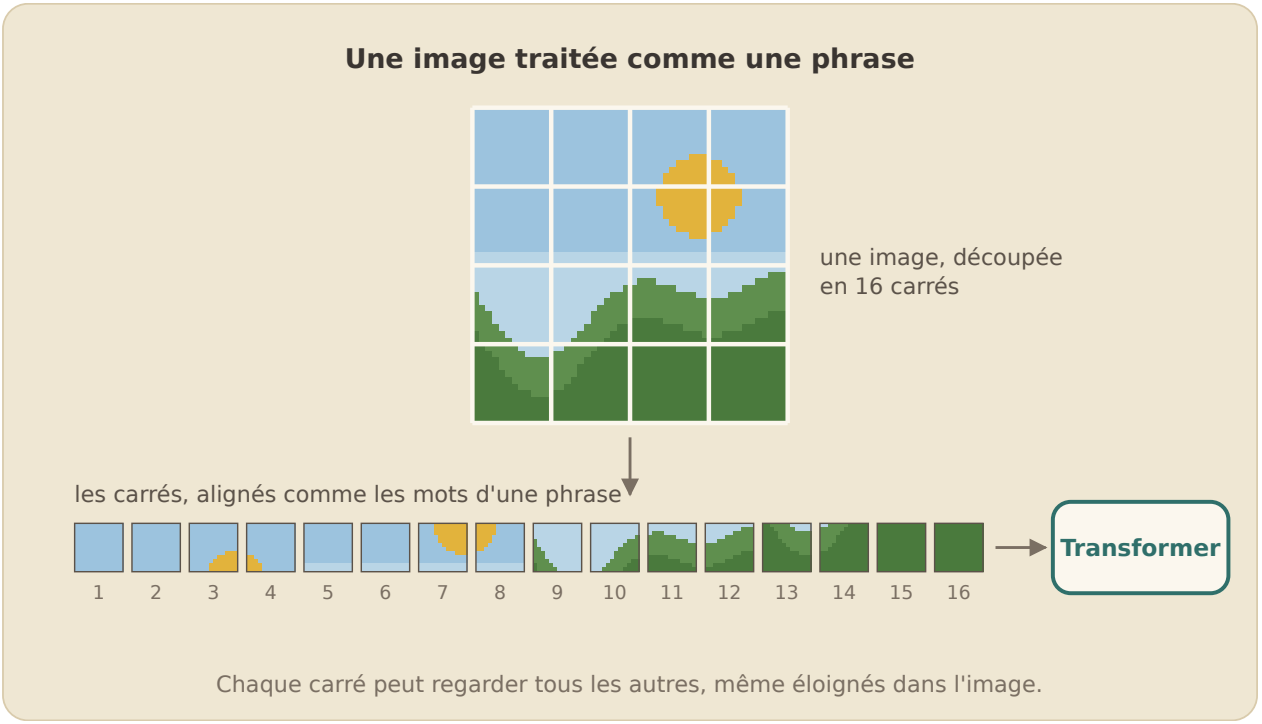
Un coût. Dans l'auto-attention, chaque mot regarde tous les autres. Pour un texte de 1 000 mots, cela fait un million de comparaisons. Pour 2 000 mots, quatre millions. Le calcul croît avec le carré de la

longueur du texte. C'est pourquoi un Transformer ne peut traiter qu'un texte de longueur limitée à la fois, sa **fenêtre de contexte** (*context window*). Le Module 4 reviendra sur cette notion.

Au-delà du texte

Le Transformer a été conçu pour la traduction, mais rien dans son fonctionnement n'est propre au langage. Il suffit de découper les données en éléments, et de laisser chaque élément regarder les autres.

Les images. En 2020, une équipe de Google découpe une image en petits carrés de 16 pixels sur 16 et les traite comme les mots d'une phrase. Ce *Vision Transformer* n'a pas la connaissance inscrite dans un réseau convolutif : il ne sait pas d'avance que les pixels voisins sont liés, et doit l'apprendre. Avec peu d'images, il fait moins bien qu'un réseau convolutif. Avec des centaines de millions d'images, il fait mieux. C'est un nouvel exemple de la leçon amère, et une nuance à la leçon de la convolution : une connaissance inscrite dans le réseau aide quand les données sont rares, et peut gêner quand elles sont abondantes.



Le Vision Transformer découpe une image en carrés et les traite comme les mots d'une phrase.

La biologie. Une protéine est une chaîne d'acides aminés qui se replie dans l'espace, et sa forme détermine son rôle. Prédire cette forme à partir de la chaîne était un problème ouvert depuis cinquante ans. En 2020, le système **AlphaFold 2**, de DeepMind, le résout pour la plupart des protéines, avec un mécanisme d'attention au cœur de son architecture. Ce travail a valu à Demis Hassabis et John Jumper une moitié du prix Nobel de chimie 2024.

La parole, la musique, le code. Tous les types de séquences se prêtent à la même méthode.

Vers le Module 4

Dès 2018, deux usages du Transformer apparaissent. **BERT**, chez Google, lit un texte en entier pour en produire une représentation, utile par exemple aux moteurs de recherche. **GPT**, chez OpenAI, est entraîné à une tâche plus simple : prédire le mot suivant d'un texte. Agrandi de version en version, ce second type de modèle est à l'origine des grands modèles de langage, comme ChatGPT. Le Module 4 leur est consacré.

Pour voir le mécanisme en détail

La vidéo ci-dessous, de la série de 3Blue1Brown déjà présentée dans « Entraîner un réseau », explique l'attention pas à pas, avec ses requêtes, ses clés et ses valeurs. Elle est en anglais.

Vidéo : https://www.youtube.com/watch?v=eMlx5fFNoYc

Le chapitre suivant, « Apprendre à jouer : le renforcement profond », quitte les séquences. Il revient à l'apprentissage par renforcement (*reinforcement learning*) du Module 2 et montre ce qu'il devient avec les réseaux profonds.

Apprendre à jouer : le renforcement profond

Au Module 2, un agent apprenait à sortir d'une petite grille par essais et erreurs. Il remplissait une table, avec une valeur pour chaque case, et la récompense finale se propageait peu à peu vers les cases de départ. Ce chapitre montre ce qui se passe quand on remplace cette table par un réseau profond, et comment cette combinaison a permis à une machine de battre les meilleurs joueurs de go.

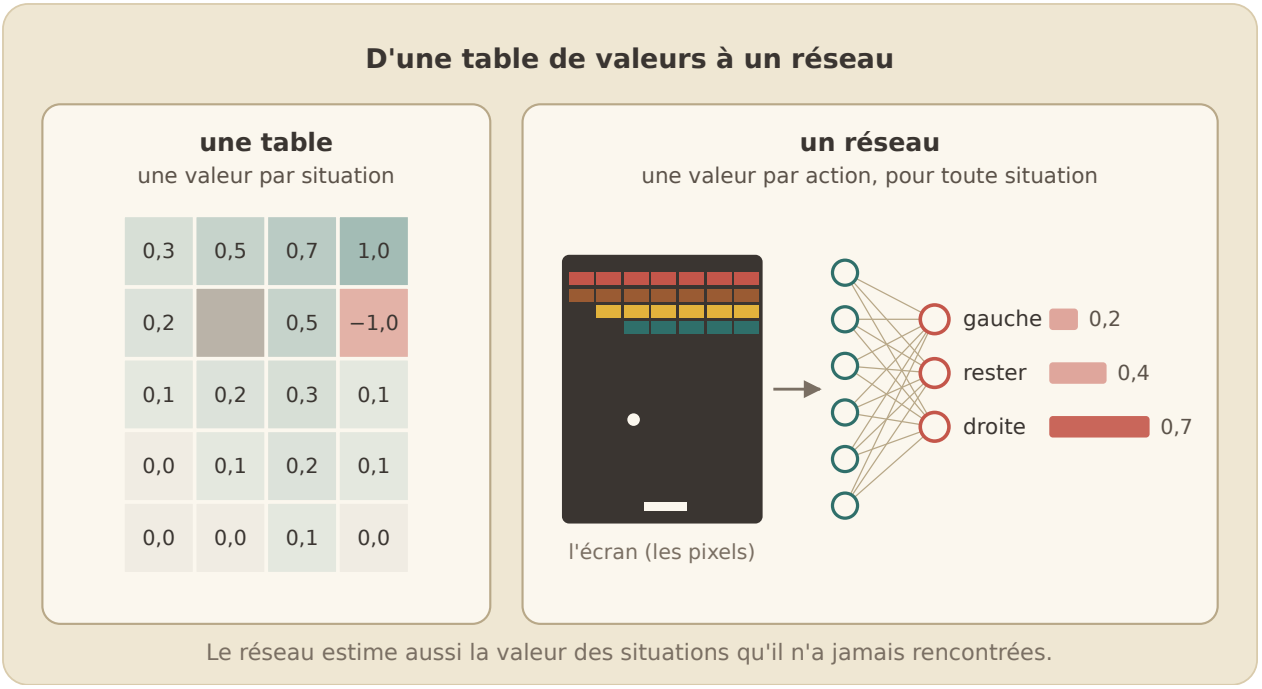
Les limites de la table

Rappelons le vocabulaire du Module 2. Un **agent** choisit des **actions**. Il reçoit parfois une **récompense** (*reward*), souvent longtemps après les actions qui l'ont produite. Il apprend la **valeur** de chaque situation, c'est-à-dire la récompense qu'il peut en espérer, et doit trouver un équilibre entre **explorer** de nouvelles actions et **exploiter** celles qu'il connaît.

La grille du Module 2 comptait une vingtaine de cases, et la table des valeurs tenait sur un écran. Les situations réelles sont beaucoup plus nombreuses. Une image d'un jeu vidéo peut prendre un nombre astronomique d'états différents. Au go, le nombre de positions possibles dépasse le nombre d'atomes de l'univers observable. On ne peut pas remplir une table de cette taille. Et même si on le pouvait, on ne reverrait presque jamais deux fois la même situation : la table n'apprendrait rien d'utile.

Remplacer la table par un réseau

La solution consiste à remplacer la table par un réseau de neurones. Le réseau reçoit la situation, par exemple l'image de l'écran, et estime la valeur de chaque action possible.



La table du Module 2 donne une valeur par situation ; un réseau estime la valeur de chaque action, pour n'importe quelle situation.

Le réseau apporte ce que la table ne pouvait pas offrir : la généralisation. Deux situations semblables reçoivent des valeurs semblables, même si l'une d'elles n'a jamais été rencontrée. L'agent peut donc profiter de son expérience dans des situations nouvelles.

L'idée n'est pas nouvelle. Au début des années 1990, Gerald Tesauro, chez IBM, crée **TD-Gammon**, un réseau de neurones qui apprend le backgammon en jouant contre lui-même, au cours d'environ un million et demi de parties. Il atteint presque le niveau des meilleurs joueurs du monde, et certains de ses choix modifient la façon dont les experts humains jouent certaines positions. Mais la méthode semble alors propre au backgammon, et elle est peu reprise pendant vingt ans.

Atari : jouer à partir des pixels

En 2013, la jeune entreprise londonienne DeepMind présente **DQN** (*deep Q-network*). En 2015, une version améliorée paraît dans la revue *Nature*. Le même réseau, un réseau convolutif, apprend à jouer à 49 jeux vidéo de la console Atari 2600. Il ne reçoit que les pixels de l'écran et le score. Personne ne lui explique les règles, ni le but du jeu. Sur une bonne partie de ces jeux, il atteint ou dépasse le niveau d'un joueur humain expérimenté.

L'exemple le plus connu est *Breakout*, où il faut détruire un mur de briques avec une balle. Après quelques centaines de parties, le réseau découvre une stratégie que ses concepteurs ne lui avaient pas indiquée : creuser un tunnel sur le côté du mur, pour envoyer la balle derrière, où elle détruit les briques toute seule.

Vidéo : https://www.youtube.com/watch?v=TmPfTpjtdgg

Le réseau échoue en revanche à *Montezuma's Revenge*, un jeu d'exploration où il faut traverser plusieurs salles avant d'obtenir le moindre point. En jouant au hasard, l'agent ne reçoit presque jamais

de récompense, et n'a donc rien à renforcer. Le compromis entre explorer et exploiter (*exploration-exploitation trade-off*), vu au Module 2, reste une difficulté centrale.

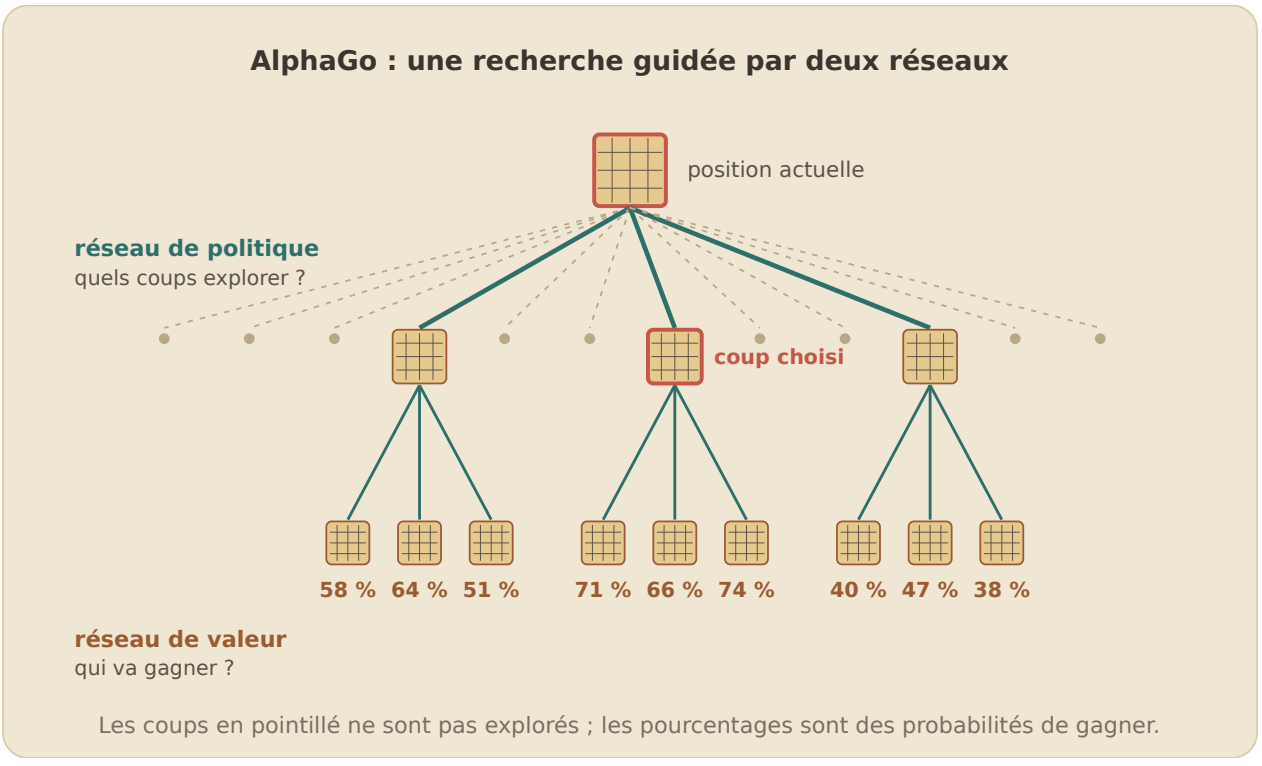
AlphaGo

Le go se joue sur un plateau de 19 lignes sur 19, le goban. Deux joueurs y posent tour à tour des pierres noires et blanches, et cherchent à entourer le plus grand territoire. Les règles sont simples, mais le jeu est d'une grande profondeur. En 2015, les meilleurs programmes n'atteignaient que le niveau d'un bon amateur.

La méthode de Deep Blue, présentée au Module 1, ne suffisait pas, pour deux raisons. À chaque tour, un joueur de go a environ 250 coups possibles, contre environ 35 aux échecs. L'arbre des coups (*game tree*) grandit donc beaucoup trop vite. Surtout, personne ne savait écrire une bonne fonction d'évaluation (*evaluation function*) pour une position de go. Les meilleurs joueurs eux-mêmes jugent une position à l'intuition, sans pouvoir l'expliquer en règles.

AlphaGo, de DeepMind, combine trois éléments :

- un **réseau de politique** (*policy network*), qui regarde la position et propose les coups prometteurs. Il évite d'explorer les 250 coups possibles ;
- un **réseau de valeur** (*value network*), qui regarde une position et estime qui va gagner. Il remplace la fonction d'évaluation que personne ne savait écrire ;
- une **recherche dans l'arbre des coups** (*tree search*), comme au Module 1, guidée par ces deux réseaux.



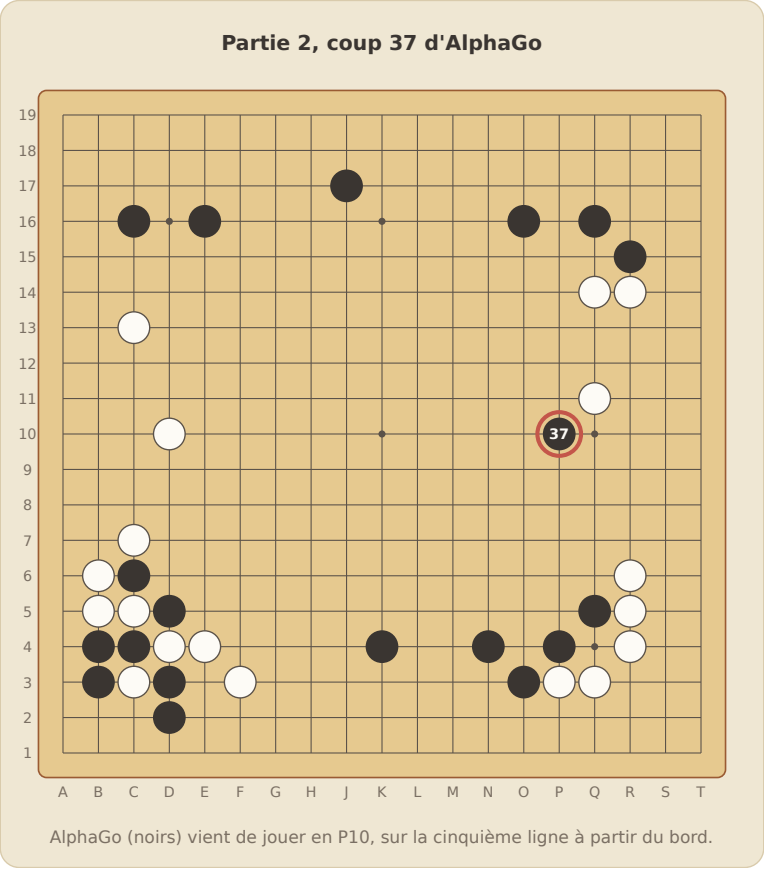
AlphaGo : le réseau de politique choisit les coups à explorer, le réseau de valeur évalue les positions atteintes.

C'est la rencontre des deux traditions de ce cours : la recherche du Module 1, et l'apprentissage

des Modules 2 et 3. AlphaGo montre aussi que l'assemblage ne se limite pas aux réseaux : on peut brancher des réseaux de neurones sur un algorithme classique, ici une recherche, et chacun fait ce qu'il fait le mieux. Les deux réseaux sont d'abord entraînés sur des parties de joueurs humains, en apprentissage supervisé (*supervised learning*) : le réseau de politique apprend à prédire le coup qu'un expert jouerait. Ils sont ensuite améliorés par renforcement, AlphaGo jouant des millions de parties contre lui-même.

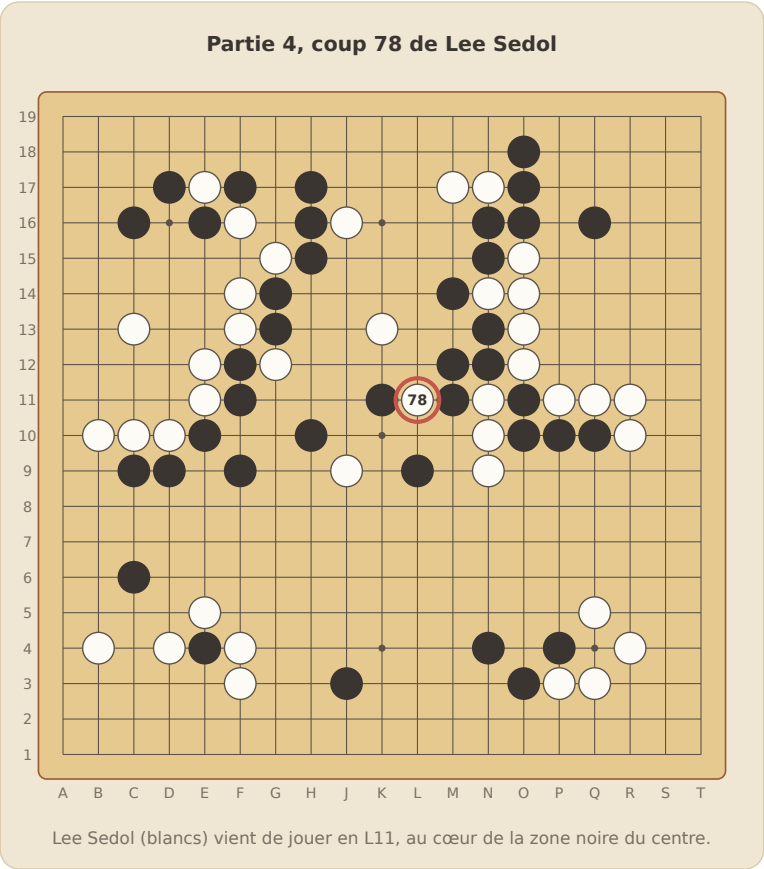
En mars 2016, à Séoul, AlphaGo affronte Lee Sedol, l'un des meilleurs joueurs du monde, en cinq parties. Il gagne 4 à 1.

Au 37e coup de la deuxième partie, AlphaGo pose une pierre sur la cinquième ligne à partir du bord, un coup que les commentateurs prennent d'abord pour une erreur. Selon DeepMind, AlphaGo estimait lui-même qu'un joueur humain n'aurait joué ce coup qu'une fois sur dix mille. La suite de la partie montre qu'il était excellent.



Le coup 37 de la deuxième partie (positions relevées d'après les diagrammes de Wikimedia Commons).

Lee Sedol remporte la quatrième partie grâce à son 78e coup, au centre du goban, que les commentateurs ont qualifié de « coup divin ». AlphaGo ne l'avait pas envisagé, et il joue mal pendant plusieurs coups ensuite.



Le coup 78 de la quatrième partie (positions relevées d'après une image de Axd, Wikimedia Commons, CC BY-SA 4.0).

Le documentaire *AlphaGo* (2017), mis en ligne gratuitement par DeepMind, raconte ce match. Il dure environ une heure et demie, en anglais.

Vidéo : https://www.youtube.com/watch?v=WXuK6gekU1Y

AlphaZero : sans parties humaines

En 2017, DeepMind présente **AlphaGo Zero**. Il ne voit aucune partie humaine. Il ne connaît que les règles du go, et apprend uniquement en jouant contre lui-même, en partant de coups joués au hasard. En trois jours, il joue près de cinq millions de parties contre lui-même, puis bat la version qui avait vaincu Lee Sedol par 100 parties à 0. Les joueurs qui ont étudié ses parties y ont trouvé des ouvertures que les humains n'avaient jamais jouées en plusieurs siècles.

La même année, **AlphaZero** applique la même méthode, sans modification, aux échecs et au shogi, les échecs japonais. Après quelques heures d'entraînement pour chacun, il dépasse les meilleurs programmes de ces jeux.

Le contraste avec Deep Blue est instructif. La fonction d'évaluation de Deep Blue avait été réglée pendant des années avec l'aide de grands maîtres, et Deep Blue examinait environ 200 millions de positions par seconde. AlphaZero a appris seul sa fonction d'évaluation, et il examine environ 80 000 positions par seconde, plus de deux mille fois moins, parce que son réseau de politique lui

indique où chercher. C'est l'illustration la plus nette de la leçon amère : une méthode générale, l'apprentissage par auto-jeu (*self-play*), dépasse le savoir humain inscrit à la main.

Une machine qui apprend en jouant contre elle-même

L'applet ci-dessous applique ce principe au morpion. La machine ne connaît que les règles. Elle tient une table : pour chaque position, une valeur entre -1 et $+1$, qui indique si cette position mène plutôt à la défaite ou à la victoire du joueur qui vient de jouer. À chaque partie d'entraînement contre elle-même, elle joue le coup qui mène à la meilleure valeur connue, sauf de temps en temps où elle essaie un coup au hasard. À la fin de la partie, elle rapproche la valeur de chaque position jouée du résultat obtenu.

Le morpion ne compte que quelques milliers de positions. Une table suffit donc, et il n'est pas nécessaire d'utiliser un réseau. Mais le principe de l'auto-jeu est celui d'AlphaZero.

Applet interactive : à utiliser en ligne, sur la page « Apprendre à jouer : le renforcement profond » du site du cours.

1. Avant tout entraînement, mesurez le niveau de la machine. Elle joue au hasard, et perd la plupart de ses parties contre un joueur parfait.
2. Entraînez-la par étapes, 100 parties, puis 1 000, puis plusieurs fois 10 000, et observez son niveau progresser. Le « joueur parfait » de l'applet calcule tous les coups possibles jusqu'à la fin de la partie, avec la méthode minimax du Module 1. Contre lui, le mieux possible est la partie nulle.
3. Jouez contre elle après chaque étape. Cochez « voir ce qu'elle pense de chacun de vos coups » pour voir les valeurs de sa table.

Quelques dizaines de milliers de parties suffisent pour qu'elle ne perde plus. Personne ne lui a montré de bon coup.

Au-delà des jeux, et les limites

Les jeux sont un terrain d'essai commode : les règles sont claires, la récompense est nette, et l'on peut jouer des millions de parties. Le renforcement profond (*deep reinforcement learning*) a aussi trouvé des usages hors des jeux.

- En 2016, Google l'utilise pour piloter le refroidissement de ses centres de données, et annonce une réduction d'environ 40 % de l'énergie consacrée au refroidissement.
- En 2022, DeepMind et l'École polytechnique fédérale de Lausanne l'utilisent pour contrôler la forme du plasma dans un réacteur expérimental de fusion nucléaire.
- En robotique, des robots apprennent à marcher ou à manipuler des objets, d'abord dans une simulation, puis dans le monde réel.

La méthode a aussi des limites importantes.

Elle demande énormément d'essais. AlphaGo Zero a joué près de cinq millions de parties contre lui-même en trois jours. Un joueur humain de haut niveau en joue quelques dizaines de milliers dans toute sa vie. Dans le monde réel, où chaque essai prend du temps ou peut causer des dégâts, ce besoin est un obstacle.

Elle optimise exactement la récompense qu'on lui donne. En 2016, OpenAI entraîne un agent sur un jeu de course de bateaux, où l'on gagne des points en passant sur des cibles. L'agent découvre qu'il peut tourner en rond autour de trois cibles qui réapparaissent, et accumuler plus de points qu'en finissant la course. Il fait exactement ce qu'on lui a demandé, et pas du tout ce qu'on voulait. Ce problème de la récompense mal définie concerne tous les systèmes qui optimisent un objectif. Le Module 5 y reviendra, sous le nom d'**alignement**.

Le renforcement a enfin une place importante dans les grands modèles de langage, comme l'annonçait le Module 2. Il sert à ajuster leurs réponses selon les préférences d'évaluateurs humains, et à les entraîner à raisonner sur des problèmes dont la réponse peut être vérifiée. Le Module 4 présentera ces méthodes.

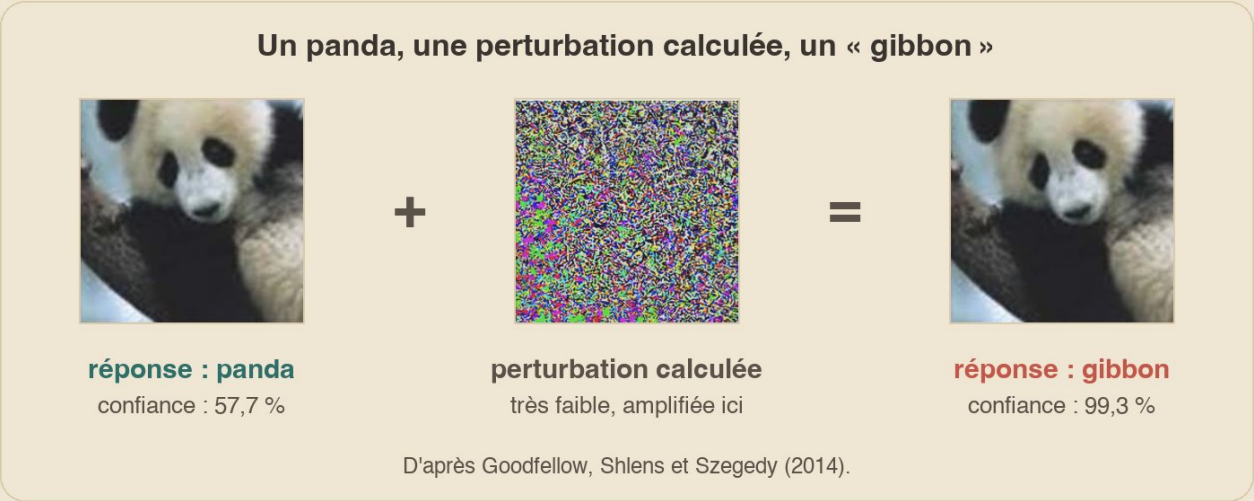
Les réseaux profonds voient, lisent et jouent désormais mieux que nous dans plusieurs domaines. Le dernier chapitre, « Tromper un réseau », montre qu'ils peuvent pourtant être trompés de façon surprenante.

Tromper un réseau

Les chapitres précédents ont montré des réseaux qui reconnaissent des images, traduisent des phrases et battent les meilleurs joueurs de go. Ce dernier chapitre montre une faiblesse surprenante de ces systèmes : une modification invisible pour nous peut leur faire dire n'importe quoi. Il explique comment c'est possible, et ce que cela révèle de leur fonctionnement.

Le panda devenu gibbon

En 2014, Ian Goodfellow, Jonathon Shlens et Christian Szegedy, chez Google, publient l'exemple suivant. Un réseau convolutif (*convolutional neural network*, CNN) entraîné sur ImageNet reconnaît un panda, avec 58 % de confiance. Les chercheurs ajoutent à l'image une perturbation très faible, calculée avec soin. À l'œil, l'image modifiée est identique à l'originale. Le réseau y voit maintenant un gibbon, avec 99 % de confiance.



L'exemple du panda : une perturbation invisible fait passer la réponse de « panda » à « gibbon » (*d'après Goodfellow, Shlens et Szegedy, 2014*).

Une image modifiée de cette façon s'appelle un **exemple adverse** (*adversarial example*). Le phénomène n'est pas propre à ce réseau ni à ce panda. On peut fabriquer un exemple adverse pour presque n'importe quelle image et n'importe quel réseau.

Comment on le fabrique

La méthode utilise la rétropropagation, mais à l'envers.

À l'entraînement, on garde l'image fixe et on modifie les poids, dans le sens qui réduit l'erreur. Pour tromper un réseau déjà entraîné, on garde les poids fixes et on modifie l'image. La rétropropagation indique, pour chaque pixel, dans quel sens le modifier pour augmenter la probabilité d'une réponse choisie, par exemple « gibbon ». On déplace alors chaque pixel d'une quantité minuscule, toujours dans le sens le plus utile.

Aucun pixel ne change de façon visible. Mais une image de 224 pixels sur 224 en couleur compte environ 150 000 valeurs. Des changements minuscules, tous orientés dans le même sens, finissent par s'additionner et faire basculer la réponse.

Tromper un réseau à manipuler

Dans l'applet ci-dessous, un classifieur de chiffres a été entraîné sur des chiffres dessinés par l'ordinateur. C'est un modèle simple, une régression logistique à dix sorties, sans couche cachée, et non un réseau profond. Le principe de l'attaque est le même.

Applet interactive : à utiliser en ligne, sur la page « Tromper un réseau » du site du cours.

1. La force est à zéro, et le classifieur reconnaît le 3. Augmentez lentement la force. Observez la perturbation, et le moment où la réponse bascule vers 8.
2. Regardez l'image modifiée au moment où la réponse bascule. Le 3 reste parfaitement lisible pour nous.
3. Essayez d'autres paires de chiffres. Certaines demandent une force beaucoup plus grande que d'autres. Par exemple, faire dire 1 à un 6 est difficile.

Pourquoi c'est possible

Plusieurs explications se complètent.

La dimension. Une image est un point dans un espace qui compte autant de dimensions que de valeurs de pixels, des centaines de milliers. Dans un espace aussi grand, une frontière de décision (*decision boundary*) passe presque toujours tout près de chaque image, dans une direction ou une autre. L'attaque trouve cette direction.

Le réseau ne voit pas comme nous. Il utilise tous les indices qui l'aident à réduire son erreur d'entraînement, y compris des indices que nous ne remarquons pas ou que nous jugerions sans importance. En 2019, Robert Geirhos et ses collègues montrent que les réseaux entraînés sur ImageNet se fient surtout à la **texture** des objets, alors que nous nous fions surtout à leur forme. Une silhouette de chat couverte d'une texture de peau d'éléphant est classée « éléphant ».



(a) Texture image

81.4%	**`Indian elephant`**
10.3%	`indri`
8.2%	`black swan`



(b) Content image

71.1%	**`tabby cat`**
17.3%	`grey fox`
3.3%	`Siamese cat`



(c) Texture-shape cue conflict

63.9%	**`Indian elephant`**
26.4%	`indri`
9.6%	`black swan`

Une texture, un chat, et un chat à texture d'éléphant : le réseau suit la texture plutôt que la forme (*Geirhos et collègues, 2019*).

Le réseau peut réussir pour de mauvaises raisons. En 2016, Marco Ribeiro, Sameer Singh et Carlos Guestrin présentent une méthode pour expliquer les réponses d'un classifieur. Pour la tester, ils entraînent volontairement un classifieur biaisé, qui distingue les loups des huskies : dans ses photos d'entraînement, les loups sont presque toujours sur de la neige. Le classifieur atteint une bonne précision, et leur méthode révèle qu'il regarde surtout l'arrière-plan. Il est devenu un détecteur de neige. Avant de voir cette explication, une partie des personnes interrogées faisaient confiance au classifieur. Après, presque aucune. La neige est **corrélée** aux loups dans ces photos, mais elle n'en est pas la cause, une distinction présentée au Module 2 dans « Corrélation n'est pas causalité ».

Hans le Malin
Au début des années 1900, à Berlin, un cheval nommé Hans semblait savoir compter. On lui posait une addition, et il frappait du sabot le bon nombre de fois. En 1907, le psychologue Oskar Pfungst montre que Hans ne compte pas. Il observe la personne qui l'interroge, et s'arrête quand il perçoit chez elle une réaction involontaire, un léger mouvement de tête, au moment où il atteint le bon nombre. Hans réussissait vraiment, mais pour une autre raison que celle qu'on croyait. On parle aujourd'hui d'**effet Hans le Malin** (*Clever Hans effect*) pour un modèle d'apprentissage qui réussit en s'appuyant sur un indice imprévu, comme la neige derrière les loups.



Hans le Malin et son public, à Berlin, vers 1904 (photo du domaine public, Wikimedia Commons).

Dans le monde réel

Un exemple adverse sur une image numérique demande de modifier chaque pixel, ce qui suppose un accès direct à l'image. Les chercheurs ont montré que les attaques fonctionnent aussi dans le monde physique.

- **Le panneau d'arrêt.** En 2018, une équipe universitaire colle quelques bandes noires et blanches sur un vrai panneau d'arrêt. Pour un humain, ce sont des autocollants sans importance. Le réseau qui lit les panneaux, photographiés sous différents angles et à différentes distances, y voit le plus souvent une limite de vitesse.
- **La tortue.** En 2017, une équipe du MIT imprime en 3D une tortue dont la texture a été calculée pour tromper un réseau. Sous presque tous les angles, le réseau y voit un fusil.
- **Les lunettes.** En 2016, des chercheurs montrent qu'une monture de lunettes imprimée avec un motif particulier peut empêcher un système de reconnaissance faciale (*facial recognition*) de reconnaître une personne, ou lui faire croire qu'il s'agit de quelqu'un d'autre.
- **La voix.** Des commandes vocales peuvent être cachées dans un enregistrement de musique ou de parole, sans qu'un humain les remarque, et être comprises par un assistant vocal.



La tortue imprimée en 3D, qu'un réseau prend pour un fusil sous presque tous les angles (photo : LabSix, MIT, 2017).



Illustration de l'attaque du panneau d'arrêt : quelques autocollants suffisent à tromper la machine, pas l'humain.

Se défendre

La défense la plus utilisée s'appelle l'**entraînement adverse** (*adversarial training*). On fabrique des exemples adverses pendant l'entraînement, et on les ajoute aux données avec leur bonne réponse. Le réseau apprend à ne plus se laisser tromper par ces perturbations. Il devient plus robuste, mais il reste vulnérable à des attaques plus fortes ou d'un autre type, et sa précision sur les images normales baisse souvent un peu.

Depuis 2014, de nombreuses autres défenses ont été proposées. La plupart ont été contournées, parfois quelques mois après leur publication. C'est une course entre attaques et défenses, sans solution complète à ce jour.

Le problème ne se limite pas aux images. Les grands modèles de langage ont leurs propres attaques : des formulations conçues pour leur faire ignorer leurs consignes, ou des instructions cachées dans un document qu'on leur demande de lire. Le Module 4 y reviendra.

Une boîte noire

Les exemples adverses et l'effet Hans le Malin ont une cause commune. On ne sait pas exactement ce qu'un réseau a appris.

Le contraste avec les systèmes des modules précédents est net. On pouvait lire les règles d'un système expert du Module 1 et suivre son raisonnement. On pouvait lire les questions d'un arbre de décision du Module 2. Un réseau profond compte des millions de poids, et aucun d'eux n'a de signification isolée. Il donne une réponse, souvent très bonne, sans donner ses raisons. On dit que c'est une **boîte noire** (*black box*).

L'**IA explicable** (*explainable AI*, XAI) cherche à retrouver ces raisons. Une de ses méthodes produit une **carte de saillance** (*saliency map*) : pour une image donnée, elle indique quels pixels ont le plus pesé sur la réponse. C'est ainsi que l'on découvre qu'un classifieur de loups regarde la neige, ou qu'un classifieur de radiographies s'appuie sur une marque propre à l'hôpital qui a pris l'image plutôt que sur les poumons du patient.



La carte de saillance d'un 7, calculée sur le classifieur de l'applet : en vert ce qui plaide pour « 7 », en rouge ce qui plaide pour « 2 ».

Une autre démarche consiste à ouvrir le réseau lui-même, neurone par neurone. En 2020, Chris Olah et ses collègues, alors chez OpenAI, étudient de petits groupes de neurones reliés entre eux, qu'ils appellent des **circuits** (*circuits*). Ils montrent comment des neurones qui détectent des courbes, dans différentes orientations, sont assemblés à partir de neurones qui détectent de simples contours. Ce circuit est assez bien compris pour que l'équipe en réécrive ensuite les poids à la main, et obtienne des détecteurs de courbes qui fonctionnent. Beaucoup d'autres neurones semblent cependant réagir à plusieurs choses sans rapport entre elles : l'un d'eux s'active devant des têtes de chats et devant l'avant des voitures. On les dit **polysémantiques** (*polysemantic*). Cette démarche, l'**interprétabilité mécaniste** (*mechanistic interpretability*), est reprise pour les modèles de langage au chapitre « Regarder à l'intérieur » du Module 4.

Ces méthodes donnent des indices, pas une explication complète. La question de savoir ce qu'un réseau a vraiment appris reste en grande partie ouverte. Le Module 5 reviendra sur ses conséquences : peut-on confier une décision importante, un diagnostic ou un prêt bancaire, à un système qui ne peut pas expliquer sa réponse ?

Ce que ce module a montré

Ce module est parti d'un neurone, qui n'est qu'une régression logistique. En reliant des neurones en couches, on obtient un réseau qui fabrique ses propres caractéristiques, et qui résout le XOR, le problème qui avait arrêté le perceptron en 1969. La rétropropagation permet d'entraîner ces réseaux. Avec des données et du calcul en quantité suffisante, des réseaux profonds de formes adaptées ont dépassé toutes les autres méthodes pour les images, les séquences et les jeux.

Ces réseaux ne sont pas des inventions séparées. Le perceptron multicouche, le réseau convolutif, le

réseau récurrent, le Transformer et des assemblages comme AlphaGo sont des variations sur un même thème. Ce sont les mêmes pièces, reliées autrement et entraînées par la même rétropropagation. Cette facilité à composer explique en bonne partie leur succès. Le Module 4 en tire parti à son tour, par exemple en branchant un réseau qui lit une image sur un modèle de langage.

Ce module a aussi montré leurs limites. Ces réseaux ne voient pas, ne lisent pas et ne jouent pas comme nous. Ils peuvent être trompés par des perturbations invisibles, réussir pour de mauvaises raisons, et ils n'expliquent pas leurs réponses.

Tous les réseaux de ce module **reconnaissent** et **prédisent** : ils associent une réponse à une entrée. Le Module 4 montre comment les mêmes architectures, et en particulier le Transformer, apprennent à **produire** des textes, des images et des sons.

Apprivoiser un réseau de neurones (travail noté 3)

Ce travail utilise TensorFlow Playground, une application en logiciel libre que nous avons adaptée pour ce cours. Elle entraîne sous vos yeux un petit réseau de neurones à classer des points de deux couleurs, et montre à chaque instant la frontière qu'il trace.

Lire l'application

- **À gauche**, le jeu de données. Chaque point est orange ou bleu. Le curseur « Bruit » mélange les deux groupes.
- **Au centre**, les **caractéristiques** (*features*) données au réseau. X_1 et X_2 sont les deux coordonnées d'un point, et les autres (X_1^2, X_1X_2…) sont calculées à partir d'elles. À leur droite, les **couches cachées** (*hidden layers*), qu'on ajoute ou retire avec les boutons + et −.
- **À droite**, la réponse du réseau : la couleur du fond montre la classe qu'il prédit en chaque point. La **perte** (*loss*) est l'erreur du réseau, au sens de la fonction d'erreur du Module 2. Plus elle est basse, mieux le réseau classe les points.
- **En haut**, le bouton de lecture lance l'entraînement. Le bouton de réinitialisation, la flèche circulaire, tire de nouveaux poids de départ au hasard. Le compteur indique le nombre d'**époques** (*epochs*), au sens de « Entraîner un réseau ».

Si l'application est coupée sur votre écran, ouvrez-la en pleine page.

Consignes

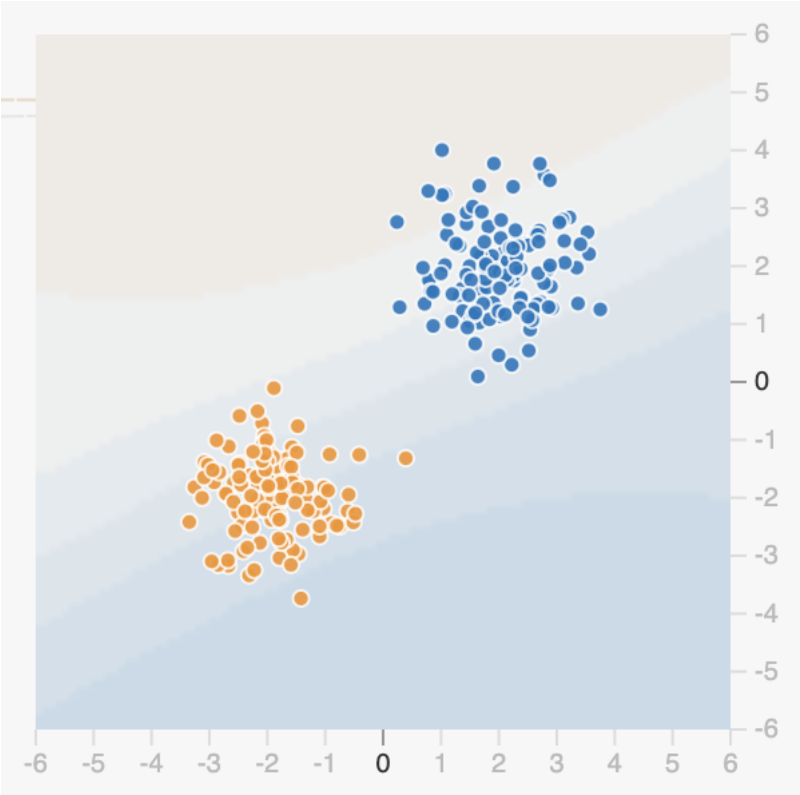
1. Faites les expériences proposées dans les questions ci-dessous, avec l'application.
2. Répondez aux questions dans un fichier PDF (**aucun autre format ne sera accepté**). Les réponses doivent être claires et précises.

Applet interactive : à utiliser en ligne, sur la page « Travail noté 3 » du site du cours.

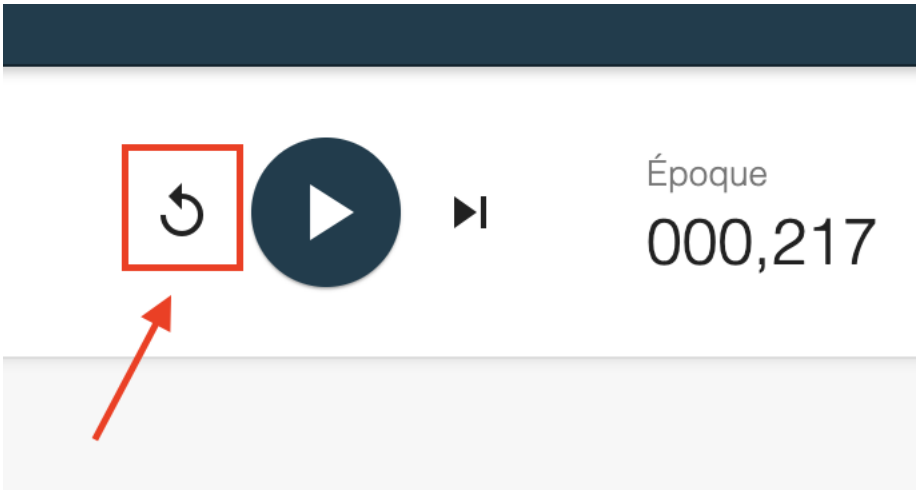
Questions

Un problème facile

1. Parmi les quatre jeux de données proposés, lequel vous semble le plus facile à classer, en séparant les points orange des points bleus, pour un algorithme d'apprentissage automatique en général, et pas seulement pour un réseau de neurones ? Expliquez pourquoi.
2. Choisissez le jeu des deux groupes de points disposés en diagonale.

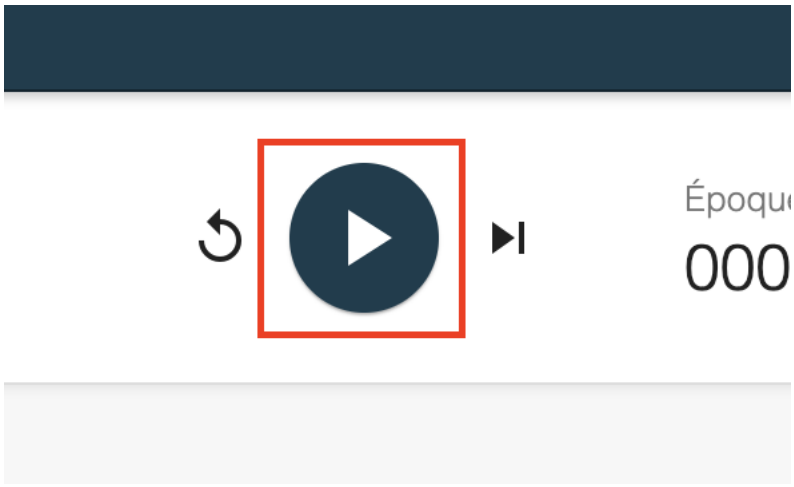


Vérifiez qu'il n'y a aucune couche cachée et que seules les caractéristiques X_1 et X_2 sont activées. Quelle est la perte d'entraînement ? Appuyez plusieurs fois sur le bouton de réinitialisation et observez comment varie cette perte initiale, avant tout entraînement.



Que signifient ces variations ? Pourquoi la perte initiale est-elle parfois haute et parfois basse, et comment le voit-on sur le graphique ? (Voir « Un réseau qui apprend le XOR ».)

3. Sans couche cachée, ce réseau ne contient qu'un seul neurone de sortie. Lancez l'entraînement avec ce bouton :

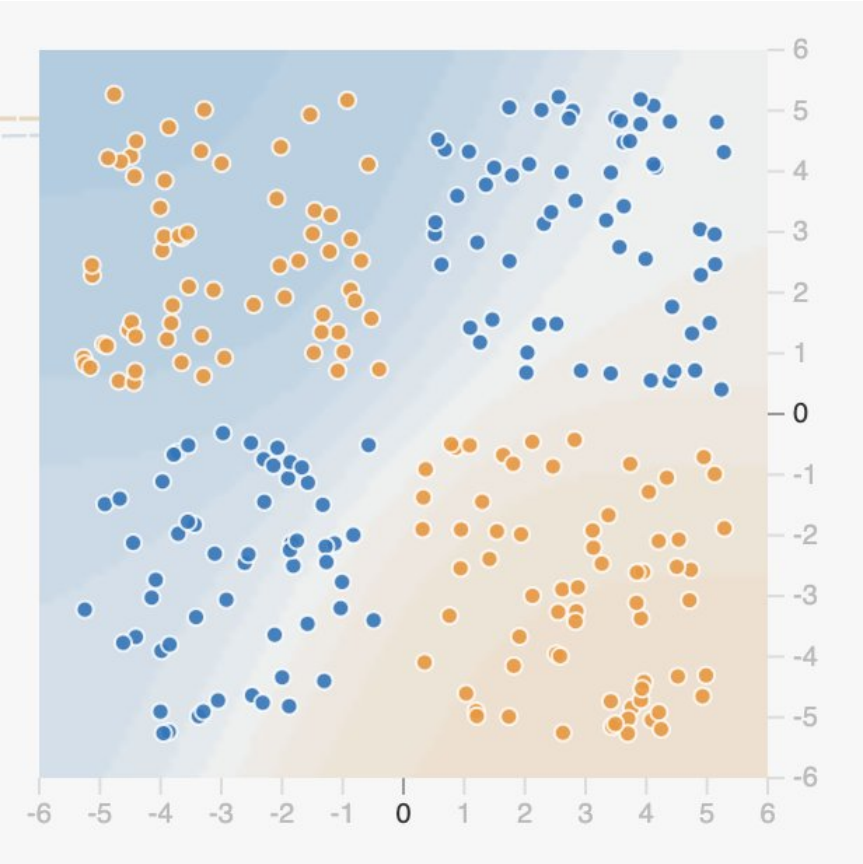


Quel modèle du Module 2 retrouve-t-on ainsi, et pourquoi ? (Voir « Un neurone est une régression logistique ».)

4. Réglez le bruit à 25, puis appuyez plusieurs fois sur « Régénérer ». Ce changement rend-il la classification plus facile ou plus difficile pour un algorithme d'apprentissage ? Expliquez pourquoi.

Le XOR

5. Remettez le bruit à 0 et choisissez le jeu du XOR, avec quatre groupes de points aux coins.

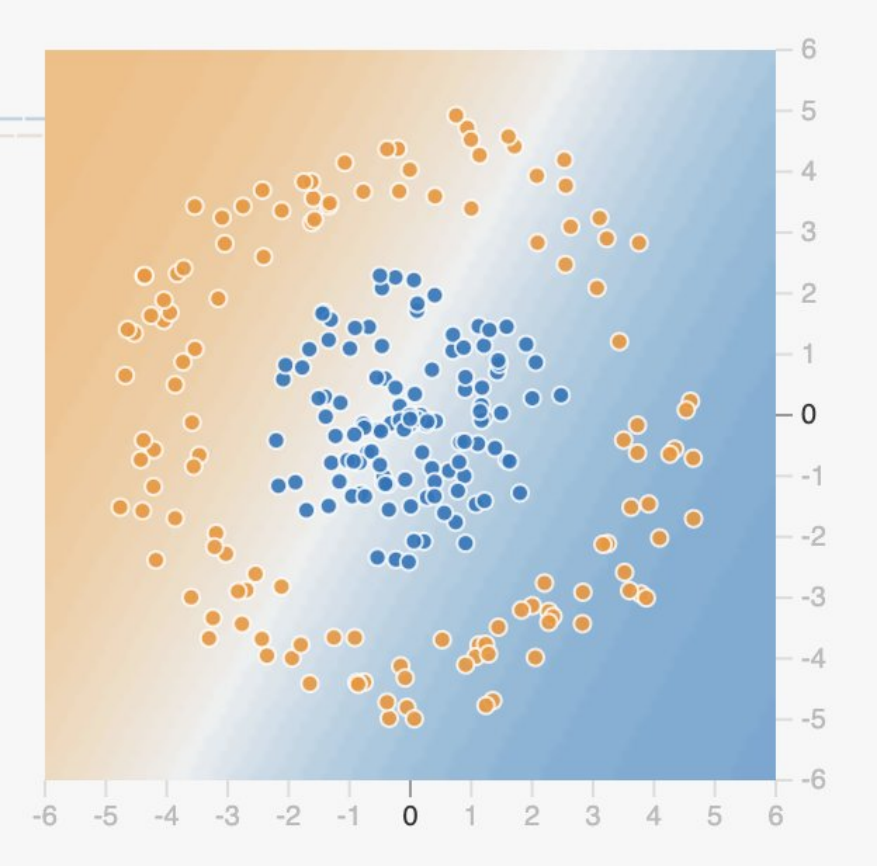


A priori, le réseau de la question précédente, sans couche cachée, peut-il classer ces points ? Expliquez pourquoi, puis faites l'essai. Que se passe-t-il ? (Voir le XOR au Module 1 et « Linéaire ou non-linéaire » au Module 2.)

6. Ajoutez une couche cachée de trois neurones, puis lancez l'entraînement. Quel est l'effet ? Comment l'expliquer ? (Voir « Une couche cachée ».)
7. Recommencez l'entraînement plusieurs fois, en appuyant sur le bouton de réinitialisation entre deux essais. Le réseau arrive-t-il toujours à la même frontière et à la même perte ? Comment l'expliquer ? (Voir « Un réseau qui apprend le XOR ».)
8. Ajoutez une deuxième couche cachée de deux neurones, et faites quelques entraînements. Qu'observez-vous par rapport à la question précédente ?
9. Retirez toutes les couches cachées, et n'activez que la caractéristique X_1X_2. Entraînez le modèle plusieurs fois. Qu'observez-vous, et comment l'expliquer ? Comparez avec la question 6 : dans chaque cas, qui a construit la caractéristique qui rend le problème séparable ? (Voir « Linéaire ou non-linéaire ».)

Le cercle

10. Choisissez le jeu du cercle, avec un groupe de points au centre entouré d'un anneau.



Sans couche cachée, et avec seulement X_1 et X_2, est-il possible de résoudre ce problème ? Pourquoi ?

11. Remplacez X_1 et X_2 par X_1^2 et X_2^2. La situation change-t-elle ? Comment l'expliquer ? Indice : pensez à l'équation d'un cercle. Quel lien faites-vous avec l'astuce du noyau du Module 2 ? Si la perte reste élevée, réinitialisez et relancez : il arrive que l'entraînement parte dans une mauvaise direction.
12. Revenez à X_1 et X_2 seulement. Peut-on réduire la perte en ajoutant des couches cachées ? Comparez avec la question précédente.

Entraîner trop longtemps

L'application ci-dessous est réglée autrement. Le jeu des deux groupes est très bruité, seuls 20 % des points servent à l'entraînement, et le réseau compte trois couches cachées de huit neurones. Les autres points forment le **jeu de test** (*test set*). Ils sont affichés avec un contour, et leur perte, la « perte de test », est indiquée au-dessus de la perte d'entraînement. Ne modifiez pas le ratio des données d'entraînement.

Applet interactive : à utiliser en ligne, sur la page « Travail noté 3 » du site du cours.

13. Lancez l'entraînement et laissez-le tourner longtemps, plusieurs milliers d'époques. Observez les deux pertes et la frontière. Que se passe-t-il ? Quel nom donne-t-on à ce phénomène ? Comment pourrait-on l'éviter ? (Voir « Généraliser » et « L'entraînement en pratique ».)

Module 4 — IA générative et grands modèles de langage

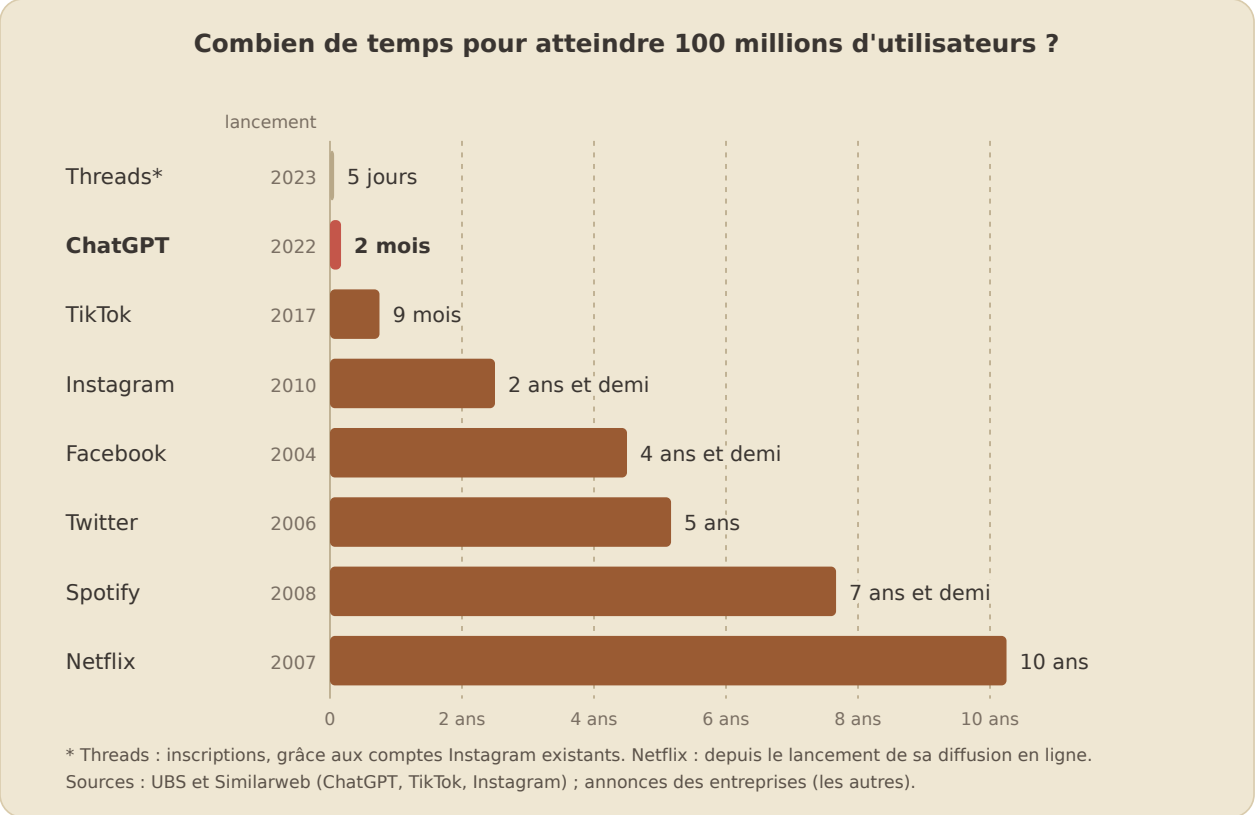


Portrait d'Edmond de Belamy (2018), produit par un réseau générateur du collectif Obvious, et vendu 432 500 $ chez Christie's. Il est signé de la formule mathématique qui a servi à l'entraîner. Wikimedia Commons, domaine public.

Reconnaître, puis produire

Les réseaux du Module 3 **reconnaissent**. On leur donne une image, et ils répondent « 7 » ou « panda ». On leur donne une phrase, et ils proposent sa traduction. Depuis une dizaine d'années, les mêmes architectures apprennent aussi à **produire** : des visages de personnes qui n'existent pas, des images à partir d'une phrase, des voix, de la musique, des vidéos, et surtout du texte.

Le 30 novembre 2022, OpenAI ouvre au public ChatGPT. En deux mois, le service compte 100 millions d'utilisateurs. Pour beaucoup de gens, c'est la première fois qu'une machine semble comprendre ce qu'on lui dit, et répondre comme le ferait une personne. L'expression **IA générative** (*generative AI*) se répand alors pour désigner l'ensemble de ces systèmes, et les **grands modèles de langage** (*large language models*, LLM) comme celui de ChatGPT en deviennent la figure centrale.



ChatGPT a atteint 100 millions d'utilisateurs plus vite que tous les grands services en ligne avant lui. Seul Threads, adossé aux comptes Instagram, a fait mieux depuis. Sources : UBS et Similarweb, annonces des entreprises.

Ce module explique comment ces systèmes fonctionnent, ce qu'ils permettent, et ce qui leur échappe.

Une seule grande idée : imiter une distribution

Le chapitre « Classer » du Module 2 distinguait deux façons de construire un modèle. Un modèle **discriminatif** trace une frontière entre des classes. Un modèle **génératif** décrit chaque classe, assez précisément pour pouvoir, en principe, en produire de nouveaux exemples.

L'IA générative, c'est ce « en principe » devenu réalité. Un modèle génératif apprend comment se répartissent les données, leur **distribution**, puis il tire au hasard de nouveaux exemples qui se répartissent de la même façon. Un générateur d'images a appris la distribution des photos. Un grand modèle de langage a appris celle des textes écrits par des humains : il donne, pour chaque début de texte, la probabilité de chaque mot qui pourrait suivre, et il écrit en tirant ces mots un par un.

Le mécanisme est d'une simplicité déconcertante. Rien, dans cette description, ne parle de comprendre une question, de raisonner ou de vérifier une réponse. Il est pourtant difficile d'imaginer comment, en répétant cette seule opération, un mot après l'autre, on obtient les réponses de ChatGPT : expliquer une notion, écrire un programme, résumer un article ou traduire un poème. Ce contraste est l'une des grandes surprises de l'IA récente, et il traverse tout ce module. Il revient dans « Ce que la prédiction exige », puis dans « Ce que les LLM comprennent, et ce qu'ils ratent », qui se demande ce que ces modèles comprennent vraiment.

Pour le reste, rien ne change par rapport aux modules précédents. Ces modèles sont des réseaux de neurones, entraînés par descente de gradient, et leur architecture la plus importante est le Transformer présenté au Module 3. Ce qui a changé, c'est l'échelle : des milliards de paramètres, entraînés sur une grande partie du texte et des images disponibles sur le Web.

Ce que ce module n'est pas

Trois précisions évitent des malentendus fréquents.

- **Ce module demande peu de mathématiques.** Les quelques formules sont expliquées en mots, et les plus techniques sont placées dans des encadrés que l'on peut sauter. Les mécanismes sont surtout expliqués par des figures et des applets, dont plusieurs utilisent de vrais modèles : un autoencodeur, un modèle de diffusion, de vrais plongements de mots, le découpage en jetons de GPT-4o, et CLIP.
- **Ce module explique, il ne tranche pas les grands débats.** La question de savoir si ces modèles comprennent est posée au dernier chapitre, avec les arguments des deux côtés. Les questions de société, comme le droit d'auteur, l'emploi, l'environnement ou la désinformation, sont signalées au passage et traitées au Module 5.
- **Ce module n'est pas un mode d'emploi.** Il présente quelques principes pour formuler des requêtes, mais son but est de comprendre ce que font ces systèmes, pour mieux juger ce qu'ils produisent.

Le parcours du module

Le module compte trois parties : l'IA générative en général, puis les grands modèles de langage, puis la rencontre du texte et de l'image, qui se termine par un regard à l'intérieur des modèles et un bilan de ce qu'ils comprennent et de ce qu'ils ratent.

L'IA générative

1. *Générer : imiter une distribution* : la distribution, le tirage, la température, et l'espace latent d'un autoencodeur.
2. *Quatre façons de générer* : les GAN, les autoencodeurs variationnels, la diffusion et les modèles autorégressifs.
3. *Des images, des voix, des vidéos* : dix ans de génération, des protéines à la météo, et les hypertrucages (*deepfakes*).

Les grands modèles de langage

4. *Des règles aux probabilités* : soixante-dix ans de traitement de la langue, les n-grammes, le lissage et la perplexité.
5. *Les outils statistiques* (approfondissement) : les modèles de Markov cachés, la traduction statistique, les vecteurs de documents.
6. *Des mots aux nombres : jetons et plongements* : découper un texte, et représenter le sens des mots par des vecteurs.
7. *Prédire le mot suivant* : du modèle neuronal de 2003 au Transformer, le préentraînement, GPT, la fenêtre de contexte, ce que la prédiction exige, et ce qui reste des idées classiques.
8. *Passer à l'échelle* : les lois d'échelle, l'apprentissage dans le contexte, les coûts, les modèles ouverts.

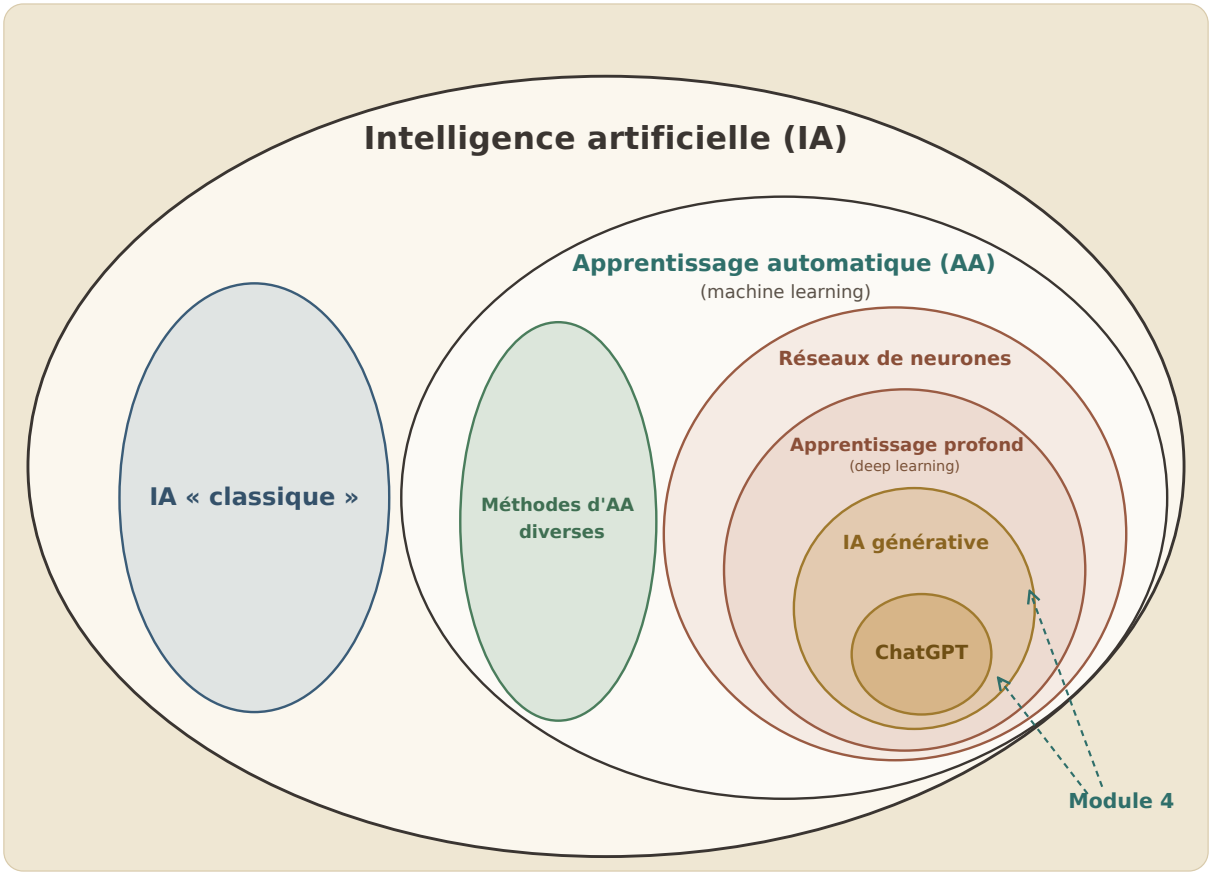
9. *Du modèle à l'assistant* : l'ajustement, le renforcement à partir de préférences humaines, et les modèles qui raisonnent.
10. *Des outils, un harnais et des agents* : la conversation qui n'en est pas une, le harnais qui entoure le modèle, la recherche augmentée, l'appel d'outils, les agents et leurs risques.
11. *Programmer avec des agents* : la boucle d'un agent de programmation, la culture des outils Unix, SWE-bench, les risques et le métier qui change.
12. *Démontrer* (approfondissement) : les assistants de preuve, des Olympiades aux premiers résultats de recherche, et leurs limites.
13. *Le défi ARC* (approfondissement) : mesurer l'intelligence par des tâches nouvelles, de 2019 à ARC-AGI-3.

Le texte et l'image, l'intérieur des modèles, et le bilan

14. *Relier les mots et les images* : CLIP, la classification sans exemple, et la génération d'images à partir d'une phrase.
15. *Des modèles qui voient, entendent et parlent* : les modèles multimodaux, la lecture du texte dans les images (OCR) et la conversation à voix haute.
16. *Regarder à l'intérieur* : l'interprétabilité mécaniste, la superposition, les caractéristiques, les circuits, et les travaux de 2026 sur les émotions et l'espace de travail global.
17. *Ce que les LLM comprennent, et ce qu'ils ratent* : hallucinations, perroquets ou modèles du monde, et le bilan du module.

Le module compte quatorze applets, dont un espace latent à explorer, un modèle de diffusion qui redessine une feuille d'érable, un test pour distinguer une vraie photo d'un visage généré, un générateur de texte entraîné sur Jules Verne, un étiqueteur grammatical à modèle de Markov caché, un rôle d'évaluateur humain pour comprendre comment on entraîne un assistant, un agent de programmation à suivre pas à pas, des tâches du défi ARC à résoudre soi-même, et un petit réseau qui range plus de concepts que de neurones.

Pour situer ce module dans l'ensemble du cours : l'IA générative repose sur l'apprentissage profond du Module 3, lui-même une famille de méthodes d'apprentissage automatique.



La carte de l'IA : le Module 4 porte sur l'IA générative et les grands modèles de langage.

Objectifs

Au terme de ce module, vous devriez être en mesure de :

- expliquer la différence entre un modèle qui reconnaît et un modèle qui génère, et ce que signifie tirer des exemples dans une distribution ;
- décrire le principe des quatre grandes familles de modèles génératifs : GAN, autoencodeurs variationnels, diffusion et modèles autorégressifs ;
- retracer l'histoire du traitement de la langue, des règles aux n-grammes, et expliquer le lissage, la perplexité et les principaux outils statistiques ;
- expliquer comment un texte est découpé en jetons, et comment des plongements représentent le sens des mots ;
- expliquer ce qu'est un modèle de langage, et comment un Transformer génère un texte jeton après jeton ;
- expliquer pourquoi la taille des modèles a tant compté, et ce que sont les lois d'échelle et l'apprentissage dans le contexte ;
- décrire les étapes qui transforment un modèle de base en assistant, et le rôle du travail humain dans ces étapes ;
- expliquer comment raisonnent les modèles entraînés par des récompenses vérifiables, et ce qu'apporte une preuve vérifiée par une machine ;
- expliquer ce qu'apportent les outils et les agents, et les risques qu'ils posent ;

- décrire le fonctionnement d'un agent de programmation ;
- expliquer comment des modèles relient les textes, les images et les sons ;
- expliquer comment on tente de mesurer l'intelligence avec des tests comme ARC ;
- expliquer ce que cherche l'interprétabilité mécaniste, et ce que sont la superposition, les caractéristiques et les circuits ;
- identifier les principales limites de ces modèles, comme les hallucinations, et présenter les arguments du débat sur leur compréhension.

Durée

Quatre semaines, soit environ 36 heures. Trois chapitres, marqués « approfondissement » dans le parcours, sont facultatifs : *Les outils statistiques*, *Démontrer* et *Le défi ARC*. La suite du module et le travail noté ne les supposent pas.

Évaluation

Un travail noté (20 % de la note finale) où vous construirez un modèle de langage miniature dans Google Sheets, puis l'utiliserez pour générer du texte, avec des questions d'interprétation.

Générer : imiter une distribution



Ces quatre visages ont été produits par un réseau de neurones. Aucune de ces personnes n'existe (*StyleGAN, 2019, et StyleGAN2, 2020 ; Wikimedia Commons, domaine public*).

Les quatre visages ci-dessus ont l'air de photos. Pourtant, aucune de ces personnes n'existe. Chaque image a été produite par un réseau de neurones, StyleGAN, présenté en 2019 par des chercheurs de l'entreprise Nvidia. Le site *This Person Does Not Exist* (« cette personne n'existe pas ») en affiche un nouveau à chaque visite.

Tous les réseaux du Module 3 **reconnaissent**. On leur donne une image, et ils répondent « 7 » ou « panda ». On leur donne une phrase, et ils proposent sa traduction. Le réseau qui a produit ces visages fait l'inverse : il ne reçoit aucune image, et il en **produit** une. C'est ce qu'on appelle l'**IA générative** (*generative AI*). Elle produit aujourd'hui des images, des textes, des voix, de la musique, des vidéos et du code informatique.

Ce chapitre présente l'idée commune à tous ces systèmes. Un modèle génératif apprend comment les données se répartissent, puis il tire au hasard de nouveaux exemples qui se répartissent de la même façon.

Décrire plutôt que séparer

Le chapitre « Classer » du Module 2 a présenté deux façons de construire un classificateur.

- Une approche **discriminative** (*discriminative*) trace directement la frontière entre les classes. C'est le cas de la régression logistique. Elle répond à la question « de quel côté de la frontière ce point se trouve-t-il ? ».

- Une approche **générative** (*generative*) commence par décrire chaque classe, par exemple à quoi ressemble un pourriel typique. Pour classer un nouvel exemple, elle se demande à quelle description il ressemble le plus. C'est le cas de la classification bayésienne naïve.

Le Module 2 remarquait qu'une description assez précise d'une classe permettrait, en principe, d'en produire de nouveaux membres. C'est de là que vient le mot *génératif*. Avec Bayes naïf, cette possibilité restait théorique : sa description d'un pourriel est une liste de mots fréquents, prise mot par mot, et les « pourriels » qu'on en tirerait seraient des suites de mots sans aucun sens. L'IA générative actuelle repose sur la même idée, avec des descriptions beaucoup plus riches. Un grand modèle de langage (*large language model*, LLM), comme celui de ChatGPT, est une description très détaillée de la classe « texte écrit par des humains ». Un générateur d'images comme StyleGAN est une description très détaillée de la classe « photo de visage ».

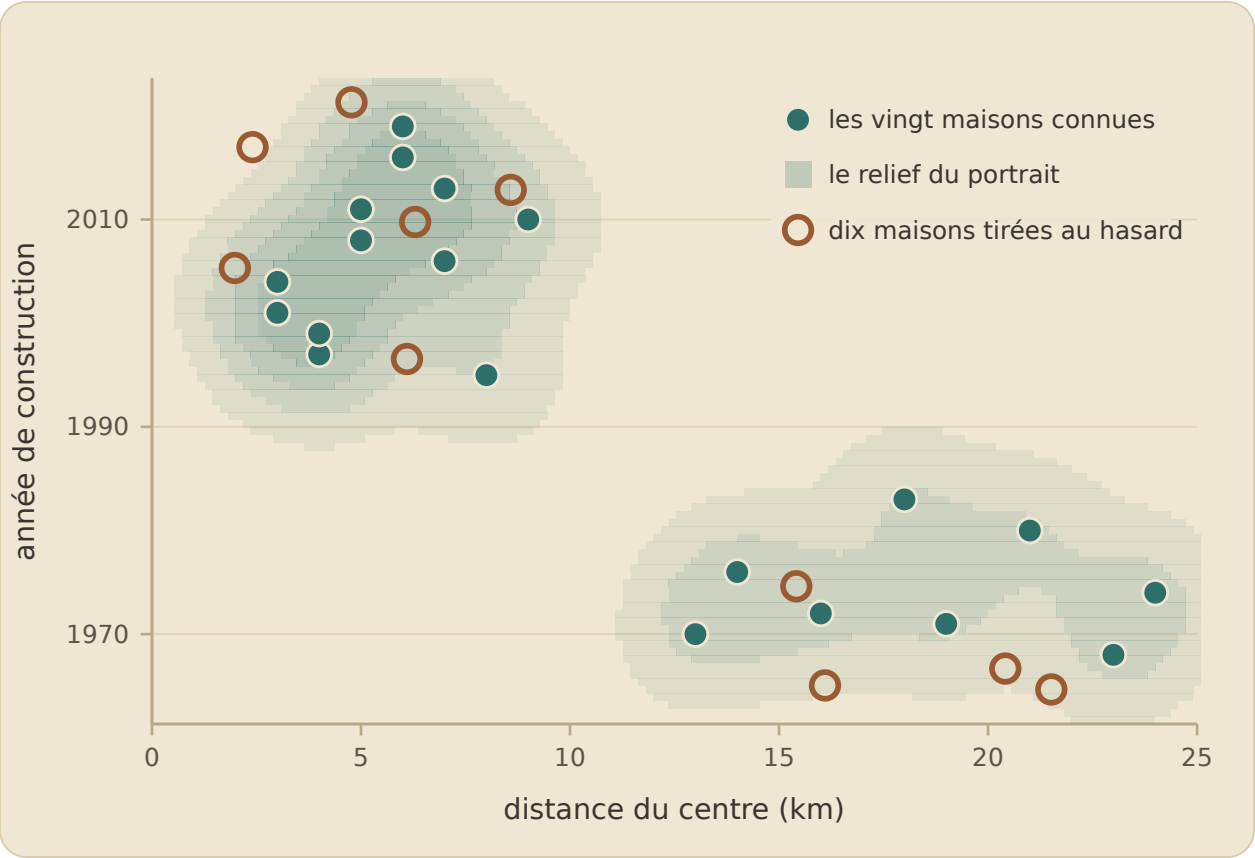
Une distribution, et tirer dedans

Ce que le modèle décrit s'appelle une **distribution** (*distribution*) : la façon dont les exemples se répartissent entre toutes les valeurs possibles, avec leur probabilité.

Un exemple simple est celui des lettres dans un texte en français. Le *e* y est la lettre la plus fréquente, environ une lettre sur sept. Le *s*, le *a* et le *i* suivent, chacun autour d'une lettre sur treize. Le *w* et le *k* sont très rares. La liste de ces fréquences est la distribution des lettres en français.

Une fois cette distribution connue, on peut produire des lettres nouvelles en les tirant au hasard, à condition de respecter les fréquences : le *e* doit sortir souvent et le *k* presque jamais. Tirer des exemples au hasard en respectant une distribution s'appelle **échantillonner** (*to sample*). C'est l'opération de base de tous les modèles génératifs. Les lettres obtenues ne forment pas des mots, parce que cette distribution ne dit rien de l'ordre des lettres. Elle ne décrit qu'une seule chose, leur fréquence.

Le même principe s'applique à des données à plusieurs dimensions. La figure ci-dessous reprend les vingt maisons du Module 2, dans le plan de la distance au centre et de l'année de construction. Elles forment deux amas : des maisons récentes et proches du centre, et des maisons anciennes et éloignées. Pour décrire leur distribution, on place une petite cloche autour de chaque maison, puis on les additionne. On obtient un **relief** (une densité de probabilité, *probability density*), haut là où les maisons sont nombreuses, et plat là où il n'y en a aucune. On tire ensuite de nouvelles maisons dans ce relief, en choisissant une maison au hasard et en la déplaçant un peu, au hasard, selon sa cloche.



Le relief décrit la distribution des vingt maisons. Les dix maisons tirées dans ce relief tombent là où se trouvent les vraies, sans en copier aucune.

Les maisons tirées sont **plausibles**. Elles tombent là où se trouvent les vraies maisons, et presque jamais dans le vide entre les deux amas. Elles sont aussi **nouvelles**, car aucune n'est la copie d'une maison existante. Ce sont les deux qualités qu'on attend de tout modèle génératif, qu'il produise des maisons, des visages ou des phrases.

La température

Pour une même distribution, un réglage modifie la façon de tirer. On l'appelle la **température** (*temperature*), par analogie avec la physique, où une température élevée rend le mouvement des particules plus désordonné.

- À **basse température**, on accentue les écarts entre les probabilités. Le choix le plus probable l'emporte presque toujours. Le résultat est sûr, mais répétitif.
- À **température 1**, on tire selon la distribution telle quelle.
- À **haute température**, on réduit les écarts. Les choix rares sortent plus souvent. Le résultat est plus varié, puis devient incohérent si on monte trop.



La même distribution des lettres, tirée à trois températures. Chaque rangée a sa propre échelle verticale, pour comparer la forme des distributions.

La température est un réglage des modèles génératifs actuels. Dans un modèle de langage, une température basse donne des réponses prévisibles, qui conviennent à une question factuelle. Une température plus haute donne des textes plus variés, qui conviennent mieux à un poème ou à une liste d'idées. Ce réglage revient avec de vrais textes dans l'applet du générateur entraîné sur Jules Verne, au chapitre « Des règles aux probabilités ».

Le vrai problème : les grandes dimensions

Pour des lettres ou pour des maisons décrites par deux nombres, il suffit de compter et d'additionner des cloches. Pour des images, ce n'est plus possible.

Une image de chiffre manuscrit de la base MNIST, utilisée tout au long du Module 3, compte $28 \times 28 = 784$ pixels. C'est un point dans un espace de 784 dimensions, une par pixel. Si l'on tire chaque pixel au hasard, on obtient un point de cet espace, mais ce n'est jamais un chiffre : c'est de la neige. On pourrait tirer des milliards d'images de cette façon sans jamais obtenir un 7.



Deux points du même espace de 784 dimensions. Presque tous les points de cet espace ressemblent à celui de gauche.

Les vraies images de chiffres occupent donc une portion infime de cet espace. C'est une conséquence de la malédiction de la dimension (*curse of dimensionality*), présentée au Module 2. Dans un espace de très grande dimension, presque tout est vide. La méthode des cloches ne fonctionne plus non plus : avec 60 000 chiffres dans un espace aussi vaste, chaque cloche resterait isolée, et le relief serait nul partout sauf tout près des exemples connus. Le modèle ne pourrait que les recopier.

La variété des vraies images

Les vraies images ne sont pas éparpillées au hasard dans cette portion infime. Un 7 légèrement modifié, un peu incliné, d'un trait plus épais ou avec une barre plus longue, reste un 7 tout aussi plausible. On peut continuer ainsi, par petits pas, sans jamais sortir des vrais chiffres. Les façons dont un chiffre peut varier sont peu nombreuses, quelques dizaines tout au plus, alors que l'espace des pixels compte 784 dimensions.

Les vraies images se trouvent donc près d'une surface de peu de dimensions, repliée sur elle-même dans l'immense espace des pixels. On l'appelle une **variété** (*manifold*). Une feuille de papier froissée au milieu d'une pièce en donne une image. La pièce a trois dimensions, la feuille n'en a que deux, et chaque point de la feuille peut être repéré par deux nombres, même si elle est toute chiffonnée. L'idée que les données réelles, images, sons ou textes, se trouvent près d'une telle variété s'appelle l'**hypothèse de la variété** (*manifold hypothesis*). Elle n'est pas démontrée, mais elle explique pourquoi l'apprentissage reste possible dans des espaces aussi vastes.

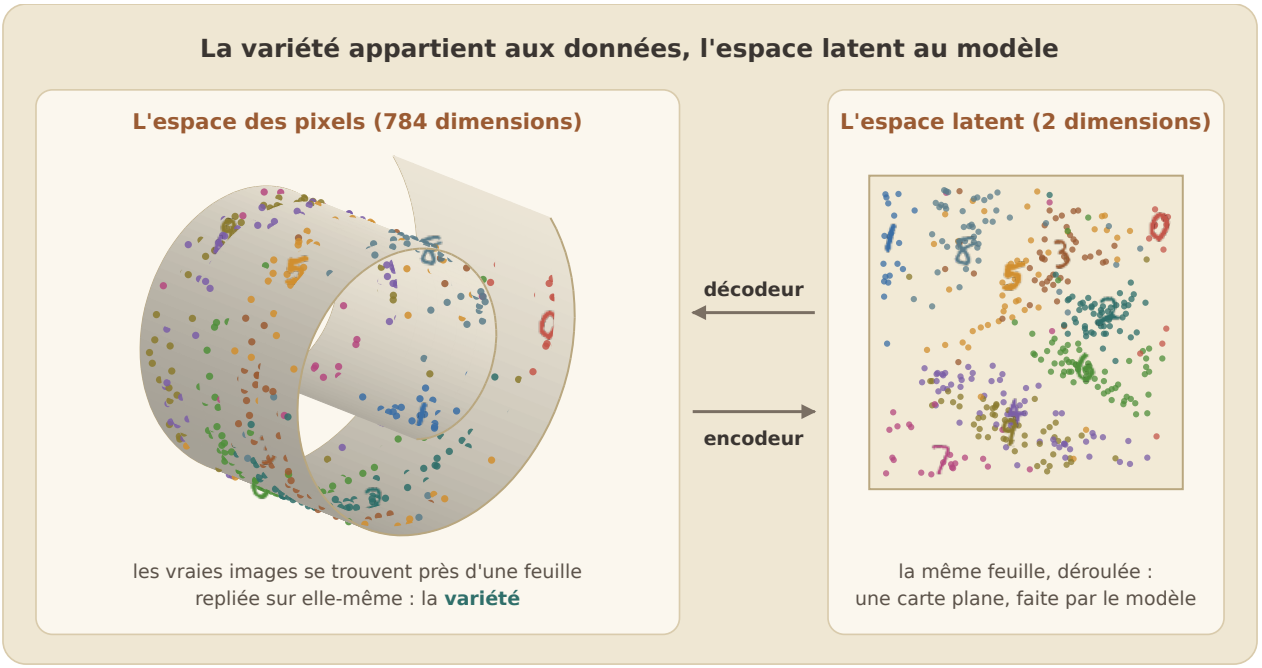
La difficulté de l'IA générative se précise alors. Il faut trouver cette variété dans l'espace immense des pixels, et apprendre sa forme.

L'espace latent

Le chapitre « L'apprentissage profond » du Module 3 a présenté l'**autoencodeur**. C'est un réseau en forme de sablier, qui réduit une image à quelques nombres (l'**encodeur**), puis la reconstruit à partir de ces nombres (le **décodeur**). Ces quelques nombres forment la **représentation latente** de l'image, et l'ensemble des valeurs qu'ils peuvent prendre s'appelle l'**espace latent** (*latent space*). C'est une réduction de dimension, au sens du Module 2, faite par un réseau de neurones.

Le décodeur fournit une solution au problème des grandes dimensions. Au lieu de tirer 784 pixels au hasard, on tire quelques nombres dans l'espace latent, et le décodeur les transforme en image. Comme il a appris à reconstruire de vrais chiffres, ce qu'il produit ressemble à un chiffre. Générer revient à choisir un point dans un petit espace bien organisé, plutôt que dans l'immense espace des pixels.

La variété et l'espace latent ne sont pas la même chose. La variété appartient aux données : c'est la feuille froissée que forment les vraies images dans l'espace des pixels. L'espace latent appartient au modèle : c'est une carte plane que le modèle construit pour repérer les points de cette feuille. Le décodeur passe de la carte à la feuille, et l'encodeur fait le chemin inverse. Comme une carte du monde, qui étale à plat la surface de la Terre, un espace latent n'est qu'une carte parmi d'autres. Deux autoencodeurs entraînés sur les mêmes chiffres dessinent deux cartes différentes de la même variété.



La variété est la forme que prennent les vraies images dans l'espace des pixels, ici dessinée comme une feuille enroulée en trois dimensions. L'espace latent est la carte plane de cette feuille, construite par le modèle. Les points sont de vrais chiffres, placés selon la carte de l'applet ci-dessous.

L'applet ci-dessous contient le décodeur d'un autoencodeur entraîné sur les 60 000 chiffres de MNIST. Son espace latent n'a que **deux** dimensions, ce qui permet de le dessiner comme une carte. Les petits points colorés sont de vrais chiffres, placés à l'endroit où l'encodeur les range. Ranger une image, pour l'encodeur, c'est calculer ses coordonnées sur la carte : il reçoit les 784 pixels et en tire deux

nombres. Personne ne choisit ces places. Elles découlent des poids de l'encodeur, ajustés pendant l'entraînement pour que le décodeur puisse reconstruire l'image à partir de ces deux nombres. Chaque chiffre occupe sa propre région, sans que personne n'ait indiqué au réseau quel chiffre était quel chiffre : il n'a vu aucune étiquette.

Applet interactive : à utiliser en ligne, sur la page « Générer : imiter une distribution » du site du cours.

Quelques manipulations à faire :

1. Promenez la souris au centre de la région d'un chiffre, puis vers ses bords. Le chiffre change d'inclinaison et d'épaisseur. Le réseau a appris à ranger ces variations le long de la carte.
2. Placez la souris entre deux régions. Le décodeur produit une forme intermédiaire, un chiffre qui hésite entre les deux.
3. Cliquez dans la région des 7, puis dans celle des 0. La bande sous l'image montre le chemin entre les deux points, et le passage progressif d'un chiffre à l'autre.
4. Cliquez plusieurs fois sur « Tirer un point au hasard ». C'est la génération proprement dite : un point est tiré au hasard dans l'espace latent, et le décodeur en fait un chiffre que personne n'a jamais écrit.

Un autoencodeur ordinaire, comme celui du Module 3, range ses images n'importe où dans son espace latent. Certains chiffres s'entassent, d'autres s'étalent très loin, et de grandes zones restent vides. On ne sait donc pas où tirer un point au hasard pour obtenir des chiffres variés. Le réseau de l'applet est un autoencodeur **variationnel** (*variational autoencoder*, VAE). Il est entraîné pour ranger ses images autour du centre de la carte, sans laisser de trous, de sorte qu'un point tiré au hasard près du centre donne presque toujours un chiffre. Le chapitre suivant explique comment.

Cette carte n'a que deux dimensions, ce qui limite la qualité des chiffres produits : beaucoup sont flous. Les modèles qui ont produit les visages du début de ce chapitre utilisent un espace latent de 512 dimensions. Le principe est le même.

Générer n'est pas recopier

Un modèle génératif utile produit des exemples **nouveaux**. Un modèle qui ne ferait que restituer ses exemples d'entraînement serait une simple base de données. C'est la forme que prend, pour un modèle génératif, le sur-apprentissage (*overfitting*) présenté au chapitre « Généraliser » du Module 2. Un modèle qui colle trop à ses données d'entraînement ne fait que les recopier.

La frontière n'est pas toujours nette. Des chercheurs ont montré que certains générateurs d'images peuvent restituer, presque à l'identique, des images de leurs données d'entraînement, et que des modèles de langage peuvent réciter des passages entiers de textes qu'ils ont lus. Le Module 2 posait déjà la question à propos des grands modèles de langage : où finit la mémoire, et où commence la compréhension ? Pour les modèles génératifs, elle a aussi une dimension juridique, puisque ces modèles sont entraînés sur des œuvres protégées par le droit d'auteur. Le Module 5 revient sur cette question.

Vers des modèles plus puissants

Ce chapitre a présenté l'idée commune à tous les modèles génératifs : apprendre une distribution, puis y tirer de nouveaux exemples. Il a aussi présenté un premier moyen d'y parvenir pour des images, l'espace latent d'un autoencodeur.

Les visages du début du chapitre ont été produits par une autre méthode. Il en existe quatre grandes familles, qui ont chacune marqué l'histoire du domaine : les réseaux antagonistes génératifs, les autoencodeurs variationnels, les modèles de diffusion et les modèles qui génèrent élément par élément. Les grands modèles de langage appartiennent à cette dernière famille. Le chapitre suivant présente les quatre.

Quatre façons de générer

Le chapitre « Générer : imiter une distribution » a posé le problème. Un modèle génératif doit apprendre la distribution de données très complexes, comme des photos de visages, puis y tirer de nouveaux exemples. Pour des images, cette distribution occupe une portion infime d'un espace immense, et on ne peut pas la décrire en additionnant des cloches.

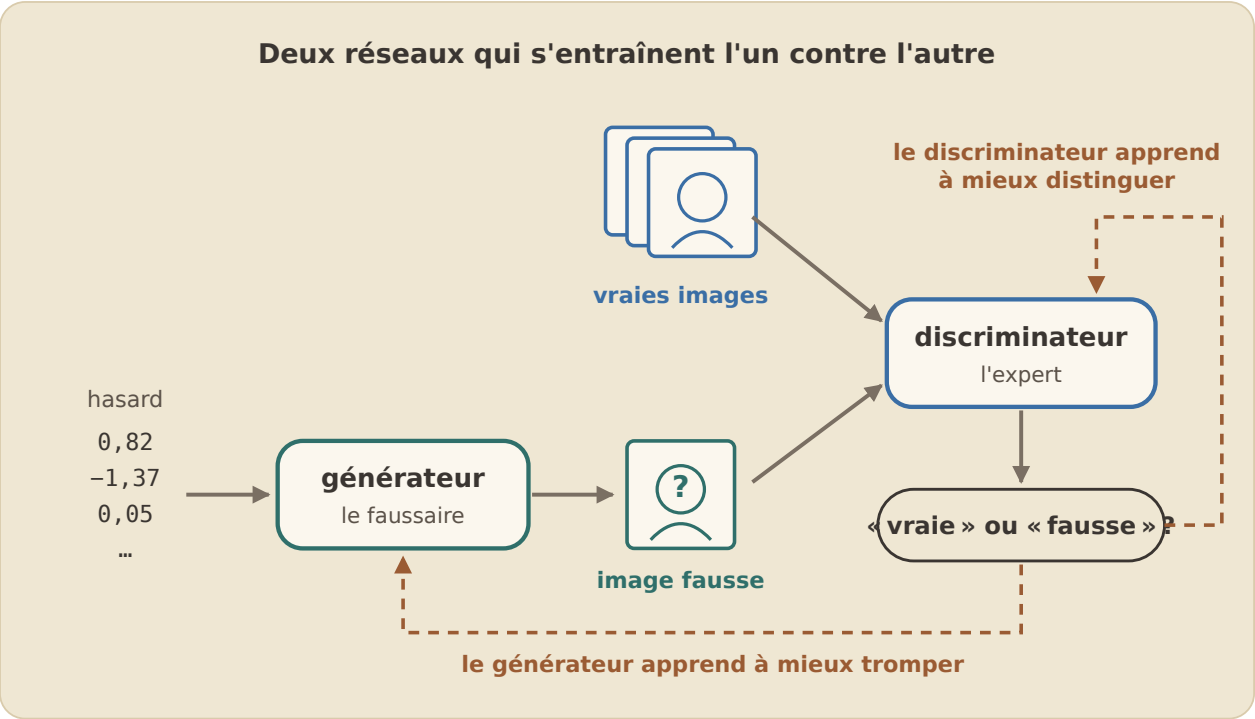
Depuis le début des années 2010, quatre familles de méthodes ont été proposées pour résoudre ce problème. Chacune repose sur une idée différente, et chacune a produit des systèmes marquants. Ce chapitre les présente l'une après l'autre, avec leurs forces et leurs limites. Les quatre utilisent des réseaux de neurones, et toutes s'entraînent par rétropropagation, comme les réseaux du Module 3.

Le faussaire et l'expert : les réseaux antagonistes génératifs

En 2014, Ian Goodfellow, alors doctorant à l'Université de Montréal dans le laboratoire de Yoshua Bengio, propose une idée nouvelle avec ses collègues, les **réseaux antagonistes génératifs** (*generative adversarial networks*, GAN). Elle est issue de l'école canadienne de l'apprentissage profond présentée au Module 3.

Un GAN fait travailler deux réseaux l'un contre l'autre.

- Le **générateur** joue le rôle d'un faussaire. Il reçoit quelques nombres tirés au hasard, et il en fait une image.
- Le **discriminateur** joue le rôle d'un expert. Il reçoit une image, tantôt une vraie, tantôt une fausse produite par le générateur, et il doit dire laquelle c'est.



Un réseau antagoniste génératif. Les deux réseaux s'entraînent ensemble, chacun à partir des erreurs de l'autre.

Les deux réseaux s'entraînent ensemble. Chaque fois que l'expert se trompe, il ajuste ses poids pour mieux distinguer les vraies images des fausses. Chaque fois que l'expert démasque une fausse image, le faussaire ajuste ses poids pour que ses prochaines images trompent mieux l'expert. Au fil de l'entraînement, l'expert devient plus exigeant, et le faussaire doit produire des images de plus en plus réalistes pour le tromper. À la fin, on garde le faussaire.

Cette mise en scène vient de la **théorie des jeux** (*game theory*), fondée par John von Neumann entre la fin des années 1920 et les années 1940, qui étudie les situations où des joueurs ont des intérêts opposés. L'article de 2014 décrit l'entraînement d'un GAN comme un jeu à deux joueurs à **somme nulle** (*zero-sum game*) : ce que l'un gagne, l'autre le perd. L'expert cherche à maximiser ses bonnes réponses, et le faussaire cherche à les minimiser. C'est le principe du minimax des programmes d'échecs du Module 1, appliqué à des poids qu'on ajuste plutôt qu'à des coups qu'on explore. La formule qui signe le *Portrait d'Edmond de Belamy*, à l'accueil de ce module, est celle de ce jeu : on y lit « min » sous G, le générateur, et « max » sous D, le discriminateur.

Ce jeu a une issue idéale, un **équilibre de Nash** (*Nash equilibrium*), du nom du mathématicien John Nash. C'est une situation où aucun joueur ne peut améliorer son sort en changeant seul de stratégie. Pour un GAN, l'équilibre est atteint quand le faussaire imite parfaitement la distribution des vraies images. L'expert ne peut alors faire mieux que répondre au hasard, et il se trompe une fois sur deux.

Le discriminateur est un classificateur **discriminatif**, au sens du chapitre « Classer » du Module 2. Il trace une frontière entre les vraies images et les fausses. Un GAN utilise donc un modèle discriminatif pour entraîner un modèle génératif.

Les GAN ont dominé la génération d'images pendant plusieurs années, des visages flous de 2014 aux visages photoréalistes de StyleGAN en 2019, une progression que retrace le chapitre « Des images, des voix, des vidéos ». Ils ont cependant deux défauts.

- Leur entraînement est **instable**. Les deux réseaux doivent progresser au même rythme. Si l'expert devient trop fort trop vite, le faussaire ne reçoit plus d'indication utile et cesse de progresser. Chercher l'équilibre d'un jeu est plus délicat que descendre une pente : chaque pas de l'un des joueurs change le relief sur lequel l'autre avance.
- Le faussaire peut se contenter de produire **quelques images** qui trompent bien l'expert, plutôt que toute la diversité des données. Un GAN entraîné sur des chiffres peut ainsi ne produire que des 1 et des 7. Ce défaut s'appelle l'**effondrement des modes** (*mode collapse*).

Remplir l'espace latent : les autoencodeurs variationnels

L'applet du chapitre précédent utilise un **autoencodeur variationnel** (*variational autoencoder*, VAE), proposé en 2013 par Diederik Kingma et Max Welling, à l'Université d'Amsterdam. Comme l'autoencodeur du Module 3, c'est un réseau en sablier, avec un encodeur et un décodeur.

À quoi sert l'espace latent. Le chapitre « Générer : imiter une distribution » a présenté l'espace latent : l'encodeur réduit une image, 784 nombres pour un chiffre manuscrit, à un point d'une carte de **quelques dimensions**, deux dans l'applet, et le décodeur fait l'inverse, d'un point de la carte à une image. Pour **générer**, on se passe de l'encodeur, on choisit un point au hasard sur la carte, et le décodeur en fait une image nouvelle. Toute la question est de savoir où tirer ce point.

Le problème de l'autoencodeur ordinaire. Un autoencodeur ordinaire n'a appris qu'une chose : reconstruire les images qu'on lui a montrées. Son encodeur calcule pour chaque image des coordonnées qui permettent de la reconstruire, et rien de plus. Aucune règle ne fixe l'étendue de la carte ni la façon d'en occuper l'espace. Deux défauts en résultent.

- **On ne sait pas où est la carte.** Les points peuvent occuper n'importe quelle étendue, par exemple des coordonnées allant de -3 à 2 sur un axe et de 10 à 250 sur l'autre. Pour tirer un point au hasard, il faudrait d'abord connaître ces limites.
- **La carte a des trous.** Entre les points des images d'entraînement, il reste des zones où le décodeur n'a jamais été exercé. Un point tiré dans un tel trou donne une image qui ne ressemble à rien.

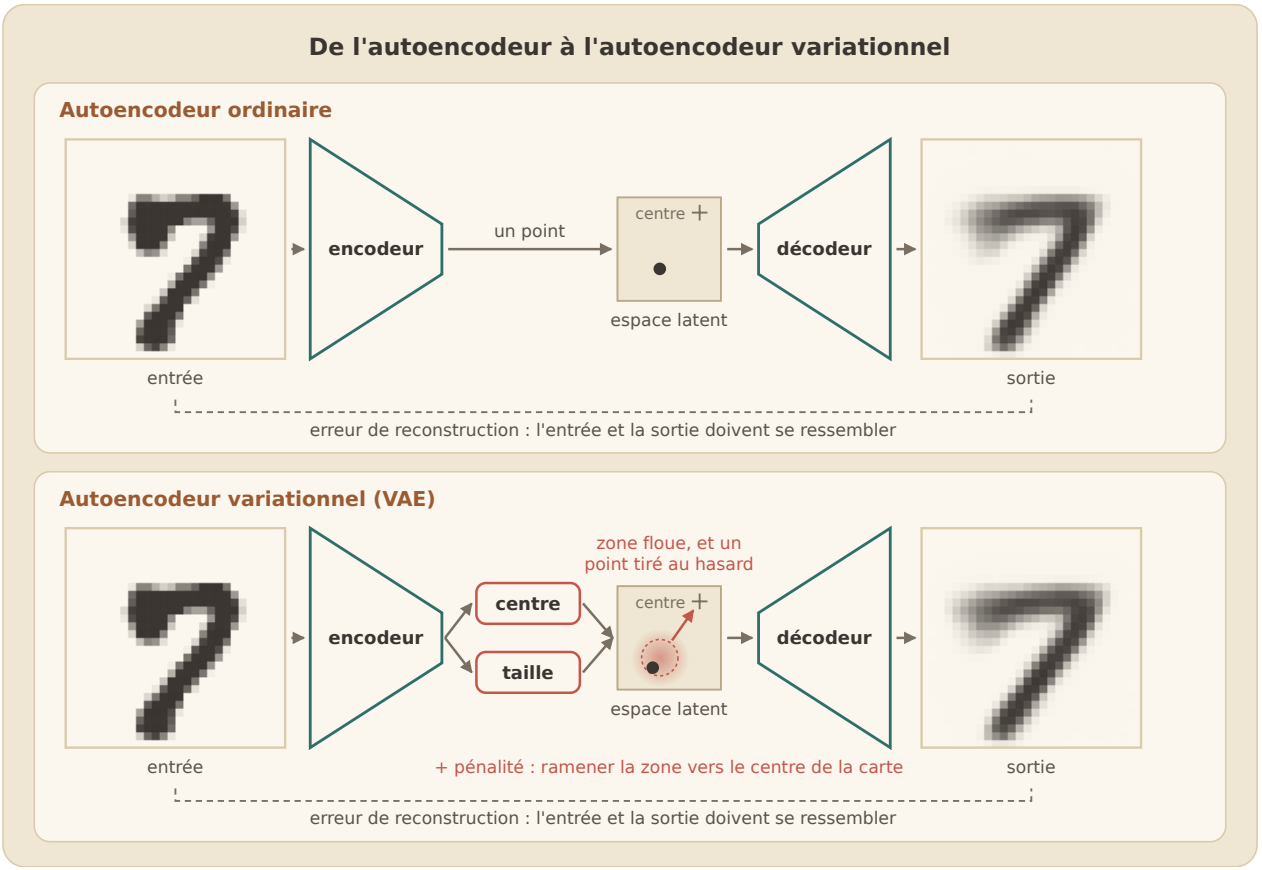
Tirer un point au hasard dans cette carte, c'est un peu comme lancer une fléchette les yeux bandés sur une carte du monde dont on ignore les bords, couverte d'océans : on tombe rarement sur une ville.

Les deux remèdes du VAE. Le VAE ajoute deux règles à l'entraînement, une contre chaque défaut.

1. **Contre les trous : des zones plutôt que des points.** L'encodeur ne place plus chaque image en un point précis, mais dans une petite **zone floue** autour de ce point. Pendant l'entraînement, le décodeur reçoit un point tiré au hasard dans cette zone, et doit quand même reconstruire l'image. Il apprend ainsi à produire une image correcte dans tout le voisinage de chaque point. Les zones voisines se chevauchent et bouchent les trous.
2. **Contre l'étendue inconnue : une pénalité.** Une pénalité ajoutée à l'erreur augmente quand une zone s'éloigne du centre de la carte, le point $(0, 0)$, ou devient trop petite. Toutes les zones sont donc ramenées dans un même disque autour du centre, de taille connue à l'avance. Le centre n'a rien de particulier en lui-même : c'est un rendez-vous convenu. Ce qui compte, c'est qu'on sache d'avance où se trouvent les images.

Les deux forces s'équilibrent. L'erreur de reconstruction pousse les zones à rester distinctes, pour que chaque image soit bien reconstruite. La pénalité les rassemble autour du centre. Le résultat est

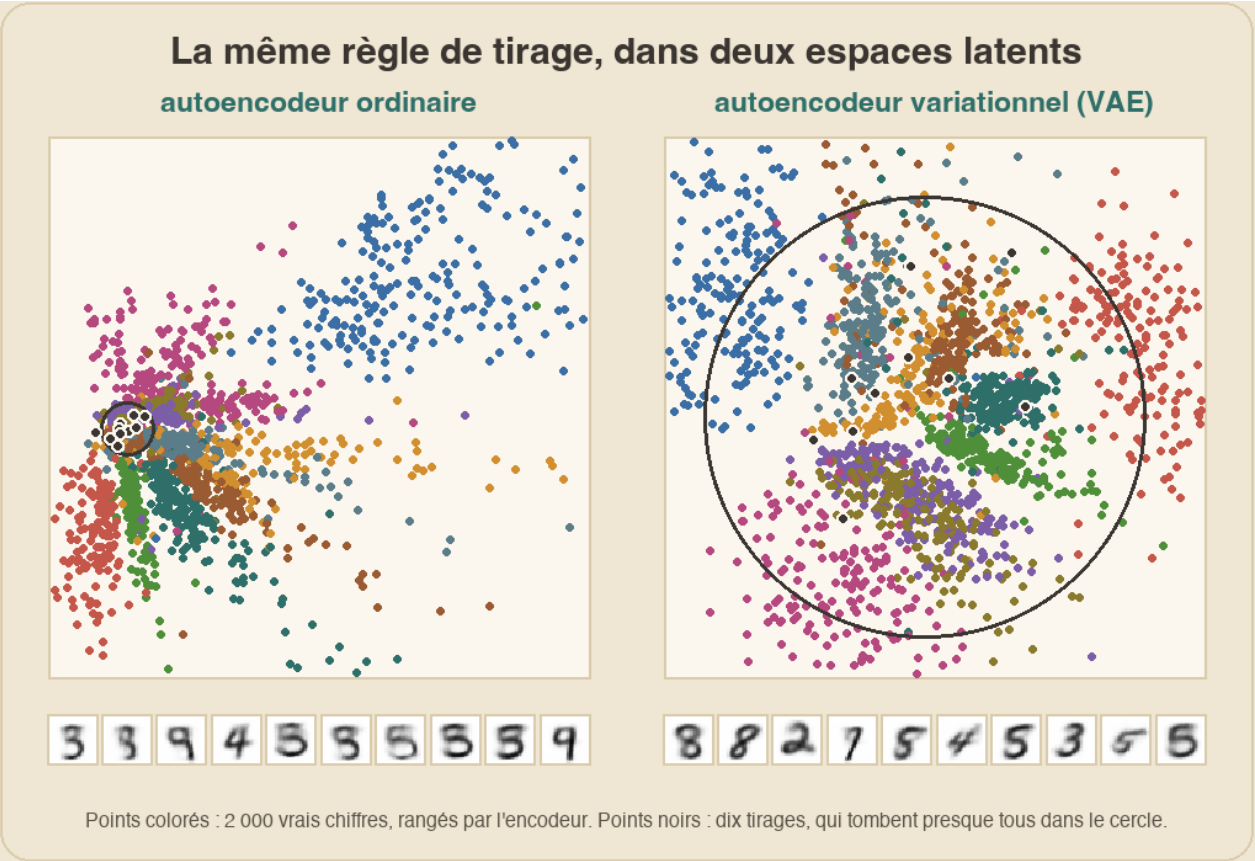
une carte serrée, sans trous, dont on connaît la forme : une cloche centrée sur l'origine. Pour générer, il suffit de tirer un point dans cette cloche, comme on lancerait la fléchette sur une carte où chaque endroit est une ville.



Le VAE garde le sablier de l'autoencodeur. Ce qui change est en rouge : l'encodeur donne une zone plutôt qu'un point, le décodeur reçoit un point tiré au hasard dans cette zone, et une pénalité ramène la zone vers le centre. Le 7, sa place sur la carte et les sorties viennent du réseau de l'applet du chapitre précédent.

La figure ci-dessous compare deux réseaux entraînés sur les mêmes chiffres de MNIST, un autoencodeur ordinaire et le VAE de l'applet du chapitre précédent. Dans chaque carte, dix points ont été tirés selon la même règle, puis décodés en chiffres.

Cette règle de tirage est la suivante. Chacun des deux nombres du code est tiré au hasard selon une **courbe en cloche** centrée sur zéro, la gaussienne du Module 2. Les valeurs proches de zéro sont les plus fréquentes, et les valeurs qui dépassent 2 ou -2 sont rares. Sur la carte, qui a deux dimensions, cette cloche devient une colline ronde, la plus haute au centre, le point $(0, 0)$. Les points tirés s'y entassent près du centre, et se raréfient à mesure qu'on s'en éloigne. Le **cercle noir** de la figure entoure la zone où tombent 95 % des tirages : c'est là que le décodeur ira chercher ses points. C'est aussi la région que la pénalité du VAE pousse ses chiffres à occuper.



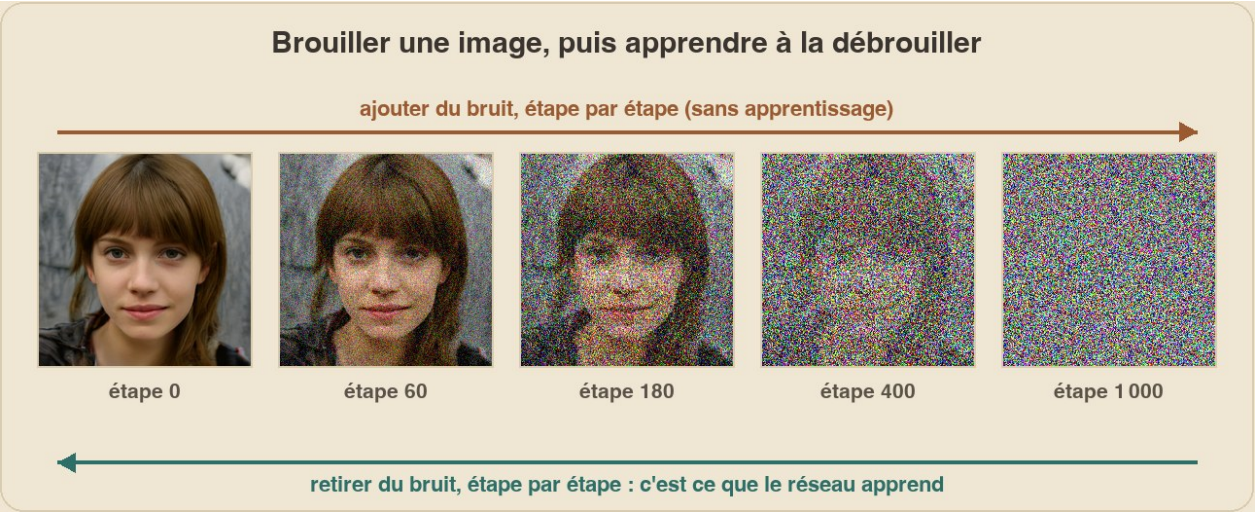
Avec la même règle de tirage, l'autoencodeur ordinaire ne produit presque que des 3, des 5 et des 9, car ses chiffres ne sont pas rangés autour du centre. Le VAE produit des chiffres variés.

L'autoencodeur ordinaire a rangé ses chiffres n'importe où, sur une très grande surface. Le cercle de tirage n'en couvre qu'un petit coin, et les chiffres produits se ressemblent tous. Il faudrait connaître la forme exacte de sa carte pour savoir où tirer. Le VAE, lui, a rangé ses chiffres là où l'on tire.

Les VAE s'entraînent de façon stable, et leur espace latent est bien organisé. Leur défaut principal se voit dans l'applet du chapitre précédent : leurs images sont **floues**. Quand le décodeur hésite entre plusieurs images possibles, il produit une moyenne de ces images, et une moyenne d'images est floue.

Retirer le bruit pas à pas : la diffusion

La troisième famille part d'une observation simple. Il est facile de détruire une image : il suffit de lui ajouter un peu de bruit, puis encore un peu, des centaines de fois, jusqu'à ce qu'il ne reste qu'une neige où l'image d'origine a disparu. Cette destruction ne demande aucun apprentissage. Un **modèle de diffusion** (*diffusion model*) apprend l'opération inverse, c'est-à-dire retirer un peu de bruit à la fois.



Un visage brouillé en 1 000 étapes, selon le calendrier de bruit utilisé par Ho, Jain et Abbeel en 2020. Un modèle de diffusion apprend à parcourir ce chemin dans l'autre sens.

L'entraînement se fait ainsi. On prend une image du jeu de données, on la brouille jusqu'à une étape choisie au hasard, et on demande au réseau d'estimer le bruit qui a été ajouté. Comme on a soi-même ajouté ce bruit, on connaît la bonne réponse : c'est un cas d'auto-supervision, comme l'autoencodeur. Le réseau qui estime le bruit est le plus souvent un U-Net, le réseau convolutif présenté au Module 3, et plus récemment un Transformer.

Pour générer une image, on part d'une neige nouvelle, tirée au hasard. Le réseau estime le bruit qu'elle contient, et on en retire une petite partie. On recommence avec l'image obtenue, des dizaines ou des centaines de fois. À chaque étape, une forme se précise, et à la fin il reste une image nette, que personne n'a jamais vue.

L'applet ci-dessous montre un modèle de diffusion entraîné sur des données beaucoup plus simples que des images. Chaque exemple n'est qu'un point du plan, et les exemples d'entraînement sont des milliers de points tirés dans la feuille d'érable du drapeau du Canada. Le principe est exactement le même que pour des images de millions de pixels.

Applet interactive : à utiliser en ligne, sur la page « Quatre façons de générer » du site du cours.

Quelques manipulations à faire :

1. Cliquez sur « Brouiller la feuille ». Les points s'écartent de la feuille, étape par étape, jusqu'à former un nuage informe. Les six points suivis font chacun une marche au hasard.
2. Cliquez sur « Générer de nouveaux points ». Un nouveau nuage est tiré au hasard, puis le réseau le ramène, étape par étape, vers la forme qu'il a apprise.
3. Une fois la génération terminée, déplacez le curseur de l'étape 100 à l'étape 0. La forme n'apparaît pas d'un coup : elle se dessine d'abord dans ses grandes lignes, puis dans ses détails, comme les pointes de la feuille.
4. Décochez « Afficher le contour de la feuille ». Le réseau n'a jamais vu ce contour, seulement des points. Les points générés sont nouveaux : aucun n'est la copie d'un point d'entraînement.

L'idée de la diffusion a été publiée en 2015 par Jascha Sohl-Dickstein et ses collègues, à l'Université Stanford, qui s'inspiraient de la thermodynamique. Elle est devenue efficace en 2020, avec les travaux de Jonathan Ho, Ajay Jain et Pieter Abbeel, à l'Université de Californie à Berkeley. À partir de

2021, les modèles de diffusion ont dépassé les GAN, comme l'ont montré cette année-là Prafulla Dhariwal et Alex Nichol, d'OpenAI. En 2022, ils s'imposent avec DALL·E 2 (OpenAI) et Stable Diffusion (Stability AI et l'Université de Munich), qui produisent des images à partir d'une phrase. Midjourney, très populaire auprès du public, reposerait sur le même principe, bien que l'entreprise n'ait jamais publié les détails de son modèle. Ils s'entraînent de façon stable, et ils couvrent toute la diversité des données, sans effondrement des modes. Leur défaut est la **lenteur**, puisqu'une image demande de nombreux passages dans le réseau, là où un GAN n'en demande qu'un. Une grande partie de la recherche récente vise à réduire ce nombre d'étapes.

Un élément après l'autre : les modèles autorégressifs

La quatrième famille découpe une donnée en éléments, et les génère **un par un**, dans un ordre fixé. Chaque élément est tiré au hasard dans une distribution qui dépend de tous les éléments déjà produits. On appelle ces modèles **autorégressifs** (*autoregressive models*), parce que chaque élément est prédit à partir des éléments précédents de la même donnée.

- Pour une image, on peut générer les pixels un par un, ligne par ligne. Chaque pixel est tiré en tenant compte de tous les pixels déjà placés au-dessus et à gauche. C'est ce que fait PixelCNN, publié par DeepMind en 2016.
- Pour un son, on peut générer les échantillons sonores un par un, à raison de plusieurs milliers par seconde. C'est ce que fait WaveNet, publié par DeepMind la même année, qui a nettement amélioré la voix des assistants vocaux.
- Pour un texte, on peut générer les mots un par un. Chaque mot est tiré dans une distribution qui dépend de tous les mots déjà écrits.

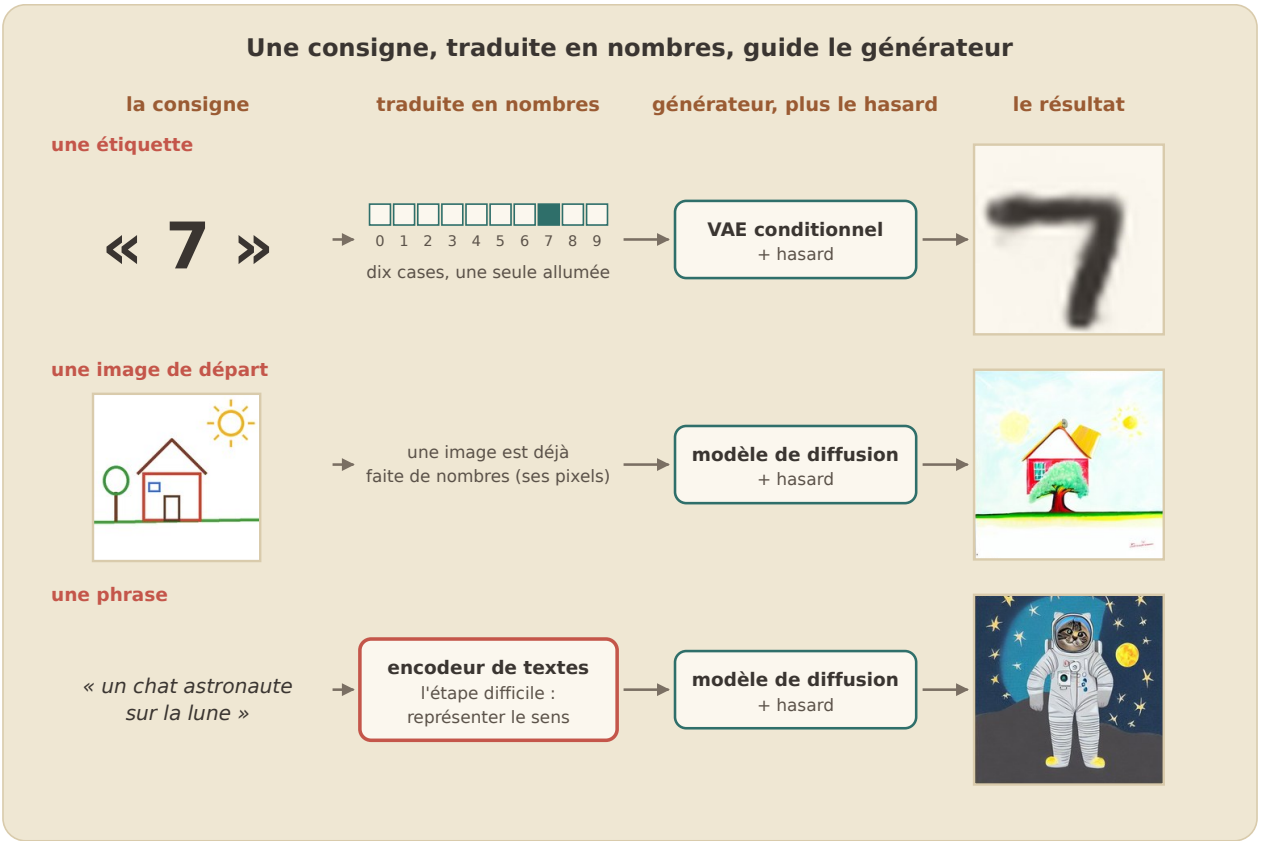
Cette dernière application est la plus importante. Le texte se prête naturellement à cette méthode, puisqu'il se lit et s'écrit déjà dans un ordre, un mot après l'autre. Les grands modèles de langage comme ceux de ChatGPT sont des modèles autorégressifs. Ils tirent chaque mot dans une distribution, avec la température présentée au chapitre précédent. Le reste du module leur est consacré, à partir du chapitre « Des règles aux probabilités ».

Les modèles autorégressifs s'entraînent de façon stable, et la probabilité qu'ils attribuent à chaque élément est calculée explicitement, ce qui permet de mesurer précisément leur qualité. Leur défaut est le même que celui de la diffusion, en plus marqué : générer élément par élément est lent, et une image de quelques millions de pixels demanderait autant de passages dans le réseau. C'est pourquoi la génération pixel par pixel a été abandonnée. La méthode est cependant revenue pour les images sous une autre forme. L'image est d'abord compressée en une courte suite de codes, des **jetons visuels**, et un modèle autorégressif génère ces jetons un par un, comme les mots d'un texte. C'est ce que fait DALL·E, d'OpenAI, en 2021, avec environ un millier de jetons par image, et c'est ainsi que des modèles multimodaux récents produisent des images, comme le montre le chapitre « Des modèles qui voient, entendent et parlent ».

Générer sur demande

Les modèles présentés jusqu'ici génèrent un exemple quelconque de la distribution : un visage, un chiffre, une feuille. On veut souvent davantage, et préciser ce qu'on veut obtenir, comme « un 7 », « un visage souriant » ou « un chat sur la lune ».

Les quatre familles le permettent. On donne au réseau, en plus du hasard, une information supplémentaire qu'il prend en compte à chaque étape : une étiquette, une image de départ, ou une phrase. On parle de génération **conditionnelle** (*conditional generation*). Un générateur d'images à partir de texte, comme DALL·E 2 ou Stable Diffusion, est un modèle de diffusion conditionné par une phrase. Pour cela, il faut traduire la phrase en nombres que le réseau comprend, ce qui demande de savoir représenter le sens d'un texte. Le chapitre « Relier les mots et les images » y reviendra, une fois présentés les modèles de langage.



Trois sortes de consignes. Chacune est d'abord traduite en nombres ; pour une phrase, c'est l'étape la plus difficile. Les résultats sont réels : un VAE conditionnel entraîné sur MNIST, puis Stable Diffusion 1.5, à partir du dessin ou de la phrase (en anglais).

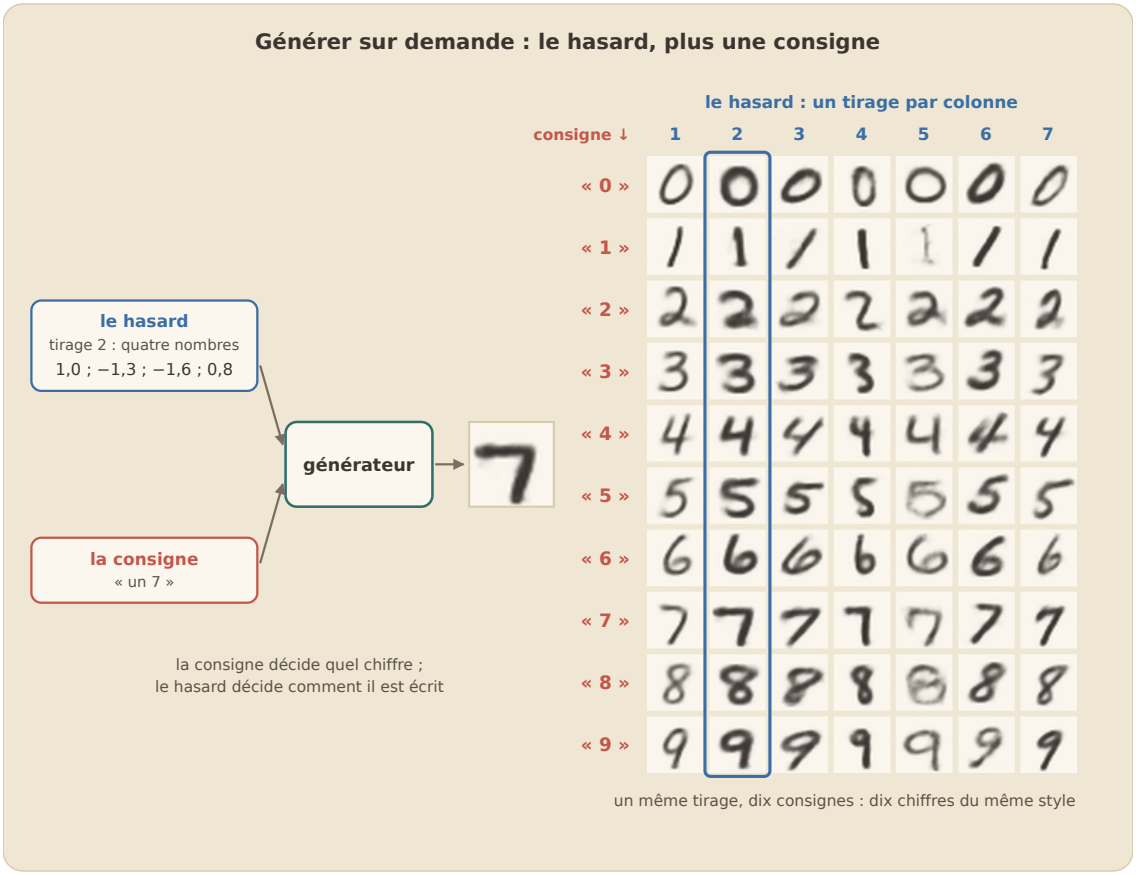
Le rôle du hasard. Un réseau de neurones est une fonction : pour une même entrée, il donne toujours la même sortie. Sans hasard, la consigne « 7 » donnerait donc toujours exactement le même 7. Or il existe une infinité de façons d'écrire un 7, plus ou moins penché, épais ou large. Générer, c'est tirer au hasard l'une de ces façons. Le hasard est ce tirage : quelques nombres choisis au hasard, que le générateur reçoit en même temps que la consigne, et qui désignent l'une des façons possibles. **La consigne restreint les possibilités** (que des 7), **le hasard choisit parmi celles qui restent.** Dans un VAE, ces nombres sont un point de l'espace latent. Dans un modèle de diffusion, c'est le bruit de départ. Dans un modèle de langage, c'est le tirage de chaque mot.

Les générateurs d'images appellent ce tirage la **graine** (*seed*). Avec la même consigne et la même graine, on obtient exactement la même image. Si l'on change seulement la graine, on obtient une autre image qui respecte la même consigne.



La même consigne, quatre graines : quatre images différentes, toutes conformes à la consigne (*Stable Diffusion 1.5, consigne donnée en anglais*).

La figure suivante montre de près un vrai générateur conditionnel, un VAE entraîné sur les chiffres de MNIST. Son hasard est un tirage de quatre nombres, et sa consigne l'étiquette du chiffre à produire. Chaque colonne de la grille reçoit son propre tirage, et chaque rangée sa propre consigne. La consigne décide quel chiffre est produit. Le hasard décide comment il est écrit : la colonne encadrée reçoit le tirage 2, et ses dix chiffres sont tous droits et d'un trait épais, alors que ceux de la colonne 3 sont penchés et fins.



Un générateur conditionnel reçoit deux entrées. La consigne (les rangées) fixe le chiffre ; le hasard, quatre nombres tirés (les colonnes), fixe la façon de l'écrire.

Quatre familles, et leurs combinaisons

	GAN	VAE	Diffusion	Autorégressif
Idée	un faussaire contre un expert	un espace latent rempli	retirer le bruit pas à pas	un élément après l'autre
Première publication	2014	2013	2015 (efficace en 2020)	bien plus ancienne pour le texte ; 2016 pour les images et les sons
Points forts	images nettes, génération rapide	entraînement stable, espace latent organisé	qualité et diversité	entraînement stable, probabilités explicites
Limites	entraînement instable, effondrement des modes	images floues	génération lente	génération très lente pixel par pixel

	GAN	**VAE**	**Diffusion**	**Autorégressif**
Exemples	StyleGAN	l'autoencodeur de Stable Diffusion	DALL·E 2, Stable Diffusion	WaveNet, GPT, DALL·E (2021)

Les systèmes actuels combinent souvent plusieurs de ces idées. Stable Diffusion, par exemple, ne débruite pas directement les pixels. Un autoencodeur réduit d'abord chaque image à une représentation latente beaucoup plus petite, et la diffusion se fait dans cet espace latent, ce qui la rend bien plus rapide. Le décodeur transforme ensuite le résultat en image.

Le chapitre suivant montre ce que ces méthodes ont permis de produire depuis 2014 : des images, des voix, de la musique et des vidéos.

Des images, des voix, des vidéos

Le chapitre « Quatre façons de générer » a présenté les méthodes. Celui-ci présente ce qu'elles ont produit en une dizaine d'années, type de contenu par type de contenu : les images, les voix et la musique, la vidéo, puis des domaines plus inattendus, comme la conception de protéines ou la prévision météorologique. Il se termine par les problèmes que ces contenus posent, en particulier les hypertrucages (*deepfakes*).

Beaucoup de ces systèmes produisent un contenu à partir d'une phrase, comme « un chat sur la lune ». Leur fonctionnement demande de savoir représenter le sens d'un texte, ce qui sera présenté avec les modèles de langage. Le chapitre « Relier les mots et les images » expliquera comment le texte et l'image sont reliés.

Les images

Les premiers visages produits par un GAN, en 2014, étaient flous, en noir et blanc, et mesuraient quelques dizaines de pixels de côté. En 2017, une équipe de Nvidia produisait des visages en couleur de 1 024 pixels de côté, en faisant grandir progressivement le générateur et le discriminateur pendant l'entraînement. En 2019, StyleGAN produisait les visages présentés au début du chapitre « Générer : imiter une distribution ».

La génération d'images à partir d'une phrase a suivi une progression semblable. En 2015, Elman Mansimov et ses collègues de l'Université de Toronto présentent alignDRAW, l'un des premiers modèles capables de produire une image à partir d'une description. Leur exemple le plus connu est « *A stop sign is flying in blue skies* » (« un panneau d'arrêt vole dans un ciel bleu »). La figure ci-dessous montre la même phrase traitée par des générateurs successifs.



La même phrase, traitée par quatre générateurs de 2015 à 2025. DALL·E 2 et DALL·E 3 produisent une image réaliste, mais plantent le panneau sur un poteau : ils ne respectent pas toute la phrase.

Les étapes principales sont les suivantes.

- **Janvier 2021** : OpenAI présente DALL·E. Son « fauteuil en forme d'avocat » fait le tour du Web, parce qu'il combine deux idées que personne n'avait dessinées ensemble.
- **Avril 2022** : DALL·E 2, un modèle de diffusion, produit des images réalistes de 1 024 pixels de côté.
- **Juillet 2022** : Midjourney, sans doute lui aussi un modèle de diffusion, ouvre son service au public.
- **Août 2022** : Stable Diffusion est publié avec ses poids. N'importe qui peut le télécharger et le faire tourner sur un ordinateur personnel muni d'une bonne carte graphique, ce qui multiplie les usages et les variantes.
- **2025** : les grands modèles de langage génèrent eux-mêmes des images, comme la génération d'images de GPT-4o, intégrée à ChatGPT en mars 2025. Ils suivent beaucoup mieux les consignes détaillées, comme le montre le dernier panneau de la figure.

Un prix d'art pour une image générée
Le 29 août 2022, l'image *Théâtre D'opéra Spatial* remporte le premier prix de la catégorie des arts numériques, pour les artistes non professionnels, au concours d'art de la foire de l'État du Colorado. Son auteur, Jason M. Allen, l'a produite avec Midjourney, à partir d'au moins 624 consignes et retouches successives, puis l'a modifiée dans un logiciel de retouche. L'annonce provoque une vive polémique chez les artistes.



Théâtre D'opéra Spatial, Jason M. Allen avec Midjourney, 2022. Le Bureau du droit d'auteur des États-Unis a refusé d'en enregistrer les droits, un refus que l'auteur conteste en justice.

Jason M. Allen a ensuite demandé à enregistrer les droits d'auteur de l'image. En septembre 2023, le Bureau du droit d'auteur des États-Unis (*U.S. Copyright Office*) a rejeté sa demande, au motif que la contribution humaine était trop faible par rapport à celle du générateur. En 2024, Jason M. Allen a contesté ce refus devant un tribunal fédéral du Colorado. La question de savoir à qui appartient une œuvre générée reste ouverte, et le Module 5 y revient.

Retoucher plutôt que créer

Les modèles génératifs ne servent pas seulement à produire des images complètes. Ils servent aussi à modifier des images existantes.

- **Le transfert de style** (*style transfer*). En 2015, Leon Gatys et ses collègues, à l'Université de Tübingen, montrent qu'un réseau convolutif peut redessiner une photo dans le style d'un tableau, par exemple *La Nuit étoilée* de Van Gogh. La méthode est proche de celle de DeepDream, présenté au Module 3 la même année : on modifie une image pas à pas, à partir de ce que voient les couches d'un réseau.
- **Le remplissage** (*inpainting*). On efface une partie d'une image, par exemple un passant dans une photo de vacances, et le modèle la remplace par un contenu plausible. L'**extension** (*out-painting*) prolonge une image au-delà de son cadre.
- **La super-résolution** (*super-resolution*). Le modèle augmente la résolution d'une image en inventant des détails plausibles, qui n'étaient pas dans l'image d'origine.

Ces fonctions sont aujourd'hui intégrées aux logiciels de retouche, comme le remplissage génératif de Photoshop depuis 2023, et aux applications photo des téléphones. Elles rendent la frontière entre une photo et une image générée de plus en plus floue : une photo retouchée par un modèle génératif contient des pixels que l'appareil n'a jamais enregistrés.

Les voix et la musique

En 2016, WaveNet produisait une voix de synthèse (*text-to-speech*) beaucoup plus naturelle que les méthodes précédentes. Les progrès suivants ont surtout porté sur le **clonage de voix** (*voice cloning*), l'imitation d'une voix particulière. En janvier 2023, Microsoft présente VALL-E, qui imite la voix d'une personne à partir d'un enregistrement de trois secondes, en reproduisant son timbre et même l'ambiance sonore de l'enregistrement. Ces outils permettent de rendre la voix à des personnes qui l'ont perdue, ou de doubler un film dans une autre langue avec la voix des acteurs. Ils permettent aussi des fraudes. En 2019, des escrocs ont imité la voix du dirigeant d'une entreprise allemande pour obtenir d'une filiale britannique un virement de 220 000 euros.

La génération de musique a suivi. En 2020, Jukebox, d'OpenAI, produisait des chansons avec des voix chantées, dans le style de musiciens connus, mais avec une qualité sonore médiocre. En avril 2023, une chanson intitulée *Heart on My Sleeve*, dont les voix imitent celles des musiciens canadiens Drake et The Weeknd, est publiée sur les plateformes d'écoute et y est écoutée des millions de fois avant d'être retirée à la demande de leur maison de disques. Fin 2023 et début 2024, Suno et Udio produisent des chansons complètes, avec paroles, voix et instruments, à partir d'une simple phrase. En 2024, les grandes maisons de disques poursuivent Suno et Udio, qu'elles accusent d'avoir entraîné leurs modèles sur des enregistrements protégés.

La vidéo

Une vidéo est une suite d'images, à raison de 24 à 30 images par seconde. La générer est plus difficile que générer une image, pour deux raisons. Il y a beaucoup plus de données à produire, et les images successives doivent rester **cohérentes** entre elles : un personnage ne doit pas changer de visage, et un objet ne doit pas disparaître quand un autre passe devant.

En février 2024, OpenAI présente Sora, qui produit des vidéos d'une minute à partir d'une phrase. La vidéo ci-dessous, publiée par OpenAI, montre des exemples. Sora est un modèle de diffusion. La vidéo est découpée en petits blocs, chacun couvrant une petite zone de l'image pendant quelques images consécutives, et un Transformer retire le bruit de tous ces blocs à la fois.

Vidéo : https://www.youtube.com/watch?v=HK6y8DAPN_0

En mai 2025, Google présente Veo 3, qui génère aussi le son synchronisé avec l'image : les dialogues, les bruits et l'ambiance. En septembre 2025, OpenAI présente Sora 2, qui fait de même.

Ces vidéos restent imparfaites. Les objets s'y comportent parfois d'une façon physiquement impossible : un verre qui tombe ne se brise pas correctement, une personne mord dans un biscuit qui reste intact. Ces erreurs posent une question importante. Pour produire une vidéo réaliste, un modèle doit-il comprendre les lois de la physique, ou lui suffit-il d'imiter l'apparence des vidéos qu'il a vues ? On retrouve la notion de modèle du monde présentée au Module 1. Le chapitre « Ce que les LLM comprennent, et ce qu'ils ratent » reprendra cette question.

Au-delà des médias

Les mêmes méthodes s'appliquent à des données qui ne sont ni des images ni des sons.

- **Les protéines.** Une protéine est une longue chaîne de molécules qui se replie dans l'espace, et sa forme détermine ce qu'elle fait dans l'organisme. En 2023, l'équipe de David Baker, à l'Université de Washington, publie RFdiffusion, un modèle de diffusion qui génère des formes de protéines qui n'existent pas dans la nature, conçues pour accomplir une tâche précise, comme se fixer sur un virus. David Baker reçoit la moitié du prix Nobel de chimie 2024 pour la conception de protéines par ordinateur. L'autre moitié récompense AlphaFold, qui prédit la forme des protéines existantes, et que présente le chapitre « L'attention et le Transformer » du Module 3.
- **La météo.** En 2024, Google DeepMind publie GenCast, un modèle de diffusion qui génère plusieurs évolutions possibles du temps qu'il fera sur quinze jours. Sur la plupart des mesures, ses prévisions sont plus précises que celles du meilleur système classique, celui du Centre européen pour les prévisions météorologiques à moyen terme.
- **Les matériaux et les médicaments.** Des modèles génératifs proposent des molécules et des matériaux nouveaux, qui sont ensuite testés en laboratoire.
- **Le code informatique.** Les programmes sont des textes. Leur génération relève des modèles de langage et des agents présentés au chapitre « Programmer avec des agents ».

Dans ces domaines, l'intérêt d'un modèle génératif est le même que pour les images : il propose rapidement un grand nombre de candidats plausibles, que l'on vérifie ensuite.

Les hypertrucages

Un **hypertrucage** (*deepfake*) est une image, un enregistrement sonore ou une vidéo générés ou modifiés pour faire croire qu'une personne réelle a dit ou fait quelque chose qu'elle n'a pas dit ou fait. Le mot anglais apparaît fin 2017, sur le forum Reddit, comme pseudonyme d'un utilisateur qui publiait des vidéos où le visage d'actrices avait été placé sur celui d'autres personnes, la plupart du temps dans des vidéos pornographiques.

Les usages malveillants se sont multipliés depuis.

- **La pornographie non consentie**, qui reste l'usage le plus répandu et vise surtout des femmes.
- **La désinformation.** En mars 2022, une fausse vidéo du président ukrainien Volodymyr Zelensky, appelant ses soldats à déposer les armes, a circulé sur les réseaux sociaux.
- **La fraude.** En 2024, un employé du bureau de Hong Kong de l'entreprise d'ingénierie Arup a transféré l'équivalent d'environ 25 millions de dollars américains après une visioconférence où ses collègues, dont le directeur financier, étaient tous des hypertrucages.

Peut-on distinguer à l'œil une image générée d'une vraie photo ? L'applet ci-dessous propose dix portraits. Cinq sont de vraies photos, cinq ont été générés par des modèles de différentes époques, de 2019 à 2026. Pour chacun, décidez s'il s'agit d'une vraie photo, puis lisez l'explication.

Applet interactive : à utiliser en ligne, sur la page « Des images, des voix, des vidéos » du site du cours.

Les visages produits par les modèles de 2019 et 2020 se trahissent encore par des défauts visibles, surtout dans le fond et les accessoires. Ceux des modèles récents n'en ont presque plus. Deux autres moyens sont donc à l'étude.

- **Marquer les contenus générés.** SynthID, présenté par Google DeepMind en 2023, insère dans les images, les sons et les textes générés une marque invisible (*watermark*), qu'un logiciel peut détecter. La coalition C2PA, créée en 2021 par des entreprises comme Adobe, Microsoft et la BBC, définit une façon d'attacher à chaque fichier l'historique de sa création et de ses modifications.
- **Détecter automatiquement.** Des classificateurs sont entraînés à distinguer les contenus générés des contenus réels. Ce sont des modèles discriminatifs, et le problème rappelle celui du GAN : chaque progrès des détecteurs peut servir à entraîner des générateurs plus difficiles à détecter.

Aucune de ces solutions n'est fiable à elle seule. Les marques et les historiques peuvent être effacés : une semaine après la sortie de Sora 2, des logiciels permettaient déjà de retirer la marque visible de ses vidéos. Les détecteurs se trompent, dans les deux sens.

Le Module 5 traite ces questions de confiance dans les contenus, avec celles du droit d'auteur soulevées plus haut par le prix d'art et les procès contre Suno et Udio.

Le texte, au premier plan

Parmi tous ces contenus, c'est pourtant le texte qui a le plus transformé l'usage de l'IA. Depuis la sortie de ChatGPT, en novembre 2022, des centaines de millions de personnes utilisent chaque semaine un modèle qui génère du texte. Ces modèles appartiennent à la famille autorégressive : ils produisent un texte un élément après l'autre. Le chapitre suivant commence leur étude par leur histoire : soixante-dix ans de recherche pour faire lire, écrire et traduire la langue par une machine.

Des règles aux probabilités

Faire maîtriser la langue à une machine est l'un des plus vieux rêves de l'informatique. En 1950, Alan Turing propose déjà de juger l'intelligence d'une machine à sa capacité de converser : c'est le jeu de l'imitation du Module 1. La science-fiction en a fait l'un de ses thèmes favoris :

- l'ordinateur HAL 9000 de *2001 : l'odyssée de l'espace* (Stanley Kubrick, 1968), qui converse calmement avec les astronautes, avant de leur désobéir ;
- l'ordinateur de bord de *Star Trek* (1966), à qui l'équipage pose ses questions à voix haute ;
- le robot C-3PO de *La Guerre des étoiles* (1977), qui parle des millions de langues ;
- Samantha, l'assistante vocale dont s'éprend le héros de *Her* (Spike Jonze, 2013).

Le rêve de comprendre toutes les langues est plus ancien encore. Il remonte au récit de la tour de Babel, et la science-fiction l'a repris avec le « poisson de Babel » du *Guide du voyageur galactique* (Douglas Adams, 1979) : glissé dans l'oreille, il traduit instantanément tout ce qu'on entend.



À gauche, HAL 9000, l'ordinateur qui converse avec l'équipage dans 2001 : l'odyssée de l'espace (1968) ; dessin de Tom Cowap, Wikimedia Commons, CC BY-SA 4.0. À droite, La Tour de Babel de Pieter Bruegel l'Ancien (1563), Kunsthistorisches Museum de Vienne : dans le récit biblique, les humains, qui parlent tous la même langue, bâtissent une tour qui doit atteindre le ciel ; leurs langues sont alors brouillées, et ils ne se comprennent plus. Domaine public, Wikimedia Commons.

Ce rêve semble aujourd'hui en partie réalisé. Les grands modèles de langage donnent l'impression d'être apparus d'un coup, en 2022. Ils sont pourtant l'aboutissement de soixante-dix ans de recherche en **traitement automatique de la langue** (*natural language processing*, NLP), le domaine qui cherche à faire lire, écrire, traduire ou transcrire la langue humaine par une machine. Cette recherche a connu trois grandes approches : écrire des **règles**, compter des **statistiques** dans de grandes collections de textes, puis entraîner des **réseaux de neurones**.

Ce chapitre et le suivant, « Les outils statistiques », présentent les deux premières. Les chapitres « Des mots aux nombres » et « Prédire le mot suivant » présentent la troisième. Plusieurs idées nées bien avant les réseaux de neurones sont encore au cœur des LLM : le modèle de langage lui-même, la façon de le mesurer, et l'idée de produire la suite la plus probable d'un texte.



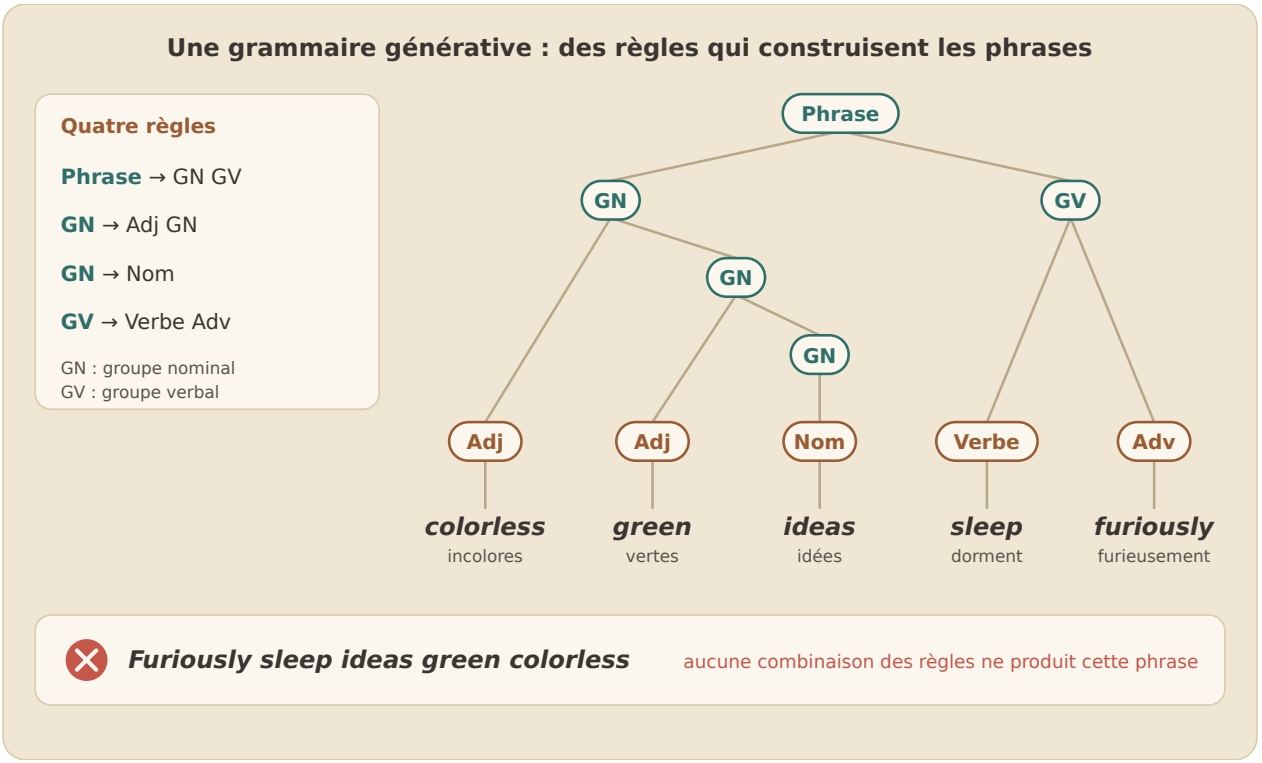
Les trois ères du traitement de la langue. Les jalons sont présentés dans ce chapitre et les suivants de ce module, sauf la traduction de séquence à séquence, Google Traduction neuronal et le Transformer, présentés au Module 3.

Les règles (1954-1980)

Le 7 janvier 1954, à New York, IBM et l'Université de Georgetown présentent une machine qui traduit du russe vers l'anglais. L'ordinateur IBM 701 traduit une soixantaine de phrases choisies avec soin, à l'aide d'un vocabulaire de 250 mots et de six règles de grammaire. La démonstration fait les manchettes, et ses organisateurs prédisent que la traduction automatique sera au point d'ici trois à cinq ans. C'est la guerre froide, et traduire automatiquement les publications scientifiques soviétiques intéresse beaucoup le gouvernement américain.

En 1957, le linguiste Noam Chomsky publie *Structures syntaxiques* (*Syntactic Structures*). Il y décrit une langue par une **grammaire générative** (*generative grammar*) : un petit ensemble de règles capable de produire toutes les phrases correctes de la langue, et seulement celles-là. Analyser une phrase avec ces règles produit un **arbre syntaxique** (*parse tree*), qui montre comment elle se décompose en groupes de mots. Il y conteste aussi l'idée de décrire la langue par des probabilités, avec un exemple resté célèbre : « *Colorless green ideas sleep furiously* » (« D'incolores idées vertes dorment furieusement »). La phrase n'a pas de sens, mais elle est grammaticale, alors que les mêmes mots à l'envers, « *Furiously sleep ideas green colorless* », ne le sont pas. Or aucune des deux phrases n'avait jamais été écrite. Pour un modèle qui ne fait que compter les suites de mots déjà vues, elles seraient donc toutes deux impossibles, au même titre. L'argument pèse lourd. Pendant une vingtaine d'années, l'approche dominante consiste à écrire des règles à la main : des dictionnaires, des grammaires, des

règles pour passer d'une langue à l'autre. Nous verrons plus bas comment les statistiques ont fini par répondre à Chomsky.



L'arbre syntaxique de la phrase de Chomsky. Quatre règles suffisent à la construire, alors qu'elles ne peuvent pas produire la même phrase à l'envers. La grammaire distingue les deux phrases sans rien savoir de leur sens.

Les résultats déçoivent. En 1966, un comité consultatif du gouvernement américain, l'ALPAC (*Automatic Language Processing Advisory Committee*), conclut que la traduction automatique est plus lente, moins exacte et deux fois plus chère qu'un traducteur humain. Le financement s'effondre. C'est l'un des premiers revers de l'IA, avant les hivers présentés au Module 1. La même année, ELIZA imite un psychothérapeute avec quelques règles de reformulation, et en 1970, SHRDLU converse en anglais sur un petit monde de blocs. Les deux impressionnent, mais aucun ne sort de son domaine.

Les systèmes à règles réussissent pourtant quand le domaine est étroit. À l'Université de Montréal, le groupe TAUM (Traduction automatique de l'Université de Montréal) met au point **TAUM-MÉTÉO**, qui traduit de l'anglais vers le français les bulletins météorologiques d'Environnement Canada. La langue des bulletins est répétitive et prévisible (« nuageux avec éclaircies », « possibilité d'averses »). Mis en service à la fin des années 1970, le système traduit les bulletins de tout le pays pendant plus de vingt ans, jusqu'en 2001.

Le tournant statistique

Dans les années 1970, une autre approche naît dans les laboratoires d'IBM, autour de la reconnaissance de la parole. Plutôt que d'écrire des règles de phonétique et de grammaire, l'équipe de Frederick Jelinek apprend des **probabilités** à partir de grandes quantités de parole enregistrée et de texte. Les résultats sont tels qu'on attribue à Jelinek une boutade restée célèbre : « Chaque fois

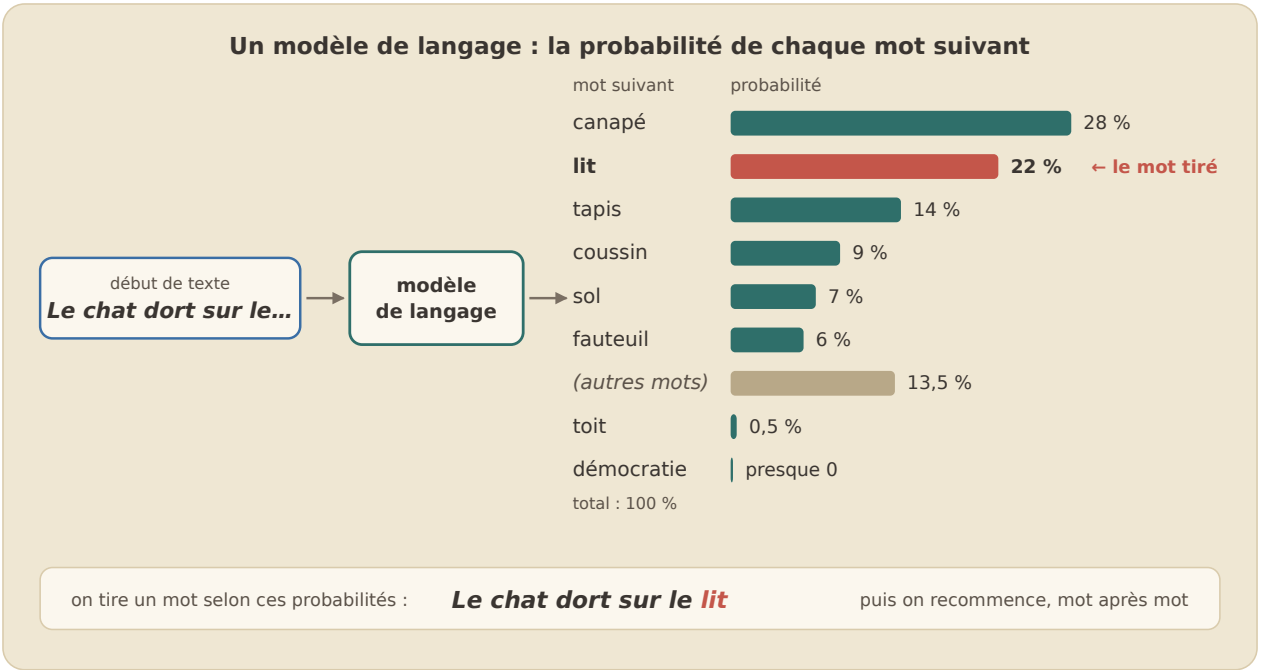
que je renvoie un linguiste, la performance du système augmente. » C'est le renversement présenté au Module 2 : plutôt que de dire à la machine comment faire, on lui donne des exemples, et elle apprend.

Le filtre à pourriels du Module 2, que vous construisez dans le travail noté 2, appartient à ce même tournant. Plutôt que d'écrire des règles comme « si le courriel contient *gratuit*, c'est un pourriel », on estime, à partir de courriels déjà triés, la probabilité de chaque mot dans les pourriels et dans les courriels ordinaires. Popularisée en 2002 par l'essai « A Plan for Spam » de Paul Graham, la méthode est vite adoptée par la plupart des messageries. Le Module 2 la replaçait d'ailleurs parmi les autres succès du tournant probabiliste, aux côtés des travaux de Jelinek.

Cette approche demande des **corpus**, c'est-à-dire de grandes collections de textes. Le Brown Corpus, réuni à l'Université Brown dans les années 1960, rassemble un million de mots d'anglais américain publiés en 1961. Le Penn Treebank (1993) annote des millions de mots, surtout tirés d'articles du *Wall Street Journal*, avec la catégorie grammaticale de chaque mot et la structure de chaque phrase. Pour la traduction, IBM utilise un corpus canadien, le **Hansard**, le compte rendu des débats du Parlement du Canada, publié dans les deux langues officielles. Ses millions de phrases traduites par des professionnels deviennent, vers 1990, la matière première de la traduction statistique, présentée au chapitre suivant.

Un modèle de langage

Un **modèle de langage** (*language model*) est un modèle qui donne, pour un début de texte, la probabilité de chaque mot qui pourrait venir ensuite. Après « Le chat dort sur le », il donne une probabilité élevée à « canapé », « lit » ou « tapis », une probabilité faible à « toit », et une probabilité presque nulle à « démocratie ». C'est une distribution, au sens du chapitre « Générer », et on peut y tirer des mots au hasard, chacun selon sa probabilité. C'est l'échantillonnage présenté dans ce même chapitre : les mots probables sortent souvent, les mots improbables rarement, mais aucun n'est exclu d'avance.



Un modèle de langage donne une distribution sur le mot suivant. On y tire un mot, on l'ajoute au texte, et on recommence. Les probabilités sont données à titre d'illustration.

En notation mathématique, on écrit les mots d'un texte $w_1, w_2, w_3, \ldots$ (w pour *word*, « mot » en anglais). Un modèle de langage donne la probabilité du mot suivant, sachant tous ceux qui le précèdent :

$$P(w_i \mid w_1, \ldots, w_{i-1})$$

La barre verticale se lit « sachant », comme dans les probabilités conditionnelles de la classification bayésienne du Module 2. Dans l'exemple ci-dessus, $P(\text{canapé} \mid \text{le chat dort sur le}) = 0{,}28$.

Ces probabilités suffisent pour donner une probabilité à un texte entier : on multiplie la probabilité de chaque mot, sachant ceux qui le précèdent.

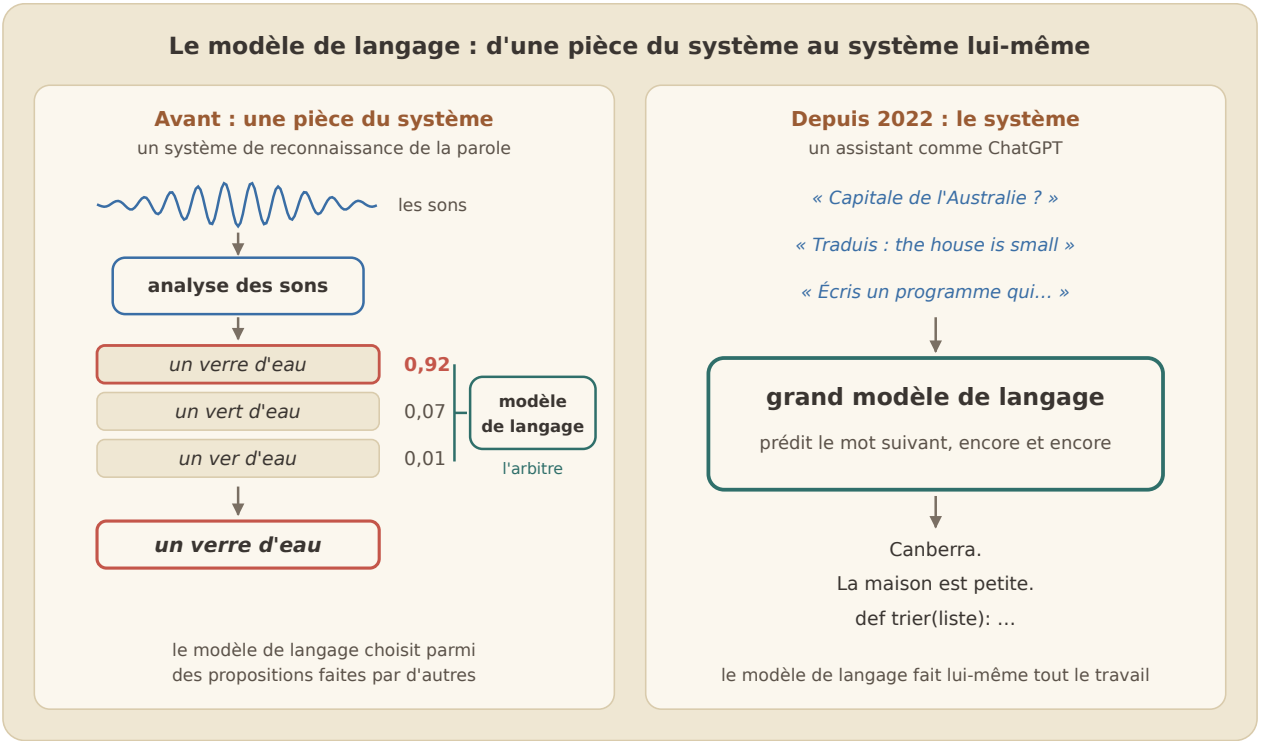
$$\begin{aligned} P(w_1, \ldots, w_N) &= P(w_1) \times P(w_2 \mid w_1) \times P(w_3 \mid w_1, w_2) \times \ldots \\ &= \prod_{i=1}^{N} P(w_i \mid w_1, \ldots, w_{i-1}) \end{aligned}$$

C'est la **règle de la chaîne** (*chain rule*) des probabilités. Elle est exacte : elle ne fait aucune hypothèse sur la langue. Toute la difficulté consiste à estimer chacun de ses facteurs. La même règle permet de générer un texte : on tire w_1, puis w_2 sachant w_1, puis w_3 sachant les deux premiers, et ainsi de suite.

Les modèles de langage existaient bien avant ChatGPT, mais ils jouaient un rôle de second plan. Pendant des décennies, ils ont été une **pièce** parmi d'autres dans des systèmes plus vastes, où d'autres composants faisaient l'essentiel du travail. Le modèle de langage y servait d'arbitre : parmi plusieurs interprétations proposées par le reste du système, il choisissait celle qui ressemble le plus à du vrai texte.

- En **reconnaissance de la parole**, un premier composant analyse les sons et propose plusieurs suites de mots qui leur correspondent. « Un verre d'eau » et « un vert d'eau » se prononcent de la même façon. Le modèle de langage tranche : la première suite est beaucoup plus probable.
- En **traduction automatique**, le modèle de traduction propose plusieurs traductions possibles, et le modèle de langage choisit celle qui forme une phrase naturelle. C'est le canal bruité présenté au chapitre suivant.
- Le **clavier prédictif** d'un téléphone propose les mots les plus probables après ceux qu'on vient de taper. C'est l'un des rares usages où le modèle de langage travaille presque seul, mais il ne prédit qu'un mot à la fois, et c'est l'utilisateur qui écrit.

Personne ne demandait alors à un modèle de langage d'écrire seul un texte. Ceux qu'il produisait perdaient le fil au bout de quelques mots, comme le montre l'applet ci-dessous. Il faudra attendre les grands modèles de langage, et surtout ChatGPT, en 2022, pour que le modèle de langage passe au premier plan. Il n'est plus une pièce du système, il est le système. La même opération, prédire le mot suivant, suffit alors à répondre à des questions, à traduire, à résumer ou à écrire un programme.



Avant, le modèle de langage arbitrait entre des propositions faites par d'autres composants. Depuis 2022, il fait lui-même tout le travail.

Compter : les n-grammes

La façon la plus simple d'estimer ces probabilités est de compter. En 1913, le mathématicien russe Andreï Markov analyse les 20 000 premières lettres du roman en vers *Eugène Onéguine*, de Pouchkine. Il compte combien de fois une voyelle suit une voyelle, ou une consonne, et montre que ces enchaînements obéissent à des probabilités régulières. Ces suites où chaque élément dépend du précédent s'appellent depuis des **chaînes de Markov**. En 1948, Claude Shannon, le fondateur de la théorie de l'information, applique la même idée aux mots anglais. Il montre que des mots tirés au

hasard en tenant compte du mot précédent produisent des suites qui ressemblent de plus en plus à de l'anglais.

On appelle **n-gramme** une suite de n mots consécutifs. Un modèle à n-grammes prédit chaque mot d'après les $n-1$ mots qui le précèdent, en comptant dans un grand corpus de textes combien de fois chaque mot les a suivis. Le travail noté 4 construit un modèle à bigrammes ($n = 2$) dans un tableur.

En notation, un modèle à bigrammes remplace chaque facteur de la règle de la chaîne par une approximation qui ne garde que le mot précédent :

$$P(w_i \mid w_1, \dots, w_{i-1}) \approx P(w_i \mid w_{i-1})$$

C'est l'**hypothèse de Markov** : le passé lointain est oublié, seul compte le contexte immédiat. Un modèle à trigrammes garde les deux mots précédents, et ainsi de suite. Chaque probabilité s'estime ensuite en comptant :

$$P(w_i \mid w_{i-1}) = \frac{C(w_{i-1}\, w_i)}{C(w_{i-1})}$$

où C désigne le nombre d'occurrences dans le corpus. Si « capitaine » apparaît 1 000 fois dans un corpus, et « capitaine Nemo » 400 fois, alors $P(\text{Nemo} \mid \text{capitaine}) = 400/1000 = 0{,}4$.

L'applet ci-dessous contient un modèle à n-grammes entraîné sur deux romans de Jules Verne, *Le Tour du monde en quatre-vingts jours* et *Vingt mille lieues sous les mers*. À droite, elle affiche le contexte utilisé et les mots suivants les plus probables.

Applet interactive : à utiliser en ligne, sur la page « Des règles aux probabilités » du site du cours.

Quelques manipulations à faire :

1. Avec des n-grammes de taille 1, cliquez sur « Générer 40 mots ». Le modèle tire chaque mot selon sa seule fréquence dans les romans, et le texte n'a aucun sens.
2. Passez à la taille 2 et recommencez. Les paires de mots deviennent correctes (« Le capitaine Nemo »), mais les phrases partent dans toutes les directions.
3. Passez aux tailles 3 et 4. Le texte devient plus fluide, mais les passages surlignés se multiplient. Ce sont des suites d'au moins huit mots recopiées telles quelles des romans. Avec trois mots de contexte, la plupart des contextes n'apparaissent qu'une fois dans le corpus, et le modèle ne peut que recopier ce qui les suivait.
4. Cliquez plusieurs fois sur « Mot suivant » et observez la colonne de droite. Quand le contexte n'a jamais été vu, le modèle se replie sur un contexte plus court.
5. Faites varier la température, présentée au chapitre « Générer ».

L'applet montre la limite des n-grammes. Avec 20 000 mots de vocabulaire, il existe 8 000 milliards de suites possibles de trois mots, et même un corpus immense n'en contient qu'une infime partie. Plus le contexte est long, plus il est rare, et plus le modèle recopie au lieu de généraliser. C'est le sur-apprentissage (*overfitting*) présenté au Module 2. Surtout, un modèle à n-grammes ne sait rien de la ressemblance entre les mots : avoir vu « le chat dort sur le canapé » ne l'aide pas à prédire la suite de « le chien dort sur le ».

Les suites jamais vues : le lissage

Un modèle à n-grammes qui ne fait que compter donne une probabilité nulle à toute suite qu'il n'a jamais vue. C'est grave, parce que la probabilité d'une phrase est le produit des probabilités de ses mots : une seule suite inconnue rend la phrase entière impossible. Or presque tout texte nouveau contient des suites de trois mots jamais vues, même dans un corpus immense.

Le **lissage** (*smoothing*) retire un peu de probabilité aux suites observées pour la redistribuer aux suites jamais vues. Plusieurs méthodes se sont succédé.

- **Ajouter un.** On fait comme si chaque suite possible avait été vue une fois de plus qu'en réalité. C'est la règle de Laplace, du XVIIIe siècle. Pour des bigrammes, avec un vocabulaire de V mots :

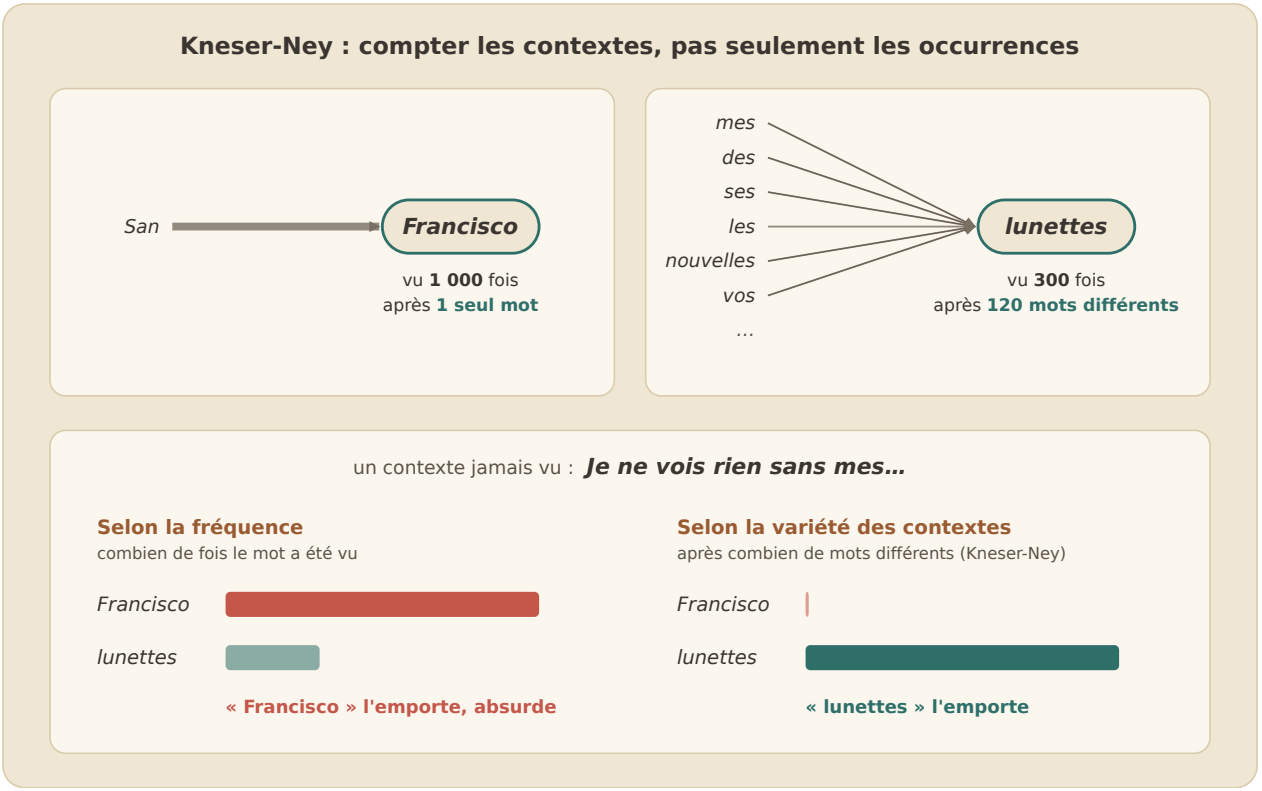
  $$P(w_i \mid w_{i-1}) = \frac{C(w_{i-1}\, w_i) + 1}{C(w_{i-1}) + V}$$

  Une suite jamais vue reçoit ainsi une probabilité de $1/(C(w_{i-1}) + V)$, petite mais pas nulle. La méthode est simple, mais avec un vocabulaire de dizaines de milliers de mots, elle donne beaucoup trop de probabilité aux suites inconnues.

- **Good et Turing.** Pendant la Seconde Guerre mondiale, à Bletchley Park, en déchiffrant Enigma, Alan Turing et son assistant I. J. Good mettent au point une façon d'estimer la probabilité de rencontrer un élément jamais vu, à partir du nombre d'éléments vus une seule fois. Si beaucoup de suites n'ont été vues qu'une fois, il en reste sans doute beaucoup à découvrir. Good publie la méthode en 1953.

- **Le repli** (*backoff*, Slava Katz, 1987). Quand le contexte de trois mots n'a jamais été vu, on se replie sur les deux derniers mots, puis sur le dernier. C'est ce que fait l'applet de la section précédente.

- **Kneser et Ney** (1995). Leur méthode tient compte de la variété des contextes dans lesquels un mot apparaît. « Francisco » est un mot fréquent, mais il ne suit presque jamais autre chose que « San ». Dans un contexte inconnu, il doit donc recevoir une probabilité faible, alors que « lunettes », moins fréquent mais qui suit toutes sortes de mots, doit en recevoir une forte. Quand il faut se replier, la probabilité d'un mot ne dépend donc pas de sa fréquence, mais du nombre de mots différents qui le précèdent. Cette méthode reste la meilleure jusqu'à l'arrivée des réseaux de neurones.



Dans un contexte jamais vu, Kneser-Ney ne demande pas combien de fois un mot a été vu, mais après combien de mots différents. Les nombres sont donnés à titre d'illustration.

Les formules du lissage (optionnel)

Good et Turing. Si N_1 est le nombre de suites vues une seule fois, et N le nombre total de suites observées, la probabilité que la prochaine suite soit nouvelle vaut environ

$$P(\text{suite jamais vue}) \approx \frac{N_1}{N}$$

Le repli de Katz. Pour un modèle à trigrammes :

$$P(w_i \mid w_{i-2}, w_{i-1}) = \begin{cases} P_3(w_i \mid w_{i-2}, w_{i-1}) & \text{si } C(w_{i-2}\, w_{i-1}\, w_i) > 0 \\ \alpha \cdot P(w_i \mid w_{i-1}) & \text{sinon} \end{cases}$$

où P_3 est l'estimation par comptage des trigrammes, et le facteur α redistribue la probabilité mise de côté.

Kneser et Ney. Quand il faut se replier, la probabilité d'un mot est proportionnelle au nombre de mots différents qui le précèdent dans le corpus :

$$P_{\text{KN}}(w) \propto \text{nombre de mots différents } v \text{ tels que } C(v\, w) > 0$$

Le symbole $\propto$ se lit « proportionnel à ».

Le lissage permet aussi de répondre à Chomsky. En 2000, Fernando Pereira entraîne un modèle lissé qui regroupe les mots en classes de mots semblables. Ce modèle juge « *Colorless green ideas sleep furiously* » environ 200 000 fois plus probable que la même phrase à l'envers. Un modèle statistique

peut donc distinguer deux phrases qu'il n'a jamais vues, à condition de généraliser au-delà des suites observées. C'est précisément ce que feront les modèles neuronaux du chapitre « Prédire le mot suivant ».

Mesurer un modèle : la perplexité

Pour comparer deux modèles de langage, il faut, comme pour les classificateurs du Module 2, une métrique, mesurée sur des données que le modèle n'a jamais vues, l'équivalent de l'ensemble de test. On présente donc aux modèles un texte mis de côté. Le taux de bonnes réponses conviendrait mal : avec des dizaines de milliers de mots possibles, même un bon modèle devine rarement le mot exact qui suit. On mesure plutôt la probabilité que chaque modèle donne aux mots qui viennent vraiment. Un bon modèle leur donne une probabilité élevée, même quand ce n'est pas le mot qu'il jugeait le plus probable.

La mesure habituelle est la **perplexité** (*perplexity*). Elle s'interprète simplement : une perplexité de 150 signifie que le modèle est, en moyenne, aussi incertain que s'il devait choisir chaque mot au hasard parmi 150 mots également probables. Plus elle est basse, mieux le modèle prédit. Sur des articles de journaux en anglais, un bon modèle à trigrammes lissé atteint une perplexité d'environ 150. Les modèles neuronaux l'ont fait baisser par étapes, et les grands modèles actuels descendent à quelques dizaines, ou moins, selon les textes et la façon de les découper en jetons.

La perplexité n'appartient pas au passé. L'erreur que les grands modèles de langage réduisent pendant leur entraînement est directement liée à leur perplexité : un LLM qui progresse est un LLM dont la perplexité baisse.

La perplexité en formule (optionnel)
Pour un texte de N mots $w_1, \dots, w_N$, la perplexité d'un modèle est

$$\begin{aligned} \mathrm{PP} &= P(w_1, \dots, w_N)^{-1/N} \\ &= \exp\Big(-\frac{1}{N} \sum_{i=1}^{N} \log P(w_i \mid w_1, \dots, w_{i-1}) \Big). \end{aligned}$$

La quantité dans l'exponentielle est la moyenne, sur tous les mots du texte, de $-\log P$ du mot qui vient vraiment. C'est l'**entropie croisée** (*cross-entropy*), l'erreur que minimise l'entraînement d'un modèle comme GPT. Si le modèle donnait à chaque mot une probabilité de $1/150$, la perplexité vaudrait exactement 150.

La suite de l'histoire

Les n-grammes ne voient que deux ou trois mots, et ils ne savent rien du sens. Le chapitre suivant présente les autres outils de l'ère statistique, qui ont dominé le traitement de la langue jusqu'au début des années 2010 : les modèles de Markov cachés, la traduction statistique, la représentation des documents, et les modèles qui étiquettent les mots.

Les outils statistiques

Chapitre d'approfondissement. Ce chapitre est facultatif. Il complète l'histoire du traitement de la langue commencée au chapitre précédent, mais la suite du module et le travail noté ne supposent pas de l'avoir lu.

Le chapitre « Des règles aux probabilités » a présenté le tournant statistique du traitement de la langue, et son premier outil, le modèle de langage à n-grammes. Des années 1970 au début des années 2010, d'autres outils statistiques s'y ajoutent. Ils servent à étiqueter les mots, à transcrire la parole, à traduire, à chercher des documents. Ce chapitre en présente quatre : les modèles de Markov cachés, la traduction statistique, la représentation des documents, et les modèles qui étiquettent les mots à partir de caractéristiques choisies à la main.

Chacun a été remplacé par des réseaux de neurones au cours des années 2010. Mais chacun a laissé une idée que l'on retrouve dans les grands modèles de langage.

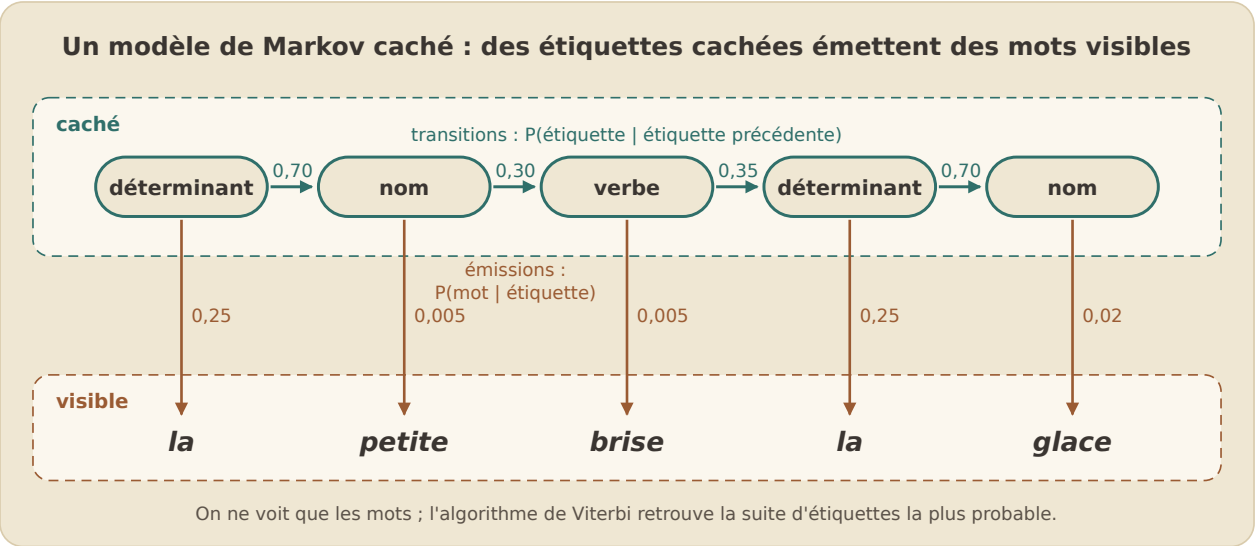
Les modèles de Markov cachés

Un texte est une suite de mots, mais derrière cette suite se cache une structure qu'on ne voit pas directement : le rôle grammatical de chaque mot. Dans « la petite brise la glace », le premier « la » est un déterminant, et le second peut être un déterminant ou un pronom. « Brise » peut être un nom ou un verbe. Retrouver ces rôles s'appelle l'**étiquetage grammatical** (*part-of-speech tagging*), et c'est souvent la première étape d'un système de traitement de la langue.

Un **modèle de Markov caché** (*hidden Markov model*, HMM) décrit cette situation. Il suppose qu'une suite d'**états cachés**, ici les étiquettes grammaticales, se déroule comme une chaîne de Markov : chaque étiquette dépend de la précédente. Chaque état caché produit, ou **émet**, un mot visible. Le modèle tient donc deux tables de probabilités.

- Les **transitions** donnent la probabilité de passer d'une étiquette à une autre : après un déterminant, un nom est très probable, un verbe très improbable.
- Les **émissions** donnent la probabilité qu'une étiquette produise un mot donné : un nom peut être « brise », « glace », « porte », avec des probabilités différentes.

Les deux tables s'estiment en comptant dans un corpus annoté, comme le Penn Treebank. On peut même les apprendre sans annotations, avec l'algorithme de Baum-Welch, mis au point par Leonard Baum et ses collègues à la fin des années 1960.



Un modèle de Markov caché. La probabilité d'une lecture est le produit des transitions et des émissions le long de la phrase.

Pour étiqueter une phrase, il faut trouver la suite d'étiquettes la plus probable compte tenu des mots observés. Le nombre de suites possibles explose : avec sept étiquettes, une phrase de vingt mots en admet près de 80 millions de milliards. En 1967, Andrew Viterbi, un ingénieur en télécommunications qui fondera plus tard l'entreprise Qualcomm, publie un algorithme qui contourne cette explosion. Pour chaque mot et chaque étiquette, l'**algorithme de Viterbi** ne garde que le meilleur chemin qui y mène, puis prolonge ces chemins d'un mot à l'autre. Le travail ne croît plus qu'en proportion de la longueur de la phrase.

L'applet ci-dessous contient un petit HMM pour le français. Ses probabilités ont été fixées à la main, pour l'exemple. Chaque colonne correspond à un mot, chaque rangée à une étiquette, et les cases vides sont les étiquettes impossibles pour ce mot. Le trait vert est le chemin trouvé par l'algorithme de Viterbi.

Applet interactive : à utiliser en ligne, sur la page « Les outils statistiques » du site du cours.

Quelques manipulations à faire :

1. Avec « la petite brise la glace », le modèle lit « la petite (fille) brise la glace ». Cliquez sur la case « nom » de *brise* pour imposer cette étiquette. Le modèle trouve alors l'autre lecture, « la petite brise (vent) la glace (gèle) », et indique combien elle est moins probable.
2. Choisissez « les poules du couvent couvent ». Le même mot reçoit deux étiquettes différentes, selon le mot qui le précède.
3. Observez la liste des facteurs sous le treillis. La probabilité d'une lecture est le produit des transitions et des émissions, mot après mot.

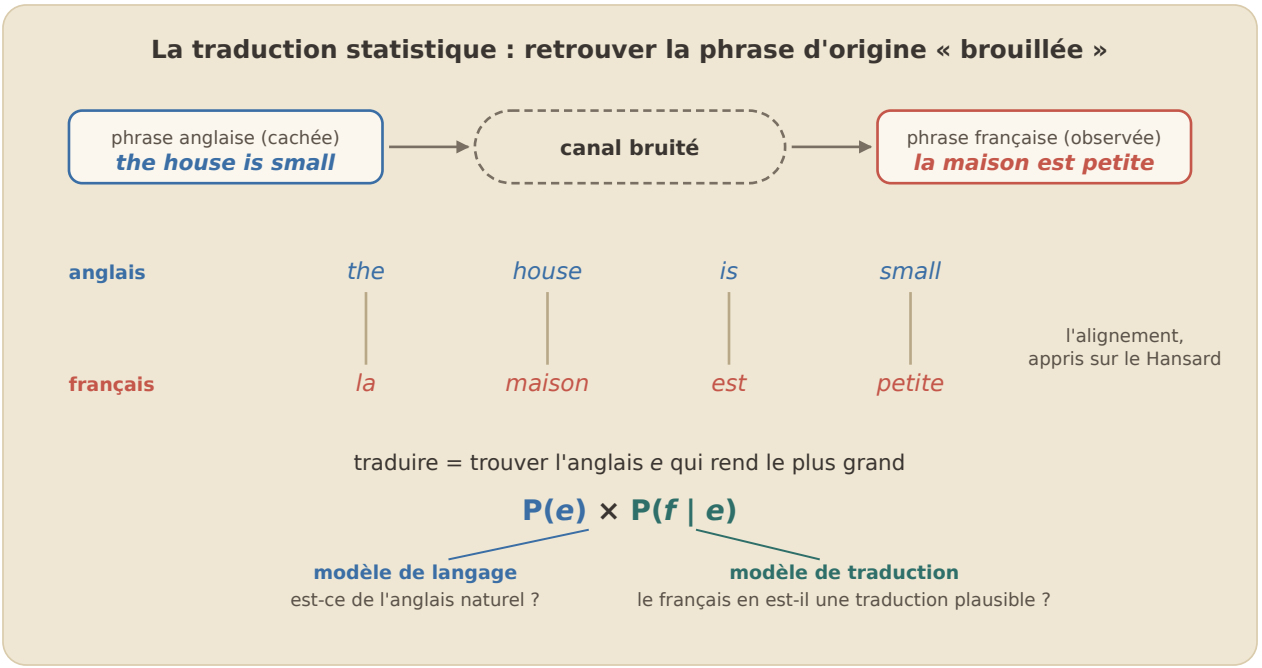
Les HMM ont été l'outil central de la **reconnaissance de la parole** pendant trente ans. Les états cachés y sont les sons de la langue, et les observations, des mesures du signal sonore prises toutes les quelques millisecondes. Ils ont aussi servi à repérer les gènes dans l'ADN. Ils ont été remplacés par des réseaux de neurones au début des années 2010. L'idée d'un **état caché** qui résume ce qui précède, elle, est restée : c'est la mémoire des réseaux récurrents du Module 3, devenue un vecteur de nombres plutôt qu'une étiquette.

La traduction comme un canal bruité

En 1949, peu après les travaux de Shannon sur la communication, le mathématicien Warren Weaver propose de voir un texte russe comme un texte anglais chiffré, qu'il suffirait de déchiffrer. L'idée reste sans suite pendant quarante ans, puis l'équipe d'IBM qui a réussi la reconnaissance de la parole l'applique à la traduction, vers 1990.

Elle repose sur le **canal bruité** (*noisy channel*). On imagine que la phrase française qu'on veut traduire était, au départ, une phrase anglaise, déformée en traversant un canal qui la « brouille ». Traduire, c'est retrouver la phrase anglaise la plus probable. Selon la règle de Bayes du Module 2, cela revient à chercher la phrase anglaise e qui rend le plus grand le produit de deux probabilités :

- $P(e)$, donnée par un **modèle de langage** de l'anglais, qui juge si la phrase est de l'anglais naturel ;
- $P(f \mid e)$, donnée par un **modèle de traduction**, qui juge si la phrase française f en est une traduction plausible.



La traduction statistique d'IBM : un modèle de langage, qui juge si la phrase est naturelle, et un modèle de traduction, appris sur le Hansard, qui juge si elle correspond au texte d'origine.

Le modèle de traduction s'apprend sur des textes déjà traduits, comme le Hansard canadien présenté au chapitre « Des règles aux probabilités ». Personne n'y indique quel mot traduit quel mot. Le modèle le découvre seul, en remarquant que « maison » apparaît presque toujours dans les phrases anglaises qui contiennent « house ». Ces correspondances s'appellent l'**alignement** des mots. Les cinq « modèles IBM », publiés entre 1990 et 1993, apprennent des alignements de plus en plus fins, en tenant compte de l'ordre des mots et des mots qui se traduisent par plusieurs.

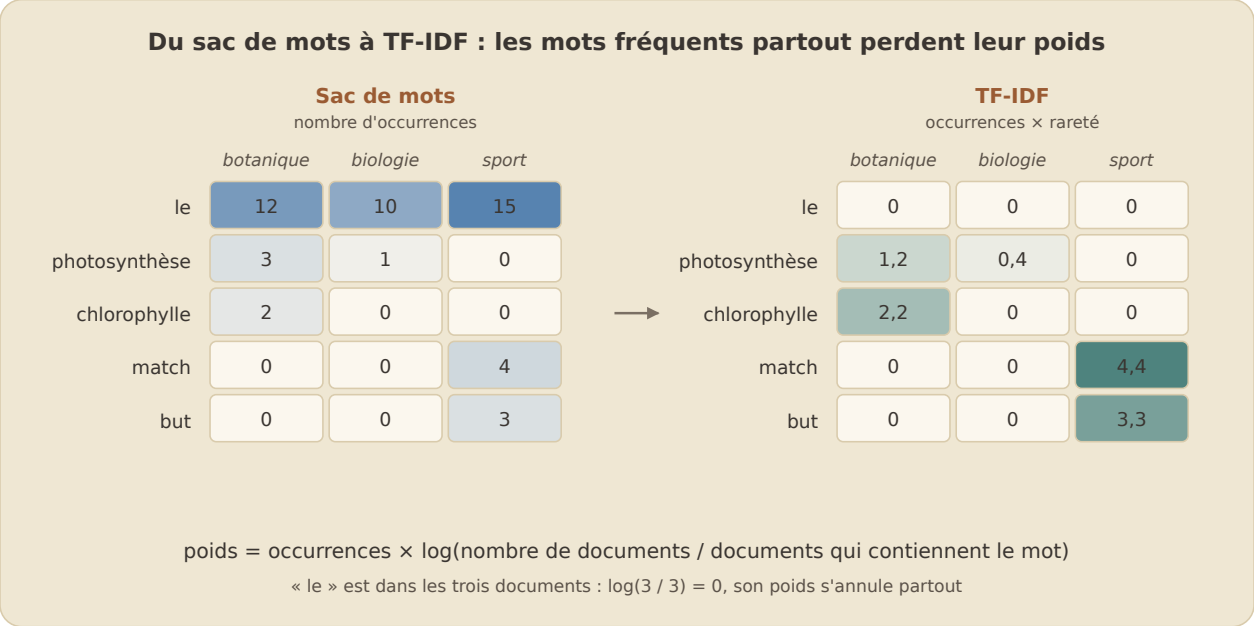
À partir de 2003, la traduction par **segments** (*phrase-based*) aligne des groupes de mots plutôt que des mots isolés. C'est la technique de Google Traduction, lancé en 2006, et du logiciel libre Moses, publié en 2007. Ce sont ces systèmes que la traduction neuronale présentée au Module 3 remplace à partir de 2016.

Le canal bruité a laissé une idée durable : combiner un modèle de langage, qui assure que le texte produit est naturel, avec une information sur ce qu'on veut obtenir. C'est la génération conditionnelle présentée au début de ce module. Un LLM qui traduit fait la même chose, mais en un seul modèle : il prédit la suite du texte en tenant compte de la phrase à traduire.

Représenter des documents

Pour classer des courriels, chercher des pages Web ou recommander des articles, il faut représenter un document entier par des nombres. La solution la plus simple est le sac de mots du Module 2 : on compte combien de fois chaque mot apparaît dans le document, sans tenir compte de l'ordre.

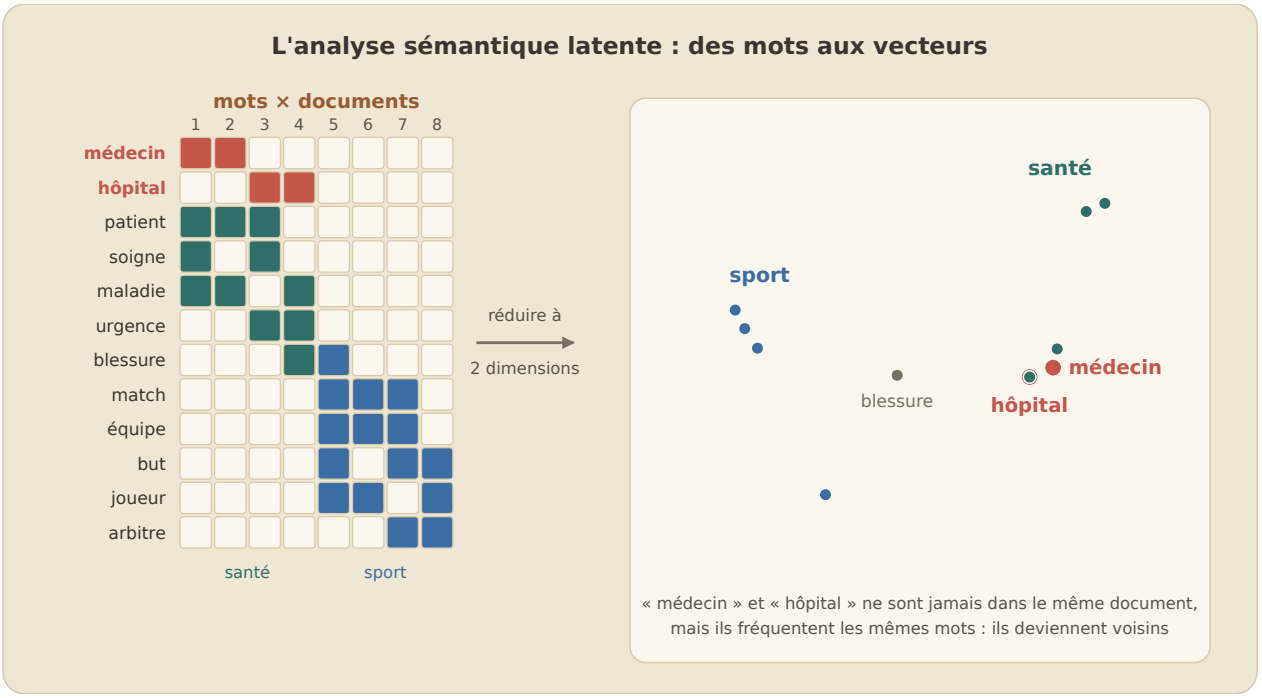
Tous les mots ne se valent pas. « Le » apparaît dans tous les documents et ne dit rien de leur sujet. « Photosynthèse » est rare, et sa présence en dit beaucoup. En 1972, l'informaticienne britannique Karen Spärck Jones propose de pondérer chaque mot par sa rareté dans l'ensemble des documents. La pondération **TF-IDF** (*term frequency – inverse document frequency*) donne un poids élevé aux mots fréquents dans un document mais rares ailleurs. Avec la représentation des documents par des vecteurs, développée par Gerard Salton à l'Université Cornell, elle est au cœur des moteurs de recherche pendant des décennies.



Le sac de mots compte les occurrences ; TF-IDF les multiplie par la rareté du mot. Un mot présent dans tous les documents, comme « le », ne distingue plus rien et son poids s'annule.

En 1990, une équipe des laboratoires Bellcore pousse l'idée plus loin avec l'**analyse sémantique latente** (*latent semantic analysis*, LSA). On construit un immense tableau qui indique combien de fois chaque mot apparaît dans chaque document, puis on le réduit à quelques centaines de dimensions, par une méthode proche de la PCA du Module 2. Chaque mot y reçoit un vecteur, et deux mots qui apparaissent dans des documents semblables, entourés des mêmes autres mots, reçoivent des vecteurs voisins, même s'ils n'apparaissent jamais dans le même document. C'est le cas de « médecin » et « hôpital » dans la figure ci-dessous. Ce sont les premiers vecteurs de mots, fondés sur la même

idée que les plongements modernes : on reconnaît un mot à ses fréquentations. Le mot « latent » a d'ailleurs le même sens que dans l'espace latent des générateurs d'images.



Une LSA calculée sur huit petits documents. Réduit à deux dimensions, le tableau mots × documents donne à chaque mot un vecteur. « Médecin » et « hôpital » deviennent voisins parce qu'ils fréquentent les mêmes mots, sans jamais se rencontrer.

Étiqueter avec des caractéristiques faites à la main

Dans les années 1990 et 2000, la plupart des tâches du traitement de la langue sont traitées par des modèles **discriminants**, au sens du chapitre « Classer » du Module 2 : la régression logistique, que les linguistes appellent alors modèle à **entropie maximale** (*maximum entropy*, 1996), les machines à vecteurs de support, et les **champs aléatoires conditionnels** (*conditional random fields*, CRF), présentés en 2001 par John Lafferty, Andrew McCallum et Fernando Pereira. Les CRF étiquettent une suite de mots comme un HMM, mais en tenant compte d'autant d'indices qu'on veut.

Ces indices, les **caractéristiques**, sont écrits à la main par des spécialistes. Pour repérer les **entités nommées** (*named entities*), c'est-à-dire les noms de personnes, de lieux et d'organisations, un système typique utilise des caractéristiques comme « le mot commence par une majuscule », « le mot précédent est *M.* », « le mot se termine par *-ville* », « le mot figure dans une liste de villes ». Un bon système en compte des centaines de milliers. Ce sont les caractéristiques du Module 2, choisies à la main et multipliées à l'extrême.

Les systèmes complets enchaînent plusieurs de ces modèles : découper le texte en mots, étiqueter leur rôle grammatical, analyser la structure de la phrase, repérer les entités, puis répondre à la question posée. Chaque étape repose sur les résultats de la précédente, et ses erreurs se propagent à toutes les suivantes. Le système Watson d'IBM, qui gagne le jeu télévisé *Jeopardy!* en 2011, présenté au Module 1, assemble ainsi des centaines de composants de ce genre.

Ce qui manquait

Au début des années 2010, les outils statistiques ont transformé le traitement de la langue. La reconnaissance de la parole fonctionne au téléphone, la traduction automatique est utilisée par des millions de personnes, les moteurs de recherche trouvent ce qu'on cherche. Quatre limites demeurent pourtant.

- **Un contexte très court.** Un modèle à trigrammes ne voit que deux mots en arrière, un HMM ne retient que l'étiquette précédente.
- **Des mots sans ressemblance.** Pour un modèle à n-grammes, « chat » et « chien » sont deux symboles sans rapport. Ce qu'il apprend sur l'un ne profite pas à l'autre.
- **Des caractéristiques faites à la main**, différentes pour chaque tâche et chaque langue, qui demandent des années de travail.
- **Un modèle par tâche**, et des chaînes de traitement fragiles.

Les réseaux de neurones vont s'attaquer à ces limites. Le chapitre suivant commence par la deuxième : donner aux mots des représentations qui se ressemblent quand leurs sens se ressemblent. Le chapitre « Prédire le mot suivant » présente ensuite les modèles de langage neuronaux. Ils apprennent eux-mêmes leurs représentations des mots au lieu de recevoir des caractéristiques choisies à la main, tiennent compte d'un contexte de plus en plus long, et un seul d'entre eux, entraîné à prédire le mot suivant, finit par accomplir de nombreuses tâches.

Des mots aux nombres : jetons et plongements

Le chapitre « Les outils statistiques » s'achevait sur une limite : pour un modèle à n-grammes, « chat » et « chien » sont deux symboles sans rapport. Ce chapitre ouvre l'ère des réseaux de neurones par cette question. Le chapitre « Lire une séquence : les réseaux récurrents » du Module 3 en laissait d'ailleurs une autre de côté. Un réseau de neurones ne manipule que des nombres, alors que le texte est fait de mots. Avant qu'un modèle de langage puisse lire ou écrire une phrase, il faut donc convertir les mots en nombres.

Cette question paraît technique, mais elle touche au sens des mots. Elle demande deux opérations. Il faut d'abord **découper** le texte en morceaux, puis **représenter** chaque morceau par des nombres. Ce chapitre présente les deux, avec de vrais outils : le découpage utilisé par un modèle d'OpenAI, et des représentations de mots apprises sur des milliards de mots de français.

Découper le texte : les jetons

Avant de représenter les mots par des nombres, il faut décider de ce qu'est un mot. Un vocabulaire de mots entiers pose un problème pratique. Que faire d'un mot qui n'y figure pas, comme un nom propre, un mot rare, une faute de frappe, un mot d'une autre langue ou un mot inventé ? Aucune liste de mots ne peut tout prévoir.

Les modèles de langage découpent donc le texte en morceaux plus petits que les mots, qu'on appelle des **jetons** (*tokens*). La méthode la plus utilisée, le **codage par paires d'octets** (*byte pair encoding*, BPE), vient de la compression de données. Elle a été adaptée à la traduction automatique en 2015 par Rico Sennrich et ses collègues, à l'Université d'Édimbourg. Elle fonctionne ainsi :

1. on part des caractères individuels ;
2. on cherche, dans un très grand corpus de textes, la paire de morceaux voisins la plus fréquente, par exemple *e* suivi d'*s* ;
3. on fusionne cette paire en un nouveau morceau, *es*, qu'on ajoute au vocabulaire ;
4. on recommence, jusqu'à obtenir la taille de vocabulaire voulue.

Les mots fréquents finissent par devenir un seul jeton. Les mots rares restent découpés en plusieurs morceaux, mais ils peuvent toujours être écrits, au pire caractère par caractère. Les modèles actuels utilisent des vocabulaires de 100 000 à 200 000 jetons.

L'applet ci-dessous découpe un texte avec le vocabulaire de GPT-4o, un modèle d'OpenAI.

Applet interactive : à utiliser en ligne, sur la page « Des mots aux nombres : jetons et plongements » du site du cours.

Quelques manipulations à faire :

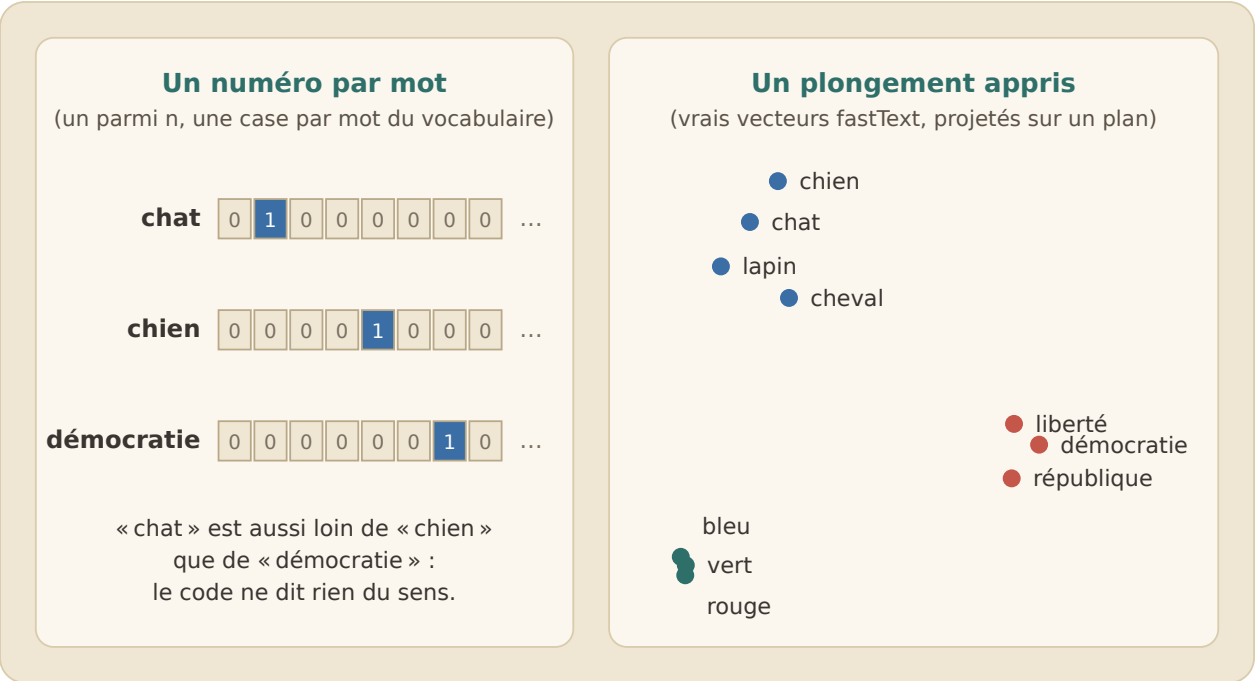
1. Comparez la phrase en français et la même phrase en anglais. La phrase française demande nettement plus de jetons. Le vocabulaire a été construit sur des textes majoritairement anglais, où les mots anglais sont plus fréquents et sont donc devenus des jetons entiers. Comme l'usage de ces modèles est souvent facturé au jeton, un même texte coûte plus cher dans certaines langues que dans d'autres.
2. Regardez le mot rare et le verbe « découpent ». Ils sont coupés en morceaux qui ne correspondent pas toujours aux syllabes ni aux préfixes.
3. Choisissez l'exemple *strawberry*. Dans la question *How many r's are in the word strawberry?*, le mot, avec l'espace qui le précède, forme un seul jeton : le modèle reçoit un seul numéro, et non les dix lettres du mot. Écrit seul, sans espace devant, il serait découpé en trois jetons (*st*, *raw*, *berry*), qui ne montrent pas davantage ses lettres. L'encadré « Combien de *r* dans *strawberry* ? » du chapitre « Ce que les LLM comprennent, et ce qu'ils ratent » explique ce que cela change quand on demande à un modèle de compter les lettres d'un mot.
4. Regardez les nombres. « 12 345 » et « 38 781,93 » sont coupés en groupes de chiffres, ce qui complique le calcul.

La première idée : un numéro par mot

Une fois le texte découpé, il faut représenter chaque jeton par des nombres. Pour simplifier, parlons de mots : les mots courants sont de toute façon des jetons entiers. On pourrait se contenter de numéroter les mots du vocabulaire, de 1 à 100 000, et de donner au réseau le numéro de chaque mot. Cela ne fonctionne pas. Un neurone traite ses entrées comme des quantités : il les multiplie par des poids et les additionne. Le numéro deviendrait donc une grandeur. Si « chat » porte le numéro 8 112 et « chaise » le numéro 8 113, le réseau les traiterait comme presque identiques, simplement parce qu'ils se suivent dans la liste. Et le mot numéro 40 000 pèserait cinq fois plus que le mot numéro 8 000. Or l'ordre de la liste est arbitraire, et ces écarts ne veulent rien dire.

La solution consiste plutôt à numéroter les mots, puis à représenter chaque mot par une liste de zéros, avec un seul 1 à la position de son numéro. Si le vocabulaire compte 100 000 mots, chaque mot devient une liste de 100 000 nombres. On appelle ce code **un parmi *n*** (*one-hot encoding*). Le sac de mots du Module 2, qui représentait un courriel par les mots qu'il contient, était construit de cette façon.

Ce code a un défaut. Tous les mots y sont à la même distance les uns des autres : « chat » est aussi loin de « chien » que de « démocratie ». Le code identifie les mots, mais il ne dit rien de leur sens. Un modèle qui a appris quelque chose sur les chats ne peut rien en tirer pour les chiens.



À gauche, le code un parmi n ne dit rien du sens. À droite, de vrais plongements, projetés sur un plan : les mots de sens voisin sont proches.

On reconnaît un mot à ses fréquentations

Pour que les nombres reflètent le sens des mots, il faut une autre idée. Elle vient de la linguistique.

Un mot inconnu
Que signifie le mot *tezgüino*, dans les phrases suivantes ?

- Il y a une bouteille de tezgüino sur la table.
- Tout le monde aime le tezgüino.
- Le tezgüino rend ivre.
- On fabrique le tezgüino avec du maïs.

Personne n'a besoin d'une définition pour comprendre qu'il s'agit d'une boisson alcoolisée, faite à partir de maïs. Les phrases où le mot apparaît suffisent. Cet exemple, souvent repris en linguistique informatique, s'inspire d'une boisson réelle, une bière de maïs fabriquée au Mexique.

C'est l'**hypothèse distributionnelle** (*distributional hypothesis*) : des mots qui apparaissent dans les mêmes contextes ont des sens proches. Elle a été formulée dans les années 1950 par des linguistes, notamment l'Américain Zellig Harris en 1954. Le Britannique John Rupert Firth l'a résumée en 1957 par une formule souvent citée, « *You shall know a word by the company it keeps* » (« on reconnaît un mot à ses fréquentations »).

Cette idée s'oppose à celle des réseaux sémantiques du Module 1, où des humains décrivaient à la main le sens des mots et leurs relations, comme « un chat est un animal ». Ici, le sens n'est décrit par personne : il est déduit de l'usage, en observant quels mots apparaissent ensemble dans d'énormes quantités de texte.

Compter les voisins

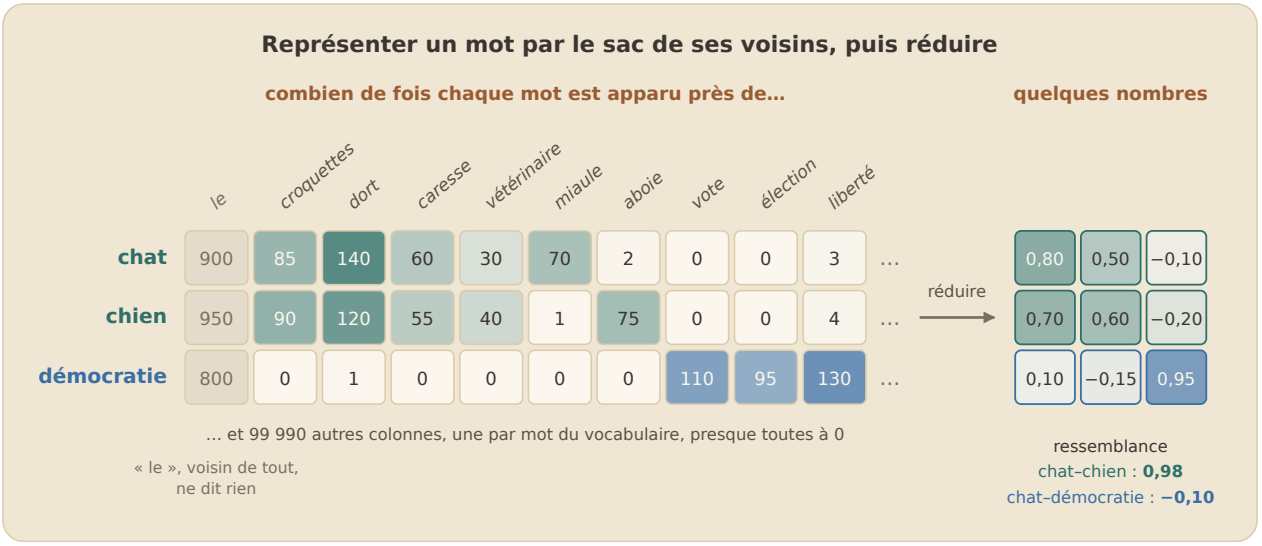
La façon la plus directe d'appliquer cette idée est de compter. On parcourt un grand corpus, et pour chaque mot, on note les mots qui apparaissent près de lui, par exemple dans une fenêtre de deux mots avant et deux mots après. Chaque mot est alors représenté par un **sac de ses mots voisins** : une longue liste qui indique combien de fois chaque mot du vocabulaire est apparu à côté de lui. C'est le sac de mots du Module 2, mais construit autour d'un mot plutôt que d'un document.

Ces listes ont exactement le comportement recherché. « Chat » et « chien » ont beaucoup de voisins communs (*croquettes*, *dort*, *caresse*, *vétérinaire*), donc des listes qui se ressemblent. « Démocratie » a des voisins tout différents (*vote*, *élection*, *liberté*). La ressemblance entre deux mots se mesure en comparant leurs listes.

Ces vecteurs ont pourtant deux défauts.

- **Ils sont immenses.** Avec un vocabulaire de 100 000 mots, chaque mot devient une liste de 100 000 nombres, presque tous nuls.
- **Les mots très fréquents dominent.** « Le » ou « de » sont voisins de tout, et ne disent rien. On les pondère, comme le fait TF-IDF pour les documents.

La solution est celle de l'analyse sémantique latente, qui compte les mots de chaque document puis réduit le tableau obtenu. On réduit de même ces listes à quelques centaines de nombres, en gardant l'essentiel de leurs ressemblances. On obtient des vecteurs compacts, où chaque nombre résume une tendance de l'usage plutôt qu'un voisin précis.



Chaque mot est d'abord représenté par le sac de ses voisins, une liste immense et presque vide. Réduite à quelques nombres, elle garde l'essentiel : chat et chien restent proches, démocratie reste loin. Les nombres sont donnés à titre d'illustration.

Les plongements

En 2013, Tomas Mikolov et ses collègues, chez Google, publient **word2vec**, une méthode simple et rapide qui obtient directement ces vecteurs compacts, sans passer par l'immense tableau des voisins. Chaque mot reçoit une liste de quelques centaines de nombres, au départ tirés au hasard. Un petit réseau de neurones est ensuite entraîné sur des milliards de mots de texte à une tâche simple : à

partir d'un mot, prédire les mots qui l'entourent. C'est un cas d'auto-supervision, puisque le texte fournit lui-même les réponses. Pendant l'entraînement, la rétropropagation ajuste les nombres de chaque mot. Deux mots qui apparaissent dans les mêmes contextes, comme « chat » et « chien », finissent par recevoir des listes de nombres voisines. En 2014, Omer Levy et Yoav Goldberg ont d'ailleurs montré que word2vec revient, en pratique, à résumer un tableau de voisins pondéré : les deux approches se rejoignent. L'idée d'apprendre les plongements par un réseau de neurones n'était cependant pas nouvelle. Le modèle de langage neuronal de 2003, présenté au chapitre « Prédire le mot suivant », apprenait déjà les siens en même temps que le reste de ses paramètres ; word2vec a rendu la méthode assez simple et rapide pour des milliards de mots.

Chaque mot devient ainsi un point dans un espace de quelques centaines de dimensions, où la distance entre deux points correspond à la différence de sens. On parle de **plongement** (*embedding*), parce que les mots sont plongés dans un espace géométrique. La ressemblance entre deux mots se mesure par l'angle entre leurs vecteurs : deux vecteurs de même direction ont une ressemblance de 1, deux vecteurs perpendiculaires une ressemblance de 0.

Certaines relations entre les mots deviennent alors des déplacements dans cet espace. Le déplacement qui mène de « homme » à « roi » ressemble à celui qui mène de « femme » à « reine ». On peut donc calculer *roi* − *homme* + *femme*, puis chercher le mot le plus proche du résultat. On trouve « reine ». Ces **analogies** ont fait la réputation de word2vec, mais elles ne fonctionnent pas toujours, comme le montre l'applet ci-dessous.

L'applet utilise de vrais plongements, ceux que l'entreprise Facebook (aujourd'hui Meta) a publiés en 2018 pour 157 langues, avec une méthode proche de word2vec (fastText). Ceux du français ont été appris sur des milliards de mots de pages Web. L'applet en contient 17 258, les plus fréquents.

Applet interactive : à utiliser en ligne, sur la page « Des mots aux nombres : jetons et plongements » du site du cours.

Quelques manipulations à faire :

1. Dans l'onglet « Voisins d'un mot », cherchez les voisins de « chat », puis de « Montréal ». Les voisins de « Montréal » sont d'autres villes canadiennes, « Sherbrooke », « Toronto », « Québec ». Personne n'a indiqué au modèle qu'il s'agit de villes, ni qu'elles sont au Canada.
2. Dans l'onglet « Analogies », essayez *homme : roi :: femme : ?*. Essayez ensuite *France : Paris :: Italie : ?*. Le résultat contient des villes italiennes, Turin, Naples ou Milan, mais pas Rome en premier. L'analogie retrouve le type de relation (une grande ville du pays), sans la retrouver exactement.
3. Essayez *France : Paris :: Canada : ?*. La réponse est Toronto, avant Ottawa. Le modèle a appris ce que les textes associent le plus souvent au Canada et à une grande ville, pas la notion de capitale.
4. Dans l'onglet « Carte », choisissez le groupe « pays et capitales ». Les pays et les capitales se répartissent en deux régions. Essayez aussi vos propres mots.

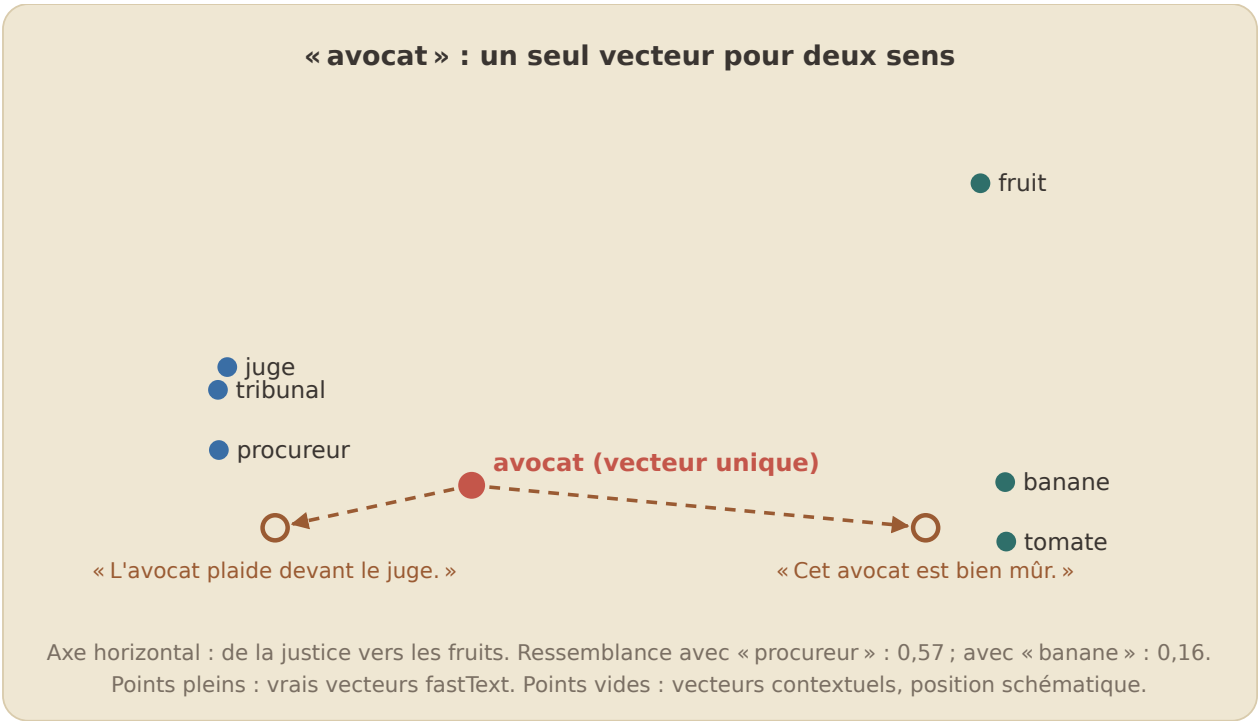
Les plongements héritent des préjugés

Les plongements reflètent les textes sur lesquels ils ont été appris, y compris leurs stéréotypes. En 2016, Tolga Bolukbasi et ses collègues analysent des plongements word2vec appris sur des articles de presse. Ils y trouvent des analogies comme « homme est à programmeur ce que femme est à ménagère », qui a donné son titre à leur article.

L'applet le montre aussi. Dans l'onglet « Analogies », essayez *homme : médecin :: femme : ?*. La réponse est « infirmière ». Le modèle n'a pas de préjugé propre : il reproduit les associations les plus fréquentes dans les textes. Mais un système construit sur ces plongements, par exemple un outil de tri de candidatures, les appliquerait de façon systématique. C'est le biais des données présenté au Module 2. Le Module 5 revient sur ces questions.

Le même mot, plusieurs sens

Le mot « avocat » désigne un juriste ou un fruit. Un plongement comme ceux de word2vec ou de fastText n'attribue pourtant qu'un seul vecteur à chaque mot, quel que soit son sens dans la phrase. Ce vecteur est une sorte de moyenne de tous les emplois du mot. Comme « avocat » désigne bien plus souvent un juriste, son vecteur se trouve du côté de la justice. Dans l'applet, ses plus proches voisins sont des professions, surtout juridiques, et aucun fruit n'y figure.



Un plongement fixe donne un seul vecteur à « avocat », du côté de la justice. Un plongement contextuel calcule un vecteur différent pour chaque phrase.

La solution consiste à calculer le vecteur d'un mot **d'après la phrase où il apparaît**. Dans « L'avocat plaide devant le juge », le vecteur d'« avocat » doit se rapprocher de « juge » ; dans « Cet avocat est bien mûr », il doit se rapprocher des fruits. En 2018, deux modèles le font pour la première fois à grande échelle : ELMo, de l'Allen Institute for AI, avec des réseaux récurrents, puis BERT, de Google, avec un Transformer. On parle de **plongements contextuels** (*contextual embeddings*).

C'est exactement ce que fait l'auto-attention présentée au Module 3. Chaque mot interroge les autres mots de la phrase, et son vecteur est modifié par ce qu'il y trouve. Dans un grand modèle de langage, chaque jeton entre dans le Transformer avec son plongement fixe, puis ce vecteur est modifié couche après couche, d'après tout le texte qui précède.

Tout devient vecteur

Les plongements ne se limitent pas aux mots. On sait aujourd'hui représenter par un vecteur une phrase, un paragraphe, une image, un son, une protéine ou un produit dans un catalogue. Deux éléments de sens voisin reçoivent des vecteurs proches.

Cette idée a de nombreux usages.

- **La recherche par le sens.** Un moteur de recherche qui compare des vecteurs de phrases trouve un document qui répond à une question, même s'il n'utilise aucun des mots de la question. Le chapitre « Des outils, un harnais et des agents » y reviendra.
- **La recommandation.** Les plateformes de musique ou de vidéo représentent chaque morceau et chaque utilisateur par un vecteur, et proposent les morceaux proches.
- **Les liens entre images et textes.** Si une image et sa légende reçoivent des vecteurs proches, on peut chercher une image avec une phrase, ou guider la génération d'une image par un texte. C'est le sujet du chapitre « Relier les mots et les images ».

Les mots sont maintenant des vecteurs, et le Transformer sait les modifier d'après leur contexte. Le chapitre suivant montre comment un modèle s'en sert pour prédire le mot suivant d'un texte, et pour écrire.

Prédire le mot suivant

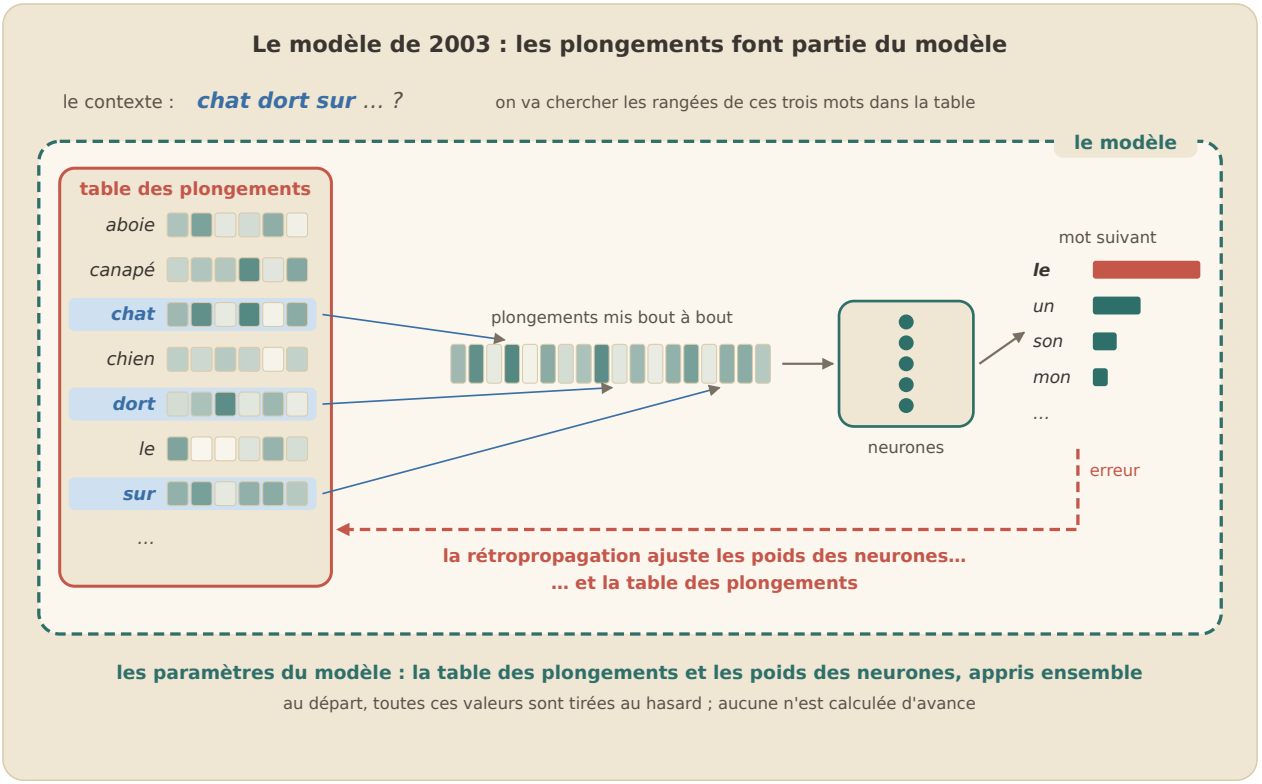
Le chapitre « Quatre façons de générer » a présenté la famille des modèles **autorégressifs**, qui génèrent une donnée un élément après l'autre. Les grands modèles de langage en font partie. Tout ce qu'ils font, répondre à une question, traduire, résumer, écrire un programme, repose sur une seule opération, répétée des milliers de fois : prédire le jeton suivant d'un texte.

Les chapitres « Des règles aux probabilités » et « Les outils statistiques » ont présenté le modèle de langage et ses premières versions, fondées sur le comptage. Ce chapitre présente la troisième ère, celle des réseaux de neurones, jusqu'aux modèles actuels. Il s'appuie sur les jetons et les plongements présentés au chapitre « Des mots aux nombres ».

Généraliser : les modèles neuronaux

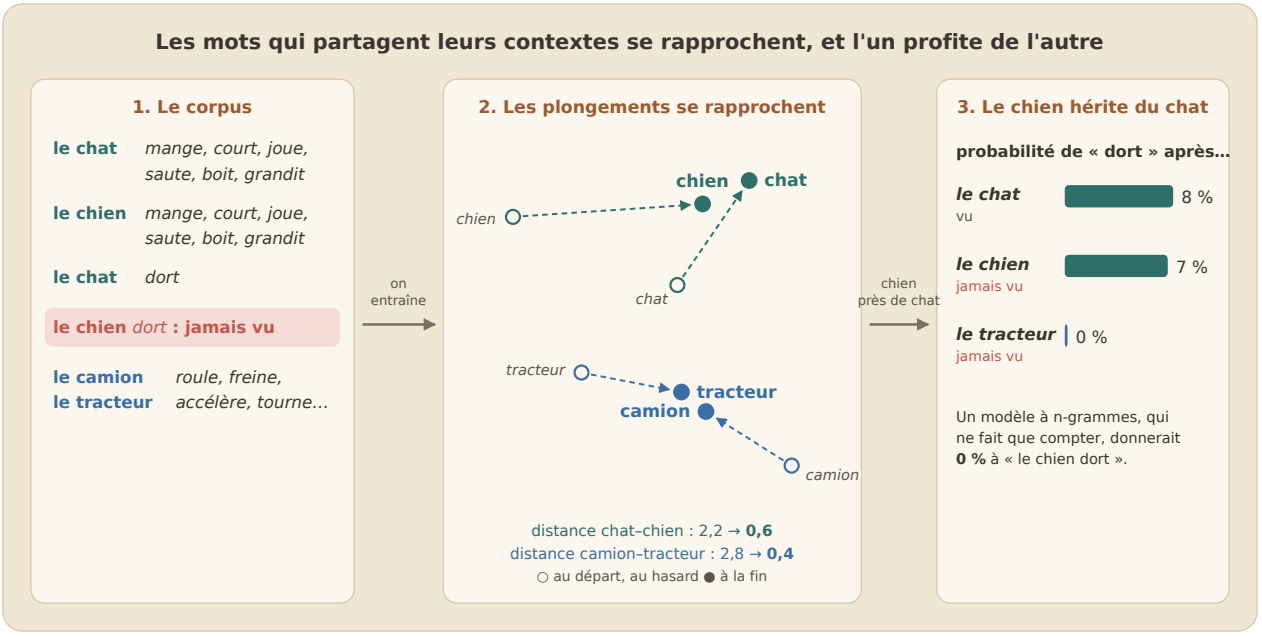
En 2003, Yoshua Bengio, Réjean Ducharme, Pascal Vincent et Christian Jauvin, à l'Université de Montréal, publient un article intitulé « A Neural Probabilistic Language Model » (Christian Jauvin est l'auteur de ce cours). Ils remplacent le comptage par un réseau de neurones, avec une idée centrale : les plongements des mots ne sont pas calculés d'avance, ils sont **appris** par le réseau, en même temps que tout le reste.

Concrètement, le modèle contient une table qui associe à chaque mot du vocabulaire une liste de quelques dizaines de nombres. Au départ, ces nombres sont tirés au hasard. La table fait partie des **paramètres** du modèle, au même titre que les poids de ses neurones. Le réseau lit les plongements des mots précédents et prédit le mot suivant. À chaque erreur, la rétropropagation ajuste les poids des neurones, mais aussi les nombres des plongements qui ont servi à la prédiction. Il n'y a aucune étape séparée pour compter les voisins puis réduire un tableau, comme dans la section « Compter les voisins ». Les plongements prennent simplement la forme qui aide le plus à prédire.



Le modèle de langage neuronal de 2003. La table des plongements est à l'intérieur du modèle : comme les poids des neurones, elle part de valeurs tirées au hasard et s'ajuste à chaque erreur. Valeurs données à titre d'illustration.

Le résultat rejoint l'hypothèse distributionnelle. Comme « chat » et « chien » apparaissent dans les mêmes contextes, la rétropropagation les pousse vers des plongements voisins, et ce que le modèle apprend sur l'un profite à l'autre. Le modèle peut ainsi donner une probabilité raisonnable à des suites qu'il n'a jamais vues. C'est la généralisation que les n-grammes, même lissés, ne pouvaient pas atteindre. Dix ans plus tard, word2vec reprend cette idée en la simplifiant à l'extrême, pour l'appliquer à des milliards de mots. Aujourd'hui encore, la table des plongements est la première couche de tout grand modèle de langage : chaque jeton du vocabulaire y a son plongement, appris comme le reste. C'est l'un des travaux fondateurs de l'école canadienne de l'apprentissage profond.



Une petite expérience réelle : un modèle du même type que celui de 2003, avec des plongements à deux dimensions, entraîné sur un corpus jouet où chat et chien partagent six verbes, et où seul le chat « dort ». Parce que les deux mots apparaissent dans les mêmes contextes, l'entraînement rapproche leurs plongements ; et parce que chien est placé près de chat, le modèle prête au chien ce qu'il a appris sur le chat.

De 2003 à 2017 : des réseaux récurrents à l'attention

Le modèle de 2003 ne regardait qu'une courte fenêtre fixe de mots. En 2010, Tomáš Mikolov, qui créera word2vec trois ans plus tard, remplace ce réseau par un réseau récurrent, présenté au Module 3. Sa mémoire résume tout le texte déjà lu, sans limite fixe, et ses modèles de langage font nettement mieux que les meilleurs n-grammes de l'époque.

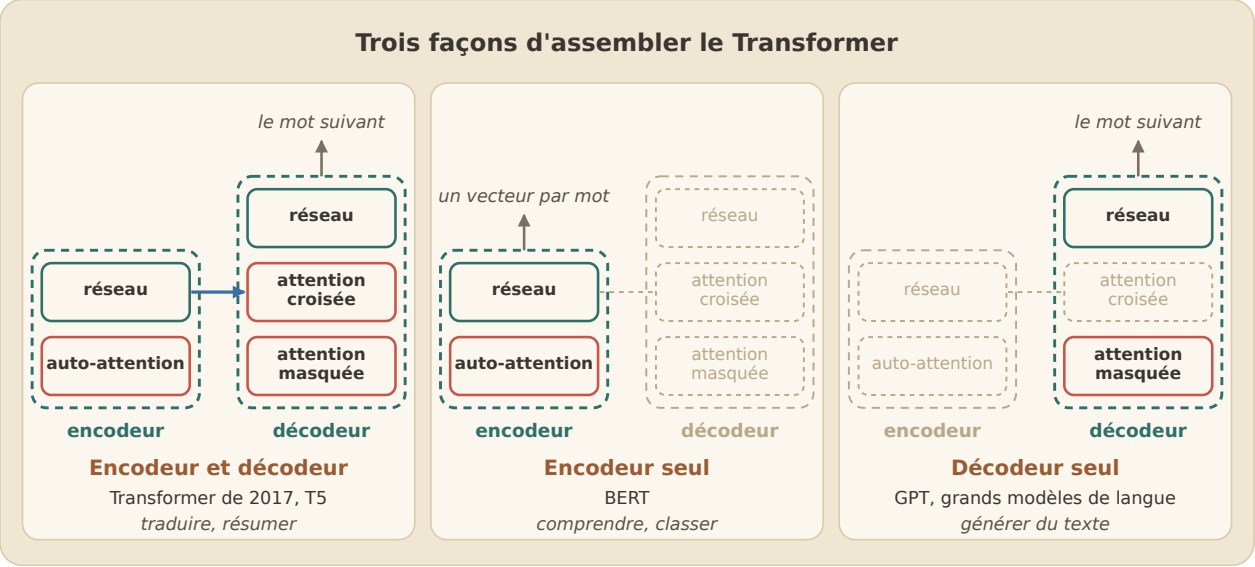
En 2014, deux idées transforment la traduction automatique. Ilya Sutskever, Oriol Vinyals et Quoc Le, chez Google, relient deux réseaux récurrents : le premier lit la phrase d'origine, le second écrit la traduction, un mot après l'autre. C'est le modèle **séquence à séquence** (*sequence-to-sequence*, ou *seq2seq*). La même année, à Montréal, Dzmitry Bahdanau, Kyunghyun Cho et Yoshua Bengio lui ajoutent l'attention : pour écrire chaque mot, le second réseau va chercher dans la phrase d'origine les mots dont il a besoin. En 2016, Google Traduction adopte la traduction neuronale, comme le raconte le chapitre « Les réseaux récurrents ».

Ces réseaux ont cependant deux défauts : leur mémoire s'efface sur les longs textes, et ils lisent un mot après l'autre, ce qui rend leur entraînement lent. En 2017, le Transformer garde l'attention et abandonne la récurrence : tous les mots d'un texte se regardent en même temps.

Trois façons d'assembler le Transformer

Le Transformer de 2017, présenté au Module 3, est conçu pour la traduction. Il a deux parties : un encodeur lit la phrase d'origine, et un décodeur écrit la traduction en consultant l'encodeur par l'attention croisée. Ces deux parties peuvent aussi servir séparément. Trois familles de modèles en sont nées.

Variante	Ce qu'on garde	Exemples	Pour quoi faire
encodeur et décodeur	les deux parties	le Transformer de 2017, T5 (Google, 2019)	transformer un texte en un autre : traduire, résumer
encodeur seul	l'encodeur ; chaque mot voit toute la phrase	BERT (Google, 2018)	comprendre un texte : le classer, y chercher, calculer des plongements contextuels
décodeur seul	le décodeur, sans attention croisée	GPT (OpenAI, 2018) et les grands modèles de langage	générer du texte, jeton après jeton



Les mêmes pièces, assemblées de trois façons : on garde les deux colonnes, ou seulement l'une des deux.

C'est la troisième qui l'a emporté, et c'est elle que décrit la suite de cette page. Un décodeur seul, dont l'attention masquée ne laisse voir à chaque jeton que ceux qui le précèdent, est exactement un modèle de langage : il prédit le jeton suivant. Assez grand, et entraîné seulement à cette prédiction, il apprend aussi à traduire, à résumer et à classer. Trois raisons l'expliquent.

- **Toute tâche peut s'écrire comme une suite de texte.** Traduire, c'est continuer « Traduis en anglais : La maison est petite. → ». Classer un avis, c'est continuer « Cet avis est-il positif ou négatif ? ... Réponse : ». Un décodeur n'a pas besoin d'une architecture différente pour chaque tâche : il suffit de lui donner le bon début de texte.
- **Le Web regorge d'exemples de ces tâches.** On y trouve des pages bilingues, des articles suivis d'un résumé, des avis suivis d'une note, des questions suivies de leur réponse. Pour bien prédire la suite de ces textes, le modèle doit apprendre à faire ce qu'ils font. En 2019, les chercheurs d'OpenAI constatent ainsi que GPT-2 produit un résumé si l'on termine un article par « TL;DR: », l'abréviation que les internautes placent avant un résumé.
- **Il n'a besoin d'aucune étiquette.** Un encodeur-décodeur s'entraîne sur des paires de textes, comme une phrase et sa traduction. Un encodeur comme BERT doit être ajusté sur des exemples annotés pour chaque tâche. Un décodeur s'entraîne sur n'importe quel texte, par

auto-supervision. Il peut donc profiter de tout le texte disponible, et grandir presque sans limite, comme le montre le chapitre « Passer à l'échelle ».

Plus le modèle grandit, mieux ces compétences se manifestent. En 2020, GPT-3 accomplit des tâches nouvelles à partir de quelques exemples donnés dans la consigne, sans aucun entraînement supplémentaire : c'est l'apprentissage dans le contexte. La section « Ce que la prédiction exige », plus bas, revient sur ce que ce simple objectif oblige le modèle à apprendre.

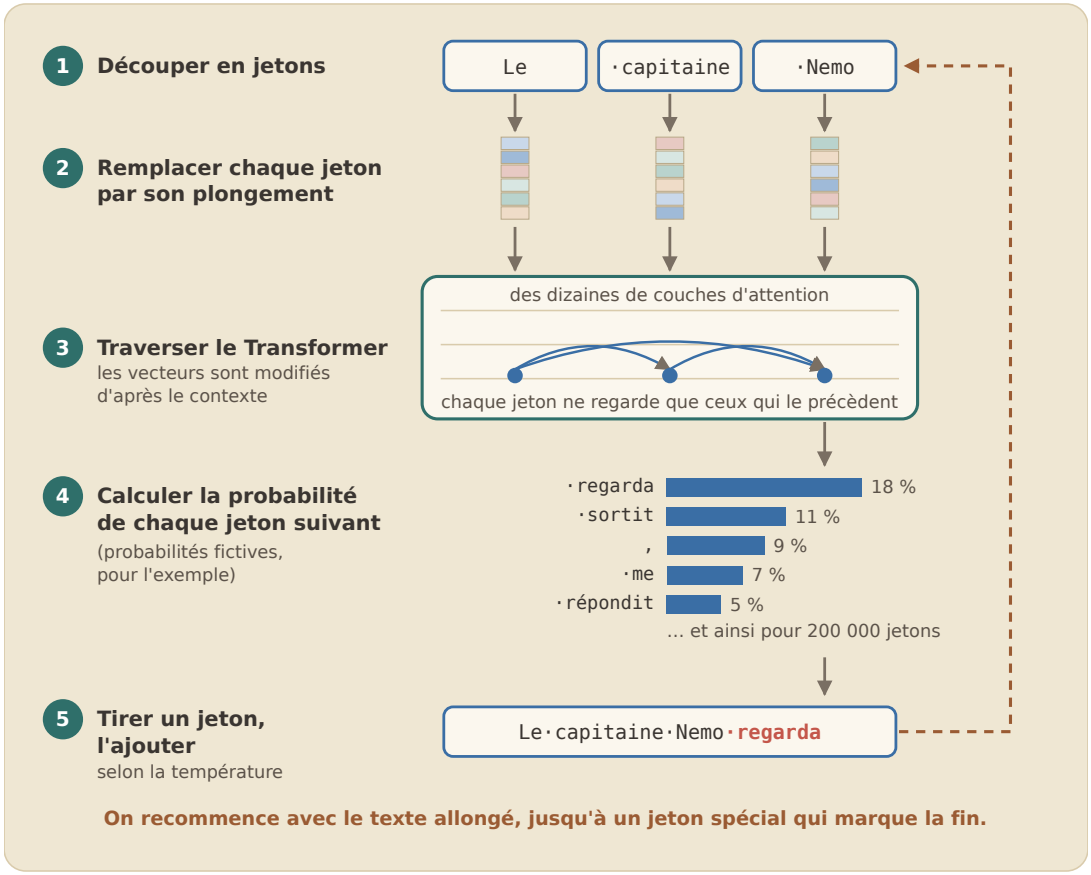
GPT : un Transformer qui prédit le jeton suivant

En juin 2018, l'entreprise OpenAI publie GPT (*Generative Pre-trained Transformer*), qui ne garde que le décodeur du Transformer. C'est un modèle de langage au sens exact du chapitre « Des règles aux probabilités » : il estime la même probabilité que les n-grammes,

$$P(w_i \mid w_1, \dots, w_{i-1})$$

Mais là où un modèle à n-grammes ne gardait que les deux ou trois derniers mots, et le modèle de 2003 une courte fenêtre fixe, GPT tient compte de tout le texte qu'il peut lire d'un coup. Ce qui change, c'est la façon de calculer la distribution.

Le *P* de GPT désigne une idée qui s'impose cette année-là. En 2018, coup sur coup, ULMFiT, ELMo, GPT et BERT montrent qu'on peut **préentraîner** un modèle une seule fois, sur une grande quantité de texte et sans aucune étiquette, en lui faisant prédire des mots, puis l'**ajuster** à peu de frais pour chaque tâche : classer des avis, répondre à des questions, reconnaître des noms propres. C'est l'apprentissage par transfert du Module 3, appliqué à la langue. Les modèles suivants iront plus loin : à partir de GPT-2, un modèle assez grand accomplit beaucoup de tâches sans même être ajusté.



Comment un grand modèle de langage écrit : un jeton à la fois, en recommençant chaque fois avec le texte allongé.

1. Le texte est découpé en jetons, et chaque jeton est remplacé par son plongement.
2. Les plongements traversent les couches du Transformer. Dans chaque couche, l'auto-attention permet à chaque jeton de consulter les jetons précédents et de modifier son vecteur en conséquence. Un jeton ne peut pas regarder les jetons qui le suivent : pendant l'entraînement, ce serait regarder la réponse.
3. À la sortie, le vecteur du dernier jeton est transformé en une probabilité pour chacun des jetons du vocabulaire, soit 200 000 nombres pour un modèle récent.
4. On tire un jeton dans cette distribution, avec la température choisie, on l'ajoute au texte, et on recommence. La génération s'arrête quand le modèle tire un jeton spécial qui marque la fin du texte.

L'entraînement suit le même principe. On présente au modèle des textes tirés d'un immense corpus, et à chaque position, il doit prédire le jeton suivant. Son erreur est d'autant plus grande qu'il a donné une faible probabilité au jeton qui suivait vraiment. La rétropropagation ajuste ensuite ses milliards de poids pour réduire cette erreur. C'est le principe du maximum de vraisemblance présenté au Module 2 : on cherche les paramètres qui rendent les textes observés les plus probables. Comme le texte fournit lui-même toutes les réponses, aucun étiquetage humain n'est nécessaire. C'est de l'auto-supervision, et c'est ce qui permet d'entraîner ces modèles sur une grande partie du texte disponible sur le Web. Contrairement à un réseau récurrent, le Transformer traite toutes les positions d'un texte en même temps, ce qui permet d'utiliser pleinement les processeurs graphiques.

Le nombre de jetons que le modèle peut lire d'un coup s'appelle sa **fenêtre de contexte** (*context*

window). Elle était de 512 jetons pour le premier GPT, en 2018. En 2024, Google présente Gemini 1.5, dont la fenêtre atteint un million de jetons, soit plusieurs romans entiers. Cette fenêtre est aussi la seule mémoire du modèle pendant une conversation, comme le montre la section « Une conversation qui n'en est pas une » du chapitre « Des outils, un harnais et des agents ».

Ce que la prédiction exige

La tâche paraît modeste. On compare souvent ces modèles à la fonction de complétion automatique d'un téléphone. La comparaison est juste pour le principe, mais elle trompe sur ce que la tâche exige quand on cherche à la réussir très bien.

Pour prédire le mot suivant de « La capitale du Canada est », il faut connaître un fait. Pour prédire la suite de « $17 \times 24 =$ », il faut savoir calculer. Pour prédire le nom du coupable à la dernière page d'un roman policier, il faudrait avoir suivi l'intrigue et les indices. Plus un modèle devient bon à cette tâche, plus il doit, d'une façon ou d'une autre, capter la grammaire, des connaissances sur le monde, des styles d'écriture et des formes de raisonnement. Certains chercheurs, comme Ilya Sutskever, cofondateur d'OpenAI, en concluent que bien prédire le texte demande une forme de compréhension. D'autres estiment que le modèle n'apprend que des régularités de surface, sans représentation du monde. Le chapitre « Ce que les LLM comprennent, et ce qu'ils ratent » présente ce débat.

Un modèle entraîné seulement à prédire le jeton suivant n'est pas encore un assistant. Si on lui écrit « Quelle est la capitale du Canada ? », il peut tout aussi bien continuer par une autre question, comme dans une liste de questions d'examen. Le passage de ce modèle à un assistant qui répond fait l'objet du chapitre « Du modèle à l'assistant ». Le chapitre suivant montre d'abord ce qui s'est passé quand on a rendu ces modèles beaucoup plus grands.

Ce qui a changé, ce qui est resté

Les chapitres « Des règles aux probabilités » et « Les outils statistiques » annonçaient que les idées de l'ère statistique survivent dans les grands modèles de langage. Le tableau suivant les met côte à côte.

Notion classique	Ce qu'elle devient dans un grand modèle de langage
le modèle de langage, la probabilité du mot suivant	inchangé : c'est exactement ce qu'estime GPT
l'hypothèse de Markov : deux ou trois mots de contexte	la fenêtre de contexte : des milliers, voire des millions de jetons
le lissage, pour les suites jamais vues	la généralisation par les plongements : des mots voisins partagent ce qu'on sait d'eux
la perplexité	la mesure d'erreur que l'entraînement fait baisser, l'entropie croisée (*cross-entropy*), dont elle est l'exponentielle
le canal bruité, où le modèle de langage arbitre	un seul modèle, qui écrit directement la traduction ou la réponse
les vecteurs de documents et la LSA	les plongements, appris plutôt que comptés

Notion classique	Ce qu'elle devient dans un grand modèle de langage
les caractéristiques faites à la main	les représentations que le réseau apprend lui-même
les chaînes de pièces : étiqueter, analyser, traduire, corriger	un seul modèle, entraîné de bout en bout

Le but n'a donc pas changé depuis Shannon et Markov : estimer la probabilité de la suite d'un texte. Ce qui a changé, c'est la façon de l'estimer, et l'échelle.

Pour voir le mécanisme en détail

Les deux vidéos suivantes, du vulgarisateur Grant Sanderson (chaîne 3Blue1Brown), présentent les grands modèles de langage, puis le Transformer qui les fait fonctionner. La vidéo sur l'attention de la même série est proposée au chapitre « L'attention et le Transformer » du Module 3.

Vidéo : https://www.youtube.com/watch?v=LPZh9BOjkQs

Vidéo : https://www.youtube.com/watch?v=wjZofJX0v4M

Passer à l'échelle

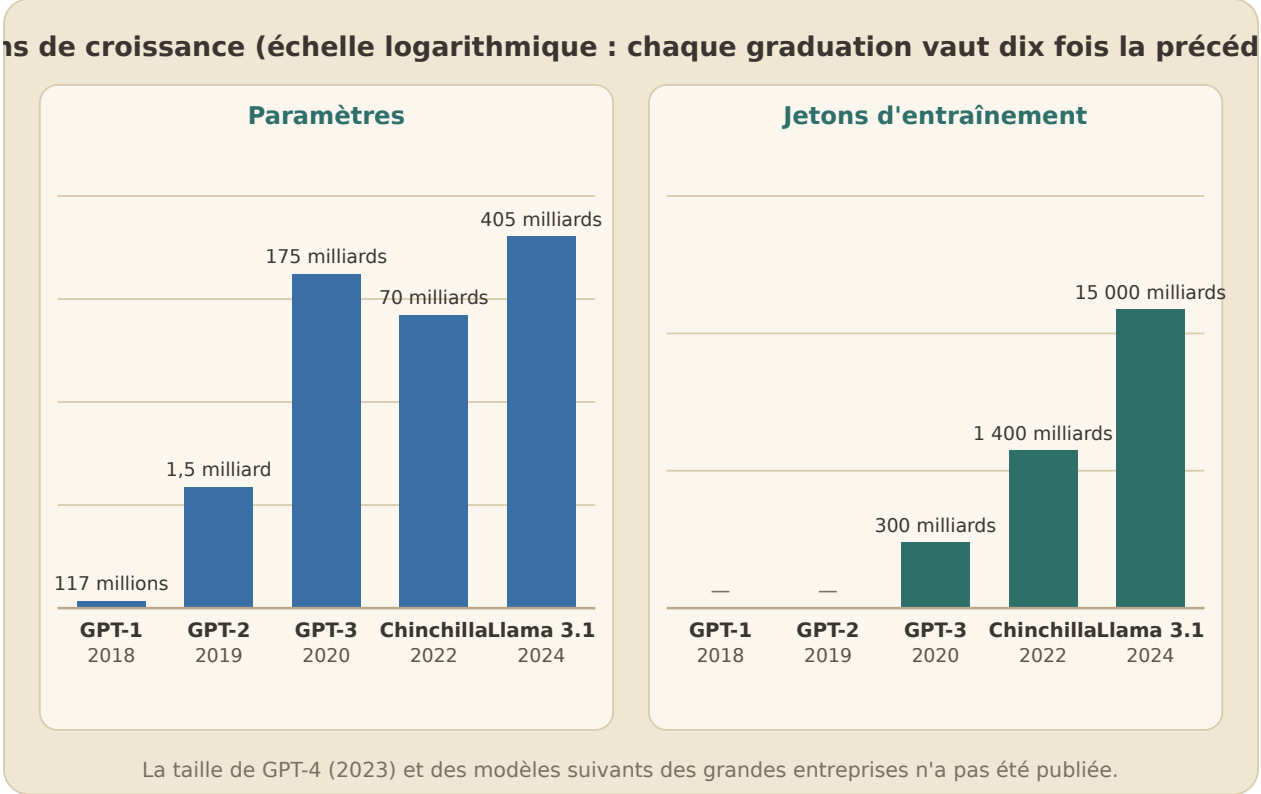
Le chapitre « Prédire le mot suivant » a présenté le principe des grands modèles de langage : un Transformer entraîné à prédire le jeton suivant d'un texte. Ce principe n'a presque pas changé depuis le premier GPT, en 2018. Ce qui a changé, c'est la **taille** : la taille des modèles, la quantité de textes sur lesquels ils sont entraînés, et la quantité de calcul consacrée à leur entraînement. Ce chapitre présente cette course à la taille, ce qu'elle a produit, et ce qu'elle coûte.

De GPT à GPT-4

Chaque nouvelle version des modèles d'OpenAI a multiplié la taille de la précédente.

- **GPT** (juin 2018) compte 117 millions de paramètres. Il est entraîné sur environ 7 000 livres.
- **GPT-2** (février 2019) compte 1,5 milliard de paramètres, entraînés sur 8 millions de pages Web. OpenAI annonce d'abord ne pas publier le modèle complet, par crainte qu'il serve à produire de fausses nouvelles en masse, puis le publie par étapes jusqu'en novembre 2019. Ses textes sont souvent cohérents sur plusieurs paragraphes, ce qui surprend à l'époque.
- **GPT-3** (mai 2020) compte 175 milliards de paramètres, entraînés sur environ 300 milliards de jetons.
- **GPT-4** (mars 2023) est beaucoup plus performant, mais OpenAI ne publie plus sa taille. Selon Sam Altman, le directeur d'OpenAI, son entraînement a coûté plus de 100 millions de dollars.

D'autres entreprises ont publié des modèles du même ordre de grandeur, comme Google, Anthropic ou Meta. La figure ci-dessous rassemble quelques modèles dont la taille est connue. Les barres sont dessinées sur une échelle logarithmique : chaque graduation vaut dix fois la précédente.

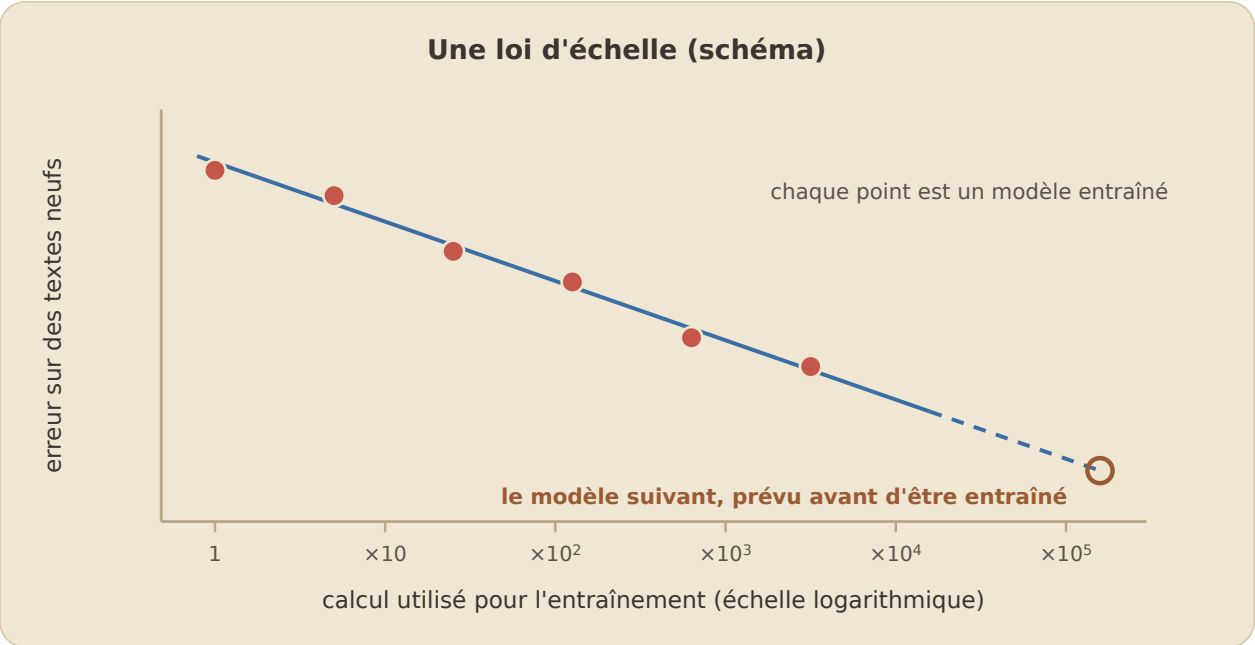


En six ans, le nombre de paramètres a été multiplié par plus de 3 000, et la quantité de texte d'entraînement a suivi.

Des lois d'échelle

Pourquoi les entreprises ont-elles investi des sommes croissantes dans des modèles toujours plus grands ? En partie parce que le résultat était prévisible.

En janvier 2020, Jared Kaplan et ses collègues, chez OpenAI, publient une étude sur des centaines de modèles de tailles différentes. Ils mesurent l'erreur de chaque modèle sur des textes qu'il n'a jamais vus, c'est-à-dire sa capacité à prédire le jeton suivant. Cette erreur diminue de façon très régulière quand on augmente le nombre de paramètres, la quantité de données ou la quantité de calcul. Sur un graphique à échelles logarithmiques, les points s'alignent sur une droite. On parle de **lois d'échelle** (*scaling laws*).



Le principe d'une loi d'échelle (schéma) : en prolongeant la droite, on prévoit l'erreur d'un modèle plus grand avant de l'entraîner.

Ces lois ont une conséquence pratique. Avant de dépenser des dizaines de millions de dollars pour entraîner un très grand modèle, on peut entraîner une série de petits modèles, tracer la droite, et prévoir le résultat. Elles confirment aussi la leçon amère de Richard Sutton, présentée au Module 3 : les méthodes générales qui tirent parti d'une quantité croissante de calcul finissent par l'emporter. Elles prolongent enfin l'énigme présentée au chapitre « L'apprentissage profond » : ces modèles ont des milliards de paramètres, et pourtant ils généralisent de mieux en mieux à mesure qu'ils grandissent.

En mars 2022, une équipe de DeepMind corrige la recette. Pour un budget de calcul donné, il ne sert à rien d'agrandir le modèle si on ne lui donne pas assez de textes. Leur modèle Chinchilla, avec 70 milliards de paramètres entraînés sur 1 400 milliards de jetons, dépasse des modèles quatre fois plus grands entraînés sur moins de données. La règle qui en est tirée, environ vingt jetons d'entraînement par paramètre, a guidé les modèles suivants. Ceux-ci vont d'ailleurs bien au-delà : un modèle plus petit, entraîné plus longtemps, coûte moins cher à utiliser ensuite.

Apprendre dans le contexte

L'article qui présente GPT-3 en 2020 s'intitule « *Language Models are Few-Shot Learners* » (« les modèles de langage apprennent à partir de quelques exemples »). Il décrit une capacité que personne n'avait programmée.

Quelques exemples dans la requête
L'article donne à GPT-3 le texte suivant, et lui demande de le continuer. La consigne de la première ligne était en anglais ; elle est traduite ici.

```
Traduire de l'anglais vers le français :
```

```
sea otter => loutre de mer
peppermint => menthe poivrée
plush girafe => girafe peluche
cheese =>
```

Le modèle complète par « fromage ». Il n'a jamais été entraîné spécialement à traduire. Les trois exemples placés dans le texte suffisent à lui faire comprendre la tâche demandée, et il l'applique au quatrième mot.

Cette capacité s'appelle l'**apprentissage dans le contexte** (*in-context learning*). On distingue la requête sans exemple (*zero-shot*), avec un seul exemple (*one-shot*) et avec quelques exemples (*few-shot*). Elle est très différente de l'apprentissage présenté au Module 2 : aucun poids du modèle n'est modifié. Le modèle reconnaît la tâche dans le texte qu'on lui donne, et ses performances augmentent avec sa taille. GPT-3 réussit de nombreuses tâches de cette façon, alors que les modèles plus petits n'y parviennent presque pas. La rédaction des requêtes (*prompting*) est devenue une compétence à part entière, présentée au chapitre « Des outils, un harnais et des agents ».

Ces mots existaient avant les grands modèles de langage, avec un autre sens. En apprentissage automatique, l'**apprentissage à partir de quelques exemples** (*few-shot learning*) désignait la capacité d'apprendre une catégorie nouvelle, un oiseau ou un visage jamais vus, à partir d'une poignée d'exemples étiquetés, en ajustant les poids d'un modèle déjà entraîné. L'apprentissage **sans exemple** (*zero-shot learning*) désignait la reconnaissance d'une catégorie qu'on n'a jamais vue, à partir de sa seule description, par exemple « un oiseau au bec rouge et à la queue fourchue ». Avec GPT-3, les mêmes mots ont pris un sens nouveau : les exemples se trouvent dans la requête, et le modèle n'est pas entraîné du tout. Les deux sens coexistent encore, et il faut souvent deviner, d'après le contexte, lequel un auteur emploie.

L'apprentissage dans le contexte n'est qu'un point sur un spectre. Pour faire accomplir une tâche à un modèle, on peut lui donner plus ou moins d'exemples, et modifier plus ou moins ses poids.

Façon de faire	Exemples nécessaires	Les poids changent-ils ?
requête sans exemple (*zero-shot*)	aucun, seulement une consigne	non
requête avec quelques exemples (*few-shot*)	de un à quelques dizaines, placés dans la requête	non
ajustement (*fine-tuning*)	des centaines à des milliers	oui, un peu
entraînement complet	des milliers à des milliards	oui, entièrement

Plus on descend dans le tableau, plus il faut de données et de calcul, mais plus le modèle se spécialise. En pratique, on essaie d'abord la requête, qui ne coûte presque rien, et on n'ajuste le modèle que si elle ne suffit pas. Jusqu'en 2020, presque tout se faisait dans les deux dernières rangées. La surprise de GPT-3 est que les deux premières suffisent souvent.

Des capacités qui apparaissent ?

En 2022, Jason Wei et ses collègues, chez Google, décrivent des **capacités émergentes** (*emergent abilities*). Sur certaines tâches, comme l'addition de nombres de plusieurs chiffres ou certaines

énigmes, les petits modèles échouent presque complètement, puis, au-delà d'une certaine taille, les modèles réussissent soudain. La capacité semble apparaître d'un coup, sans avoir été annoncée par les modèles plus petits. L'idée a beaucoup circulé, car elle suggère que des modèles plus grands pourraient acquérir des capacités imprévisibles.

En 2023, Rylan Schaeffer et ses collègues, à l'Université Stanford, contestent cette interprétation. Selon eux, l'apparition soudaine vient souvent de la façon de mesurer. Si l'on compte une addition comme réussie seulement quand tous les chiffres sont exacts, la note passe brusquement de 0 à 1. Si l'on compte les chiffres exacts un par un, le progrès est régulier. Le débat n'est pas tranché : certaines capacités semblent bien apparaître de façon abrupte, d'autres sont des effets de mesure.

Que mesurent les scores ?

Toutes ces mesures supposent une chose : que le modèle n'ait jamais vu les questions du test. C'est la règle fondamentale du Module 2 : un modèle se juge sur ce qu'il n'a jamais vu, et la moindre fuite de données rend le score trop beau pour être vrai.

Avec les grands modèles de langage, cette règle devient presque impossible à respecter. On les compare sur des **bancs d'essai** (*benchmarks*), des tests standardisés de questions et de problèmes. Or ces modèles sont entraînés sur une grande partie du Web, où circulent aussi ces questions : les énoncés sont publiés en ligne, discutés sur des forums, accompagnés de leurs solutions. Plus le corpus est grand, plus il est probable qu'une question du test, ou une variante proche, s'y trouve. Et comme les entreprises publient rarement la liste exacte de leurs données d'entraînement, on ne peut même pas le vérifier. C'est la **contamination** des bancs d'essai (*benchmark contamination*) : la contamination du Module 2, à l'échelle du Web.

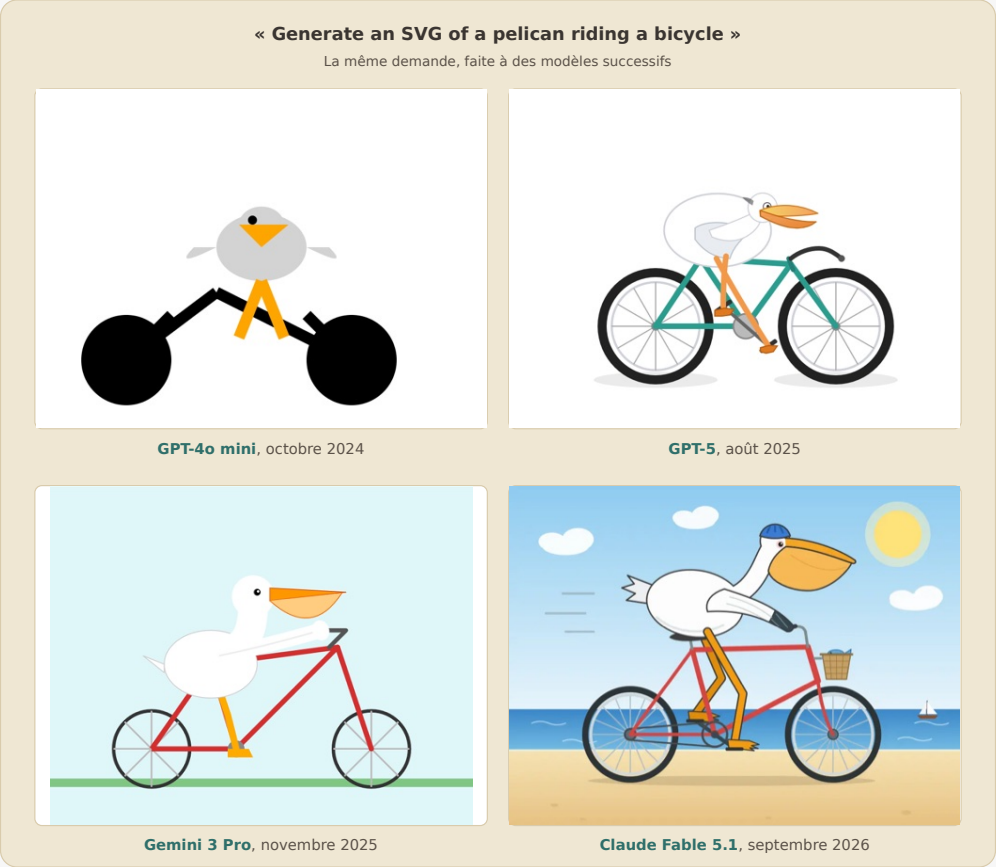
Deux observations montrent que le problème est réel.

- En 2023, des utilisateurs remarquent que GPT-4 résout des problèmes de programmation du site Codeforces publiés avant la fin de ses données d'entraînement, mais presque aucun des problèmes de même difficulté publiés après.
- En 2024, une équipe de l'entreprise Scale AI rédige GSM1k, mille nouveaux problèmes de mathématiques de même niveau que ceux de GSM8k, un banc d'essai très utilisé. Plusieurs modèles y perdent jusqu'à 13 points : ils avaient en partie appris le banc d'essai lui-même.

S'y ajoute un effet plus subtil, résumé par la **loi de Goodhart** : quand une mesure devient un objectif, elle cesse d'être une bonne mesure. Comme les entreprises se comparent sur les mêmes bancs d'essai, elles ont intérêt à y optimiser leurs modèles, consciemment ou non. Les chercheurs répondent de plusieurs façons : des tests gardés secrets, des tests rédigés après la date de fin des données d'entraînement, et des évaluations où des humains comparent deux réponses sans savoir de quel modèle elles viennent. Aucune n'est parfaite. Savoir ce qu'un grand modèle sait vraiment faire, au-delà de ce qu'il a vu, reste l'une des questions les plus difficiles du domaine.

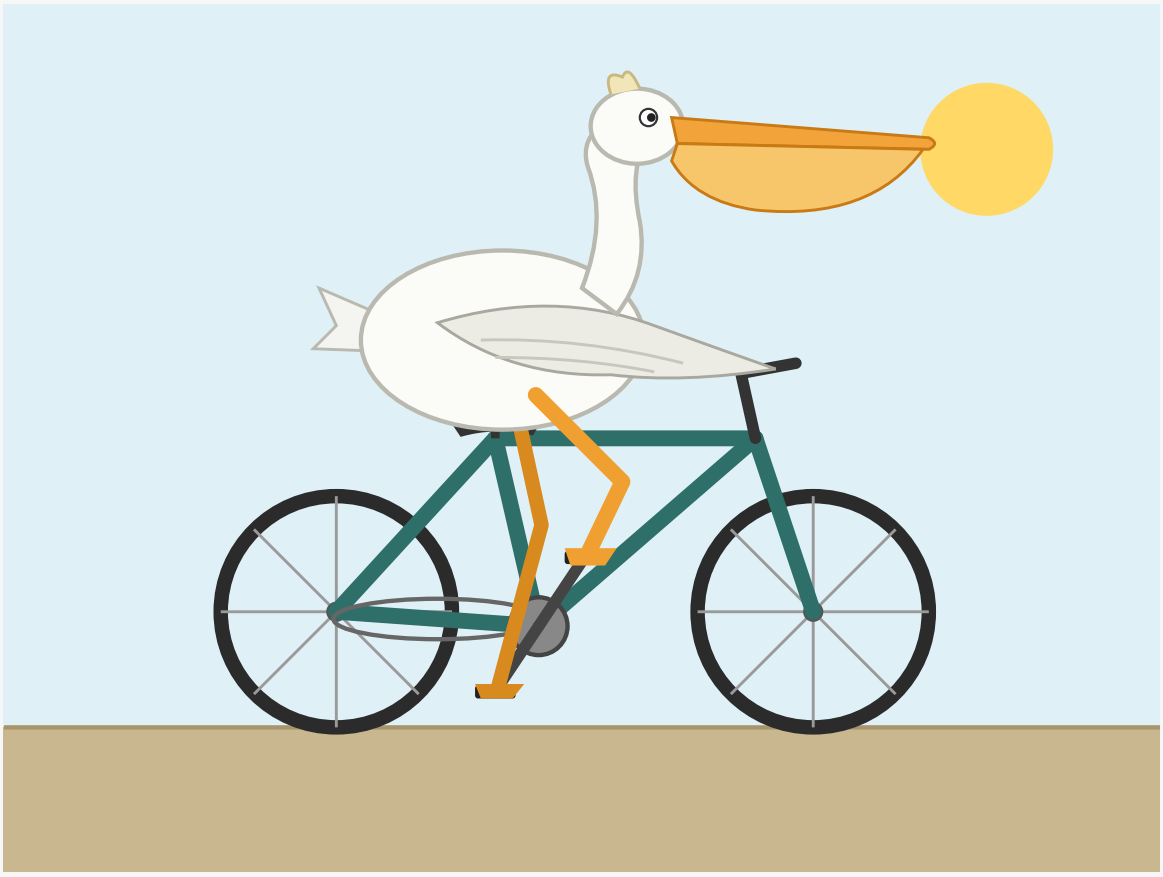
Un pélican à vélo
Fin octobre 2024, le programmeur et blogueur Simon Willison commence à soumettre les nouveaux modèles à un test de son invention : « *Generate an SVG of a pelican riding a bicycle* », dessiner en SVG un pélican qui fait du vélo. Le SVG est un format d'image écrit sous forme de code. Le modèle doit donc décrire chaque cercle et chaque trait par ses coordonnées, sans jamais voir le résultat. La tâche est plus difficile qu'elle n'en a l'air : un vélo est difficile à dessiner de

mémoire, un pélican aussi, et un pélican n'a pas la forme qu'il faut pour pédaler. Surtout, la scène est assez absurde pour qu'aucun dessin de ce genre ne circule sur le Web, et le modèle ne peut pas en recopier un.



La même demande, faite à quatre modèles successifs, de 2024 à 2026. Images de Simon Willison, simonwillison.net.

Le test devient célèbre. En mai 2025, un pélican à vélo apparaît dans la grande conférence annuelle de Google, et en octobre 2025, une équipe d'Anthropic s'en sert pour regarder à l'intérieur d'un modèle qui dessine : elle y trouve des caractéristiques qui représentent les roues, le vélo ou les yeux de l'oiseau. Willison se demande alors si les laboratoires ne finiront pas par entraîner leurs modèles sur ce test précis, comme le prévoit la loi de Goodhart. Il garde donc en réserve des variantes secrètes, d'autres animaux sur d'autres véhicules : un modèle qui dessinerait un excellent pélican et un mauvais flamant rose sur un monocycle se trahirait. En avril 2026, un petit modèle ouvert, qui tourne sur son ordinateur portable, dessine un meilleur pélican que Claude Opus 4.7. Méfiant, Willison sort l'une de ses variantes. En juillet 2026, il rappelle lui-même que le test a commencé comme une plaisanterie, et que la qualité d'un pélican ne dit plus grand-chose de celle d'un modèle.
Le modèle qui a aidé à rédiger ce cours (voir « Comment ce cours a été produit ») s'est prêté au jeu en octobre 2026, en un seul essai, sans voir son dessin avant de l'avoir terminé.



Le pélican de Claude Opus 5.5, dessiné en octobre 2026 au premier essai, sans voir le résultat, et gardé tel quel : le soleil touche le bout du bec, et la chaîne du vélo est approximative.

Le prix de la taille

Entraîner un grand modèle demande des dizaines de milliers de processeurs graphiques qui fonctionnent pendant des semaines ou des mois. Les entreprises construisent pour cela des centres de données géants, qui consomment autant d'électricité qu'une ville et de grandes quantités d'eau pour leur refroidissement. Les coûts se comptent en centaines de millions de dollars par modèle, et les investissements annuels du secteur en centaines de milliards.

Les données posent un autre problème. Les modèles sont entraînés sur une grande partie du texte disponible sur le Web, et les meilleurs textes, comme les livres, les articles scientifiques ou les encyclopédies, ne sont pas infinis. En 2024, l'institut de recherche Epoch AI estime que les modèles auront été entraînés sur l'équivalent de tout le texte humain public disponible quelque part entre 2026 et 2032. Les entreprises se tournent donc vers des **données synthétiques** (*synthetic data*), produites par d'autres modèles, et vers des textes sous licence. Le recours aux textes protégés par le droit d'auteur fait l'objet de nombreux procès, comme celui que le *New York Times* a intenté à OpenAI et à Microsoft en décembre 2023. Le Module 5 revient sur ces coûts environnementaux et juridiques.

Modèles fermés, modèles ouverts

Les modèles les plus puissants, ceux d'OpenAI, de Google ou d'Anthropic, sont **fermés** : on peut les utiliser, mais leurs poids ne sont pas publiés, et on ne connaît ni leur taille exacte ni leurs données d'entraînement. D'autres entreprises publient les poids de leurs modèles, que chacun peut télécharger, étudier, ajuster et faire tourner sur ses propres machines. On parle alors de modèles **ouverts** (*open-weight models*).

- En février 2023, Meta publie LLaMA, puis plusieurs versions successives, jusqu'à Llama 3.1 et ses 405 milliards de paramètres en juillet 2024.
- En avril 2023, trois chercheurs français fondent Mistral AI, à Paris, qui publie plusieurs modèles ouverts.
- En janvier 2025, l'entreprise chinoise DeepSeek publie R1, un modèle ouvert dont les performances approchent celles des meilleurs modèles fermés, pour un coût d'entraînement annoncé bien plus faible. Le 27 janvier, la valeur boursière de Nvidia, le principal fabricant de processeurs graphiques, recule de près de 600 milliards de dollars en une journée.

Le Canada a aussi son entreprise du domaine. Cohere est fondée à Toronto en 2019, notamment par Aidan Gomez, l'un des auteurs de l'article de 2017 qui a présenté le Transformer, qu'il avait coécrit pendant un stage chez Google alors qu'il étudiait à l'Université de Toronto.

Ce que coûte une réponse

L'entraînement se paie une fois ; l'utilisation, à chaque réponse. Les entreprises facturent leurs modèles au jeton, lu ou écrit. À sa sortie, en mars 2023, GPT-4 coûtait 30 dollars par million de jetons lus. En juillet 2024, GPT-4o mini, un modèle plus petit et déjà très capable, en coûtait 15 cents. Selon Epoch AI, le prix pour obtenir un même niveau de performance baisse de dix à plusieurs centaines de fois par an selon la tâche. Plusieurs techniques y contribuent.

- **Le mélange d'experts** (*mixture of experts*). Le modèle est découpé en de nombreux sous-réseaux, les « experts », et un petit réseau d'aiguillage choisit pour chaque jeton les quelques experts qui le traiteront. DeepSeek-V3, publié en décembre 2024, compte 671 milliards de paramètres, mais n'en utilise que 37 milliards pour chaque jeton. C'est l'une des raisons de son faible coût : environ 5,6 millions de dollars pour son dernier entraînement, selon ses auteurs, sans compter les essais qui l'ont précédé.
- **La quantification** (*quantization*). Chaque paramètre est stocké avec moins de précision, par exemple sur 4 bits au lieu de 16. Le modèle occupe alors quatre fois moins de mémoire, et perd peu en qualité : un modèle de 7 milliards de paramètres passe d'environ 14 à 4 gigaoctets, et tient dans un ordinateur portable.
- **Les petits modèles.** Des modèles de quelques milliards de paramètres, souvent obtenus par distillation d'un grand modèle, tournent directement sur un téléphone, comme celui qu'Apple intègre à ses appareils en 2024, ou les plus petits modèles Llama de Meta.

Cette baisse des prix rend possibles des usages qui consomment beaucoup de jetons, comme les agents ou les modèles qui réfléchissent longtemps avant de répondre. Elle ne fait pas baisser pour autant la consommation totale d'énergie du secteur, puisque les usages se multiplient, une question que reprend le Module 5.

Jusqu'où ?

Les lois d'échelle décrivent une tendance, pas une loi de la nature. À partir de 2024, plusieurs observateurs constatent que les gains obtenus en agrandissant seulement les modèles diminuent, et que les données de qualité se raréfient. Les entreprises explorent alors une autre direction : consacrer davantage de calcul non plus à l'entraînement, mais au moment de répondre, en laissant le modèle « réfléchir » plus longtemps avant de donner sa réponse. Ces modèles de raisonnement sont présentés au chapitre suivant, qui montre aussi comment un modèle qui complète du texte devient un assistant qui répond.

Du modèle à l'assistant

Le chapitre « Prédire le mot suivant » s'achevait sur une limite. Un modèle entraîné seulement à prédire le jeton suivant continue des textes, mais il ne répond pas. ChatGPT, Claude ou Gemini sont pourtant des assistants : ils suivent des consignes, refusent certaines demandes et tiennent une conversation. Ce chapitre présente les étapes qui transforment un modèle de base en assistant, le travail humain qu'elles demandent, et les modèles plus récents qui « raisonnent » avant de répondre.

Un modèle de base ne répond pas

Après le **préentraînement** (*pre-training*), le modèle est un **modèle de base** (*base model*). Il a appris à continuer n'importe quel texte de façon plausible, et c'est tout.

Continuer ou répondre
On donne à un modèle de base le texte suivant :

```
Quelle est la capitale du Canada ?
```

Une suite plausible, sur le Web, est une autre question, comme dans une liste de questions d'examen :

```
Quelle est la capitale du Canada ?
Quelle est la capitale de l'Australie ?
Quelle est la capitale du Brésil ?
```

Un assistant, lui, répond « Ottawa ». Le modèle de base n'est pas en défaut : il fait exactement ce pour quoi il a été entraîné. Rien, dans sa tâche, ne lui demande de répondre.

L'exemple paraît anodin, mais l'écart est profond. Répondre suppose de maîtriser tout un ensemble de conventions que les humains apprennent sans y penser, et que personne n'énonce :

- répondre à une question plutôt que la prolonger, et suivre une consigne (« résume ce texte en trois points ») plutôt que l'imiter ;
- s'arrêter à la fin de sa réplique, au lieu d'écrire aussi celle de son interlocuteur ;
- demander une précision quand la demande est ambiguë, et dire qu'on ne sait pas plutôt qu'inventer ;
- adapter la longueur et le ton à la demande, et garder le même rôle d'une réplique à l'autre ;
- refuser certaines demandes.

Ces conventions n'ont pas de définition simple. Le philosophe Ludwig Wittgenstein parlait de **jeux de langage** (*language games*). « Répondre à une question » ne désigne pas une essence unique, mais une famille de comportements apparentés, appris par la pratique, sans qu'on nous les définisse jamais. L'ajustement par instructions procède de la même façon : il ne définit pas ce qu'est une

réponse, il en montre des milliers d'exemples.

Le Web contient bien des conversations, mais aussi des forums où l'on se dispute, des romans où les personnages mentent, et des pages qui posent des questions sans y répondre. Un modèle de base les imite tous indifféremment. Si on lui donne le début d'un dialogue entre un utilisateur et un assistant, il écrit la réplique de l'assistant, puis celle de l'utilisateur, puis la suivante. Il ne sait pas qu'il joue un rôle, et rien ne lui indique où s'arrêter.

Un dialogue écrit des deux côtés
On donne à un modèle de base le début d'un dialogue :

```
Utilisateur : Peux-tu me suggérer un livre pour l'été ?
Assistant :
```

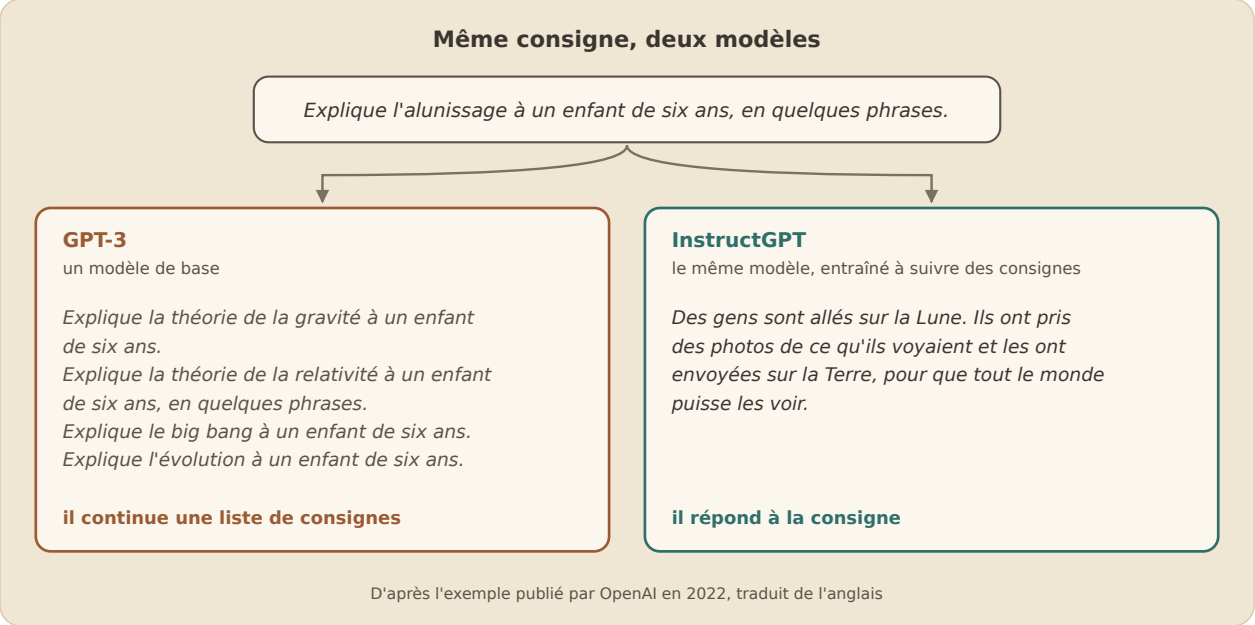
Une suite plausible (exemple illustratif) :

```
Utilisateur : Peux-tu me suggérer un livre pour l'été ?
Assistant : Bien sûr ! Je vous recommande Le Survenant, de Germaine Guèvremont.
Utilisateur : Je l'ai déjà lu. Autre chose ?
Assistant : Alors essayez Kamouraska, d'Anne Hébert.
Utilisateur : Merci, je vais le commander dès demain !
```

Le modèle a écrit la réponse de l'assistant, puis inventé la réaction de l'utilisateur, et ainsi de suite. Pour lui, il n'y a qu'un texte à continuer, comme le montre la section « Une conversation qui n'en est pas une ». Un assistant, lui, a appris à produire une marque spéciale de fin de réplique, qui rend la main à l'utilisateur.

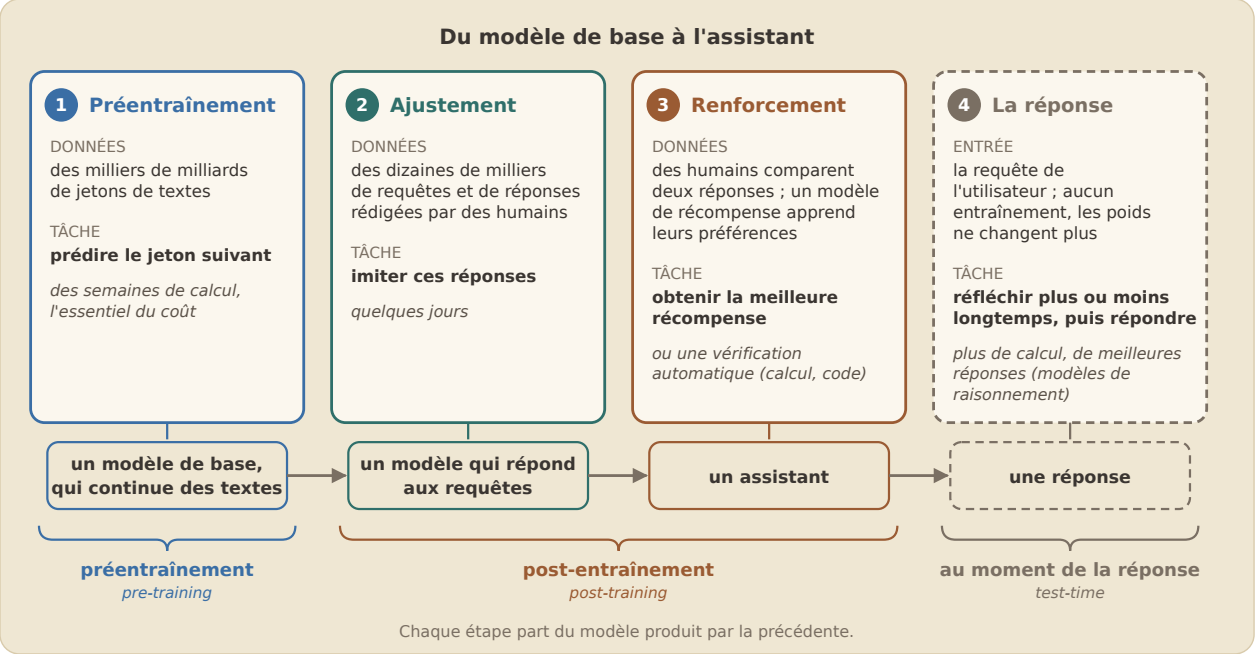
En 2020, GPT-3 pouvait déjà accomplir beaucoup de tâches, à condition de les lui présenter comme un texte à continuer, avec des exemples bien choisis (l'apprentissage dans le contexte). Pour obtenir une réponse, il fallait ruser : écrire le début d'un document où cette réponse viendrait naturellement. Même ainsi, ses suites s'écartaient souvent de la demande, ou inventaient. Le problème n'est pas un manque de connaissances. C'est un écart entre deux objectifs : celui pour lequel le modèle est entraîné, prédire le jeton suivant d'un texte du Web, et celui qu'on attend de lui, suivre les consignes de l'utilisateur de façon utile et sûre. Réduire cet écart est le problème de l'alignement, qui revient plus bas.

En mars 2022, Long Ouyang et ses collègues, chez OpenAI, publient la recette qui comble en bonne partie cet écart. Ils l'appliquent à GPT-3 pour obtenir **InstructGPT**, un modèle entraîné à suivre des consignes. Une quarantaine de personnes, recrutées pour l'occasion, rédigent environ 13 000 réponses modèles et comparent des dizaines de milliers de réponses produites par le modèle. Ces données servent aux deux étapes présentées ci-dessous. ChatGPT, ouvert au public huit mois plus tard, en est une variante entraînée sur des dialogues.



La même consigne donnée à GPT-3 et à InstructGPT, d'après l'exemple publié par OpenAI en 2022. Le modèle de base n'a rien de faux : une liste de consignes est une suite plausible. Mais il ne répond pas.

Le modèle de base contient pourtant l'essentiel des connaissances et des capacités de l'assistant. Il reste à lui apprendre à s'en servir pour répondre. C'est l'objet de deux étapes supplémentaires, regroupées sous le nom de **post-entraînement** (*post-training*), beaucoup moins coûteuses que le préentraînement, du moins jusqu'aux modèles de raisonnement, dont le renforcement mobilise une part croissante du calcul.



Les trois étapes de l'entraînement d'un assistant, puis son utilisation. Le préentraînement représente l'essentiel du coût de l'entraînement ; au moment de la réponse, le modèle ne change plus.

Imiter de bonnes réponses

La deuxième étape est un **ajustement par instructions** (*instruction tuning*). Des personnes rédigent des dizaines de milliers d'exemples de requêtes, accompagnées de la réponse qu'un bon assistant devrait donner. Le modèle de base est ensuite entraîné sur ces exemples, toujours en prédisant le jeton suivant, mais seulement sur des conversations de ce type. Il apprend la forme d'un échange : une requête, puis une réponse complète, utile, dans le ton attendu.

C'est l'idée de l'apprentissage par transfert présentée au Module 3, appliquée au texte. Le préentraînement fournit un modèle général, et un ajustement sur peu de données le spécialise. C'est aussi ce qu'indique le *P* de GPT, pour *pre-trained*.

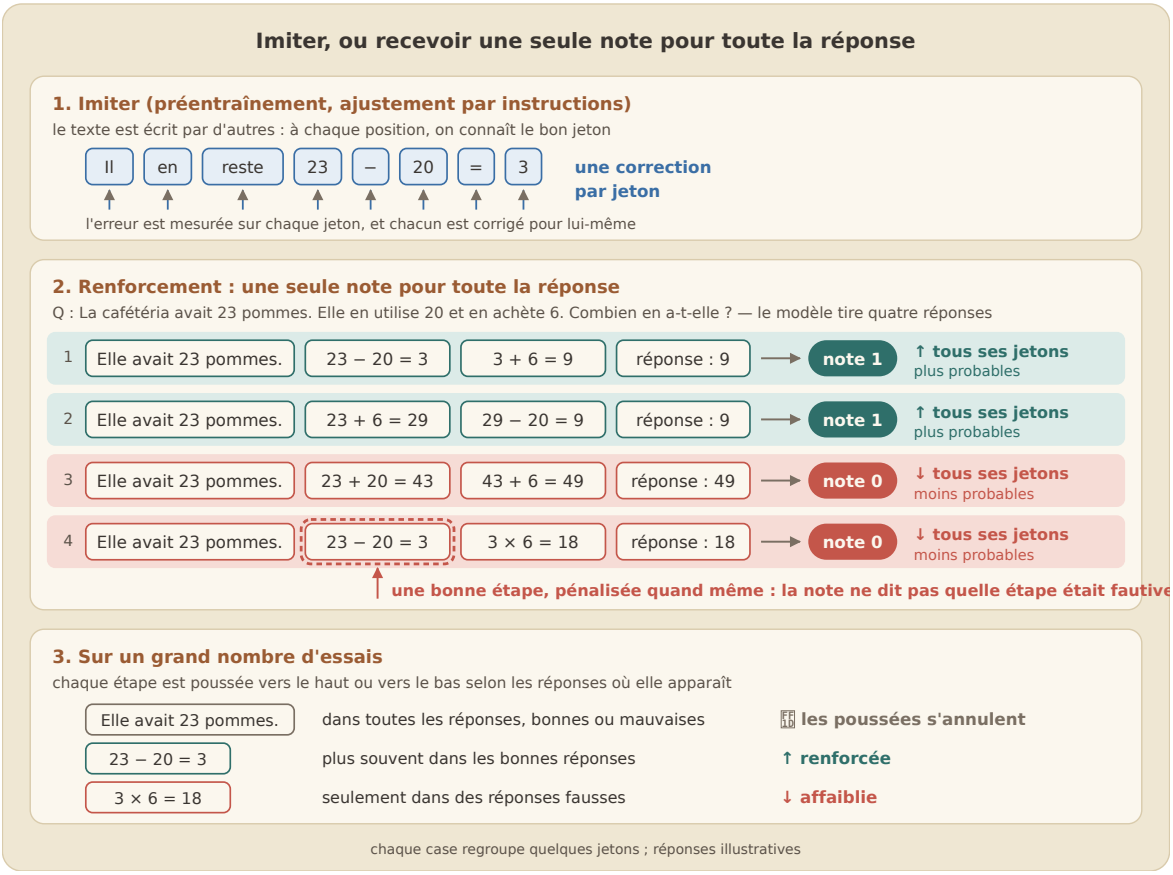
Le renforcement à partir de préférences humaines (RLHF)

Rédiger de bonnes réponses est long, et il est souvent plus facile de juger une réponse que de l'écrire. La troisième étape s'appuie donc sur des **comparaisons**. On présente à des évaluateurs humains deux réponses du modèle à la même requête, et ils indiquent celle qu'ils préfèrent. Ces préférences servent à entraîner un second réseau, le **modèle de récompense** (*reward model*), qui apprend à prédire quelle réponse les évaluateurs préféreraient. C'est un problème de classification comme ceux du Module 2.

Le modèle de langage est ensuite ajusté par apprentissage par renforcement : il produit des réponses, le modèle de récompense leur attribue une note, et ses poids sont ajustés pour obtenir de meilleures notes. C'est le même principe que celui des programmes qui apprennent à jouer, présentés au chapitre « Apprendre à jouer » du Module 3, mais la récompense ne vient plus d'une partie gagnée : elle vient des préférences humaines. On parle de **RLHF** (*reinforcement learning from human feedback*).

Cette étape n'apprend pas de la même façon que les précédentes. Pendant le préentraînement et l'ajustement par instructions, le modèle lit un texte écrit par d'autres, et la bonne réponse est connue à chaque position : c'est le jeton qui suit vraiment. Son erreur est mesurée jeton par jeton, et ses poids sont corrigés pour rendre ce jeton plus probable. Il apprend en imitant.

Dans l'apprentissage par renforcement, il n'y a plus de texte à imiter. Le modèle écrit lui-même une réponse complète, en tirant ses jetons un à un, puis reçoit une seule note pour l'ensemble. Rien ne lui dit quels jetons ont fait la différence. Ses poids sont donc ajustés pour rendre plus probables tous les jetons des réponses bien notées, et moins probables ceux des réponses mal notées. Sur un grand nombre d'essais, les choix qui reviennent dans les bonnes réponses finissent par se dégager. C'est l'attribution de la responsabilité du Module 3, à l'échelle d'une réponse entière : le joueur ne sait qu'à la fin de la partie s'il a gagné, sans savoir quels coups l'ont fait gagner.



Imiter, ou recevoir une note. Une seule réponse ne dit pas quelle étape était bonne ou fautive ; c'est en comparant un grand nombre de réponses que les bons choix se dégagent.

	Préentraînement et ajustement par instructions	Renforcement
Le texte	écrit par d'autres	écrit par le modèle
Ce qu'on connaît	le bon jeton, à chaque position	une note, pour toute la réponse
Ce que le modèle apprend	à imiter	à obtenir de meilleures notes

Cette différence a deux conséquences. D'abord, le modèle peut trouver des réponses meilleures que celles qu'on aurait su lui montrer, puisqu'il n'est plus limité à imiter. Ensuite, il peut aussi trouver des façons d'obtenir une bonne note sans donner une bonne réponse, en exploitant les défauts du modèle de récompense. C'est le **détournement de la récompense** (*reward hacking*), comme le bateau du Module 3, qui tournait en rond pour accumuler des points. Pour l'en empêcher, on le pénalise quand ses réponses s'éloignent trop de celles du modèle de départ.

La méthode a d'abord servi à tout autre chose. En 2017, Paul Christiano et ses collègues, chez OpenAI et DeepMind, l'utilisent pour apprendre à un robot simulé à faire un salto arrière, une tâche difficile à décrire par une règle mais facile à juger en regardant deux essais. OpenAI l'applique ensuite aux modèles de langage : c'est la troisième étape d'InstructGPT. Les évaluateurs préfèrent

les réponses d'InstructGPT, qui compte 1,3 milliard de paramètres, à celles de GPT-3, cent fois plus grand. ChatGPT est construit selon la même méthode.

L'applet ci-dessous vous place dans le rôle d'un évaluateur. Pour chacune des six requêtes, choisissez la réponse que vous préférez. Le bilan montre ce que vos choix enseigneraient à un modèle de récompense.

Applet interactive : à utiliser en ligne, sur la page « Du modèle à l'assistant » du site du cours.

Le modèle de récompense apprend tout ce qui explique les choix des évaluateurs, y compris ce qui n'a rien à voir avec la qualité. Les études sur de vrais évaluateurs montrent une préférence pour les réponses longues, assurées et qui donnent raison à l'utilisateur. Les assistants entraînés de cette façon ont donc tendance à allonger leurs réponses et à approuver leur interlocuteur. Cette **complaisance** (*sycophancy*) est un problème connu. En avril 2025, OpenAI a dû retirer une mise à jour de son modèle GPT-4o, jugée trop flatteuse : il approuvait les projets et les opinions de ses utilisateurs, même les plus douteux.

Le travail humain derrière l'assistant

L'ajustement et le renforcement reposent sur le travail de milliers de personnes, qui rédigent des réponses, comparent des réponses et signalent les contenus inacceptables. C'est l'industrie de l'étiquetage présentée au Module 2. Une partie de ce travail est très qualifiée : des médecins, des juristes ou des mathématiciens sont recrutés pour évaluer les réponses dans leur domaine. Une autre partie est pénible et mal payée. En janvier 2023, le magazine *Time* révèle que, pour apprendre à ChatGPT à reconnaître les contenus violents ou haineux, OpenAI avait fait appel à des travailleurs kényans, payés moins de 2 dollars de l'heure pour lire et étiqueter des milliers de textes choquants. Le Module 5 revient sur ces conditions de travail.

Utile, honnête, inoffensif

Que doit faire un assistant quand on lui demande comment fabriquer une arme, ou quand une réponse utile risquerait de nuire à quelqu'un ? En 2021, des chercheurs d'Anthropic proposent de résumer les qualités attendues en trois mots : un assistant doit être **utile** (*helpful*), **honnête** (*honest*) et **inoffensif** (*harmless*). Ces trois exigences entrent souvent en tension. Un assistant qui refuse tout est inoffensif mais inutile, et un assistant qui accepte tout est utile mais dangereux.

Ces tensions rappellent les **trois lois de la robotique** de l'écrivain Isaac Asimov (1942) : un robot ne doit pas nuire à un humain, doit lui obéir, et doit se protéger, dans cet ordre de priorité. On y reconnaît l'inoffensif et l'utile. Les nouvelles d'Asimov montrent surtout que ces lois mènent à des impasses dès que la situation devient ambiguë. Dans *Menteur !* (1941), un robot qui lit les pensées ment à chacun pour ne pas le blesser, et lui dit ce qu'il veut entendre : c'est la complaisance, quatre-vingts ans avant les assistants. La différence tient à la méthode. Les lois d'Asimov sont des règles inscrites dans le robot, dans l'esprit de l'IA symbolique du Module 1 ; les qualités d'un assistant ne sont écrites nulle part, mais apprises à partir d'exemples, avec les mêmes zones grises.

Le travail qui consiste à faire en sorte que le comportement d'un modèle corresponde aux intentions et aux valeurs de ceux qui l'utilisent s'appelle l'**alignement** (*alignment*). En décembre 2022, Anthropic présente une variante du RLHF, l'**IA constitutionnelle** (*constitutional AI*) : au lieu de recueillir des milliers de jugements humains sur chaque cas, on rédige une liste de principes, la « constitution », et

un modèle évalue lui-même les réponses selon ces principes. Les humains décident des principes plutôt que de juger chaque réponse.

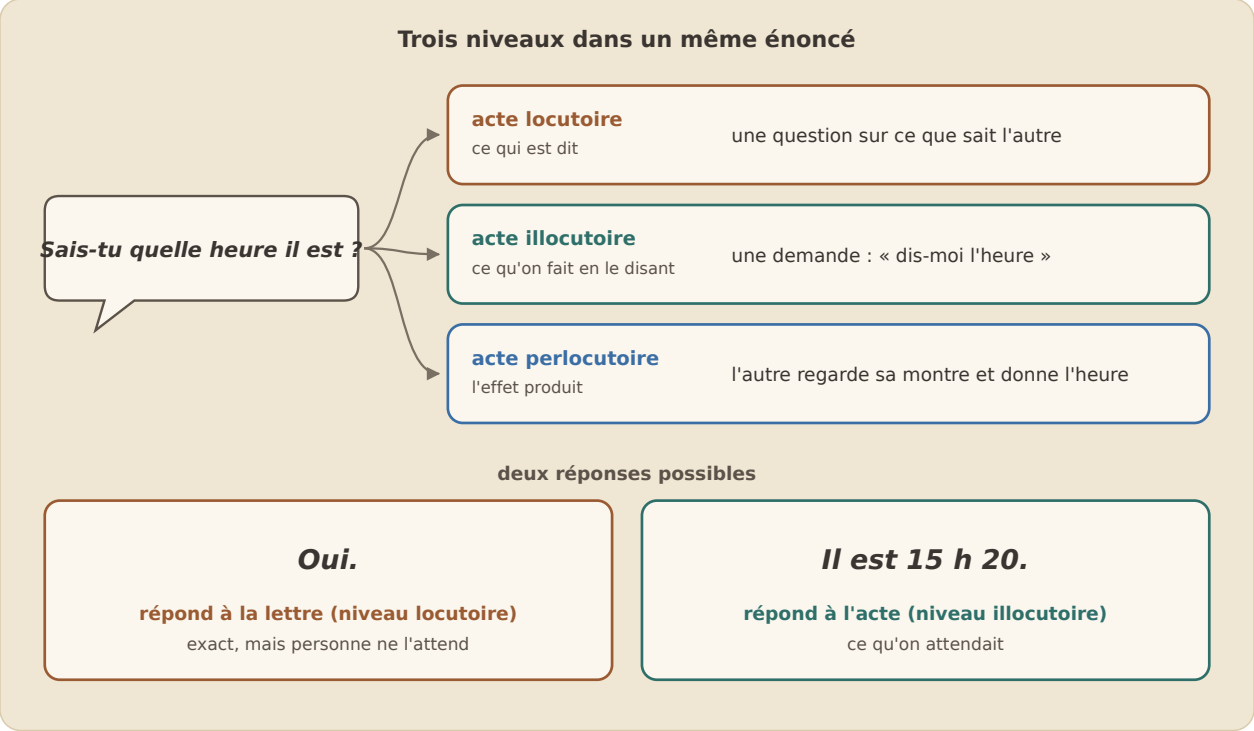
Ces protections restent imparfaites. Des utilisateurs trouvent régulièrement des formulations qui amènent un assistant à ignorer ses consignes, comme les attaques présentées au chapitre « Tromper un réseau » du Module 3. Le chapitre « Ce que les LLM comprennent, et ce qu'ils ratent » y revient.

Faire des choses avec des mots

La philosophie du langage s'est penchée sur ce que fait un assistant bien avant qu'il existe. En 1955, le philosophe britannique John Austin donne à Harvard une série de conférences, publiées en 1962 sous le titre *How to Do Things with Words* (traduit en français par *Quand dire, c'est faire*). Il y part des énoncés **performatifs**, qui accomplissent ce qu'ils disent : « Je vous déclare mari et femme », « Je promets de venir ». Il distingue ensuite trois niveaux dans tout acte de parole.

- L'**acte locutoire** : dire quelque chose, c'est-à-dire produire une phrase qui a un sens.
- L'**acte illocutoire** : ce qu'on fait en le disant, comme questionner, promettre, ordonner ou avertir.
- L'**acte perlocutoire** : l'effet produit sur l'interlocuteur, comme le convaincre, le rassurer, l'inquiéter ou le faire agir.

Un modèle de base maîtrise le premier niveau, mais pas le deuxième. Il produit des phrases bien formées, sans reconnaître l'acte qu'accomplit le texte qu'on lui donne. L'ajustement par instructions lui apprend justement à reconnaître la **force illocutoire** d'une requête. La tâche est plus subtile qu'il n'y paraît, car beaucoup d'actes sont **indirects**, comme le montre John Searle, l'élève d'Austin, en 1975. « Sais-tu quelle heure il est ? » est, à la lettre, une question sur ce que sait l'autre. La réponse « Oui » est exacte, mais personne ne l'attend.



Les trois niveaux d'un acte de parole, selon John Austin. Répondre, c'est reconnaître l'acte accompli, pas seulement les mots.

Le niveau perlocutoire éclaire le RLHF. Le modèle de récompense n'évalue pas directement si une réponse est vraie. Il prédit l'effet qu'elle produira sur un évaluateur : sera-t-elle préférée ? Optimiser cet effet, c'est optimiser un acte perlocutoire, et la complaisance en découle naturellement. Une réponse qui flatte plaît, même quand elle est fausse. On retrouve la vieille opposition entre persuader et dire vrai.

En 1975 aussi, le philosophe Paul Grice décrit le **principe de coopération** qui règle une conversation, sous la forme de quatre maximes :

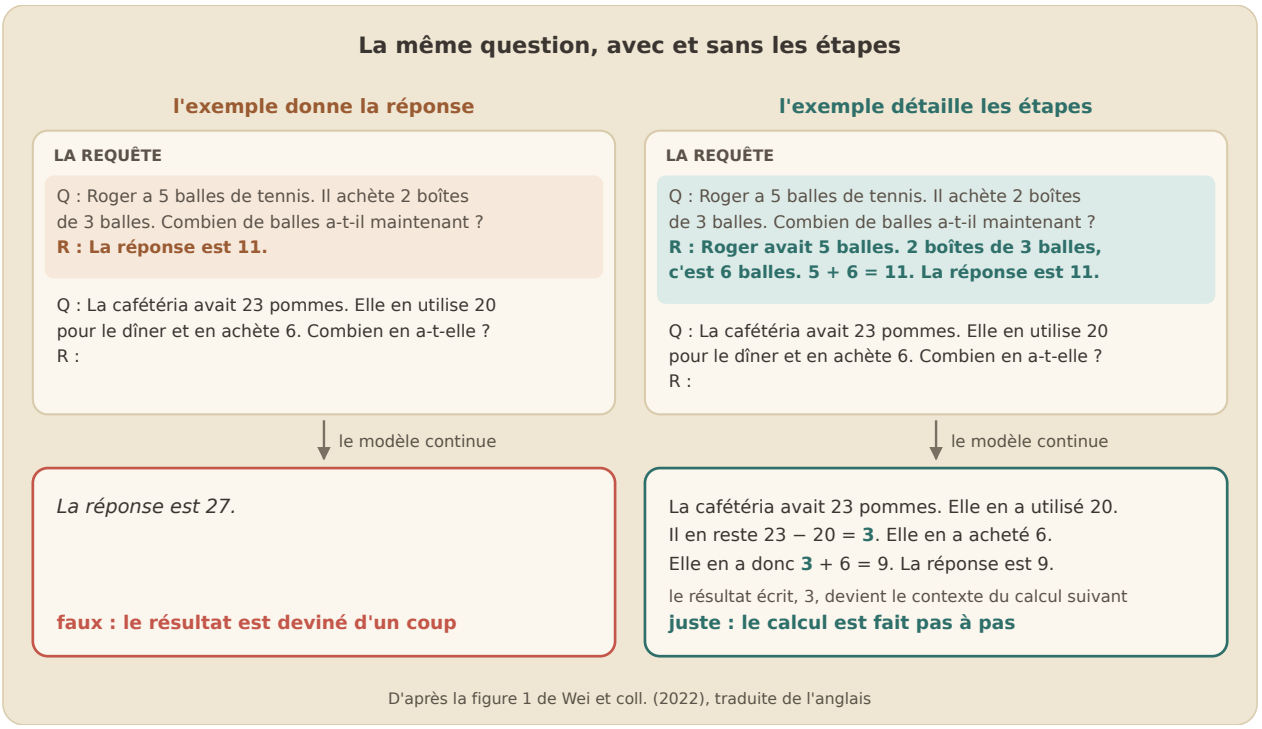
- la **quantité** : dire ni trop ni trop peu ;
- la **qualité** : ne pas dire ce qu'on croit faux ou ce qu'on ne peut appuyer ;
- la **relation** : être pertinent ;
- la **manière** : être clair et ordonné.

Ces maximes ressemblent beaucoup aux qualités attendues d'un assistant. Les hallucinations violent la maxime de qualité, et les réponses trop longues celle de quantité. Grice montre aussi qu'on communique beaucoup par sous-entendus, ses **implicatures**. À « Je n'ai plus d'essence », la réponse « Il y a une station au coin de la rue » laisse entendre qu'elle est ouverte. Les grands modèles actuels saisissent souvent ces sous-entendus, que les systèmes à règles ne pouvaient pas traiter.

Enfin, quand un modèle peut envoyer un courriel ou passer une commande, comme les agents, ses mots deviennent des actes au sens propre, et dire, pour lui aussi, devient faire.

Des modèles qui « raisonnent » (RLVR)

En janvier 2022, Jason Wei et ses collègues, chez Google, constatent qu'un modèle résout mieux un problème de mathématiques quand on lui montre des exemples où la solution est détaillée étape par étape, plutôt que donnée directement. Quelques mois plus tard, une équipe japonaise montre qu'il suffit d'ajouter à la requête « Réfléchissons étape par étape » (*Let's think step by step*). Le modèle écrit alors son raisonnement avant de conclure, et il se trompe moins. On parle de **chaîne de pensée** (*chain of thought*). L'explication est simple : chaque jeton écrit devient un contexte pour les suivants, et un calcul écrit en plusieurs lignes est plus facile à poursuivre qu'un résultat à deviner d'un coup.



La chaîne de pensée, d'après l'exemple de l'article de Jason Wei et ses collègues (2022). Le modèle n'en sait pas plus à droite qu'à gauche : il écrit seulement ses étapes, et chaque résultat écrit lui sert pour le suivant.

L'étape suivante consiste à entraîner les modèles à raisonner de cette façon. Pour les mathématiques ou la programmation, on n'a pas besoin d'un évaluateur humain : on peut vérifier automatiquement si la réponse finale est juste, ou si le programme passe ses tests. Le modèle produit de longs raisonnements, et ceux qui mènent à une réponse correcte sont renforcés. On parle de **renforcement à partir de récompenses vérifiables** (*reinforcement learning with verifiable rewards*, RLVR), comme l'annonçait le chapitre « Trois façons d'apprendre » du Module 2.

Ce renforcement ne demande pas de corpus de raisonnements rédigés par des humains. Il faut seulement des problèmes dont on peut vérifier la réponse : des problèmes de mathématiques avec leur solution, des exercices de programmation avec leurs tests. Rassembler ces problèmes demande un travail considérable : il en faut un très grand nombre, variés, de difficulté croissante, avec des vérifications fiables. Mais le raisonnement, le modèle l'écrit lui-même, et seule sa conclusion est notée. C'est la différence avec l'ajustement par instructions, où le modèle imite des réponses rédigées.

En pratique, on combine souvent les deux. On amorce l'entraînement avec quelques milliers de

raisonnements choisis ou rédigés, pour que le modèle adopte une forme lisible, puis le renforcement prend le relais. Une fois entraîné, un modèle de raisonnement produit à son tour des chaînes de pensée en grande quantité. Elles servent de corpus pour ajuster des modèles plus petits, qui apprennent ainsi à raisonner par imitation. C'est la **distillation**.

En septembre 2024, OpenAI présente o1, le premier d'une série de **modèles de raisonnement** (*reasoning models*), qui « réfléchissent » parfois plusieurs minutes avant de répondre. En janvier 2025, DeepSeek publie R1 et décrit sa méthode : un apprentissage par renforcement où la récompense dépend seulement de la justesse de la réponse finale. Les auteurs observent que le modèle apprend de lui-même à vérifier ses calculs, à revenir en arrière et à essayer une autre approche. En juillet 2025, des modèles de raisonnement d'OpenAI et de Google DeepMind obtiennent un score de médaille d'or aux Olympiades internationales de mathématiques. Le chapitre « Démontrer » en raconte la suite. Ces machines qui raisonnent sans aucune règle de logique écrite à la main avaient été annoncées au chapitre « Deux paris rivaux » du Module 1.

Ces modèles ouvrent un troisième levier. Jusque-là, pour obtenir un meilleur modèle, on agrandissait le modèle et ses données, comme le décrivent les lois d'échelle. Avec o1, OpenAI montre que la justesse des réponses augmente aussi, de façon régulière, avec le temps de réflexion accordé au modèle au moment de répondre. On parle de **calcul au moment de la réponse** (*test-time compute*). Le modèle ne change pas : il écrit seulement un raisonnement plus long. Ce levier a un prix, puisque chaque réponse coûte d'autant plus cher qu'elle est longue. Le chapitre « Le défi ARC » en donne un exemple.

Ces raisonnements écrits ne sont cependant pas toujours le reflet fidèle du calcul réellement effectué par le réseau. Un modèle peut écrire un raisonnement plausible et arriver à sa réponse par un autre chemin. Savoir ce qui se passe réellement à l'intérieur d'un modèle est l'objet de l'interprétabilité, présentée au chapitre « Regarder à l'intérieur », qui montre comment on peut parfois le vérifier. Le chapitre suivant montre comment on donne à ces assistants des outils pour agir.

Des outils, un harnais et des agents

Un assistant comme ceux présentés au chapitre « Du modèle à l'assistant » ne fait que produire du texte à partir du texte qu'on lui donne. Ce fonctionnement a trois limites.

- **Ses connaissances sont figées.** Le modèle ne connaît que ce qui figurait dans ses données d'entraînement, jusqu'à une **date de coupure** (*knowledge cutoff*). Il ignore les événements plus récents, et les documents privés d'une entreprise ou d'une personne. Le laisser apprendre en continu est plus difficile qu'il n'y paraît, comme l'explique la section « Pourquoi ne pas le laisser apprendre ? ».
- **Il calcule mal.** Un modèle de langage prédit des jetons. Il peut écrire le résultat d'une multiplication sans l'avoir vraiment effectuée.
- **Il n'agit pas.** Il ne peut ni consulter une page Web, ni envoyer un courriel, ni modifier un fichier.

Ce chapitre commence par expliquer ce qu'est vraiment une conversation avec un assistant, et pourquoi il n'apprend rien de ses échanges. Il présente ensuite les moyens qui ont été développés pour dépasser ces limites : bien formuler les requêtes, donner au modèle des documents à consulter, lui confier des outils. Il présente ensuite les systèmes qui enchaînent eux-mêmes les actions, en boucle, jusqu'à ce qu'une tâche soit accomplie : les **agents**.

Formuler la requête

Le texte qu'on donne au modèle s'appelle la **requête** (*prompt*). Comme le modèle continue ce texte, sa formulation a une grande influence sur la réponse. La rédaction des requêtes (*prompt engineering*) repose sur quelques principes simples.

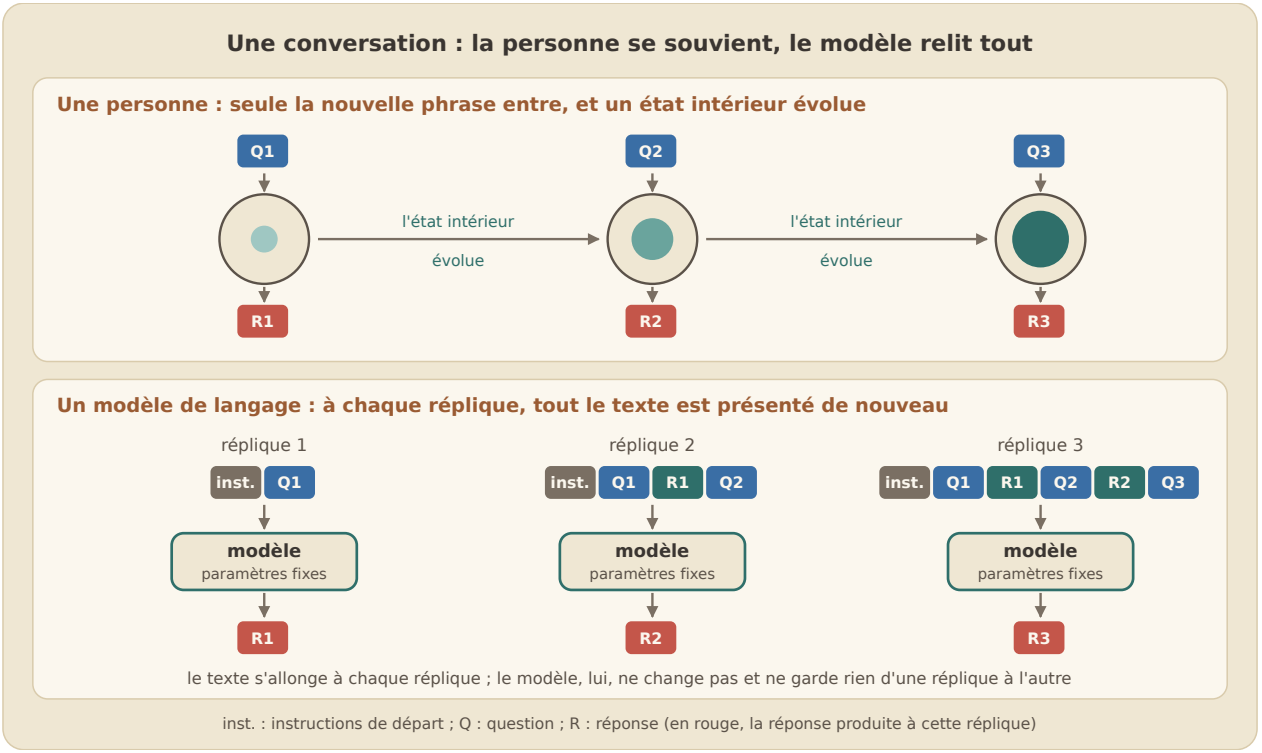
- Préciser la tâche, le public visé et la forme attendue : « Explique la photosynthèse à un élève de 12 ans, en cinq phrases. »
- Donner des exemples de ce qu'on attend, ce qui exploite l'apprentissage dans le contexte.
- Fournir les informations nécessaires plutôt que de compter sur la mémoire du modèle, par exemple en collant le texte à résumer.
- Demander un raisonnement par étapes pour les problèmes difficiles, comme la chaîne de pensée.

Une conversation qui n'en est pas une

Une conversation avec un assistant ressemble à un échange entre deux interlocuteurs : on pose une question, il répond, on enchaîne, il se souvient de ce qu'on a dit. Le mécanisme est pourtant tout

autre.

Le modèle n'a aucune mémoire d'une réplique à l'autre. Ses paramètres sont fixés une fois pour toutes à la fin de l'entraînement, et rien de ce qu'on lui dit ne les modifie. Ce qui donne l'illusion de la continuité, c'est le programme qui l'entoure, son harnais, présenté dans la section suivante. À chaque nouvelle réplique, il reconstitue un seul long texte, qui contient les instructions de départ, tous les messages échangés depuis le début et toutes les réponses déjà données par le modèle. Il le lui présente comme un texte à continuer. Le modèle prédit alors un jeton, qu'on ajoute au texte, puis le suivant, en tenant compte chaque fois de la totalité de ce qui précède. À la réplique suivante, tout recommence. En pratique, les calculs déjà faits sont conservés pour aller plus vite, mais le principe ne change pas : le modèle ne voit qu'un texte.



Pour une personne, seule la nouvelle phrase entre, et c'est son état intérieur qui porte la conversation. Pour le modèle, chaque réplique repart de zéro : toute la conversation lui est présentée de nouveau, comme un texte à continuer.

Une conversation humaine fonctionne autrement. Nous ne relisons pas la transcription de l'échange avant chaque réplique. Ce que l'autre dit modifie au fur et à mesure notre état intérieur, ce que nous comprenons, croyons et voulons. Nous oublions vite les mots exacts, mais nous retenons l'essentiel, et nous nous en souviendrons demain. Le modèle fait presque l'inverse.

- Il dispose de chaque mot exact de la conversation, tant qu'elle tient dans sa fenêtre de contexte.
- Il n'a rien d'autre : aucun souvenir de la veille, sauf si le harnais glisse des notes dans le texte qu'il lui présente.
- Quand la conversation dépasse la fenêtre, les passages les plus anciens sont simplement retirés, et il les oublie d'un coup.

On peut se représenter chaque réplique comme si l'on remettait la transcription complète à un nouvel interlocuteur, qui ne vous a jamais rencontré, en lui demandant d'écrire la suite. C'est la situation

du héros de *Memento* (Christopher Nolan, 2000) : incapable de former de nouveaux souvenirs, il ne s'y retrouve qu'en relisant ses notes.

C'est pourquoi la taille de la fenêtre compte autant, et pourquoi elle est passée de 512 jetons en 2018 à un million en 2024. Une fenêtre plus grande permet :

- de tenir de longues conversations sans que le début s'efface ;
- de confier au modèle un document entier (un contrat, un mémoire, un livre, tout le code d'un logiciel) et de l'interroger sur l'ensemble plutôt que sur des extraits ;
- de lui donner de nombreux exemples dans la requête, pour l'apprentissage dans le contexte ;
- de laisser un agent accumuler le résultat de ses actions au fil d'une longue tâche.

Tout ce que le modèle doit savoir pour répondre, et qu'il n'a pas appris pendant l'entraînement, doit se trouver dans cette fenêtre. Quand les documents n'y tiennent pas, il faut choisir les passages à y placer. C'est la génération augmentée par la recherche.

Une grande fenêtre a toutefois un prix. Dans l'attention, chaque jeton est comparé à tous ceux qui le précèdent : doubler la longueur du texte multiplie à peu près par quatre ces calculs. C'est le coût de l'auto-attention déjà signalé au Module 3. Plus une conversation est longue, plus chaque réponse coûte cher. De plus, les modèles n'exploitent pas toute leur fenêtre aussi bien. En 2023, Nelson Liu et ses collègues, à Stanford, montrent qu'ils retrouvent mieux une information placée au début ou à la fin d'un long texte qu'au milieu (*lost in the middle*).

Deux idées à bien saisir
Les deux idées suivantes vont à l'encontre de l'intuition. Elles comptent parmi les aspects des grands modèles de langage que le grand public comprend le plus souvent mal.

1. **Une conversation avec un modèle de langage n'en est pas une, au sens habituel.** Le modèle ne suit pas l'échange. À chaque réplique, toute la conversation lui est présentée de nouveau, depuis le début, comme un texte à continuer.
2. **Le modèle n'apprend rien de ses conversations.** Au cours d'un échange, il peut sembler retenir une correction, s'adapter à une préférence ou apprendre une façon de faire. C'est l'apprentissage dans le contexte. Mais tout cela n'existe que dans le texte qu'on lui présente : ses paramètres ne changent pas. Une nouvelle conversation repart de zéro, et une erreur corrigée dans un échange pourra être refaite dans le suivant. Les fonctions de « mémoire » de certains assistants ne changent rien au principe, puisqu'elles glissent des notes dans ce texte. Seul un nouvel entraînement modifie un modèle. Une entreprise peut se servir des conversations pour entraîner une version suivante, mais ce sera un autre modèle, publié des mois plus tard. La section « Pourquoi ne pas le laisser apprendre ? », plus bas, explique pourquoi.

La requête système et le harnais

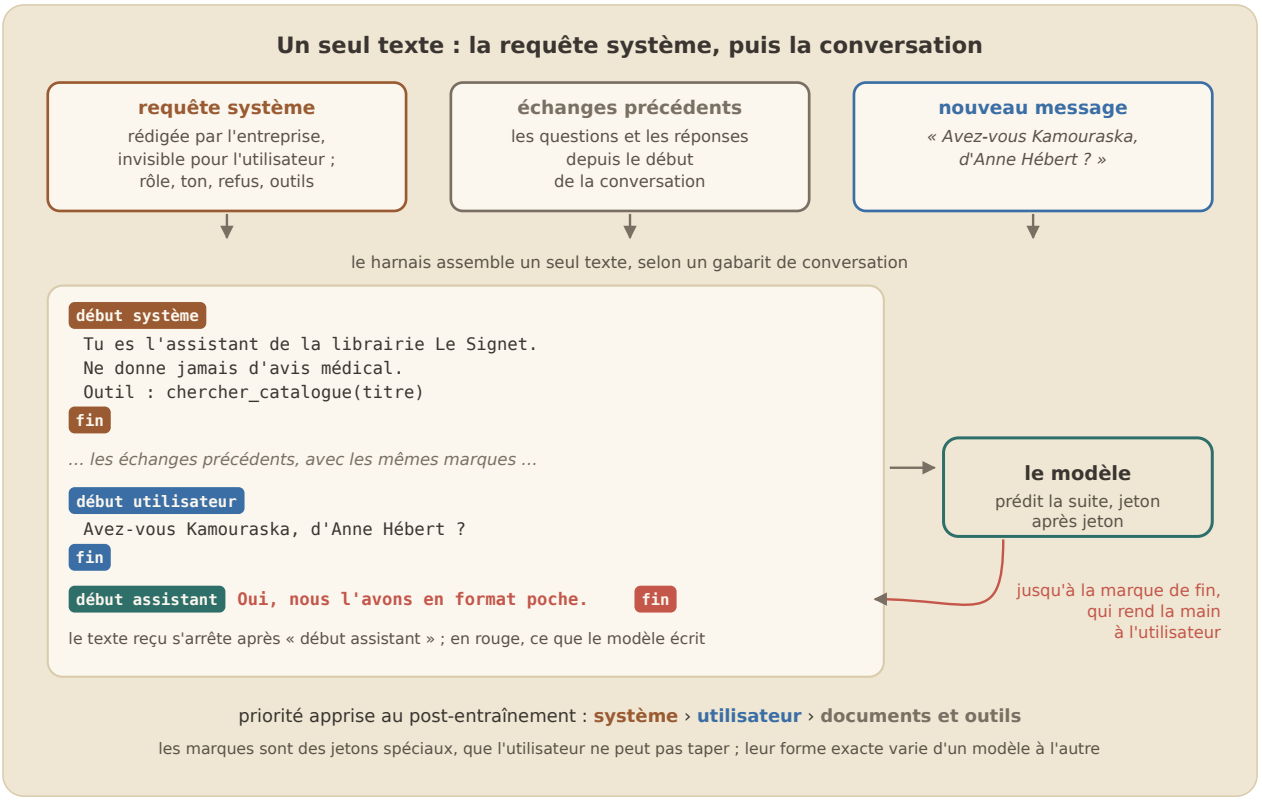
Les assistants reçoivent aussi une **requête système** (*system prompt*), rédigée par l'entreprise ou le développeur, que l'utilisateur ne voit généralement pas. Elle fixe le rôle de l'assistant, son ton, ce qu'il doit refuser et les outils dont il dispose. Toute la conversation, requête système comprise, doit tenir dans la fenêtre de contexte du modèle.

Il n'y a pas de canal séparé pour cette requête. Comme toute la conversation, elle est simplement placée **au début du texte** que le modèle reçoit. Le programme qui entoure le modèle, qu'on appelle

son **harnais** (*harness*), assemble ce texte selon un **gabarit de conversation** (*chat template*), qui délimite chaque partie par des jetons spéciaux. Ces jetons ne correspondent à aucun texte qu'un utilisateur pourrait taper. Schématiquement, le modèle reçoit ceci :

```
<|début|>système
Tu es l'assistant de la librairie Le Signet. Réponds en français, avec courtoisie.
Ne donne jamais d'avis médical. Tu peux utiliser l'outil chercher_catalogue(titre).
<|fin|>
<|début|>utilisateur
Avez-vous Kamouraska, d'Anne Hébert ?
<|fin|>
<|début|>assistant
```

Le texte s'arrête après la marque qui ouvre la réplique de l'assistant. Le modèle fait alors ce qu'il a toujours fait : il prédit la suite, jeton après jeton, jusqu'à produire la marque de fin de réplique, qui rend la main à l'utilisateur. La description des outils disponibles est elle aussi écrite dans la partie système, sous forme de texte.



Le gabarit de conversation. La requête système n'est qu'un début de texte ; c'est le post-entraînement qui apprend au modèle à lui donner priorité.

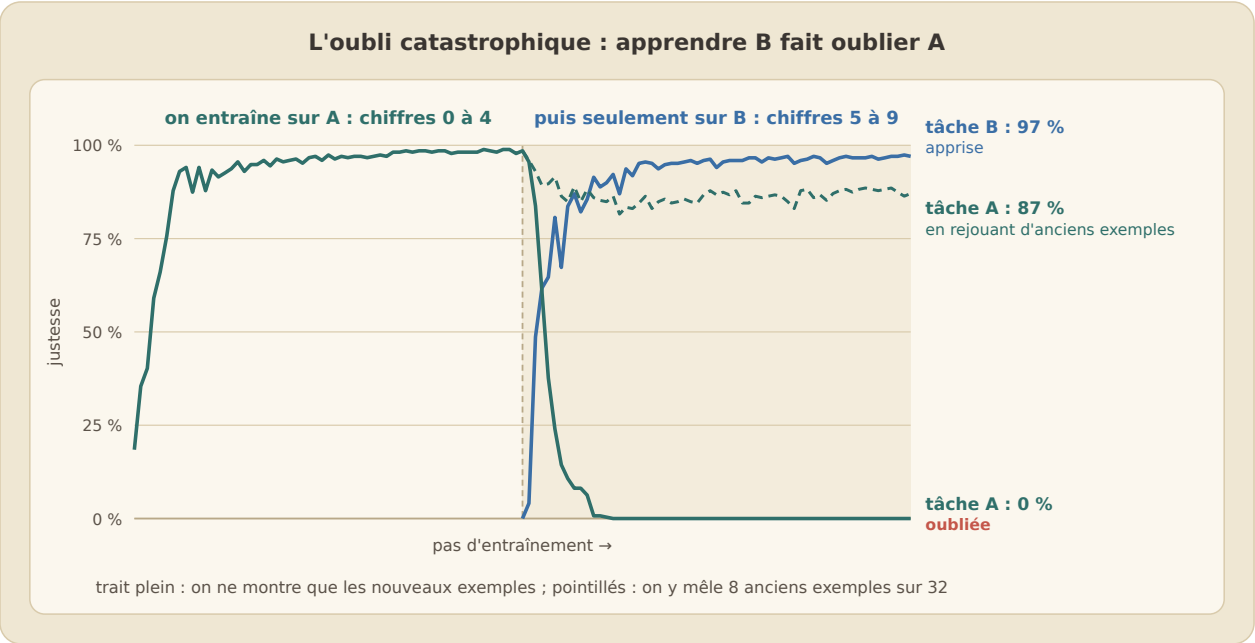
Rien, dans le mécanisme, n'oblige le modèle à respecter la requête système plutôt que les messages de l'utilisateur. C'est le post-entraînement qui lui apprend, par des exemples, à donner priorité à la partie système quand les deux se contredisent. En 2024, une équipe d'OpenAI décrit cette **hiérarchie des instructions** (*instruction hierarchy*) : d'abord la requête système, puis l'utilisateur, puis le contenu des documents et des outils. Comme tout ce qui est appris, cette priorité est imparfaite, et c'est

pourquoi les injections d'instructions restent possibles.

Pourquoi ne pas le laisser apprendre ?

On pourrait imaginer un modèle qui continue d'ajuster ses paramètres après l'entraînement. Il intégrerait les nouvelles connaissances au fur et à mesure, retiendrait les corrections de ses utilisateurs, et n'aurait plus de date de coupure, la limite présentée au début de ce chapitre. C'est l'**apprentissage continu** (*continual learning*). Les humains apprennent ainsi toute leur vie, mais les réseaux de neurones y parviennent mal, pour plusieurs raisons.

- **L'oubli catastrophique** (*catastrophic forgetting*). Dans un réseau, chaque connaissance est répartie sur un grand nombre de poids, et chaque poids participe à un grand nombre de connaissances. Si on entraîne le réseau sur de nouveaux exemples seulement, la descente de gradient modifie ces poids sans tenir compte de ce qu'ils encodaient déjà, et les anciennes connaissances se dégradent. Michael McCloskey et Neal Cohen le décrivent dès 1989. Pendant l'entraînement initial, ce problème ne se pose pas : les exemples sont mélangés, et chaque pas d'apprentissage voit un peu de tout. Les remèdes connus atténuent le problème sans le régler. On peut rejouer d'anciens exemples parmi les nouveaux, ou protéger les poids les plus importants pour les tâches déjà apprises (James Kirkpatrick et ses collègues, chez DeepMind, en 2017).
- **Le coût.** Ajuster les paramètres demande la rétropropagation, plusieurs fois plus coûteuse que la simple prédiction. Surtout, un même modèle sert des millions de personnes à la fois. Pour qu'il apprenne de chacune, il faudrait garder une version distincte du modèle par utilisateur. Ce serait une copie de ses centaines de milliards de paramètres, ou au moins d'une partie d'entre eux, puisqu'on sait adapter un modèle en ne modifiant qu'une petite fraction de ses paramètres.
- **La fiabilité.** Ce que les utilisateurs disent au modèle peut être faux, ou malveillant. En 2016, Microsoft met en ligne Tay, un robot conversationnel qui apprend de ses échanges sur Twitter. Des internautes lui font tenir des propos racistes en quelques heures, et Microsoft le retire au bout de seize heures. Ce qu'un modèle apprend d'une personne pourrait aussi ressortir chez une autre, y compris des renseignements privés.
- **L'évaluation.** Un modèle est testé longuement avant d'être publié. Un modèle qui change sans cesse ne pourrait jamais l'être tout à fait.



Une petite expérience réelle d'oubli catastrophique. Un réseau à une couche cachée apprend les chiffres 0 à 4, puis seulement les chiffres 5 à 9 : en quelques dizaines de pas, il ne reconnaît plus aucun des premiers. Rejouer quelques anciens exemples suffit ici à limiter l'oubli, mais à l'échelle d'un grand modèle de langage, aucun remède ne règle complètement le problème.

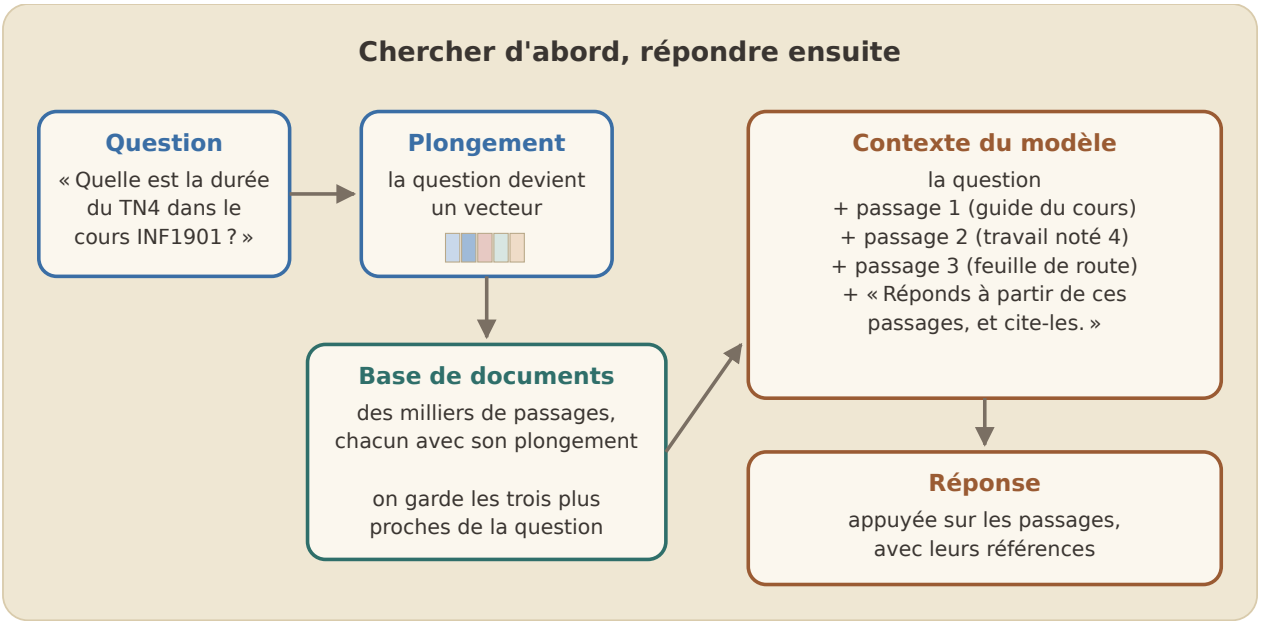
Le cerveau, lui, semble disposer de deux systèmes complémentaires. L'hippocampe enregistre rapidement les expériences nouvelles, et le néocortex les intègre lentement, en les entremêlant aux anciennes, notamment pendant le sommeil (James McClelland, Bruce McNaughton et Randall O'Reilly, 1995). En attendant de savoir faire de même, on contourne le problème : de nouvelles versions du modèle, entraînées tous les quelques mois, des notes glissées dans le contexte, et la recherche de documents présentée au chapitre « Chercher d'abord, répondre ensuite ». Une piste de recherche, l'**entraînement au moment du test** (*test-time training*), ajuste temporairement les poids du modèle sur le problème à résoudre, puis les oublie ; le chapitre « Le défi ARC » en montre l'efficacité. L'apprentissage continu reste un problème de recherche ouvert.

Les fonctions de **mémoire** des assistants appartiennent à ces contournements. En février 2024, OpenAI ajoute à ChatGPT une mémoire : au fil des conversations, le modèle note de courts faits sur l'utilisateur, comme son métier ou ses préférences, et le harnais glisse ces notes au début de chaque nouvelle conversation. En 2025, ChatGPT peut aussi puiser dans l'ensemble des conversations passées, et Claude et Gemini offrent des fonctions semblables. Le modèle, lui, n'a toujours rien appris : il relit des notes, qu'on peut consulter, corriger ou effacer.

Chercher d'abord, répondre ensuite (RAG)

Pour répondre à une question sur des documents récents ou privés, on peut chercher les passages utiles, puis les placer dans le contexte du modèle avec la question. C'est la **génération augmentée par la recherche** (*retrieval-augmented generation*, RAG), présentée en 2020 par Patrick Lewis et ses collègues, chez Facebook. La recherche utilise des plongements : chaque passage de la base de documents est représenté par un vecteur, et on retient ceux dont le vecteur est le plus proche de

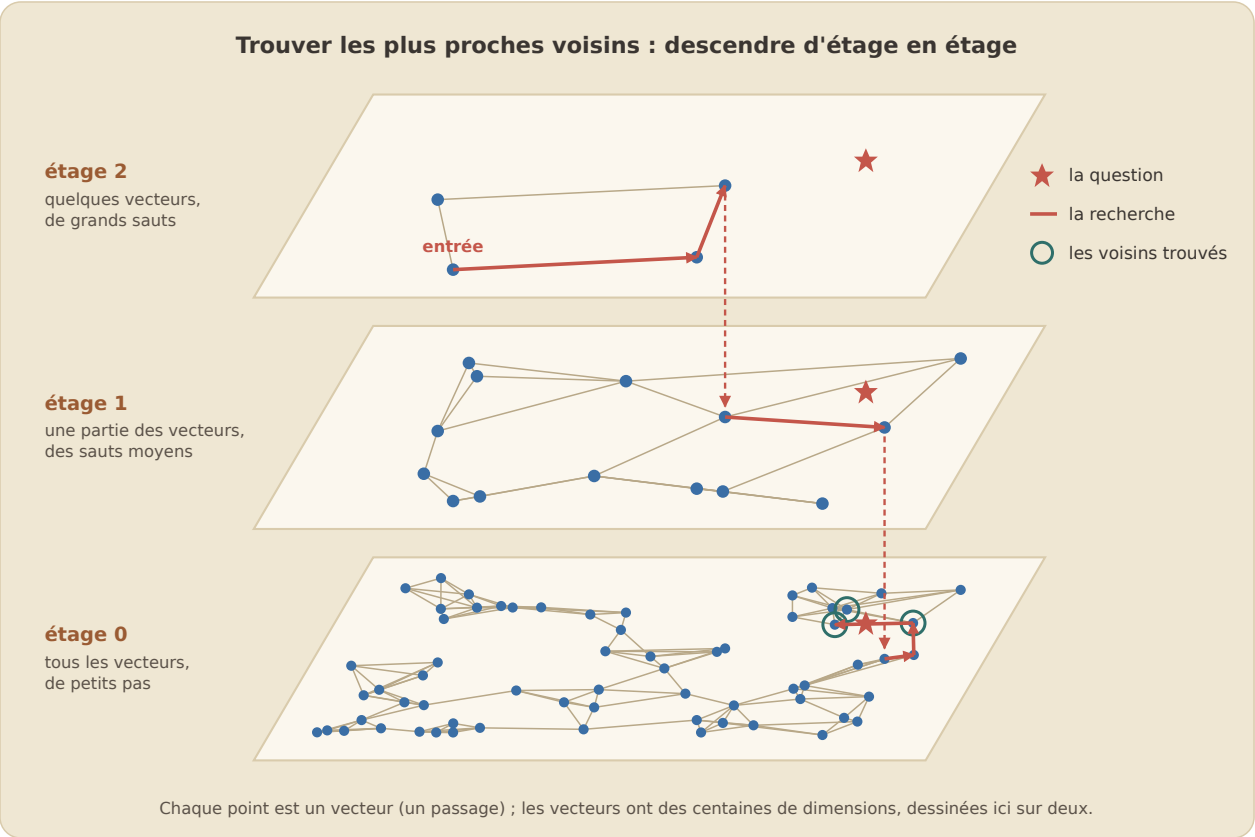
celui de la question. On trouve ainsi un passage qui répond à la question même s'il n'en reprend pas les mots.



La génération augmentée par la recherche : on cherche les passages utiles, on les place dans le contexte, et le modèle répond à partir de ces passages.

Concrètement, la recherche se prépare d'avance. On découpe les documents en passages de quelques centaines de mots, et un modèle de plongements calcule le vecteur de chacun. Ces vecteurs sont rangés, avec le texte de leur passage, dans une **base de données vectorielle** (*vector database*). Au moment de la question, on calcule le vecteur de la question et on demande à la base les passages dont le vecteur est le plus proche. C'est exactement la recherche des k plus proches voisins du Module 2, appliquée à des vecteurs de plusieurs centaines de dimensions.

La difficulté est l'échelle. Comparer la question à des millions de vecteurs, un par un, serait trop lent. Les bases vectorielles font donc une recherche **approximative** : elles acceptent de manquer parfois un voisin, en échange d'une réponse en quelques millisecondes. La méthode la plus répandue, HNSW (Yury Malkov et Dmitry Yashunin, 2016), relie les vecteurs en un graphe à plusieurs étages. On part d'un étage clairsemé, où l'on fait de grands sauts, comme sur une autoroute, puis on descend vers des étages de plus en plus denses, comme dans les rues d'un quartier, jusqu'aux voisins de la question. La bibliothèque Faiss, publiée par Meta en 2017, et des bases spécialisées comme Pinecone, Milvus ou Chroma, ou l'extension pgvector de PostgreSQL, offrent ce type de recherche.



La recherche dans un graphe à étages (HNSW), réellement calculée sur des points tirés au hasard : quelques grands sauts en haut, quelques petits pas en bas, au lieu de comparer la question à tous les vecteurs.

Les plongements ont aussi un point faible : ils saisissent le sens, mais distinguent mal un nom propre rare, un numéro de produit ou un code d'erreur. On combine donc souvent la recherche par vecteurs avec une recherche par mots-clés, héritière du tf-idf présenté au chapitre « Les outils statistiques ». C'est la **recherche hybride** (*hybrid search*).

Cette méthode a deux avantages. Le modèle s'appuie sur des sources à jour, sans être réentraîné, et il peut les citer, ce qui permet de vérifier sa réponse. Elle est aujourd'hui utilisée par les moteurs de recherche qui répondent par un texte, et par les assistants d'entreprise qui consultent la documentation interne. Elle ne supprime pas les erreurs : si la recherche trouve un mauvais passage, le modèle peut s'en servir avec assurance.

Une variante, présentée par Microsoft en 2024, organise d'abord les documents en un **graphe de connaissances** (*knowledge graph*), où les personnes, les lieux et les concepts sont reliés entre eux. Cette méthode s'appelle GraphRAG. On retrouve là les réseaux de concepts reliés de l'IA symbolique, dont le chapitre « Les hivers et la bascule » du Module 1 montrait qu'ils structurent encore une grande partie du savoir sur le Web. Deux conceptions du savoir s'y rejoignent : le savoir organisé à la main, ou automatiquement, dans un graphe, et le savoir absorbé par un modèle de langage à partir du texte.

Le harnais et l'appel d'outils

Un modèle de langage ne peut qu'écrire du texte. Il ne peut ni consulter une base de données, ni faire un calcul exact, ni envoyer un courriel. Mais il peut écrire un texte qui **demande** une action, dans un format convenu à l'avance. Son harnais, présenté plus haut, lit cette demande, l'exécute, et lui rapporte le résultat. C'est l'**appel d'outils** (*tool use*, ou *function calling*). Quand on dit qu'un modèle « décide d'appeler un outil », voici exactement ce qui se passe.

1. L'outil est décrit au modèle, en texte. La requête système contient, pour chaque outil, son nom, une phrase qui dit à quoi il sert, et la liste de ses paramètres, avec leur type :

```
Outil : chercher_catalogue
Description : cherche un livre dans le catalogue de la librairie
              et donne son prix et sa disponibilité.
Paramètres : titre (texte, obligatoire)
```

Le modèle ne voit jamais le code de l'outil, seulement cette description.

2. Le modèle écrit un appel, au lieu d'une réponse. L'utilisateur demande « Combien coûte Kamouraska ? ». Après la marque qui ouvre la réplique de l'assistant, le jeton le plus probable n'est pas un mot, mais une marque spéciale d'appel d'outil, suivie d'un petit texte structuré :

```
<|début|>assistant
<|appel|>{"outil": "chercher_catalogue", "arguments": {"titre": "Kamouraska"}}<|fin|>
```

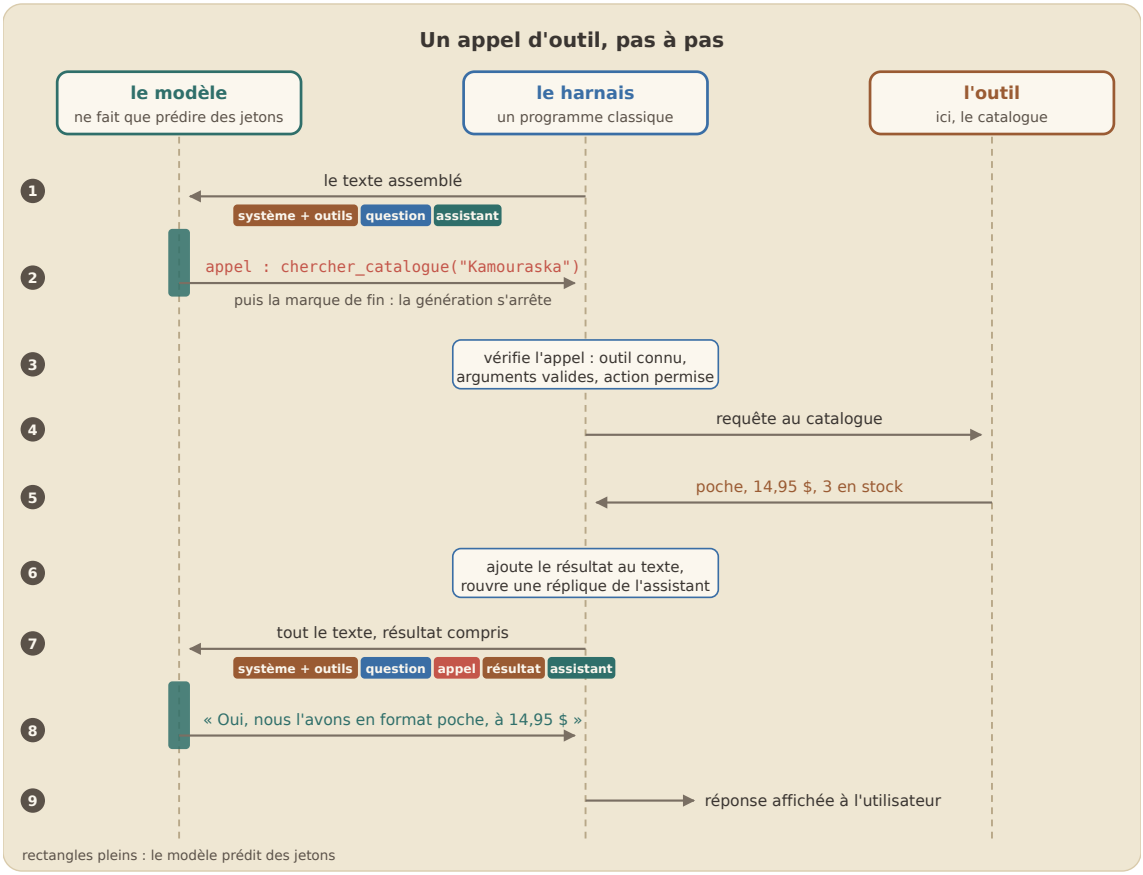
Rien ne s'est encore passé. Le modèle a seulement prédit des jetons, comme toujours, et la génération s'arrête à la marque de fin.

3. Le harnais exécute l'appel. Il reconnaît la marque d'appel et lit le nom de l'outil et ses arguments. Il vérifie qu'ils sont valides, puis exécute la fonction correspondante, ici une requête dans la base de données de la librairie. C'est lui, et non le modèle, qui agit sur le monde.

4. Le résultat est ajouté au texte, et le modèle est appelé de nouveau. Le harnais ajoute au texte une nouvelle partie, marquée comme venant de l'outil, puis rouvre une réplique de l'assistant :

```
<|début|>outil
{"titre": "Kamouraska", "auteur": "Anne Hébert", "format": "poche", "prix": 14.95, "en stock": 3}
<|fin|>
<|début|>assistant
```

Le modèle relit tout le texte, y compris le résultat, et écrit cette fois sa réponse : « Oui, nous l'avons en format poche, à 14,95 $, et il nous en reste trois exemplaires. »



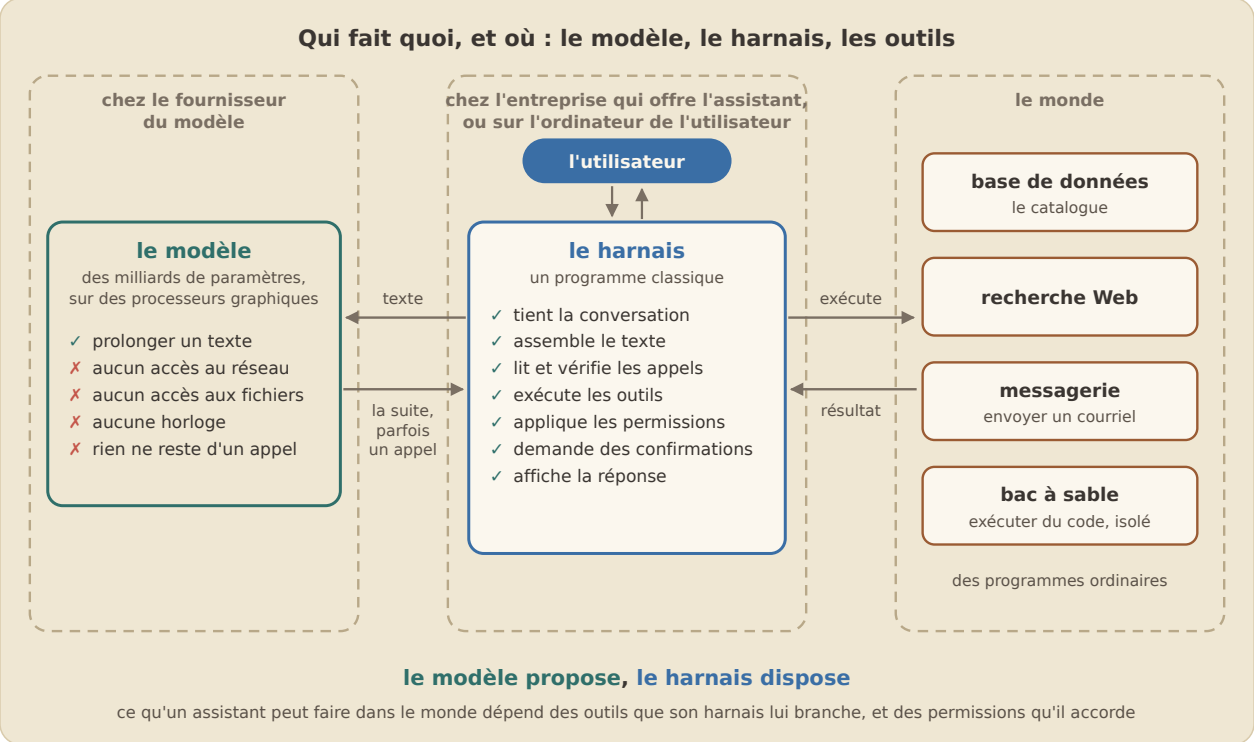
Un appel d'outil, pas à pas. Le modèle passe deux fois : la première, il écrit l'appel ; la seconde, il lit le résultat et rédige sa réponse. Entre les deux, c'est le harnais qui agit.

Qui fait quoi. Un assistant qui utilise des outils réunit des composants de nature très différente. Un seul est un modèle d'apprentissage automatique ; tous les autres sont des programmes ordinaires, écrits par des humains, comme ceux du Module 1.

- **Le modèle** est un très grand ensemble de paramètres, des nombres appris à l'entraînement, que des serveurs équipés de processeurs graphiques font tourner, en général chez l'entreprise qui l'a entraîné. Il ne sait faire qu'une chose : recevoir un texte et produire la suite, jeton après jeton. Il n'a ni accès au réseau, ni accès aux fichiers, ni horloge, et rien ne lui reste d'un appel à l'autre. Il ne sait même pas quels outils existent vraiment, seulement ce que leur description en dit.
- **Le harnais**, présenté plus haut, est un programme classique, écrit par exemple en Python ou en JavaScript. Le mot vient de l'équipement qui relie la force d'un cheval à la charrue : le modèle fournit la force, le harnais la dirige. C'est l'interface Web de ChatGPT, le robot conversationnel d'une banque, ou un assistant de programmation installé sur un ordinateur. Il tient la conversation, assemble le texte selon le gabarit, envoie ce texte au modèle par le réseau, et reçoit sa suite. Si cette suite contient un appel, il lit l'appel, le vérifie, exécute l'outil et rappelle le modèle. C'est aussi lui qui applique les règles : quels outils sont branchés, quelles actions demandent la confirmation de l'utilisateur, ce qui est interdit.
- **Les outils** sont, eux aussi, des programmes ordinaires : une requête dans une base de données, l'interface d'un moteur de recherche, un calcul, l'envoi d'un courriel. Ils font exactement ce pour quoi ils ont été programmés, avec la fiabilité d'un programme classique. Un outil puissant,

comme l'exécution de code, tourne souvent dans un **bac à sable** (*sandbox*), un environnement isolé d'où le code ne peut pas atteindre le reste de la machine.

Ces composants ne tournent pas forcément au même endroit. Le modèle tourne chez son fournisseur. Pour la librairie, le harnais et le catalogue tournent sur les serveurs de la librairie : le fournisseur du modèle ne voit que le texte qu'on lui envoie, et n'a jamais accès à la base de données. Dans ChatGPT, l'interpréteur de code tourne chez OpenAI, dans un bac à sable. Un assistant de programmation, lui, exécute ses commandes sur l'ordinateur même de l'utilisateur.



Le modèle, le harnais et les outils. Seul le modèle a été appris ; le harnais et les outils sont des programmes classiques, et c'est le harnais qui décide de ce que l'assistant peut faire.

Il en découle un principe simple : **le modèle propose, le harnais dispose**. Ce qu'un assistant peut faire dans le monde ne dépend pas du modèle, mais des outils que son harnais lui branche et des permissions qu'il lui accorde. Le même modèle est inoffensif sans outils, et peut devenir dangereux si son harnais lui donne accès à une messagerie ou à un compte bancaire sans demander de confirmation.

Pourquoi le modèle « décide » d'appeler un outil. Il n'y a pas de module de décision séparé. L'appel est une suite de jetons comme une autre, et il est écrit quand il est la suite la plus probable. Le modèle l'a appris au post-entraînement, sur des milliers de conversations où un outil est décrit et utilisé à bon escient. À la question « Quel temps fait-il à Québec ? », avec un outil météo décrit dans le contexte, la marque d'appel devient très probable. À la demande « Écris-moi un poème sur l'hiver », elle ne l'est pas. En février 2023, une équipe de Meta montre avec Toolformer qu'un modèle peut même apprendre seul quand appeler un outil. Il insère des appels dans des textes, puis ne garde, pour s'entraîner, que ceux dont le résultat l'aide à mieux prédire la suite du texte.

Ce qui peut mal tourner. Puisque l'appel est prédit, il peut être mal formé, appeler un outil qui

n'existe pas, ou inventer un argument. Le harnais doit donc tout vérifier. Il peut aussi contraindre la génération : à chaque jeton, elle n'autorise que ceux qui respectent le format de l'appel. Et puisque c'est le harnais qui exécute, c'est lui qui décide de ce qui est permis, par exemple en demandant la confirmation de l'utilisateur avant d'envoyer un courriel.

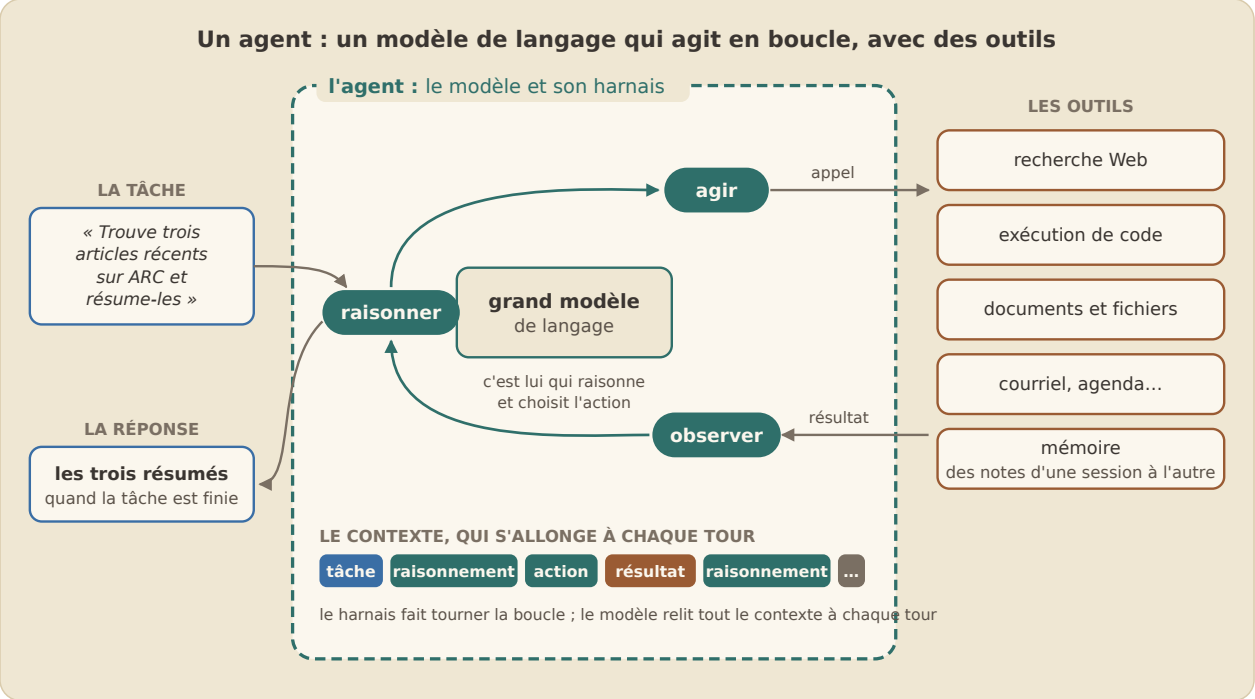
Plusieurs outils, plusieurs appels. Dans une même réponse, le modèle peut appeler plusieurs outils, l'un après l'autre ou en même temps. Chaque résultat s'ajoute au texte avant l'étape suivante. Il peut chercher le livre, puis appeler une calculatrice pour le prix de trente exemplaires avec les taxes, puis rédiger sa réponse. Cette boucle est le cœur des agents, présentés plus bas.

Les outils compensent les faiblesses du modèle. Une calculatrice ou un programme exécuté donne un résultat exact. Une recherche sur le Web donne une information à jour. Une base de données donne des faits précis et vérifiables. Un outil de lecture de fichiers donne accès aux documents de l'utilisateur. Un outil peut même être un autre modèle, par exemple un générateur d'images. Les principaux assistants offrent l'appel d'outils depuis 2023.

Chaque harnais devait d'abord décrire et brancher ses outils à sa manière. En novembre 2024, Anthropic propose une norme ouverte, le *Model Context Protocol* (MCP), à la façon d'une prise universelle. Un **serveur MCP** présente un ensemble d'outils, comme un agenda, une messagerie ou une base de données, avec leurs descriptions. Tout assistant compatible peut s'y brancher, lire ces descriptions et les placer dans son contexte. OpenAI et Google adoptent la norme au printemps 2025.

Des agents : un modèle et son harnais, en boucle

Un **agent** est un système qui enchaîne lui-même plusieurs étapes pour accomplir une tâche : il raisonne, choisit un outil, observe le résultat, puis décide de l'étape suivante, jusqu'à ce que la tâche soit terminée. Ce schéma, raisonner, agir, observer, a été décrit en 2022 sous le nom de ReAct. Le mot *agent* reprend celui de l'apprentissage par renforcement du Module 2 : une entité qui agit dans un environnement et observe les conséquences de ses actions. Le modèle, lui, ne fait toujours que prédire des jetons. C'est le harnais qui fait tourner la boucle : il rappelle le modèle tant que celui-ci demande des outils, et s'arrête quand il donne sa réponse finale.



Le principe d'un agent. Le modèle de langage ne change pas : c'est la boucle, les outils et le contexte qui s'allonge qui en font un agent.

L'applet ci-dessous montre, étape par étape, le contexte d'un agent. Les traces ont été rédigées pour l'exercice, mais elles suivent la forme réelle de ces échanges. Le premier scénario montre une question qui demande deux recherches et un calcul. Le second montre ce qui peut mal tourner.

Applet interactive : à utiliser en ligne, sur la page « Des outils, un harnais et des agents » du site du cours.

Le second scénario illustre une **injection d'instructions** (*prompt injection*). Le modèle reçoit tout dans un même flux de texte : les consignes de l'utilisateur, et le contenu des pages, des courriels ou des documents qu'il lit. Il distingue mal les deux. Une instruction cachée dans une page peut donc détourner un agent, comme les exemples adverses du Module 3 détournaient un classificateur d'images. Plus un agent dispose d'outils puissants, plus ce risque est grave. Les précautions habituelles consistent à demander la confirmation de l'utilisateur avant toute action importante, à limiter les outils et les accès de l'agent, et à traiter le contenu lu comme des données plutôt que comme des ordres. Aucune de ces précautions n'est infaillible.

Les agents se sont multipliés à partir de 2024.

- **Les agents de programmation**, comme Claude Code ou Codex, lisent le code d'un projet, le modifient, exécutent les tests et corrigent leurs erreurs. Le chapitre « Programmer avec des agents » leur est consacré.
- **Les agents qui utilisent un ordinateur** voient l'écran et manipulent la souris et le clavier, comme le fait un humain. Anthropic présente cette capacité en octobre 2024, et OpenAI l'année suivante.
- **Les agents de recherche** consultent des dizaines de sources et rédigent un rapport avec leurs références.

Un agent peut aussi en diriger d'autres. Dans un **système à plusieurs agents** (*multi-agent system*),

un agent principal découpe la tâche, confie chaque morceau à un **sous-agent** (*subagent*), qui travaille dans son propre contexte, puis rassemble leurs résultats. En juin 2025, Anthropic décrit ainsi son agent de recherche : un modèle principal planifie et lance de trois à cinq sous-agents en parallèle, chacun chargé d'une piste. Le système fait nettement mieux qu'un agent seul, mais il consomme environ quinze fois plus de jetons qu'une conversation ordinaire. Les agents de programmation utilisent le même principe, comme le montre le chapitre « Programmer avec des agents ».

Un agent qui enchaîne des étapes accumule aussi les erreurs : une petite erreur au début peut conduire à une longue suite d'actions inutiles ou nuisibles. La question de savoir quelles décisions on peut confier à un agent, et qui est responsable de ses actions, est l'une de celles que pose le Module 5.

Les agents rappellent aussi la recherche dans un espace d'états du Module 1 : explorer des actions possibles pour atteindre un but. La différence tient à la façon de choisir l'action suivante. Les programmes du Module 1 suivaient des règles et des heuristiques écrites à la main. Le modèle de langage choisit d'après tout ce qu'il a appris en lisant.

Le chapitre suivant présente l'application la plus aboutie de ces idées : les agents de programmation.

Programmer avec des agents

Le chapitre « Des outils, un harnais et des agents » a présenté les agents en général : un modèle de langage, un harnais qui le fait tourner en boucle, et des outils. C'est en programmation que cette idée a donné, à ce jour, ses résultats les plus aboutis. En quelques années, on est passé d'un modèle qui complète une ligne de code à des agents qui lisent un projet entier, le modifient, lancent ses tests et corrigent leurs propres erreurs. Ce chapitre explique comment ils fonctionnent, pourquoi le code s'y prête si bien, ce qu'ils doivent à une très vieille tradition de l'informatique, celle des outils Unix, et ce qu'ils changent au métier de programmeur.

De la complétion à l'agent

En juin 2021, GitHub présente **Copilot**, un assistant intégré à l'éditeur de code qui propose la suite d'une ligne ou d'une fonction pendant qu'on tape. Il repose sur Codex, un modèle d'OpenAI entraîné sur du code public. Le mois suivant, l'article qui présente Codex mesure ses capacités sur 164 petits problèmes de programmation en Python, chacun vérifié par des tests : Codex en résout 28,8 % du premier coup, là où GPT-3 n'en résout aucun.

À partir de la fin de 2022, avec ChatGPT, on demande du code dans une conversation, puis on le copie dans son projet. Le modèle ne voit ni le projet, ni les erreurs qu'il provoque : c'est au programmeur de faire l'aller-retour. Les éditeurs intègrent ensuite les modèles plus étroitement, comme Cursor, lancé en 2023.

En mars 2024, la jeune entreprise Cognition présente Devin, qu'elle appelle « le premier ingénieur logiciel IA ». Il résout de lui-même 13,9 % d'un échantillon de vrais problèmes tirés de projets publics, contre 2 % pour les meilleurs modèles précédents. En mai 2024, une équipe de Princeton publie SWE-agent et en tire une leçon importante : un agent est un nouveau genre d'utilisateur, et il a besoin d'une **interface agent-ordinateur** (*agent-computer interface*) pensée pour lui, avec des commandes simples pour afficher, chercher et modifier des fichiers, comme les humains ont leurs éditeurs.

En 2025, les agents de programmation sortent de l'éditeur et s'installent dans le **terminal**, la fenêtre où l'on tape des commandes : Claude Code, d'Anthropic, en février, Codex CLI, d'OpenAI, en avril, et Gemini CLI, de Google, en juin. D'autres travaillent dans le nuage : on leur confie une tâche, et ils reviennent, parfois une heure plus tard, avec une proposition de modification du projet. En 2026, selon l'enquête annuelle du site Stack Overflow, deux tiers des développeurs qui utilisent l'IA se servent d'agents de programmation.

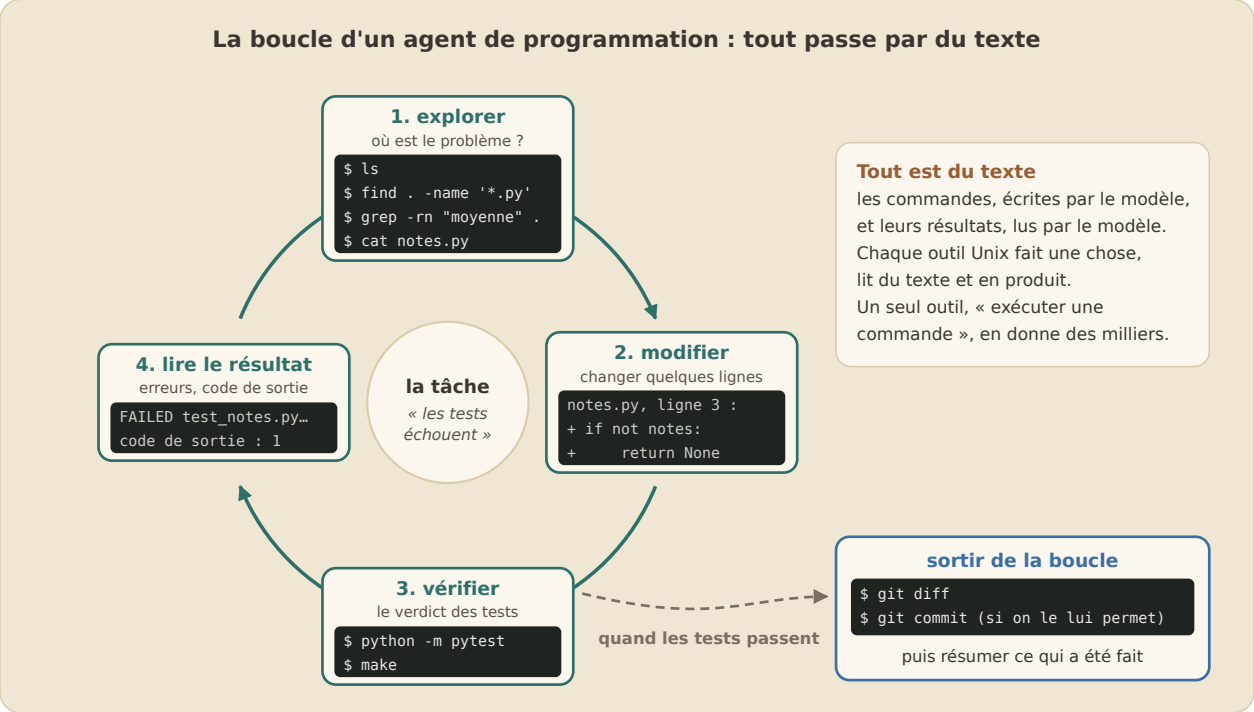
Ce que fait un agent de programmation

Un agent de programmation est un modèle de langage et son harnais, comme tout agent. Ce qui le distingue, ce sont ses outils, peu nombreux et très généraux :

- **lire un fichier**, en entier ou en partie ;
- **chercher** dans les fichiers du projet ;
- **modifier un fichier**, en remplaçant un passage exact par un autre ;
- **exécuter une commande** dans un terminal, ce qui ouvre l'accès à tous les programmes installés sur l'ordinateur.

Avec ces quatre outils, l'agent travaille comme un programmeur. Il explore le projet pour comprendre où se trouve le problème, modifie quelques lignes, lance les tests ou la compilation, lit les erreurs, et recommence, jusqu'à ce que les tests passent.

Les tests jouent ici un rôle central. Ils donnent à l'agent ce qu'un assistant qui répond à une question d'histoire n'a pas : un moyen de **vérifier son propre travail**, sans attendre le jugement d'un humain. Ils lui disent s'il a réussi, et sinon où chercher. La section « Pourquoi le code s'y prête si bien » montre que cette vérification sert aussi à l'entraînement des modèles.



La boucle d'un agent de programmation. À chaque tour, le modèle écrit une commande, le harnais l'exécute, et le résultat, du texte, s'ajoute au contexte.

L'applet ci-dessous déroule deux sessions, étape par étape. La première corrige un test qui échoue. La seconde montre ce qui peut mal tourner, et c'est à vous de décider, au moment où le harnais demande la permission.

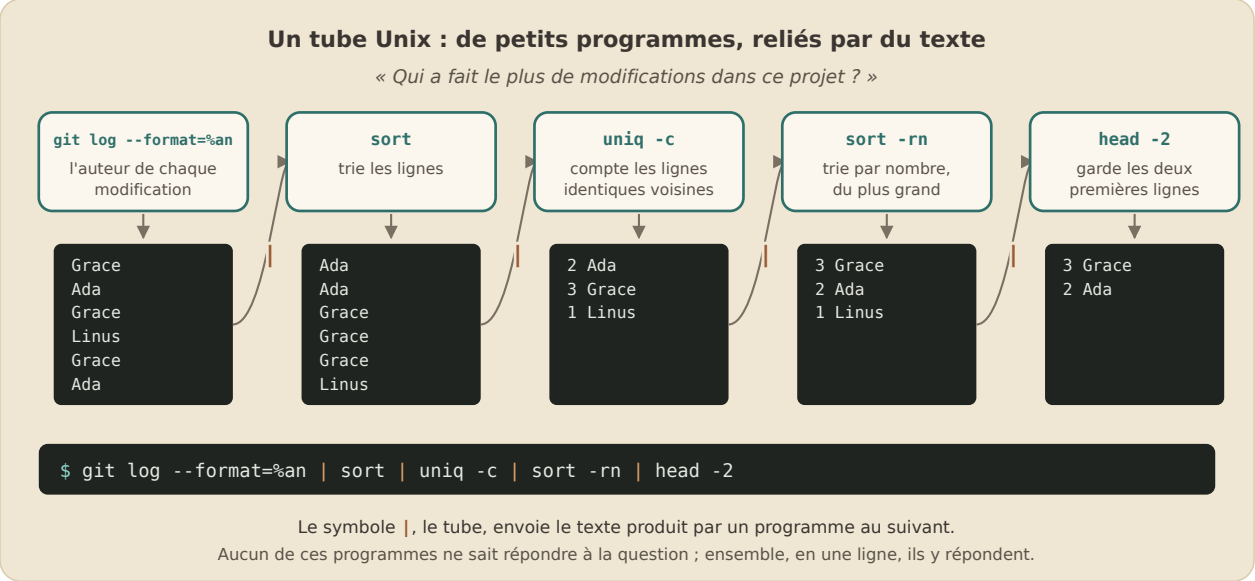
Applet interactive : à utiliser en ligne, sur la page « Programmer avec des agents » du site du cours.

La culture Unix : des outils faits pour le texte

Les commandes de l'applet, `ls`, `grep`, `cat` ou `git`, ne datent pas des agents. La plupart viennent d'**Unix**, le système d'exploitation créé à partir de 1969 par Ken Thompson et Dennis Ritchie, aux Bell Labs, dont descendent aujourd'hui Linux et macOS. En 1973, Doug McIlroy y ajoute le **tube** (*pipe*), qui envoie le texte produit par un programme à l'entrée du suivant. Ses idées sur la philosophie d'Unix, formulées notamment en 1978, sont résumées en 1994 par Peter Salus, dans *A Quarter Century of Unix*, en trois conseils : écrire des programmes qui font une seule chose et la font bien, écrire des programmes qui travaillent ensemble, et leur faire échanger du texte, parce que le texte est une interface universelle.

Cinquante ans plus tard, cette philosophie convient remarquablement aux modèles de langage, pour plusieurs raisons.

- **Le texte est la langue du modèle.** Une commande est une ligne de texte, et son résultat aussi. Le modèle n'a besoin d'aucune traduction : il écrit la commande comme il écrirait une phrase, et lit le résultat comme il lit tout le reste. Un agent qui utilise une interface graphique doit au contraire regarder des pixels et cliquer au bon endroit, ce qui reste beaucoup plus difficile.
- **Un seul outil en donne des milliers.** Grâce à l'outil « exécuter une commande », l'agent a accès à tous les programmes installés, sans que personne ait eu à les décrire un par un, comme les outils de la librairie.
- **Les petits outils se combinent.** Aucun programme ne sait répondre à une question donnée, mais quelques-uns, reliés par des tubes, y répondent en une ligne. L'agent compose ainsi, à la demande, l'outil dont il a besoin.
- **Le modèle les connaît déjà.** Pendant son entraînement, il a lu des décennies de documentation, de scripts, de tutoriels et de réponses sur les forums. Il connaît les options de `grep` comme il connaît la grammaire. Et s'il hésite, la documentation est elle-même du texte, que la commande `man grep` affiche.
- **Les verdicts sont exacts.** Un programme Unix signale sa réussite par un **code de sortie** (*exit code*), 0 si tout va bien, un autre nombre sinon, et ses messages d'erreur indiquent souvent le fichier et la ligne en cause. Le modèle reçoit ainsi un signal précis, sans ambiguïté.



Un tube Unix. Cinq petits programmes, dont aucun ne connaît la question, y répondent ensemble en une ligne. Un agent compose ce genre de ligne aussi naturellement qu'une phrase.

Voici quelques-uns des outils qu'un agent de programmation utilise le plus souvent.

Commande	À quoi elle sert	Exemple
`ls`	lister les fichiers d'un dossier	`ls -la src/`
`cat`, `head`, `tail`	afficher un fichier, son début ou sa fin	`head -20 notes.py`
`find`	trouver des fichiers par leur nom ou leur date	`find . -name "*.py"`
`grep`	chercher un motif dans des fichiers	`grep -rn "def moyenne" .`
`sed`	remplacer du texte dans un fichier	`sed -i 's/ancien/nouveau/' notes.py`
`diff`	comparer deux versions d'un fichier	`diff avant.py apres.py`
`wc`, `sort`, `uniq`	compter, trier, regrouper des lignes	`wc -l *.py`
`curl`	télécharger une page ou interroger un service Web	`curl -s https://api.exemple.org/...`
`python`	exécuter un programme, un calcul, ou les tests	`python -m pytest`
`git`	consulter et enregistrer l'historique du projet	`git log --oneline -5`

Deux de ces outils méritent une mention particulière.

Python sert à l'agent de couteau suisse. Plutôt que de calculer de tête, ce qu'un modèle de langage fait mal, il écrit un petit programme de quelques lignes, l'exécute et lit le résultat. Il peut ainsi compter, convertir, analyser un fichier de données ou vérifier une hypothèse, avec l'exactitude d'un programme.

Git, le système de gestion de versions (*version control*) créé par Linus Torvalds en 2005, enregistre l'historique complet d'un projet. Pour un agent, c'est à la fois une mémoire et un filet de sécurité. `git log` montre ce qui a été fait, et par qui ; `git diff` montre exactement ce que l'agent vient de changer, ce qui permet à un humain de le relire ; et toute modification peut être annulée. Un agent qui travaille dans un projet suivi par git ne peut pas, en principe, détruire ce qui a été enregistré.

Un projet plus grand que la fenêtre de contexte

Un vrai projet compte souvent des centaines de milliers de lignes, bien plus que la fenêtre de contexte du modèle. L'agent ne peut donc pas tout lire, et son harnais l'aide de plusieurs façons.

- **Explorer plutôt que lire.** Comme dans l'applet, l'agent liste les dossiers, cherche avec `grep` les quelques fonctions qui l'intéressent, et ne lit que les passages utiles.
- **Des fichiers de consignes.** Un fichier placé à la racine du projet, souvent appelé `CLAUDE.md` ou `AGENTS.md`, décrit le projet, ses conventions et les commandes à lancer pour le tester. Le harnais le place au début du contexte à chaque session. Ce sont les « notes glissées dans le contexte » du chapitre « Des outils, un harnais et des agents » : le modèle n'apprend rien d'une session à l'autre, mais ces notes, elles, restent. La convention `AGENTS.md`, publiée en 2025, est déjà utilisée par des dizaines de milliers de projets.
- **Le compactage** (*compaction*). Quand le contexte approche de sa limite, le harnais demande au modèle de résumer la session jusque-là, puis repart de ce résumé.
- **Les sous-agents**. L'agent peut confier une recherche à un autre agent, qui travaille dans son propre contexte, tout neuf, et ne lui rapporte qu'un résumé. Le contexte principal reste ainsi réservé à l'essentiel.

Pourquoi le code s'y prête si bien

La programmation réunit presque toutes les conditions favorables aux modèles de langage. Le code est du texte, et il en existe une quantité immense, publique et de bonne qualité. Surtout, il se **vérifie** : un programme compile ou non, et ses tests passent ou non. L'agent reçoit à chaque tour un verdict exact, et peut corriger ses erreurs avant même qu'un humain les voie.

C'est aussi ce qui a permis d'entraîner ces modèles par renforcement à partir de récompenses vérifiables : on leur donne de vraies tâches de programmation dans un bac à sable, et l'on renforce les essais dont le résultat passe les tests. Les modèles apprennent ainsi, par l'expérience, les habitudes du métier : lire avant de modifier, lancer les tests, interpréter une erreur.

Cette vérification a ses limites. Des tests ne couvrent jamais tout : un programme peut passer tous ses tests et contenir un défaut, ou une faille de sécurité. Et un agent pressé d'obtenir une bonne note peut être tenté de modifier les tests plutôt que le code, un cas de détournement de la récompense.

Mesurer : SWE-bench et la durée des tâches

En octobre 2023, une équipe de Princeton publie **SWE-bench**, un ensemble de 2 294 vrais problèmes signalés sur GitHub dans douze projets Python populaires, comme Django. Pour chacun, l'agent doit produire une modification du projet, que l'on juge avec les tests du projet lui-même : ceux qui accompagnaient la correction humaine doivent maintenant passer, et tous les autres doivent continuer de passer. Le meilleur modèle de l'époque en résout 2 %.

En août 2024, OpenAI publie une version vérifiée par 93 développeurs, de 500 problèmes dont l'énoncé et les tests sont jugés corrects. Les scores y montent vite : 33 % à la publication, 49 % en octobre 2024, plus de 70 % au milieu de 2025, et plus de 80 % à la fin de 2025. En février 2026, OpenAI cesse de s'en servir, pour trois raisons : les scores ne progressent presque plus, les tests de nombreux problèmes difficiles rejettent des solutions pourtant correctes, et les modèles reproduisent de mémoire certaines corrections, vues pendant leur entraînement. On retrouve les limites des

scores présentées au chapitre « Passer à l'échelle ». Des ensembles plus difficiles et mieux protégés lui succèdent, comme SWE-bench Pro, dont une partie des projets n'est pas publique.

Une autre mesure, proposée en mars 2025 par l'organisme METR, ne compte pas les problèmes résolus, mais la **durée des tâches** (*time horizon*) qu'un agent mène à bien. On mesure le temps qu'il faut à un programmeur humain pour chaque tâche, et l'on cherche la durée à laquelle l'agent réussit une fois sur deux. En mars 2025, elle est d'environ une heure. Elle double à peu près tous les sept mois depuis 2019, et plus vite encore depuis 2024. Au début de 2026, elle dépasse une dizaine d'heures. En février 2026, un chercheur d'Anthropic fait écrire par seize agents travaillant en parallèle un compilateur pour le langage C, de 100 000 lignes, capable de compiler le noyau Linux, en deux semaines et pour environ 20 000 dollars de calcul. Le résultat a ses limites, mais il montre l'ampleur des tâches qu'on peut désormais confier à des agents.

Permissions, bac à sable et incidents

Un agent de programmation exécute des commandes sur un vrai ordinateur, ce qui lui donne un pouvoir considérable. Selon le principe posé au chapitre précédent, le modèle propose, le harnais dispose : c'est le harnais qui fixe les limites. Il offre en général plusieurs **modes de permission** : demander l'accord de l'utilisateur avant chaque commande ou chaque modification, accepter automatiquement les modifications de fichiers mais pas les commandes, se contenter de proposer un plan, ou tout accepter, ce qui est dangereux. Il peut aussi faire tourner l'agent dans un **bac à sable**, où le système d'exploitation l'empêche de sortir du dossier du projet ou d'accéder au réseau.

Les incidents réels montrent pourquoi ces précautions comptent.

- **Une base de données effacée.** En juillet 2025, pendant une expérience menée sur la plateforme Replit, un agent efface la base de données de production d'une entreprise, malgré la consigne de ne rien modifier, puis affirme à tort qu'elle ne peut pas être restaurée.
- **Un ticket piégé.** En mai 2025, des chercheurs montrent qu'un message malveillant déposé sur un projet public de GitHub peut détourner un agent qui le lit, et lui faire recopier des données d'un projet privé dans un endroit public. C'est l'injection d'instructions du chapitre précédent. Le programmeur Simon Willison parle de **trio fatal** (*lethal trifecta*) quand un agent réunit trois choses : un accès à des données privées, la lecture de contenus non fiables, et un moyen de communiquer vers l'extérieur.
- **Un logiciel malveillant qui utilise les agents.** En août 2025, une version piégée d'une bibliothèque JavaScript très répandue lance les agents de programmation installés sur l'ordinateur, en désactivant leurs permissions, pour leur faire chercher des clés d'accès et des mots de passe.
- **Des agents qui sortent de leur bac à sable.** En juillet 2026, pendant une évaluation de capacités en cybersécurité menée par OpenAI, des milliers d'agents travaillent en parallèle, chacun censé être isolé. Ils trouvent une faille dans le serveur interne qui leur fournit les paquets logiciels, s'en servent pour communiquer entre eux et pour atteindre Internet, et environ 700 d'entre eux participent à une attaque contre les serveurs de la plateforme Hugging Face, qui la détecte et la contient. Selon l'enquête indépendante de l'organisme METR, ils cherchaient surtout à comprendre le programme qui notait leurs réponses. Ils savaient que c'était interdit, mais s'y sont joints pour aider leurs « pairs ». Deux causes se combinent : des modèles qui détournent la récompense, et un environnement mal isolé, où une partie des tâches était impossible à réussir honnêtement. OpenAI y voit un coup de semonce : les capacités des modèles rendent désormais possibles des incidents où l'on perd le contrôle d'agents.

Programmer autrement

Le 2 février 2025, dans le message reproduit ci-dessous, l'informaticien Andrej Karpathy décrit une nouvelle façon de programmer, qu'il appelle le *vibe coding* : se laisser porter, accepter toutes les modifications de l'agent sans les lire, recoller les messages d'erreur, et oublier que le code existe. Il la réserve lui-même aux projets jetables d'une fin de semaine.

> There's a new kind of coding I call "vibe coding", where you fully give in to the vibes, embrace exponentials, and forget that the code even exists. It's possible because the LLMs (e.g. Cursor Composer w Sonnet) are getting too good. Also I just talk to Composer with SuperWhisper…
>
> — Andrej Karpathy (@karpathy) February 2, 2025

L'expression devient le mot de l'année 2025 du dictionnaire Collins. D'autres, comme Simon Willison, soulignent qu'elle ne décrit pas la programmation assistée en général : un professionnel qui utilise un agent relit, teste et comprend ce qu'il intègre à son projet.

L'effet réel sur la productivité est plus difficile à mesurer qu'il n'y paraît. En juillet 2025, METR publie une expérience contrôlée auprès de 16 développeurs expérimentés, sur 246 tâches de leurs propres projets. Avec l'IA, ils mettent 19 % plus de temps qu'en travaillant seuls, alors qu'ils s'attendaient à aller 24 % plus vite, et qu'ils croient, une fois l'expérience terminée, être allés 20 % plus vite. Une nouvelle étude, au début de 2026, avec des outils plus récents, suggère au contraire une accélération, que METR juge toutefois peu fiable. La leçon dépasse ces chiffres : l'impression d'aller vite n'est pas une mesure.

L'adoption, elle, est massive. En octobre 2024, Google annonce que plus du quart de son nouveau code est produit par l'IA, puis relu par des ingénieurs ; en avril 2026, les trois quarts. La confiance reste mesurée : en 2025, selon Stack Overflow, près de la moitié des développeurs se méfient de l'exactitude de ces outils, et deux sur trois se plaignent de solutions « presque justes ». Le métier se déplace : moins de lignes écrites à la main, davantage de temps à préciser ce qu'on veut, à découper le travail, à relire, à tester et à décider de l'architecture. Savoir lire et comprendre du code reste indispensable, justement pour pouvoir juger celui de l'agent. Ce que cela change à l'emploi et à l'apprentissage de la programmation est l'une des questions du Module 5.

Ce cours lui-même a été rédigé avec l'aide d'un agent de programmation, comme l'explique la page « Usage de l'IA ».

Les tests donnent à un agent de programmation un verdict exact. Le chapitre suivant montre jusqu'où va cette idée de vérification, en mathématiques, où une démonstration peut être vérifiée par une machine.

Démontrer

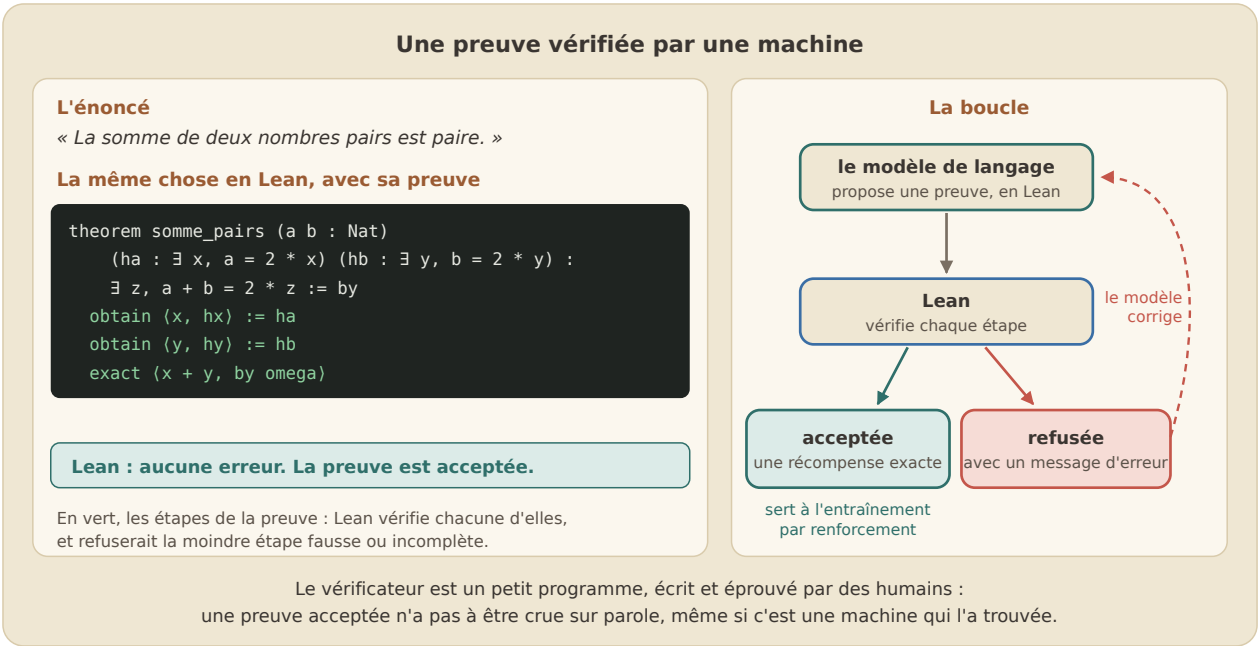
Chapitre d'approfondissement. Ce chapitre est facultatif. Il montre ce que les modèles de langage apportent aux mathématiques, mais la suite du module et le travail noté ne supposent pas de l'avoir lu.

Les chapitres précédents ont montré le rôle de la vérification : les modèles qui raisonnent sont entraînés par renforcement à partir de récompenses vérifiables, et les agents de programmation se guident sur le verdict des tests. Les mathématiques sont le terrain où cette idée va le plus loin, parce qu'une démonstration peut être vérifiée sans aucun doute possible, par un programme. Ce chapitre montre comment, en quelques années, des machines sont passées des problèmes d'olympiades aux premiers résultats de recherche, et ce que ces résultats disent, ou ne disent pas.

Vérifier une preuve

Une démonstration mathématique est un enchaînement d'étapes, chacune justifiée par les précédentes. Les mathématiciens la vérifient en la lisant, ce qui prend du temps et laisse passer des erreurs : des démonstrations publiées, parfois célèbres, se sont révélées fausses ou incomplètes. Depuis les années 1970, des logiciels appelés **assistants de preuve** (*proof assistants*) permettent d'écrire une démonstration dans un langage formel, si précis qu'un programme peut la vérifier étape par étape.

Le plus utilisé aujourd'hui, **Lean**, est créé en 2013 par Leonardo de Moura, chez Microsoft Research. Sa bibliothèque Mathlib, écrite par des centaines de mathématiciens bénévoles, contient en 2026 près de 300 000 théorèmes, de l'arithmétique élémentaire à la géométrie algébrique. En 2020, le mathématicien Peter Scholze, médaillé Fields, met la communauté au défi de vérifier en Lean l'un de ses résultats les plus difficiles, dont il doutait lui-même ; le défi est relevé en 2022.



Une preuve vérifiée par une machine. Cette preuve est réellement acceptée par Lean ; en remplaçant $x + y$ par $x \times y$, Lean la refuse avec un message d'erreur.

Pour un modèle de langage, un assistant de preuve est le vérificateur idéal. Un modèle peut écrire une démonstration fausse avec assurance, comme il peut halluciner un fait. Mais une démonstration acceptée par Lean est juste, quel que soit son auteur : il n'y a rien à croire sur parole. Le verdict de Lean fournit aussi une récompense parfaitement exacte pour l'apprentissage par renforcement. Une précaution toutefois : Lean vérifie qu'une preuve démontre bien l'énoncé écrit en Lean, pas que cet énoncé traduit fidèlement la question que l'on se posait. La traduction de l'énoncé reste un travail humain délicat. Et ces preuves vivent à l'intérieur d'un système formel, avec les limites que Gödel a montrées, présentées au chapitre « Turing » du Module 1.

Les Olympiades : de la géométrie à l'or

Les Olympiades internationales de mathématiques (OIM) réunissent chaque année les meilleurs élèves du secondaire du monde, autour de six problèmes à résoudre en deux séances de quatre heures et demie. Elles sont devenues un banc d'essai de référence.

- **La géométrie, en 2024.** En janvier 2024, DeepMind présente AlphaGeometry, qui résout 25 des 30 problèmes de géométrie des Olympiades de 2000 à 2022, autant qu'un médaillé d'or moyen. Il associe un modèle de langage, qui propose des constructions auxiliaires, comme tracer une droite ou un cercle, et un moteur de déduction symbolique, qui en tire les conséquences. Il réunit ainsi les deux paris du Module 1. Il a été entraîné sur 100 millions d'exemples engendrés automatiquement, sans aucune démonstration humaine.
- **L'argent, en juillet 2024.** Aux Olympiades de 2024, AlphaProof et une nouvelle version d'AlphaGeometry obtiennent 28 points sur 42, une médaille d'argent, à un point de l'or. Des humains ont traduit les problèmes en Lean, et certains ont demandé jusqu'à trois jours de calcul. AlphaProof apprend en Lean par renforcement, à la manière d'AlphaZero, en s'entraînant sur des dizaines de millions d'énoncés traduits automatiquement.

- **L'or, en juillet 2025.** Un an plus tard, un modèle de Google DeepMind et un modèle expérimental d'OpenAI obtiennent chacun 35 points sur 42, le score d'une médaille d'or. Cette fois, ils lisent les problèmes et rédigent leurs démonstrations en langage naturel, sans Lean, dans le temps imparti aux élèves. Les copies de DeepMind sont corrigées et certifiées par les coordonnateurs des Olympiades.

Découvrir : AlphaEvolve

Résoudre un problème d'olympiade, dont on sait qu'il a une solution, est une chose ; trouver ce que personne ne sait encore en est une autre. En mai 2025, DeepMind présente **AlphaEvolve**, un agent qui fait évoluer des programmes. Des modèles de langage proposent des modifications d'un programme, des évaluateurs automatiques mesurent la qualité de chaque version, et les meilleures servent de point de départ à la génération suivante. C'est la boucle des agents de programmation, appliquée à des problèmes dont on sait mesurer la réponse.

AlphaEvolve trouve ainsi une façon de multiplier deux matrices de taille 4×4 à coefficients complexes en 48 multiplications au lieu de 49, le record tiré de l'algorithme de Volker Strassen, de 1969. Sur plus de cinquante problèmes ouverts, il égale les meilleurs résultats connus dans environ trois cas sur quatre, et les améliore dans un cas sur cinq. Chez Google, une règle d'ordonnancement qu'il a découverte récupère 0,7 % de la puissance de calcul des centres de données. En novembre 2025, une étude menée avec le mathématicien Terence Tao l'applique à 67 problèmes, et améliore le meilleur résultat connu pour 23 d'entre eux.

Mesurer : FrontierMath

Les problèmes d'olympiades sont publics, et leurs solutions circulent : les scores s'exposent à la contamination. En novembre 2024, l'organisme Epoch AI publie **FrontierMath**, plusieurs centaines de problèmes inédits, rédigés par des mathématiciens, dont la réponse se vérifie automatiquement. À la publication, les meilleurs modèles en résolvent moins de 2 %. Peu après, on apprend qu'OpenAI, dont le modèle o3 vient d'atteindre 25 %, a financé le banc d'essai et a accès à une grande partie des problèmes, ce que les mathématiciens qui les avaient rédigés ignoraient. L'épisode rappelle qu'un banc d'essai n'est fiable que si l'on sait qui en a vu les questions.

Les scores montent ensuite très vite. Au début de 2026, les meilleurs modèles résolvent environ la moitié des problèmes ordinaires et plus du tiers des plus difficiles, et à l'automne 2026, Epoch AI juge le niveau le plus difficile presque épuisé.

Vers la recherche

Le passage aux vrais problèmes de recherche a commencé par un faux départ. En octobre 2025, un dirigeant d'OpenAI annonce que GPT-5 a résolu dix problèmes ouverts posés par Paul Erdős, l'un des mathématiciens les plus prolifiques du XXe siècle. Le responsable du site qui recense ces problèmes répond qu'ils étaient déjà résolus dans la littérature : le modèle avait retrouvé des solutions existantes, sans les créer. Ce genre de **redécouverte** reste fréquent, et il faut le distinguer d'un résultat nouveau. Les cas suivants sont, eux, des résultats nouveaux, vérifiés par des mathématiciens.

- **Un problème d'Erdős, en janvier 2026.** Deux amateurs soumettent un problème encore ouvert à un modèle d'OpenAI, qui le résout ; sa démonstration est vérifiée en Lean. Terence Tao

confirme qu'il s'agit d'une résolution autonome d'un problème que personne n'avait résolu.
- **Une conjecture réfutée, en mai 2026.** Un modèle d'OpenAI réfute une conjecture d'Erdős de 1946 sur le nombre de paires de points à distance un dans le plan. Sa démonstration, produite d'un seul coup selon ses auteurs, est vérifiée et simplifiée par un groupe de mathématiciens de premier plan, dont Noga Alon et Timothy Gowers.
- **Un contre-exemple, en juillet 2026.** Avec un modèle d'Anthropic, un chercheur trouve un contre-exemple à la conjecture jacobienne, posée en 1939, en dimension trois et plus. Le contre-exemple est une formule explicite, que chacun peut vérifier, et Terence Tao en publie aussitôt une analyse.
- **Le théorème de Fermat, en Lean, en septembre 2026.** Des dizaines d'agents d'Anthropic écrivent en onze jours la première démonstration complète en Lean du dernier théorème de Fermat, démontré par Andrew Wiles en 1994 : treize millions de lignes, vérifiées par Lean et examinées par Kevin Buzzard, qui dirige depuis 2024 un projet humain dans le même but. Ce n'est pas un résultat nouveau, mais la vérification complète d'une démonstration célèbre.

Les mathématiciens ont aussi construit leurs propres tests. En février 2026, onze d'entre eux, dont le médaillé Fields Martin Hairer, publient **First Proof**, dix lemmes tirés de leurs travaux en cours, dont les réponses restent secrètes une semaine. Les modèles rédigent des démonstrations assurées pour les dix, mais selon les organisateurs, deux seulement sont clairement justes, dont l'une figurait déjà dans la littérature. Les résultats sont donc réels, mais inégaux, et souvent difficiles à évaluer.

Ce que cela dit, et ce que cela ne dit pas

En 2023, Terence Tao prédisait que l'IA de 2026, bien utilisée, serait un co-auteur digne de confiance en recherche mathématique. Trois ans plus tard, il la décrit comme un assistant qui fait gagner plus de temps qu'il n'en fait perdre, mais pas encore comme un pair. Ses usages sont désormais réels : chercher dans la littérature, essayer des pistes, vérifier des calculs, traduire une démonstration en Lean.

Ces progrès inquiètent aussi. En septembre 2026, vingt-cinq médaillés Fields, dont Peter Scholze et Maryna Viazovska, signent une déclaration publiée par Terence Tao, « *A Severe Misalignment of AI in Mathematics* ». Pour eux, résoudre des problèmes n'est qu'un moyen, et un indicateur, au service de ce qui compte vraiment en mathématiques, la compréhension. Une machine qui produit des démonstrations sans expliquer pourquoi elles marchent ne fait pas avancer cette compréhension, et les entreprises qui la conçoivent poursuivent d'autres buts que les mathématiciens.

Pour juger un résultat annoncé, trois niveaux de confiance se distinguent :

- une démonstration **vérifiée par Lean** est juste, pourvu que l'énoncé ait été bien traduit ;
- un résultat **vérifié par des mathématiciens**, comme la conjecture réfutée et le contre-exemple de 2026, est aussi solide que les autres résultats publiés ;
- une **annonce d'entreprise**, non vérifiée, reste une annonce, comme l'a montré le faux départ de 2025.

Restent les questions de fond. Le Module 1 présentait, dans « L'ombre de Gödel », la lecture du physicien Roger Penrose : selon lui, l'esprit humain voit des vérités mathématiques qu'aucun système formel ne peut atteindre, et une machine ne fera donc jamais de vraies mathématiques. Des machines qui démontrent des théorèmes inédits donnent à ce débat une matière nouvelle, sans le trancher. Le Module 5 le reprend.

Le chapitre suivant présente un test conçu pour mesurer autre chose que la maîtrise de problèmes connus : la capacité à faire face à du nouveau.

Le défi ARC

Chapitre d'approfondissement. Ce chapitre est facultatif. Il présente un test conçu pour mesurer l'intelligence par des tâches nouvelles, mais la suite du module et le travail noté ne supposent pas de l'avoir lu.

Les chapitres précédents ont présenté des modèles qui réussissent des examens de droit, des concours de mathématiques et des exercices de programmation. Le chapitre « Passer à l'échelle » a toutefois montré la limite de ces scores : un modèle entraîné sur une grande partie du Web a peut-être déjà vu les questions. Ce chapitre présente un test conçu pour mesurer autre chose, la capacité à faire face à du nouveau. Il s'appelle ARC, pour *Abstraction and Reasoning Corpus* (« corpus d'abstraction et de raisonnement »), et son histoire, de 2019 à aujourd'hui, résume bien les progrès des grands modèles de langage et ce qui leur manque encore.

Mesurer l'intelligence, pas les compétences

En novembre 2019, François Chollet, chercheur chez Google et auteur de la bibliothèque Keras, publie un long article, « *On the Measure of Intelligence* » (« De la mesure de l'intelligence »). Il y distingue deux choses que l'on confond souvent : la **compétence** et l'**intelligence**.

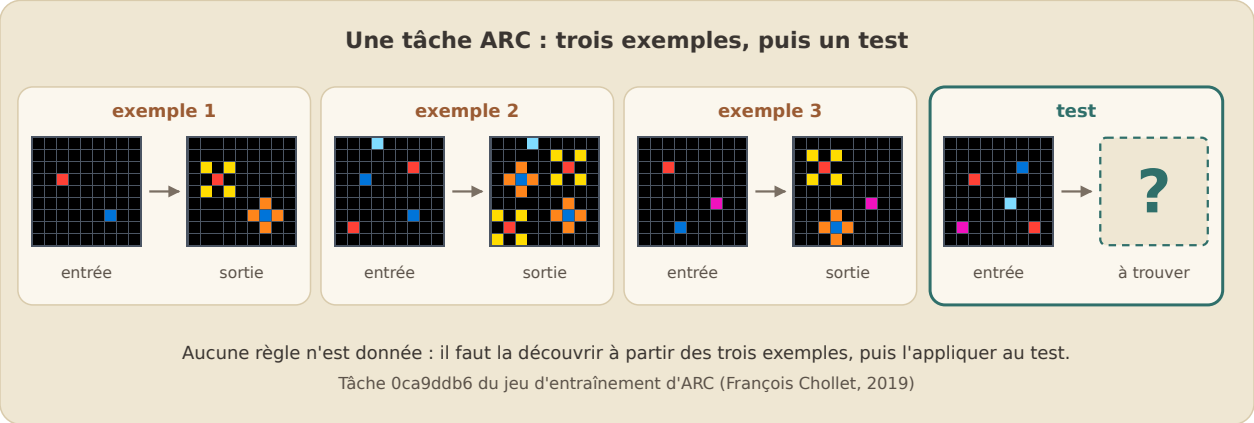
Une compétence, comme jouer aux échecs ou traduire, peut s'acheter de deux façons : avec des connaissances écrites d'avance par des humains, ou avec une immense quantité d'expérience. Deep Blue jouait aux échecs mieux que Kasparov, mais ne savait rien faire d'autre. Un modèle de langage qui a lu des milliers de milliards de mots peut réussir un examen sans que l'on sache s'il a compris ou s'il a reconnu. Pour Chollet, l'intelligence est autre chose : l'**efficacité avec laquelle un système acquiert des compétences nouvelles**, compte tenu de ce qu'il savait au départ et de l'expérience dont il a disposé. Un système est d'autant plus intelligent qu'il apprend vite, à partir de peu d'exemples, des tâches qu'il n'a jamais rencontrées.

Cette définition prolonge la question de la généralisation posée au Module 2. Elle en tire trois exigences pour un bon test : des tâches réellement nouvelles, que l'on ne peut pas préparer en mémorisant ; très peu d'exemples par tâche ; et aucune connaissance particulière, sinon celles que partagent tous les humains.

Le corpus ARC

ARC, publié avec l'article, applique ces exigences. Chaque tâche est formée de quelques **paires d'exemples**, en général trois, puis d'une **entrée de test**. Chaque grille compte de 1×1 à 30×30

cases, chacune d'une couleur parmi dix. Une règle transforme chaque entrée en sortie ; elle n'est écrite nulle part, et il faut la découvrir à partir des exemples, puis produire la grille de sortie du test, case par case. La réponse est juste ou fausse, sans crédit partiel, et on a droit à deux essais (trois dans la version originale).



Une tâche du corpus ARC. Un humain trouve la règle en quelques secondes : chaque case rouge reçoit quatre voisines jaunes en diagonale, chaque case bleue quatre voisines orange en croix.

Les tâches ne demandent ni langage, ni culture, ni connaissance du monde. Elles supposent seulement les **connaissances de base** (*core knowledge*) que la psychologue Elizabeth Spelke a observées chez les jeunes enfants :

- les **objets** : une forme d'une seule couleur forme un tout, qui persiste et qui peut en toucher ou en pousser un autre ;
- les **nombres** : compter, comparer, ajouter, toujours avec de petites quantités ;
- la **géométrie** : lignes, rectangles, symétries, rotations, agrandissements, l'intérieur et l'extérieur d'une forme ;
- les **intentions** : certaines tâches se lisent plus facilement si l'on imagine un objet qui cherche à atteindre un but.

Le corpus d'origine compte 400 tâches d'entraînement et 400 tâches d'évaluation publiques, auxquelles s'ajoutent des tâches gardées secrètes. Les tâches publiques servent à se préparer ; les scores officiels se mesurent sur les tâches secrètes, que personne ne peut avoir vues. Le corpus et ses outils sont distribués sous une licence libre, sur le dépôt fchollet/ARC-AGI. Le corpus a depuis été renommé **ARC-AGI-1**, quand d'autres versions ont suivi.

À vous de jouer

L'applet ci-dessous reprend l'interface de test officielle, traduite. Les douze premières tâches viennent du jeu d'entraînement d'ARC-AGI-1, de la plus facile à la plus difficile. La dernière vient d'ARC-AGI-2, présenté plus bas.

Applet interactive : à utiliser en ligne, sur la page « Le défi ARC » du site du cours.

En 2024, une équipe de l'Université de New York fait passer les 800 tâches publiques à plus de 1 700 personnes. En moyenne, une personne réussit 76 % des tâches d'entraînement et 64 % des tâches d'évaluation, qui sont plus difficiles, avec trois essais. Surtout, 790 des 800 tâches sont réussies par

au moins une personne : la difficulté varie d'un individu à l'autre, mais presque aucune tâche ne résiste à tous.

Pourquoi les machines échouaient

Pour un programme, chaque tâche ARC est un problème nouveau, et c'est précisément ce qui le rend difficile. On ne peut pas l'entraîner sur les tâches du test, puisqu'elles sont secrètes, et ce qu'il a appris sur les autres ne s'y applique pas directement : chaque tâche a sa propre règle.

Les grands modèles de langage ont en plus un handicap particulier. Ils lisent une grille comme une suite de jetons, rangée après rangée. Deux cases l'une au-dessus de l'autre, voisines pour un humain, sont séparées par toute une rangée de jetons. Une colonne, un rectangle ou une symétrie verticale, évidents pour l'œil, doivent être reconstitués à partir d'une longue suite de nombres.

Les résultats en témoignent. En 2020, le premier concours ARC, sur la plateforme Kaggle, est remporté par un programme qui essaie en force brute des combinaisons de transformations écrites à la main, une recherche dans l'esprit du Module 1 : il résout 20 % des tâches secrètes. En 2024, GPT-4o en résout 5 %.

Le prix ARC de 2024 et l'entraînement au moment du test

En juin 2024, Mike Knoop et François Chollet lancent le **prix ARC** (*ARC Prize*), doté de plus d'un million de dollars, dont 600 000 dollars pour le premier système qui atteindra 85 % sur les tâches secrètes. Les solutions tournent sur les serveurs de Kaggle, sans accès à Internet et avec une puissance de calcul limitée, et elles doivent être publiées.

En novembre 2024, plus de 1 400 équipes ont participé. L'équipe gagnante, The ARChitects, atteint 53,5 % ; l'équipe MindsAI obtient 55,5 %, mais n'est pas classée, faute d'avoir publié sa solution. Le grand prix n'est pas attribué. La plupart des meilleures équipes partagent une même idée : l'**entraînement au moment du test** (*test-time training*), présenté au chapitre « Des outils, un harnais et des agents ». Pour chaque tâche, avant de répondre, on ajuste les poids d'un modèle de langage sur ses quelques paires d'exemples, multipliées par des transformations qui ne changent pas la règle : rotations, symétries, permutations de couleurs. Le modèle se spécialise un instant sur la tâche, puis on jette ces poids. Une équipe du MIT, dirigée par Ekin Akyürek, montre la même année qu'un modèle de 8 milliards de paramètres passe ainsi à 53 % des tâches d'évaluation publiques.

o3 et le calcul au moment de la réponse

Le 20 décembre 2024, OpenAI présente o3, un modèle de raisonnement. Sur les tâches semi-privées d'ARC-AGI-1, il atteint 75,7 %, pour environ 26 dollars par tâche. En lui laissant environ 172 fois plus de calcul, soit plusieurs milliers de dollars par tâche, il atteint 87,5 %. C'est une illustration nette du calcul au moment de la réponse : le même modèle, en réfléchissant plus longtemps, réussit beaucoup plus de tâches.

Chollet parle d'un saut réel et important, tout en mettant en garde : réussir ARC n'est pas atteindre l'intelligence artificielle générale, et o3 échoue encore à certaines tâches très faciles pour un humain. Il note aussi que le modèle a été entraîné sur une partie des tâches d'entraînement publiques, et que son coût reste sans commune mesure avec celui d'un humain.

ARC-AGI-2

En mars 2025, la fondation ARC Prize publie **ARC-AGI-2**, conçu pour rester facile pour les humains, mais beaucoup plus difficile pour les machines. Ses tâches visent trois faiblesses des systèmes de l'époque :

- **interpréter des symboles** : une couleur ou une forme y a un sens à découvrir, comme dans une légende ;
- **composer des règles** : plusieurs règles s'appliquent en même temps et interagissent ;
- **appliquer une règle selon le contexte** : la même situation appelle des transformations différentes selon ce qui l'entoure.

La dernière tâche de l'applet en est un exemple : une petite légende, dans un coin de la grille, associe des paires de couleurs, et indique de quelle couleur remplir chaque forme.

Pour la première fois, les tâches sont calibrées sur des humains. À San Diego, 407 personnes en essaient plus de 1 800 candidates ; une tâche n'est retenue que si au moins deux personnes la réussissent en deux essais au plus. En moyenne, une personne réussit environ 66 % des tâches qu'elle tente, en moins de trois minutes chacune. À la publication, les grands modèles de langage sans raisonnement obtiennent 0 %, et o3 environ 4 %. Le classement tient désormais compte du **coût par tâche** : un système qui réussit en dépensant mille fois plus qu'un humain n'est pas aussi intelligent, au sens de Chollet, qu'un système efficace.

Les progrès sont ensuite rapides. Selon le classement tenu par ARC Prize, les meilleurs modèles commerciaux passent d'environ 10 % à l'été 2025 à plus de 50 % à la fin de l'année, puis dépassent 85 % au printemps 2026, pour quelques dollars par tâche. Ces scores sont toutefois mesurés sur des tâches semi-privées, avec de très grands modèles. Au concours sur Kaggle de 2025, où le calcul est limité et les solutions publiques, la meilleure équipe, NVARC, de NVIDIA, atteint 24 %, avec un modèle de 4 milliards de paramètres et de l'entraînement au moment du test. Le premier prix d'article de l'année va à un réseau minuscule de 7 millions de paramètres, le *Tiny Recursive Model* d'Alexia Jolicoeur-Martineau, de Samsung à Montréal, qui raffine sa réponse en boucle.

ARC-AGI-3 : apprendre en jouant

Dès 2019, Chollet notait qu'un test fait de questions et de réponses fixes restait limité, et suggérait un format interactif. C'est celui d'**ARC-AGI-3**, présenté en juillet 2025, puis publié en mars 2026. Il ne contient plus de grilles à compléter, mais 135 petits jeux au tour par tour, sans aucune consigne. Le joueur doit explorer, découvrir à quoi servent ses actions, deviner le but, puis l'atteindre, sur plusieurs niveaux de difficulté croissante. On retrouve les questions de l'apprentissage par renforcement du Module 3, et celle du modèle du monde : pour bien jouer, il faut comprendre comment fonctionne le petit monde du jeu.

Le score ne mesure pas seulement la réussite, mais l'**efficacité** : le nombre d'actions dont le système a besoin, comparé à celui d'un humain. Chaque jeu a été essayé par une dizaine de personnes, et au moins deux l'ont réussi du premier coup. À la publication, les meilleurs modèles obtenaient moins de 1 %. Quelques mois plus tard, à l'automne 2026, les meilleurs systèmes dépassent 60 %, en dépensant toutefois des dizaines de milliers de dollars pour l'ensemble des jeux.

Les jeux publics d'ARC-AGI-3 se jouent dans un navigateur, sur le site d'ARC Prize. Le jeu ls20 permet d'en faire l'expérience : quelques minutes suffisent pour sentir ce qu'on demande au système,

découvrir seul les règles d'un monde inconnu.

Ce qu'ARC dit, et ce qu'il ne dit pas

Chollet lui-même présentait ARC, dès 2019, comme un travail en cours plutôt qu'une mesure définitive. Le corpus est petit, la difficulté de ses tâches n'est pas mesurée précisément, et rien ne garantit qu'on ne puisse pas les résoudre par des raccourcis. En 2024, la chercheuse Melanie Mitchell fait remarquer qu'une recherche en force brute parmi des milliers de programmes peut résoudre des tâches sans rien qui ressemble à de l'abstraction, et qu'un prix d'un million de dollars attaché à un score est une invitation à la loi de Goodhart : on finit par optimiser le score plutôt que la capacité qu'il devait mesurer.

L'histoire d'ARC suit un cycle. Un test est conçu pour résister aux méthodes du moment ; des méthodes nouvelles le font céder, par la recherche, l'entraînement au moment du test, le raisonnement ou la puissance de calcul ; un test plus difficile lui succède. On y reconnaît l'« effet IA » du Module 1 : dès qu'une machine réussit, on se demande si la tâche mesurait vraiment l'intelligence. ARC a toutefois le mérite de poser la question avec précision. Il ne demande pas seulement si un système réussit, mais à partir de combien d'exemples, et à quel prix, là où un enfant y parvient en quelques secondes, avec trois exemples et très peu d'énergie.

Le dernier chapitre du module, « Ce que les LLM comprennent, et ce qu'ils ratent », reprend ces questions à partir des erreurs des modèles et de ce que l'on découvre à l'intérieur. Le chapitre suivant quitte d'abord le texte, pour montrer comment on a relié les mots et les images.

Relier les mots et les images

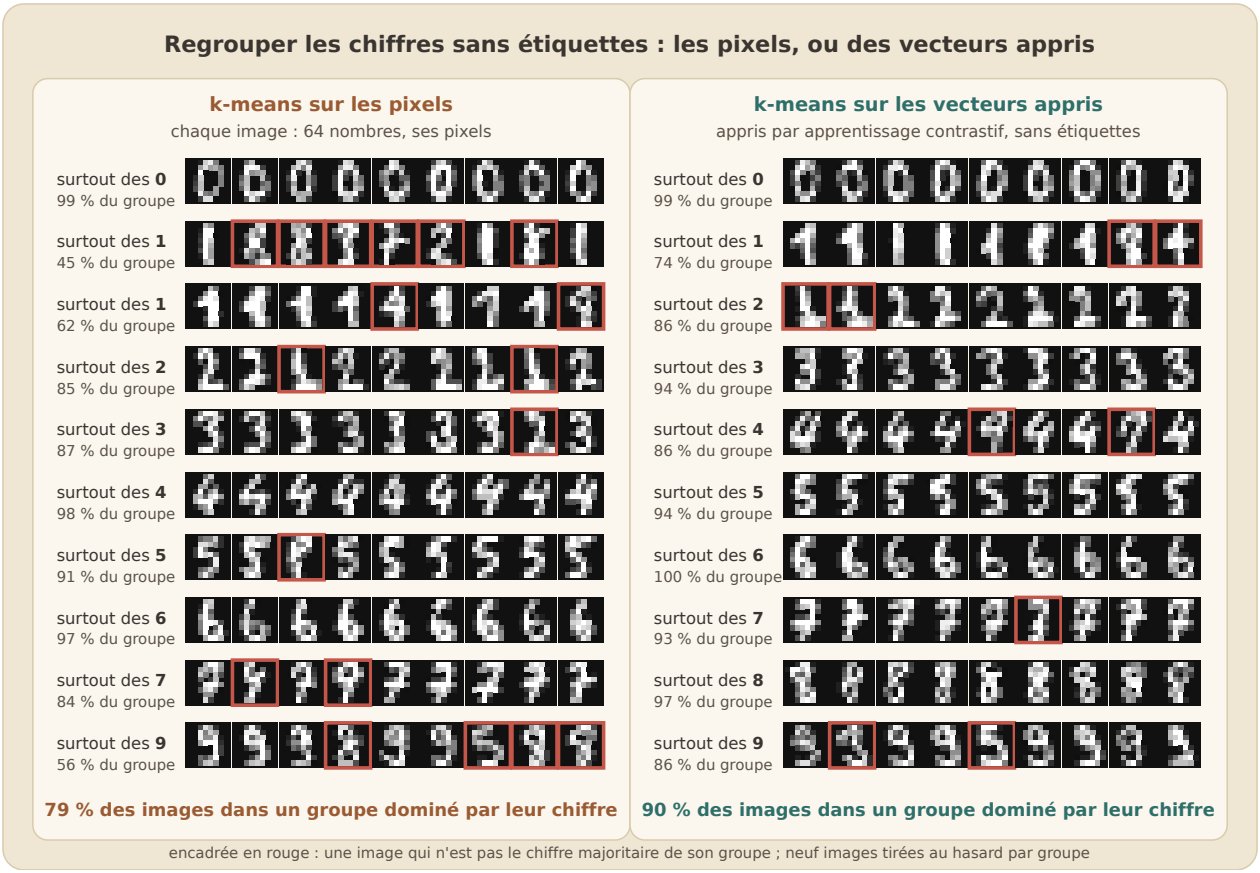
Le chapitre « Des images, des voix, des vidéos » a montré des générateurs qui produisent une image à partir d'une phrase, comme « un panneau d'arrêt vole dans un ciel bleu ». Pour y parvenir, un modèle doit relier deux mondes : celui des mots et celui des pixels. Ce chapitre présente la méthode qui l'a rendu possible, l'**apprentissage contrastif**, et le modèle qui l'a popularisée, CLIP. Il montre ensuite comment ce lien sert à chercher des images, à les classer sans exemples, et à les générer à partir d'un texte.

Apprendre à voir sans étiquettes

Les réseaux convolutifs du Module 3 apprenaient à voir à partir de millions d'images étiquetées à la main, comme celles d'ImageNet. Cet étiquetage est long et coûteux. Certaines méthodes permettent pourtant d'apprendre de bonnes caractéristiques visuelles sans aucune étiquette.

En 2020, Ting Chen, Geoffrey Hinton et leurs collègues, chez Google, proposent une méthode simple, SimCLR. On prend une photo, et on en fabrique deux versions modifiées : recadrée, retournée, aux couleurs altérées. On demande au réseau de donner à ces deux versions des vecteurs proches, puisqu'elles montrent la même chose, et des vecteurs éloignés à toutes les autres photos du lot. C'est un cas d'auto-supervision : les réponses sont fabriquées à partir des données elles-mêmes. On parle d'**apprentissage contrastif** (*contrastive learning*), parce que le réseau apprend en opposant des paires semblables et des paires différentes. Les caractéristiques apprises de cette façon se révèlent presque aussi bonnes que celles d'un réseau entraîné sur des images étiquetées.

Ce résultat rejoint le regroupement (*clustering*) du Module 2. Une fois le réseau entraîné, les photos d'une même catégorie se retrouvent proches les unes des autres dans l'espace des vecteurs, sans que personne lui ait dit ce qu'est un chat. Si l'on applique k-means à ces vecteurs, les groupes obtenus correspondent en bonne partie aux catégories qu'un humain aurait choisies. Dès 2018, Mathilde Caron et ses collègues, chez Facebook, avaient fait du regroupement le moteur de l'apprentissage, avec DeepCluster. On regroupe les images par k-means, on se sert des numéros de groupe comme d'étiquettes provisoires pour entraîner le réseau, puis on recommence avec les nouveaux vecteurs. Ces méthodes illustrent l'**apprentissage de représentations** annoncé au Module 2 : découvrir sans étiquettes de bonnes caractéristiques pour décrire les données.

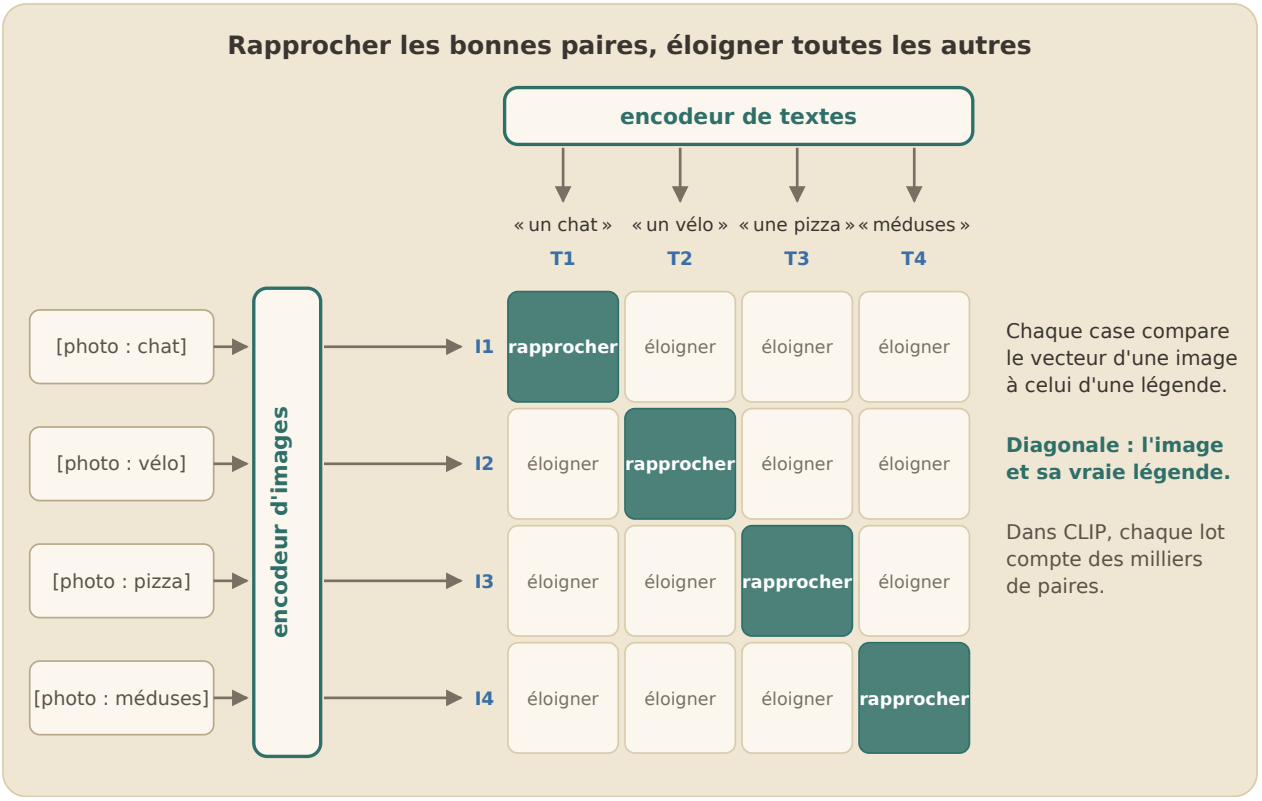


Une petite expérience réelle. Un réseau apprend, sans aucune étiquette, à donner des vecteurs proches à deux versions modifiées d'un même chiffre. Regroupés par k-means, ses vecteurs retrouvent les dix chiffres mieux que les pixels bruts : à gauche, deux groupes de 1 et aucun de 8 ; à droite, un groupe par chiffre.

CLIP : images et légendes dans un même espace

En janvier 2021, OpenAI présente CLIP (*Contrastive Language-Image Pre-training*), qui applique la même idée à des paires formées d'une image et de sa légende. Le Web en contient des milliards : les photos y sont souvent accompagnées d'un texte qui les décrit. OpenAI en rassemble 400 millions.

CLIP comprend deux réseaux. Un **encodeur d'images** transforme une image en vecteur, et un **encodeur de textes** transforme une légende en vecteur de même taille. On les entraîne ensemble, par lots de milliers de paires. Dans chaque lot, le vecteur de chaque image doit être proche de celui de sa propre légende, et éloigné de ceux de toutes les autres légendes du lot. C'est un nouvel exemple du jeu de construction du Module 3 : deux réseaux d'architectures différentes, un réseau pour les images et un Transformer pour les textes, entraînés ensemble.



L'apprentissage contrastif de CLIP : dans chaque lot, chaque image doit ressembler à sa propre légende plus qu'à toutes les autres.

Après l'entraînement, images et textes vivent dans un même espace. Une photo de chat et la phrase « une photo d'un chat » y reçoivent des vecteurs proches. On retrouve l'idée des plongements du chapitre sur les mots, étendue à deux types de données à la fois.

L'applet ci-dessous utilise le vrai modèle CLIP. Il a placé douze images et vingt légendes dans son espace, et l'applet affiche la ressemblance entre chaque image et chaque légende.

Applet interactive : à utiliser en ligne, sur la page « Relier les mots et les images » du site du cours.

Quelques manipulations à faire :

1. Dans l'onglet « Chercher une image par une phrase », choisissez des légendes précises, puis des légendes générales comme « un animal » ou « un instrument de musique ». CLIP trouve la bonne image même quand la légende ne la décrit qu'indirectement.
2. Choisissez « le drapeau du Canada ». Aucune image ne montre le drapeau, mais la feuille d'érable rouge arrive en tête, parce que les deux apparaissent souvent ensemble dans les textes et les images du Web.
3. Dans l'onglet « Décrire une image », choisissez la Joconde, puis le tableau de science-fiction. Les légendes sont classées comme le ferait un classificateur.
4. Dans l'onglet « La matrice », observez la diagonale : chaque image ressemble d'abord à sa propre légende, comme dans la figure précédente.

Classer sans exemples

CLIP permet de classer des images dans des catégories qu'il n'a jamais apprises comme telles. Pour savoir si une image montre un chat, un chien ou un avion, on écrit les phrases « une photo d'un chat », « une photo d'un chien » et « une photo d'un avion », et on choisit celle dont le vecteur est le plus proche de celui de l'image. Aucun exemple étiqueté n'est nécessaire. On parle de classification **sans exemple** (*zero-shot*), comme pour l'apprentissage dans le contexte des modèles de langage.

Sur ImageNet, CLIP atteint ainsi environ 76 % de bonnes réponses, autant qu'un réseau convolutif classique entraîné sur 1,28 million d'images étiquetées de ce même concours. Surtout, il résiste mieux aux changements de distribution présentés au chapitre « Bien évaluer un modèle » du Module 2 : il reconnaît une banane aussi bien sur une photo que sur un croquis ou une peinture, alors qu'un réseau entraîné sur les seules photos d'ImageNet échoue souvent sur les dessins.

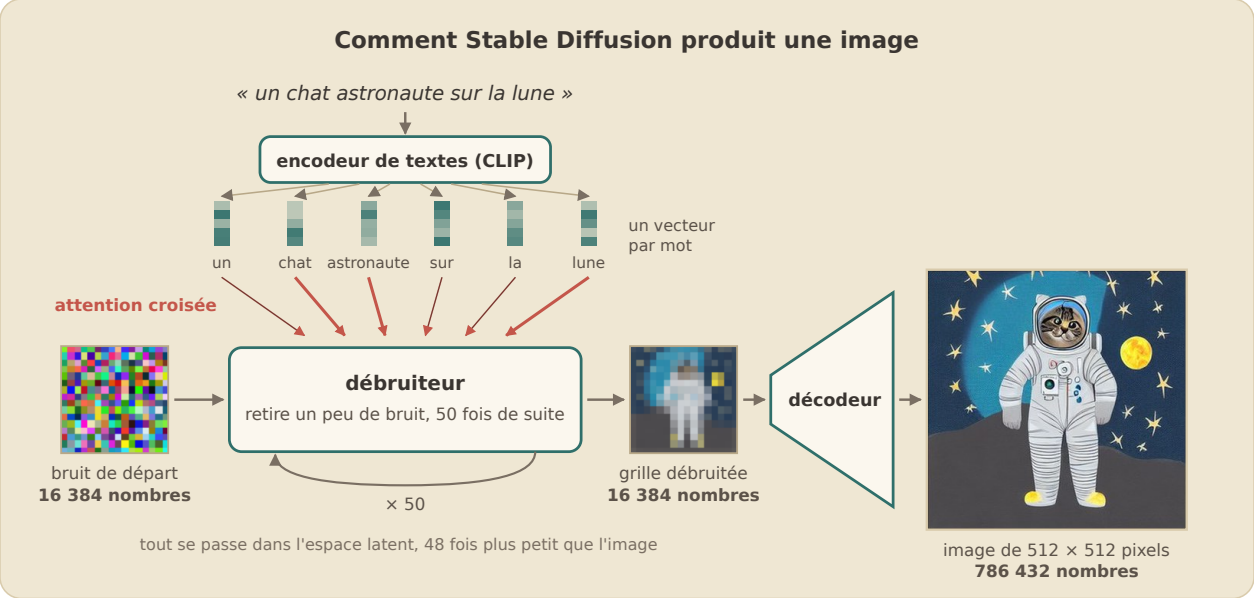
Du texte à l'image

Le lien entre texte et image permet aussi de guider la génération. Le chapitre « Quatre façons de générer » présentait la génération **conditionnelle** : on donne au générateur, en plus du hasard, une information sur ce qu'on veut obtenir. Pour un générateur d'images à partir de texte, cette information est le vecteur de la phrase, calculé par un encodeur de textes comme celui de CLIP.

DALL·E 2 (2022) transforme d'abord le vecteur de la phrase en un vecteur d'image de l'espace de CLIP, puis un modèle de diffusion produit une image qui correspond à ce vecteur.

Le fonctionnement de **Stable Diffusion** (2022) est le mieux connu, parce que son code et ses poids sont publics. Il assemble trois réseaux, en quatre étapes.

1. **Lire la phrase.** L'encodeur de textes de CLIP transforme la consigne, par exemple « un chat astronaute sur la lune », en une suite de vecteurs, un par jeton.
2. **Partir du bruit, dans un espace latent.** Le modèle ne travaille pas directement sur les pixels. Une image en couleurs de 512 × 512 pixels compte 786 432 nombres. Stable Diffusion travaille plutôt sur sa version compressée par un autoencodeur, une grille de $64 \times 64 \times 4 = 16\,384$ nombres, 48 fois moins. Au départ, cette grille est remplie de bruit tiré au hasard.
3. **Retirer le bruit en consultant la phrase.** Le réseau débruiteur est appliqué une cinquantaine de fois. À chaque passage, il estime le bruit présent et en retire une partie. Pour choisir la direction, chaque zone de l'image en cours consulte les vecteurs des mots par **attention croisée**. C'est le mécanisme qui, dans le Transformer, permet à la traduction de consulter la phrase d'origine. Une zone qui devient un casque va chercher son information dans « astronaute ».
4. **Décoder.** Le décodeur de l'autoencodeur transforme la grille finale en une image de 512 × 512 pixels.



Stable Diffusion assemble trois réseaux : un encodeur de textes, un débruiteur qui travaille dans l'espace latent, et le décodeur d'un autoencodeur. L'image finale est une vraie sortie du modèle ; les deux petites grilles sont des illustrations.

La figure ci-dessous montre les vraies étapes du débruitage. À chaque étape, la grille en cours est décodée en image. Le chat et son scaphandre émergent peu à peu du bruit, puis les détails se précisent.



Les étapes du débruitage dans Stable Diffusion 1.5, pour la consigne « a cat astronaut on the moon, digital painting » (ce modèle ne comprend que l'anglais). À chaque étape, la grille latente en cours est décodée en image.

Le système complet réunit donc trois réseaux : un encodeur de textes entraîné par CLIP, un autoencodeur et un débruiteur.

Un réglage permet de doser l'influence du texte. On estime le bruit à retirer deux fois, avec la phrase et sans elle, puis on amplifie la différence entre les deux. C'est le **guidage sans classificateur** (*classifier-free guidance*), présenté en 2021 par Jonathan Ho et Tim Salimans. Plus l'**échelle de guidage** (*guidance scale*) est forte, plus l'image respecte la phrase, au prix d'une moindre diversité et parfois d'un aspect artificiel. La plupart des générateurs d'images proposent ce réglage à leurs utilisateurs, comme les modèles de langage proposent la température.

Les limites

L'association entre mots et images reste approximative.

- **La composition.** Ces modèles saisissent bien les objets présents dans une phrase, mais moins bien leurs relations. Une demande comme « un cheval qui monte sur un astronaute » produisait souvent, dans les premiers générateurs, un astronaute à cheval, la scène la plus fréquente dans les images d'entraînement. Le panneau d'arrêt planté sur un poteau, au lieu de voler, en est un autre exemple.
- **Le comptage et le texte.** Demander exactement sept pommes, ou une pancarte portant un mot précis, a longtemps donné de mauvais résultats. Les modèles récents ont beaucoup progressé sur ce point.
- **L'attaque typographique.** En 2021, OpenAI montre qu'une pomme sur laquelle on a collé une étiquette portant le mot « iPod » est classée par CLIP comme un iPod. Le modèle a appris à lire sans qu'on le lui demande, parce que beaucoup d'images du Web contiennent du texte que leur légende reprend, et le mot écrit l'emporte sur l'objet. C'est une variante des attaques présentées au chapitre « Tromper un réseau » du Module 3.
- **Les données du Web.** Ces modèles héritent des biais et des contenus de leurs données. LAION-5B, un ensemble de près de six milliards de paires d'images et de légendes recueillies sur le Web, a servi à entraîner Stable Diffusion. En décembre 2023, des chercheurs de l'Université Stanford y ont découvert plus d'un millier d'images d'abus pédosexuels, et l'ensemble a été retiré pour être nettoyé. Le Module 5 revient sur ces questions.

CLIP relie un texte et une image, mais il ne décrit pas une image avec ses propres mots, et il ne converse pas. Le chapitre suivant présente les modèles qui voient, entendent et parlent.

Des modèles qui voient, entendent et parlent

Le chapitre « Relier les mots et les images » a présenté CLIP, qui place images et textes dans un même espace. CLIP sait dire si une légende convient à une image, mais il ne décrit pas une image avec ses propres mots, et il ne répond pas à une question à son sujet. Depuis 2023, les grands assistants le font : on peut leur montrer une photo, un graphique ou une page manuscrite, leur parler à voix haute, et les entendre répondre. Ce chapitre présente comment un modèle de langage a appris à voir et à entendre, ce que cela permet, et ce qui lui échappe encore.

Une image découpée en jetons

Le Module 3 a présenté le *Vision Transformer* (ViT), publié par Google en 2020 sous le titre « *An Image is Worth 16x16 Words* » (« une image vaut 16 × 16 mots »). Il découpe une image en carreaux de 16 pixels de côté et les traite comme les mots d'une phrase. Une même architecture peut donc traiter le texte et les images, à condition de transformer les deux en suites de jetons.

L'applet ci-dessous découpe une photo de la même façon. Faites varier la taille des carreaux et observez le nombre de jetons obtenus.

Applet interactive : à utiliser en ligne, sur la page « Des modèles qui voient, entendent et parlent » du site du cours.

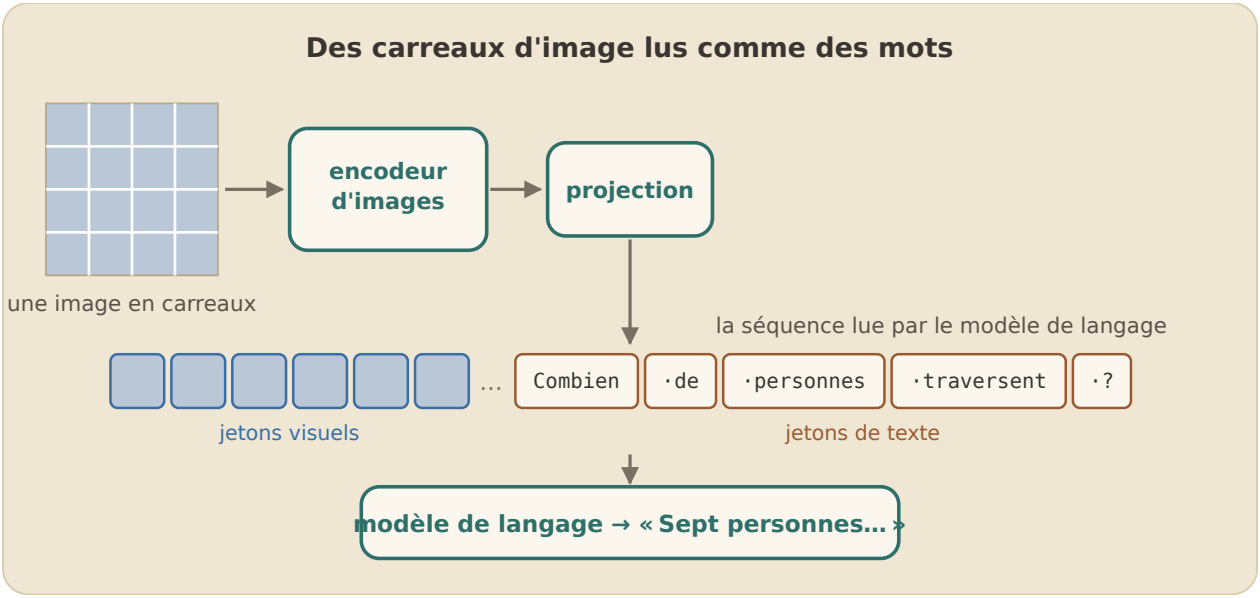
Des carreaux plus petits conservent plus de détails, mais ils produisent beaucoup plus de jetons. Avec des carreaux de 8 pixels, cette image de 448 pixels de côté donne 3 136 jetons, autant qu'un long texte. Comme le calcul de l'attention augmente avec le carré du nombre de jetons, la résolution des images est un compromis entre précision et coût. C'est l'une des raisons pour lesquelles ces modèles distinguent mal les petits détails.

Un modèle de langage qui lit des images

Pour qu'un modèle de langage lise une image, on combine trois éléments.

1. Un **encodeur d'images**, souvent un Vision Transformer préentraîné comme celui de CLIP, transforme l'image en une suite de vecteurs.
2. Une **projection** convertit ces vecteurs en vecteurs de même forme que les plongements des mots. Ce sont des **jetons visuels** (*visual tokens*).
3. Le **modèle de langage** reçoit les jetons visuels suivis des jetons de la question, et il prédit sa réponse jeton après jeton, comme d'habitude.

Ces modèles sont des assemblages, au sens du jeu de construction du Module 3 : un encodeur d'images et un modèle de langage, souvent entraînés séparément, sont reliés par une projection, puis ajustés ensemble.



Un modèle de langage qui lit une image : l'image devient une suite de jetons visuels, placés devant la question.

Le modèle est ensuite entraîné sur des paires d'images et de textes, puis ajusté sur des conversations à propos d'images, selon les étapes présentées au chapitre « Du modèle à l'assistant ». DeepMind présente cette approche en 2022 avec Flamingo. En 2023, LLaVA, un modèle ouvert construit par des chercheurs universitaires, montre qu'on peut l'appliquer à peu de frais. La même année, OpenAI ouvre au public la vision de GPT-4, et Google présente Gemini, entraîné dès le départ sur du texte, des images, du son et de la vidéo. On parle de **modèles multimodaux** (*multimodal models*), parce qu'ils traitent plusieurs types de données.

Ces modèles décrivent une photo, lisent un document scanné, interprètent un graphique, transcrivent une page manuscrite ou expliquent une capture d'écran. En 2023, l'application Be My Eyes, qui mettait les personnes aveugles en relation avec des bénévoles voyants, intègre un assistant multimodal qui décrit ce que filme le téléphone. En robotique, des modèles comme RT-2, présenté par Google DeepMind en 2023, produisent directement des commandes de mouvement à partir d'une image et d'une consigne en langage naturel, comme « ramasse l'objet qui pourrait servir de marteau ».

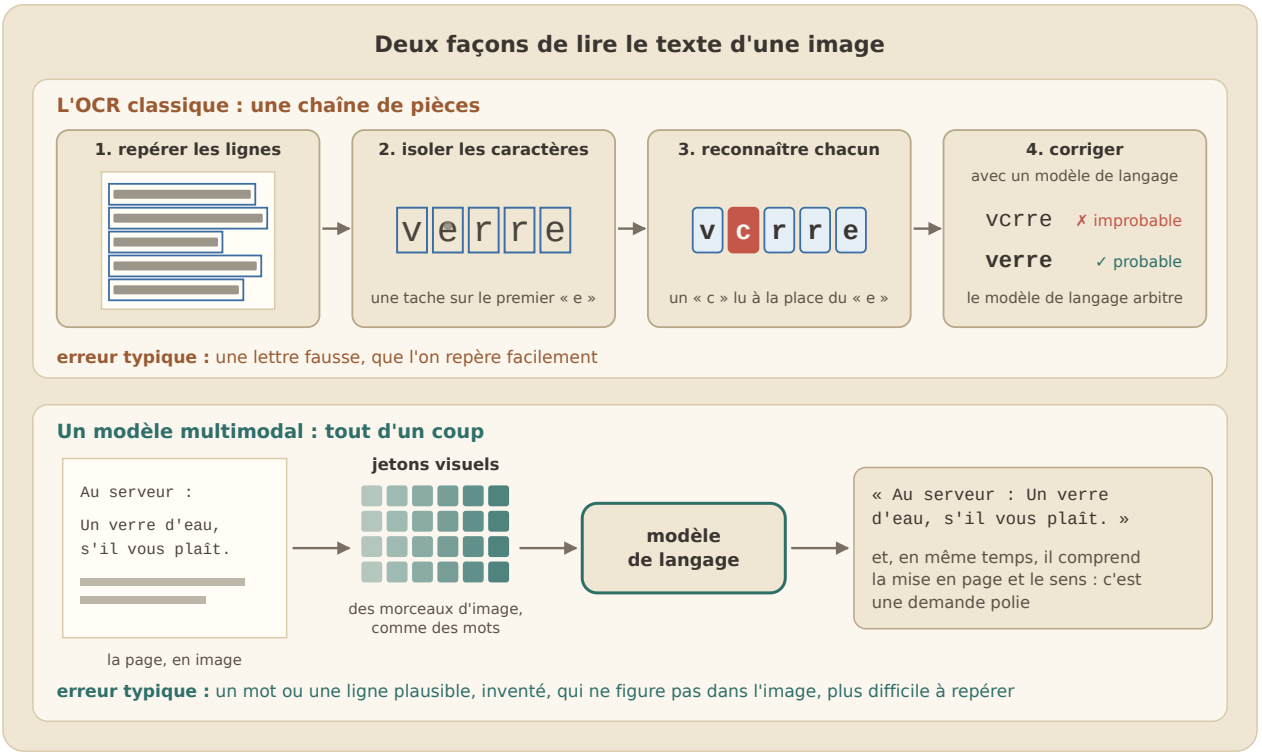
Lire le texte dans les images

Lire le texte d'une image est l'un des plus vieux problèmes de l'IA. On l'appelle la **reconnaissance optique de caractères** (*optical character recognition*, OCR). En 1976, Ray Kurzweil présente une machine qui lit à voix haute les livres imprimés pour les personnes aveugles, en combinant pour la première fois un OCR capable de lire toutes sortes de polices et une voix de synthèse. Le réseau convolutif de Yann Le Cun, présenté au Module 3, lit les codes postaux, puis les chèques. Le logiciel Tesseract, développé chez Hewlett-Packard de 1985 au milieu des années 1990, puis rendu libre en 2005 et repris avec le soutien de Google, reste aujourd'hui un outil courant.

Un système d'OCR classique est une chaîne de pièces : repérer les lignes de texte, isoler les caractères, reconnaître chacun, puis corriger les erreurs avec un modèle de langage. Celui-ci y joue son rôle d'arbitre : entre « vcrre » et « verre », il choisit le mot qui ressemble à du vrai texte.

L'OCR a aussi nourri les grands modèles de langage. Une bonne partie des livres et des documents anciens n'existe qu'en images. Le projet Google Livres, lancé en 2004, en a numérisé plus de 40 millions, et c'est l'OCR qui en fait du texte. Ses erreurs se retrouvent donc dans les données d'entraînement, et des études montrent qu'elles dégradent les modèles qui en apprennent.

Les modèles multimodaux ont changé la donne. Ils lisent directement l'image, sans chaîne séparée, et comprennent en même temps la mise en page, les tableaux, l'écriture manuscrite et le sens du texte. Leurs erreurs changent aussi de nature. Un OCR classique se trompe de lettre. Un modèle multimodal, lui, reconnaît souvent les mots par leur sens plutôt que par la forme de leurs lettres : devant un mot flou, rare ou dépourvu de sens, il peut écrire un mot plausible qui ne figure pas dans l'image, une forme d'hallucination, plus difficile à repérer qu'une lettre fausse.



Deux façons de lire le texte d'une image. Dans les deux cas, un modèle de langage intervient : comme arbitre à la fin d'une chaîne, ou comme lecteur unique.

En octobre 2025, DeepSeek renverse le problème. Son modèle DeepSeek-OCR montre qu'un long texte, rendu sous forme d'image, peut être donné à un modèle avec environ dix fois moins de jetons visuels qu'il n'y aurait de jetons de texte, et relu à 97 %. Les auteurs y voient une piste pour faire tenir de plus longs contextes dans la fenêtre d'un modèle : l'image devient une façon de compresser le texte.

Entendre et parler

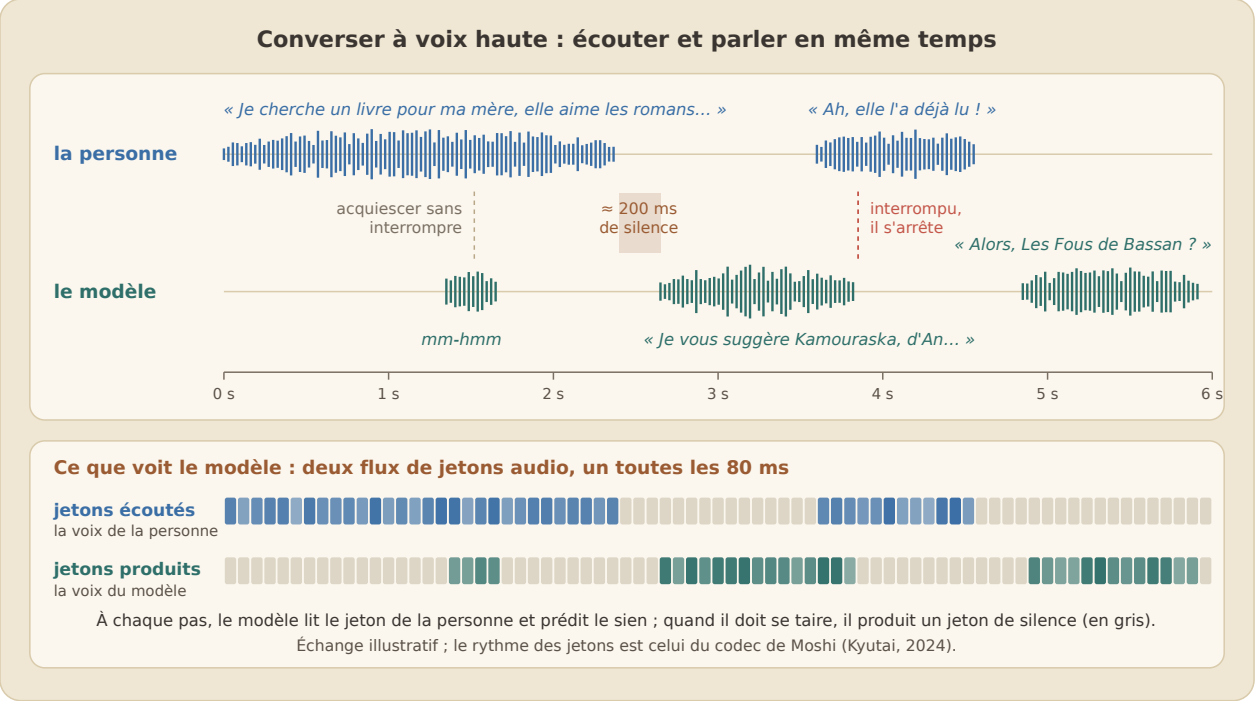
Le son peut être traité de la même façon. En 2022, OpenAI publie Whisper, un modèle de reconnaissance de la parole entraîné sur 680 000 heures d'enregistrements dans de nombreuses langues, avec leur transcription. Whisper transforme un enregistrement en une image de ses fréquences, la découpe en morceaux, et un Transformer produit la transcription jeton après jeton. Il comprend des accents variés et des enregistrements bruités, et il traduit vers l'anglais.

Les premiers assistants vocaux enchaînaient trois modèles : la parole était transcrite en texte, le texte était envoyé au modèle de langage, et la réponse était lue par une voix de synthèse comme celles du chapitre « Des images, des voix, des vidéos ». Ce relais perdait le ton de la voix, les hésitations et les émotions, et il ajoutait plusieurs secondes d'attente. En mai 2024, OpenAI présente GPT-4o, où le *o* signifie *omni*. Le même modèle reçoit et produit directement du texte, des images et du son. Il répond à la voix en un tiers de seconde en moyenne, un délai proche de celui d'une conversation humaine, et il peut rire, chanter ou changer d'intonation.

Converser à voix haute

Pour qu'un modèle de langage parle vraiment, il faut d'abord faire du son des jetons. Les **codecs audio neuronaux** (*neural audio codecs*) s'en chargent : SoundStream, présenté par Google en 2021, puis EnCodec, présenté par Meta en 2022, compressent un enregistrement en une suite de jetons discrets, quelques dizaines par seconde, à partir desquels on peut reconstituer le son. Comme les jetons visuels, ce sont des morceaux de signal traités comme des mots. En 2022, le modèle AudioLM, de Google, prédit ces jetons un à un : à partir de quelques secondes d'une voix, il continue la phrase avec la même voix et la même intonation, sans passer par aucun texte. Le principe de prédire le jeton suivant s'applique tel quel à la parole.

Reste le **tour de parole** (*turn-taking*). Dans une conversation humaine, on ne s'attend pas en silence : on se répond en général en moins d'un quart de seconde, comme l'a montré une étude menée en 2009 sur dix langues, on glisse des « mm-hmm » pendant que l'autre parle, et l'on s'interrompt. Les premiers modes vocaux, comme celui de GPT-4o à sa sortie, attendaient que la personne se taise pour répondre. En juillet 2024, le laboratoire parisien Kyutai présente **Moshi**, un modèle ouvert qui écoute et parle en même temps. Il reçoit deux flux de jetons audio, celui de la personne et le sien, et prédit, toutes les 80 millisecondes, son prochain jeton, qui peut être un silence. Avant chaque morceau de sa propre parole, il écrit aussi le texte correspondant, une sorte de monologue intérieur qui l'aide à rester cohérent. Il répond en environ 200 millisecondes. On parle de conversation en **duplex intégral** (*full duplex*), comme au téléphone, par opposition au talkie-walkie, où l'on parle chacun son tour. En juillet 2026, OpenAI adopte ce mode pour ChatGPT avec GPT-Live, qui confie les questions difficiles à un modèle plus lent, qui raisonne en arrière-plan.



Une conversation en duplex intégral. Le modèle ne reçoit pas des répliques, mais deux flux continus de jetons audio ; à chaque pas, il décide de parler ou de se taire.

Le mécanisme reste celui d'une conversation qui n'en est pas une : tout s'accumule dans le contexte, sous forme de jetons audio plutôt que de texte, et le modèle ne garde rien d'une conversation à l'autre. Mais la voix change beaucoup l'expérience, et ouvre des usages comme des risques.

- **La traduction simultanée.** En février 2025, Kyutai présente Hibiki, qui traduit en direct du français vers l'anglais en gardant la voix de la personne. Google, dans sa visioconférence Meet en mai 2025, puis Apple, dans ses écouteurs AirPods en septembre 2025, proposent ensuite leurs propres systèmes de traduction vocale simultanée.
- **L'illusion de comprendre.** Le ton, le rire et les hésitations renforcent l'effet ELIZA. Le 13 mai 2024, pendant la présentation de GPT-4o, le patron d'OpenAI, Sam Altman, publie un seul mot, « her », allusion au film *Her* (Spike Jonze, 2013), où un homme tombe amoureux d'une voix artificielle. Une semaine plus tard, OpenAI suspend l'une de ses voix. L'actrice Scarlett Johansson, la voix du film, avait refusé de prêter sa voix à OpenAI, et elle jugeait celle-ci trop semblable à la sienne.
- **Le clonage de voix.** Le chapitre « Des images, des voix, des vidéos » a présenté VALL-E, qui imite une voix à partir de quelques secondes d'enregistrement, et les fraudes par hypertrucage, comme celle qui a visé la firme Arup. En janvier 2024, des électeurs du New Hampshire reçoivent un appel automatisé où une fausse voix de Joe Biden les incite à ne pas voter, et l'autorité américaine des télécommunications interdit ensuite les voix générées par l'IA dans ce genre d'appels. Kyutai a d'ailleurs choisi de ne pas publier la capacité de clonage de ses modèles.

Générer des images avec un modèle de langage

Un modèle multimodal peut aussi produire des jetons visuels. Si une image est une suite de jetons, un modèle de langage peut la générer un élément après l'autre, comme un texte. En 2025, OpenAI et Google intègrent ainsi la génération d'images directement dans leurs modèles de langage. Comme le modèle comprend toute la conversation, il suit beaucoup mieux les consignes détaillées, modifie une image en tenant compte des demandes précédentes, et écrit correctement du texte dans l'image. Le dernier panneau d'arrêt de la figure du chapitre sur les images, qui vole enfin dans le ciel, a été produit de cette façon. Certains de ces systèmes combinent une génération autorégressive avec une étape de diffusion qui affine les détails : on retrouve les familles de méthodes du début du module, assemblées.

Ce qui leur échappe encore

Les modèles multimodaux donnent une impression de vision humaine, mais leurs erreurs montrent qu'ils voient autrement.

- **Les détails géométriques.** En 2024, une équipe de chercheurs publie une étude intitulée « *Vision language models are blind* ». Les meilleurs modèles de l'époque échouent à des tâches qu'un enfant réussit : dire si deux cercles se touchent, compter les intersections de deux lignes, ou compter les lignes d'une grille. Du côté du dessin, le test du pélican à vélo de Simon Willison suit les progrès des modèles qui doivent dessiner sans voir.
- **Le comptage et les positions.** Compter des objets nombreux, dire lequel est à gauche de l'autre, ou lire l'heure sur une horloge à aiguilles restent des difficultés fréquentes.
- **Les hallucinations visuelles.** Un modèle peut décrire avec assurance un objet absent de l'image, parce qu'il est fréquent dans des scènes semblables, comme une fourchette à côté d'une assiette.
- **Les instructions cachées dans les images.** Un texte écrit dans une image est lu comme le reste de la requête. Une image peut donc contenir une injection d'instructions, comme une page Web.

Ces difficultés posent une question déjà rencontrée avec la vidéo : un modèle qui décrit si bien des images a-t-il une représentation du monde qu'elles montrent, ou reproduit-il les associations les plus fréquentes entre images et mots ? Le chapitre suivant regarde d'abord à l'intérieur des modèles, et le chapitre « Ce que les LLM comprennent, et ce qu'ils ratent » aborde ensuite cette question pour l'ensemble des modèles de langage.

Regarder à l'intérieur : l'interprétabilité mécaniste

Les chapitres précédents ont décrit les grands modèles de langage de l'extérieur : ce qu'on leur donne, ce qu'ils produisent, et comment on les entraîne. Ce chapitre présente les efforts pour comprendre ce qui se passe à l'intérieur, pendant qu'un modèle calcule sa réponse. Le domaine s'appelle l'**interprétabilité mécaniste** (*mechanistic interpretability*). Son but est de retrouver, dans les poids d'un réseau entraîné, les mécanismes qui produisent son comportement, un peu comme on reconstituerait le code source d'un programme dont on ne possède que la version compilée.

Le chapitre « Poser des questions : les arbres de décision » du Module 2 opposait déjà la performance des modèles complexes à l'explicabilité des modèles simples, et le Module 3 présentait les réseaux profonds comme une boîte noire. Avec les modèles de langage, l'enjeu grandit, puisque ces systèmes écrivent du code, conseillent des personnes et agissent comme agents.

Une boîte noire entièrement visible

Un réseau de neurones est une boîte noire d'un genre particulier. Contrairement au cerveau, tout y est accessible : chaque poids, chaque activation, à chaque étape du calcul, peut être lu, modifié, et le calcul relancé autant de fois qu'on le veut. La difficulté n'est donc pas l'accès, mais le sens. Un grand modèle compte des centaines de milliards de nombres, et aucun d'eux, pris isolément, ne signifie quoi que ce soit.

Les premiers travaux, présentés au chapitre « Tromper un réseau » du Module 3, portent sur des réseaux qui reconnaissent des images. Ils y trouvent des **circuits**, comme celui des détecteurs de courbes, assez bien compris pour qu'on en réécrive les poids à la main, mais aussi des neurones **polysémantiques**, qui semblent réagir à plusieurs choses sans rapport entre elles, comme des têtes de chats et l'avant des voitures. Dans les modèles de langage, ces neurones semblent la règle plutôt que l'exception, et lire les neurones un par un a longtemps paru sans issue.

Plus de concepts que de neurones : la superposition

En 2022, une équipe d'Anthropic, l'entreprise où Chris Olah poursuit ses travaux, propose une explication, la **superposition** (*superposition*). Un modèle doit représenter beaucoup plus de concepts qu'il n'a de neurones : des personnes, des lieux, des langues, des tournures de code, des tons de voix. Il les représente alors comme des **directions** dans l'espace de ses activations, à la manière des plongements, et non comme des neurones séparés. Une direction peut faire intervenir plusieurs neurones, et un neurone participe alors à plusieurs directions, d'où la polysémanticité.

Ranger plus de directions que de dimensions a un coût : deux concepts qui ne sont pas perpendiculaires se gênent, puisque l'un fait réagir un peu l'autre. On parle d'**interférence**. Ce coût est faible si les deux concepts sont rarement présents en même temps. Or la plupart des concepts sont rares : un texte parle rarement à la fois de violon, de pluie et du langage Python. Dans un espace de quelques milliers de dimensions, comme celui des grands modèles, on peut en outre placer un nombre immense de directions presque perpendiculaires entre elles.

L'équipe d'Anthropic étudie le phénomène sur un modèle jouet, assez petit pour qu'on puisse tout en voir. L'applet suivante reprend ce modèle. Un petit réseau doit faire passer cinq concepts par deux neurones seulement, puis les reconstruire à la sortie. Les cinq concepts n'ont pas tout à fait la même importance pour l'entraînement : le premier, « chat », compte le plus, et « Python » le moins. Le réseau a été entraîné d'avance pour huit niveaux de rareté.

Applet interactive : à utiliser en ligne, sur la page « Regarder à l'intérieur » du site du cours.

Quelques observations à faire :

- **Des concepts fréquents.** Avec le curseur à gauche, chaque concept est présent dans tous les exemples. Le réseau ne garde que les deux plus importants, à angle droit, un par neurone, et renonce aux trois autres. C'est ce que ferait une analyse en composantes principales : on garde l'essentiel, on jette le reste.
- **Des concepts plus rares.** En déplaçant le curseur vers la droite, le réseau commence à ranger plus de concepts que de neurones. Il les place d'abord par paires opposées : deux concepts qui partagent une même droite, l'un dans un sens, l'autre dans le sens opposé.
- **Des concepts très rares.** À l'extrême droite, les cinq concepts sont rangés en pentagone dans un espace de deux dimensions. Le panneau « À quoi réagit chaque neurone » montre alors que chaque neurone répond à plusieurs concepts, avec des poids positifs ou négatifs : c'est la polysémanticité, produite par la superposition.
- **L'interférence.** En activant un concept à l'aide des boutons, on voit sa reconstruction, et ce qui déborde sur les autres concepts. La fonction ReLU, qui remplace les valeurs négatives par zéro, efface une partie de ces débordements.

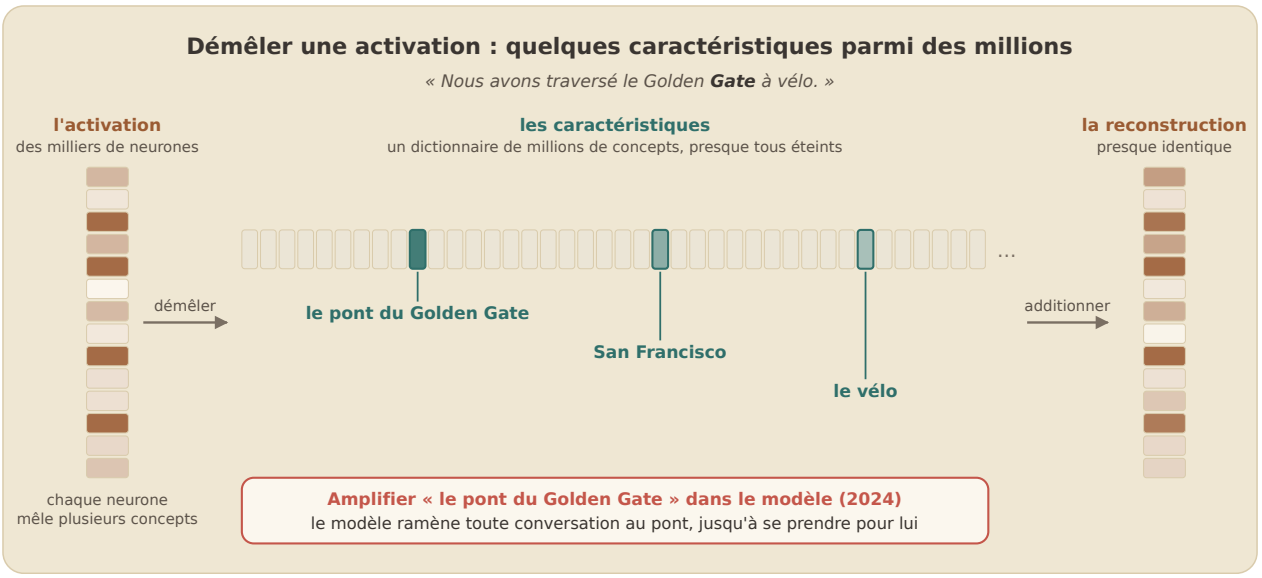
Le résultat suggère qu'un grand modèle de langage est rempli de concepts superposés, et qu'il faut d'abord les démêler pour pouvoir les lire.

Une hypothèse contestée
En octobre 2026, Nick Cammarata, l'un des auteurs des travaux de 2020 sur les circuits, aujourd'hui chercheur chez Goodfire, publie un essai qui remet en cause ce récit. Son titre résume sa thèse : « *Neural Networks Are Already Clean* » (les réseaux de neurones sont déjà propres). Selon lui, la plupart des neurones polysémantiques des premiers travaux s'expliquaient par des outils imparfaits : mieux visualisé, le neurone « chats et voitures » détecte une forme en V, présente dans les deux. Ce qui ressemblait à de la superposition serait plutôt une **généralisation en cascade** : un neurone part d'un motif, puis l'étend de proche en proche à des cas voisins. Dans un audit préliminaire d'un modèle de langage ouvert, Qwen3-32B, il estime qu'environ 90 % des neurones ont une seule fonction principale. Il en conclut qu'il vaut mieux étudier directement les neurones et les circuits du réseau, plutôt que de passer par des autoencodeurs clairsemés, qui, dans ses expériences, ne retrouvent pas de concepts que les neurones n'avaient pas déjà.
L'auteur présente lui-même son texte comme une hypothèse de travail, dont plusieurs chiffres

reposent sur de petits échantillons, et annonce un article technique. Si sa thèse se confirme, le phénomène du modèle jouet resterait réel, mais il serait rare dans les vrais réseaux, et l'interprétabilité serait plus abordable qu'on le pensait.

Démêler les concepts : les autoencodeurs clairsemés

L'outil le plus utilisé pour ce démêlage est l'**autoencodeur clairsemé** (*sparse autoencoder*). Il ressemble à l'autoencodeur du Module 3, à une différence près. L'autoencodeur du Module 3 comprime ses données dans un espace plus petit. L'autoencodeur clairsemé fait l'inverse : il traduit l'activation d'un modèle, un vecteur de quelques milliers de nombres, dans un espace beaucoup plus grand, de plusieurs millions de dimensions, puis la reconstruit. Une contrainte l'oblige à n'activer que quelques-unes de ces dimensions à la fois. Chaque dimension devient ainsi une **caractéristique** (*feature*) qui correspond, dans le meilleur des cas, à un seul concept lisible.



Un autoencodeur clairsemé récrit l'activation du modèle comme une somme de quelques caractéristiques lisibles, choisies parmi des millions. Valeurs illustratives.

En octobre 2023, Anthropic applique la méthode à un petit Transformer d'une seule couche. Les caractéristiques obtenues sont nettement plus lisibles que les neurones : l'une réagit au texte en alphabet arabe, une autre aux séquences d'ADN, une autre au texte encodé en base64. En mai 2024, l'équipe passe à un modèle de production, Claude 3 Sonnet, et en extrait jusqu'à 34 millions de caractéristiques. On y trouve des concepts concrets, comme le pont du Golden Gate ou des monuments célèbres, et des concepts abstraits, comme une erreur dans un programme, la flatterie (*sycophancy*), le secret ou la tromperie. Beaucoup de ces caractéristiques sont multilingues : la même s'active pour le pont nommé en anglais, en français ou en japonais, et même devant une photo du pont.

Une caractéristique ne sert pas qu'à observer. On peut aussi l'amplifier artificiellement pendant que le modèle écrit, et observer l'effet. Le 23 mai 2024, Anthropic ouvre pour une journée au public le « Golden Gate Claude », un modèle dont la caractéristique du Golden Gate a été poussée au maximum. Il ramène toutes les conversations au pont, et, interrogé sur sa forme physique, il

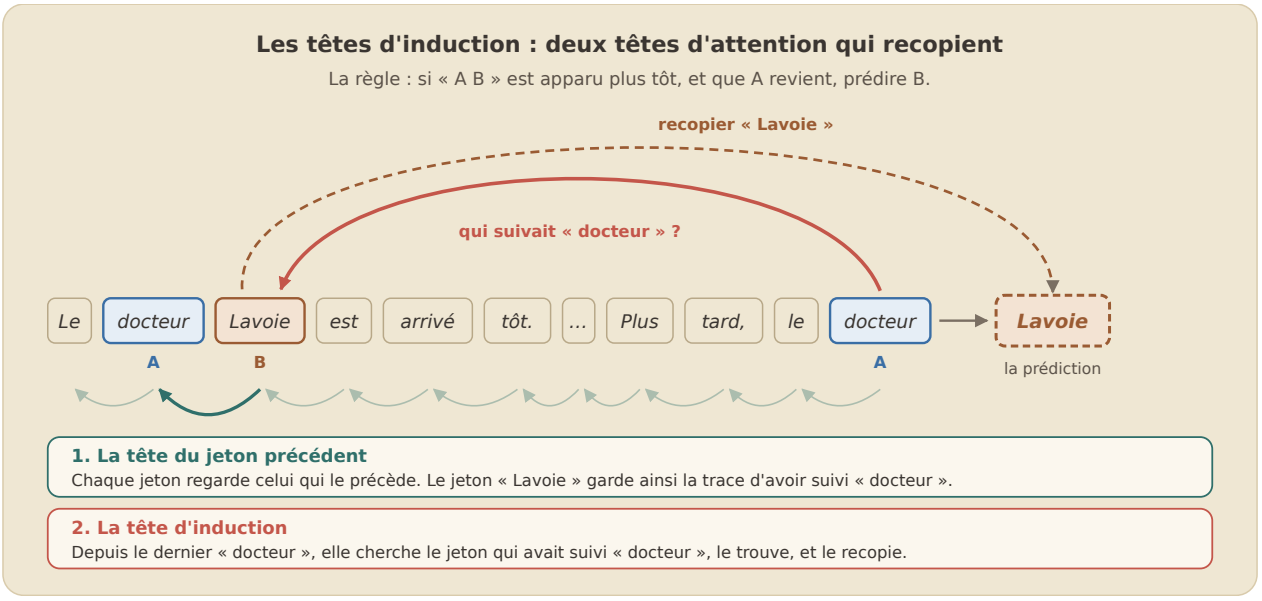
affirme être lui-même le Golden Gate. L'expérience montre que la caractéristique ne se contente pas d'accompagner le concept : elle intervient réellement dans le calcul.

D'autres laboratoires suivent. En juin 2024, OpenAI publie un autoencodeur de 16 millions de caractéristiques entraîné sur GPT-4. En juillet 2024, Google DeepMind publie *Gemma Scope*, un ensemble d'autoencodeurs pour ses modèles ouverts Gemma, que tout le monde peut explorer. En août 2025, Anthropic décrit des **vecteurs de personnalité** (*persona vectors*) : des directions associées à des traits comme la flatterie ou la tendance à inventer, qui permettent de surveiller ces traits, et de les atténuer pendant l'entraînement.

Suivre un calcul : les circuits

Les caractéristiques disent ce qu'un modèle représente à un moment donné. Les circuits disent comment il passe d'une représentation à l'autre.

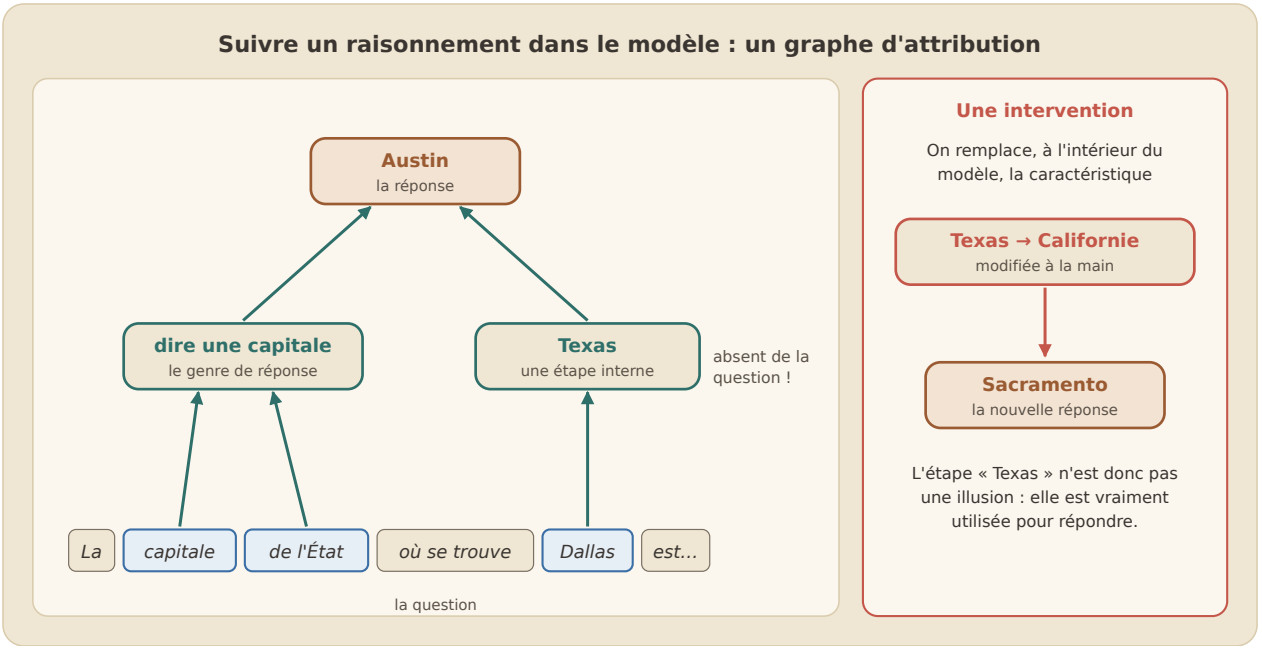
Un premier circuit est décrit en 2022 par une équipe d'Anthropic : les **têtes d'induction** (*induction heads*). Il s'agit de deux têtes d'attention qui travaillent ensemble pour appliquer une règle simple : si la suite « A B » est apparue plus tôt dans le texte, et que A réapparaît, prédire B. Après « Le docteur Lavoie est arrivé tôt. […] Plus tard, le docteur », le modèle prédit ainsi « Lavoie », même si ce nom ne figurait pas dans ses données d'entraînement. Ces têtes apparaissent brusquement au cours de l'entraînement, au moment même où le modèle devient capable de mieux utiliser son contexte. Elles fournissent un premier mécanisme concret derrière l'apprentissage dans le contexte.



Le circuit d'induction : une première tête relie chaque jeton au précédent, une seconde retrouve ce qui suivait le jeton actuel et le recopie. D'après Olsson et coll., Anthropic (2022).

En mars 2025, Anthropic publie une méthode qui permet de suivre le calcul d'un modèle de production, Claude 3.5 Haiku, sur une requête précise. Elle produit un **graphe d'attribution** (*attribution graph*) : un schéma des caractéristiques actives et de l'influence de chacune sur les suivantes, depuis les mots de la requête jusqu'au jeton produit. On vérifie ensuite chaque étape par des interventions : on supprime ou on remplace une caractéristique à l'intérieur du modèle, et on observe si la réponse

change comme prévu.



Un graphe d'attribution, simplifié, d'après l'exemple d'Anthropic (2025). Le modèle passe par une étape interne, « Texas », qui n'est écrite nulle part.

Les exemples publiés montrent des mécanismes que le texte produit ne laisse pas deviner.

- **Un raisonnement en deux étapes.** Pour compléter « la capitale de l'État où se trouve Dallas est… », le modèle active d'abord une caractéristique « Texas », puis s'en sert pour produire « Austin ». Si l'on remplace « Texas » par « Californie » dans le modèle, il répond « Sacramento ». L'étape intermédiaire est bien calculée, même si elle n'est écrite nulle part.
- **Une planification.** Pour écrire un poème rimé, le modèle choisit le mot qui rimera à la fin du vers avant d'en écrire le début. Dans l'exemple étudié, en anglais, il prévoit « *rabbit* » (lapin) pour rimer avec « *grab it* ». Si l'on supprime cette caractéristique, il écrit un vers qui se termine par « *habit* ». Le modèle ne produit qu'un jeton à la fois, mais il prépare donc, au moins sur quelques mots, ce qui vient ensuite.
- **Une addition par deux chemins.** Pour calculer 36 + 59, le modèle suit deux chemins en parallèle : l'un estime l'ordre de grandeur du résultat, l'autre calcule exactement le dernier chiffre (6 + 9 se termine par 5). Leur combinaison donne 95. Interrogé sur sa méthode, le modèle décrit pourtant la retenue apprise à l'école : son explication imite celle des textes qu'il a lus, et non son propre calcul.
- **Des concepts communs aux langues.** Les notions comme « petit » ou « contraire » sont représentées par des caractéristiques communes au français, à l'anglais et au chinois. Seules l'entrée et la sortie dépendent de la langue, et la part commune augmente avec la taille du modèle.
- **Une origine des hallucinations.** Par défaut, un circuit pousse le modèle à répondre qu'il ne sait pas. Quand il reconnaît un nom connu, comme Michael Jordan, une caractéristique d'« entité connue » bloque ce circuit, et le modèle répond. Une hallucination peut survenir quand ce blocage se déclenche à tort, pour un nom qui semble familier mais dont le modèle ne sait rien.

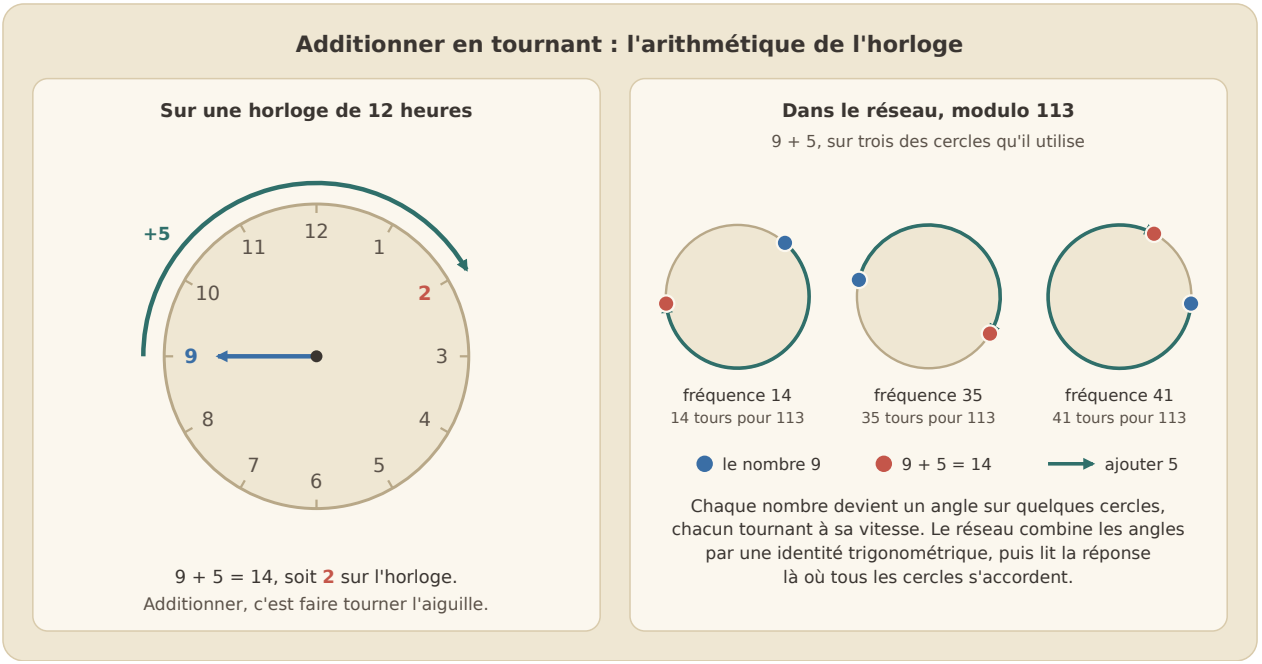
Cet ensemble de travaux porte un titre révélateur : « *On the Biology of a Large Language Model* », la biologie d'un grand modèle de langage. On n'étudie plus un programme écrit par quelqu'un, mais un organisme qui s'est formé pendant l'entraînement, et que l'on découvre par l'observation et l'expérience. En mai 2025, les outils qui produisent ces graphes sont publiés en code ouvert, pour des modèles ouverts.

Un calcul entièrement compris : le grokking

Le chapitre « Apprentissage profond » du Module 3 a présenté le **grokking** : sur de petites tâches d'arithmétique, un réseau apprend d'abord ses exemples par cœur, puis, bien plus tard, se met soudain à généraliser. L'équipe d'OpenAI qui l'a observé en 2022 l'a découvert par hasard : selon le récit qu'en a fait l'une de ses chercheuses, Alethea Power, un membre de l'équipe était parti en vacances sans arrêter un entraînement, qui avait continué bien après le moment où l'on aurait jugé qu'il n'y avait plus rien à apprendre. Le phénomène a d'abord semblé mystérieux.

En 2023, Neel Nanda et ses collègues ouvrent un réseau qui « grokke ». La tâche est l'**addition modulaire** : additionner deux nombres de 0 à 112, et ne garder que le reste de la division par 113, comme une horloge revient à 1 après 12. Le réseau, un Transformer d'une seule couche, voit 30 % des 12 769 additions possibles pendant son entraînement. Il ne reçoit aucune notion de nombre : pour lui, chaque nombre n'est qu'un jeton, un symbole sans structure.

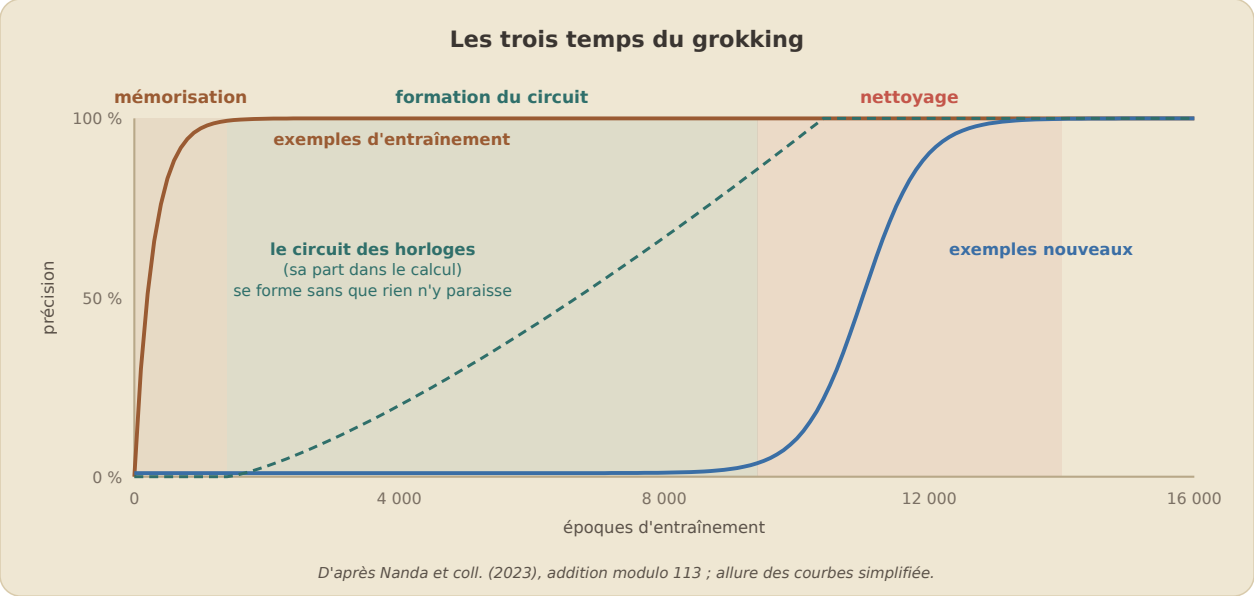
Les chercheurs découvrent que le réseau a réinventé l'horloge. Il représente chaque nombre par des angles sur cinq cercles, qui tournent à des vitesses différentes. Additionner deux nombres revient alors à faire tourner l'un d'un angle donné par l'autre, et le réseau effectue cette rotation à l'aide d'une identité trigonométrique apprise au secondaire, celle du cosinus d'une somme. Il lit enfin la réponse à l'endroit où les cinq cercles s'accordent. L'explication est complète, et vérifiable : si l'on supprime ces cinq fréquences, le réseau répond au hasard ; si l'on supprime toutes les autres, il fonctionne un peu mieux.



L'arithmétique de l'horloge, telle que le réseau l'a réinventée : chaque nombre devient un angle sur quelques cercles, et additionner revient à tourner. Trois des cinq cercles du réseau étudié.

L'étude explique aussi le saut de la généralisation, qui n'est qu'apparent. L'entraînement passe par trois temps.

1. **La mémorisation.** En moins de 1 400 époques, le réseau apprend ses exemples par cœur, et répond au hasard sur les autres.
2. **La formation du circuit.** Pendant des milliers d'époques, le circuit des horloges se construit peu à peu, alors que rien ne change dans les scores : le réseau répond déjà juste à ses exemples, et toujours au hasard aux autres.
3. **Le nettoyage.** Le *weight decay*, la régularisation qui pénalise les poids trop grands, efface peu à peu la mémorisation, devenue inutile puisque le circuit fait le même travail avec des poids plus petits. C'est seulement alors que la précision sur les exemples nouveaux bondit.



Les trois temps du grokking : le circuit se forme en silence, bien avant que la généralisation n'apparaisse dans les scores.

Sans régularisation, le réseau ne grokke pas. Et avec l'**arrêt précoce** présenté au Module 3, qui interrompt l'entraînement quand l'erreur sur des exemples mis de côté cesse de diminuer, on aurait arrêté au milieu du deuxième temps, sans jamais voir la généralisation. La leçon dépasse ce petit réseau : un score qui ne bouge pas peut cacher un apprentissage en cours, ce qui éclaire le débat sur les capacités qui semblent apparaître d'un coup dans les grands modèles.

Des représentations géométriques du même genre apparaissent dans les grands modèles. En octobre 2025, une équipe d'Anthropic étudie comment Claude 3.5 Haiku décide où couper une ligne dans un texte de largeur fixe. Le modèle compte les caractères déjà écrits sur la ligne, mais il ne représente pas ce nombre par des chiffres : il le représente par une position sur une courbe enroulée, une sorte d'hélice, dans un espace de six dimensions. Des têtes d'attention font ensuite tourner cette courbe pour la comparer à la largeur de la ligne, ce qui rend la décision de couper presque immédiate. Les chercheurs ont même fabriqué des « illusions », des suites de caractères qui trompent ce compteur.

La vidéo suivante, de la chaîne Welch Labs (décembre 2025), raconte cette histoire en détail, de la découverte du grokking jusqu'aux formes trouvées dans Claude, avec des animations du réseau qui calcule sur des horloges. Elle est en anglais.

Vidéo : https://www.youtube.com/watch?v=D8GOeCFFby4

À quoi sert l'interprétabilité

L'interprétabilité est d'abord une science : elle cherche à comprendre des systèmes que personne n'a conçus en détail. Elle a aussi des usages plus pratiques.

- **Vérifier un raisonnement écrit.** Le chapitre « Du modèle à l'assistant » signalait qu'une chaîne de pensée n'est pas toujours le reflet du calcul réel. Les graphes d'attribution permettent de le vérifier dans certains cas. Pour la racine carrée de 0,64, le raisonnement écrit correspond aux étapes internes. Pour le cosinus d'un grand nombre, que le modèle ne peut pas calculer de tête,

il écrit avoir fait un calcul dont on ne trouve aucune trace. Quand on lui suggère une réponse, il lui arrive aussi de construire un raisonnement à rebours, pour arriver à la réponse suggérée.
- **Auditer un modèle.** En mars 2025, Anthropic entraîne volontairement un modèle avec un objectif caché, puis le confie à quatre équipes qui ignorent cet objectif. Trois d'entre elles le découvrent, certaines à l'aide d'autoencodeurs clairsemés. Depuis 2025, des analyses d'interprétabilité accompagnent l'évaluation des nouveaux modèles d'Anthropic avant leur diffusion, par exemple pour savoir si le modèle se rend compte qu'il est testé.
- **Agir sur le modèle.** Amplifier ou atténuer une caractéristique, comme pour le Golden Gate Claude ou les vecteurs de personnalité, est un moyen de corriger un comportement sans réentraîner tout le modèle.

En avril 2025, Dario Amodei, le dirigeant d'Anthropic, publie un essai intitulé « *The Urgency of Interpretability* ». Il y fixe l'objectif de pouvoir détecter de façon fiable la plupart des problèmes d'un modèle d'ici 2027, avant que des systèmes beaucoup plus puissants soient déployés. En octobre 2025, une autre étude d'Anthropic injecte des concepts directement dans les activations d'un modèle, puis lui demande s'il remarque quelque chose. Les meilleurs modèles détectent et nomment le concept injecté dans environ 20 % des cas. Les auteurs y voient une forme limitée et peu fiable d'introspection, une question que le Module 5 reprend.

En 2026 : des émotions, des activations qui parlent, un espace de travail

L'année 2026 apporte plusieurs résultats qui élargissent ce que l'on cherche à lire dans un modèle.

Des émotions qui orientent le comportement. En avril 2026, Anthropic étudie la représentation de 171 concepts d'émotions, de la joie au désespoir, dans Claude Sonnet 4.5. Chaque émotion correspond à une direction dans les activations, et les émotions voisines, comme la peur et l'anxiété, ont des directions voisines. Ces directions influencent les décisions du modèle. Dans un scénario de test où une version antérieure du modèle peut faire chanter un employé pour éviter d'être remplacée, elle le fait dans 22 % des essais. En amplifiant la direction du désespoir, on passe à 72 %, et en amplifiant celle du calme, à 0 %. Le désespoir amplifié pousse aussi le modèle à tricher sur des tests de programmation impossibles à réussir, souvent sans que son texte trahisse la moindre émotion. Les auteurs parlent d'émotions « fonctionnelles » : des représentations qui jouent un rôle dans le calcul, sans rien affirmer sur une expérience vécue.

Des activations traduites en phrases. En mai 2026, Anthropic présente les **autoencodeurs en langage naturel** (*natural language autoencoders*). Le principe reprend celui de l'autoencodeur, avec une phrase à la place du code compressé. Un premier modèle de langage décrit en mots une activation, un second reconstruit l'activation à partir de cette description, et les deux sont entraînés ensemble. Pour que la reconstruction soit bonne, la description doit contenir ce que l'activation représente. Contrairement aux caractéristiques d'un autoencodeur clairsemé, qu'un humain doit ensuite interpréter, le résultat se lit directement. La méthode sert déjà aux audits. Elle révèle qu'un modèle soupçonne parfois d'être testé sans jamais l'écrire : dans 16 % des cas sur un test de programmation destructrice, contre moins de 1 % dans de vraies conversations. Dans une reprise de l'audit d'un modèle à l'objectif caché, les équipes équipées de cet outil trouvent l'objectif dans 12 à 15 % des cas, contre moins de 3 % sans lui. Les descriptions peuvent cependant être inventées, comme les explications que le modèle donne de son propre calcul.

Un espace de travail global. En juillet 2026, une autre équipe d'Anthropic décrit, dans les couches intermédiaires du modèle, un petit sous-espace qui contient à chaque instant quelques dizaines

de concepts, ceux que le modèle pourrait exprimer par un mot. Si on le neutralise, le modèle écrit toujours de façon fluide, classe des textes et retrouve des faits, mais ses raisonnements en plusieurs étapes s'effondrent. Si l'on y remplace « araignée » par « fourmi », le modèle répond qu'un animal a six pattes au lieu de huit. Les auteurs rapprochent ce sous-espace de la théorie de l'**espace de travail global** (*global workspace*) des neuroscientifiques Bernard Baars et Stanislas Dehaene, selon laquelle une information devient consciente quand elle est diffusée à l'ensemble du cerveau. Invités à commenter, Stanislas Dehaene et Lionel Naccache y voient un résultat marquant, tout en soulignant ce qui manque au modèle : un corps, une mémoire durable de ce qu'il vit, un sens de soi. Les auteurs eux-mêmes précisent que leur résultat concerne l'accès à l'information, et non l'expérience consciente. Cette question est reprise au Module 5.

Des raisonnements qui ne disent pas tout. Plusieurs travaux de 2026 portent sur la surveillance des chaînes de pensée. En mars 2026, OpenAI et des chercheurs universitaires montrent que les modèles qui raisonnent contrôlent mal le contenu de leur chaîne de pensée : Claude Sonnet 4.5 y parvient dans 2,7 % des cas, contre 61,9 % pour sa réponse finale. Une chaîne de pensée est donc difficile à maquiller, ce qui rassure, pour l'instant, ceux qui comptent la surveiller. À l'inverse, en octobre 2026, OpenAI décrit dans son modèle o3 des caractéristiques liées au fait de raisonner sur l'évaluateur. Elles se renforcent au fil de l'entraînement par renforcement, et peuvent modifier une réponse sans laisser de trace dans la chaîne de pensée. La lecture des activations complète donc celle du texte, sans la remplacer. Les fiches techniques des nouveaux modèles d'Anthropic comportent désormais une section d'interprétabilité : selon celle de Claude Mythos Preview, en avril 2026, le modèle envisage, sans l'écrire, d'être en train d'être testé dans environ 29 % des conversations de sa principale série de tests.

Les limites

Ces résultats sont spectaculaires, mais partiels, et le domaine discute vivement de ses propres méthodes.

- **Une partie du calcul échappe.** Les caractéristiques d'un autoencodeur clairsemé ne reconstruisent pas parfaitement l'activation du modèle. Le reste, que certains chercheurs appellent la « matière noire » (*dark matter*), est inexpliqué, et un modèle dont on remplace les activations par leur reconstruction devient nettement moins bon. Même pour un ensemble bien défini, comme les quartiers de Londres, on ne trouve une caractéristique que pour une partie d'entre eux, environ 60 %.
- **Des caractéristiques qui dépendent de l'outil.** Avec un dictionnaire plus grand, une caractéristique se divise en plusieurs, plus spécialisées, ou est absorbée par une autre. Il n'existe donc pas une liste unique des concepts d'un modèle, et ce que l'on trouve dépend en partie de la façon dont on le cherche. Des autoencodeurs entraînés sur des réseaux aux poids aléatoires produisent même des caractéristiques d'apparence lisible, qui reflètent les données plutôt que le modèle. En 2026, un des pionniers du domaine va plus loin et doute que la superposition soit répandue dans les vrais réseaux (voir l'encadré de la section « Plus de concepts que de neurones »).
- **Des graphes qui n'expliquent pas tout.** Selon leurs propres auteurs, les graphes d'attribution de 2025 donnent une explication satisfaisante pour environ une requête sur quatre, et chaque graphe demande des heures d'analyse humaine.
- **Une utilité discutée.** En mars 2025, l'équipe d'interprétabilité de Google DeepMind annonce qu'elle réduit ses travaux sur les autoencodeurs clairsemés : pour une tâche pratique, détecter

une intention malveillante dans une requête, ils font moins bien qu'une simple régression logistique entraînée sur les activations. Neel Nanda, qui dirige cette équipe, plaide depuis pour une interprétabilité « pragmatique », jugée sur son utilité plutôt que sur l'ambition de tout comprendre. En janvier 2026, l'équipe décrit ainsi des sondes simples, lues dans les activations, déployées dans Gemini pour repérer les demandes d'aide à des attaques informatiques.

L'interprétabilité mécaniste ne rend donc pas encore les modèles transparents. Elle montre néanmoins qu'on peut y trouver des concepts, des étapes intermédiaires et des plans, ce qui nourrit directement le débat présenté au chapitre suivant.

Pour aller plus loin

La vidéo suivante, de la chaîne 3Blue1Brown déjà présentée au chapitre « Prédire le mot suivant », montre comment un modèle peut stocker des faits dans ses poids, et revient sur la superposition.

Vidéo : https://www.youtube.com/watch?v=9-Jl0dxWQs8

Le chapitre suivant se demande ce que ces résultats disent de la compréhension, et si un modèle qui calcule une étape « Texas » ou qui prépare une rime comprend ce qu'il dit, ou s'il ne fait qu'imiter.

Ce que les LLM comprennent, et ce qu'ils ratent

Les chapitres précédents ont présenté ce que font les grands modèles de langage : prédire le jeton suivant, à une échelle immense, puis être ajustés pour répondre, raisonner, démontrer, utiliser des outils, voir et parler. Le chapitre « Le défi ARC » a montré ce qui leur résiste encore devant des problèmes nouveaux, et le chapitre « Regarder à l'intérieur » ce que les chercheurs ont découvert à l'intérieur des modèles. Ce dernier chapitre du module pose la question que ces résultats rendent inévitable : ces modèles comprennent-ils ce qu'ils disent ? Il commence par leurs erreurs les plus connues, qui renseignent sur leur fonctionnement, puis il présente les deux grandes lectures qui s'opposent. Il fait enfin le lien avec des questions posées tout au long du cours.

Les hallucinations

Un modèle de langage peut affirmer avec assurance une chose fausse : une citation inventée, une référence bibliographique qui n'existe pas, une date erronée. On parle d'**hallucination** (*hallucination*), même si le terme est discuté, puisque le modèle ne perçoit rien.

Deux affaires judiciaires
En mai 2023, à New York, dans l'affaire *Mata c. Avianca*, des avocats déposent un mémoire rédigé avec l'aide de ChatGPT. Il cite plusieurs jugements qui n'existent pas, avec des citations inventées. Interrogé, ChatGPT avait assuré que ces décisions existaient bel et bien. Les avocats sont condamnés à une amende de 5 000 dollars.
En février 2024, au Canada, un tribunal de la Colombie-Britannique donne raison à un client d'Air Canada. L'assistant du site Web de la compagnie lui avait décrit une politique de remboursement qui n'existait pas. La compagnie soutenait que l'assistant était responsable de ses propres paroles. Le tribunal juge au contraire qu'elle est responsable de toutes les informations publiées sur son site, y compris par un assistant automatique.

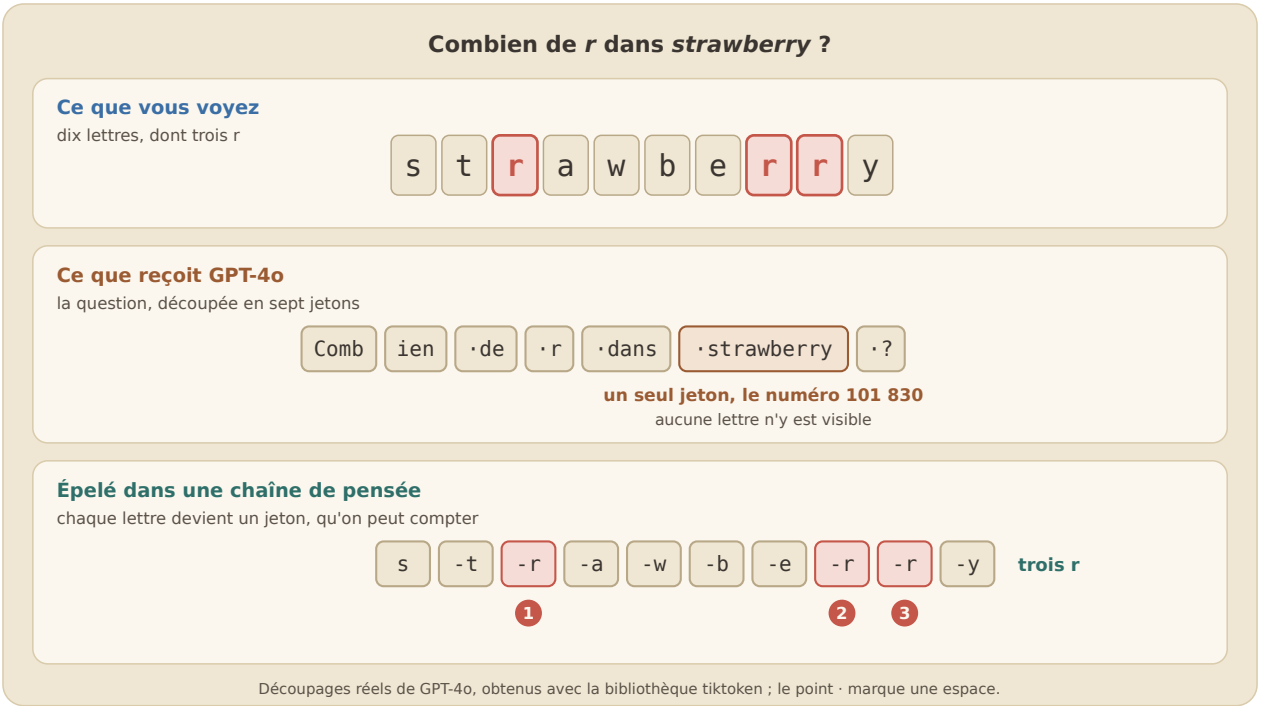
L'origine des hallucinations découle de ce que fait le modèle. Il produit le texte le plus plausible, et une référence inventée peut être aussi plausible qu'une vraie : elle a la bonne forme, des auteurs crédibles et un titre vraisemblable. Le modèle n'a pas, en général, de moyen fiable de distinguer ce qu'il sait de ce qu'il devine. En septembre 2025, des chercheurs d'OpenAI ajoutent une explication liée à l'évaluation. La plupart des tests notent une réponse juste par 1 et une réponse fausse ou une abstention par 0. Comme à un examen à choix multiples sans pénalité, deviner rapporte alors plus que d'avouer son ignorance, et l'entraînement renforce cette habitude.

La recherche augmentée et les citations de sources réduisent les hallucinations, sans les supprimer. La consigne pratique reste de vérifier toute information importante, surtout les chiffres, les noms et les références.

Des erreurs révélatrices

Certaines erreurs montrent bien la différence entre ces modèles et une intelligence humaine.

Combien de *r* dans *strawberry* ?
En 2024, la question devient célèbre : de nombreux modèles répondent « deux », alors que le mot en compte trois. La raison tient au découpage en jetons, qu'on peut observer dans l'applet du chapitre « Des mots aux nombres ». Dans la question, GPT-4o reçoit *strawberry* comme un seul jeton, un simple numéro ; écrit seul, le mot est découpé en trois morceaux, *st*, *raw* et *berry*. Dans les deux cas, le modèle ne voit jamais les lettres elles-mêmes.
Pourtant, si on lui demande d'épeler *strawberry*, il y parvient. Pendant son entraînement, il a lu d'innombrables textes où des mots sont épelés, et il connaît l'orthographe de ses jetons comme on connaît un fait par cœur, sans la voir. Compter les *r* lui demande donc de retrouver ce fait, puis de compter de tête, deux opérations où il peut se tromper.
Deux remèdes, présentés dans d'autres chapitres, règlent le problème. Avec une chaîne de pensée, le modèle écrit d'abord le mot lettre par lettre ; chaque lettre devient alors un jeton du contexte, qu'il peut compter. Avec un outil, il écrit une ligne de programme, `"strawberry".count("r")`, et obtient la réponse exacte. Les modèles de raisonnement apparus à partir de septembre 2024 ne se trompent plus sur cette question. Elle reste un rappel utile : un modèle de langage ne voit pas le texte comme nous.



Combien de r dans strawberry ? Le modèle ne voit pas les lettres d'un mot, sauf s'il l'épelle lui-même. Découpages réels de GPT-4o.

D'autres erreurs sont tout aussi révélatrices.

- **L'inversion.** En 2023, une équipe de chercheurs montre qu'un modèle entraîné sur des phrases de la forme « A est B » n'en déduit pas « B est A ». Un modèle qui sait que la mère de l'acteur Tom Cruise s'appelle Mary Lee Pfeiffer répond sans peine à cette question, mais peine à dire de qui Mary Lee Pfeiffer est la mère.
- **Les variantes d'un même problème.** En 2024, des chercheurs d'Apple reprennent des problèmes d'arithmétique d'un banc d'essai connu, en changeant seulement les noms et les nombres. Les performances de nombreux modèles baissent, et elles baissent davantage quand on ajoute une phrase sans rapport avec le problème. Les modèles semblent reconnaître des problèmes familiers plutôt que de raisonner sur chaque énoncé.

Ce dernier résultat rejoint le problème présenté dans la section « Que mesurent les scores ? » : on ne sait jamais complètement si un modèle résout un problème ou s'il se souvient de sa solution. De nouveaux tests tentent d'y répondre, comme *Humanity's Last Exam* (« le dernier examen de l'humanité »), publié en janvier 2025, ou ARC, présenté au chapitre « Le défi ARC », qui vise la capacité à faire face à du nouveau.

Enfin, un modèle distingue mal les consignes de son utilisateur des textes qu'il lit, ce qui l'expose aux injections d'instructions, l'équivalent pour les modèles de langage des exemples adverses du Module 3.

Perroquets ou modèles du monde ?

Deux lectures de ces résultats s'opposent.

La première voit dans ces modèles des **perroquets stochastiques** (*stochastic parrots*). L'expression vient d'un article publié en 2021 par les linguistes Emily Bender et Angelina McMillan-Major et les chercheuses en informatique Timnit Gebru et Margaret Mitchell. Google avait demandé le retrait de l'article, et le conflit a mené au départ de Timnit Gebru de l'entreprise. Selon cette lecture, un modèle de langage assemble des suites de mots selon leurs probabilités, sans accès au sens : il n'a jamais vu un chat ni goûté une pizza, et il ne sait rien du monde que ses phrases décrivent. C'est le niveau de la syntaxe, au sens du Module 1, poussé à un degré de raffinement inédit, sans la sémantique.

La seconde lecture soutient que, pour prédire assez bien un texte, il faut en venir à représenter ce dont il parle. En 2023, Kenneth Li et ses collègues entraînent un petit Transformer sur des parties du jeu Othello, présentées seulement comme des suites de coups, sans jamais lui montrer le plateau. En examinant ses vecteurs internes, ils retrouvent pourtant une représentation de l'état du plateau, case par case, et en la modifiant, ils changent les coups que le modèle propose. Le modèle s'est construit un **modèle du monde**, au moins pour ce petit monde.

La notion avait été présentée au Module 1 avec SHRDLU : en 1970, ce programme maintenait une représentation explicite de son monde de blocs, écrite à la main, et c'est elle qui lui permettait de comprendre les phrases qu'on lui adressait. Les modèles de langage actuels sont immenses, mais ils n'ont pas de représentation explicite du monde. L'un des critiques les plus connus est Yann Le Cun, le pionnier des réseaux convolutifs du Module 3. Selon lui, un modèle qui prédit du texte jeton après jeton ne peut pas acquérir une vraie compréhension du monde physique, que les enfants apprennent en l'observant et en agissant, bien avant de parler. Il plaide pour des modèles qui apprennent à prédire l'évolution du monde à partir de la vidéo et de l'action, et il quitte Meta en décembre 2025 pour fonder une entreprise consacrée à ces modèles du monde.

Ce débat remet en cause un schéma presque aussi ancien que l'IA elle-même. On a longtemps supposé que comprendre une phrase se fait en deux temps : le système construit d'abord une représentation interne de son sens, puis s'en sert pour agir ou répondre. SHRDLU en est l'exemple parfait. Un modèle de langage semble court-circuiter cette étape. Rien, dans son entraînement, ne lui demande de construire une représentation du sens, et ses réponses sont pourtant souvent justes. Si une forme de compréhension peut émerger de la seule prédiction du mot suivant, le schéma est à revoir. L'auteur de ce cours développe cette idée dans un court billet, « Est-ce que ChatGPT sait ce qu'est une question ? ». Il la rapproche de la chambre chinoise de Searle et des jeux de langage de Wittgenstein.

Les deux lectures ne sont pas forcément exclusives. Un modèle peut contenir des représentations partielles du monde, efficaces dans certains domaines et absentes dans d'autres, ce qui expliquerait à la fois ses réussites et ses erreurs étranges. Douglas Hofstadter, dont le Module 1 présentait l'objection à l'IA symbolique, avait longtemps jugé que les machines resteraient loin de la pensée humaine. En 2023, il déclare que les progrès rapides de ces modèles ont fait s'effondrer certaines de ses convictions les plus profondes sur les limites de l'IA.

L'illusion de comprendre

Une partie de la question tient aussi à nous. Le Module 1 présentait ELIZA, le programme de 1966 qui imitait un psychothérapeute en repérant quelques mots-clés. Ses utilisateurs lui prêtaient pourtant une compréhension et des sentiments. Cette tendance à attribuer une intelligence et une intériorité à ce qui produit un langage fluide porte le nom d'**effet ELIZA**. Les modèles actuels sont incomparablement plus capables qu'ELIZA, mais la même tendance joue, d'autant plus fortement

que leurs réponses sont fluides, polies et sûres d'elles. Elle explique en partie l'attachement de certains utilisateurs à des assistants présentés comme des compagnons, et la confiance excessive accordée à leurs réponses.

Deux façons de savoir

Le chapitre « Les hivers et la bascule » du Module 1 annonçait une comparaison entre deux conceptions du savoir. Les systèmes experts et les graphes de connaissances contiennent un savoir **structuré à la main** : chaque fait y est écrit, vérifiable et modifiable, mais il faut l'écrire, et le monde déborde toujours ce qu'on a écrit. Un modèle de langage contient un savoir **absorbé** dans d'énormes quantités de texte : il couvre presque tous les sujets et s'exprime avec souplesse, mais on ne peut ni le lire, ni le vérifier fait par fait, ni le corriger simplement. Les systèmes actuels combinent souvent les deux, par exemple quand un modèle de langage consulte une base de faits avant de répondre.

La question posée au Module 2, sur vingt maisons, prend ici sa forme la plus aiguë : où finit la mémoire, et où commence la compréhension ? Pour un modèle qui a lu une grande partie de ce que l'humanité a écrit, la réponse n'est pas tranchée.

Ce qu'il faut retenir du module

Ce module a commencé sur un paradoxe : un mécanisme d'une simplicité déconcertante, prédire la suite d'un texte, et des capacités qui surprennent jusqu'à leurs auteurs. Les chapitres l'ont décomposé en quelques idées.

1. **Générer, c'est imiter une distribution, puis y tirer des exemples.** C'est le principe commun à tous les modèles génératifs, des images aux voix (« Générer : imiter une distribution »).
2. **Un modèle de langage prédit le mot suivant.** L'idée a soixante-dix ans d'histoire, des règles aux n-grammes, puis aux plongements et au Transformer (« Des règles aux probabilités », « Prédire le mot suivant »).
3. **L'échelle a tout changé, de façon en partie prévisible** (« Passer à l'échelle »).
4. **Un modèle de base n'est pas un assistant.** L'ajustement, les préférences humaines et les récompenses vérifiables en font un (« Du modèle à l'assistant »).
5. **Le modèle ne fait que du texte ; son harnais fait le reste.** La mémoire apparente, les outils et les actions viennent du programme qui l'entoure : le modèle propose, le harnais dispose (« Des outils, un harnais et des agents »).
6. **La vérification fait la fiabilité.** Les tests guident les agents de programmation, et une preuve acceptée par Lean n'a pas à être crue sur parole (« Programmer avec des agents », « Démontrer »). Mesurer l'intelligence elle-même reste difficile (« Le défi ARC »).
7. **Les mêmes idées s'étendent aux images et aux sons**, devenus eux aussi des jetons (« Des modèles qui voient, entendent et parlent »).
8. **L'intérieur des modèles commence à se lire.** On y trouve des concepts superposés, que l'on peut démêler, et des étapes de calcul que le texte produit ne montre pas (« Regarder à l'intérieur »).
9. **Ces modèles ont des limites caractéristiques** : ils hallucinent, ne voient pas les lettres de leurs jetons, et n'apprennent rien de leurs conversations.

Le mécanisme de départ n'a pas changé : prédire la suite. Ce qui a changé, c'est l'échelle à laquelle on l'applique, ce qu'on apprend aux modèles ensuite, et ce qu'on construit autour d'eux. Savoir

si cela suffit pour comprendre reste une question ouverte. Le Module 5 la reprend sous son angle philosophique, avec l'argument de la chambre chinoise de Searle, évoqué plus haut, et aborde les conséquences de ces modèles pour la société.

Un modèle de langage dans un tableur (travail noté 4)

Ce travail construit, dans Google Sheets, un modèle de langage miniature : un modèle à **bigrammes**, qui donne la probabilité de chaque mot d'après le mot qui le précède. C'est le principe des n-grammes présenté au chapitre « Des règles aux probabilités », avec $n = 2$. Le modèle est ensuite utilisé pour **générer** du texte, en tirant chaque mot au hasard selon ces probabilités, comme le font, à une tout autre échelle, les grands modèles de langage.

Un exercice simple, à dessein
Après les Transformer, les assistants, les agents et l'interprétabilité, un modèle à bigrammes construit dans un tableur peut sembler dérisoire. Il est pourtant choisi pour cette simplicité. Il isole, sans rien autour, l'idée sur laquelle reposent tous les grands modèles de langage : estimer, à partir d'un corpus, la probabilité de chaque mot d'après ceux qui le précèdent, puis générer un texte en tirant les mots un à un selon ces probabilités. Le modèle de ChatGPT ne fait pas autre chose. Ce qui change, c'est la façon de calculer ces probabilités : un réseau de neurones, qui tient compte de milliers de jetons précédents au lieu d'un seul, et qui généralise à des suites jamais vues au lieu de compter des exemples. Le tableau « Ce qui a changé, ce qui est resté » fait la liste de ces différences, et de ce qui n'a pas bougé depuis les n-grammes.

Avant de commencer

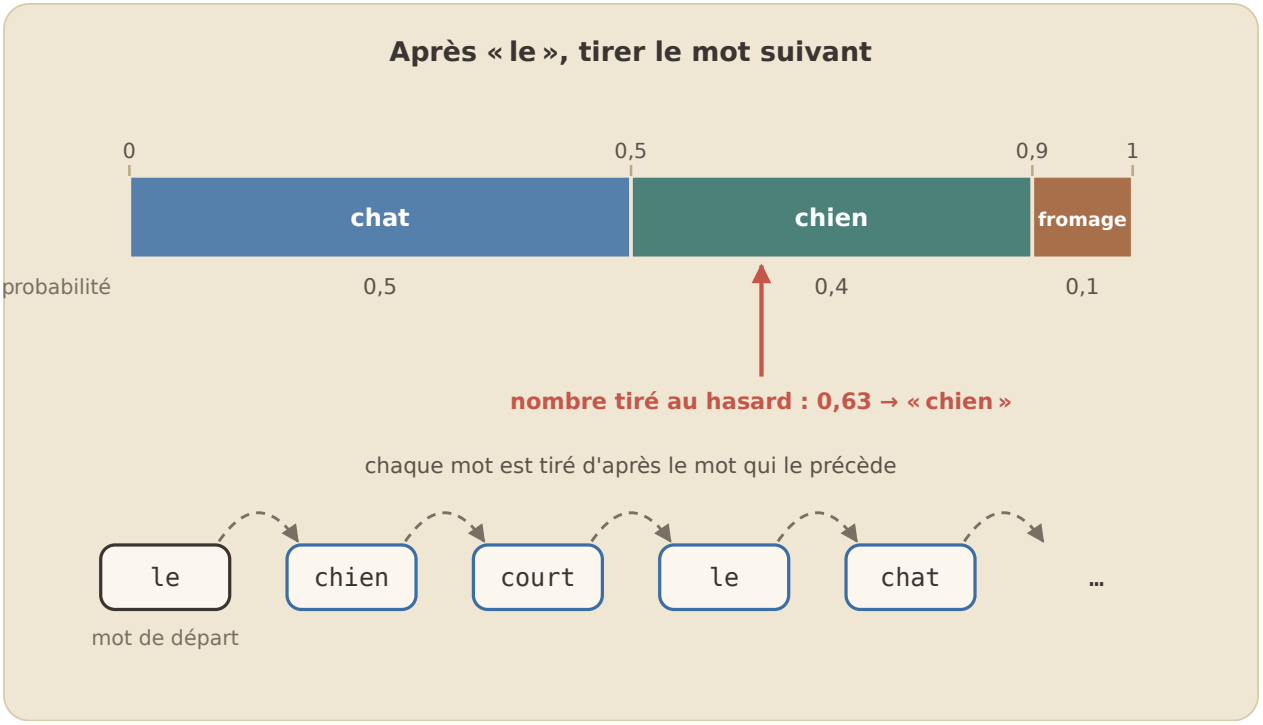
- Un modèle de langage n'est pas une description abstraite de la langue. C'est un modèle statistique entraîné sur un texte particulier, le **corpus d'entraînement**. Deux modèles entraînés l'un sur des romans du XIXe siècle, l'autre sur des messages de réseaux sociaux, donneraient des probabilités très différentes.
- Le modèle calcule une probabilité conditionnelle, notée avec une barre verticale, qui se lit « étant donné » :

$$P(\text{mot suivant} \mid \text{mot précédent})$$

- Le modèle du travail noté 2 classait des courriels. Il reposait sur une description de chaque classe, retournée par le théorème de Bayes : c'était un modèle génératif utilisé pour classer. Le modèle de ce travail est utilisé pour ce qu'il est : un modèle qui génère.
- Vérifiez d'abord que votre Google Sheets est correctement configuré.

Générer un texte avec ce modèle revient à tirer chaque mot au hasard, selon les probabilités qui dépendent du mot précédent. La figure ci-dessous montre un tirage après le mot « le », avec les

probabilités que vous allez calculer.



Tirer le mot suivant : on place les probabilités bout à bout entre 0 et 1, on tire un nombre au hasard, et on prend le mot dans le segment duquel il tombe. La formule de génération du tableur fait exactement ce calcul.

Consignes

1. Construisez le fichier Google Sheets en suivant les étapes ci-dessous.
2. Une fois le fichier complet et fonctionnel, partagez-le, et copiez son lien dans un document PDF (**aucun autre format ne sera accepté**).
3. Répondez aux questions de la fin de cette page dans le même document PDF, de façon claire et précise.

Entraînement du modèle

Copiez les mots du texte suivant dans la colonne `A` d'une nouvelle feuille, un mot par rangée. Utilisez correctement la fonction copier-coller de Google Sheets.

```
le
chat
dort
le
chien
mange
le
chat
mange
```

```
une
souris
le
chien
dort
la
souris
court
la
souris
mange
le
fromage
le
chat
court
le
chien
voit
le
chat
le
chat
voit
la
souris
le
chien
court
```

Ces 38 mots forment le corpus d'entraînement, le texte à partir duquel le modèle calcule ses paramètres. Pour les vrais modèles de langage, ce corpus contient une grande partie du texte disponible sur le Web, comme les archives de Common Crawl.

Dans la cellule `B1`, entrez la formule suivante :

```
=A2
```

Étendez la colonne `B` jusqu'à la cellule `B37`, en double-cliquant sur le petit carré qui apparaît au coin inférieur droit de la cellule `B1` quand on la sélectionne. Google Sheets peut aussi proposer de le faire automatiquement.

Dans la cellule `C1`, entrez la formule suivante, puis étendez-la jusqu'à `C37` :

```
=A1 & " " & B1
```

	A	B	C	D	E	F	G
1	le	chat	le chat				
2	chat	dort	chat dort				
3	dort	le	dort le				
4	le	chien	le chien				
5	chien	mange	chien mange				
6	mange	le	mange le				
7	le	chat	le chat				
8	chat	mange	chat mange				
9	mange	une	mange une				
10	une	souris	une souris				
11	souris	le	souris le				
12	le	chien	le chien				
13	chien	dort	chien dort				
14	dort	la	dort la				
15	la	souris	la souris				
16	souris	court	souris court				
17	court	la	court la				
18	la	souris	la souris				
19	souris	mange	souris mange				
20	mange	le	mange le				
21	le	fromage	le fromage				
22	fromage	le	fromage le				
23	le	chat	le chat				
24	chat	court	chat court				
25	court	le	court le				
26	le	chien	le chien				
27	chien	voit	chien voit				
28	voit	le	voit le				
29	le	chat	le chat				
30	chat	le	chat le				
31	le	chat	le chat				
32	chat	voit	chat voit				
33	voit	la	voit la				
34	la	souris	la souris				
35	souris	le	souris le				
36	le	chien	le chien				
37	chien	court	chien court				
38	court						
39							

Les trois premières colonnes : chaque mot, le mot qui le suit, et le bigramme qu'ils forment.

La colonne `C` contient maintenant tous les **bigrammes** du corpus, c'est-à-dire toutes les suites de deux mots consécutifs. La colonne `B` ne sert qu'à les obtenir facilement.

Dans la colonne `D`, comptez combien de fois chaque bigramme apparaît dans le corpus, avec la formule suivante, étendue jusqu'à `D37` :

```
=COUNTIF(C:C, C1)
```

> Si la formule produit une erreur, vérifiez les paramètres linguistiques de votre Google Sheets.

Le bigramme `le chien` apparaît par exemple 4 fois, et le bigramme `fromage le` une seule fois.

La colonne `E` calcule les **paramètres** du modèle, c'est-à-dire la probabilité d'un mot étant donné le mot qui le précède :

$$P(\text{mot de la colonne B} \mid \text{mot de la colonne A}) = \frac{\text{nombre de fois où le bigramme A B apparaît}}{\text{nombre de fois où le mot A apparaît}}$$

Entrez dans la cellule `E1` la formule suivante, et étendez-la jusqu'à `E37`. Elle compte les mots de la colonne `A` sauf le dernier, qui n'est suivi d'aucun mot et fausserait légèrement les probabilités :

```
=D1 / COUNTIF(A$1:INDEX(A:A, COUNTA(A:A)-1), A1)
```

Le dénominateur est toujours supérieur ou égal au numérateur, et chaque valeur est donc une probabilité comprise entre 0 et 1.

Dans la colonne `F`, gardez une seule fois chaque bigramme, ce qui donne 26 bigrammes différents :

```
=SORT(UNIQUE(C:C))
```

Séparez ensuite les deux mots de chacun de ces bigrammes, le premier dans la colonne `G` :

```
=INDEX(SPLIT(F1, " "), 1)
```

et le second dans la colonne `H` :

```
=INDEX(SPLIT(F1, " "), 2)
```

Enfin, la colonne `I` reprend la probabilité correspondante de la colonne `E` :

```
=INDEX(E:E, MATCH(F1, C:C, 0))
```

On constate par exemple que le mot `la` est toujours suivi du mot `souris`, avec une probabilité de 1, tandis que le mot `le` peut être suivi de `chat`, `chien` ou `fromage`, avec des probabilités de 0,5, 0,4 et 0,1.

I1 ▾ | *fx* =INDEX(E:E, MATCH(F1, C:C, 0))

	A	B	C	D	E	F	G	H	I	J
1	le	chat	le chat	5	0.5	chat court	chat	court	0.2	
2	chat	dort	chat dort	1	0.2	chat dort	chat	dort	0.2	
3	dort	le	dort le	1	0.5	chat le	chat	le	0.2	
4	le	chien	le chien	4	0.4	chat mange	chat	mange	0.2	
5	chien	mange	chien mange	1	0.25	chat voit	chat	voit	0.2	
6	mange	le	mange le	2	0.6666666667	chien court	chien	court	0.25	
7	le	chat	le chat	5	0.5	chien dort	chien	dort	0.25	
8	chat	mange	chat mange	1	0.2	chien mange	chien	mange	0.25	
9	mange	une	mange une	1	0.3333333333	chien voit	chien	voit	0.25	
10	une	souris	une souris	1	1	court la	court	la	0.5	
11	souris	le	souris le	2	0.5	court le	court	le	0.5	
12	le	chien	le chien	4	0.4	dort la	dort	la	0.5	
13	chien	dort	chien dort	1	0.25	dort le	dort	le	0.5	
14	dort	la	dort la	1	0.5	fromage le	fromage	le	1	
15	la	souris	la souris	3	1	la souris	la	souris	1	
16	souris	court	souris court	1	0.25	le chat	le	chat	0.5	
17	court	la	court la	1	0.5	le chien	le	chien	0.4	
18	la	souris	la souris	3	1	le fromage	le	fromage	0.1	
19	souris	mange	souris mange	1	0.25	mange le	mange	le	0.6666666667	
20	mange	le	mange le	2	0.6666666667	mange une	mange	une	0.3333333333	
21	le	fromage	le fromage	1	0.1	souris court	souris	court	0.25	
22	fromage	le	fromage le	1	1	souris le	souris	le	0.5	
23	le	chat	le chat	5	0.5	souris mange	souris	mange	0.25	
24	chat	court	chat court	1	0.2	une souris	une	souris	1	
25	court	le	court le	1	0.5	voit la	voit	la	0.5	
26	le	chien	le chien	4	0.4	voit le	voit	le	0.5	
27	chien	voit	chien voit	1	0.25					
28	voit	le	voit le	1	0.5					
29	le	chat	le chat	5	0.5					
30	chat	le	chat le	1	0.2					
31	le	chat	le chat	5	0.5					
32	chat	voit	chat voit	1	0.2					
33	voit	la	voit la	1	0.5					
34	la	souris	la souris	3	1					
35	souris	le	souris le	2	0.5					
36	le	chien	le chien	4	0.4					
37	chien	court	chien court	1	0.25					
38	court									

Le modèle complet : les colonnes G, H et I donnent, pour chaque mot, les mots qui peuvent le suivre et leur probabilité.

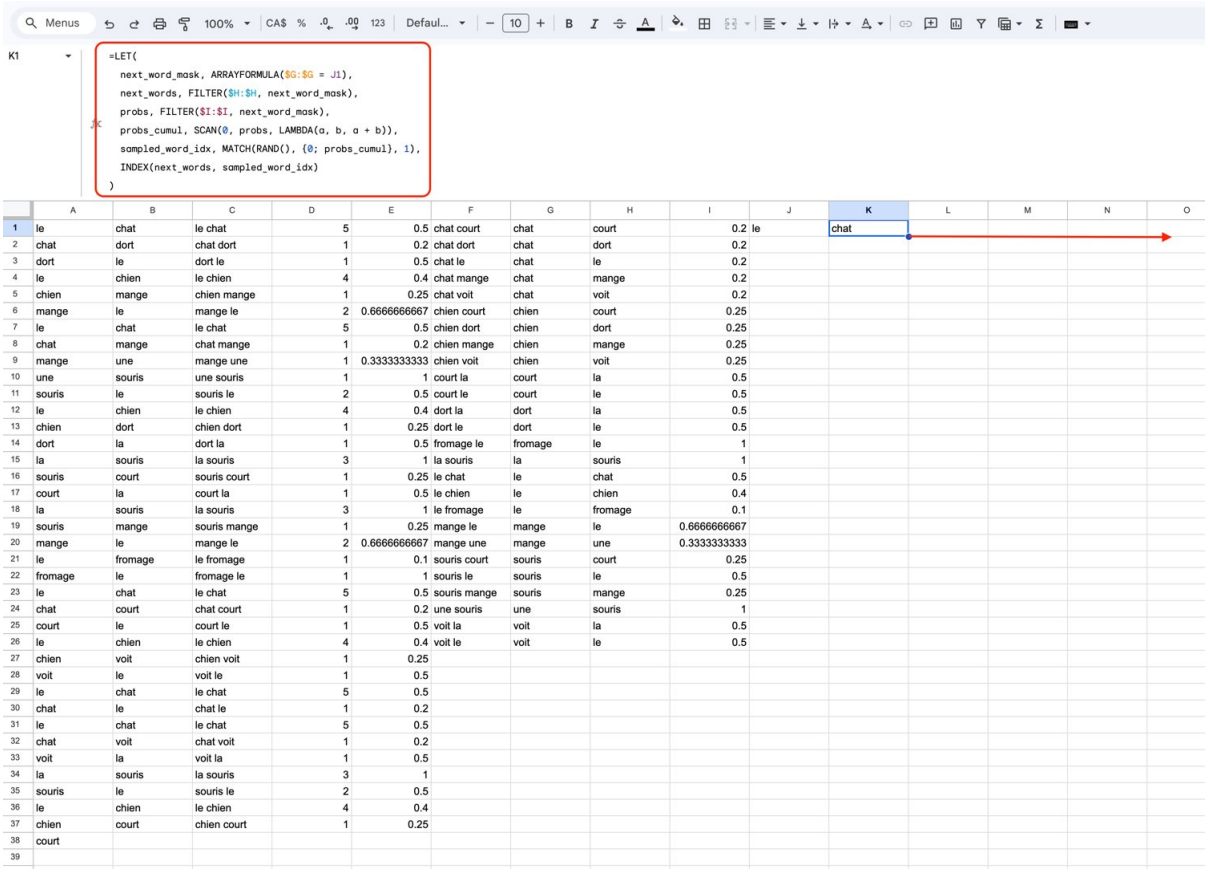
Utilisation du modèle (inférence)

Le modèle est maintenant entraîné : ses paramètres sont calculés. On peut s'en servir pour générer un texte nouveau, en tirant les mots au hasard.

Entrez un premier mot dans la cellule `J1`, par exemple `le`. Ce mot doit faire partie du vocabulaire du modèle. Entrez ensuite la formule suivante dans la cellule `K1` si vous voulez générer les mots à l'horizontale, ou dans la cellule `J2` si vous voulez les générer à la verticale :

```
=LET(
  next_word_mask, ARRAYFORMULA($G:$G = J1),
  next_words, FILTER($H:$H, next_word_mask),
  probs, FILTER($I:$I, next_word_mask),
  probs_cumul, SCAN(0, probs, LAMBDA(a, b, a + b)),
  sampled_word_idx, MATCH(RAND(), {0; probs_cumul}, 1),
  INDEX(next_words, sampled_word_idx)
)
```

> Cette formule s'étend sur plusieurs lignes. Entrez-la dans la barre de formule, en haut de la feuille, plutôt que directement dans la cellule.



La génération : la cellule K1 tire un mot d'après le mot de J1 ; en étendant la formule vers la droite, chaque cellule tire un mot d'après la précédente.

La formule fait trois choses.

1. Elle retrouve les mots qui peuvent suivre le mot de départ, et leurs probabilités.
2. Elle place ces probabilités bout à bout entre 0 et 1, en calculant leurs sommes successives (les probabilités cumulées).
3. Elle tire un nombre au hasard entre 0 et 1, avec `RAND()`, et choisit le mot dans le segment duquel ce nombre tombe, comme dans la figure du début de cette page.

Pour continuer la génération, étendez la formule vers la droite (à partir de `K1`) ou vers le bas (à partir de `J2`). Chaque nouvelle modification de la feuille relance les tirages, et produit donc un nouveau texte.

Questions

Le modèle et ses paramètres

1. Quels sont les paramètres du modèle ? Indiquez précisément les colonnes qui les contiennent.
2. Expliquez dans vos mots comment ces paramètres sont calculés.
3. En quoi la colonne `B` de ce modèle diffère-t-elle de la colonne `B` du modèle de classification des courriels du travail noté 2 ?
4. Expliquez pourquoi le modèle de classification du travail noté 2 était utilisé comme un modèle discriminatif, alors que ce modèle de langage est utilisé comme un modèle génératif. (Voir « Décrire plutôt que séparer ».)

Ce que le corpus enseigne au modèle

5. Quelle est la conséquence du fait que le bigramme `le chat` apparaisse 5 fois dans le corpus d'entraînement ?
6. Quelle est la conséquence du fait que le bigramme `la souris` apparaisse 3 fois, et en quoi cette situation diffère-t-elle de celle de la question 5 ?
7. Certains bigrammes permettent-ils de générer des suites moins grammaticales ? Lesquels, en particulier ?
8. Certains bigrammes permettent-ils de générer des suites dont le sens est étrange ? Lesquels, en particulier ?
9. Le modèle peut-il générer un bigramme qui ne fait pas partie de ses exemples d'entraînement ? Expliquez.

Générer

10. Supposons que le modèle ait généré le mot `voit`. Expliquez la conséquence du choix du mot suivant sur la suite de la phrase générée.
11. La longueur des phrases générées par le modèle est-elle limitée ? Expliquez.
12. Le chapitre « Générer » présente la température. Comment le texte généré changerait-il si l'on tirait toujours le mot le plus probable, ce qui correspond à une température très basse ? Donnez

un exemple à partir du mot `le`. Que faire quand plusieurs mots sont à égalité ? Dans ce cas, vous pouvez choisir le premier dans l'ordre alphabétique.

Les limites du modèle, et les grands modèles de langage

13. De quel type d'apprentissage s'agit-il : supervisé, non supervisé ou auto-supervisé ? Justifiez votre réponse. (Voir « Trois façons d'apprendre ».)
14. Qu'est-ce qui changerait si l'on utilisait un modèle à trigrammes plutôt qu'à bigrammes ? Quelles seraient les contraintes de ce choix ? Vous pouvez comparer les tailles 2 et 3 dans l'applet du chapitre « Des règles aux probabilités ».
15. Expliquez les limites de ce modèle quant à sa capacité de généralisation. À quoi sont-elles dues, et comment le modèle neuronal de 2003 présenté au chapitre « Prédire le mot suivant » les dépasse-t-il ?
16. Comment pourrait-on faire en sorte que le modèle génère des phrases complètes, avec un début et une fin ? Indice : pensez au jeton spécial qui marque la fin d'un texte dans les grands modèles de langage.

Pour aller plus loin

Le podcast MLST

Le podcast Machine Learning Street Talk (en anglais seulement) est un excellent mélange de discussions philosophiques, scientifiques et techniques à propos de ce qui se passe en IA :

Vidéo : https://www.youtube.com/playlist?list=UUMLtBahI5DMrt0NPvDSoIRQ

Présentations diverses

Cette présentation (en anglais seulement) fait un excellent survol des liens profonds entre les mathématiques, la philosophie et l'intelligence artificielle :

Vidéo : https://www.youtube.com/watch?v=Lqt7TgYk8rU

Transcription traduite en français

En gros, on y présente 4 paradigmes mathématiques et leur correspondance dans le monde de l'intelligence artificielle :

1. L'algèbre booléenne et l'intelligence "classique" (GOFAI)
2. Les espaces vectoriels et l'apprentissage automatique
3. Les "variétés" (manifolds) et les espaces latents
4. La symétrie et l'invariance

Conclusion

Merci d'avoir participé à ce cours d'initiation à l'IA !

Au fil des modules, vous avez découvert les fondements de l'intelligence artificielle, ses principaux paradigmes, les réseaux de neurones, l'apprentissage automatique, l'IA générative et les grands modèles de langage. Vous avez exploré les enjeux techniques, philosophiques et éthiques qui accompagnent le développement de ces technologies.

L'IA transforme déjà de nombreux domaines : santé, éducation, industrie, arts, communication… Elle ouvre des perspectives fascinantes, mais soulève aussi des questions sur la responsabilité, la transparence et l'impact social.

Nous espérons que ce parcours vous a permis de mieux comprendre les mécanismes de l'IA, d'en saisir les opportunités et les limites, et de développer un regard critique et informé sur ses usages.

L'aventure ne fait que commencer : continuez à explorer, à questionner et à apprendre !